

陈希孺文集

广义线性模型的 拟似然法

陈希孺 / 著

中国科学技术大学出版社

广义线性模型的 拟似然法

陈希孺 / 著

内 容 简 介

本书是一本广义线性模型理论的入门用书,内容除了广义线性模型的建模方法外,主要是关于广义线性模型的几种基本统计推断形式(极大似然估计、假设检验和拟似然估计)的大样本理论,最后一章讲述了广义线性模型的模型选择和诊断.

本书可作为高等学校数理统计专业的教材,也可供相关专业人员参考

图书在版编目(CIP)数据

广义线性模型的拟似然法/陈希孺著. —合肥:中国科学技术大学出版社,
2011.1

(陈希孺文集)

ISBN 978-7-312-02284-5

I. 广… II. 陈… III. 线性模型—研究 IV. O212

中国版本图书馆 CIP 数据核字(2010)第 159275 号

- 出版** 中国科学技术大学出版社
安徽省合肥市金寨路 96 号,邮编: 230026
网址: <http://press.ustc.edu.cn>
- 印刷** 合肥晓星印刷有限责任公司
- 发行** 中国科学技术大学出版社
- 经销** 全国新华书店
- 开本** 710mm×960mm 1/16
- 印张** 11.25
- 插页** 1
- 字数** 207 千
- 版次** 2011 年 1 月第 1 版
- 印次** 2011 年 1 月第 1 次印刷
- 定价** 25.00 元

总 序

陈希孺先生是我国杰出的数理统计学家和教育家, 1934 年 2 月出生于湖南望城, 1956 年毕业于武汉大学数学系, 先后在中国科学院数学研究所、中国科学技术大学数学系和中国科学院研究生院工作, 1980 年晋升为教授, 1997 年当选为中国科学院院士, 并先后当选为国际统计学会 (ISI) 的会员和国际数理统计学会 (IMS) 的会士. 陈先生的毕生精力都贡献给了我国的科学事业和教育事业, 取得了令人瞩目的成就, 做出了若干具有国际影响的重要工作, 这些基本上反映在他颇丰的著述中: 出版专著和教科书 14 部, 统计学科普读物 3 部. 在陈先生的诸多著作中, 教科书占据重要的位置, 一直被广泛用作本科生和研究生的基础课教材, 在青年教师和研究人员中也拥有众多读者, 影响了我国统计学界几代人.


陈希孺先生多年来一直参与概率统计界的学术领导工作, 尤其致力于人才培养和统计队伍的建设. 在经过“文革”十年的停顿, 我国统计队伍十分衰微的情况下, 他多次主办全国性的统计讲习班, 带领、培养和联系了一批人投入研究工作, 这对于我国数理统计队伍的振兴和壮大起到了重要作用. 陈先生在中国科学技术大学数学系任教长达 26 年之久, 在教书育人和学科建设等方面做出了重要贡献. 中国科学技术大学概率统计学科及其博士点能有今天

这样的发展,毋庸置疑,是与陈先生奠基性的工作以及一贯的悉心指导和关怀完全分不开的。

陈希孺先生是我十分敬重的一位数学家. 1983 年我国首批授予博士学位的 18 人中,就有 3 位出自他的门下,一时传为佳话. 令人扼腕浩叹的是,陈先生已于 3 年前过早地离开了我们. 我坚信,陈先生在逆境中奋发求学的坚强意志,敦厚的为人品格,严谨的治学态度,奖掖后学的高尚风范,连同他的大量著作,将会成为激励我们前行的一笔非常宝贵的精神财富。

这次出版的《陈希孺文集》,是在陈希孺先生的夫人朱锡纯先生授权下,由中国科学技术大学出版社编辑出版的. 该文集收集了陈先生各个时期已出版的著述和部分遗稿,迄今最为全面地反映了陈先生一生的科研和教学成果,一定会对学术界和教育界具有重要的参考价值. 值得一提的是,中国科学技术大学出版社决定以该文集出版的经营收益设立“陈希孺统计学奖”,我想,这应该可以看做我们全体中国科学技术大学师生员工对为学校的发展做出贡献的老一辈科学家和教育家的一种敬仰和感念吧!

中国科学技术大学校长
中国科学院院士

A handwritten signature in black ink, reading '侯建国' (Hou Jian'guo), the name of the President of the University of Science and Technology of China.

2008 年初冬于中国科学技术大学

前 言

本书是在陈希孺先生遗留手稿的基础上整理出版的. 2003 年, 陈先生分别在武汉大学和中国科学技术大学讲授了“广义线性模型中的拟似然方法”这个专题, 当时武汉大学将讲稿印刷了一些给参加学习者使用. 在中国科学技术大学讲学期间, 中国科学技术大学出版社向陈先生约稿, 他答应在对书稿加以修改和充实后将其付梓. 陈先生 2005 年 8 月因病去世后, 在其夫人朱锡纯先生的授权下, 出版社将陈先生的书稿整理作为陈希孺文集中的一本出版.

本书是一本广义线性模型理论的入门用书, 内容除了广义线性模型的建模方法外, 主要是关于广义线性模型的几种基本统计推断形式(极大似然估计、假设检验和拟似然估计)的大样本理论, 最后一章讲述了广义线性模型的模型选择和诊断.

本书可作为高等学校数理统计专业的教材, 也可供相关专业人员参考.

目 次

001 总序

003 前言

001 引言

005 第 1 章 建模问题

006 1.1 一维广义线性回归

018 1.2 多维广义线性回归

043 第 2 章 广义线性回归极大似然估计的大样本理论

044 2.1 向量函数导数

049 2.2 自然联系

075 2.3 非自然联系

100 2.4 拟似然估计

131 第 3 章 GLM 参数的假设检验

132 3.1 Wald 检验

135 3.2 约束检验

139 3.3 似然比检验

143 第4章 模型的选择与诊断

144 4.1 p 值或拟合优度

152 4.2 模型选择

158 4.3 诊断问题

引 言

广义线性模型(Generalized Linear Models, GLM) 的名称最早是 1972 年由 Nelder 和 Wedderburn 在《Generalized Linear Models》(J. Roy. Statist. Soc., Ser. A; 370 ~ 384) 一文中引进的, 其个别特例, 尤其是 Logistic 模型、Probit 模型等, 可追溯到 1920 年.

GLM 一提出即受到统计学界很大的重视. Green 和 Silverman 在其 1994 年的著作《Nonparametric Regression and Generalized Linear Models》中认为 “One of the most important developments in statistics in the last 25 years has been the introduction and widespread use of GLM”. 自 1970 年以来发表的有关论文以千计, 其中绝大部分是应用性的. 1983 年 McCullagh 和 Nelder 出版了大部分的同名著作, 1989 年出了第 2 版.

GLM 的提出源于线性回归在应用上有重要影响的两个缺点, 一是它只适用于因变量 y 取连续值的情况, 它特别不适用于分类数据 (如 y 取 0, 1 为值). 二是 y 的期望 $E(y)$ 与自变量 x 是用线性关系

$$E(y) = z'(x)\beta$$

相联系 ($z(x)$ 由 x 决定, 例如 $z(x)$ 可以是 x 的各分量的一个多项式) 的. 选择面太窄, 往往与实际情况不符. 另外, 线性回归的统计推断基本上只适用于误差正态的情形, 在某些 y 取连续值的场合, y 的分布是偏态的, 如指数分布、Gamma 分布之类. 在这类场合, 线性回归不是一个合适的工具.

GLM 的特点正好是对应上面指出的问题:

1. 因变量 y 可以取连续值或离散值, 从常见的应用看, 取离散值的场合更重要.

2. 取代 $E(y) = z'(x)\beta$, 有

$$E(y) = h(z'(x)\beta)$$

函数 h (其反函数 g 称为联系 (或连接) 函数 (link function)) 有较大的选择余地, 这样扩大了模型的适用面.

3. y (q 维) 有指数型分布

$$y \sim \exp(\theta'y - b(\theta))d\mu(y)$$

其中, θ 为 q 维参数向量, μ 是 $\mathbb{R}^q$ 上的 σ 有限测度, μ 与 θ 无关 (或联系函数 $g = h^{-1}$ 使 $\theta = g[E(y)]$, 即 $\theta = z'(x)\beta$, 称自然联系).

指数型分布是一个适中的选择, 一方面它包括了应用上最常见的一些分布: 二项分布、多项分布、Poisson 分布, 以及连续型的正态分布、指数分布、Gamma 分布等. 另一方面, 这分布类有很好的分析性质, 又便于理论上的研究.

例如 Poisson 分布

$$P(Y = y) = \frac{1}{y!} e^{-\lambda} \lambda^y \quad (y = 0, 1, \dots)$$

可写为标准形式.

广义线性模型主要用于因变量取离散值的情况. 当可能值为一切自然数 $0, 1, 2, \dots$ 时, 多用 Poisson 分布, 当 y 取有限个值(实际是响应可以有有限个状态)时, 多项分布是自然的选择. 在很大的程度上可以说, 广义线性回归就是针对这种情况的回归分析. 在具体定模型时, 需要考虑这有限个状态之间的关系. 一种是无序的, 即各状态的优劣并无公共的认定. 例如外出旅行, 有 k 种交通工具可以选择, 其优劣取决于具体情况而并无公认的排序. 另一种是有序的, 即各状态的优劣次序有公共的认定. 如治疗效果、产品质量的分级等. 不同情况建模方法有所不同. 其详可参看 Fahrmeir 等《Multivariate Statistical Modelling Based on Generalized Linear Models》一书第 3 章.

设有了 n 个独立样本 (y_i, x_i) ($1 \leq i \leq n$). y_i 的分布

$$\exp(\theta_i' y_i - b(\theta_i)) d\mu(y_i) \quad (\theta_i \text{ 的维数 } q_i \text{ 可与 } i \text{ 有关})$$

中的参数 θ_i 与 x_i 有关, 与参数向量 β 之值有关. β 为 p 维的. p 与 y 的维数 q 没有关系(p 与 i 无关).

设 β 的真值为 β_0 , 联系函数 g 的反函数为 h , 则 $E(y_i) = h(z_i' \beta_0)$, $z_i = z(x_i)$ 为 $p \times q$ 矩阵, 其意义已在前面说明. 另一方面, 由上述指数型分布, 易证 $E(y_i) = \frac{\partial b(\theta)}{\partial \theta} \Big|_{\theta=\theta_i} \equiv \dot{b}(\theta_i)$. 故有 $\dot{b}(\theta_i) = h(z_i' \beta)$, 而 $\theta_i = \dot{b}^{-1}(h(z_i' \beta))$. 由此得出样本的(对数)似然函数

$$\begin{aligned} L_n(\beta) &= \sum_{i=1}^n [\theta_i' y_i - b(\theta_i)] \\ &= \sum_{i=1}^n [y_i' b^{-1}(h(z_i' \beta)) - b(\dot{b}^{-1}(h(z_i' \beta)))]. \end{aligned} \quad (1)$$

统计推断的主要任务是估计 β_0 及检验关于 β_0 的假定, 也有和模型诊断有关的问题: 模型与数据的拟合、异常值、强影响点、自变量选择、模型选择等. 在估计上主要使用极大似然估计(MLE) $\hat{\beta}: L_n(\hat{\beta}_n) = \sup_{\beta} L_n(\beta)$, 通常是通过求解下面的似然方程得到基值:

$$\frac{\partial L_n(\beta)}{\partial \beta} \equiv S_n(\beta)$$

$$\equiv \sum_{i=1}^n z_i H(z_i' \beta) \Sigma^{-1}(z_i' \beta) (y_i - h(z_i' \beta)) = 0. \quad (2)$$

记 $h(t) = (h_1(t_1, \dots, t_q), \dots, h_g(t_1, \dots, t_q))'$. 则 $H(t)$ 的 (j, l) 元为 $\partial h_j / \partial t_l$. $\Sigma(z_i' \beta)$ 是 y_i 的协方差阵 $\text{Cov}(y_i)$ (但 β_0 要改为 β), 或

$$\Sigma(t) = b(\dot{b}^{-1}(h(t)))$$

而 $\ddot{b}(\theta) = \partial^2 b(\theta) / \partial \theta \partial \theta'$ 为 q 阶方阵, 其 (j, l) 元为 $\partial^2 b(\theta) / \partial \theta_j \partial \theta_l$ (当 y 有分布 $\exp(y'\theta - b(\theta)) d\mu(y)$ 时, $\text{Cov}(y) = b(\theta)$).

关于(似然方程的根) $\hat{\beta}_n$ 的存在、唯一及 $\hat{\beta}_n$ 的渐近性质的问题, 自 20 世纪 70 年代以来即有不少的研究, 起初的结果是针对某些特殊分布并加上了很强的条件. 1985 年, Fahrmeir 等在其工作《Consistency and asymptotic normality of the MLE in GLM》(Ann. Statist., 1985:342) 中, 在比以往工作更弱的条件下得出了更一般的结果(在 θ_i 的维数 q_i 与 i 无关的条件下), 是这方面的一项重要进展, 不过, 要将其形式上一般的结果用于特例并不容易, 只是在 $\{z_i\}$ 有界或 $\{y_i\}$ 有界(即 y 的分布中那个测度 μ 的支撑为有界)这两种情况, 以及在自然联系(即 $\theta_i = z_i' \beta$ 时, 因 $\theta_i = \dot{b}^{-1}(h(z_i' \beta))$, 这表示要取 $h = \dot{b}$) 时, 才有较理想的结果. 当然, 这包含了应用上最重要的一些情况. 对非自然联系, 要求的条件苛刻. 大体上说, 不能与自然联系偏离太多. 从数学的角度, 还有些精细化的问题可以研究. 但要做出很富有统计应用意义的成果恐怕很难.

第 1 章

建 模 问 题

本章的任务是以广义线性模型为依托,对几类在实用上常见的问题建立其统计模型,而把关于对这种模型进行统计推断的问题留到下一章.

所谓建模,无非是对问题的统计总体概率性质的一种刻画或规定,这种规定可以很细,如给出了分布的具体形式,也可以较粗,如只规定了其均值或均值与方差的形式,在回归性质的问题中,这意味着规定在给定自变量 x 值的条件下,因变量 y 的条件分布 $y | x$,或分布 $y | x$ 的均值与方差等.

建模问题的正确解决在很大程度上依赖于对问题的实际背景以及对所要解决的问题的正确定位.因为,在建模的过程中,往往面临一些选择问题,其解决不可能仅依赖于数学上的考虑,如在回归问题中的自变量的选择,回归函数的形式及误差的分布等等,数学的作用当然也不可忽视,不仅对各种类型的分布的性质了解很有指导意义,还有在自变量的选择中,如问题的实际背景不足以提供一个唯一的合理答案,则数学的方法一般可以提供一种远优于随意选择的答案.在模型的诊断中数学工具也可以发挥重要的作用.

1.1 一维广义线性回归

1.1.1 定义

设有因变量 y , 自变量 x , y 为1维的, x 一般为多维, 通常的线性回归有以下几个特征:

1. $E(y) = \mu = z'(x)\beta$ (线性: 线性指对 β , 而非 x).

$z(x)$ 为 x 的已知(向量)函数^①, z' 表示转置(本书中上标“'”都表示转置, 不是导数), $z(x)$ 常简记为 z .

2. $x, z(x), y$ 都是取连续值的变量, 如农作物产量、人的身高体重之类.

3. y 的分布为正态, 或接近正态之分布.

广义线性回归从以下几方面推广:

① 例如, x 为1维的, $z'(x)$ 可以是 $(1, x), (1, x, x^2), (1, e^x)$ 等, 若 $x = (x_1, x_2)'$, $z(x)$ 可以是 $(1, x_1, x_2)', (1, x_1, x_2, x_1^2, x_2^2, x_1 x_2)$ 等

1° $E(y) = \mu = h(z'\beta)$, h 为一严格单调、充分光滑的函数. h 已知, $g = h^{-1}$ (h 的反函数) 称为**联系函数**(link function), 则有

$$g(\mu) = z'\beta.$$

$E(y)$ 不就等于 $z'\beta$, 而是 $z'\beta$ 的某一函数.

2° $x, z(x), y$ 可取**连续或离散值**, 且在应用上更多见的情况为**离散值**. 如 $\{0, 1\}, \{0, 1, 2, \dots\}$ 等.

3° y 的分布属于指数型, 正态是其一特例.

这里考虑的 y 为 1 维的, 故属于 1 维指数型, 其形式为

$$c(y)\exp(\theta y - b(\theta))d\mu(y), \theta \in \Theta(\text{参数空间}) \quad (1.1)$$

其中, θ 为参数, 称为自然参数, $b(\theta)$ 为 θ 的已知函数, μ 为一测度 (不一定是概率测度), 常见的有两种可能:

a: 当 y 为连续变量时, $d\mu(y)$ 为 Lebesgue 测试: $d\mu(y) = dy$.

b: 当 y 为离散变量时, y 取有限个值 $a_1, \dots, a_m$ 或可列个值 $a_1, a_2, \dots$, 这时 $\mu(\{a_i\}) = 1$ ($i = 1, \dots, m$); 或 $\mu(\{a_i\}) = 1$ ($i = 1, 2, \dots$). (1.2)

故

$$\int_c^d c(y)\exp(\theta y - b(\theta))dy = 1, \quad \text{对一切 } \theta \in \Theta(\text{连续情况}) \quad (1.3)$$

或

$$\sum_i c(a_i)\exp(\theta a_i - b(\theta)) = 1, \quad \text{对一切 } \theta \in \Theta(\text{离散情况}). \quad (1.4)$$

$[c, d]$ (或 $(c, d), (c, d], [c, d)$ 等) 为 y 的取值区间, 可为 $(-\infty, \infty), (0, \infty), (-\infty, 0)$ 或任何其他有限或无限区间. 离散情况, $c(a_i)\exp(\theta a_i - b(\theta))$ 为 y 取 a_i 的概率 (参数为 θ 时). 关于指数型的讨论见 1.1.4 小节. 此处指出: 若 y 有分布 (1.1) 式, 则

$$E(y) = \dot{b}(\theta) (= db(\theta)/d\theta), \quad \text{Var}(y) = b(\theta) (= d^2 b(\theta)/d\theta^2), \quad (1.5)$$

事实上, 在 (1.3) 式两边对 θ 求导, 有

$$\int_c^d (y - \dot{b}(\theta))c(y)\exp(\theta y - b(\theta))dy = 0. \quad (1.6)$$

注意到 (1.3) 式, 以及 $E(y) = \int_c^d yc(y)\exp(\theta y - b(\theta))dy$, 得 (1.5) 式的第一式——此处及以下在积分号下求导的合理性将在后面证明, 再在 (1.6) 式两边对 θ 求导, 有

$$\int_c^d [y - \dot{b}(\theta)]^2 c(y)\exp(\theta y - b(\theta))dy - b(\theta) \int_c^d c(y)\exp(\theta y - b(\theta))dy = 0,$$

此式左边第一项为 $\text{Var}(y)$, 第二项为 $\ddot{b}(\theta)$. 故得式(1.5)式的第二式.

例 1.1 研究一些因素(自变量)对“剖腹产后是否有感染”的影响:

$$y = \begin{cases} 1, & \text{有感染;} \\ 0, & \text{无感染;} \end{cases}$$

$$x = (x_{(1)}, x_{(2)}, x_{(3)}):$$

$$x_{(1)} = \begin{cases} 1, & \text{剖腹事先未计划} \\ 0, & \text{剖腹事先计划} \end{cases}$$

$$x_{(2)} = \begin{cases} 1, & \text{服用抗生素} \\ 0, & \text{不服用} \end{cases}$$

$$x_{(3)} = \begin{cases} 1, & \text{有危险因子(如产妇有高血压,糖尿病之类)} \\ 0, & \text{无} \end{cases}$$

下标加括号,表明是总体量,以与样本区别.

记 $\pi = p(y = 1)$. 有(对 $y = 0, 1$)

$$\begin{aligned} P(Y = y) &= \pi^y (1 - \pi)^{1-y} = (1 - \pi) \left(\frac{\pi}{1 - \pi} \right)^y \\ &= (1 - \pi) \exp \left(y \log \frac{\pi}{1 - \pi} \right), \end{aligned} \quad (1.7)$$

令 $\theta = \log \frac{\pi}{1 - \pi}$, 则 $1 - \pi = \frac{1}{1 + e^\theta}$, 而(1.7)式可变为

$$P(Y = y) = \exp(\theta y - \log(1 + e^\theta)) \quad (-\infty < \theta < \infty) \quad (1.8)$$

此相当于(1.4)式中 $\{a_1, a_2\} = \{0, 1\}$, $b(\theta) = \log(1 + e^\theta)$, $c(y) = 1$ 的情况, 有

$$\begin{aligned} \dot{b}(\theta) &= e^\theta / (1 + e^\theta) = \pi (= E(y)) \\ \ddot{b}(\theta) &= \frac{e^\theta}{(1 + e^\theta)^2} = \pi(1 - \pi) (= \text{Var}(y)) \end{aligned}$$

与(1.5)式一致.

此例中 z 就取为 x , 引进符号

$$\eta = z'\beta \quad (1.9)$$

对二项分布 $B(n, p)$: $P(Y = y) = \binom{n}{y} p^y (1 - p)^{n-y} = \exp(\theta y - b(\theta)) d\mu(y)$:

$$\theta = \log \frac{p}{1 - p}, b(\theta) = n \log(1 + e^\theta), \mu(\{i\}) = 1 \quad (i = 0, 1, \dots, n).$$

设观察了 n 位产妇,第 i 位的 y 值记为 y_i , z 值记为 z_i (即 $(x_{1i}, x_{2i}, x_{3i})'$), $\eta_i = z_i' \beta$ ($i = 1, \dots, n$). 其中, π, θ 值分别为 π_i, θ_i ($\theta_i = \log \frac{\pi_i}{1 - \pi_i}$). 并设引入了联系函数 $g(\pi_i) = \eta_i$ (注意 $\mu_i = E(y_i) = \pi_i$), 或 $\pi_i = h(\eta_i)$ ($h = g^{-1}$), 则 $\theta_i = \log \frac{h(\eta_i)}{1 - h(\eta_i)}$. 代入(1.8)式中,得 $(y_1, \dots, y_n)$ 的联合概率函数

$$\exp \left\{ \sum_{i=1}^n y_i \log \frac{h(\eta_i)}{1 - h(\eta_i)} + \sum_{i=1}^n \log(1 - h(\eta_i)) \right\}. \quad (1.10)$$

此式依赖 (x_i, y_i) ($1 \leq i \leq n$) 及参数 β . 它通过 $\eta_1, \dots, \eta_n$ 而依赖 β . 利用它可对 β 进行统计推断,例如,判断所提因素对“产后感染”发生概率的影响,推断方法的讨论见后.

例 1.2 研究两种化学物质 TNF 与 IFN 对引发细胞癌变的影响. $x = (x_{(1)}, x_{(2)})'$:

$x_{(1)} = \text{TNF 的剂量}(0, 1, 2, \dots),$

$x_{(2)} = \text{IFN 的剂量}(0, 1, 2, \dots),$

$y = \text{观察到的细胞变异数}(0, 1, 2, \dots).$

决定取 Poisson 分布作为 y 的分布:

$$P(Y = y) = \frac{1}{y!} e^{-\lambda} \lambda^y = \frac{1}{y!} \exp(y \log \lambda - \lambda) \quad (\lambda > 0), \quad (1.11)$$

令 $\theta = \log \lambda$, 有

$$P(Y = y) = \frac{1}{y!} \exp(\theta y - e^\theta) \quad (y = 0, 1, 2, \dots; -\infty < \theta < \infty) \quad (1.12)$$

此相当于(1.4)式中的 $c(y) = 1/y!$, $b(\theta) = e^\theta$, $a_i = i$ ($i = 0, 1, 2, \dots$), 则有

$$\dot{b}(\theta) = \dot{b}(\theta) = e^\theta = \lambda = E(y) = \text{Var}(y),$$

与(1.5)式一致.

引进联系函数 $\eta = g(\mu) = g(\lambda)$ (μ 总用于记 $E(y)$), 或 $\lambda = e^\theta = h(\eta)$ ($h = g^{-1}$), 或 $\theta = \log h(\eta)$, 设作了 n 次观察,第 i 次有 y_i, z_i ($z_i = (x_{1i}, x_{2i})'$ 是 (x_1, x_2) 在第 i 次观察中的取值), 而 λ, θ 值分别为 λ_i, θ_i , 则 $(y_1, \dots, y_n)$ 的联合概率函数为 $(\eta_i = z_i' \beta)$

$$(y_1! \cdots y_n!)^{-1} \exp \left(\sum_{i=1}^n y_i \cdot \log h(\eta_i) - \sum_{i=1}^n h(\eta_i) \right) \quad (1.13)$$

它通过 $\eta_1, \dots, \eta_n$ 而依赖 β , 利用它可对 β 进行统计推断, 以判断两种物质对引发细胞变异的作用如何.

例 1.3 y 是某种极值(水文、地震、材料断裂强度之类), 采用 Gamma(Γ) 分布去描述: y 有密度

$$f(y | \mu, \nu) = \frac{1}{\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^{\nu} y^{\nu-1} \exp\left(-\frac{\nu}{\mu}y\right) I(y > 0) \quad (\mu > 0, \nu > 0). \quad (1.14)$$

$$\begin{aligned} \Gamma(s) &= \int_0^{\infty} e^{-t} t^{s-1} dt \quad (s > 0), \\ \Gamma(n) &= (n-1)! \quad (n = 1, 2, \dots), \\ \Gamma(s+1) &= s\Gamma(s) \end{aligned}$$

则

$$E(y) = \mu, \quad \text{Var}(y) = \mu^2/\nu \quad (1.15)$$

此处关心的参数为 μ , 而 ν 视为冗余参数, 在讨论中, 凡冗余参数(如此处的 ν), 则视之为已知的, 当它确为未知时, 则必须从样本可以估计, 以其估计值代替而视为已知.

令 $\theta = -\frac{\nu}{\mu}$, 将(1.14)式表为

$$\frac{1}{\Gamma(\nu)} y^{\nu-1} \exp(\theta y - (-\nu \log(-\theta))) I(y > 0) \quad (-\infty < \theta < 0). \quad (1.16)$$

(1.16) 式相当于(1.3)式的 $c = 0, d = \infty$, 而由

$$\frac{1}{\Gamma(\nu)} y^{\nu-1} I(y > 0), \quad b(\theta) = -\nu \log(-\theta)$$

得 $E(y) = \dot{b}(\theta) = -\nu/\theta = \mu$, $\text{Var}(y) = b(\theta) = -\nu/\theta^2 = \mu^2/\nu$, 与(1.15)式一致.

引进联系函数 $g, h = g^{-1}$ 则 $-\nu/\theta = \mu = h(\eta)$, 而 $\theta = -\nu/h(\eta)$. 若有样本 $y_1, \dots, y_n, y_i$ 相应的 z 值为 $z_i, \eta_i = z_i'/\beta$, 相应的 θ 值为 $\theta_i = -\nu/h(\eta_i)$. 则 $(y_1, \dots, y_n)$ 的联合密度为

$$\prod_{i=1}^n \frac{1}{\Gamma(\nu)} y_i^{\nu-1} \cdot \exp\left(-\sum_{i=1}^n \frac{\nu}{h(\eta_i)} y_i + \sum_{i=1}^n \nu \log\left(\frac{\nu}{h(\eta_i)}\right)\right). \quad (1.17)$$

它通过 $\eta_1, \dots, \eta_n$ 依赖 β , 利用它对 β 进行统计推断.

提醒要点: ① 当 y 为 1 维时, y 的分布中只能有 1 个未知参数(此例为 μ). 若

有多个参数,剩下的为冗余,它必须已知或可由样本估计,即以估计值为已知值;
 ② 在各次观察中冗余参数不变.如在此例中,相应 y_i 的 μ 值可变,为 μ_i (与此相应, θ 值则为 $\theta_i = -\nu/\mu_i$),但 ν 则不随 i 变化.

例 1.4 y 有正态分布 $N(\mu, \sigma^2)$, 其密度为

$$\frac{1}{\sqrt{2\pi}\sigma} e^{-y^2/(2\sigma^2)} \cdot \exp\left(\frac{\mu}{\sigma^2}y - \frac{1}{2}\left(\frac{\mu}{\sigma}\right)^2\right) \quad (\sigma \text{ 为冗余参数, 已知}). \quad (1.18)$$

令 $\theta: \mu/\sigma^2$, 则 $\mu^2/\sigma^2 = \sigma^2\theta^2$, 而 (1.18) 式可写为

$$\frac{1}{\sqrt{2\pi}\sigma} e^{-y^2/(2\sigma^2)} \cdot \exp\left(\theta y - \frac{\sigma^2}{\mu^2}\theta^2\right) \quad (1.19)$$

此相于 (1.3) 式的 $c = -\infty, d = \infty, c(y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-y^2/(2\sigma^2)}, b(\theta) = \frac{\sigma^2}{2}\theta^2$. 有

$\dot{b}(\theta) = \sigma^2\theta = \mu = E(y), b(\theta) = \sigma^2 = \text{Var}(y)$, 与 (1.5) 式一致. 如取联系函数为 $\mu: z, \beta$, 则与通常线性回归一致; 若取其他联系函数, 则属于广义线性回归.

两点注意:

① 在单指参数族中, 方差是均值的函数 (当然反过来也成立): 因为方差 $b(\theta) > 0$, 故 $\dot{b}(\theta)$ 严格上升. 因此有反函数 $\dot{b}^{-1}$. 故由 $\theta = \dot{b}^{-1}(E(y))$ 有

$$\begin{aligned} \sigma^2 = \text{Var}(y) &= b(\theta) = \dot{b}(\dot{b}^{-1}(E(y))) \\ &= \dot{b}(\dot{b}^{-1}(\mu)) \triangleq \sigma^2(\mu)^\text{①}. \end{aligned} \quad (1.20)$$

在有些实际问题中, 数据显示均值方差之间的关系不符合 (1.20) 式, 这时就不可以使用单参指数族的模型. 在 Γ 函数和正态分布的例中包含了一个冗余参数, 调整它的值有时可以解决上述问题.

② 如在例 1.1 这类例子中, 自变量值的可能组合数很少 (在例 1.1 中只有 $2^3 = 8$ 个). 这时样本呈现分组的状态. 设 $y_1, \dots, y_m$ 是同一 x 值下的 y 样本, 这时往往用于一个样本

$$Y = \sum_{i=1}^m y_i \quad \text{或} \quad \bar{Y} = \sum_{i=1}^m y_i / m$$

取代 $y_1, \dots, y_m$ (即我们只见到 Y 或 $\bar{Y}$ 和 m , 而不一定能见到原始记录 $y_1, \dots$,

① $\sigma^2(\mu)$ 称为“方差函数”: y 的方差 σ^2 作为其均值 μ 的函数.

y_m . 这样做并无损失, 因: ① Y (或 $\bar{Y}$) 是充分统计量, 因此无信息丧失; ② Y (或 $\bar{Y}$) 仍为指数型分布: 当 y_i 有分布 (1.1) 式时

$$Y \text{ 有分布 } c_1(Y) \exp(\theta Y - mb(\theta)) d\mu_1(Y); \quad (1.21)$$

$$\bar{Y} \text{ 有分布 } c_2(\bar{Y}) \exp(\theta m \bar{Y} - mb(\theta)) d\mu_2(\bar{Y}). \quad (1.22)$$

(1.21) 和 (1.22) 式中的 c_1, c_2 及 μ_1, μ_2 可以与 (1.1) 式中的 c 及 μ 不同, 但不失为指数型分布形状. 其中, (1.22) 式非标准形式, 引进新参数 $\tilde{\theta} = m\theta$, 将 (1.22) 式变为

$$c_2(\bar{Y}) \exp\left(\tilde{\theta} \bar{Y} - mb\left(\frac{\tilde{\theta}}{m}\right)\right) d\mu_2(\bar{Y}), \quad (1.23)$$

则成为标准形式, 有

$$E(\bar{Y}) = db_1(\tilde{\theta})/d\tilde{\theta} = \dot{b}(\tilde{\theta}/m) = \dot{b}(\theta) \quad (\text{回顾 } \dot{b}(\theta) = db(\theta)/d\theta)$$

$$\text{Var}(\bar{Y}) = d^2 b_1(\tilde{\theta})/d\tilde{\theta}^2 = m^{-1} \ddot{b}(\tilde{\theta}/m) = m^{-1} \ddot{b}(\theta)$$

即 $E(\bar{Y}) = E(y_i)$, $\text{Var}(\bar{Y}) = \text{Var}(y_i)/m$, 与常见公式符合.

以上的讨论是在 $y_1, \dots, y_m$ 为 iid. 的条件下进行的. 实际问题中这可能不完全成立, 如: ① 同一组 x 值上所观察的 y 值有正相关性; ② 有些未包含在 x 中的因素 (问题中未予考虑或尚未认知) 对各观察值的影响不同, 而使 $y_1, y_2, \dots, y_m$ 不同分布. 这两点总的影 响是加大 $Y = \sum_{i=1}^m y_i$ 的方差, 即比按公式算的 $mb(\theta)$ 大, 称为“超散布性”(over-dispersion). 这个问题的处理见后.

1.1.2 哑(或虚)变量(dummy variable)

设有一个因素(自变量之一)有 k 个“状态”, 我们固然可以用数字 $1, \dots, k$ 来标识它, 但不可用于计算, 因为它们无数量意义. 例如农业试验中, 品种是一个因素, 有 k 类种子. 解决的办法是引进哑变量 $x_1, \dots, x_q$, $q = k - 1$:

$$x_j = \begin{cases} 1, & \text{若样品处在状态 } j (\text{该试验用种子 } j) \\ 0, & \text{其他} \end{cases} \quad (j = 1, \dots, q). \quad (1.24)$$

故

$$x_1 = \dots = x_q = 0, \quad \text{当样品处在状态 } k. \quad (1.25)$$

设这个试验只包含“品种”这一个因素, 模型为

$$E(y) = \beta_0 + \beta_1 x_1 + \dots + \beta_q x_q \quad (y \text{ 为产量}) \quad (1.26)$$

则可见

$$\begin{aligned} E(y \mid \text{状态 } j) &= \beta_0 + \beta_j \quad (j = 1, \dots, q); \\ E(y \mid \text{状态 } k) &= \beta_0. \end{aligned} \quad (1.27)$$

故(1.24)式这种取哑变量法,是以状态 k 作为标准,而 β_j 衡量(在产量上)状态 j 超出状态 k 之值.

另一种取法是($j = 1, \dots, q$)

$$x_j = \begin{cases} 1, & \text{若样品处在状态 } j \\ -1, & \text{若样品处在状态 } k. \\ 0, & \text{其他} \end{cases} \quad (1.28)$$

这时

$$x_1 = \dots = x_q = -1 \quad (\text{样品处在状态 } k). \quad (1.29)$$

因此按(1.26)式,有

$$\begin{aligned} E(y \mid \text{状态 } j) &= \beta_0 + \beta_j \quad (j = 1, \dots, q) \\ E(y \mid \text{状态 } k) &= \beta_0 - (\beta_1 + \dots + \beta_q) \end{aligned} \quad (1.30)$$

于是

$$\frac{1}{k} \sum_{j=1}^k E(y \mid \text{状态 } j) = \beta_0$$

故 β_0 为平均效应,而 β_j ($j \leq q$) 衡量状态 j 效应超出平均之值.

1.1.3 联系函数·自然联系函数

联系函数 $g: g(\mu) = \eta = z'\beta$, $\mu = E(y)$, 其反函数 h 也很常用. 作为联系函数, g 必须严格单调且充分光滑, 即有足够阶数的导数.

有一个特殊的联系函数, 即

$$g = b^{-1} \quad \text{或} \quad h = b \quad (\text{回顾 } \dot{b}(\theta) = db(\theta)/d\theta) \quad (1.31)$$

起着重要的作用, 它称为自然联系函数, 这时有

$$z'\beta = g(\mu) = g(\dot{b}(\theta)) = \theta. \quad (1.32)$$

因此, 指数型分布(1.1)式中的自然参数, 就是 $z'\beta$. 这一重要关系式是“自然联系函数”这一名称的由来. 其方便之处, 目前我们可以看到一点: 若有了样本 $y_1, \dots, y_n$, 与 y_i 相应的 z 值为 z_i , 则 $(y_1, \dots, y_n)$ 的联合密度为

$$\prod_{i=1}^n c(y_i) \cdot \exp(\beta' \sum_{i=1}^n z_i y_i - \sum_{i=1}^n b(z_i' \beta)),$$

其形式比在其他联系函数下来得简单,且由此形式看出 $\sum_{i=1}^n z_i y_i$ 为充分统计量. 其最重要的优点是:它使广义线性模型下统计推断的大样本理论更易处理. 当然,在一个实际问题中选择联系函数,主要应根据问题本身的情况.

例 1.1(续) 因本例 $\pi = \mu$, 自然联系函数由 $z'\beta = \theta = \log \frac{\pi}{1-\pi}$ 确定,即

$$g(t) = \log \frac{t}{1-t} \quad \text{或} \quad h(t) = \frac{e^t}{1+e^t} (= \bar{b}(t)) \quad (1.33)$$

$$\pi = e^{z'\beta} / (1 + e^{z'\beta})$$

这就是很知名很重要的 logit(或 logistic) 模型(logit = logit, 取对数之意), 注意 (1.33) 式右边之值总在 (0,1) 内, 符合 π 作为概率的要求.

一般, $\pi = h(z'\beta)$, 故 h 应满足 $0 < h < 1$, 若 h 为严增, 则 $h(-\infty)$ 一般应为 0, $h(\infty)$ 一般应为 1, 这样 π 可取 (0,1) 内任何值(如果问题的性质限定了 π 只能取 (0,1) 内某个区间中的值, 则另当别论). 因此, h 应为一分布函数, 有几个选择. 在实用中常用到的有

$$h_1(t) = \Phi(t) \quad (N(0,1) \text{ 的分布}); \text{联系函数 } g = \Phi^{-1}, \quad (1.34)$$

称为 probit 模型;

$$h_2(t) = 1 - \exp(-e^t); \text{联系函数 } g(\pi) = \log(-\log(1-\pi)), \quad (1.35)$$

其联系函数的形式使之有 log-log 模型的名称.

(1.33) ~ (1.35) 式这 3 个 $h(t)$ 的图像如图 1.1 所示, 从图像上看, 三者颇有些差距, 尤其是 log-log 与其他两者的差距, 但我们需要注意一点: 选择 $h(t)$ 或选择 $h\left(\frac{t-a}{\sigma}\right)$, 使用极大似然法所作的统计分析, 结果一致. 这里 $\sigma > 0$ 和 a 为常数, 理由如下: 令


$$h_1(t) = h\left(\frac{t-a}{\sigma}\right),$$

现在我们有二个模型:

$$\pi = h(\beta_0 + z'\beta) \quad (1.36)$$

$$\pi = h_1(\beta_0^* + z'\beta^*) = h\left(\frac{\beta_0^* - a}{\sigma} + z'\beta^* / \sigma\right) \quad (1.37)$$

此处已把常数项 β_0 明确标出(在一般理论探讨中, 可设 β_0 已吸入 β 内: 令 $\tilde{z} = \begin{pmatrix} 1 \\ z \end{pmatrix}$, $\tilde{\beta} = \begin{pmatrix} \beta_0 \\ \beta \end{pmatrix}$ 即可) 当有了样本 (z_i, y_i) , $1 \leq i \leq n$ 时, 按 (1.35) 式和 (1.36)

图 1.1 $h(t)$ 的分布图形

式,分别得出两个联合密度:

$$f = \prod_{i=1}^n (h(\beta_0 + z_i' \beta))^{y_i} (1 - h(\beta_0 + z_i' \beta))^{1-y_i}$$

$$f_1 = \prod_{i=1}^n (h(\tilde{\beta}_0 + z_i' \tilde{\beta}))^{y_i} (1 - h(\tilde{\beta}_0 + z_i' \tilde{\beta}))^{1-y_i}$$

$$\tilde{\beta}_0 = \frac{\beta_0^* - a}{\sigma}, \quad \tilde{\beta} = \frac{\beta^*}{\sigma}$$

用极大似然估计,即求 f, f_1 的极大值点,因 f, f_1 形式完全一致,故若以 $\hat{\beta}_0, \hat{\beta}$ 分别记 β_0, β 的极大似然估计,则 $\tilde{\beta}_0, \tilde{\beta}$ 的极大似然估计分别也是 $\hat{\beta}_0, \hat{\beta}$ (即 $\frac{\hat{\beta}_0^* - a}{\sigma} = \hat{\beta}_0, \hat{\beta}^* / \sigma = \hat{\beta}$). 因此 β_0^*, β^* 的极大似然估计分别为

$$\hat{\beta}_0^* = a + \sigma \hat{\beta}, \quad \hat{\beta}^* = \sigma \hat{\beta}$$

以此代入(1.36)式和(1.37)式,得出在这两模型下, π 估计分别为:

按(1.36)式: $h(\hat{\beta}_0 + z' \hat{\beta})$;

按(1.37)式: $h_1(\hat{\beta}_0^* + z' \hat{\beta}^*) = h\left(\frac{a + \sigma \hat{\beta}_0 - a}{\sigma} + z' \sigma \hat{\beta} / \sigma\right) = h(\hat{\beta}_0 + z' \hat{\beta})$.

二者完全一致,故选 h 或 h_1 ,不影响分析结果.

依这个结果,再考察前面(1.33)~(1.35)式定义的 h, h_1, h_2 之间的差距,我们意识到:这差距中有一部分是由于“位置”与“刻度”的差异而来,并非真实的有实际意义的差距,因为,这3个分布的均值,方差分别为

$$h: 0, \pi^2/3; \quad h_1: 0, 1; \quad h_2: -0.5772, \pi^2/6$$

$$\text{Euler 常数} = \lim_{n \rightarrow \infty} \left(\sum_{i=1}^n i^{-1} - \log n \right)$$

我们看出,它们之间有差别,要调整到同一个数再比较,这样,把三者的均值、方差都调整为0,1,这意味着用 $h\left(\frac{\pi}{\sqrt{3}}t\right)$ 取代 h, h_1 不动,而 $h_2(t)$ 用 $h_2(\pi t/\sqrt{6} - 0.5772)$ 取代,经过取代后3个分布的形状如图1.2所示,由图上看,其差距与图1.1比有所接近,尤其是 h 与 h_1 ,因为 h 较易计算,故在实用上用得最多.




图 1.2 $h(t)$ 的分布图形

1.1.4 单参数指数型分布族

单参数指数型分布有形状(1.1)式,把 $e^{b(\theta)}$ 记为 $B(\theta)$, (1.1) 式可写为

$$\int e^{\theta y} c(y) d\mu(y) = B(\theta) \quad (\theta \in \Theta, \text{要求 } B(\theta) < \infty). \quad (1.38)$$

$d\mu(y)$ 或为 dy , 或为“计点测度”(每个点有测度 1), 这时(1.38)式为求和, 也有二者混合的情况, 如在截尾分布, 截尾点的测度大于 0, 而其余处有密度.

(1.38) 式中的 Θ 一般是“使(1.38)式左边的积分有限的一切 θ 之集”, 称为其“自然参数空间”, 在比较少见的情况下, Θ 也可以是自然参数空间的一部分, 不难证明以下的性质:

1° 自然参数空间 Θ 是一个区间, 区间可以有界、一端有界或为 $\mathbb{R}^1$, 可以是开的、闭的、左闭右开或左开右闭, 都有可能.

为此只需证: 若 $\theta_i \in \Theta$ ($i = 1, 2$), $\theta_1 < \theta_2$, 而 $\theta_1 < \theta_0 < \theta_2$, 则 $\theta_0 \in \Theta$. 这由不等式

$$e^{\theta_0 y} \leq e^{\theta_1 y} + e^{\theta_2 y}, \quad \text{对一切 } y$$

立即推出.

2° (1.38) 式左边可以在积分号下对 θ 求任意次导数(在 Θ 的内点处).

我们可以证明一个比这更一般的结果: 对任何可测函数 $d\mu(y)$, 若 θ 是集合

$$\Theta_0 = \left\{ \theta : \int e^{\theta y} |c(y)| d\mu(y) < \infty \right\}$$

的内点, 则积分

$$J(\theta) \triangleq \int e^{\theta y} c(y) d\mu(y)$$

在 θ_0 处可在积分号下求导, 事实上, 因 θ_0 为内点, 存在 $\Delta > 0$ 使 $[\theta_0 - \Delta, \theta_0 + \Delta] \subset \Theta_0$, 找 $h, 0 < |h| < \Delta$, 考察

$$\begin{aligned} [J(\theta_0 + \bar{h}) - J(\theta_0)]/h &= \int (e^{(\theta_0 + \bar{h})y} - e^{\theta_0 y})/h \cdot g d\mu(y) \\ &= \int \frac{e^{hy} - 1}{h} e^{\theta_0 y} g d\mu(y) = \int y e^{h y} e^{\theta_0 y} g d\mu(y) \\ &= \int y e^{(\theta_0 + h)y} g d\mu(y) \quad (g = c(y) d\mu(y)) \quad (1.39) \end{aligned}$$

$\bar{h}$ 介于 0 与 h 之间, 因为 $|\bar{h}| \leq |h|$, 有

$$e^{(\theta_0 + \bar{h})y} \leq e^{-\Delta_1 |y|} (e^{(\theta_0 + \Delta)y} + e^{(\theta_0 - \Delta)y}), \quad \Delta_1 = \Delta - |h| > 0.$$

分为“ $\theta_0 + \bar{h} \geq 0, y \geq 0$ ”, “ $\theta_0 + \bar{h} \geq 0, y < 0$ ”, “ $\theta_0 + \bar{h} < 0, y \geq 0$ ”, “ $\theta_0 + \bar{h} < 0, y < 0$ ”4 个情况证明, 而 $\sup_y |y| e^{-\Delta_1 |y|} \equiv l < \infty$, 故

$$|y e^{h y} e^{\theta_0 y} g| \leq l [e^{(\theta_0 + \Delta)y} + e^{(\theta_0 - \Delta)y}] g \quad (1.40)$$

由于 $\theta_0 \pm \Delta \in \Theta_0$, (1.40) 式右边 $d\mu$ 可积, 故知(1.39)式最后积分中之被积函数受控, 故可在积分号下取极限, 得

$$dJ(\theta_0)/d\theta = \int y e^{\theta_0 y} g d\mu(y)$$

这证明了所要结果.

将此结果用于 $d(y) \equiv 1$, 知(1.38)式可在积分号下求导, 得

$$dB(\theta)/d\theta = \int y e^{\theta y} c(y) d\mu(y) \quad (\theta \text{ 为 } \Theta \text{ 的内点}),$$

再将此结果用于 $d(y) \equiv y$, 得上式右边可在积分号下求导, 有

$$d^2 B(\theta)/d\theta^2 = \int y^2 e^{\theta y} c(y) d\mu(y) \quad (\theta \text{ 为 } \Theta \text{ 的内点}),$$

等等, 这些结果也就给了均值、方差表达式(1.5)一个严格的证明.

通常把单参指数分布族形状写为

$$D(\theta) e^{\theta y} c(y) d\mu(y) = e^{\theta y - b(\theta)} c(y) d\mu(y),$$

相当于 $D(\theta) = e^{-b(\theta)}$, 即 $b(\theta) = -\log D(\theta)$, 而

$$E(y) = \dot{b}(\theta) = -\frac{1}{D(\theta)} \frac{dD(\theta)}{d\theta},$$

$$\text{Var}(y) = \ddot{b}(\theta) = -\frac{1}{D(\theta)} \frac{d^2 D(\theta)}{d\theta^2} + \frac{1}{D^2(\theta)} \left(\frac{dD(\theta)}{d\theta} \right)^2,$$

不如使用(1.1)式的形式那么简单.

从这一结果知, $B(\theta) = e^{b(\theta)}$ 无穷次可导(实际上易证它是复变数 θ 的解析函数), 故 $b(\theta)$ 亦然, 且因 b 的二阶导数 $\ddot{b} > 0$, b 为严凸的. 因此, 在(1.1)式中, $b(\theta)$ 并非是可以任意选择的.

1.2 多维广义线性回归

1.2.1 定义

在1.1节中我们见过几种目标变量 Y 取值的情况: ① 连续取值: 人的身高、元件的寿命之类; ② 取离散值, 但仍有数量意义, 如“受感染细胞数”取 $0, 1, 2, \dots$, 用 Poisson 分布描述; m 个患者中痊愈的个数, 取 $0, 1, \dots, m$ 为值; ③ 变量为属性, 但只有两个状态, 如“产后受感染与否”, 用 $0-1$ 变量描述, $0, 1$ 无数量意义, 只指示有无以上这些情况都可以用一个单变量描述之, 其统计模型取为单参

(数)指数型分布. 另一些情况, 其目标变量 Y 需取为向量的, 如 $Y = (Y_{(1)}, Y_{(2)}) = (\text{身高、体重})$ 这种取连续向量值的目标变量, 如用多元正态为统计模型, 得到熟知的多重线性回归. 除此以外, 还有一种重要情况: Y 取 k 个“状态”之一 ($k \geq 3$). 如在例 1.1 中, 感染可分 2 种类型. 于是每个产妇处在 3 个状态之一: 无感染、I 型感染、II 型感染. 它当然可用 0, 1, 2 这 3 个数字标识. 因此可能会认为, 此例中的目标变量 Y 只取 3 个值 0, 1, 2, 非向量. 但这一看法是错误的, 因为此处 0, 1, 2 并无数量意义, 只是一种“标签”. 正确的做法是如 1.1.2 小节中那样引入“哑变量” $y_{(1)}, \dots, y_{(q)}, q = k - 1$:

$$y_{(j)} = \begin{cases} 1, & \text{若 } y \text{ 取状态 } j \\ 0, & \text{其他} \end{cases} \quad (j = 1, \dots, q), \quad (1.41)$$

而把目标变量 y 定为 $y = (y_{(1)}, \dots, y_{(q)})'$. 它共取 k 个值:

$$a_1 = (1, 0, 0, \dots, 0); \dots; a_j = (0, \dots, 0, 1, 0, \dots, 0); \dots; a_k = (0, \dots, 0).$$

“ $y = a_j$ ” $\Leftrightarrow$ “ y 取状态 j ” ($j = 1, \dots, k$).

一般, 设目标变量 y 为 q 维的: $y = (y_{(1)}, \dots, y_{(q)})$. 它取值于 $\mathbb{R}^q$ 中的一 Borel 集 A , 应用上 A 有两个情况: ① 离散情况, A 为一有限或可列集. 如在上例, 有

$$A = \{a_1, \dots, a_k\}.$$

② 连续情况, A 为 $\mathbb{R}^q$ 中一区间, 即形如

$$A = \{(t_1, \dots, t_q) : a_j < t_j < b_j, j = 1, \dots, q\}$$

之集. 不等号也可改为等号(全为不等号称开区间, 全为等号称闭区间, 左端全为等号右端全为不等号, 称左闭右开区间, 等等, a_j 可为 $-\infty$, b_j 可为 ∞ . 于是有有界区间及无界区间之分别) 与 1 维广义线性模型相似, 多维广义线性模型的一个要素是: y 有指数型分布:

$$c(y) \exp(\theta' y - b(\theta)) d\mu(y) \quad (\theta \in \Theta), \quad (1.42)$$

$\theta = (\theta_{(1)}, \dots, \theta_{(q)})$ 为 q 维参数向量, θ 与模型中一些有实际意义的参数相关联 (见例 1.5), 因

$$\int_A c(y) \exp(\theta' y - b(\theta)) d\mu(y) = 1, \quad (1.43)$$

在积分号下对 θ 求导, 易得

$$\mu \triangleq E(y) = \dot{b}(\theta) \triangleq \frac{\partial b(\theta)}{\partial \theta} = \left(\frac{\partial b}{\partial \theta_{(1)}}, \dots, \frac{\partial b}{\partial \theta_{(q)}} \right)'. \quad (1.44)$$

二次求导, 得

$$\text{Cov}(y) = \ddot{b}(\theta) \triangleq \frac{\partial b(\theta)}{\partial \theta \partial \theta'} = \left(\frac{\partial^2 b}{\partial \theta_i \partial \theta_j} \right)_{i,j=1,\dots,q} \quad (1.45)$$

另一个要素是联系函数,设有自变量 x (向量),它影响目标变量 y 的取值,由 x 产生 $q \times p$ 矩阵 $z' = z'(x)$ (q 是 y 的维数, p 可以任意).例如,在 x 的多项式回归中, z' 包含 x 各分量的一些幂次以及交互乘积等,而 β 为 p 维未知参数.记

$$\eta = z'\beta, \quad (1.46)$$

定义集合 (y 的期望之集合)

$$B = \{\mu: \mu = \int_A y c(y) \exp(\theta'y - b(\theta)) d\mu(\theta), \theta \in \Theta\}, \quad (1.47)$$

即 y 的一切期望值之集,联系函数 g 是一个定义于 B 上取值 $\mathbb{R}^q$ 的充分光滑的函数,满足条件:

$$\mu_1 \neq \mu_2 \Rightarrow g(\mu_1) \neq g(\mu_2) \quad (1.48)$$

$$g(\mu) = \eta = z'\beta \quad (1.49)$$

可以证明(见马尔库什维奇《解析函数论》第1章末):若 Θ 为 $\mathbb{R}^q$ 之开集,则定义于 $C \triangleq g(B)$ 上的, g 的反函数 h ,也是同阶光滑(实际上,在 g 有导数时这结果初等,上引马氏书在于只假定 g 连续而要证 h 连续).有

$$\mu = E(y) = h(z'\beta) \quad (1.50)$$

注意 g, h 和 $z'\beta$, 都是 q 维列向量.

若有了样本 $(y_i, x_i)^{\textcircled{1}}$ ($1 \leq i \leq n$),相应地有 $z_i' \triangleq z'(x_i)$ 及 $\eta_i = z_i'\beta$, 以及 $(\mu_i = E(y_i))$

$$\theta_i = \dot{b}^{-1}(\mu_i) = \dot{b}^{-1}(h(z_i'\beta)), \quad (1.51)$$

得 $(y_1, \dots, y_n)$ 的联合密度

$$\prod_{i=1}^n c(y_i) \exp\left(\sum_{i=1}^n y_i' \dot{b}^{-1}(h(z_i'\beta)) - \sum_{i=1}^n b(\dot{b}^{-1}(h(z_i'\beta)))\right) \quad (1.52)$$

利用它可以对未知参数 β 进行统计推断.

关于在同一自变量 x 值下一些 y 值之和或平均,仍是指数型,情况与1维的完全一样.

多维指数型分布的基本性质也与1维情况相似.主要有两点:

① 注意 $y_{(i)}$ 与 y_i 的分别. $y_{(i)}$ 是 y 的第 i 分量,为1维; y_i 是 y 的观察值,为 q 维.以后都坚持这个写法.

1. 集合 $\{\theta: \int_A c(y) e^{\theta'y} d\mu(y) < \infty\}$ 为一凸集. 这集称为指数型族(1.42)式的自然参数空间. (1.42) 式中的参数空间 Θ 一般就是此集合, 也可以是其一部分.

2. 设 $d(y)$ 为一可测函数, 积分

$$\int c(y) d(y) e^{\theta'y} d\mu(y) \quad (1.53)$$

对 θ 属于某集 A 时存在有限, 而 A 作为 $\mathbb{R}^q$ 之子集有内点, 则在 A 的任一内点处, 积分(1.53)式的任意阶偏导数存在, 且可在积分号下求导. 证明与 y 的维数 $q = 1$ 时同.

3. 设分布族(1.42)式中测度 μ 的支撑有界(即 y 的值域有界), 则 $b(\theta)$ 的任意阶偏导数(它在 Θ 的内部 Θ^0 存在)在 Θ^0 有界.

证明显然. 因为, $b(\theta)$ 的任一 r 阶偏导数可表为一些形如

$$E_{\theta}(y_{(1)}^{j_1} \cdots y_{(q)}^{j_q}) \quad (j_1 \geq 0, \cdots, j_q \geq 0; j_1 + \cdots + j_q \leq r)$$

的量的多项式. 因 y 有界, 上述那些量都有界.

自然联系函数的定义与 1 维的一样:

$$g = \dot{b}^{-1} \quad \text{或} \quad h = g^{-1} = \dot{b}, \quad (1.54)$$

它满足

$$\theta = \dot{b}^{-1}(\mu) = \eta \quad (\eta = z'\beta), \quad (1.55)$$

$\dot{b}^{-1}$ 存在. 此因 $\text{Cov}(y) > 0$, 故 $\ddot{b}(\theta) = \partial \dot{b}(\theta) / \partial \theta' > 0$, 因此映射 $\dot{b}$ 为一一的. 又 $b(\theta)$ 有任意阶偏导数, 光滑条件也满足.

1.2.2 多项分布的情形

我们再继续前面的讨论. 目标变量 $Y = (Y_{(1)}, \cdots, Y_{(q)})$ 取 $a_1, \cdots, a_k$ 等 k 个不同值. $(a_1, \cdots, a_k)$ (见(1.41)式下) 其取 a_j 的概率记为 $\pi_{(j)}$ ($j = 1, \cdots, q$), 而 $\pi = (\pi_{(1)}, \cdots, \pi_{(q)})'$ (取 a_k 的概率为 $1 - (\pi_{(1)} + \cdots + \pi_{(q)})$). π 受自变量 x 的影响, 可视为 $\pi = \pi(x)$. 又记 $|\pi| = \pi_{(1)} + \cdots + \pi_{(q)}$, 有

$$\begin{aligned} P(Y = y) &= P(Y = (y_{(1)}, \cdots, y_{(q)})') = (1 - |\pi|)^{(1 - (y_{(1)} + \cdots + y_{(q)})')} \prod_{j=1}^q \pi_{(j)}^{y_{(j)}} \\ &= (1 - |\pi|) \prod_{j=1}^q \left(\frac{\pi_{(j)}}{1 - |\pi|} \right)^{y_{(j)}} \end{aligned}$$

$$= (1 - |\pi|) \exp\left(\sum_{j=1}^q y_{(j)} \log \frac{\pi_{(j)}}{1 - |\pi|}\right)$$

当 $y = (y_{(1)}, \dots, y_{(q)})' = a_1, \dots, a_k$ 时, 其他为 0.

引进参数

$$\theta = (\theta_{(1)}, \dots, \theta_{(q)})' = \left(\log \frac{\pi_{(1)}}{1 - |\pi|}, \dots, \log \frac{\pi_{(q)}}{1 - |\pi|}\right)' \quad (1.56)$$

$$\Rightarrow e^{\theta_j} = \pi_{(j)} / (1 - |\pi|) \Rightarrow \sum_{j=1}^q e^{\theta_j} = |\pi| / (1 - |\pi|)$$

$$\Rightarrow 1 - |\pi| = \left(1 + \sum_{j=1}^q e^{\theta_j}\right)^{-1} \Rightarrow \pi_{(j)} = e^{\theta_j} / \left(1 + \sum_{r=1}^q e^{\theta_r}\right).$$

易见

$$P(Y = y) = \exp(y'\theta - b(\theta)), \quad (1.57)$$

其中, $b(\theta) = -\log(1 - |\pi|)$, 即

$$b(\theta) = \log\left(1 + \sum_{j=1}^q e^{\theta_{(j)}}\right). \quad (1.58)$$

分布(1.57)式有(1.42)式的形状, 测度 μ 为

$$\mu(\{a_j\}) = 1 \quad (j = 1, \dots, k), \quad \text{他处为 } 0$$

$$a_j = (0, \dots, 0, 1, \dots, 0) \quad (j = 1, \dots, q)$$

$$a_k = (0, \dots, 0), \quad q = k - 1.$$

由(1.56)式知, 自然联系函数为

$$g(\pi) = (g_1(\pi), \dots, g_q(\pi))' = (1.56) \text{ 式右边}, \quad (1.59)$$

其中, $\pi = (\pi_{(1)}, \dots, \pi_{(q)})'$. g 的反函数 h 为 $h = (h_1, \dots, h_q)'$, 其中

$$h_j(\theta) = e^{\theta_{(j)}} / \left(1 + \sum_{r=1}^q e^{\theta_{(r)}}\right) \quad (j = 1, \dots, q). \quad (1.60)$$

建模的工作有 3 个方面: ① 定义 Y 的分布类型, 对此处所论多项模型, 问题已解决了; ② 定联系函数; ③ 定线性预测子 $\eta = z'(x)\beta$, 这涉及 $z(x)$ 和 β 的选择. ② 和 ③ 两个方面与问题的具体形式有关, 以下几段考虑几个实用上常见的情况.

1.2.3 目标各状态无序的情况

其对立面是“有序”, 例如产品质量分甲、乙、丙 3 级, 病情分 1, 2, 3 期, 考生成绩分不及格、中、良、优等 4 级.

考察状态 j . 把其余的 $q-1$ 个状态总合成一个状态看, 则得到一个如例 1.1 那样的 2 元格局. 仿 (1.9) 式, 引进对状态 j 的线性预测子

$$\eta_j = z_{0j}'(x)\beta_j \quad (j = 1, \dots, q)$$

此处 β_j 为 p_0 维向量, z_{0j} 为 p_0 维向量, 与 x 有关. $z_{0j}(x)$ 是某个由 x 决定的, 并针对状态 j 的向量, 参数 β_j 也是针对状态 j , 为 p_0 维^①(维数也可与 j 有关, 无本质区别):

$$\beta = (\beta_1', \dots, \beta_q')' \quad (1.61)$$

是 $p \equiv q \cdot p_0$ 维向量;

$$Z' = z'(x) = \begin{bmatrix} z_{01}'(x) & & & \\ & z_{02}'(x) & & \\ & & \ddots & \\ & & & z_{0q}'(x) \end{bmatrix} \quad (1.62)$$

为 $q \times p$ 矩阵.

得线性预测子 η 为

$$\eta \equiv \eta(x) \equiv \begin{bmatrix} \eta_{(1)} \\ \vdots \\ \eta_{(q)} \end{bmatrix} \equiv \begin{bmatrix} \eta_{(1)}(x) \\ \vdots \\ \eta_{(q)}(x) \end{bmatrix} = Z'(x)\beta \equiv Z'\beta \quad (1.63)$$

在许多情况下, $z_{0j}(x)$ 可以取得与 j 无关, 记为 $z_0(x)$. 这时有

$$Z'(x) = \begin{bmatrix} Z_0'(x) & & & \\ & Z_0'(x) & & \\ & & \ddots & \\ & & & Z_0'(x) \end{bmatrix}.$$

但 β_j 不能取成一样, 因为自变量 x 对各状态, 例如, x 某一分量值增加有利于状态 1 出现而不利于状态 2 出现. 至于 $z_{0j}(x)$ 或 $z_0(x)$ 如何定, 当然取决于问题的具体性质. 一经选定了联系函数 g , 线性预测子 η , 并有了样本 (Y_i, x_i) ($i = 1, \dots, n$). 就可写出 $Y_1, \dots, Y_n$ 的联合分布. 记 $\eta_i = \eta(x_i)$ (勿与 (1.63) 式中的 $\eta_{(i)}$ 混淆), $h = g^{-1}$. 则 Y_i 来自的总体其 θ 值为

$$\begin{aligned} \theta_i &= b^{-1}(\pi_i) = b^{-1}(h(\eta_i)) \\ &= b^{-1}(h(z_0'(x_i)\beta_1, \dots, z_0'(x_i)\beta_q)) \end{aligned} \quad (1.64)$$

① p_0 的确定问题见例 1.5.

它依赖于 x_i 及参数 $\beta = (\beta_1, \dots, \beta_q)'$. 注意此处 θ_i, π_i 勿与以前的 $\theta_{(i)}, \pi_{(i)}$ 混淆; θ_i, π_i 是 Y_i 的分布中参数 θ, π 所取的值, 它们都是 q 维向量; 而 $\theta_{(i)}, \pi_{(i)}$ 则是 θ, π 的第 i 分量, 为 1 维的. 由 (1.64) 式, 得到 $Y_1, \dots, Y_q$ 的联合概率分布:

$$\prod_{i=1}^n c(y_i) \exp \left\{ Y_i' \dot{b}^{-1} (h(z_0'(x_i) \beta_1, \dots, z_0'(x_i) \beta_q)) - b(\dot{b}^{-1} (h(z_0'(x_i) \beta_1, \dots, z_0'(x_i) \beta_q))) \right\} \quad (1.65)$$

在自然联系情况, $h = \dot{b}$, 上式成为

$$\prod_{i=1}^n c(y_i) \exp \left\{ \sum_{j=1}^q Y_{ij} z_0'(x_i) \beta_j - \log \left(1 + \sum_{j=1}^q e^{z_0'(x_i) \beta_j} \right) \right\} \quad (1.66)$$

其中, $Y_i = (y_{i1}, \dots, y_{iq})'$. 由此出发, 用极大似然法, 对参数 β 进行统计推断.

例 1.5 设在例 1.1 中, 感染细分为 I, II 两种类型, 于是 Y 有 3 个状态:

① I 型感染; ② II 型感染; ③ 无感染. 观察了 251 例剖腹产, 数据如表 1.1 所示.

表 1.1 各组感染情况

组	大小	$y_{(1)}$	$y_{(2)}$	$x_{(1)}$	$x_{(2)}$	$x_{(3)}$
		目标变量		自变量		
1	40	4	4	0	0	0
2	58	11	17	0	0	1
3	2	0	0	0	1	0
4	18	0	1	0	1	1
5	9	0	0	1	0	0
6	26	10	13	1	0	1
7	98	4	7	1	1	1

没有
(1, 1, 0)

($x_{(1)} = 1$: 剖腹非计划; $x_{(2)} = 1$: 服用抗生素; $x_{(3)} = 1$: 有危险因子)

例如, 第 2 组是那些产妇: 剖腹早计划; 不服用抗生素; 有危险因子, 一共 58 名. 结果, I, II 型感染者分别有 11, 17 人, 无感染者 $58 - 11 - 17 = 30$ 人.

先算出 $z_{(0)}'(x_i)$. 例如, 当 x_i 属于第 4 组时, $z_{(0)}'(x_i) = (1, 0, 1, 1)$ ①. 此例

① (1, 0, 1, 1) 中, 第 1 元关乎常数项, 总是 1; 后 3 元分别表示 $x_{(1)}, x_{(2)}, x_{(3)}$ 所处状态, 即表中“自变量”那一栏.

$k = 3, q = k - 1 = 2$, 有 β_1 和 β_2 . 将其表为

$$\beta_1 = (\beta_{10}, \beta_{11}, \beta_{12}, \beta_{13})', \quad \beta_2 = (\beta_{20}, \beta_{21}, \beta_{22}, \beta_{23}).$$

$(z_{(0)})'(x)$ 就取为 $(1, x_{(1)}, x_{(2)}, x_{(3)})$. 将表中之值代入公式(1.66), 略去与 β 无关的因子 $\prod_{i=1}^n c(y_i)$, 并取对数, 略去“exp”号, 结果为

$$\begin{aligned} & 40[4\beta_{10} + 4\beta_{20}] + 58[11(\beta_{10} + \beta_{13}) + 17(\beta_{20} + \beta_{23})] \\ & + 18[\beta_{20} + \beta_{22} + \beta_{23}] + 26[10(\beta_{10} + \beta_{11} + \beta_{13}) + 13(\beta_{20} + \beta_{21} + \beta_{23})] \\ & + 98[4(\beta_{10} + \beta_{11} + \beta_{12} + \beta_{13}) + 7(\beta_{20} + \beta_{21} + \beta_{22} + \beta_{23})] \\ & - \left\{ 40\log(1 + e^{\beta_{10}} + e^{\beta_{20}}) + 58\log(1 + e^{\beta_{10}+\beta_{13}} + e^{\beta_{20}+\beta_{23}}) \right. \\ & + 2\log(1 + e^{\beta_{10}+\beta_{12}} + e^{\beta_{20}+\beta_{22}}) + 18\log(1 + e^{\beta_{10}+\beta_{12}+\beta_{13}} + e^{\beta_{20}+\beta_{22}+\beta_{23}}) \\ & + 9\log(1 + e^{\beta_{10}+\beta_{11}} + e^{\beta_{20}+\beta_{21}}) + 26\log(1 + e^{\beta_{10}+\beta_{11}+\beta_{13}} + e^{\beta_{20}+\beta_{21}+\beta_{23}}) \\ & \left. + 98\log(1 + e^{\beta_{10}+\beta_{11}+\beta_{12}+\beta_{13}} + e^{\beta_{20}+\beta_{21}+\beta_{22}+\beta_{23}}) \right\}. \end{aligned}$$

要找 $\beta_{10}, \beta_{20}, \dots, \beta_{13}, \beta_{23}$ 之值, 使此函数达到最大, 此处用的是自然联系, 不然形式会更复杂.

由此例可见, 使用广义线性模型往往引致众多参数和复杂的计算, 如目标有 k 状态, 自变量中属性因子有 r 个, 数量因子有 Λ 个. 现计算针对目标的一个状态需要多少参数, 即前文的 p_0 . 为此, 先设 r 个属性因子分别有状态 $t_1, \dots, t_r$ 个. 则为描述这些因子, 分别需要 $t_1 - 1, \dots, t_r - 1$ 个(哑)变量, Λ 个数量因子. 则只需 Λ 个变量去描述, 故总共需 $\Lambda + \sum_{j=1}^r (t_j - 1)$ 个变量, 相应有这么多个参数, 再加上一个关于常数项的参数, 共有

$$p_0 = \Lambda + \sum_{j=1}^r (t_j - 1) + 1 = \Lambda + t_1 + \dots + t_r - (r - 1).$$

对本例, $\Lambda = 0, r = 3, t_1 = t_2 = t_3 = 2$, 得 $p_0 = 4$, 且 $k = 3, q = k - 1 = 2$. 而 β 的维数 $p = qp_0 = 2 \times 4 = 8$.

1 2.4 状态有序的情况

其意义已在 1.2.3 小节开头处说明过了, 应注意的是: 此处指的序应是公认的, 不依特定人的好恶.

一种定序的机制是: 有一个潜在或明显的变量 U 及门限 $\theta_1 < \theta_2 < \dots < \theta_q$, 使得

$$\dot{Y} \equiv \text{样品的序值} = r, \text{ 当且仅当 } \theta_{r-1} < U \leq \theta_r \quad (1.67)$$

$$(r = 1, \dots, k).$$

此处已定 $\theta_0 = -\infty, \theta_k = \infty$ (注意 $q = k - 1$). 又门限值 $\theta_1, \dots, \theta_q$ 可以是已知或未知的. 若为未知的, 则它们也是模型中需要估计的参数.

例如, 根据考生的成绩 (U) 将其分入不及格(1)、中(2)、良(3)、优(4)等4个等级 ($k = 4, q = 3$). $\theta_1, \theta_2, \theta_3$ 3个门限定为 59, 74 和 89. 在本例中, 变量 U 是明显的, 而门限值也已知.

又如收购农产品, 收购人员依据目视、手感给送来的产品定个等级. 他心目中可能还是有一定的数量指标在, 但并非很明确. 这时 U 是潜在的, 门限也不明确, 可视为未知.

(1.67) 式中的 $\dot{Y}$ 不要与以前的样本 Y 混淆: Y 为 q 维, 当样品序值为 r 时, 若 $r \leq q$, 则 $Y = (0, \dots, 0, 1, 0, \dots, 0)'$, 1 在第 r 位. 若 $r = k$, 则 $Y = (0, \dots, 0)'$, 而 $\dot{Y}$ 则等于 k .

假定有一些因素 x 可以影响 U 的取值, 如当 U 为学生考分时, x 可以包含诸如该生的努力程度、学习方法, 教师授课质量与考题质量等因素. 假定 x 对 U 的影响通过 “ $-z_0'\gamma$ ” 表达, γ 为参数, 但还有一个随机成分 e 存在. 例如, 由于随机的原因, 一贯努力且资质不错的学生在一次考试中也可能会得低分. 这样,

$$U = -z_0'(x)\gamma + e. \quad (1.68)$$

以 F 记 e 的分布函数—— F 是建模过程中需要给予规定的一个成分, 当然还有 $z_0(x)$, 仍记

$$P(\dot{Y} = r) = \pi_{(r)} \quad (r = 1, \dots, q);$$

$$P(\dot{Y} = k) = 1 - \sum_{j=1}^q \pi_{(j)} = 1 - |\pi|$$

则有

$$\begin{aligned} P(\dot{Y} \leq r | x) &= \pi_{(1)} + \dots + \pi_{(r)} = P(U \leq \theta_r | x) \\ &= P(e \leq \theta_r + z_0'(x)r) \\ &= F(\theta_r + z_0'(x)\gamma). \end{aligned} \quad (1.69)$$

于是

$$F^{-1}(\pi_{(1)} + \dots + \pi_{(r)}) = \theta_r + z_0'(x)\gamma \quad (r = 1, \dots, q). \quad (1.70)$$

由(1.70)式立即得到联系函数 g 、参数向量 β 与线性预测子 $\eta = z'(x)\beta$ 的形状^①(假定 $\theta_1, \dots, \theta_q$ 未知. 当 $\theta_1, \dots, \theta_q$ 已知时作相应的变动):

$$\begin{aligned} g(\pi) &\equiv (g_1(\pi), \dots, g_q(\pi))' \\ &= (F^{-1}(\pi_{(1)}), \dots, F^{-1}(\pi_{(1)} + \dots + \pi_{(q)}))', \\ \beta &= (\theta_1, \dots, \theta_q, \gamma')', \\ z'(x) &= \begin{bmatrix} 1 & 0 & z_0'(x) \\ \vdots & \vdots & \vdots \\ 0 & 1 & z_0'(x) \end{bmatrix}. \end{aligned}$$

g 的反函数 $h = g^{-1}$ 为

$$\begin{aligned} h(t) &\equiv (h_1(t_1, \dots, t_q), \dots, h_q(t_1, \dots, t_q))' \\ &= (F(t_1), F(t_2) - F(t_1), \dots, F(t_q) - F(t_{q-1})), \end{aligned}$$

定义域为 $t_1 < t_2 < \dots < t_q$.

上面定义的模型取决于累积分布 F , 故称为累积线性模型. F 的不同选择产生不同的模型. 在应用上常见的有以下几种:

1. **Logistic 模型:** $F(t) = e^t / (1 + e^t)$

这时有

$$P(\dot{Y} \leq r) = \frac{\exp(\theta_r + z_0'(x)\gamma)}{1 + \exp(\theta_r + z_0'(x)\gamma)}. \quad (1.71)$$

由此推出

$$P(\dot{Y} \leq r | x) / P(\dot{Y} > r | x) = \exp(\theta_r + z_0'(x)\gamma). \quad (1.72)$$

因此对 x 不同的值 x_1, x_2 , 有

$$\frac{P(\dot{Y} \leq r | x_1)}{P(\dot{Y} > r | x_1)} \bigg/ \frac{P(\dot{Y} \leq r | x_2)}{P(\dot{Y} > r | x_2)} = \exp((z_0(x_1) - z_0(x_2))'\gamma), \quad (1.73)$$

与 r 无关. 若 $(z_0(x_1) - z_0(x_2))'\gamma > 0$, 则(1.73)式右边大于1. 因此在 $x = x_1$ 时, $\dot{Y}$ 取小值的概率, 大于在 $x = x_2$ 之下 $\dot{Y}$ 取小值的概率. 称 $\dot{Y} | x_1$ 随机地小于 $\dot{Y} | x_2$. 反之, 若 $(z_0(x_1) - z_0(x_2))'\gamma < 0$, 则 $\dot{Y} | x_1$ 随机地大于 $\dot{Y} | x_2$.

2. **分组 Cox 模型:** F 为极小值分布: $F(t) = 1 - \exp(-e^t)$

有

① 这表明: 联系函数在选定 F 时已被决定了, 不能再由人选择. 择定联系函数仍由一定自由, 但是通过对 F 的选择去实现的.

$$P(\dot{Y} > r | x) = 1 - F(\theta_r + z_0'(x)\gamma) = \exp(-e^{\theta_r + z_0'(x)\gamma}). \quad (1.74)$$

因此

$$\log(-\log P(\dot{Y} > r | x)) = \theta_r + z_0'(x)\gamma. \quad (1.75)$$

3. 极大值分布模型: $F(t) = \exp(-e^{-t})$

有

$$\begin{aligned} P(\dot{Y} \leq r | x) &= \exp(-e^{-(\theta_r + z_0'(x)\gamma)}) - \log(-\log P(\dot{Y} \leq r | x)) \\ &= \theta_r + z_0'(x)\gamma. \end{aligned} \quad (1.76)$$

后两种模型从统计分析的角度看是等价的. 事实上, 令

$$Y^* = (k+1) - \dot{Y},$$

即把原序倒转, 则由(1.76)式, 有

$$\begin{aligned} \log(-\log P(Y^* > k-r | x)) &= \log(-\log P(\dot{Y} \leq r | x)) \\ &= -(\theta_r + z_0'(x)\gamma) \end{aligned} \quad (1.77)$$

令

$$\theta_j^* = -\theta_{k-j} \quad (j = 1, \dots, q = k-1), \quad \gamma^* = -\gamma.$$

(1.77) 式有形式

$$\log(-\log P(Y^* > k-r | x)) = \theta_{k-r}^* + z_0'(x)\gamma^*,$$

即(改 $k-r$ 为 r)

$$\log(-\log P(Y^* > r | x)) = \theta_r^* + z_0'(x)\gamma^*, \quad (1.78)$$

(1.78) 式与(1.75)式一致. 因此, 把模型 3 个 $\dot{Y}$ 的数据转化为 Y^* , 则 Y^* 适合模型 2. 对 Y^* 按模型 2 估计 θ_r, γ , 得 $\hat{\theta}_r, \hat{\gamma}$, 转化为

$$\hat{\theta}_j^* = -\hat{\theta}_{k-j}, \quad \hat{\gamma}^* = -\hat{\gamma}$$

即得在原模型(模型 3)下, θ_j 与 γ 的估计值.

这 3 个分布的图像如图 1.3 所示. 从图可看出在小值处, 模型 1, 2 接近, 在大值处则模型 1, 3 接近. 图中的虚线显示因 $-z_0'(x)\gamma$ 而产生的分布位移. 这种位移影响到取各序值的概率大小.

我们注意到, 选定 F 的同时也就决定了联系函数. 有无可能这样去选择 F , 以得到自然联系? 下面证明这是不可能的. 事实上, 按(1.70)式和(1.56)式, 为得到自然联系, F 必须满足

$$F^{-1}(\pi_{(1)} + \dots + \pi_{(r)}) = \log \frac{\pi_{(r)}}{1 - |\pi|} \quad (r = 1, \dots, q), \quad (1.79)$$




图 1.3 3 种分布图形

对一切满足 $\pi_{(r)} > 0 (r = 1, \dots, q)$, $|\pi| < 1$ 的 $(\pi_{(1)}, \dots, \pi_{(q)})$ 成立.

取 $r = 1$, 而令 $\pi_{(j)} \downarrow 0 (j = 2, \dots, q)$, 则因 $|\pi| \rightarrow \pi_{(1)}$, 由 (1.79) 式, 得

$$F^{-1}(\pi_{(1)}) = \log \frac{\pi_{(1)}}{1 - \pi_{(1)}} \quad (0 < \pi_{(1)} < 1)$$

在上式中用 $\pi_{(1)} + \dots + \pi_{(r)}$ 取代 $\pi_{(1)}$, 得

$$F^{-1}(\pi_{(1)} + \dots + \pi_{(r)}) = \log \frac{\pi_{(1)} + \dots + \pi_{(r)}}{1 - (\pi_{(1)} + \dots + \pi_{(r)})},$$

而这与(1.79)式矛盾. 这证明了满足(1.79)式的 F 不存在.

现设有了样本 (y_i, x_i) , $y_i = (y_{i1}, \dots, y_{iq})'$ ($i = 1, \dots, n$). 则 $y_1, \dots, y_n$ 的概率函数为

$$C \prod_{i=1}^n \left\{ \pi_{(1)}^{y_{i1}}(x_i) \cdots \pi_{(q)}^{y_{iq}}(x_i) (1 - |\pi(x_i)|)^{1 - \sum_{j=1}^q y_{ij}} \right\}, \quad (1.80)$$

其中, C 为一与参数无关的量. 由(1.69)式, 有

$$\begin{aligned} \pi_{(1)}(x_i) &= F(\theta_1 + z_0'(x_i)\gamma), \\ \pi_{(r)}(x_i) &= F(\theta_r + z_0'(x_i)\gamma) - F(\theta_{r-1} + z_0'(x_i)\gamma) \\ (r &= 2, \dots, q) \end{aligned}$$

而 $|\pi(x_i)| = \sum_{j=1}^q \pi_{(j)}(x_i) = 1 - F(\theta_q + z_0'(x_i)\gamma)$. 代入(1.80)式, 得

$$\begin{aligned} C \prod_{i=1}^n \left\{ \prod_{j=1}^q (F(\theta_j + z_0'(x_i)\gamma) - F(\theta_{j-1} + z_0'(x_i)\gamma))^{y_{ij}} \right. \\ \left. \cdot (1 - F(\theta_q + z_0'(x_i)\gamma))^{1 - \sum_{j=1}^q y_{ij}} \right\} \end{aligned} \quad (1.81)$$

其中, $y_{ij} = 1$, 若第 i 个样品的序值为 j , 否则 $y_{ij} = 0$. 利用(1.81)式, 由极大似然法, 可对参数 $\theta_1, \dots, \theta_q$ 和 γ 作出推断.

另一个应用是对一样品的序值作判别: 样品的序值不易测定或当时尚未测定, 要依据其一些指标, 即 x 值, 对其作出判定, 为此用已有样本 (y_i, x_i) ($1 \leq i \leq n$), 对 $\theta_1, \dots, \theta_q$ 和 γ 作出估计, 得 $\hat{\theta}_1, \dots, \hat{\theta}_q$ 和 $\hat{\gamma}$, 并据此对 $\pi_{(j)}(x)$ 作出估计, 得

$$\begin{aligned} \hat{\pi}_{(j)}(x) &= F(\hat{\theta}_j + z_0'(x)\hat{\gamma}) - F(\hat{\theta}_{j-1} + z_0'(x)\hat{\gamma}) \\ (j &= 1, \dots, k). \end{aligned} \quad (1.82)$$

此处定 $\hat{\theta}_0 = -\infty$, $\hat{\theta}_k = \infty$. 然后取满足条件

$$\hat{\pi}_{(j(x))}(x) = \max_{1 \leq r \leq k} \hat{\pi}_{(r)}(x)$$

的 $j(x)$ 作为该样品序值的估计. 或以判别分析的语言说, 把该样品判入第 $j(x)$

类. (y_i, x_i) ($1 \leq i \leq n$), 称为训练样本.

作为门限值 $\theta_1, \dots, \theta_q$, 满足 $\theta_1 < \dots < \theta_q$. 但其估计值 $\hat{\theta}_1, \dots, \hat{\theta}_q$ 不一定满足这个次序. 这样就会带来麻烦, 例如, $\pi_{(r)}(x)$ 的估计值 (1.82) 式可以是负的. 为避免这一点, 引进新参数 $\alpha_1, \dots, \alpha_q$ 取代 $\theta_1, \dots, \theta_q$:

$$\alpha_1 = \theta_1, \quad \alpha_r = \log(\theta_r - \theta_{r-1}) \quad (r = 2, \dots, q)$$

或

$$\theta_1 = \alpha_1, \quad \theta_r = \alpha_1 + e^{\alpha_2} + \dots + e^{\alpha_r} \quad (r = 2, \dots, q).$$

如果估计出 $\alpha_1, \dots, \alpha_q$ 之值, 得 $\hat{\alpha}_1, \dots, \hat{\alpha}_q$, 则用

$$\hat{\theta}_1 = \hat{\alpha}_1, \quad \hat{\theta}_r = \hat{\alpha}_1 + e^{\hat{\alpha}_2} + \dots + e^{\hat{\alpha}_r} \quad (r = 2, \dots, q)$$

去估计 $\theta_1, \dots, \theta_q$, 必有 $\hat{\theta}_1 < \dots < \hat{\theta}_q$.

下面要找出新参数下的联系函数与线性预测子. 由 (1.70) 式有

$$\begin{aligned} F^{-1}(\pi_{(1)}) &= \theta_1 + z_0'(x)\gamma = \alpha_1 + z_0'(x)\gamma \\ \log(F^{-1}(\pi_{(1)} + \dots + \pi_{(r)}) - F^{-1}(\pi_{(1)} + \dots + \pi_{(r-1)})) \\ &= \log(\theta_r - \theta_{r-1}) = \alpha_r \quad (r = 2, \dots, q) \end{aligned}$$

由此得到联系函数 $g(\pi) = (g_1(\pi), \dots, g_q(\pi))'$, 其中

$$g_1(\pi) = F^{-1}(\pi_{(1)}),$$

$$g_r(\pi) = \log(F^{-1}(\pi_{(1)} + \dots + \pi_{(r)}) - F^{-1}(\pi_{(1)} + \dots + \pi_{(r-1)})) \quad (r = 2, \dots, q).$$

线性预测子 $\tilde{Z}'(x)\tilde{\beta}$, 其中 $\tilde{\beta} = (\alpha_1, \dots, \alpha_q, \gamma')'$, 而

$$\tilde{Z}'(x) = \begin{bmatrix} 1 & & & z_0'(x) \\ & 1 & 0 & 0' \\ & & \ddots & \vdots \\ 0 & & & 1 & 0' \end{bmatrix} = \begin{bmatrix} & z_0'(x) \\ & 0' \\ & \vdots \\ I_q & 0' \end{bmatrix}$$

其中, $0'$ 是 0 行向量, 其维数与 $z_0'(x)$ 的维数, 即 γ 的维数相同. 通过 $\tilde{Z}(x)$ 及 $\tilde{\beta}$ 表出 $\pi = (\pi_{(1)}, \dots, \pi_{(q)})'$ 的表达式为

$$\pi_{(1)}(x) = F(\alpha_1 + z_0'(x)\gamma),$$

$$\begin{aligned} \pi_{(r)}(x) &= F(\alpha_1 + e^{\alpha_r} + \dots + e^{\alpha_r} + z_0'(x)\gamma) \\ &\quad - F(\alpha_1 + e^{\alpha_2} + \dots + e^{\alpha_{r-1}} + z_0'(x)\gamma) \quad (r = 2, \dots, q) \end{aligned}$$

例 1.6 呼吸测验. 目标 Y 分 3 个状态: 正常、边缘、不正常. 自变量有 2 个: 年龄: 分 < 40 和 $40 \sim 59$ 两级. 吸烟史: 分“从不吸烟”、“过去吸”和“现在吸”3 级. 数据如表 1.2 所示.

表 1.2 目标情况

年龄	吸烟史	结 果(人数)		
		正常	边缘	不正常
< 40	从 不	577	27	7
	过去吸	192	20	3
	现在吸	682	46	11
40 ~ 59	从 不	164	4	0
	过去吸	145	15	7
	现在吸	245	47	27

本例有 2 个属性自变量: 年龄: 2 状态; 吸烟史: 3 状态. 共需 $(2-1) + (3-1)$ 个(哑) 变量, 即 3 个变量 $x_{(1)}, x_{(2)}, x_{(3)}$ 去描述之:

$$x_{(1)} = \begin{cases} 1, & \text{年龄} < 40 \\ 0, & \text{年龄} \geq 40 \end{cases}$$

$$(x_{(2)}, x_{(3)}) = \begin{cases} (1, 0), & \text{不吸烟} \\ (0, 1), & \text{过去吸, 现在不吸} \\ (0, 0), & \text{现在吸} \end{cases}$$

另加上 2 个门限参数 $\theta_1 < \theta_2$ ($q = 2 = k - 1, k = 3$) 共有 5 个变量. 故 β 为 5 维: $(\theta_1, \theta_2, \gamma')'$, γ 为 3 维, 其 3 个分量 γ_1, γ_2 和 γ_3 分别关乎 $x_{(1)}, x_{(2)}$ 和 $x_{(3)}$. 此处不需常数项相关的那样的 γ_0 . 因 γ_0 可吸收到 θ_1, θ_2 中, 成为 $\theta_1 + \gamma_0, \theta_2 + \gamma_0$. 后者可改记为 θ_1, θ_2 .

又此处对 Y 的每一状态, 用同一个 γ (前面在讨论无序情况时, Y 的每一状态须用不同参数). 原因在于: 此处 Y 的状态如何划分, 取决于单一变量 U (如学生的分数). 而在无序场合则不然: 每一状态有其各自的特性. 如交通工具选择可有 4 个状态: 飞机(1)、火车(2)、汽车(3)、轮船(4). “经济状态好” 倾向有利于状态(1) 而不利(3) 和(4), 即对各状态影响不同.

1 2 5 多种选择的情况

有 k 个对象, 人们可自由地从中选择一种. 如外出旅行, 有 k 种交通工具可供选择; 买计算机, 有 k 种品牌可供选择等. 哪一种被选上, 取决于被选对象的条件, 如交通工具的费用、旅途时间之类, 以及选择者的条件(经济状态、年龄等). 这“供选状态的条件 + 选择者的条件”, 即问题中的自变量. 目标变量即选择结

果. 分析的目的是评估这些自变量对选择结果的影响.

为定模型, 要考虑两个问题:

1. 决定“对象被选上”的概率的机制——如同在有序情况下通过潜在变量、门限和分布 F 决定概率.

2. 决定线性预测子.

先考虑第一个问题. 根据“利益分析”决定各对象被选中的概率, 这个理论假定: 对每一具体的选择者, k 个供选对象各有一个“利益值”相关联, 分别记为 $u_1, \dots, u_k$. 例如在选择交通工具时, 经济拮据的人对火车所赋“利益值”要比“飞机”所赋“利益值”为大. 若选择者对 $u_1, \dots, u_k$ 之值已完全了解, 则他选状态 r , 使 $u_r = \max_j u_j$. 但一般 u 值并不完全确定, 或也可能, 选择者对其了解存在一定的随机误差——例如发生的事故影响人对 u 值的看法. 因此, 人们估量的利益值为 $U_1, \dots, U_k$, 其中

$$U_j = u_j + \xi_j \quad (j = 1, \dots, k). \quad (1.83)$$

而 $\xi_1, \dots, \xi_k$ 为 iid. 随机变量, 选择者根据“ U 值最大”去挑选状态, 于是

$$\begin{aligned} P(\text{状态 } r \text{ 被选择}) &= P(U_r \geq U_j) \quad (j = 1, \dots, k) \\ &= P(\xi_j \leq u_r - u_j + \xi_r, j = 1, \dots, k) \end{aligned} \quad (1.84)$$

以 F 记 $\xi_1, \dots, \xi_k$ 的公共分布. 对上式, 在给定 ξ_r 的条件下求条件概率, 得

$$P(\text{状态 } r \text{ 被选择}) = \int_{-\infty}^{\infty} \prod_{j=1, j \neq r}^k F(t + u_r - u_j) f(t) dt \quad (1.85)$$

其中, $f(t) = dF(t)/dt$ 为 ξ_j 的概率密度.

对 F 的不同选取, 可得各种模型, 如选 F 为 $N(0, \sigma_0^2)$ (σ_0 已知), 得所谓多维 Probit 模型, 它涉及多维正态分布函数的计算, 实施较强, 另一个选择是选 F 为极值分布:

$$F(t) = \exp(-e^{-t}) \quad (-\infty < t < \infty)$$

其密度 $f(t) = e^{-t} \exp(-e^{-t})$ 关于 O 不对称, 但导致简单结果: 代入 (1.85) 式, 直接积分, 易得

$$\begin{aligned} \pi_{(r)} &= P(\text{对象 } r \text{ 被选择}) = e^{u_r} / \sum_{j=1}^k e^{u_j} \\ &= e^{u_r^*} / (1 + \sum_{j=1}^q e^{u_j^*}) \quad (r = 1, \dots, q) \\ u_j^* &= u_j - u_k \quad (j = 1, \dots, q, q = k-1) \end{aligned} \quad (1.86)$$

与 (1.60) 式对照 (注意 (1.60) 式中的 $h_{j(\theta)}$ 是 $P_\theta(Y \text{ 取状态 } j)$), 相当于此处的

$\pi_{(j)}$), 看出此处的 u_j^* 相当于该处的 $\theta_{(j)}$, 即 $(u_1^*, \dots, u_q^*)'$ 相当于自然参数 $\theta(\theta_{(1)}, \dots, \theta_{(q)})'$. 故在这一特例, 自然参数 θ 有一个实际的意义. 这也可视为对多维 logit 模型的一个背景解释.

转到第 2 个问题, 先通过一个实例.

例 1.7 旅行工具有飞机、火车、轮船、汽车 4 种可供选择, $k = 4, q = k = 1 = 3$, 只需考虑前 3 种. 影响选择的因素考虑了以下这些:

I 类: 供选对象的条件

1° 旅费: 分低、中、高 3 等

		w_1	w_2	
哑变量 w_1, w_2	低	1	0	——
				轮船
回归系数 β_{01}, β_{02}	中	0	1	——
				火车
	高	0	0	——
				飞机

2° 旅行时间: 分快、中、慢 3 等

		w_3	w_4	
哑变量 w_3, w_4	快	1	0	——
				飞机
回归系数 β_{03}, β_{04}	中	0	1	——
				火车
	慢	0	0	——
				轮船

3° 旅途浏览价值: 分有、无二等

哑变量 w_5 $w_5 \begin{cases} \text{有: 1} \text{—— 车、船} \\ \text{无: 0} \text{—— 飞机} \end{cases}$

回归系数 β_{05}

II 类: 选择者条件, 且对“供选对象被选上之影响”因人而异者

4° 经济状态: 分低、中、高 3 等

哑变量 x_1, x_2 :	x_1	x_2
低	1	0
中	0	1
高	0	0

5° 性别:男、女

哑变量 x_3 $\begin{cases} \text{男} \longrightarrow 0 \\ \text{女} \longrightarrow 1 \end{cases}$

6° 健康状况:好、差

哑变量 x_4 $\begin{cases} \text{好} \longrightarrow 0 \\ \text{不好} \longrightarrow 1 \end{cases}$

Ⅲ类: 供选者条件,其对“供选对象被选上之影响”不因人而异者

7° 去站点(车站、机场、码头)的方便程度:方便,不方便.

哑变量 v_1' $\begin{cases} \text{方便} \longrightarrow 0 \\ \text{不方便} \longrightarrow 1 \end{cases}$
回归系数 γ_1

8° 去站点的费用:分高、中、低 3 等

	v_2	v_3
哑变量 v_2, v_3	高	1 0
回归系数 γ_1, γ_3	中	0 1
	低	0 0

Ⅱ,Ⅲ 两类的差别可举例说明如下:如经济状况,对选择者各异,但一种特定的经济状况,对供选对象被选上之影响,也因人而异,并不全取决于这一特定的经济状况本身,如经济状况好的人未必一定倾向选择飞机,经济状况不好的人,也未必一定倾向于不选飞机.

因此,对Ⅱ类中的因素,需要对各供选状态分别设回归系数,在此例中,Ⅱ类因素有 4 个,加上一个常数项,共 5 个,其对飞机、火车、轮船这 3 种对象下,回归系数分别记为

$\beta_{11}, \beta_{12}, \beta_{13}, \beta_{14}, \beta_{15}; \quad \beta_{21}, \beta_{22}, \beta_{23}, \beta_{24}, \beta_{25}; \quad \beta_{31}, \beta_{32}, \beta_{33}, \beta_{34}, \beta_{35}.$

现设某旅行者个人状况为:

经济状况:中 性别:男 健康状况:好

他去船码头方便,其余不方便

他去机场费用高,去车站中等,去船码头低.

对此人而言

$Z_0(x) = (1, x_1, x_2, x_3, x_4)' = (1, 0, 1, 0, 0)'$

经济状态中 $\Rightarrow (x_1, x_2) = (0, 1)$; 性别男 $\Rightarrow x_3 = 0$.

健康状况好 $\Rightarrow x_4 = 0$

$V_0(v) = (v_1, v_2, v_3)'$, 如右表与被选对象有关的部分(这与个人无关)为:

	v_1	v_2	v_3
飞机	1	1	0
火车	1	0	1
轮船	0	0	0

	w_1	w_2	w_3	w_4	w_5
飞机	0	0	1	0	0
火车	0	1	0	1	1
轮船	1	0	0	0	1

综合这几部分,得此人的“ Z' ”:

	I 类					II 类												III 类		
	w_1	w_2	w_3	w_4	w_5	$Z'_0(x)$				$Z'_0(x)$				$Z'_0(x)$				v_1	v_2	v_3
飞机	0	0	1	0	0	1	0	1	0	0	0	0	0	0	0	0	0	1	1	0
火车	0	1	0	1	1	0	0	0	0	0	1	0	1	0	0	0	0	1	0	1
轮船	1	0	0	0	1	0	0	0	0	0	0	0	0	0	1	0	1	0	0	0

而参数向量为:

$$\beta = (\beta_{01}, \dots, \beta_{05}; \beta_{11}, \dots, \beta_{15}; \beta_{21}, \dots, \beta_{25}; \beta_{31}, \dots, \beta_{35}; \gamma_1, \gamma_2, \gamma_3)'$$

由这个特例的示范,不难看出一般情况下的处理方法,设在一个选择问题中,经过种种考虑,选定了3类因素: W (与供选对象有关) X (与人有关,且对供选对象被选机会的影响不因人而异)对 w, x, v ,分别选定向量 l_w, l_x 和 l_v .例如 $w = (w_1, w_2, w_3)'$,则 l_w 可以是 $(w_1, w_2, w_3, w_1 w_2)'$,余类推. l_w 和 l_v 要对每一供选对象(总的供选对象数-1)定.如一共有 k 个对象,则需定出 $l_w(1), \dots, l_w(q)$,这在上例中就是表中最左边那一块, l_v 也要对每一供选对象定,故也有 $l_v(1), \dots, l_v(q)$.但 l_x 则对每一供选对象都一样,这时,矩阵 Z' (它与 w, x 有关,因 w 与样本无关,故可记为 $Z'(x)$ 有形式

供选对象	类别		
	I 类	II 类	III 类
	w	x	v
1	$l_w(1)$	l_x	$l_v(1)$
2	$l_w(2)$	l_x	$l_v(2)$
$\vdots$	$\vdots$	$\ddots$	$\vdots$
q	$l_w(q)$	l_x	$l_v(q)$

而参数向量 β 为: $\beta = (\beta_w', \beta_{x1}', \dots, \beta_{xq}', \beta_v')'$,其中, $\beta_v, \beta_{x1}, \beta_v$ 的维数分

别与 l_w, l_x 和 l_v 的维数同, $\beta_{x1}, \dots, \beta_{xq}$ 的维数相同.

确定 $Z'(x)$ 后, 以 $Z'(x)\beta$ 的第 j 分量取代 (1.85) 式中的 $u_j (j = 1, \dots, q)$, 得出

$$\pi_{(r)}(x) = P(\text{对象 } r \text{ 被选择} \mid x)$$

然后, 有了样本 $(y_i, x_i) = (y_{i1}, \dots, y_{iq}, x_i) (1 \leq i \leq n)$, 就可写出 $y_1, \dots, y_n$ 的联合概率分布 (略去一个与参数无关的量)

$$\prod_{i=1}^n \{ \pi_{(1)}^{y_{i1}}(x_i) \cdots \pi_{(q)}^{y_{iq}}(x_i) (1 - |\pi(x_i)|)^{1-(y_{i1} + \cdots + y_{iq})} \} (|\pi(x_i)| = \sum_{r=1}^q \pi_{(r)}(x_i)),$$

而用极大似然法对 β 做统计推断.

从以上讨论中看出, β 往往会是一个维数很高的向量, 这导致很大的计算量. 为使 β 的维数不致过于升高, 在筛选因子以至供选对象数目上, 需要把把关. 这个问题主要是实际的或专业性质的. 统计学中筛选自变量的方法 (借助样本) 有时可以起一些作用, 但终究是辅助性的.

在本例中, 有些因子 (如旅费) 本是数量性的. 如当数量处理, 只一个变量即可刻画. 一改用几个等级 (如高、中、低), 反而增加了变量而且损失了一些样本信息 (知道旅费“高”, 不如确切知道旅费是多少). 为什么要这样做? 这是出于希望自变量取不同值的数目少一些, 理论表明, 这时大样本极限分布的拟合较好.

1.2.6 两步模型

这种模型把全部目标状态先分成若干类, 同一类中的状态, 在某方面有相似之处, 不同类之间则不相似, 第一步考察样品落入哪一类, 下一步则在该类中定出其状态.

例如, 一种产品有 A, B 两个质量指标, 按 A 分有 3 个等级: A_1, A_2, A_3 ; 按 B 分有 4 个等级: B_1, B_2, B_3, B_4 . 于是一产品的质量有 12 个“状态”. 先考察其 A 指标属于哪一档. 定下后再决定其 B 指标属于哪一档. 这样, 全部 12 个状态 $A_1 B_1, A_1 B_2, \dots, A_3 B_4$ 分成 3 大类: 第 1 类含 $A_1 B_1, \dots, A_1 B_4$, 第 2, 3 类分别含 $A_2 B_1, \dots, A_2 B_4$ 以及 $A_3 B_1, \dots, A_3 B_4$.

一般, 设分成 7 类. 第 1 类含状态 $1, 2, \dots, m_1, \dots$, 第 j 类含状态 $m_{j-1} + 1, \dots, m_j (j = 2, \dots, t)$. $m_t = k$ 为总状态数, $q = k - 1$.

假定有一个潜在或明显的变量 U 在决定类属时起作用. 仍以 $\dot{Y}$ 记样本的序值, 即所属状态的编号, 而门限为 $\theta_1 < \dots < \theta_{t-1}$, 且

$$\dot{Y} \in S_j \Leftrightarrow \theta_{j-1} < U \leq \theta_j \quad (j = 1, \dots, t, \theta_0 = -\infty, \theta_t = \infty)$$

第2步,在每一类 S_j 内,有一个变量 U_j ,门限 $\theta_{j1} < \cdots < \theta_{j, m_j - m_{j-1} - 1}$,以决定在该类中属何状态(第 j 类中状态数为 $m_j - m_{j-1}$,门限数比它少1):

$$\dot{Y} = m_{j-1} + r \mid \dot{Y} \in S_j \Leftrightarrow \theta_{j, r-1} < U_j \leq \theta_{jr} \\ (\theta_{j0} = -\infty, \theta_{j, m_j - m_{j-1}} = \infty)$$

U, U_j 之值受到自变量 x 及随机误差的影响:

$$U = -z_0'(x)\beta_0 + e_0, \quad U_j = -z_j'(x)\beta_j + e_j$$

其中, $e_0, e_1, \cdots$ 为 iid. (独立同分布), 有公共分布 $F^{①}$. 记 $T_j = S_1 \cup \cdots \cup S_j$, 有

$$P(\dot{Y} \in T_j \mid x) = F(\theta_j + z_j'(x)\beta_0) \quad (j = 1, \cdots, t-1), \quad (1.87)$$

$$P(\dot{Y} \leq m_{j-1} + r \mid \dot{Y} \in S_j, x) = F(\theta_{jr} + z_j'(x)\beta_j) \\ (r = 1, \cdots, m_j - m_{j-1} - 1). \quad (1.88)$$

第2步在不同的类内用不同的参数向量 β_j , 因 x 在各类中影响的方式可能不同.

按(1.87)式和(1.88)式,不难写出 $z_0'(x)$, 如下表.

不同类属

$$z'(x) = \begin{pmatrix} \begin{matrix} 1 & \cdots & z_0'(x) \\ & \ddots & \vdots \\ & & 1 & z_0'(x) \end{matrix} & & & \\ & \begin{matrix} 1 & \cdots & z_1'(x) \\ & \ddots & \vdots \\ & & 1 & z_1'(x) \end{matrix} & & & \\ & & \ddots & & & \\ & & & \ddots & & \\ & & & & \ddots & \\ & & & & & \ddots \\ & & & & & 1 & z_t'(x) \\ & & & & & & \ddots \\ & & & & & & 1 & z_t'(x) \end{pmatrix} \begin{matrix} t-1 \text{ 行} \\ m_1-1 \text{ 行} \\ \\ m_j-m_{j-1}-1 \text{ 行} \\ \\ m_t-m_{t-1}-1 \text{ 行} \end{matrix}$$

第 1 类 第 j 类, 有 $m_j - m_{j-1}$ 个状态, 占 $m_j - m_{j-1} - 1$ 行 第 7 类

$t-1+l$ 列 m_1-1+l_1 列 $m_j-m_{j-1}-1+l_j$ 列 $m_t-m_{t-1}-1+l_t$ 列

参数向量 β 为

$$\beta = (\theta_1, \cdots, \theta_{t-1}, \beta_0'; \theta_{11}, \cdots, \theta_{1, m_1-1}, \beta_1'; \cdots; \theta_{t1}, \cdots, \theta_{t, m_t-m_{t-1}-1}, \beta_t')'$$

通过线性预测子 $z'(x)\beta$ 表达 $\pi_{(r)}(x) = P(\dot{Y} = r \mid x)$ 的公式易由(1.87)式和(1.88)式推出: 先由(1.87)式算出

$$P(\dot{Y} \in S_j \mid x) = F(\theta_j + z_0'(x)\beta_0) - F(\theta_{j-1} + z_0'(x)\beta_0) \\ (j = 1, \cdots, t).$$

① 也可以假定不同分布: 与类有关的分布为 F , 在类 j 中涉及的分布(即 e_j 的分布)为 F_j ($j = 1, \cdots, t$) 相应地把(1.88)式中的 F 改为 F_j , 所有的论述仍适用, 但在计算上复杂一些

$(F(\theta_0 + z_0'(x)\beta_0) = F(-\infty) = 0, F(\theta_t + z_0'(x)\beta_0) = F(\infty) = 1)$, 然后, 对 $r = 1, \dots, m_j - m_{j-1}$, 按(1.88)式, 有(约定 $m_0 = 0$)

$$\begin{aligned} & \pi_{(m_{j-1}+r)}(x) \\ &= P(\dot{Y} = m_{j-1} + r \mid x) \\ &= P(\dot{Y} \in S_j \mid x) P(\dot{Y} = m_{j-1} + r \mid \dot{Y} \in S_j \mid x) \\ &= \{F(\theta_j + z_0'(x)\beta_0) - F(\theta_{j-1} + z_0'(x)\beta_0)\} \\ & \quad \cdot \{F(\theta_{jr} + z_j'(x)\beta_j) - F(\theta_{j,r-1} + z_j'(x)\beta_j)\} \quad (j = 1, \dots, t). \end{aligned}$$

由此, 在有了样本 $(y_i, x_i) = (y_{i1}, \dots, y_{iq}, x_i) \quad (1 \leq i \leq n)$, $q = k - 1 = m_t - 1$ 可以写出 $y_1, \dots, y_n$ 的联合概率分布.

形式上也不难写出联系函数 g : 按下述公式

$$g(\pi) = (g_1(\pi), \dots, g_q(\pi))' = z'(x)\beta$$

及(1.87)式, 得

$$g_j(\pi) = F^{-1}(\pi_{(1)} + \dots + \pi_{(m_j)}) \quad (j = 1, \dots, t-1). \quad (1.89)$$

注意到(1.88)式的左边等于 $(\pi_{(m_{j-1}+1)} + \dots + \pi_{(m_{j-1}+r)}) / (\pi_{(m_{j-1}+1)} + \dots + \pi_{(m_j)})$, 有(1.89)式针对第 j 类中的第 r 个状态. 此状态序号为 $(t-1) + (m_1 - 1) + [(m_2 - m_1) - 1] + \dots + [m_{j-1} - m_{j-2} - 1] + r = t + m_{j-1} - j + r$.

$$\begin{aligned} g_{t-j+m_{j-1}+r}(\mu) &= F^{-1}\left(\frac{\pi_{(m_{j-1}+1)} + \dots + \pi_{(m_{j-1}+r)}}{\pi_{(m_{j-1}+1)} + \dots + \pi_{(m_j)}}\right) \\ & \quad (r = 1, \dots, m_j - m_{j-1} - 1, j = 1, \dots, t, m_0 = 0). \end{aligned} \quad (1.90)$$

(1.89)式中有 $t-1$ 个函数, (1.90)式中有 $m_j - m_{j-1} - 1$ 个函数 $(j = 1, \dots, t)$, 总共有

$$(t-1) + \sum_{j=1}^t (m_j - m_{j-1} - 1) = m_t - m_0 - 1 = k - 1 = q$$

个, 与 $z'(x)$ 的行数一致.

1.2.7 序贯模型

在有些问题中, 目标各状态排成一个自然次序. 一个对象从状态 1 开始, 可能最终停留在这个状态, 也可能上升到状态 2. 一般, 在对象进至状态 r 后, 它可以最终保持在 r 或上升至 $r+1, \dots$ 例如人的职务、职称的提升等, 一种不可逆转的疾病的分期, 属于这种情况. 所关心的是该对象的最终状态. 分析的目的是弄清: 最终取某一状态的概率与某些因素(自变量)之间的关系.

设共有 k 个状态 $1, \dots, k, q = k-1$. 个体自状态 1 始, 逐步往上进展至 $2, 3, \dots, r$. 到 r 即停止, r 为其最终状态, 记为 $\dot{Y} = r$. 要决定在已给自变量 x 值时, $\dot{Y} = r$ 的条件概率

$$\pi_{(r)}(x) = P(\dot{Y} = r | x).$$

设在某时刻个体已进展至状态 r . 它能否维持在此处, 取决于某变量 U_r 和门限 θ_r :

给定个体在状态 r , 它最终维持在此 $\Leftrightarrow U_r \equiv -z_0'(x)\beta' + e_r \leq \theta_r$, 而 e_r 有分布 F . 这样, $P(\dot{Y} = r | x)$ 是下面一共 r 个条件概率之积:

$$\begin{aligned} & P(\text{它能进展到 } j+1 | \text{ 给定个体在状态 } j, x) \\ &= 1 - P(\text{它停留在 } j | \text{ 给定个体在状态 } j, x) = 1 - P(U_j \leq \theta_j) \\ &= 1 - P(e_j \leq \theta_j + z_0'(x)\beta^*) = 1 - F(\theta_j + z_0'(x)\beta^*) \\ & \quad (j = 1, \dots, r-1; \text{共 } r-1 \text{ 个}), \end{aligned}$$

$$P(\text{它停留在 } f | \text{ 给定个体在状态 } r, x) = F(\theta_r + z_0'(x)\beta^*), \quad (1.91)$$

由此得

$$\pi_{(r)}(x) = P(\dot{Y} = r | x) = F(\theta_r + z_0'(x)\beta^*) \prod_{j=1}^{r-1} [1 - F(\theta_j + z_0'(x)\beta^*)] \quad (1.92)$$

$r = 1$ 时乘积号那一项理解为 1. 这里设 e_r 的分布 F 与 r 无关. 若有关, 只需在 (1.91) 式中改 F 为 F_r , (1.92) 式中改 F 为 F_j .

取特殊的分布 F , 得到特定的模型, 常用的有:

$$\text{序贯 logit 模型: } F(t) = \frac{e^t}{1 + e^t}.$$

$$\text{极值模型: } F(t) = 1 - \exp(-e^t).$$

$$\text{指数模型: } F(t) = 1 - e^{-t}, t > 0; = 0, t \leq 0.$$

这些分布被选择更多地是由于计算上的方便, 不一定由于其有某种理论根据.

极值模型有这样一性质: 经过适当的参数变换, 它可转化为分组 Cox 模型 (1.74) 式. 实际上, 按 (1.91) 式, 对极值模型, 有

$$P(\dot{Y} = r | x, \dot{Y} \geq r) = 1 - \exp(-e^{\theta_r + z_0'(x)\beta^*}), \quad (1.93)$$

令

$$\dot{\theta}_j = \log\left(\sum_{i=1}^j e^{\theta_i}\right) \quad (j = 1, \dots, q), \quad \dot{\theta}_0 = -\infty, \quad e^{\theta_j} = e^{\dot{\theta}_j} - e^{\dot{\theta}_{j-1}} \quad (1.94)$$

由(1.93)式有

$$\begin{aligned} P(\dot{Y} > r \mid x, \dot{Y} \geq r) &= 1 - P(\dot{Y} = r \mid x, \dot{Y} \geq r) = \exp(-e^{\theta_r + z_0'(x)\beta^*}) \\ \text{即 } P(\dot{Y} > r \mid x) / \{P(\dot{Y} = r \mid x) + P(\dot{Y} > r \mid x)\} &= \exp(-e^{\theta_r + z_0'(x)\beta^*}), \text{ 故} \\ P(\dot{Y} > r \mid x) / P(\dot{Y} = r \mid x) &= \frac{\exp(-e^{\theta_r + z_0'(x)\beta^*})}{1 - \exp(-e^{\theta_r + z_0'(x)\beta^*})} \\ &= \frac{\exp(-e^{\dot{\theta}_r + z_0'(x)\beta^*} + e^{\dot{\theta}_{r-1} + z_0'(x)\beta^*})}{1 - \exp(-e^{\dot{\theta}_r + z_0'(x)\beta^*} + e^{\dot{\theta}_{r-1} + z_0'(x)\beta^*})} \equiv J_1. \end{aligned}$$

又由(1.92)式,

$$\begin{aligned} P(\dot{Y} = r \mid x) &= (1 - \exp(-e^{\theta_r + z_0'(x)\beta^*})) \prod_{j=1}^{r-1} \exp(-e^{\theta_j + z_0'(x)\beta^*}) \\ &= (1 - \exp(-e^{\dot{\theta}_r + z_0'(x)\beta^*} + e^{\dot{\theta}_{r-1} + z_0'(x)\beta^*})) \exp(-e^{\dot{\theta}_{r-1} + z_0'(x)\beta^*}) \\ &= \exp(-e^{\dot{\theta}_{r-1} + z_0'(x)\beta^*}) - \exp(-e^{\dot{\theta}_r + z_0'(x)\beta^*}) \equiv J_2. \end{aligned}$$

因此有 $P(\dot{Y} \leq r \mid x) = 1 - P(\dot{Y} < r \mid x) = 1 - J_1 J_2 = 1 - \exp(-e^{\dot{\theta}_r + z_0'(x)\beta^*})$, 故

$$P(\dot{Y} > r \mid x) = \exp(-e^{\dot{\theta}_r + z_0'(x)\beta^*}) \quad (r = 1, \dots, q), \quad (1.95)$$

而这与(1.74)式一致, 只是(1.74)式中的 θ_r , 在此换成 $\dot{\theta}_r$.

序贯模型的联系函数易由(1.91)式得出: 把(1.91)式写为

$$\begin{aligned} P(\dot{Y} = r \mid \dot{Y} \geq r, x) &= \frac{P(\dot{Y} = r \mid x)}{P(\dot{Y} \geq r \mid x)} = \frac{\pi_{(r)}}{1 - (\pi_{(1)} + \pi_{(r-1)})} \\ &= F(\theta_r + z_0'(x)\beta^*) \end{aligned}$$

此处略去了 $\pi_{(j)}^{(x)}$ 中的 x , 于是, 若记联系函数 $g(\pi) = (g_1(\pi), \dots, g_q(\pi))'$, 则

$$g_r(\pi) = F^{-1}\left(\frac{\pi_{(r)}}{1 - \pi_{(1)} - \dots - \pi_{(r-1)}}\right) \quad (r = 1, \dots, q). \quad (1.96)$$

线性预测子 $z'(x)\beta$, 其中

$$z'(x) = \begin{bmatrix} 1 & & & z_0'(x) \\ & 1 & & z_0'(x) \\ & & \ddots & \vdots \\ 0 & & & 1 & z_0'(x) \end{bmatrix}, \quad \beta = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_q \\ \beta^* \end{bmatrix}$$

对序贯 logit 模型, 有 $F(t) = e^t / (1 + e^t)$, 而

$$F^{-1}(t) = \log \frac{t}{1-t},$$

故由(1.96)式, 有

$$g_r(\pi) = \log \frac{\pi_{(r)}}{1 - (\pi_{(1)} + \cdots + \pi_{(r)})} \quad (r = 1, \cdots, q), \quad (1.97)$$

比照(1.96)式与(1.56)式, 可以看出: 不论怎样选择 F , 也不可能得到自然联系. 因为, (1.96)式右边(在选定 F 后) 只与 $\pi_{(1)}, \cdots, \pi_{(r)}$ 有关, 而(1.56)式右边第 r 元 $\log \frac{\pi_{(r)}}{1 - \sum \pi}$, 则与整个 π 有关.

估计出 $\theta_1, \cdots, \theta_q$ 和 β^* , 可利用(1.92)式估计(据个体的 x 值) 该个体最终取序值 r 的概率. 而用(1.91)式可以估计在该个体已达到序值 r 的条件下, 该个体最终停留在 r 的概率.

在上述讨论中, 作了两个简化假定: 一是在各状态下使用同一些自变量 x . 二是在各状态下 x 的影响相同——这反映在使用同一个 β 上. 在这种可能: ①使用的 x 与个体当时所处序值有关; ②同一个因素, 在个体处在不同阶段时, 所起作用可以不同. 例如, 一个由助教升讲师时起作用的那些个人条件, 与他由副教授升教授时起作用的条件不尽一样. 例如基金的有无多少, 在前者作用不大而在后者作用大. 一个人的病是否稳定在 1 期, 所依赖的个人条件, 一般也可能与其能否稳定在 2 期的条件有所不同. 在这种较复杂的提法下, 相应的模型也不难提出. 至于 e_r 的分可以与 r 有关一点, 已在前面提及过了.

第 2 章

广义线性回归 极大似然估计的大样本理论

2.1 向量函数导数

设 $t = (t_1, \dots, t_p) \in \mathbb{R}^p$, 而

$$f(t) = \begin{bmatrix} f_1(t) \\ \vdots \\ f_q(t) \end{bmatrix},$$

则定义

$$\dot{f}(t) = \partial f / \partial t' = \begin{bmatrix} \partial f_1 / \partial t_1 & \partial f_1 / \partial t_2 & \cdots & \partial f_1 / \partial t_p \\ \partial f_2 / \partial t_1 & \partial f_2 / \partial t_2 & \cdots & \partial f_2 / \partial t_p \\ \vdots & \vdots & & \vdots \\ \partial f_q / \partial t_1 & \partial f_q / \partial t_2 & \cdots & \partial f_q / \partial t_p \end{bmatrix}$$

为 $q \times p$ 矩阵, 而

$$\dot{f}'(t) = \partial f' / \partial t = (\partial f / \partial t')',$$

这里, 上标“'”总是指向量或矩阵的转置, 而非导数.

若 $q = 1$, 则 $\partial f / \partial t$ 也有意义, 为

$$\partial f / \partial t = \begin{bmatrix} \partial f / \partial t_1 \\ \vdots \\ \partial f / \partial t_p \end{bmatrix},$$

而 $\dot{f}(t) = (\partial f / \partial t)'$ 为行向量. 若 $p = 1, q \geq 1$, 则

$$\partial f / \partial t = \begin{bmatrix} \partial f_1 / \partial t \\ \vdots \\ \partial f_q / \partial t \end{bmatrix}.$$

若 $p > 1, q > 1$, 则 $\partial f / \partial t$ 和 $\partial f' / \partial t'$ 都无意义.

若 $q = 1$, 则 $\partial(\partial f / \partial t) / \partial t'$ 为

$$f(t) \equiv \frac{\partial^2 f(t)}{\partial t \partial t'} \equiv \frac{\partial^2 f(t)}{\partial t' \partial t} \equiv (\partial^2 f / \partial t_i \partial t_j)_{i,j=1, \dots, p}$$

为 p 阶方阵, (i, j) 元为 $\partial^2 f / \partial t_i \partial t_j$. 当 $q > 1$ 时, $\dot{f}(t)$ 无定义.

若 $f(t) = t$, 则

$$\dot{f}(t) = I_p (p \text{ 为阶单位阵}), \quad f(t) = 0. \quad (2.1)$$

复合函数的导数

设 $F(t) = f(g(h(t)))$, 则

$$\dot{F}(t) = \dot{f}(v) \Big|_{v=g(h(t))} \dot{g}(w) \Big|_{w=h(t)} \dot{h}(t). \quad (2.2)$$

为书写简便, 常记 $\partial f(t)/\partial t' \Big|_{t=a}$ 为 $\dot{f}(a)$, 而记 $\partial f'(t)/\partial t \Big|_{t=a}$ 为 $\partial f'(a)/\partial t$, 于是

$$\dot{F}(t) = \dot{f}(g(h(t)))g(h(t))\dot{h}(t), \quad (2.2a)$$

$$\partial F'(t)/\partial t = \partial h'(t)/\partial t \cdot \partial g'(h(t))/\partial w \cdot \partial f'(g(h(t)))/\partial v. \quad (2.2b)$$

这里有一点易混淆, 即 $\dot{f}(g(h(t)))$ (例如) 可理解为 $\partial f(g(h(t)))/\partial t'$. 故我们约定: 在复合函数的情况, 加“ $\cdot$ ”运算只理解为对最外层变量. 如 $f(g(h(t)))$ 是 $f(w)$ 与 $w = g(h(t))$ 的复合, w 为外层. 故 $\dot{f}(g(h(t)))$, 依此规则, 理解为 $\dot{f}(w) \Big|_{w=g(h(t))} = \partial f(w)/\partial w' \Big|_{w=g(h(t))}$.

内积求导公式

若 $g(t), h(t)$ 为同维向量函数, $f(t) = g(t)h(t) = g'(t)h(t)$, 则

$$\dot{f}(t) = g'(t)\dot{h}(t) + h'(t)\dot{g}(t). \quad (2.3)$$

特别, 若 A 为 q 阶常矩 $\begin{bmatrix} a_1' \\ \vdots \\ a_q' \end{bmatrix}$, 则

$$f(t) \equiv Ag(t) = \begin{bmatrix} a_1'g(t) \\ \vdots \\ a_q'g(t) \end{bmatrix}.$$

按(2.3)式, $\partial(a_j'g(t))/\partial t' = a_j'g$, 故

$$\dot{f}(t) = A\dot{g} \quad (\text{若 } g(t) = t, \text{ 则为 } A). \quad (2.3a)$$

中值公式与积分公式

设 $f(t)$ 为 1 维, t 可以多维. 则

$$f(b) - f(a) = \dot{f}(t^*)(b - a), \quad (2.4)$$

其中, t^* 在 a, b 连线段 $\overline{ab}$ 内.

当 f 为多维 $(f_1, \dots, f_g)$ 时, (2.4) 式不适用. 因对每个 $j = 1, \dots, q$, 有 $f_j(b)$

$-f_j(a) = \dot{f}_j(t_j^*)(b-a)$, 故

$$f(b) - f(a) = \begin{bmatrix} \dot{f}_1(t_1^*) \\ \vdots \\ \dot{f}_q(t_q^*) \end{bmatrix} (b-a),$$

其中, $t_1^*, \dots, t_q^*$ 都在 $\overline{ab}$ 内, 但不必相同. 故上式不能写为 $f(b) - f(a) = \dot{f}(t^*)(b-a)$ 的形式.

现设 $b = a_n$, 而 $\lim_{n \rightarrow \infty} a_n = a$. 又 f (各分量) 在 a 的近邻有 1, 2 阶偏导数. 则因 $t_j^* \in \overline{aa_n}$, 有

$$\dot{f}_j(t_j^*) - \dot{f}_j(a) = (f_{j1}(t_j^*) - f_{j1}(a), \dots, f_{jp}(t_j^*) - f_{jp}(a)),$$

其中, f_{jt} 为 $\dot{f}_j$ 的第 t 分量, p 为 t 的维数. 对每个 $i = 1, \dots, p$ 用 (2.4) 式, 有

$$f_{jt}(t_j^*) - f_{jt}(a) = \dot{f}_{jt}(\tilde{t}_j)(t_j^* - a), \quad \tilde{t}_j \in \overline{at_j^*}.$$




图 2.1

因 $\|t_j^* - a\| \leq \|a_n - a\|$ (见图 2.1), 又因 $\dot{f}_{jt}(\tilde{t}_j)$ 各元涉及的为 f 的 2 阶偏导数, 在 a 近邻有界. 故由上式知

$$|f_{jt}(t_j^*) - f_{jt}(a)| = O(\|a_n - a\|).$$

因此

$$\begin{aligned} \dot{f}_j(t_j^*) &= \dot{f}_j(a) + (\dot{f}_j(t_j^*) - \dot{f}_j(a)) \\ &= \dot{f}_j(a) + O(\|a_n - a\|). \end{aligned}$$

由此得

$$\begin{aligned} f(a_n) - f(a) &= \begin{bmatrix} \dot{f}_1(t_1^*) \\ \vdots \\ \dot{f}_q(t_q^*) \end{bmatrix} (a_n - a) \\ &= \begin{bmatrix} \dot{f}_1(a) \\ \vdots \\ \dot{f}_q(a) \end{bmatrix} (a_n - a) + O(\|a_n - a\|)(a_n - a). \end{aligned}$$

当一个矩阵 $A = O(c_n)$ 时, 是指其各元皆为 $O(c_n)$, 上式最右边第 1 项为 $\dot{f}(a)(a_n - a)$, 第 2 项为 $O(\|a_n - a\|^2)$, 故有

$$f(a_n) - f(a) = \dot{f}(a)(a_n - a) + O(\|a_n - a\|^2). \quad (2.4a)$$

(2.4) 式对多维 f 不适用, 而(2.4a) 式中的余项的确切形式不明, 这有时不便使用, 这时下面的确切公式(积分公式) 有用:

$$f(b) - f(a) = \left(\int_0^1 \dot{f}(a + (b-a)u) du \right) (b-a). \quad (2.5)$$

证明容易. 任取 f 的分量 f_j , 令 $h(u) = f_j(a + (b-a)u)$, 则 $f_j(b) - f_j(a) = h(1) - h(0) = \int_0^1 \frac{\partial h(u)}{\partial u} du$. 按复合函数求导公式, $\partial h(u)/\partial u = \dot{f}_j(a + (b-a)u) \partial\{(b-a)u\}/\partial u = \dot{f}_j(a + (b-a)u)(b-a)$. 因此

$$\begin{aligned} f_j(b) - f_j(a) &= \int_0^1 \{ \dot{f}_j(a + (b-a)u)(b-a) \} du \\ &= \left[\int_0^1 \dot{f}_j(a + (b-a)u) du \right] (b-a) \end{aligned}$$

对 $j = 1, \dots, q$ 成立, 即(2.5) 式, 因

$$\dot{f}(t) = \begin{bmatrix} \dot{f}_1(t) \\ \vdots \\ \dot{f}_q(t) \end{bmatrix}.$$

对 1 维 f_1 , 此法可继续使用以得到 2 阶表达式:

$$\dot{f}(a + (b-a)u) = \dot{f}(a) + [\dot{f}(a + (b-a)u) - \dot{f}(a)].$$

对后一项用(2.5) 式, 得把 $\dot{f}$ 转置成列, 以适应(2.5) 式. 又以 $c = a + (b-a)u$, 得 $a + (c-a)v = a + (b-a)uv$:

$$\begin{aligned} \dot{f}'(a + (b-a)u) - \dot{f}'(a) &= \left(\int_0^1 (\dot{f}') (a + (b-a)uv) dv \right) (b-a)u \\ &= \left(\int_0^1 \dot{f}(a + (b-a)uv) dv \right) (b-a). \end{aligned}$$

因 f 对称, 有(上式转置)

$$\begin{aligned} \dot{f}(a + (b-a)u) - \dot{f}(a) &= (b-a)' \int_0^1 \dot{f}(a + (b-a)uv) u dv \\ &= (b-a)' \int_0^u \dot{f}(a + (b-a)w) dw \end{aligned}$$

代入(2.5) 式得

$$f(b) - f(a)$$

$$\begin{aligned}
&= \left\{ \int_0^1 [\dot{f}(a) + (b-a)' \int_0^u f(a + (b-a)w) dw] du \right\} (b-a) \\
&= \dot{f}(a)(b-a) + (b-a)' \int_0^1 \left\{ \int_0^u f(a + (b-a)w) dw \right\} du \cdot (b-a) \\
&= \dot{f}(a)(b-a) + (b-a)' \left\{ \int_0^1 \left(\int_w^1 du \right) \dot{f}(a + (b-a)w) dw \right\} (b-a) \\
&= \dot{f}(a)(b-a) + (b-a)' \left\{ \int_0^1 (1-w) f(a + (b-a)w) dw \right\} (b-a).
\end{aligned} \tag{2.5a}$$

这就是所要的公式,若 $b-a \approx 0$ 而 f 连续,则

$$f(a + (b-a)w) = f(a) + o(1). \tag{2.5b}$$

而由(2.5a)式有

$$\begin{aligned}
&f(b) - f(a) \\
&= \dot{f}(a)(b-a) + \frac{1}{2}(b-a)' \ddot{f}(a)(b-a) + o(\|b-a\|^2) \tag{2.5c}
\end{aligned}$$

若 f 的3阶导数在 a 的近邻存在有界,则(2.5b)式中的 $o(1)$ 枯叶加强为 $O(\|b-a\|)$, 而(2.5c)式可改进为

$$\begin{aligned}
&f(b) - f(a) \\
&= \dot{f}(a)(b-a) + \frac{1}{2}(b-a)' \ddot{f}(a)(b-a) + O(\|b-a\|^3). \tag{2.5d}
\end{aligned}$$

反函数求导公式

设1维或多维函数 $f(t)$ 反函数存在,记为 $u = f^{-1}(t)$. 则 $t = f(u)$. 故按复合函数求导公式,有

$$I = \partial t / \partial t' = \dot{f}(u) u(t).$$

由此得

$$\dot{u}(t) \equiv \partial u(t) / \partial t' = (\dot{f}(u))^{-1} = \dot{f}^{-1}(f^{-1}(t)). \tag{2.6}$$

若 $u(t) = \dot{b}'^{-1}(t)$, 则 $f = \dot{b}'$, 而 $\dot{f} = b$, 故

$$\partial \dot{b}'^{-1}(t) / \partial t' = b^{-1}(\dot{b}'^{-1}(t)). \tag{2.7}$$

2.2 自然联系

2.2.1 导出似然方程

设独立样本 (y_i, x_i) ($1 \leq i \leq n$), y_i 为 q 维, y_i 有分布

$$c(y_i) \exp(y_i' \theta_i - b(\theta_i)) d\nu(y_i), \quad \text{Cov}(y_i) = \dot{b}(\theta_i), \quad E(y_i) = \dot{b}'(\theta_i) \quad (2.8)$$

$c(y_i) > 0$ 不依赖 θ_i , θ_i 通过下述关系与线性预测子 $z_i' \beta$ 发生关系:

$$\theta_i = u(z_i' \beta) \quad (2.9)$$

$z_i = z(x_i)$ 为已知 $p \times q$ 阵. 此式应理解为: 当参数真值为 β 值时, y_i 分布中的参数为 $u(z_i' \beta)$. 于是, 由 β (待估参数) 及已知的 z_i , 决定了 θ_i , 按 (2.8) 式, 决定了 y_i 的分布, 因而其均值 $E_{\beta}(y_i)$, 记为 $\mu_i(\beta)$ 或 $\mu(z_i' \beta)$, 因 θ_i 是通过 $z_i' \beta$ 依赖 β .

以 g 记联系函数, 即

$$g(\mu(z_i' \beta)) = z_i' \beta \Rightarrow \mu(z_i' \beta) = h(z_i' \beta), \quad h = g^{-1}. \quad (2.9a)$$

另一方面, $\mu(z_i' \beta) = \dot{b}'(\theta_i)$, 故 $\theta_i = \dot{b}'^{-1}(\mu(z_i' \beta))$. 由 (2.9a) 式有

$$\theta_i = \dot{b}'^{-1}(h(z_i' \beta)) \quad (\text{注意 } \dot{b} \text{ 为行, } \dot{b}' \text{ 为列}). \quad (2.10)$$

比较 (2.9) 式和 (2.10) 式, 得

$$u(t) = \dot{b}'^{-1}(h(t)) = \dot{b}'^{-1}(g^{-1}(t)) \quad (2.10a)$$

由 (2.9a) 式, 知 $\mu(t)$ 和 $h(t)$ 是一个函数, 引进 μ 是强调其为均值的特点.

似然函数为 (2.8) 式对 $i = 1, \dots, n$ 之积. 取对数, 并略去与 θ_i 无关的部分, 且以 (2.9) 式取代 θ_i , 有

$$l_n(\beta) = \sum_{i=1}^n [y_i' u(z_i' \beta) - b(u(z_i' \beta))] \quad (2.11)$$

$l_n(\beta)$ 称为对数似然函数.

β 可允许取值范围:

因 (2.8) 式为分布, 其在 $\mathbb{R}^q$ 上之积分为 1. 因此 θ_i 必须在集

$$\Theta = \left\{ \theta_i : \int_{\mathbb{R}^q} c(y) \exp(y' \theta) d\nu(y) < \infty \right\} \quad (\Theta \text{ 为凸集})$$

内, $\dot{\Theta}$ 不依赖 i , 是 θ 的参数空间. 为避免数学上的困难, 去掉 Θ 的边界点, 剩下 Θ 的内点集 Θ° 作为 θ 的空间. 由 (2.9) 式, 知 β 必须在集合

$$B^\circ = \{\beta : u(z_i, \beta) \in \Theta^\circ, 1 \leq i \leq n\}$$

内. 因 u 连续 (因 $\dot{b}^{-1}$ 及 h 连续 (由联系函数 g 连续推出)), 知 B° 为开集, 注意 B° 依赖 $z_1, \dots, z_n$.

以 β_0 记 β 的真值. β_0 的极大似然估计 (MLE) 是满足

$$\hat{\beta}_n \in B^\circ, \quad l_n(\hat{\beta}_n) = \sup\{l_n(\beta) : \beta \in B^\circ\} \quad (2.12)$$

的 $\hat{\beta}_n$ 点 $\hat{\beta}_n$, 以及 l_n 在 B° 内任一局部极值点, 都满足似然方程

$$S_n(\beta) \equiv \partial l_n(\beta) / \partial \beta = 0, \quad (2.13)$$

其解, 称为似然解. 为求似然方程, 记

$$U(t) = \dot{u}(t), \quad (2.14)$$

则由复合函数求导公式, 有

$$\begin{aligned} \partial b(u(z_i, \beta)) / \partial \beta &= (\partial b(u(z_i, \beta)) / \partial \beta')' \\ &= (\dot{b}(u(z_i, \beta)) U(z_i, \beta) z_i')' \\ &= z_i U'(z_i, \beta) \dot{b}'(u(z_i, \beta)) = z_i U'(z_i, \beta) \mu(z_i, \beta). \end{aligned} \quad (2.15)$$

后一式因 $\mu(z_i, \beta) = E_\beta(y_i) = \dot{b}'(\theta_i) = \dot{b}'(u(z_i, \beta))$. 而

$$\begin{aligned} \partial(y_i' u(z_i, \beta)) / \partial \beta &= (\partial(y_i' u(z_i, \beta)) / \partial \beta')' \\ &= (y_i' U(z_i, \beta) z_i')' = z_i U'(z_i, \beta) y_i. \end{aligned}$$

由此及 (2.11) 式, 得似然方程

$$S_n(\beta) \equiv \partial l_n(\beta) / \partial \beta = \sum_{i=1}^n z_i U'(z_i, \beta) (y_i - \mu(z_i, \beta)) = 0. \quad (2.16)^\text{①}$$

自然联系

当 u 为恒等函数, 即 $\theta_i = u(z_i, \beta) = z_i' \beta$ 时, 称自然联系. 由 (2.10) 式, 有

$$h(z_i, \beta) = \dot{b}'(\theta_i) = \dot{b}'(z_i' \beta) \Rightarrow h = \dot{b}' \Rightarrow g = h^{-1} = \dot{b}'^{-1}$$

即相应于取联系函数 g 为 $\dot{b}'^{-1}$ 时, 称为自然联系函数. 因 $u(t) = t$, 有 $U(t) =$

① 利用 $u(t)$ 的表达式 (2.10), 公式 (2.7) 及 (2.10), 以及 $\text{Cov}(y_i) = b(\theta_i)$, 可将 (2.16) 式写为 $\sum_{i=1}^n \text{Cov}^{-1} \frac{\partial \mu_i'}{\partial \beta} (y_i - \mu_i) = 0$, $\mu_i = \mu(z_i, \beta) = E(y_i)$ 这突出了似然方程只依赖 $E(y_i)$ 和 $\text{Cov}(y_i)$, 在 GEE 中常用这一形式

I , 而(2.16)式化简为

$$S_n(\beta) = \sum_{i=1}^n z_i (y_i - \mu(z_i' \beta)) = 0, \quad (2.17)$$

在2.2节中总假定取自然联系.

在自然联系下, β 的空间 B° 为凸集. 事实上, 设 $\beta^{(1)}, \beta^{(2)} \in B^\circ$, 则依 B° 的定义, 有

$$\theta^{(j)} = u(z_i' \beta^{(j)}) = z_i' \beta^{(j)} \in \Theta^\circ \quad (j = 1, 2).$$

现设 $0 < c < 1$, 则

$$z_i' (c\beta^{(1)} + (1-c)\beta^{(2)}) = c\theta^{(1)} + (1-c)\theta^{(2)} \in \Theta^\circ,$$

因 Θ° 为凸, 故由 B° 定义, 知 $c\beta^{(1)} + (1-c)\beta^{(2)} \in B^\circ$. 这证明了 B° 为凸.

2.2.2 自然联系下似然解的唯一性(即 MLE 的唯一性, 见下)

定理 2.1 在自然联系下, 若

$$T_n \equiv \sum_{i=1}^n z_i z_i' > 0 \quad (2.18)$$

($A > 0$ 表示 A 正定, $A > B$ 表示 $A - B > 0$. 若改 $>$ 为 $\geq$, 称半正定), 则似然解唯一.

证明用到以下的简单引理.

引理 2.1 设 $z_1, \dots, z_n$ 都是 $p \times q$ 矩阵, $A_1, \dots, A_n$ 都是 q 阶正定阵. 则当(2.18)式成立时, 有

$$\sum_{i=1}^n z_i A_i z_i' > 0.$$

证 因 $A_i > 0$, 存在常数 $c_i > 0$ 使 $A_i > c_i I_q, 1 \leq i \leq n$. 记 $c = \min(c_1, \dots, c_n)$, 则 $c > 0, A_i > c I_q (1 \leq i \leq n)$. 故

$$\sum_{i=1}^n z_i A_i z_i' > c \sum_{i=1}^n z_i I_q z_i' = c \sum_{i=1}^n z_i z_i' > 0.$$

回到定理的证明. 设 $\beta^{(1)} \neq \beta^{(2)}$, 都是似然解. 则 $S_n(\beta^{(2)}) - S_n(\beta^{(1)}) = 0$. 按(2.5)式, 有

$$0 = \left(\int_0^1 \dot{S}_n(\beta^{(1)} + (\beta^{(2)} - \beta^{(1)})u) du \right) (\beta^{(2)} - \beta^{(1)}).$$

由 $S_n(\beta)$ 的表达式(2.17)式, 并注意在自然联系下, 有

$$\mu(z_i' \beta) = h(z_i' \beta) = b'(z_i' \beta)$$

得

$$\dot{S}_n(\beta) = - \sum_{i=1}^n z_i b(z_i' \beta) z_i' (= - \sum_{i=1}^n z_i \text{Cov}_\beta(y_i) z_i' = - F_n(\beta)). \quad (2.18a)$$

故有

$$0 = \left(\int_0^1 - \sum_{i=1}^n z_i b(z_i(\beta^{(1)} + (\beta^{(2)} - \beta^{(1)})u)) z_i' \right) du (\beta^{(2)} - \beta^{(1)}).$$

左乘 $(\beta^{(2)} - \beta^{(1)})'$, 有

$$(\beta^{(2)} - \beta^{(1)})' \int_0^1 \left(\sum_{i=1}^n z_i b(\cdots) z_i' \right) du (\beta^{(2)} - \beta^{(1)}) = 0. \quad (2.19)$$

因 b 恒大于 0, 故按引理, 总有 $\sum_{i=1}^n z_i b(\cdots) z_i' > 0$, 故

$$A \equiv \int_0^1 \left(\sum_{i=1}^n z_i b(\cdots) z_i' \right) du > 0.$$

于是由 (2.19) 式, 有 $(\beta^{(2)} - \beta^{(1)})' A (\beta^{(2)} - \beta^{(1)}) = 0$. 因 $A > 0$, 必有 $\beta^{(2)} - \beta^{(1)} = 0$, 与 $\beta^{(1)} \neq \beta^{(2)}$ 矛盾. 证毕.

注 2.1 由 (2.18) 式, 及 $\dot{S}_n(\beta) = l_n(\beta)$, 以及上面所证的 $\sum_{i=1}^n z_i b(z_i' \beta) z_i' > 0$, 由此知 $- \dot{l}_n(\beta) > 0$.




图 2.2

关于似然方程 $S_n(\beta) = 0$ 根的存在, 相合性与渐近正态性, 其证明的思想如下:

β 为 p 维. 在 $\mathbb{R}^p$ 中作一个以真值 β_0 为中心的椭球 $A \subset B^o$, 如图 2.2. 以 $l_n(\beta)$ 记对数似然函数, $S_n(\beta) = \partial l_n(\beta) / \partial \beta$. 设法证明:

$$\sup\{l_n(\beta) : \beta \in \partial A\} < l_n(\beta_0).$$

由此式知, $l_n(\beta)$ 在 $\beta \in A$ 上的(局部)极大值不能在边界 ∂A 上达到, 而必在 A 内部某点 $\hat{\beta}_n$ 处达到. 因此在 $\hat{\beta}_n$ 点处, l_n 对 β 的偏导数为 0:

$$S_n(\hat{\beta}_n) = \partial l_n(\beta) / \partial \beta \Big|_{\hat{\beta}_n} = 0,$$

即 $\hat{\beta}_n$ 为似然方程的一根. 这证明了似然解为存在性. 据前述, 在自然联系下, 似然解唯一且就是 MLE.

适当取 A 使它随样本量 n 增加而缩小至 β_0 一点, 则将得 $\hat{\beta}_n \rightarrow \beta_0 (n \rightarrow \infty)$. 这证明了 $\hat{\beta}_n$ 为 β_0 的相合估计.

为证 $\hat{\beta}_n$ 渐近正态, 注意 $S_n(\hat{\beta}_n) = 0$, 故

$$\begin{aligned} S_n(\beta_0) &= S_n(\beta_0) - S_n(\hat{\beta}_n) \quad (\text{用积分公式}) \\ &= \left[\int_0^1 -\dot{S}_n(\beta_0 + (\hat{\beta}_n - \beta_0)u) du \right] (\hat{\beta}_n - \beta_0) \\ &\equiv B_n(\hat{\beta}_n - \beta_0) \Rightarrow (\hat{\beta}_n - \beta_0) = B_n^{-1} \cdot S_n(\beta_0). \end{aligned}$$

因已证 $\hat{\beta}_n$ 相合而 $0 \leq u \leq 1$, 知

$$\beta_0 + (\hat{\beta}_n - \beta_0)u \approx \beta_0,$$

故

$$-\dot{S}_n(\beta_0 + (\hat{\beta}_n - \beta_0)u) \approx -\dot{S}_n(\beta_0).$$

而在自然联系下, 有

$$-\dot{S}_n(\beta_0) = \sum_{i=1}^n z_i \Sigma_i z_i' \quad \begin{pmatrix} z_i = z(x_i) \\ \Sigma_i = \Sigma(z_i, \beta_0) \end{pmatrix}$$

为非随机方阵. 故

$$\hat{\beta}_n - \beta_0 \approx \left(\sum_{i=1}^n z_i \Sigma_i z_i' \right)^{-1} S_n(\beta_0)$$

而

$$S_n(\beta_0) = \sum_{i=1}^n z_i (y_i - \mu(z_i, \beta_0)), \quad (2.19a)$$

其中, $y_i - \mu(z_i, \beta_0)$ ($i = 1, 2, \dots$), 独立且有均值 0. 按中心极限定理, 在一定的条件下, 其线性组合, 即 (2.19a) 式的右边, 有渐近正态性. 这就证明了 $\hat{\beta}_n - \beta_0$ 的渐近正态性.

由凸分析知, 一严凸函数在一开凸集上 (我们前已指出, 在自然联系下, β 的空间 B° 为开凸集) 无局部极大点. 若有局部极小点, 则必唯一, 且就是全局极小点. 因此, $l_n(\beta) (= -(-l_n(\beta)))$, 是严凸函数之负) 若在 B° 内有全局极大点, 则

它必唯一,这证明了 MLE 的唯一性.

这结果形式上与定理 2.1 有差别,因后者证明似然解唯一而此结果证明 MLE 唯一,但在此处 $-l_n(\beta)$ 为严凸函数的情况,二者一致,因 MLE 与似然解一致,因此,往下讨论 MLE 的性质时,可以用似然解取代 MLE 去研究.

2.2.3 一些备用条件

现引进几个记号及条件,并讨论它们之间的关系.

y_i 相应的参数为 $\theta_i = z_i'\beta$. 故所有与 $y_1, \dots, y_n$ 有关的量,如 y_i 本身及 $S_n(\beta)$ 等的均值、协方差阵等,都与 β 有关. 因此,如 $y_i, S_n(\beta)$ 的协方差阵,记为 $\text{Cov}_\beta(y_i), \text{Cov}_\beta(S_n(\beta))$,以显示其与 β 有关. 由指数族的性质, $\text{Cov}_\beta(y_i) = \dot{b}(\theta_i) = b(z_i'\beta)$. 以后常以 Σ 取代 b ,以突出其为协方差阵,故 $\text{Cov}_\beta(y_i) = \Sigma(z_i'\beta)$.

记 $F_n(\beta) = \text{Cov}_\beta(S_n(\beta))$. 由于 $S_n(\beta)$ 中各项独立(因 y_i 独立),又 $\text{Cov}_\beta(z_i y_i) = z_i \text{Cov}_\beta(y_i) z_i' = z_i \Sigma(z_i'\beta) z_i'$, 故

$$F_n(\beta) \equiv \text{Cov}_\beta(S_n(\beta)) = \sum_{i=1}^n z_i \Sigma(z_i'\beta) z_i' (= l_n(\beta)). \quad (2.20)$$

设 β_0 为 β 的“真值”(β 是流动值),它就是我们估计的对象. 约定:凡一个依赖 β 的量其 β 取值 β_0 时,略去 β_0 . 故 S_n, F_n 分别是 $S_n(\beta_0), F_n(\beta_0)$ 等等.

按引理 2.1,在条件(2.18)式成立时, $F_n(\beta) > 0$, 故 $F_n > 0$. 故存在唯一的方阵 $A > 0$ 使 $A^2 = F_n$. 此 A 记为 $F_n^{1/2}$. 它对称正定. 给定 $\delta > 0$, 定义集合

$$N_n(\delta) = \{\beta : \|F_n^{1/2}(\beta - \beta_0)\| \leq \delta\}, \quad (2.21)$$

$\|a\|$ 表向量 a 之长,即 $(a'a)^{1/2}$. $N_n(\delta)$ 是一以 β_0 为中心的闭椭圆,如图 2.3.

其边界为

$$\partial N_n(\delta) = \{\beta : \|F_n^{1/2}(\beta - \beta_0)\| = \delta\}.$$

对任一对称方阵 A , 以 $\underline{\lambda}(A)$ 和 $\bar{\lambda}(A)$ 分别记其最小和最大特征根. 有 $\underline{\lambda} \|a\|^2 \leq a'Aa \leq \bar{\lambda}(A) \|a\|^2$ 对任何向量 a . 因此,若 $\beta \in N_n(\delta)$, 则 $\|F_n^{1/2}(\beta - \beta_0)\|^2 = (\beta - \beta_0)' F_n^{1/2} F_n^{1/2} (\beta - \beta_0) = (\beta - \beta_0)' F_n (\beta - \beta_0) \leq \delta^2$. 故 $\underline{\lambda}(F_n) \|\beta - \beta_0\|^2 \leq (\beta - \beta_0)' F_n (\beta - \beta_0) \leq \delta^2$. 即




图 2.3

$$\|\beta - \beta_0\| \leq \delta / \sqrt{\lambda(F_n)}, \quad \beta \in N_n(\delta). \quad (2.21a)$$

对任何矩阵 $A = (a_{ij})$, 以 $|A|$ 记 $\max_{i,j} |a_{ij}|$, $\det(A)$ 记 A 的行列式, 对方阵 $A = (a_{ij})$, 以 $\text{tr}(A)$ 记其 trace, 即 $\sum_i a_{ii}$. 习知若 A, B 分别为 $m \times n$ 及 $n \times m$, 则 $\text{tr}(AB) = \text{tr}(BA)$. 对于对称方阵 A , $\text{tr}(A) = A$ 的一切特征根之和.

关于 $|A|$ 有以下的简单引理.

引理 2.2 设 $A_n = (a_{ij}^{(n)})$ 为 m 阶对称方阵 ($n = 1, 2, \dots$). 又存在一串非负常数 $c_n \rightarrow 0$, 使 $-c_n I_m \leq A_n \leq c_n I_m$. 则

$$\lim_{n \rightarrow \infty} |A_n| = 0.$$

证 因 A_n 对称, 有 m 阶正交阵 $H_n = (h_{ij}^{(n)})$, 使 $A_n = H_n \Lambda_n H_n'$, 其中, Λ_n 为对角阵

$$\Lambda_n = \begin{bmatrix} \lambda_{n1} & & 0 \\ & \ddots & \\ 0 & & \lambda_{nm} \end{bmatrix} \quad (\lambda_{n1}, \dots, \lambda_{nm} \text{ 为 } A_n \text{ 的特征根}).$$

由 $-c_n I_m \leq A_n \leq c_n I_m$ 知 $|\lambda_{nj}| \leq c_n (1 \leq j \leq m)$. 故由

$$a_{ij} = \sum_{k=1}^m \lambda_{nk} h_{ik}^{(n)} h_{kj}^{(n)}$$

及 $|h_{ij}^{(n)}| \leq 1$, 对 $i, j = 1, \dots, m$ (因 H_n 正交), 有

$$|a_{ij}^{(n)}| \leq \max_k |\lambda_{nk}| \sum_{k=1}^m |h_{ik}^{(n)}| |h_{kj}^{(n)}| \leq c_n m \quad (i, j = 1, \dots, m).$$

故 $|A_n| \leq m c_n \rightarrow 0$, 因 $c_n \rightarrow 0$. 引理证毕.

现引进以下条件:

(D)

$$\lambda(F_n) \rightarrow \infty \quad (n \rightarrow \infty). \quad (2.22)$$

此条件与 $F_n^{-1} \rightarrow 0$ 等价, 因 F_n^{-1} 的特征根为 F_n 的特征根倒数. 由 (2.21a) 知, 当条件 (D) 成立时, 有

$$\sup\{\|\beta - \beta_0\| : \beta \in N_n(\delta)\} \rightarrow 0, \quad (2.22a)$$

即当 $n \rightarrow \infty$ 时, $N_n(\delta)$ 缩向其中 β_0 . 记

$$V_\epsilon(\beta_0) = \{\beta : \|\beta - \beta_0\| < \epsilon\},$$

即以 β_0 为中心, ϵ 为半径的开球. 由 (2.22a) 式知, 当条件 (D) 成立时, 对任何 $\epsilon > 0$, 当 n 充分大时, 有

$$N_n(\delta) \subset V_\epsilon(\beta_0) \quad (n \text{ 充分大}). \quad (2.22b)$$

(C) 存在常数 $c > 0$ (与下文的 δ 无关), 使对任给 $\delta > 0$, 存在 $n_1 = n_1(\delta)$, 使当 $n \geq n_1$ 时, 有

$$F_n(\beta) \geq cF_n, \quad \beta \in N_n(\delta). \quad (2.23)$$

若记 $V_n(\beta) = F_n^{-1/2} F_n(\beta) F_n^{-1/2}$, 则(2.23)式左、右乘 $F_n^{-1/2}$, 得

$$V_n(\beta) \geq cI, \quad n \geq n_1, \quad \beta \in N_n(\delta), \quad (2.23a)$$

反过来, 由(2.23a)式也易得(2.23)式, 故二者等价. 又由 $V_n(\beta)$ 定义, 知

$$V_n \equiv V_n(\beta_0) = I. \quad (2.23b)$$

(N)

$$\sup\{|V_n(\beta) - I| : \beta \in N_n(\delta)\} \rightarrow 0. \quad (2.24)$$

引理 2.3 若对任何 $\epsilon > 0$ 存在 $n_1 = n_1(\epsilon)$, 使当 $n \geq n_1$ 时, 有 ($\leq$ 是半正定意义)

$$(1 - \epsilon)F_n \leq F_n(\beta) \leq (1 + \epsilon)F_n, \quad \beta \in N_n(\delta), \quad (2.24a)$$

则条件(N)成立. 反过来, 由条件(N)可推出(2.24a)式.

证 把(2.24a)式各项左右各乘 $F_n^{-1/2}$, 得

$$(1 - \epsilon)I \leq V_n(\beta) \leq (1 + \epsilon)I, \quad \beta \in N_n(\delta), \quad (2.24b)$$

即

$$-\epsilon I \leq V_n(\beta) - I \leq \epsilon I, \quad \beta \in N_n(\delta).$$

按引理 2.2 的证明, 由上式得 $|V_n(\beta) - I| \leq q\epsilon$ (q 为 F_n 的阶, ϵ 相当该引理中的 $c_n, n \rightarrow \infty$), 对 $\beta \in N_n(\delta)$. 因 $\epsilon > 0$ 可任意小, 这表明条件(N)成立.

反过来, 若条件(N)成立, 则当 n 充分大时, $V_n(\beta) - I$ 各元绝对值, 对 $\beta \in N_n(\delta)$ 一致收敛于 0. 因此对任给 $\epsilon > 0$, 当 n 充分大时应有 $-\epsilon I \leq V_n(\beta) - I \leq \epsilon I$, 即(2.24b)式. 对(2.24b)式各项两边乘以 $F_n^{1/2}$, 即得(2.24a)式. 引理证毕.

引理 2.4 (N) $\Rightarrow$ (C).

证 若(N)成立, 则由引理 2.3, 有 $F_n(\beta) \geq (1 - \epsilon)F_n$. 即(2.23)式 ($c = 1 - \epsilon$). 引理证毕.

此引理之逆不真: (C) $\nRightarrow$ (N).

(S₀) ($\delta > 0$ 给定) 存在 $\epsilon > 0, c > 0$ 及 n_1 , 使

$$\inf\{\underline{\lambda}(F_n(\beta)) : \beta \in V_\epsilon(\beta_0)\} \geq c(\bar{\lambda}(F_n))^{1/2+\delta}, \quad n \geq n_1. \quad (2.25)$$

注 2.2 由条件(注意 $\Sigma_i = \Sigma(z_i', \beta_0)$)

$$(1 - \epsilon)\Sigma_i \leq \Sigma(z_i', \beta) \leq (1 + \epsilon)\Sigma_i, \quad \beta \in N_n(\delta), \quad (2.26)$$

可推出(2.24a)式,因而推出(N).事实上,(2.26)式各项左乘 z_i ,右乘 z_i' ,再对 $i = 1, \dots, n$ 相加,即得(2.24a)式.

引理 2.5 (D) + (S_{1/2}) $\Rightarrow$ (C).

证 由条件(S_{1/2})知 $\underline{\lambda}(F_n(\beta)) \geq c\bar{\lambda}(F_n)$, $\beta \in V_\epsilon(\beta_0)$, n 充分大.由条件(D)知 $N_n(\delta) \subset V_\epsilon(\beta_0)$ 当 n 充分大(见(2.22b)式).故知当 n 充分大时,有

$$\underline{\lambda}(F_n(\beta)) \geq c\bar{\lambda}(F_n), \quad \beta \in N_n(\delta),$$

即条件(C)成立.引理证毕.

2.2.4 自然联系下 MLE 的存在与弱相合(WC)

定义 β_0 的估计量 $\hat{\beta}_n$ 如下($\hat{\beta}_n$ 称为 β_0 的MLE)

$$\begin{aligned} \hat{\beta}_n &\equiv \hat{\beta}_n(y_1, \dots, y_n) \\ &= \begin{cases} l_n(\beta) \text{ 在 } B^\circ \text{ 的全局极大点,} & \text{若存在全局极大点} \\ B^\circ \text{ 中选定一点 } \beta^*, & \text{若不存在全局极大点.} \end{cases} \end{aligned}$$

定理 2.2 在(D) + (C)之下,有

$$\lim_{n \rightarrow \infty} P(l_n(\beta) \text{ 在 } B^\circ \text{ 的全局极大点存在}) = 1, \quad (2.27)$$

$$\hat{\beta}_n \rightarrow \beta_0 \text{ in pr. (依概率收敛于 } \beta_0, \text{ 即 WC).} \quad (2.28)$$

证 记事件

$$\begin{aligned} G_n &= \{l_n(\beta) \text{ 在 } B^\circ \text{ 上的全局极大点存在}\}, \\ H_n &= \{l_n(\beta_0) > \sup\{l_n(\beta) : \beta \in \partial N_n(\delta)\}\}. \end{aligned}$$

往证 $H_n \subset G_n$, $P(H_n) \rightarrow 1$.若此已证,则有 $P(G_n) \rightarrow 1$.即(2.27)式. $H_n \subset G_n$ 前已指出,因 H_n 成立表明 $l_n(\beta)$ 在 $N_n(\delta)$ 内有一局部极大点.而由于 $-l_n(\beta)$ 严凸.它也是全局极大点(注2.1),即 G_n 成立.

为证 $P(H_n) \rightarrow 1$,取 $\beta \in \partial N_n(\delta)$.用Talor展开(2.5a)式,并注意 $l_n(\beta) = -F_n(\beta)$ (见(2.20)式), $\partial l_n / \partial \beta = S_n(\beta)$,有

$$\begin{aligned} l_n(\beta) - l_n(\beta_0) &= (\beta - \beta_0)' S_n - (\beta - \beta_0)' \int_0^1 (1-w) F_n(\beta_w) dw (\beta - \beta_0), \quad (2.29) \end{aligned}$$

其中, $\beta_w = \beta_0 + (\beta - \beta_0)w$.因为 β_0 和 β 都 $\in N_n(\delta)$,有 $\beta_w \in N_n(\delta)$.故由条件(C),知当 n 充分大时, $F_n(\beta_w) \geq cF_n$, $c > 0$,对一切 $w \in [0, 1]$.故

$$\int_0^1 (1-w) F_n(\beta_w) dw > c F_n \int_0^1 (1-w) dw = \frac{c}{2} F_n. \quad (2.29a)$$

因此, 注意 $\beta \in \partial N_n(\delta)$, 因而 $\|F_n^{1/2}(\beta - \beta_0)\| = \delta$, 有

$$\begin{aligned} & (\beta - \beta_0)' \int_0^1 (1-w) F_n(\beta_w) dw (\beta - \beta_0) \\ & \geq \frac{c}{2} (\beta - \beta_0)' F_n (\beta - \beta_0) \\ & = \frac{c}{2} \|F_n^{1/2}(\beta - \beta_0)\|^2 = c\delta^2/2. \end{aligned}$$

故由此及(2.29)式, 知 $l_n(\beta) - l_n(\beta_0) \leq (\beta - \beta_0)' S_n - c\delta^2/2$, 对一切 $\beta \in \partial N_n(\delta)$. 所以若定义事件

$$M_n = \{(\beta - \beta_0)' S_n < c\delta^2/2 \text{ 对一切 } \beta \in \partial N_n(\delta) \text{ 成立}\}$$

则 $M_n \subset H_n$. 因 $(\beta - \beta_0)' S_n = (\beta - \beta_0)' F_n^{1/2} F_n^{-1/2} S_n$, 有

$$|(\beta - \beta_0)' S_n| \leq \|(\beta - \beta_0) F_n^{1/2}\| \|F_n^{-1/2} S_n\| = \delta \|F_n^{-1/2} S_n\|.$$

定义事件 $A_n = \{\|F_n^{-1/2} S_n\| < c\delta/2\}$, 则 $A_n \subset M_n \subset H_n$. 为证 $P(H_n) \rightarrow 1$, 只需证

$$P(A_n) \rightarrow 1 \quad (n \rightarrow \infty). \quad (2.30)$$

因 $S_n = \sum_{i=1}^n z_i (y_i - \mu_i(\beta_0))$, 而 $\mu_i(\beta_0)$ 为 $E(y_i)$, 故 $E(S_n) = 0$. 由 $y_1, \dots, y_n$ 独立, 知 $E\{(y_i - \mu_i(\beta_0))(y_j - \mu_j(\beta_0))\} = \text{Cov}_{\beta_0}(y_i) \Sigma(z_i' \beta_0) (i = j)$, 该式等于 0 ($i \neq j$),

$$\begin{aligned} E(S_n S_n') &= \sum_{i,j=1}^n z_i E[(y_i - \mu_i(\beta_0))(y_j - \mu_j(\beta_0))'] z_j' \\ &= \sum_{i=1}^n z_i \Sigma z_i' \beta_0 z_i' = F_n. \end{aligned} \quad (2.31)$$

现由 Markov 不等式, 得

$$\begin{aligned} P(A_n) &\geq P(\|F_n^{-1/2} S_n\|^2 < (c\delta/2)^2) = 1 - P(\|F_n^{-1/2} S_n\|^2 \geq (c\delta/2)^2) \\ &\geq 1 - \frac{1}{(c\delta/2)^2} E(\|F_n^{-1/2} S_n\|^2) = 1 - \frac{4}{c^2 \delta^2} E(S_n' F_n^{-1} S_n). \end{aligned} \quad (2.31a)$$

因 $S_n' F_n^{-1} S_n$ 为 1 阶方阵, 有 $S_n' F_n^{-1} S_n = \text{tr}(S_n' F_n^{-1} S_n) = \text{tr}(F_n^{-1} S_n S_n')$, 故由(2.31)式, 有 $E(S_n' F_n^{-1} S_n) = E\{\text{tr}(F_n^{-1} S_n S_n')\} = \text{tr}\{E(F_n^{-1} S_n S_n')\} = \text{tr}\{F_n^{-1} E(S_n S_n')\} = \text{tr}(F_n^{-1} F_n) = \text{tr}(I_p) = p$, 其中 p 是 F_n 的阶, 即 z_i 的行数, 由此及(2.31)式, 有

$$P(A_n) \geq 1 - 4p/(c\delta)^2. \quad (2.32)$$

以上推导似与 n 无关,其实是(取定 δ 后)要 n 充分大时才成立.因此以上推导依赖(2.29a)式,而(2.29a)式基于

$$F_n(\beta_w) \geq cF_n \text{ 对一切 } w \in [0,1] \quad (n \text{ 充分大})$$

此处用到“ n 充分大”.但(2.32)式中对 δ 取法无限制(但不同的 δ , (2.32)式要求的“ n 充分大”不同: δ 愈大,集 $N_n(\delta)$ 就愈大,要求 n 也愈大).故若任给 $\eta > 0$,可取 $\delta > 0$,使 $4p/(c\delta)^2 < \eta$,则由(2.32)式,知当 n 充分大时,有 $P(A_n) \geq 1 - \eta$,这证明了 $P(A_n) \rightarrow 1$.如前所述,这推出 $P(H_n) \rightarrow 1$,因而推出 $P(G_n) \rightarrow 1$,即(2.27)式.

为证(2.28)式,注意当 H_n 发生时, $\hat{\beta} \in N_n(\delta)$,而当 n 充分大时, $N_n(\delta) \subset V_\epsilon(\beta_0)$. $\epsilon > 0$ 给定(此因条件(D),见(2.22b)式),故 $P(\hat{\beta}_n \in V_\epsilon(\beta_0)) \geq P(H_n)$,当 n 充分大,因而

$$P(\|\hat{\beta}_n - \beta_0\| < \epsilon) = P(\hat{\beta}_n \in V_\epsilon(\beta_0)) \geq P(H_n) \rightarrow 1 \quad (n \rightarrow \infty)$$

对任给 $\epsilon > 0$ 成立.这表明 $\hat{\beta}_n \rightarrow \beta_0$ in pr.,即(2.28)式.定理证毕.

2.2.5 自然条件下 MLE 的强相合(SC)

定理 2.3 设条件(D)成立,且对某 $\delta > 0$,条件(S_δ)成立,则以概率 1 成立

$$\hat{\beta} \rightarrow \beta_0, \quad \text{记为 } \hat{\beta}_n \rightarrow \beta_0, \text{ a.s.} \quad (2.33)$$

注 2.3 把(2.33)式的意思确切解释一下, $\hat{\beta}_n$ 是 $y_1, \dots, y_n$ 的函数,记为 $\hat{\beta}_n(y_1, \dots, y_n)$. 以 M 记 y_i 的值域(如在 logistic 模型中, y_i 只取 0,1 两值,则 $M = \{0,1\}$).故作为一串 MLE $\{\hat{\beta}_n(y_1, \dots, y_n) : n \geq 1\}$,是定义在无穷维空间

$$M^* = M \times M \times M \times \dots \equiv M^\infty$$

上.(2.33)式的意思是说,除去 M^* 中一个零概率集 M_0 ,当 $(y_1, y_2, \dots) \in M_0$ 时,有 $\lim_{n \rightarrow \infty} \hat{\beta}_n(y_1, \dots, y_n) = \beta_0$.即对任给 $\epsilon > 0$,对 $(y_1, y_2, \dots) \in M_0$,存在 $n_1 = n_1(y_1, y_2, \dots)$ (表明 n 依赖于 $(y_1, y_2, \dots)$)使当 $n \geq n_1$ 时, $\hat{\beta}_n(y_1, \dots, y_n) \in V_\epsilon(\beta_0)$,通常就简单地说“当 n 充分大时 $\hat{\beta}_n \in V_\epsilon(\beta_0)$ ”,上文明确指出:这“ n 充分大”, n 要大到怎样,不仅取决于 ϵ ,也依赖特定的 $(y_1, y_2, \dots) (\in M_0)$.在简单说法中这意思未明白表达出来.

引理 2.6 设 $\xi_1, \xi_2, \dots$ 是一列均值 0 的随机变量, 相互独立. 且 $B_n \equiv \text{Var}(\xi_1 + \dots + \xi_n) = \sum_{i=1}^n \text{Var}(\xi_i) \rightarrow \infty (n \rightarrow \infty)$, 则对任何 $\delta > 0$, 有

$$\lim_{n \rightarrow \infty} \left(\sum_{i=1}^n \xi_i / B_n^{1/2+\delta} \right) = 0, \quad \text{a.s.} \quad (2.34)$$

此引理是 Petrov 《Sums of Independent Random Variable》P.272, 定理 14 的一特例. 此处证明从略.

注 2.4 令 $\eta_n = \sum_{i=1}^n \xi_i / B_n^{1/2}$, 则 $E(\eta_n) = 0$, $\text{Var}(\eta_n) = 1$, 在概率论上称为“标准化”变量, 它“在概率上有界”. 而 $B_n \rightarrow \infty$, 知 $B_n^\delta \rightarrow \infty$, 故 $\sum_{i=1}^n \xi_i / B_n^{1/2+\delta} = \eta_n / B_n^\delta$ 应 $\rightarrow 0$. 这只是一个启发式论据, 不能作为严格证明.

回到定理的证明, 定义事件

$$E_\epsilon = \{l_n(\beta_0) > \sup_{\|\beta - \beta_0\| = \epsilon} l_n(\beta) \quad (n \text{ 充分大})\}$$

(此处“ n 充分大”按注 2.3 解释, 因 $l_n(\beta)$ 依赖样本 $y_1, y_2, \dots$) 往证: 如果

$$P(E_\epsilon) = 1, \quad \text{对任何 } \epsilon > 0, \quad (2.35)$$

则 $\hat{\beta}_n \rightarrow \beta_0$, a.s.. 事实上, 若 E_ϵ 成立, 则 $l_n(\beta)$ 在 $V_\epsilon(\beta_0)$ 内部有一局部极大点, 如前所论述, 它就是 $\hat{\beta}_n$. 因此

$$E_\epsilon \text{ 发生} \Rightarrow \hat{\beta}_n \in V_\epsilon(\beta_0) \quad (n \text{ 充分大})$$

即对任何 $\epsilon > 0$, 有 $P(\hat{\beta}_n \in V_\epsilon(\beta_0) \text{ 当 } n \text{ 充分大}) \geq P(E_\epsilon) = 1$. 由 $\epsilon > 0$ 的任意性, 不难看出, 这证明了(2.33)式.

为证(2.35)式, 任取 β 使 $\|\beta - \beta_0\| = \epsilon$. 用展式(2.29), 并注意到

$$|(\beta - \beta_0)' S_n| \leq \|\beta - \beta_0\| \|S_n\| = \epsilon \|S_n\|,$$

又因 $w \in [0, 1]$, 有 $\beta_w \in V_\epsilon(\beta_0)$. 故由条件(S_δ), 知当 n 充分大时, 有 $\underline{\lambda}(F_n(\beta_w)) \geq C[\bar{\lambda}(F_n)]^{1/2+\delta}$. 因此, 对充分大的 n

$$\begin{aligned} (\beta - \beta_0)' F_n(\beta_w) (\beta - \beta_0) &\geq C[\bar{\lambda}(F_n)]^{1/2+\delta} \|\beta - \beta_0\|^2 \\ &= c\epsilon^2 [\bar{\lambda}(F_n)]^{1/2+\delta}. \end{aligned}$$

由此知 $(\beta - \beta_0)' \int_0^1 (1-w) F_n(\beta_w) dw (\beta - \beta_0) \leq \frac{1}{2} c\epsilon^2 [\bar{\lambda}(F_n)]^{1/2+\delta}$, 因而

$$l_n(\beta) - l_n(\beta_0) \leq \epsilon (\|S_n\| - \frac{c}{2} \epsilon [\bar{\lambda}(F_n)]^{1/2+\delta}). \quad (2.36)$$

对充分大的 n 及球面 $\|\beta - \beta_0\| = \epsilon$ 上的 β . 定义事件

$$A = \{\lim_{n \rightarrow \infty} (S_n / [\bar{\lambda}(F_n)]^{1/2+\delta}) = 0\},$$

则当 A 发生, n 充分大时, 有 $S_n / [\bar{\lambda}(F_n)]^{1/2+\delta} < c\epsilon/4$, 因而由 (2.36) 式, 知 $l_n(\beta) - l_n(\beta_0) < -(c\epsilon^2/4)[\bar{\lambda}(F_n)]^{1/2+\delta}$, 故事件 E_ϵ 发生. 即 $A \subset E_\epsilon$. 故为证明 (2.35) 式, 只需证明 $P(A) = 1$, 即

$$\lim_{n \rightarrow \infty} (S_n / \bar{\lambda}(F_n))^{1/2+\delta} = 0, \quad \text{a.s.} \quad (2.37)$$

S_n 为 p 维随机向量 (p 是 z_i 的行数, 即 β 的维数, 因线性预测子为 $z_i'\beta$, 故 β 的维数 = z_i' 的列数 = z_i 的行数), 记为 $S_n = (S_{n1}, \dots, S_{np})'$. (2.37) 式为

$$\lim_{n \rightarrow \infty} (S_{nj} / [\bar{\lambda}(F_n)]^{1/2+\delta}) = 0, \quad \text{a.s.} \quad (j = 1, \dots, p). \quad (2.38)$$

以 $j = 1$ 为例, 以 a_i' 记 z_i 的第 1 行, 则

$$S_{n1} = \sum_{i=1}^n a_i' (y_i - \mu(z_i'\beta_0)) \equiv \sum_{i=1}^n \xi_i, \quad \xi_i = a_i' (y_i - \mu(z_i'\beta_0)).$$

前已指出 $E(S_n) = 0$, 以及 S_n 的协方差阵为 F_n (见 (2.31) 式). 而 S_{n1} 的方差 B_n 为 F_n 的 (1,1) 元: $B_n = F_n(1,1)$. 因 $F_n > 0$, 有 $F_n(1,1) \leq \bar{\lambda}(F_n)$, 故

$$B_n \leq \bar{\lambda}(F_n). \quad (2.39)$$

另一方面, $B_n \geq \underline{\lambda}(F_n)$, 由条件 (D), 知 $\underline{\lambda}(F_n) \rightarrow \infty$, 故 $B_n \rightarrow \infty$. 因此按引理 2.6, 有 (2.34) 式, 再由 (2.39) 式, 即得 (2.38) 式当 $j = 1$. 定理证毕.

2.2.6 自然联系下 MLE 的渐近正态性

定理 2.4 设条件 (D) 与条件 (N) 成立, 则当 $n \rightarrow \infty$ 时, $F_n^{1/2}(\hat{\beta}_n - \beta_0)$ 依分布收敛于 p 维标准正态分布 $N(0, I_p)$:

$$F_n^{1/2}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I_p) \quad (2.40)$$

先引入一些预备事实. 设 x 是一个 q ($q \geq 1$) 维随机向量. 定义

$$m(t) = E(e^{t'x}), \quad t \in \mathbb{R}^p$$

为 x 的矩母函数.

q 维标准正态分布 $N(0, I_q)$ 有密度函数

$$f(x) = c \cdot e^{-x'x/2}, \quad x \in \mathbb{R}^q, \quad c = (\sqrt{2\pi})^{-q}$$

其矩母函数为

$$m_0(t) = c \int_{\mathbb{R}^q} \exp(-x'x/2 + t'x) dx$$

$$\begin{aligned}
&= c e^{t'/2} \int_{\mathbb{R}^q} \exp\left(-\frac{1}{2}(t-x)'(t-x)\right) dx \\
&= c e^{t'/2} \int_{\mathbb{R}^q} \exp\left(-\frac{1}{2}u'u\right) du = e^{t'/2} = e^{\|t\|^2/2}.
\end{aligned}$$

引理 2.7 设 $x_1, x_2, \dots$ 是一串 q 维随机向量, $m_n(t)$ 为 x_n 的矩母函数. 若 $\{m_n(t), n \geq 1\}$ 都在某一以 0 为中心, $\varepsilon > 0$ 为半径的 q 维球 $V_\varepsilon(0)$ 内有限, 且对任何 $t \in V_\varepsilon(0)$ 有 $\lim_{n \rightarrow \infty} m_n(t) = e^{\|t\|^2/2}$. 则 x_n 依分布收敛于 $N(0, I_q)$.

证明从略. 可参看 Loeve 《Probability Theory》第 4 章.

引理 2.8 在定理 2.4 的条件下, 有

$$F_n^{-1/2} S_n \xrightarrow{d} N(0, I_p). \quad (2.41)$$

证 记 $\beta_n = \beta_0 + \delta F_n^{-1/2} t$, t 为 p 维单位向量 ($\|t\| = 1$). 则

$$\|F_n^{1/2}(\beta_n - \beta_0)\| = \|F_n^{-1/2}(\delta F_n^{-1/2} t)\| = \delta \|t\| = \delta$$

$$\Rightarrow \beta_n \in N_n(\delta).$$

利用 (2.29) 式, 取其中的 β 为 β_n , 注意到 $\beta_n - \beta_0 = \delta F_n^{-1/2} t$, 得

$$\begin{aligned}
l_n(\beta_n) &= l_n(\beta_0) + \delta t' F_n^{-1/2} S_n \\
&\quad - \delta^2 t' \int_0^1 (1-w) F_n^{-1/2} F_n(\beta_0 + w \delta F_n^{-1/2} t) F_n^{-1/2} dw \cdot t \\
&= l_n(\beta_0) + \delta t' F_n^{-1/2} S_n - \delta^2 t' \int_0^1 (1-w) V_n(\beta_w) dw \cdot t \\
&= l_n(\beta_0) + \delta t' F_n^{-1/2} S_n - \delta^2 t' \int_0^1 (1-w) (V_n(\beta_w) - I_p) dw \cdot t \\
&\quad - \delta^2 t' \int_0^1 (1-w) I_p dw \cdot t \\
&\equiv l_n(\beta_0) + \delta t' F_n^{-1/2} S_n - J_n - \delta^2 \|t\|^2/2,
\end{aligned} \quad (2.42)$$

其中

$$J_n = \delta^2 t' \int_0^1 (1-w) (V_n(\beta_w) - I_p) dw \cdot t,$$

$$\beta_w = \beta_0 + w(\beta_n - \beta_0) \in N_n(\delta),$$

因 β_0, β_n 都 $\in N_n(\delta)$ ($0 \leq w \leq 1$). 故由条件 (N), $|V_n(\beta_w) - I|$ 对单位球上的 t 一致地收敛于 0, $n \rightarrow \infty$, 由此知 $J_n \rightarrow 0, n \rightarrow \infty$. 由 (2.42) 式得

$$e^{l_n} e^{l_n(\beta_n)} = e^{-\delta^2 \|t\|^2/2} e^{\delta t' F_n^{-1/2} S_n} e^{l_n(\beta_0)}, \quad (2.43)$$

两边同乘 $\prod_{i=1}^n c(y_i) d\nu(y_i)$, 并对 $y_1, \dots, y_n$ 积分, 注意对任何 $\beta \in B^\circ$, 有

$$e^{l_n(\beta)} \prod_{i=1}^n c(y_i) d\nu(y_i) = \prod_{i=1}^n \exp(y_i' \beta - b(\beta)) \prod_{i=1}^n c(y_i) d\nu(y_i),$$

恰是参数值为 β 时 $(y_1, \dots, y_n)$ 的联合分布. 故对 (2.43) 式两边乘以

$\prod_{i=1}^n c(y_i) d\nu(y_i)$ 后对 $y_1, \dots, y_n$ 积分, 结果为 (注意 J_n 非随机)

$$e^{J_n} = e^{-\delta^2 \|t\|^2/2} E_{\beta_0}(e^{\delta t F_n^{-1/2} S_n}) \quad (\text{此为 } m_n(\delta t)) \quad (2.44)$$

即

$$m_n(\delta t) = e^{\|\delta t\|^2/2} e^{J_n}, \quad (2.45)$$

其中, m_n 是 $F_n^{-1/2} S_n$ 的矩母函数. 据前证, $\lim_{n \rightarrow \infty} J_n = 0$, 故若在 (2.45) 式两边令 $n \rightarrow \infty$, 将得 $m_n(\delta t) \rightarrow \exp(\|\delta t\|^2/2)$. 因 t 为任何单位向量, δ 可取任何 > 0 的值, 故得

$$m_n(t) \rightarrow \exp(-\|t\|^2/2) \quad (t \in \mathbb{R}^p, t \neq 0). \quad (2.46)$$

而当 $t = 0$ 时, $m_n(t)$ 和 $\exp(\|t\|^2/2)$ 皆为 1, 故 (2.46) 式仍成立. 因此证明了 $m_n(t) \rightarrow \exp(-\|t\|^2/2)$ 对一切 p 维向量 t . 据引理 2.7, 得 (2.41) 式. 引理证毕.

定理 2.4 的证明

因 $\hat{\beta}_n$ 为 MLE, 有 $S_n(\hat{\beta}_n) = 0$. 故

$$S_n = S_n(\beta_0) = -(S_n(\hat{\beta}_n) - S_n(\beta_0)).$$

利用积分公式 (2.5) 式, 取其中 $f = S_n$, $a = \beta_0$, $b = \hat{\beta}_n$. 因 $S_n = \partial l_n / \partial \beta$, 有 $\dot{S}_n(\beta) = l_n(\beta) = -F_n(\beta)$ (见 (2.20) 式). 故有

$$S_n = \int_0^1 F_n(\beta_0 + (\hat{\beta}_n - \beta_0)u) du \cdot (\hat{\beta}_n - \beta_0).$$

两边各左乘 $F_n^{-1/2}$, 并于右边右乘 $F_n^{-1/2} F_n^{1/2} (= I)$ 于 $(\hat{\beta}_n - \beta_0)$ 前, 有

$$\begin{aligned} F_n^{-1/2} S_n &= \int_0^1 F_n^{-1/2} F_n(\beta_u) F_n^{-1/2} du \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0) \\ &= \int_0^1 I_p du \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0) + \int_0^1 (V_n(\beta_u) - I) du \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0) \\ &= I_p \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0) + \int_0^1 (V_n(\beta_u) - I) du \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0). \end{aligned} \quad (2.47)$$

此处 $\beta_u = \beta_0 + u(\hat{\beta}_n - \beta_0)$. 定理 2.2 中已证明, 在 (D) + (C) 之下, 当 $n \rightarrow \infty$

时,以 $\rightarrow 1$ 的概率有 $\hat{\beta}_n \in N_n(\delta)$.现(D)+(N)成立,而(N) $\Rightarrow$ (C)(引理2.4),故(D)+(C)成立.因此,按条件(N),当 $n \rightarrow \infty$ 时,有

$$|V_n(\beta_u) - I| \leq \sup(|V_n(\beta) - I|; \beta \in N_n(\delta)) \rightarrow 0, \text{ in pr. .}$$

因此当 $n \rightarrow \infty$ 时,有

$$\int_0^1 (V_n(\beta_u) - I) du \equiv B_n \rightarrow 0, \text{ in pr. .}$$

由此及(2.47)式,有

$$F_n^{-1/2} S_n = (I_p + B_n) \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0), \quad I_p + B_n \rightarrow I_p, \text{ in pr. .}$$

由此及引理2.8,有

$$W_n \equiv (I_p + B_n) \cdot F_n^{1/2} (\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I_p),$$

但

$$F_n^{1/2} (\hat{\beta}_n - \beta_0) = (I_p + B_n)^{-1} W_n.$$

而 $(I_p + B_n)^{-1} \rightarrow I_p$, in pr.,由此得(2.40)式.定理证毕.

要在特定的场合验证条件(D)、(C)、(N)和 (S_δ) 成立,很不容易.对两个在应用上常见的情况,有合适的结果.下面分别来讨论.

2.2.7 $\{z_i, i \geq 1\}$ 有界的情况

定理 2.5 设以下条件成立:

1° $\{z_i, i \geq 1\}$ 有界,其闭包(指 $\{z_i\}$ 及一切作为 $\{z_i\}$ 的子列的极限的矩阵之集合 $\mathcal{A}$)也有界. $\mathcal{A}$ 满足条件: $z'\beta \in \Theta^\circ$ 对任何 $z \in \mathcal{A}, \beta \in B^\circ$ (Θ° 是 θ 的值域的内点集).

2° $\underline{\lambda}(T_n) \rightarrow \infty$.

则条件(D)、(C)、(N)全满足,故MLE $\hat{\beta}_n$ 弱相合的且渐近正态(满足(2.40)式).

若除此外还满足:

3° 存在常数 $c > 0, \delta > 0$,使 $\underline{\lambda}(T_n) \geq c(\bar{\lambda}(T_n))^{1/2+\delta}$ 当 n 充分大.

则条件 (S_δ) 满足,故 $\hat{\beta}_n$ 为弱相合的.

证 取 $\eta > 0$ 充分小,使闭邻域 $V = \{\beta: \|\beta - \beta_0\| \leq \eta\} \subset B^\circ$ 因 $\mathcal{A}$ 与 V 都是有界闭集知 $M \equiv \{z'\beta: z \in \mathcal{A}, \beta \in V\}$ 为有界闭集.由指数分布族性质,并

因由条件 1° 知 $\dot{b}(\theta)$ 在 $\theta \in M$ 上一致连续 (因 $M \subset \Theta^\circ$ 而 $b(\theta)$ 在 Θ° 上连续). 另外 $\dot{b}(\theta) > 0$ 对任何 $\theta \in \Theta^\circ$. 由此可知, 存在常数 $c_1, c_2 (0 < c_1 \leq c_2 < \infty)$, 使

$$c_1 I_q \leq \Sigma(z_i' \beta) \leq c_2 I_q \quad (i \geq 1, \beta \in V) \quad (2.48)$$

(此因 $\Sigma(z_i' \beta)$ 和 $b(\theta)$ 都是 y 的协方差阵). 在上式中的所有的 3 项各左乘 z_i , 右乘 z_i' , 再将结果对 $i = 1, \dots, n$ 求和, 即得 $c_1 T_n \leq F_n(\beta) \leq c_2 T_n$, 特别, $c_1 T_n \leq F_n \leq c_2 T_n$, 因此 $\underline{\lambda}(F_n) \geq c_1 \underline{\lambda}(T_n) \rightarrow \infty$ (由条件 2°), 这证明了条件 (D) 成立. 另由上式, 有 $T_n \geq c_2^{-1} F_n$, 故 $F_n(\beta) \geq c_1 c_2^{-1} F_n = c F_n, \beta \in V, c = c_1 c_2^{-1} \geq 0$, 因 $\underline{\lambda}(F_n) \rightarrow \infty$ 知, 当 n 充分大时, $N_n(\delta) \subset V$ (见 (2.22b) 式), 因此有 $F_n(\beta) \geq c F_n$ 对 $\beta \in N_n(\delta), n$ 充分大, 此即条件 (C). 为证条件 (N), 注意,

$$\sup \{ \| z_i' \beta - z_i' \beta_0 \| : i \geq 1; \beta \in N_n(\delta) \} \rightarrow 0, \quad n \rightarrow \infty. \quad (2.49)$$

事实上, 上面已证条件 (D) 成立, 故当 $n \rightarrow \infty$ 时, 有 $\{ \| \beta - \beta_0 \| : \beta \in N_n(\delta) \} \rightarrow 0$.

又 $\{ z_i, i \geq 1 \}$ 有界, 故 (2.49) 式成立. 由此, 注意到前面证明中提到的 $\dot{b}$ 的连续性 & $b > 0$, 即知对任给 $\epsilon > 0$, 当 n 充分大时, 有

$$(1 - \epsilon) \Sigma(z_i' \beta) \leq \Sigma(z_i' \beta) \leq (1 + \epsilon) \Sigma(z_i' \beta), \quad \beta \in N_n(\delta).$$

各项左乘 z_i , 右乘 z_i' , 再对 $i = 1, \dots, n$ 求和, 即得

$$(1 - \epsilon) F_n(\beta) \leq F_n \leq (1 + \epsilon) F_n(\beta), \quad \beta \in N_n(\delta).$$

由此, 据引理 2.3, 知条件 (N) 成立.

最后, 由前面已证的 $c_1 T_n \leq F_n \leq c_2 T_n$, 结合条件 3°, 以及 $F_n(\beta) \geq c F_n$, 当 $\beta \in V$ 时, 有

$$\begin{aligned} \underline{\lambda}(F_n(\beta)) &\geq c \underline{\lambda}(F_n) \geq c c_1 \underline{\lambda}(T_n) \geq c c_1 [\bar{\lambda}(T_n)]^{1/2+\delta} \\ &\geq c_1 c_2 [c_2^{-1} \bar{\lambda}(F_n)]^{1/2+\delta} = c_1 c_2^{1/2-\delta} [\bar{\lambda}(F_n)]^{1/2+\delta} \quad (\beta \in V) \end{aligned}$$

即条件 (S₀) 成立. 定理证毕.

2.2.8 y 的值域有界的情况

定理 2.6 假定 y 的值域是 $\mathbb{R}^q$ 中的有界集, 且:

1° 条件 (D) 成立;

2° $\lim_{n \rightarrow \infty} \text{tr}(z_n' F_n^{-1} z_n) = 0$.

则条件 (N) 成立, 而 MLE $\hat{\beta}_n$ 为弱相合的且渐近正态.

注 2.5 本定理与定理 2.5 不同之处在于,在定理 2.5 中,条件(D)可自定理的假定推出,但在此处不行,它必须作为假定.

在条件 1°, 2° 之下,有

$$\max_{1 \leq m \leq n} \text{tr}(z_m' F_n^{-1} z_m) \rightarrow 0 \quad (n \rightarrow \infty). \quad (2.50)$$

证 设 $n > m$, 则 $(\Sigma_i = \Sigma(z_i' \beta_0))$

$$F_n = \sum_{i=1}^m z_i \Sigma_i z_i' + \sum_{i=m+1}^n z_i \Sigma_i z_i'.$$

因 $\Sigma_i > 0$, 有 $z_i \Sigma_i z_i' \geq 0$, 故 $\sum_{i=m+1}^n z_i \Sigma_i z_i' \geq 0$, 故 $F_n \geq F_m$, 因而 $F_n^{-1} \leq F_m^{-1}$, 故有(凡不带“tr”之处, $\leq$ 都是指半正定意义)

$$z_i' F_n^{-1} z_i \leq z_i' F_m^{-1} z_i \quad (n > m, i \geq 1). \quad (2.51)$$

给定 $\epsilon > 0$, 据条件 2° 找 m_1 充分大, 使

$$\text{tr}(z_n' F_n^{-1} z_n) \leq \epsilon \quad (n \geq m_1). \quad (2.52)$$

固定 m_1 , 因条件(D)成立, 有 $F_n^{-1} \rightarrow 0$, 故存在 m_2 充分大, 使

$$\text{tr}(z_i' F_n^{-1} z_i) \leq \epsilon \quad (n \geq m_2, i = 1, \dots, m_1). \quad (2.53)$$

令 $m = \max(m_1, m_2)$, 取 $n \geq m$, 而考察 $z_i' F_n^{-1} z_i (1 \leq i \leq n)$. 分两种情况: 甲, $i \leq m_1$, 这时因 $n \geq m_2$, 有 $\text{tr}(z_i' F_n^{-1} z_i) \leq \epsilon$ (据(2.53)式); 乙, $m_1 < i$, 这时按(2.52)式, 有 $\text{tr}(z_i' F_n^{-1} z_i) \leq \epsilon$, 因 $i \leq n$, 据(2.51)式, 有 $z_i' F_n^{-1} z_i \geq z_i' F_i^{-1} z_i$, 因而 $\text{tr}(z_i' F_n^{-1} z_i) \leq \text{tr}(z_i' F_i^{-1} z_i) \leq \epsilon$. 总结这两种情况, 得 $\max_{1 \leq i \leq n} \text{tr}(z_i' F_n^{-1} z_i) \leq \epsilon$, 当 $n \geq m$. 由 ϵ 的任意性, 证明了(2.50)式.

引理 2.9 设方阵 $A \geq 0$. 则对任何向量 a , 有

$$a' A a \leq \text{tr}(A) \|a\|^2. \quad (2.54)$$

证 将 A 用正交阵

$$H = \begin{bmatrix} h_1' \\ \vdots \\ h_m' \end{bmatrix}$$

化为对角形

$$A = (h_1 \cdots h_m) \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_m \end{bmatrix} \begin{bmatrix} h_1' \\ \vdots \\ h_m' \end{bmatrix},$$

其中, $\lambda_1, \dots, \lambda_m$ 为 A 的特征根, 有 $\text{tr}(A) = \sum_{i=1}^m \lambda_i$, 而 $h_1, \dots, h_m$ 都是单位长向

量,于是,由 $|h_i'a| \leq \|h_i\| \|a\| = \|a\|$, 有

$$a'Aa = \sum_{i=1}^m \lambda_i (h_i'a)^2 \leq \sum_{i=1}^m \lambda_i \|a\|^2 = \text{tr}(A) \|a\|^2.$$

引理 2.10 设函数 g 定义在 y 的值域上,非负,且

$$E_\beta(g(y_i)) < \infty \quad (i = 1, \dots, n, \beta \in N_n(\delta)). \quad (2.55)$$

又定理 2.6 的条件成立,则对任给 $\epsilon > 0$, 存在 $n_1 = n_1(\epsilon)$, 使在 $n \geq n_1$ 时, 对 $1 \leq i \leq n, \beta \in N_n(\delta)$ 有

$$(1 - \epsilon)E(g(y_i)) \leq E_\beta(g(y_i)) \leq (1 + \epsilon)E(g(y_i)), \quad (2.56)$$

这里 $E_\beta(g(y_i))$ 是指参数为 β , 因而 $\theta_i = z_i'\beta$ 时, $g(y_i)$ 的期望, 即

$$E_\beta(g(y_i)) = \int_Q g(y) \exp(y'\theta_i - b(\theta_i)) c(y) d\nu(y), \quad (2.57)$$

而 $E(g(y_i)) = E_{\beta_0}(g(y_i))$, Q 为 y 的值域.

证 由 (2.57) 式, 有

$$\begin{aligned} E_\beta(g(y_i)) - E(g(y_i)) &= \int_Q g(y) [\exp(y'z_i'\beta - b(z_i'\beta)) - \exp(y'z_i'\beta_0 - b(z_i'\beta_0))] c(y) d\nu(y) \\ &= \int_Q g(y) \exp(y'z_i'\beta_0 - b(z_i'\beta_0)) \{ \exp(y'z_i'(\beta - \beta_0) - (b(z_i'\beta) - b(z_i'\beta_0))) - 1 \} c(y) d\nu(y). \end{aligned} \quad (2.58)$$

任取 $\beta \in N_n(\delta)$, 记 $\beta - \beta_0 = F_n^{-1/2}\alpha$, 则 $\|\alpha\| = \|F_n^{1/2}(\beta - \beta_0)\| \leq \delta$, 由此并结合引理 2.9, 有

$$\begin{aligned} \|z_i'(\beta - \beta_0)\|^2 &= \|z_i'F_n^{-1/2}\alpha\|^2 = \alpha'F_n^{-1/2}z_i z_i'F_n^{-1/2}\alpha \\ &\leq \delta^2 \text{tr} C_n^{-2}(F_n^{-1/2}z_i z_i'F_n^{-1/2}) \\ &= \delta^2 \text{tr}(z_i'F_n^{-1/2}F_n^{-1/2}z_i) = \delta^2 \text{tr}(z_i'F_n^{-1}z_i) \rightarrow 0, \end{aligned} \quad (2.59)$$

对 $(1, n)$ 内的 i 一致成立. 把 (2.58) 式最后积分 $[\]$ 内的量记为 a , 又记 $\max_{1 \leq i \leq n} \text{tr}(z_i'F_n^{-1}z_i) = c_n^2$, 由 (2.59) 式, 有

$$\|z_i'(\beta - \beta_0)\| \leq \delta c_n \quad (1 \leq i \leq n). \quad (2.60)$$

因 y 的值域 Q 有界, 以 M 记 $\sup\{\|y\| : y \in Q\}$, 则

$$|y'z_i'(\beta - \beta_0)| \leq \|y\| \|z_i'(\beta - \beta_0)\| \leq M\delta c_n.$$

由中值公式 (2.4) 及 $\partial b(z_i'\beta)/\partial \beta' = \dot{b}(z_i'\beta)z_i'$, 有

$$b(z_i'\beta) - b(z_i'\beta_0) = \dot{b}(z_i'\beta)z_i'(\beta - \beta_0). \quad (2.61)$$

因 $\dot{b}$ 是期望, 当 $\|y\| \leq M$ 时, $\|\dot{b}\| \leq M$, 由此及 (2.60)、(2.61) 式, 有

$$|b(z_i'\beta_0) - b(z_i'\beta)| \leq M\delta c_n \quad (1 \leq i \leq n, \beta \in N_n(\delta)). \quad (2.62)$$

因(2.60)式、(2.62)式,注意(2.58)式[]内的表达式 a 的形式,有

$$|a| \leq \exp(2M\delta c_n) - 1 \leq \varepsilon \quad (n \text{ 充分大}),$$

此处利用了 $c_n \rightarrow 0$. 由此及(2.58)式,有

$$\begin{aligned} |E_\beta(g(y_i)) - E(g(y_i))| &\leq \varepsilon \int_Q g(y) \exp(y'z_i'\beta_0 - b(z_i'\beta_0)) c(y) d\nu(y) \\ &= \varepsilon \cdot E(g(y_i)) \quad (1 \leq i \leq n, \beta \in N_n(\delta)), \end{aligned}$$

即(2.56)式,引理证毕.

引理 2.11 设 X 为随机向量, a 为常向量. 则

$$E[(X - a)(X - a)'] \geq \text{Cov}(X). \quad (2.63)$$

证 记 $E(X) = a_0$; 则 $\text{Cov}(X) = E[(X - a_0)(X - a_0)']$. 故由

$$\begin{aligned} (X - a)(X - a)' &= [(X - a_0) - (a - a_0)][(X - a_0) - (a - a_0)]' \\ &= (X - a_0)(X - a_0)' + (a - a_0)(a - a_0)' \\ &\quad - (a - a_0)(X - a_0)' - (X - a_0)(a - a_0)'. \end{aligned}$$

因 $E(X) = a_0$, 右边后两项的期望为 0, 故

$$E[(X - a)(X - a)'] = \text{Cov}(X) + (a - a_0)(a - a_0)'. \quad (2.64)$$

因 $(a - a_0)(a - a_0)' \geq 0$, 由(2.64)式得(2.63)式.

定理 2.6 的证明

由引理 2.12, 记 $\alpha(\beta) = E_\beta(y_i)$, 有

$$E_\beta[(y_i - a(\beta_0))(y_i - a(\beta_0))'] \geq \text{Cov}_\beta(y_i) = \Sigma(z_i'\beta), \quad (2.64a)$$

而

$$\begin{aligned} &E_\beta[(y_i - a(\beta_0))(y_i - a(\beta_0))'] \\ &= \int_Q (y - a(\beta_0))(y - a(\beta_0))' e^{y z_i' \beta - b(z_i' \beta)} c(y) d\nu(y) \\ &= \int_Q (y - a(\beta_0))(y - a(\beta_0))' [e^{(y z_i' \beta - b(z_i' \beta))} - e^{(y z_i' \beta_0 - b(z_i' \beta_0))}] c(y) d\nu(y) \\ &\quad + \int_Q (y - a(\beta_0))(y - a(\beta_0))' \exp\{y' z_i' \beta_0 - b(z_i' \beta_0)\} c(y) d\nu(y). \end{aligned} \quad (2.65)$$

右边后一积分即为 $\text{Cov}_{\beta_0}(y_i) = \Sigma(z_i'\beta_0)$, 故由(2.64a)、(2.65)式, 有

$$\begin{aligned} &\Sigma(z_i'\beta_0) - \Sigma(z_i'\beta) \\ &\geq \Sigma(z_i'\beta_0) - E_\beta[(y_i - a(\beta_0))(y_i - a(\beta_0))'] \end{aligned}$$

$$= \int_Q (y - a(\beta_0))(y - a(\beta_0))' (e^{y'z_i\beta_0 - b(z_i\beta_0)} - e^{y'z_i'\beta - b(z_i'\beta)}) c(y) d\nu(y).$$

任取单位长向量 λ , 将上式左乘 λ' , 右乘 λ , 得

$$\begin{aligned} & \lambda'(\Sigma(z_i'\beta_0) - \Sigma(z_i'\beta))\lambda \\ & \geq \int_Q \|\lambda'(y - a(\beta_0))\|^2 \{e^{y'z_i\beta_0 - b(z_i\beta_0)} - e^{y'z_i'\beta - b(z_i'\beta)}\} c(y) d\nu(y) \\ & \equiv E(g(y_i)) - E_\beta(g(y_i)) \\ g(y) & \equiv \|\lambda'(y - a(\beta_0))\|^2 \geq 0. \end{aligned}$$

于是, 利用引理 2.10, 对给定的 $\epsilon > 0$, 存在 n_1 , 使当 $n \geq n_1$ 时, 有

$$\lambda'(\Sigma(z_i'\beta_0) - \Sigma(z_i'\beta))\lambda \geq -\epsilon \lambda' \Sigma(z_i'\beta_0) \lambda.$$

由此式, 因单位向量 λ 任意, 有

$$\Sigma(z_i'\beta_0) - \Sigma(z_i'\beta) \geq -\epsilon \Sigma(z_i'\beta_0). \quad (2.66)$$

因 β_0, β 的位置是对称的(注意在以上讨论中, β_0 为真参数值这一点并无作用), 在(2.66)式中交换 β_0 与 β 的位置, 得

$$\begin{aligned} \Sigma(z_i'\beta) - \Sigma(z_i'\beta_0) & \geq -\epsilon \Sigma(z_i'\beta) \Rightarrow \Sigma(z_i'\beta) \geq \frac{1}{1+\epsilon} \Sigma(z_i'\beta_0) \\ \Rightarrow \Sigma(z_i'\beta) - \Sigma(z_i'\beta_0) & \geq -\frac{\epsilon}{1+\epsilon} \Sigma(z_i'\beta_0) \geq -\epsilon \Sigma(z_i'\beta_0). \end{aligned} \quad (2.67)$$

结合此二式((2.66)式与(2.67)式), 用注 2.2, 知条件(N)成立. 定理证毕.

2 2 9 若干例子

例 2.1 Poisson 分布

$$P(Y = y) = \frac{1}{y!} e^{-\lambda} \lambda^y = \frac{1}{y!} \exp(y\theta - e^\theta) \quad (y = 0, 1, 2, \dots),$$

其中, $\lambda > 0$, $\theta = \log \lambda$, 取值于 $\Theta^0 = (-\infty, \infty)$.

在自然联系下, $\theta = Z'\beta$, 即 $\lambda = \exp(Z'\beta)$, 而 y 的方差为 λ , 即 $\Sigma(z_i'\beta) = \exp(z_i'\beta)$,

$$F_n(\beta) = \sum_{i=1}^n z_i z_i' \exp(z_i'\beta_0), \quad F_n = F_n(\beta_0) = \sum_{i=1}^n z_i z_i' \exp(z_i'\beta_0).$$

假设定理 2.6 的条件 1°, 2° 满足, 往证条件(N)成立——注意的是, 此例中 y 非有界, 故不能引用定理 2.6.

在引理 2.10 的证明中, 已证得(见(2.59)式)

$$c_n \equiv \sup\{\|z_i'(\beta - \beta_0)\| : 1 \leq i \leq n, \beta \in N_n(\delta)\} \rightarrow 0 \quad (n \rightarrow \infty),$$

而

$$\Sigma(z_i, \beta) / \Sigma(z_i, \beta_0) - 1 = (e^{z_i \beta} - e^{z_i \beta_0}) / e^{z_i \beta_0} = e^{z_i (\beta - \beta_0)} - 1,$$

故有

$$\sup\{|\Sigma(z_i, \beta) - \Sigma(z_i, \beta_0)| / \Sigma(z_i, \beta_0) : 1 \leq i \leq n, \beta \in N_n(\delta)\} \rightarrow 0.$$

由此可知, 对任给 $\epsilon > 0$, 当 n 充分大时, 有

$$\begin{aligned} (1 - \epsilon) \Sigma(z_i, \beta_0) &\leq \Sigma(z_i, \beta) \leq (1 + \epsilon) \Sigma(z_i, \beta_0) \\ (1 \leq i \leq n, \beta \in M_n(\delta)). \end{aligned} \quad (2.68)$$

按注 2.2, 由此推出(2.24a)式, 并由引理 2.3 推出条件(N)成立.

又条件(D)已假定成立, 故条件(D)、(C)、(N)成立.

如果 $\{z_i, i \geq 1\}$ 有界, 则不必假定定理 2.6 的条件 $1^\circ, 2^\circ$ 满足, 因在本例中 $\Theta^0 = (-\infty, \infty)$, 定理 2.5 的条件 1° 自动成立, 因此据该定理, 若 $\lambda(T_n) \rightarrow \infty$, 则条件(D)、(N)(因而(C))全部满足, 若添上定理 2.5 的条件 3° , 则条件(S_δ)也满足.

例 2.2 1 维 Logistic 模型

$$P(Y = 1) = \mu, \quad P(Y = 0) = 1 - \mu \quad (0 < \mu < 1)$$

表为

$$\begin{aligned} P(Y = y) &= \mu^y (1 - \mu)^{1-y} \\ &= (1 - \mu) \exp\left(y \log \frac{\mu}{1 - \mu}\right) = \exp\{y\theta - \log(1 + e^\theta)\} \\ (y = 0, 1, \theta &= \log \frac{\mu}{1 - \mu}, -\infty < \theta < \infty). \end{aligned}$$

自然联系为 $\theta = z'\beta$, 即 $\mu = e^{z'\beta} / (1 + e^{z'\beta})$, 这表示了我们关心的参数 μ 与自变量 z 及回归系数 β 的关系.

本例 y 的值域为界集 $\{0, 1\}$, 定理 2.6 可用, y 的方差为 $\Sigma(z_i, \beta) = \mu(1 - \mu) = \exp(z_i' \beta) / (1 + \exp(z_i' \beta))^2$.

对目标值取 $k \geq 3$ 个状态的场合, 要引进哑变量 ($q = k - 1$)

$$Y = (Y_{(1)}, \dots, Y_{(q)})',$$

其值域含 k 个向量 $\{(1, 0, \dots, 0)', (0, 1, 0, \dots, 0)', \dots, (0, \dots, 0, 1)', (0, \dots, 0)'\}$.

对此集中任一个 $y = (y_{(1)}, \dots, y_{(q)})'$, 有

$$\begin{aligned} P(Y = y) &= \pi_{(1)}^{y_{(1)}} \cdots \pi_{(q)}^{y_{(q)}} (1 - |\pi|)^{1 - y_{(1)} - \cdots - y_{(q)}} \\ &= \exp(y'\theta - \log(1 + e^{\theta_{(1)}} + \cdots + e^{\theta_{(q)}})) \\ (\pi_{(1)} > 0, \dots, \pi_{(q)} > 0, 0 < |\pi| = \pi_{(1)} + \cdots + \pi_{(q)} < 1). \end{aligned}$$

其中, $\theta = (\theta_{(1)}, \dots, \theta_{(q)})'$, 而 $\theta_{(j)} = \log(\pi_{(j)} / (1 - |\pi|))$, 自然联系为 $\theta = z'\beta$, 即 $\log(\pi_{(j)} / (1 - |\pi|)) = z_{j0}'\beta$, z_{j0}' 为 z' 的第 j 行. 这表达我们关系的参数 $\pi = (\pi_{(1)}, \dots, \pi_{(q)})$ 与自变量 z 及回归系数 β 之间的关系. 本例中 y 的值域有界, 定理 2.6 可用.

例 2.3 指数分布 y 有密度函数

$$f_{\lambda}(y) = \lambda^{-1} e^{-y/\lambda} I(y > 0) \quad \left(I(y > 0) = \begin{cases} 1, & y > 0 \\ 0, & y \leq 0 \end{cases}, \lambda > 0 \right).$$

引进参数 $\theta = -1/\lambda$, 化为标准形

$$- \theta e^{\theta y} c(y) = \exp(\theta y - (-\log(-\theta))) c(y) \quad (-\infty < \theta < 0).$$

$c(y)$ 即 $I(y > 0)$, 自然联系为 $-\lambda^{-1} = \theta = z'\beta$ 或 $\lambda = -1/z'\beta$.

从本例看出, 必须关注 β 的值域问题, 为简便计, 以下设 β 为一维, 则 z 为 1×1 , 即为实数. 因 $\lambda > 0$, $z'\beta (= Z\beta)$ 必须为负. 故若样本中 $z_1, \dots, z_n$ 皆大于 0, 则 β 的值域为 $B^o(-\infty, 0)$. 若 $z_1, \dots, z_n$ 皆小于 0, 则为 $(0, \infty)$; 若 $z_1, \dots, z_n$ 中既有大于 0 也有小于 0 的, 则 B^o 为空集, 问题无意义.

现设有了样本 (y_i, z_i) ($1 \leq i \leq n$), 先撇开广义线性模型的架构, 直接求 β 的 MLE. 因 $\lambda = -1/(z\beta)$. 样本 y_i 中的 λ 参数值为 $-1/(z_i\beta)$. 因此, $(y_1, \dots, y_n)$ 有概率密度

$$(-1)^n z_1 \cdots z_n \beta^n \exp\left(\beta \sum_{i=1}^n z_i y_i\right),$$

使其达到最大的 β 值, 即 MLE $\hat{\beta}_n$, 为

$$\hat{\beta}_n = - \left(\sum_{i=1}^n z_i y_i / n \right)^{-1}.$$

令 $\xi_i = z_i y_i$, 由 y_i 有密度 $-z_i \beta e^{z_i \beta y_i} I(y_i > 0)$, 易知 ξ_i 有密度

$$\begin{cases} -\beta \exp(\beta x) I(x > 0), & z_i > 0 \\ \beta \exp(\beta x) I(x < 0), & z_i < 0 \end{cases}$$

只与 z_i 的符号有关, 上面已指出, $z_1, \dots, z_n$ 必须同符号且全不为 0, 这样, $\xi_1, \dots, \xi_n$ 为独立同分布(iid.), 易算出 $E_{\beta}(\xi_1) = -1/\beta$, $\text{Var}_{\beta}(\xi_1) = 1/\beta^2$.

现设 β_0 为真参数值, 下面来证明

$$|\beta_0|^{-1} \sqrt{n}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, 1) \quad (n \rightarrow \infty). \quad (2.69)$$

事实上, 由 $\hat{\beta}_n = -1/\bar{\xi}_n$ ($\bar{\xi}_n = \sum_{i=1}^n \xi_i / n$), 得

$$|\beta_0|^{-1} \cdot \sqrt{n}(\hat{\beta}_n - \beta_0) = |\beta_0|^{-1} \sqrt{n} \frac{1 + \bar{\xi}_n \beta_0}{-\bar{\xi}_n} = |\beta_0|^{-1} \sqrt{n} \frac{\bar{\xi}_n + \beta_0^{-1}}{-\bar{\xi}_n / \beta_0}.$$

因 $E(\xi_1) = -1/\beta_0$, 由 Kolmogorov 大数律, 知 $\bar{\xi}_n \rightarrow -1/\beta_0, \text{a.s.}$ 则 $-\bar{\xi}_n/\beta_0 \rightarrow 1/\beta_0^2, \text{a.s.}$ 因此, 可以用 $1/\beta_0^2$ 取代分母中的 $-\bar{\xi}_n/\beta_0$, 而不影响其极限分布, 即

$|\beta_0|^{-1} \sqrt{n}(\hat{\beta}_n - \beta_0)$ 与 $|\beta_0| \sqrt{n}(\bar{\xi}_n + \beta_0^{-1})$ 有同一极限分布. 但因 $\xi_1, \dots, \xi_n$ 为 i.i.d., $E(\xi_1) = -\beta_0^{-1}$ 而 $\text{Var}(\xi_1) = \beta_0^{-2}$, 由 i.i.d. 和的中心极限定理, $|\beta_0| \sqrt{n}(\bar{\xi}_n + \beta_0^{-1})$ 有极限分布 $N(0, 1)$, 故 $|\beta_0| \sqrt{n}(\bar{\xi}_n - \beta_0^{-1})$ 也有极限分布 $N(0, 1)$, 由此得

$$|\beta_0|^{-1} \sqrt{n}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, 1). \quad (2.70)$$

若按广义线性模型理论, 则有

$$F_n^{1/2}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, 1). \quad (2.71)$$

此处因 $\text{Var}(y_i) = (z_i \beta_0)^{-2}$, 有 $F_n = \sum_{i=1}^n z_i^2 (z_i \beta_0)^{-2} = n\beta_0^{-2}$, 而 $F_n^{1/2} = |\beta_0|^{-1} \sqrt{n}$, 故 (2.71) 式与 (2.70) 式完全一致. 但是, 为导出 (2.71) 式 (即定理 2.4), 要加上一系列的条件, 而在前面我们导出 (2.70) 式时, 除 $z_1, \dots, z_n$ 同号且全不为 0 外, 不需附加任何条件.

本例表明, 前面我们为证明 β_0 的 MLE $\hat{\beta}_n$ 的相合性、渐近正态性所加上的条件, 并非必要. 但目前对这些条件在何种情况下能减轻多少, 还毫无了解.

例 2.4 Γ 分布, y 有密度函数

$$\frac{1}{\Gamma(\nu)} \nu^\nu \mu^{-\nu} y^{\nu-1} e^{-\mu^{-1}y} I(y > 0) \quad (\nu > 0 \text{ 已知}, 0 < \mu < \infty).$$

参数为 μ . 此分布有均值 μ , 方差 μ^2/ν , 引进参数 $\theta = -\nu/\mu$, 将其转化为标准指数型分布

$$\frac{1}{\Gamma(\nu)} y^{\nu-1} \cdot \exp(y\theta - (-\nu \log(-\theta))) I(y > 0) \quad (-\infty < \theta < 0).$$

设有了样本 $(y_i, z_i) (1 \leq i \leq n)$. 自然联系 $\theta_i = -\nu/\mu_i = z_i' \beta$. 若 β 为 1 维, 则 z_i 为数, 情况与上例一样: $\{z_i\}$ 必须同号且全非 0. 在这个前提下, 一切与前例无异 (前例为本例 $\nu = 1$ 的特例), 可以像上例一样, 直接求出其 MLE $\hat{\beta}$ 并用中心极限定理证明 $\hat{\beta}_n$ 的渐近正态性, 其形式与广义线性模型理论给出的 (2.71) 式完全一样, 且不用任何条件.

若 β 为多维, 则问题复杂化. 一是有一个 β 的值域空间 B° (是 $B \equiv \{\beta: z_i' \beta < 0, i \geq 1\}$ 的内部, 对固定的 n , 当然只要求在定义 B° 时限制 $i = 1, \dots, n$, 但因考虑极限理论, 要求 $n \rightarrow \infty$, 故必须取 $i \geq 1$) 是否非空的问题——若为空, 模型无意义. 在 β 维数 $p = 1$ 时, 若一切 $z_i > 0$, 则 $B^\circ = (-\infty, 0)$, 若一切 $z_i < 0$, 则 $B^\circ = (0, \infty)$, 对 $p > 1$, 这集合无法明显定出, 但下述方法可帮助肯定在一些情况下 $B^\circ \neq \emptyset$.

引理 2.12 若存在 $\beta_1 \in \mathbb{P}^p$, 使

$$\sup\{z_i' \beta_1 / \|z_i\|, i \geq 1\} \equiv a < 0, \quad (2.72)$$

则 $B^\circ \neq \emptyset$.

事实上, 只需证明

$$B^\circ = \{\beta: \sup_{i \geq 1} z_i' \beta / \|z_i\| < 0\}, \quad (2.73)$$

若已证, 则当 (2.72) 式成立时, $\beta_1 \in B^\circ$, 故 $B^\circ \neq \emptyset$.

先设 $\beta^* \in (2.73)$ 式右边, 则

$$\sup_{i \geq 1} c_i' \beta^* = a < 0, \quad c_i = z_i / \|z_i\| \quad (\text{注意 } \|c_i\| = 1).$$

现任取 $\beta \in V_{|a|/2}(\beta^*)$. 记 $b = \beta - \beta^*$, $\|b\| \leq |a|/2$. 故 $|c_i' b| \leq |a|/2$, $i \geq 1$. 有

$$\begin{aligned} \sup_{i \geq 1} c_i' \beta &= \sup_{i \geq 1} (c_i' \beta^* + c_i' b) \leq \sup_{i \geq 1} c_i' \beta^* + \sup_{i \geq 1} |c_i' b| \\ &\leq a + |a|/2 = a/2 < 0 \quad (\text{因 } a < 0). \end{aligned}$$

这证明了 $\beta \in (2.73)$ 式右边, 因而 $V_{|a|/2}(\beta^*) \subset (2.73)$ 式右边 $\subset B$, 因此 β^* 是 B 的内点, 即 $\beta^* \in B^\circ$.

反过来, 设 $\beta^* \notin (2.73)$ 式右边, 往证 $\beta^* \notin B^\circ$. 为此只需证明

$$V_\epsilon(\beta^*) \not\subset B \quad (\epsilon > 0) \quad (2.74)$$

因 $\beta^* \notin (2.73)$ 式右边, 则 $\sup_{i \geq 1} c_i' \beta^* \geq 0$ ($c_i = z_i / \|z_i\|$), 若为大于 0, 则存在 i 使 $z_i' \beta^* > 0$, 这时 $\beta^* \notin B$, 故 $\beta^* \notin B^\circ$. 若为等于 0, 则有一子例 $\{i_j: j \geq 1\}$ 使 $c_{i_j}' \beta^* \rightarrow 0$ ($j \rightarrow \infty$). 因此可找到充分大的 j' , 使 $c_{i_{j'}}' \beta^* > -\epsilon/3$. 令 $\beta = \beta^* + \frac{\epsilon}{2} c_{i_{j'}}$, 则 $\|\beta - \beta^*\| = \epsilon/2 < \epsilon$, 故 $\beta \in V_\epsilon(\beta^*)$. 但

$$\begin{aligned} c_{i_{j'}}' \beta &= c_{i_{j'}}' \beta^* + c_{i_{j'}}' (\beta - \beta^*) \\ &> -\epsilon/3 + \frac{\epsilon}{2} c_{i_{j'}}' c_{i_{j'}} = -\epsilon/3 + \epsilon/2 > 0, \end{aligned}$$

故 $\beta \notin B$. 这证明了 (2.74) 式, 因而本引理得证.

另一个复杂化的情况,是当 $p > 1$ 时,似然方程无显式解.实际上,易见似然方程为(见(2.17)式,且注意 $\mu(z_i, \beta) = \mu_i = -\nu/\theta_i$)

$$\sum_{i=1}^n z_i (y_i + \nu/z_i, \beta) = 0.$$

这方程无法得出解析表达式的解,因此上例那种直接方法不可行,这就得求助于定理 2.4,有:若 $\beta_0 \in B^o$, 则

1° 当 $\lim_{n \rightarrow \infty} \lambda(\sum_{i=1}^n z_i z_i' \|z_i\|^{-2}) = \infty$ 时,条件(D)、(N) 满足.

2° 若增加条件:存在 $c > 0$, 使当 n 充分大时有

$$\lambda(Q_n) \geq c[\bar{\lambda}(Q_n)]^{1/2+\delta} (Q_n = \sum_{i=1}^n z_i z_i' \|z_i\|^{-2}), \quad (2.75)$$

则条件(S_δ) 满足. 因此,在条件 1° 之下,MLE $\hat{\beta}_n$ 为弱相合且渐近正态;在条件 1° + 2° 之下,它还是强相合的.

为证此,注意 y_i 的方差(在参数为 $\theta_i = z_i' \beta$ 时),即 $\Sigma(z_i, \beta)$, 为 $\nu/(z_i' \beta)^2$, 故(仍记 $c_i = z_i / \|z_i\|$)

$$F_n = \sum_{i=1}^n z_i \Sigma(z_i, \beta_0) z_i' = \nu \sum_{i=1}^n z_i z_i' / (z_i' \beta_0)^2 = \nu \sum_{i=1}^n \left\{ \frac{z_i z_i' / \|z_i\|^2}{(c_i' \beta_0)^2} \right\}. \quad (2.75a)$$

因 $\|c_i\| = 1$, 有 $|c_i' \beta_0| \leq |\beta_0|$, 故由上式知 $F_n \geq \nu |\beta_0|_0^{-2} Q_n$, 由条件 1° 即得 $\lambda(F_n) \rightarrow \infty (n \rightarrow \infty)$, 即条件(D).

为证条件(N), 利用 $\Sigma(z_i, \beta) = \nu(z_i' \beta)^{-2}$, 有

$$\begin{aligned} |\Sigma(z_i, \beta) - \Sigma(z_i, \beta_0)| &= \nu |(z_i' \beta)^{-2} - (z_i' \beta_0)^{-2}| \\ &= \nu (z_i' \beta_0)^{-2} \frac{|(z_i' \beta_0)^2 - (z_i' \beta)^2|}{(z_i' \beta)^2} \\ &= \Sigma(z_i, \beta_0) |(c_i' \beta_0)^2 - (c_i' \beta)^2| / (c_i' \beta)^2, \end{aligned} \quad (2.76)$$

其中, $c_i = z_i / \|z_i\|$, 因条件(D) 成立, 对 $\beta \in N_n(\delta)$ 一致地有 $\|\beta - \beta_0\| \leq [\lambda(F_n)]^{-1/2} \delta \rightarrow 0 (n \rightarrow \infty)$, 又 $\|c_i\| = 1$, 因此有

$$\sup\{|(c_i' \beta)^2 - (c_i' \beta_0)^2| : \beta \in N_n(\delta), i \geq 1\} \rightarrow 0 \quad (n \rightarrow \infty) \quad (2.77)$$

又因 $\beta_0 \in B^o$, 按引理 2.12, 有 $(c_i' \beta_0)^2 \geq a > 0 (i \geq 1)$, 对某 $a > 0$. 因此, 由 $(c_i' \beta)^2 = [c_i' \beta_0 + c_i' (\beta - \beta_0)]^2$, 知当 n 充分大时, 对 $\beta \in N_n(\delta)$ 及 $i \geq 1$, 一致地有

$$(c_i'\beta)^2 \geq (\sqrt{a} - (\underline{\lambda}(F_n))^{-1/2}\delta)^2 \geq a/2. \quad (2.78)$$

由(2.76)~(2.78)式,知对任给 $\epsilon > 0$,当 n 充分大时,对 $\beta \in N_n(\delta)$ 及 $i = 1, 2, \dots$,一致地有

$$|\Sigma(z_i'\beta) - \Sigma(z_i'\beta_0)| \leq \epsilon \Sigma(z_i'\beta_0),$$

即(2.26)式,按注2.2及引理2.3,知条件(N)成立.

现设条件(2.75)式成立,因 $\beta_0 \in B^\circ$,有 $c_i'\beta_0 \leq -a < 0$ ($i \geq 1$).故由(2.75a)式,知

$$F_n \leq \nu a^{-2} Q_n.$$

由此得

$$\bar{\lambda}(Q_n) \geq \nu^{-1} a^2 \bar{\lambda}(F_n), \quad (2.79)$$

此与(2.75)式结合,得

$$\underline{\lambda}(Q_n) \geq c(\nu^{-1} a^2)^{1/2+\delta} [\bar{\lambda}(F_n)]^{1/2+\delta}. \quad (2.80)$$

取 $\beta \in V_\epsilon(\beta_0)$, $\epsilon > 0$ 充分小,使 $V_\epsilon(\beta_0) \subset B^\circ$,则 $\|\beta\| \leq \|\beta_0\| + \epsilon$,因此有 $(c'\beta)^2 \leq \|\beta\|^2 \leq (\|\beta_0\| + \epsilon)^2$.由此,若在(2.75a)式中改 β_0 为 β ,相应地 $F_n(= F_n(\beta_0))$ 改为 $F_n(\beta)$,得 $F_n(\beta) \geq \nu(\|\beta_0\| + \epsilon)^{-2} Q_n$,因而有 $\underline{\lambda}(F_n(\beta)) \geq \nu(\|\beta_0\| + \epsilon)^{-2} \underline{\lambda}(Q_n)$.再由(2.80)式,即得

$$\underline{\lambda}(F_n(\beta)) \geq \nu(\|\beta_0\| + \epsilon)^{-2} c \cdot (\nu^{-1} a^2)^{1/2+\delta} (\bar{\lambda}(F_n))^{1/2+\delta},$$

即条件(S_δ)成立.

2.3 非自然联系

在非自然联系时, $\theta = u(Z'\beta)$,其中 u 不是恒等函数, $U(t) = \partial u(t)/\partial t'$ 就不是单位阵,因此,似然方程(2.16)不能化简为(2.17)式这样的简单形式.这带来一系列的复杂问题.首先, β 的值域 B° 不一定是凸集, $-l(\beta)$ 不再是严凸函数.这样,MLE $\hat{\beta}_n$ 唯一性的证明(2.2.2小节)在此失效. $l_n(\beta)$ 的全局极大点即使存在,也只是似然方程的某一解,且无法确定是哪一个,因此在这里无法像在自然联系下那样证得MLE有如何的性质,而只能证得“在真参数 β_0 的近邻内有一似然解,它具有如何如何的性质”.即使这样,在现实应用中,我们无法把这一似

然解(它在 β_0 附近,是我们想要的解)从似然方程可能的多个解中分辨出来.而且,上述较弱的结论,证明也比自然联系下更为复杂.

在自然联系下, $F_n(\beta) = \text{Cov}_\beta(S_n(\beta))$ 这个矩阵起重要作用,其实质原因是它的另一身份: $F_n(\beta) = I(\beta)$,后者把 $l(\beta)$ 作 Taylor 展开时碰到.因此 $l_n(\beta)$ 不依赖于 $y_1, \dots, y_n$, 是非随机的且 $\ddot{l}_n(\beta) > 0$. 这一点极大地简化了理论.在非自然联系下, $l_n(\beta)$ 与 $y_1, \dots, y_n$ 有关,且不是凸的.下面先给出其表达式.

2.3.1 $l(\beta)$ 的表达式

易知

$$S_n(\beta) = \frac{\partial l_n(\beta)}{\partial \beta} = \sum_{i=1}^n z_i U'(z_i' \beta) (y_i - \mu(z_i' \beta)) \equiv \sum_{i=1}^n z_i \begin{bmatrix} v_{1i} \\ v_{qi} \end{bmatrix}$$

这里

$$\begin{bmatrix} v_{1i} \\ \vdots \\ v_{qi} \end{bmatrix} = U'(z_i' \beta) (y_i - \mu(z_i' \beta))$$

以下分别以 u_r, y_r 和 $\mu_r(z_i' \beta)$ 记 u, y_i 和 $\mu(z_i' \beta)$ 的第 r 分量.回顾 $\mu(z_i' \beta) = E_\beta(y_i) = \dot{b}'(\theta_i) = \dot{b}'(u(z_i' \beta))$, 注意到 $U'(z_i' \beta)$ 的第 j 行为 $(\partial u_1(z_i' \beta)/\partial t_j, \dots, \partial u_q(z_i' \beta)/\partial t_j)$, 则有

$$v_{ji} = \sum_{r=1}^q \frac{\partial u_r(z_i' \beta)}{\partial t_j} [y_{ir} - \mu_r(z_i' \beta)]$$

由此有(用内积求导公式,因 $\partial u_r(z_i' \beta)/\partial t_j$ 和 $y_{ir} - \mu_r(z_i' \beta)$ 都是1维的,不必计较次序,注意 $\partial u_r(z_i' \beta)/\partial t_j = \partial u_r(t)/\partial t_j |_{t=z_i' \beta}$, 其余类似)

$$\partial v_{ji} / \partial \beta' = \sum_{r=1}^q \frac{\partial^2 u_r(z_i' \beta)}{\partial t_j \partial t'} z_i' [y_{ir} - \mu_r(z_i' \beta)] - \frac{\partial u_r(z_i' \beta)}{\partial t_j} \frac{\partial u_r(z_i' \beta)}{\partial t'} z_i',$$

因为

$$\begin{bmatrix} \partial^2 u_r(z_i' \beta) / \partial t_1 \partial t' \\ \vdots \\ \partial^2 u_r(z_i' \beta) / \partial t_q \partial t' \end{bmatrix} = \ddot{u}_r(z_i' \beta), \quad \begin{bmatrix} \partial u_r(z_i' \beta) / \partial t_1 \\ \vdots \\ \partial u_r(z_i' \beta) / \partial t_q \end{bmatrix} = \dot{u}_r'(z_i' \beta),$$

所以

$$\ddot{l}_n(\beta) = \sum_{i=1}^n z_i \sum_{r=1}^q \ddot{u}_r(z_i' \beta) z_i' [y_{ir} - \mu_r(z_i' \beta)]$$

$$\begin{aligned}
& - \sum_{i=1}^n z_i \sum_{r=1}^q \dot{u}_r'(z_i, \beta) \dot{u}_r(z_i, \beta) z_i' \equiv J_1 - J_2, \\
J_1 &= \sum_{i=1}^n z_i \sum_{r=1}^q \dot{u}_r(z_i, \beta) (y_{ir} - \mu_r(z_i, \beta) z_i') \equiv R_n(\beta). \quad (2.81)
\end{aligned}$$

$\mu_r(z_i, \beta)$ 是 $b'(u(z_i, \beta))$ 这列向量的第 r 元, 故

$$\dot{\mu}_r(z_i, \beta) = b(u(z_i, \beta)) U(z_i, \beta) \text{ 的第 } r \text{ 行,}$$

而

$$\mu_r'(z_i, \beta) = U'(z_i, \beta) \text{ 的第 } r \text{ 列.}$$

由此得 $\sum_{r=1}^q \ddot{u}_r(z_i, \beta) [y_{ir} - \mu_r(z_i, \beta) z_i'] z_i' = U'(z_i, \beta) \Sigma(z_i, \beta) U(z_i, \beta)$. 因此

$$\begin{aligned}
J_2 &= \sum_{i=1}^n z_i U'(z_i, \beta) \Sigma(z_i, \beta) U(z_i, \beta) z_i' \\
&\equiv F_n(\beta) = \text{Cov}_\beta(S_n(\beta)). \quad (2.82)
\end{aligned}$$

因此得

$$\ddot{l}_n(\beta) = R_n(\beta) - F_n(\beta) \equiv -H_n(\beta). \quad (2.83)$$

与自然联系的公式比, 多出了 $R_n(\beta)$, 而正是这一项有随机性.

2.3.2 条件和一般性结果

在自然联系下, (D)、(C), ... 这些条件都是涉及 $F_n(\beta)$ (是以其 $-\ddot{l}(\beta)$ 的作用而来). 在非自然联系, $F_n(\beta)$ 的地位由 $H_n(\beta)$ 取代. 故条件是与它有关. 由于 $H_n(\beta)$ 不仅形式复杂且带随机性, 有关条件的验证也就很难.

(D*) 即 (D): $\lambda(F_n) \rightarrow \infty$, 即 $F_n^{-1} \rightarrow 0$.

(C*) 存在常数 $c > 0$, 使对给定的 $\delta > 0$, 当 $n \rightarrow \infty$ 时有

$$P(H_n(\beta) \geq cF_n, \text{对一切了 } \beta \in N_n(\delta)) \rightarrow 1,$$

此处 $N_n(\delta)$ 的意义仍如前, 因 $H_n(\beta)$ 与 $y_1, \dots, y_n$ 有关, 故 $H_n(\beta)$ 是否大于 cF_n , 为随机事件, 故有一定概率. 这概率是在 $\beta = \text{真参数值 } \beta_0$ 之下计算的, 即 $P = P_{\beta_0}$.

定义 $V_n(\beta) = F_n^{-1/2} H_n(\beta) F_n^{-1/2}$.

(N*) 当 $n \rightarrow \infty$ 时, $V_n(\beta)$ 对 $N_n(\delta)$ 内的 β 依概率一致收敛于单位阵 I (p 阶, $p = z_i$ 的行数即 β 的维数). 即

$$\lim_{n \rightarrow \infty} P(\sup_{\beta \in N_n(\delta)} |V_n(\beta) - I| \geq \epsilon) = 0.$$

(S_δ^*) 存在 β_0 的领域 $V_\epsilon(\beta_0) \equiv N, \epsilon > 0$, 常数 $c > 0, \delta > 0$, 满足

$$P(\text{当 } n \text{ 充分大时, } \inf_{\beta \in N} \{\lambda(H_n(\beta))\} \geq c(\bar{\lambda}(F_n))^{1/2+\delta}) = 1.$$

这“ n 充分大”, 大到多少才行, 与样本 $y_1, y_2, \dots$ 有关, 即 $n \geq n_1(y_1, y_2, \dots)$ 的意思. 更确切的参看注 2.3.

定理 2.2' 若条件 (D^*) 、 (C^*) 满足, 则存在 β_0 的一估计量 $\hat{\beta}_n$, 使

1° $P(\hat{\beta}_n \text{ 是似然方程(2.16) 的解}) \rightarrow 1 (n \rightarrow \infty)$.

2° $\hat{\beta}_n$ 为 β_0 的 WC, 即当 $n \rightarrow \infty$ 时, $\hat{\beta}_n$ 依概率收敛于 β_0 .

我们往往把这样一个估计量 $\hat{\beta}_n$ 称为 β_0 的 MLE, 但已不再是 MLE 的原意因为它不一定是 $l_n(\beta)$ 的极大值点. 但是, 如在 B° 内有 $l_n(\beta)$ 的极大点, 它必在似然解(可以有多个)之列, 而 2° 保证了所说的解在待估的 β_0 的近旁.

但是, 在定理只肯定存在这样一个 $\hat{\beta}_n$, 而不能指明如何找到它: 当使用一批数据建立了似然方程, 并用数值方法得出其一解时, 不知是否尚有其他解, 因此也就不知它是否是定理中指出的那个 $\hat{\beta}_n$; 若求出若干个解, 则本定理不能指明怎样去挑出一个满足定理结论的那种解.

在自然联系, 因 MLE $\hat{\beta}_n$ 为 $l_n(\beta)$ 全局极大点, 且除它外, 别无任何其他的局部极大点, 故 $\hat{\beta}_n$ 可由样本唯一地确定. 至于计算上的难度, 那是另外的问题.

定理 2.6' 若 $(D^*) + (N^*)$ 成立, 且

$$F_n^{-1/2} S_n \xrightarrow{d} N(0, I_p), \quad (2.84)$$

则

$$F_n^{1/2}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I_p) \quad (2.85)$$

定理 2.3' 若 $(D^*) + (S_\delta^*)$ 对某个 $\delta > 0$ 成立, 则存在 β_0 的估计量 $\hat{\beta}_n$, 使:

1° $P(\text{对一切充分大的 } n, \hat{\beta}_n \text{ 为似然方程(2.16) 的解}) = 1$;

2° $\hat{\beta}_n$ 为 β_0 的 SC, 即 $\hat{\beta}_n \rightarrow \beta_0, \text{ a.s.}$

这里“充分大的 n ”的意义, 也与注 2.3 的同.

这些定理的证明步骤, 与自然联系下相应定理的证明完全类似, 只在小处有些技术性修改, 以定理 2.2' 为例, 证明中引进 $N_n(\delta)$. 事件 H_n (不用 G_n , 因不涉及全局极大点) 与前一样, 只是在对 $l_n(\beta)$ 作展开时, 那里的 (2.29) 式中的 F_n

当以 H_n 取代, 因此处 $-i_n(\beta)$ 为 $H_n(\beta)$ 而非 $F_n(\beta)$. 但由条件 (C^*) , 有 $H_n(\beta_w) \geq cF_n$ (以接近 1 的概率成立), 故仍得出 (2.29a) 式 (以接近 1 的概率成立). 以下证明, 完全平行推去, 只不时地要拖着一个“以接近 1 的概率成立”的尾巴.

定理 2.6' 的情况有所不同. 我们见到, 这里增加了一个条件 (2.85), 而在定理 2.6 中, (2.85) 式是作为引理 2.8, 即可以由定理 2.6 的条件推出, 不必作为假定其所以有这个差异, 问题在于“把 (2.43) 式两边乘以 $\prod_{i=1}^n c(y_i) d\nu(y_i)$ 再积分”这一步, 右边没有问题, 而左边, 在定理 2.6, 因 e^{J_n} 为常数, 积分结果得 e^{J_n} , 因而得到 (2.45) 式, 再由 $J_n \rightarrow 0$ 得 (2.46) 式, 定理得证. 在此处, 定理 2.6' 则不然: J_n 已不再是常数而为随机 (因在此处, (2.42) 式中的 $V_n(\beta_w) = F_n^{1/2} H_n(\beta_0 + w\delta F_n^{-1/2} t) F_n^{-1/2}$, 而 H_n 为随机的), 故左边的积分已不再是 e^{J_n} , 以下证明失效.

处理这个困难有两个办法:

1° 把上述“左边的积分” $\rightarrow 1$ 作为一个附加条件.

这时, (2.45) 式以

$$m_n(\delta t) = e^{\|\delta t\|^2/2} E_{\beta_n}(e^{J_n})$$

(其所以为 E_{β_n} , 是因为上述积分为

$$\int e^{J_n} \{e^{J_n(\beta_n)} \prod_{i=1}^n c(y_i) d\nu(y_i)\}$$

而 $\{ \}$ 内是 $y_1, \dots, y_n$ 当参数 $\beta = \beta_n$ (即 $\theta_i = z_i' \beta_n, 1 \leq i \leq n$) 下的概率元) 按假定 $E_{\beta_n}(e^{J_n}) \rightarrow 1$, 令 $n \rightarrow \infty$, 得 (2.46) 式.

2° 考虑到 S_n 是独立变量和, (2.41) 式可更方便地用中心极限定理的方法去处理, 故可以将其列为一个条件, 而针对具体问题去直接验证它.

我们采用 2°, 因为 1° 一般更难处理.

我们看到, 非自然联系下, 形式上理论与自然联系其实差异不多. 问题实质在于, 在具体情况下, (D^*) , (C^*) , ... 这些条件的验证, 比之 (D) , (C) , ... 这些条件要困难得多, 下面将看到这一点.

2.3.3 $\{z_i, i \geq 1\}$ 有界

记

$$M = \left\{ E(y | \theta) = \int y c(y) e^{y\theta - b(\theta)} d\nu(y) : \theta \in \Theta^o \right\}$$

$$= \{\dot{b}'(\theta) : \theta \in \Theta^o\}$$

即 y 的均值的值域, 由于 $\dot{b}'$ 是连续、一一对应的变换, 故 M 是 $\mathbb{R}^q$ 中的开集.

联系函数 $g(t)$ 定义于 M , 取值于 $\mathbb{R}^q$, 其值域为

$G \equiv G(M) = \{g(t) : t \in M\}$ (在自然联系, $g = \dot{b}'^{-1}$, 而 $G = \Theta^o$), 要求 g 连续、一一对应, 即 $t^{(1)} \neq t^{(2)} \Rightarrow g(t^{(1)}) \neq g(t^{(2)})$, 则 G 也是 $\mathbb{R}^q$ 中的开集, g 的反函数 $h(t) = g^{-1}(t)$ 定义于 G , 值域为 M . 因要求

$$g(\mu) = z'\beta,$$

而 $\mu \in M$, 故 $z'\beta$ 必须属于 G . 若有样本 (y_i, z_i) ($1 \leq i \leq n$), 则必须有 $z_i'\beta \in G$ ($1 \leq i \leq n$), 因此 β 允许取值的范围为

$$B = \{\beta : z_i'\beta \in G, 1 \leq i \leq n\}.$$

因 G 为开集, 其内点集 $B^o = B$. 但在考虑大样本问题时 ($n \rightarrow \infty$), B 要定义为

$$B = \{\beta : z_i'\beta \in G, i \geq 1\}.$$

这时, 其内点集 B^o 就不一定与 B 一致了, 取 B^o 为 β 的值域.

由联系函数 g 的定义, 有

$$g(\mu) = z'\beta, \quad \mu = \dot{b}'(\theta)$$

故

$$\theta = \dot{b}'^{-1}(\mu) = \dot{b}'^{-1}(g^{-1}(z'\beta)) = \dot{b}'^{-1}(h(z'\beta)) \equiv u(z'\beta)$$

即

$$u(t) = \dot{b}'^{-1}(h(t)) \equiv \dot{b}'^{-1}(g^{-1}(t)) \quad (t \in B^o)$$

这表达了函数 u 与联系 g 之间的关系, 如图 2.4. 在讲述广义线性模型定义时, 我们是从 g 出发, 但直接使用 u 也有好处, 在应用上一有了样本 (y_i, z_i) , 就知 y_i 相应的 θ_i 参数 $\theta_i = u(z_i'\beta)$, 而可写出其依赖 β 的概率函数. 在理论上, 似然方程作为以 β 为未知量的方程, 通过 u 去表示比通过 g 表示简单. 这从 θ_i 的两个表达式

$$\theta_i = u(z_i'\beta), \quad \theta_i = \dot{b}'^{-1}(g^{-1}(z_i'\beta)) = \dot{b}'^{-1}(h(z_i'\beta))$$




图 2.4

即 $u(t) = \dot{b}'^{-1}(h(t))$, $h(t) = \dot{b}'(u(t))$, 由此, 注意到

$$\frac{\partial \dot{b}'(t)}{\partial t'} = b(t) \text{ 存在, 且大于 } 0$$

$$\frac{\partial \dot{b}'^{-1}(t)}{\partial t} = b^{-1}(\dot{b}'^{-1}(t)) \text{ 存在, 且大于 } 0$$

知 $u(t)$ 在 G 内连续 $\Leftrightarrow h(t)$ 在 G 内连续, $u(t)$ 的分量直到 k 阶为止的一切偏导数存在(连续) $\Leftrightarrow h(t)$ 的分量直到 k 阶为止的一切偏导数存在(连续). 例如

$$u(t), \dot{u}(t), u_r(t) \text{ 在 } t \in G \text{ 存在连续 } (1 \leq r \leq g) \quad (2.86)$$

等价于 $h(t), \dot{h}(t), \ddot{h}_r(t)$ 在 $t \in G$ 存在连续 $(1 \leq r \leq q)$.

设有了一组样本 (y_i, z_i) ($i = 1, 2, \dots$), 记

$$y = \{z_i, i \geq 1\} \text{ 的闭包,}$$

即 z_i 本身及 $\{z_i, i \geq 1\}$ 的极限点之集.

定理 2.7 设

1° $\{z_i, i \geq 1\}$ 有界(因此 y 有界), 且

$$\{z'\beta: z \in y, \beta \in B^0\} \subset G, \quad \beta_0 \in B^0 (\beta_0 \text{ 为参数真值});$$

$$2^\circ \lambda(T_n) \rightarrow \infty, T_n = \sum_{i=1}^n z_i';$$

3° 条件(2.86) 成立;

$$4^\circ \det(\dot{u}(t)) \neq 0 (t \in G).$$

则存在 β_0 的估计量 $\hat{\beta}_n$, 满足

$$\lim_{n \rightarrow \infty} P(\hat{\beta}_n \text{ 为似然方程的解}) = 1, \quad (2.87)$$

$$\hat{\beta}_n \text{ 为 } \beta_0 \text{ 的 WC 估计: } \hat{\beta}_n \rightarrow \beta_0, \text{ in. pr. }, \quad (2.87a)$$

$$F_n^{1/2}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I_p) \quad (n \rightarrow \infty). \quad (2.88)$$

与定理 2.5 比较, 这里添加了条件 3°, 在自然联系下, $u(t) = t$, (2.86) 式满足, 故可视定理 2.5 为本定理的特例.

条件 1° 值得解释一下, 根据 B^0 的定义, 当 $\beta \in B^0$ 时, 有 $z_i'\beta \in G$ ($i \geq 1$), 而我们在论证中只涉及 $z_i'\beta$ ($i \geq 1$), 并不涉及 $z'\beta, z \notin \{z_i, i \geq 1\}$. 那么, 为什么要假定对 y 中的 z 也满足 $z'\beta, z \notin \{z_i, i \geq 1\}$. 而且, 为什么要假定对 y 中的 z 也满足 $z'\beta \in G$ 呢? 因为这个条件保证了 $\{z_i'\beta: i \geq 1\}$ 这个集合不会无限接近 G 的边界, 因而也就保证了 $\{\theta_i = u(z_i'\beta): i \geq 1\}$ 不会无限靠近 Θ^0 的边界, 所以需要这一点, 是因为 $b(\theta)$ 在 $\theta \in \Theta^0$ 时有良好性质, 但若 $\theta \rightarrow \Theta$ 边界, 则情况变得复杂, 不好处理.

例如, 当 $\beta \rightarrow \beta_0$ 时, 参数为 β 时的协方差阵 $\Sigma(z_i'\beta_0) \equiv b(u(z_i'\beta_0))$, 与参数 β_0 时协方差阵 $\Sigma(z_i'\beta_0) = b(u(z_i'\beta_0))$, 是不是很接近呢? 当然, 由 $\{z_i\}$ 有界及 $\beta \rightarrow \beta_0$, 知 $z_i'\beta - z_i'\beta_0$ 对 $i \geq 1$ 一致趋近于 0. 但 i 充分大时, $z_i'\beta, z_i'\beta_0$ 可以

很接近 G 的边界, 故 $u(z_i'\beta)$ 与 $u(z_i'\beta_0)$ 可以有很大的差距, 因而不能保证 $\dot{b}(u(z_i'\beta))$ 与 $\dot{b}(u(z_i'\beta_0))$ 很接近. 在条件 1° 之下, 这种情况不会发生.

注 2.6 $u(t)$ 定义于开集 G 上, 连续, 取值于 $\mathbb{R}^q$, 且是一一对应变换, 这是因为 $u(t) = \dot{b}'^{-1}(h(t))$, h 作为联系函数 g 的反函数, 为一一对应. (因 g 作为联系函数要求为一一对应), 而由指数族性质, 知 $\dot{b}'^{-1}$ 为一一对应. 事实上, 设 $\theta^{(1)} \neq \theta^{(2)}$, 由积分公式, 知

$$\dot{b}'(\theta^{(2)}) - \dot{b}'(\theta^{(1)}) = \int_0^1 \dot{b}(\theta^{(1)} + w(\theta^{(2)} - \theta^{(1)})) dw (\theta^{(2)} - \theta^{(1)})$$

由 $b > 0$, 知

$$A = \int_p^1 \dot{b}(\theta^{(1)} + w(\theta^{(2)} - \theta^{(1)})) dw > 0$$

故 $\det(A) \neq 0$. 由 $\det(A) \neq 0$ 及 $\theta^{(2)} - \theta^{(1)} \neq 0$, 知 $A(\theta^{(2)} - \theta^{(1)}) \neq 0$. 这证明

了 $\dot{b}'(\theta^{(1)}) \neq \dot{b}'(\theta^{(2)})$, $\theta^{(1)} \neq \theta^{(2)}$, 因此 $\dot{b}'$ 为一一对应, 因其反函数 $\dot{b}'^{-1}$ 也是一一对应, 由 h 及 $\dot{b}'^{-1}$ 皆为一一对应, 知 u 也是一一对应, 这样, u 有反函数. 应当注意的是:

1. 一个函数 $y = f(x) (\mathbb{R}^q \rightarrow \mathbb{R}^q)$ 有连续导数不能推出其反函数有导数存在, 如图 2.5. 一个简单例子是

$$y = f_1(x) = \begin{cases} x^2, & x \geq 0 \\ -x^2, & x < 0 \end{cases},$$

则 $f(x)$ 的导数 $df(x)/dx = 2|x|$ 处处存在连续, 但其反函数

$$x = f_1^{-1}(y) = \begin{cases} \sqrt{y}, & y \geq 0 \\ -\sqrt{y}, & y < 0 \end{cases}$$

在 0 点无导数. 又如

$$y = f_2(x) = \begin{cases} \exp\left(-\frac{1}{x}\right), & 0 < x < \infty \\ -\exp\left(\frac{1}{x}\right), & -\infty < x < 0 \\ 0, & x = 0 \end{cases}$$




图 2.5

在 $-\infty < x < \infty$ 处处有无穷阶导数,但其反函数

$$x = f_2^{-1}(y) = \begin{cases} -1/\log y, & 0 < y < 1 \\ 1/\log(-y), & -1 < y < 0 \\ 0, & y = 0 \end{cases}$$

在 $y = 0$ 处无导数(但这一注解不适用于 $\dot{b}'$, 因前已证明(见(2.7)式) $\partial \dot{b}'(t)/\partial t' = \dot{b}(\dot{b}'(t))$).

2. 一个一一对应变换的 Jacobi 行列式不一定处处不为 0. 例如上面的 $y = f_1(x)$, 为一一对应, 但 Jacobi 行列式(即 $df(x)/dx$) 在 $x = 0$ 处为 0^①. 反之, 一个变换, 其 Jacobi 行列式处处不为 0, 不一定为一一对应. 例: $y_1 = x_1 \cos x_2$, $y_2 = x_1 \sin x_2$ ($x_1 > 0$, $x_2 > 0$), 其 Jacobi 行列式为 x_1 , 处处大于 0, 但非一一对应.

定理 2.7 的证明依赖于以下一些引理.

引理 2.13 设 $\epsilon > 0$ 充分小, 使 $\bar{V}_\epsilon(\beta_0) \subset B^o(\bar{V}_\epsilon(\beta_0) = V_\epsilon(\beta_0))$ 的闭包 $= \{\beta: \|\beta - \beta_0\| \leq \epsilon\}$, 则存在 $c > 0$ 使对一切 $i \geq 1$ 及 $\beta \in \bar{V}_\epsilon(\beta_0)$, 有

$$U'(z_i, \beta) U(z_i, \beta) \geq c I_q, \quad (2.89)$$

$$U'(z_i, \beta) \Sigma(z_i, \beta) U(z_i, \beta) \geq c I_q. \quad (2.90)$$

证 设(2.89)式不成立, 即对任何自然数 m , 存在下标 i_m 及 $\beta^{(m)} \in \bar{V}_\epsilon(\beta_0)$, 使 $U'(z_{i_m}, \beta^{(m)}) U(z_{i_m}, \beta^{(m)}) \not\geq \frac{1}{m} I_q$, 因而存在单位向量 λ_m , 使

$$\lambda_m' U'(z_{i_m}, \beta^{(m)}) U(z_{i_m}, \beta^{(m)}) \lambda_m \leq m^{-1}. \quad (2.91)$$

因 $\{\lambda_m\}$, $\{z_{i_m}\}$ 和 $\{\beta^{(m)}\}$ 都处在一有界集内, 故存在 m 的子列 $\{m_j, j = 1, 2, \dots\}$, 使当 $j \rightarrow \infty$ 时, 有

$$\lambda_{m_j} \rightarrow \lambda^*, \quad z_{i_{m_j}} \rightarrow z^*, \quad \beta^{(m_j)} \rightarrow \beta^*.$$

在(2.91)式中用 m_j 取代 m , 然后令 $j \rightarrow \infty$, 利用 U 的连续性(条件 3°), 得

$$\lambda^{*'} U'(Z^*, \beta^*) U(Z^*, \beta^*) \lambda^* \equiv \|U(Z^*, \beta^*) \lambda^*\|^2 = 0,$$

即 $U(Z^*, \beta^*) \lambda^* = 0$. 因 $z^* \in y$, $\beta^* \in \bar{V}_\epsilon(\beta_0)$, 知 $Z^*, \beta^* \in G$. 由条件 4° 知 $\det(U(Z^*, \beta^*)) \neq 0$, 而 $\lambda^* \neq 0$ (它是单位向量), 故有 $U(Z^*, \beta^*) \lambda^* \neq 0$, 矛盾. 这证明了(2.89)式.

为证(2.90)式, 注意到 $\Sigma(z_i, \beta) = b(u(z_i, \beta))$. 首先由条件 1° 知, 闭集 T

① 因此, 定理 2.7 的条件 4° 不可缺少, 它不能由 u 是一一对应变换推出来的.

$\equiv \{Z'\beta: Z \in y, \beta \in \bar{V}\epsilon(\beta_0)\} \subset G$, 故 $u(t) \in \Theta^\circ$, 当 $t \in T$. 由此及(2.86)式可知, 存在常数 $c_1 > 0$, 使

$$b(u(t)) \geq c_1 I_q \quad (t \in T). \quad (2.92)$$

因若不然, 则存在一串 $\{t_m, m \geq 1\} \subset T$, 使 $b(u(t_m)) \not\geq \frac{1}{m} I_q$. 用刚才的证法, 可找到单位向量 λ^* 及 $t^* \in T$, 使

$$\lambda^{*\prime} \dot{b}(u(t^*)) \lambda^* = 0,$$

但由于 $t^* \in T$, 知 $u(t^*) \in \Theta^\circ$, 因而有 $\lambda^{*\prime} \dot{b}(u(t^*)) > 0$, 与上式矛盾. 这证明了(2.92)式.

现任取 $\mathbb{R}^q$ 中的单位向量 λ , 由(2.92)式, 注意到 $z_i' \beta \in T$, 有

$$\begin{aligned} & \lambda' U'(z_i' \beta) \Sigma(z_i' \beta) U(z_i' \beta) \lambda \\ &= (U(z_i' \beta) \lambda)' \dot{b}(u(z_i' \beta)) (U(z_i' \beta) \lambda) \\ &\geq c_1 \|U(z_i' \beta) \lambda\|^2 = c_1 \lambda' (U'(z_i' \beta) U(z_i' \beta)) \lambda, \end{aligned}$$

由此, 利用已证的(2.89)式, 有

$$\lambda' U'(z_i' \beta) \Sigma(z_i' \beta) U(z_i' \beta) \lambda \geq c_1 c.$$

由于 λ 为任意取的单位向量, 由上式得

$$U'(z_i' \beta) \Sigma(z_i' \beta) U(z_i' \beta) \geq c_1 c I_q.$$

这证明了(2.90)式, 其中常数 c 取为上式中的 $c_1 c$. 引理证毕.

以下把 $U(z_i' \beta_0)$, $\Sigma(z_i' \beta_0)$, $\mu(z_i' \beta_0)$, 分别简记为 U_i , Σ_i , $\mu_i, \dots$.

引理 2.14 在定理条件下, 有 ($E = E_{\beta_0}$)

$$\sup\{E(\|Y_i - \mu_i\|^3), i \geq 1\}. \quad (2.93)$$

证 因 $\|Y_i - \mu_i\|^3 \leq 8(\|y_i\|^3 + \|\mu_i\|^3)$, 而 $\{\|\mu_i\|^3; i \geq 1\}$ 有界 (此因 $\mu_i = E(Y_i) = \dot{b}'(u(z_i' \beta_0))$, $\{z_i' \beta_0, i \geq 1\} \subset$ 闭集 T , 而 $\{u(t): t \in T\}$ 为 Θ° 的一有界闭集, 故由 $\dot{b}(\theta)$ 在 $\theta \in \Theta^\circ$ 连续, 知 $\{\dot{b}'(u(z_i' \beta_0)), i \geq 1\}$ 有界.) 因此, 为证(2.93)式, 只需证 $\sup\{E(\|Y_i\|^3), i \geq 1\} < \infty$. 因为 $[E(\|Y_i\|^3)]^{1/3} \leq [E(\|Y_i\|^4)]^{1/4}$, 故只需证

$$\sup\{E(\|Y_i\|^4), i \geq 1\} < \infty. \quad (2.94)$$

记 $Y_i = (y_{i1}, \dots, y_{iq})$, 则

$$\|Y_i\|^4 = \left(\sum_{j=1}^q y_{ij}^2\right)^2 \leq q(y_{i1}^4 + \dots + y_{iq}^4).$$

故为证(2.94)式,只需证

$$\sup\{E(y_{ij}^4), i \geq 1\} < \infty. \quad (2.95)$$

记 $\theta_i = u(z_i' \beta_0) = (\theta_{i1}, \dots, \theta_{iq})'$. 由

$$\exp(b(\theta_i)) = \int e^{y_i' \theta_i} c(y_i) d\nu(y_i),$$

两边对 θ_{ij} 求 4 阶偏导数,有

$$\partial^4 e^{b(\theta_i)} / \partial \theta_{ij}^4 = \int y_{ij}^4 e^{y_i' \theta_i} c(y_i) d\nu(y_i).$$

故

$$e^{-b(\theta_i)} (\partial^4 e^{b(\theta_i)} / \partial \theta_{ij}^4) = \int y_{ij}^4 e^{y_i' \theta_i - b(\theta_i)} c(y_i) d\nu(y_i) = E(y_{ij}^4). \quad (2.96)$$

因 $\{\theta_i = u(z_i' \beta_0) : i \geq 1\}$ 落在 Θ^0 的一个闭集内, $b(\theta)$ 及其任意阶偏导数都有界,故(2.96)式左边, $i \geq 1$ 是有界的. 这证明了(2.95)式,因而(2.94)式成立. 引理证毕.

引理 2.15 在定理的条件下,条件(D*)成立.

证 由(2.90)式及条件 2°,有

$$\begin{aligned} F_n &\equiv \sum_{i=1}^n z_i U_i' \Sigma_i U_i z_i' \geq \sum_{i=1}^n z_i c I_q z_i' = c T_n \\ &\Rightarrow \underline{\lambda}(F_n) \geq c \underline{\lambda}(T_n) \rightarrow \infty. \end{aligned}$$

引理 2.16 在定理条件下,有

$$\begin{aligned} \varepsilon_n &\equiv \sup\{|U'(z_i' \beta) \Sigma(z_i' \beta) U(z_i' \beta) - U_i' \Sigma_i U_i| : \\ &\quad i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0 \quad (n \rightarrow \infty). \end{aligned} \quad (2.97)$$

证 由引理 2.15,有 $\underline{\lambda}(F_n) \rightarrow \infty$. 故 $\|\beta - \beta_0\|$ 对 $\beta \in N_n(\delta)$ 一致趋于 0 ($n \rightarrow \infty$). 因 $\{z_i\}$ 有界,由此知 $\sup\{\|z_i'(\beta - \beta_0)\| : i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0$ ($n \rightarrow \infty$). 由此,并注意到 Σ 和 U 的连续性,即得(2.97)式.

引理 2.17 设 $\xi_1, \xi_2, \dots$ 为一串 q 维随机向量,满足条件:

$$\lambda' \xi_n \xrightarrow{d} N(0, 1), \text{ 对任何 } q \text{ 维单位向量 } \lambda \quad (n \rightarrow \infty), \quad (2.98)$$

则

$$\xi_n \xrightarrow{d} N(0, I_q) \quad (n \rightarrow \infty). \quad (2.99)$$

证 由(2.98)式,知 $\lambda' \xi_n$ 的特征函数 $E(e^{it \lambda' \xi_n}) \rightarrow e^{-t^2/2}$ ($t^2 = -1$),对任何实数 t . 若以 φ_n 记 ξ_n 的特征函数 $E(e^{it' \xi_n})$,上式可表为

$$\varphi_n(t\lambda) \rightarrow e^{-t^2/2} = e^{-\|t\lambda\|^2/2}. \quad (2.100)$$

当 λ 跑遍一切 q 维单位向量, 而 t 跑遍一切实数时, $t\lambda$ 跑遍 $\mathbb{R}^q$. 故 (2.100) 式可写为 $\varphi_n(s) \rightarrow e^{-\|s\|^2/2}$, 对任何 $s \in \mathbb{R}^q$. 因 $e^{-\|s\|^2/2}$ 就是 $N(0, I_q)$ 的特征函数, 据特征函数的收敛定理, 由 (2.100) 式推出 (2.99) 式. 引理证毕.

引理 2.18 设对每个 n 有独立随机变量 $\xi_{n1}, \dots, \xi_{nn}$, 其均值为 0, 方差之和为 1. 若对任何 $\varepsilon > 0$, 有

$$\sum_{i=1}^n E[\xi_{ni}^2 I(|\xi_{ni}| \geq \varepsilon)] \rightarrow 0 \quad (n \rightarrow \infty), \quad (2.101)$$

则

$$\sum_{i=1}^n \xi_{ni} \xrightarrow{d} N(0, 1). \quad (2.102)$$

此为著名的 Lindeberg 中心极限定理. 证明见 Loeve 《Probability Theory》第 6 章.

定理 2.7 的证明

按定理 2.6', 要验证条件 (D*)、(N*) 和 (2.85) 式. (D*) 已见引理 2.15, 现证明 (2.85) 式. 令 λ 为 q 维单位向量, 以及

$$\begin{aligned} y_i^* &= \Sigma_i^{-1/2}(y_i - \mu_i), \quad a_{ni}' = \lambda' F_n^{-1/2} z_i U_i' \Sigma_i^{1/2} \\ \xi_{ni} &= a_{ni}' y_i^*, \quad \eta_{ni} = \xi_{ni} / \|a_{ni}\| \quad (1 \leq i \leq n), \end{aligned}$$

则有

$$\lambda' F_n^{-1/2} S_n = \sum_{i=1}^n \xi_{ni} = \sum_{i=1}^n \|a_{ni}\| \eta_{ni}.$$

因 $\{z_i\}, \{U_i\}, \{\Sigma_i^{-1/2}\}$ 皆有界, 而 $F_n^{-1} \rightarrow 0$, 知

$$\max_{1 \leq i \leq n} \|a_{ni}\| \rightarrow 0 \quad (n \rightarrow \infty).$$

又因 $E(y_i^*) = 0$, $\text{Cov}(y_i^*) = \Sigma_i^{-1/2} \text{Cov}(y_i) \Sigma_i^{-1/2} = I_q$, 有

$$E(\xi_{ni}) = 0,$$

$$\begin{aligned} \sum_{i=1}^n \text{Var}(\xi_{ni}) &= \sum_{i=1}^n a_{ni}' \text{Cov}(y_i^*) a_{ni} = \sum_{i=1}^n a_{ni}' a_{ni} \\ &= \lambda' F_n^{-1/2} \sum_{i=1}^n z_i U_i' \Sigma_i^{-1/2} \Sigma_i^{1/2} U_i z_i' \cdot F_n^{-1/2} \lambda \\ &= \lambda' F_n^{-1/2} F_n F_n^{-1/2} \lambda = \lambda' \lambda = 1. \end{aligned}$$

因此, 据引理 2.18, 为证

$$\lambda' F_n^{-1/2} S_n \equiv \sum_{i=1}^n \xi_{ni} \xrightarrow{d} N(0, 1) \quad (n \rightarrow \infty), \quad (2.103)$$

只需证:对任何 $\varepsilon > 0$, 有

$$\sum_{i=1}^n \mathbb{E}[\xi_{ni}^2 (|\xi_{ni}| \geq \varepsilon)] \rightarrow 0 \quad (n \rightarrow \infty). \quad (2.104)$$

因 $\Sigma_i \geq cI$, 对某个 $c > 0, i \geq 0$, 知 $\underline{\lambda}(\Sigma_i) \geq c$, 即 $\bar{\lambda}(\Sigma_i^{-1/2}) \leq c^{-1/2} (i \geq 1)$. 于是有 $\|y_i^*\|^3 \leq c^{-3/2} \|y_i - \mu_i\|^3$. 由此及引理 2.14, 有

$$M \equiv \sup\{\mathbb{E}(\|y_i^*\|^3): i \geq 1\} < \infty. \quad (2.105)$$

现有

$$\mathbb{E}[\xi_{ni}^2 I(|\xi_{ni}| \geq \varepsilon)] = \sum_{i=1}^n \|a_{ni}\|^2 \mathbb{E}(\eta_{ni}^2 I(|\eta_{ni}| \geq \varepsilon / \|a_{ni}\|)).$$

因 $I(|\eta_{ni}| \geq \varepsilon / \|a_{ni}\|) \leq (\varepsilon / \|a_{ni}\|)^{-1} |\eta_{ni}|$, 有

$$\mathbb{E}[\xi_{ni}^2 I(|\xi_{ni}| \geq \varepsilon)] \leq \sum_{i=1}^n \|a_{ni}\|^2 \cdot \|a_{ni}\| \varepsilon^{-1} \mathbb{E}(|\eta_{ni}|^3), \quad (2.106)$$

由 $\xi_{ni} = a_{ni}^* y_i^*$, 有 $|\xi_{ni}| \leq \|a_{ni}\| \cdot \|y_i^*\|$, 故 $|\eta_{ni}| \leq |\xi_{ni}| / \|a_{ni}\| \leq \|y_i^*\|$. 由此及(2.105)式, 知 $\sup\{\mathbb{E}(|\eta_{ni}|^3): 1 \leq i \leq n\} \leq M < \infty$. 故由(2.106)式, 得

$$\begin{aligned} & \sum_{i=1}^n \mathbb{E}[\xi_{ni}^2 I(|\xi_{ni}| \geq \varepsilon)] \\ & \leq \varepsilon^{-1} \left(\max_{1 \leq i \leq n} \|a_{ni}\| \right) \sum_{i=1}^n \|a_{ni}\|^2 \sup\{\mathbb{E}(|\eta_{ni}|^3): 1 \leq i \leq n\} \\ & \leq \varepsilon^{-1} \max_{1 \leq i \leq n} \|a_{ni}\| \cdot 1 \cdot M \rightarrow 0 \quad (n \rightarrow \infty). \end{aligned}$$

这证明了(2.104)式, 因而(2.103)式也成立. 因(2.103)式对任何单位向量 λ 都成立, 按引理 2.18, 有(2.85)式.

剩下证明条件 (N^*) , 按 $H_n(\beta)$ 的表达式(2.83), 它可以由以下两个结论推出:

$$1^\circ \text{ 当 } n \rightarrow \infty \text{ 时, } \sup\{|F_n^{-1/2} R_n(\beta) F_n^{-1/2}|: \beta \in N_n(\delta)\} \rightarrow 0, \text{ in pr.}; \quad (2.107)$$

$$2^\circ \text{ 当 } n \rightarrow \infty \text{ 时, } \sup\{|F_n^{-1/2} F_n(\beta) F_n^{-1/2} - I|: \beta \in N_n(\delta)\} \rightarrow 0. \quad (2.108)$$

(因 $R_n(\beta)$ 为随机(依赖 $y_1, \dots, y_n$) 而 $F_n(\beta)$ 非随机, 故 1° 带“in pr.”, 而 2° 则否.)

按 $R_n(\beta)$ 的表达式(2.81), 并记

$$\alpha_{ni} = F_n^{-1/2} z_i = \begin{pmatrix} \alpha_{ni1} \\ \vdots \\ \alpha_{nip} \end{pmatrix}, \quad \alpha_{ni}: p \times q \text{ 阵}. \quad (2.109)$$

易得到下面的分解式

$$F_n^{-1/2} R_n(\beta) F_n^{-1/2} = \sum_{r=1}^q [B_{nr} + C_{nr}(\beta) + D_{nr}(\beta)], \quad (2.110)$$

其中(注意 $\mu_{ir} = \mu_{ir}(\beta_0) = E(y_{ir})$)

$$B_{nr} = \sum_{i=1}^n \alpha_{ni} u_r(z_i' \beta_0) \alpha_{ni}' (y_{ir} - \mu_{ir}),$$

$$C_{nr}(\beta) = \sum_{i=1}^n \alpha_{ni} (\ddot{u}_r(z_i' \beta) - \ddot{u}_r(z_i' \beta_0) \alpha_{ni}' (y_{ir} - \mu_{ir})),$$

$$D_{nr}(\beta) = \sum_{i=1}^n \alpha_{ni} \dot{u}_r(z_i' \beta) \alpha_{ni}' (\mu_{ir} - \mu_{ir}(\beta)).$$

取 B_{nr} 的 (j, k) 元, 记为 f_n , 有

$$f_n = \sum_{i=1}^n \alpha_{nij}' \dot{u}_r(z_i' \beta_0) \alpha_{nik} \cdot (y_{ir} - \mu_{ir}) \equiv \sum_{i=1}^n m_{ni} (y_{ir} - \mu_{ir}).$$

(m_{ni} 与 j, k 有关, 但 j, k 已固定, 不必标出.)

由条件 1° 及 3°, 有 $|u_r(z_i' \beta_0)| \leq M < \infty$ ($i \geq 1$), 对某常数 M . 故^①

$$\begin{aligned} |m_{ni}|^2 &\leq (qM \|\alpha_{nij}\| \|\alpha_{nik}\|)^2 \\ &\leq M^2 q^3 \|\alpha_{nij}\|^2 \max_{1 \leq i \leq n} |\alpha_{ni}|^2 (\|\alpha_{nik}\|^2 \leq q |\alpha_{ni}|^2). \end{aligned}$$

因 $\text{tr}(\alpha_{ni} \alpha_{ni}') = \sum_{j=1}^p \|\alpha_{nij}\|^2 \geq \|\alpha_{ni}'\|^2$, 由上式得

$$\sum_{i=1}^n m_{ni}^2 \leq M^2 q^3 \sum_{i=1}^n \text{tr}(\alpha_{ni} \alpha_{ni}') \max_{1 \leq i \leq n} |\alpha_{ni}|^2. \quad (2.111)$$

往证(2.111)式右边 $\rightarrow 0$ ($n \rightarrow \infty$). 为此, 只需证

$$\sup_{n \geq 1} \sum_{i=1}^n \text{tr}(\alpha_{ni} \alpha_{ni}') < \infty, \quad (2.112)$$

① 设 q 阶方程 $C = (c_{ij})$ 满足 $|C| \leq M, a = (a_1, \dots, a_q)', b = (b_1, \dots, b_q)'$. 则

$$\begin{aligned} |a'Cb| &= \left| \sum_{i,j=1}^q c_{ij} a_i b_j \right| \leq M \sum_{i,j=1}^q |a_i b_j| = M \sum_{i=1}^q |a_i| \sum_{j=1}^q |b_j| \\ &\leq M \left(q \sum_{i=1}^q a_i^2 \right)^{1/2} \left(q \sum_{j=1}^q b_j^2 \right)^{1/2} = Mq \|a\| \|b\|. \end{aligned}$$

$$\max_{1 \leq i \leq n} |\alpha_{ni}| \rightarrow 0 \quad (n \rightarrow \infty). \quad (2.113)$$

由 $F_n = \sum_{i=1}^n z_i U_i' \Sigma_i U_i z_i'$ 及 $U_i' \Sigma_i U_i \geq cI$ ($i \geq 1$) (见 2.90) 式, 知 $F_n \geq$

$c \sum_{i=1}^n z_i z_i' = cT_n$. 故 $T_n \leq c^{-1}F_n$, 而

$$\begin{aligned} \sum_{i=1}^n \text{tr}(\alpha_{ni} \cdot \alpha_{ni}') &= \sum_{i=1}^n \text{tr}(F_n^{-1/2} z_i z_i' F_n^{-1/2}) = \text{tr}(F_n^{-1/2} \sum_{i=1}^n z_i z_i' F_n^{-1/2}) \\ &= \text{tr}(F_n^{-1/2} T_n F_n^{-1/2}) \leq c^{-1} \text{tr}(F_n^{-1/2} F_n F_n^{-1/2}) \\ &= c^{-1} \text{tr}(I_p) = c^{-1} p, \end{aligned} \quad (2.113a)$$

即(1.112)式. 至于(2.113)式, 由 $\alpha_{ni} = F_n^{-1/2} z_i$, $\{z_i, i \geq 1\}$ 有界及 $\lambda(F_n) \rightarrow \infty$ 即推出 $F_n^{-1} \rightarrow 0$, 因此

$$\lim_{n \rightarrow \infty} \sum_{i=1}^n m_{ni}^2 = 0, \quad (2.114)$$

有 $E(y_{ir} - \mu_{ir}) = 0$, 而 $\sup\{\text{Var}(y_{ir}) : i \geq 1\} \equiv M < \infty$. 这是因为 $\text{Var}(y_{ir})$ 是 $b(z_i' \beta_0)$ 的主对角线上第 r 元, 而 $\{\ddot{b}(u(z_i' \beta_0)) : i \geq 1\}$ 是有界的, 这与(2.114)式结合, 得

$$E(|f_n|^2) = \sum_{i=1}^n m_{ni}^2 \text{Var}(y_{ir}) \leq M \sum_{i=1}^n m_{ni}^2 \rightarrow 0$$

于是, 由 Markov 不等式, 有

$$P(|f_n| \geq \epsilon) = P(|f_n|^2 \geq \epsilon^2) \leq E(|f_n|^2)/\epsilon^2 \rightarrow 0,$$

对任何 $\epsilon > 0$, 即 $f_n \rightarrow 0$ in pr. 当 $n \rightarrow \infty$. 因为这对 B_{nr} 的任何一元都成立, 得

$$|B_{nr}| \rightarrow 0, \text{ in pr. } (n \rightarrow \infty). \quad (2.115)$$

$D_{nr}(\beta)$ 与 B_{nr} 类似: 任取 $D_{nr}(\beta)$ 的 (j, k) 元, 记为 $f_{nj\beta}$, 则

$$f_{nj\beta} = \sum_{i=1}^n \alpha_{nij}' u_r(z_i' \beta) \alpha_{nik} (\mu_{ir} - \mu_{ir}(\beta)),$$

有

$$\begin{aligned} |f_{nj\beta}| &\leq \sum_{i=1}^n |\alpha_{nij}' u_r(z_i' \beta) \alpha_{nik}| \cdot |\mu_{ir} - \mu_{ir}(\beta)| \\ &\leq \sum_{i=1}^n q |\dot{u}_r(z_i' \beta)| \cdot \|\alpha_{nij}\| \cdot \|\alpha_{nik}\| \cdot |\mu_{ir} - \mu_{ir}(\beta)|. \end{aligned} \quad (2.116)$$

因

$\mu_{ir} - \mu_{ir}(\beta) = \{\dot{b}'(u(z_i'\beta_0)) - \dot{b}'(u(z_i'\beta))\}$ 的 r 元,
 而因条件(D*)成立,有 $\sup\{\|z_i'\beta - z_i'\beta_0\| : \beta \in N_n(\delta), i \geq 1\} \rightarrow 0 (n \rightarrow \infty)$,
 而 $\{z_i : i \geq 1\}$ 有界,故有 $\sup\{\|z_i'\beta_0 - z_i'\beta\| : \beta \in N_n(\delta), i \geq 1\} \rightarrow 0 (n \rightarrow \infty)$.
 这结合 $\dot{b}'(u(t))$ 的连续性,得

$$M_n \equiv \sup\{|\mu_{ir} - \mu_{ir}(\beta)| : \beta \in N_n(\delta), i \geq 1\} \rightarrow 0 \quad (n \rightarrow \infty) \quad (2.117)$$

同样

$$Q \equiv \sup\{|u_r(z_i'\beta)| : \beta \in N_n(\delta), i \geq 1\} < \infty, \quad (2.118)$$

故由(2.116)式,有

$$\begin{aligned} \sup\{|f_{n\beta}| : \beta \in N_n(\delta)\} &\leq qQM_n \sum_{i=1}^n \|\alpha_{ni}\| \|\alpha_{nk}\| \\ &\leq qQM_n \left(\sum_{i=1}^n \|\alpha_{ni}\|^2\right)^{1/2} \left(\sum_{i=1}^n \|\alpha_{nk}\|^2\right)^{1/2}. \end{aligned} \quad (2.119)$$

因 $\text{tr}(\alpha_n \alpha_n') = \|\alpha_{n1}\|^2 + \cdots + \|\alpha_{nq}\|^2 \geq \|\alpha_{nj}\|^2$, 有(据(2.113a)式)

$$\sum_{i=1}^n \|\alpha_{ni}\|^2 \leq \sum_{i=1}^n \text{tr}(\alpha_n \alpha_n') \leq c^{-1}p. \quad (2.120)$$

结合(2.117) ~ (2.120)式,得

$$\sup\{|f_{n\beta}| : \beta \in N_n(\delta)\} \rightarrow 0 \quad (n \rightarrow \infty),$$

即

$$\sup\{|D_{nr}(\beta)| : \beta \in N_n(\delta)\} \rightarrow 0 \quad (n \rightarrow \infty). \quad (2.121)$$

$D_{nr}(\beta)$ 不依赖 $y_1, \dots, y_n$, 故没有“in pr.”.

从 $C_{nr}(\beta)$ 中任取其 (j, k) 元, 记为 $f_{n\beta}$, 有

$$f_{n\beta} = \sum_{i=1}^n \alpha_{nij}'(u_r(z_i'\beta) - u_r(z_i'\beta_0)) \alpha_{nik}(y_{ir} - \mu_{ir}),$$

于是

$$\begin{aligned} \sup\{|f_{n\beta}| : \beta \in N_n(\delta)\} \\ \leq \sum_{i=1}^n \sup\{|\alpha_{nij}'(u_r(z_i'\beta) - u_r(z_i'\beta_0)) \alpha_{nik}| : \beta \in N_n(\delta)\} |y_{ir} - \mu_{ir}|. \end{aligned}$$

与前面一样的推理: 由 $\sup\{\|z_i'\beta_0 - z_i'\beta\| : i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0$ 及 $\ddot{u}(t)$ 的连续性, 有

$$\epsilon_n \equiv \sup\{|u_r(z_i'\beta) - u_r(z_i'\beta_0)| : \beta \in N_n(\delta), i \geq 1\} \rightarrow 0 \quad (n \rightarrow \infty).$$

又 $\sup\{E(|y_{ir} - \mu_{ir}|), i \geq 1\} \leq \sup\{\sqrt{\text{Var}(y_{ir})} : i \geq 1\} \equiv Q < \infty$, 因此有

$$E\{\sup\{|f_{n\beta}| : \beta \in N_n(\delta)\} \leq qQ\epsilon_n \sum_{i=1}^n \|\alpha_{ni}\| \|\alpha_{nk}\|.$$

前面已证明后一个和不超过 $c^{-1}p$, 因此, 由上式, 注意 $\epsilon_n \rightarrow 0$, 得

$$E\{\sup\{|f_{n\beta}| : \beta \in N_n(\delta)\} \rightarrow 0 \quad (n \rightarrow \infty).$$

利用 Markov 不等式, 得 $\sup\{|f_{n\beta}| : \beta \in N_n(\delta)\} \rightarrow 0$, in pr. $(n \rightarrow \infty)$. 这证明了

$$\sup\{|c_{nr}(\beta)| : \beta \in N_n(\delta)\} \rightarrow 0 \text{ in pr. } (n \rightarrow \infty). \quad (2.122)$$

结合(2.115)、(2.121)和(2.122)式, 就证明了(2.107)式.

现往证(2.108)式. 有

$$\begin{aligned} & \sup\{|F_n^{-1/2}F_n(\beta)F_n^{-1/2} - I| : \beta \in N_n(\delta)\} \\ &= \sup\{|F_n^{-1/2}(F_n(\beta) - F_n)F_n^{-1/2}| : \beta \in N_n(\delta)\} \\ &= \sup\{|F_n^{-1/2}\{\sum_{i=1}^n z_i(U'z_i'\beta)\Sigma(z_i'\beta)U(z_i'\beta) - U_i'\Sigma_i U_i\}F_n^{-1/2}| : \beta \in N_n(\delta)\}. \end{aligned} \quad (2.123)$$

由引理 2.17((2.97)式), 知存在常数 $\eta_n \rightarrow 0$, 使

$$-\eta_n I_q \leq U'(z_i'\beta)\Sigma(z_i'\beta)U(z_i'\beta) - U_i'\Sigma_i U_i \leq \eta_n I_q.$$

由此及(2.123)式, 有

$$\begin{aligned} & \sup\{|F_n^{-1/2}F_n(\beta)F_n^{-1/2} - I| : \beta \in N_n(\delta)\} \\ & \leq \left| F_n^{-1/2} \sum_{i=1}^n z_i z_i' F_n^{-1/2} \right| \cdot \eta_n = |F_n^{-1/2} T_n F_n^{-1/2}| \eta_n. \end{aligned}$$

前已证明 $T_n \leq c^{-1}F_n$ (见(2.113)式下), 故 $|F_n^{-1/2}T_n F_n^{-1/2}| \leq c^{-1}|I| = c^{-1}$, 因此

$$\sup\{|F_n^{-1/2}F_n(\beta)F_n^{-1/2} - I| : \beta \in N_n(\delta)\} \leq c^{-1}\eta_n \rightarrow 0.$$

这证明了(2.108)式, 从而完成了定理 2.7 的证明.

2.3.4 y 的值域有界

定理 2.8 假定:

1° y 的值域有界;

2° $\lambda(T_n) \rightarrow \infty$, $T_n = \sum_{i=1}^n z_i z_i'$;

3° $\lim_{n \rightarrow \infty} \text{tr}(z_n' F_n^{-1} z_n) = 0$,

$$\text{tr}(F_n^{-1} T_n) = \text{tr}(F_n^{-1} \sum_{i=1}^n z_i z_i') = \sum_{i=1}^n \text{tr}(F_n^{-1} (z_i z_i'))$$

$$= \sum_{i=1}^n \text{tr}(z_i' F_n^{-1} z_i);$$

$$4^\circ \sup\{\text{tr}(F_n^{-1} T_n), n \geq 1\} \equiv c < \infty;$$

5° u 的前 1, 2 阶偏导数在 G 上处处存在, 且皆在 G 上一致连续, 在 G 上有界.

则定理 2.7 的结论, 即 (2.87), (2.87a) 和 (2.88) 式, 全部成立. 与定理 2.6 比较, 1° 相同, 5° 是由于在非自然联系下 u 不是恒等函数而引起的, 3° 与定理 2.6 的 2° 同. 故可以说, 除 5° 外, 定理 2.8 用 2° + 4° 取代了定理 2.6 的“条件(D) 成立”. 易证

$$2^\circ + 4^\circ \Rightarrow (D) ((D^*))$$

因由 4°, 知 $\text{tr}(F_n^{-1/2} T_n F_n^{-1/2}) \leq c$. 因 $F_n^{-1/2} T_n F_n^{-1/2}$ 正定, 由此知 $F_n^{-1/2} T_n F_n^{-1/2} \leq c I_p$, 即 $T_n \leq c F_n$. 再由 2°, 知 $\underline{\lambda}(F_n) \geq c^{-1} \underline{\lambda}(T_n) \rightarrow \infty$.

因此, 这里加的条件 2° + 4°, 比定理 2.6 加的条件强. 其所以要这样, 是因为仅由条件(D) (在此处为(D*), 形式一样, 都为 $\underline{\lambda}(F_n) \rightarrow \infty$, 但此处 F_n 的表达式, 与自然联系下 F_n 的表达式不一样, 故不宜仍写为(D)) 不能推出 $F_n \geq c T_n$ 对某个 $c > 0$, 而没有这个就推不出 (2.113a) 式 (在 $\{z_i\}$ 有界时, 只要定理 2.7 的条件 1° 满足, 则 $F_n \geq c T_n$ 可以不依靠此处的 4° 而证明) 这可由反例: $p = q = 1$, $c(y) = I(0 < y < 1)$, $d_\nu(y) = dy$, $\beta_0 = 1$, $z_i = i$ ($i \geq 1$) 得到证明.

定理 2.8 与定理 2.7 最大的差别在于: 前者所添加的条件 5° 要求 u 的 1, 2 阶偏导数在 G 内不仅存在连续 (这是后者的条件 3° 也要求的), 还须有界. 这一点要求很高, 以致一些应用上常见的模型也不能满足 (例如, y 取 0, 1 两值时的 Probit 模型, 这时 $b(\theta) = \log(1 + e^\theta)$ 定义于 $(-\infty, \infty)$, 其反函数 $\dot{b}(t) = \log(e^t - 1)$ 定义于 $t > 0$, 联系函数 $g = \Phi$, Φ 为 $N(0, 1)$ 的分布函数, 故 $h = g^{-1} = \Phi$, 而 $u(t) = \log(e^{\Phi(t)} - 1)$, 定义于 $t \in \mathbb{R}^1$ 其一阶导数为 $\varphi(t)e^{\Phi(t)}/(e^{\Phi(t)} - 1)$, $\varphi(t) = e^{-t^2/2}/\sqrt{2\pi}$. 可以证明: 当 $t \rightarrow -\infty$ 时, 此导数 $\rightarrow \infty$, 故不能满足 (见后) 有界的条件).

在定理 2.7 中不要求导数有界, 是因为该定理的条件 1°, 把 $u(t)$ 中的变量 t 限制在 G 的一个有界闭集上. $u(t)$ 既然在开集 G 内有连续 1, 2 阶导数, 则 1, 2 阶导数必在含于 G 的任何有界闭集上为有界: 在定理 2.7 证明过程中, 涉及 $u(t)$ 及其导数时, t 都是取 z_i' 的形式, 而这种值都属于集

$$\{z'\beta: z \in y, \beta \in \bar{V}_\epsilon(\beta_0)\};$$

对某 $\epsilon > 0$, 这是一个处于 G 内的有界闭集. 对定理 2.8 而言, 因 $\{z_i, i \geq 1\}$ 可以无界, $z_i'\beta$ 当 $i \rightarrow \infty$ 时, 可以无限地接近 G 的边界. 因此, 不能不要求 u 的有关导数在整个 G 上有界.

因此, 还不能说定理 2.8 已恰当地处理了 y 有界情况下 MLE 的大样本理论. 需要找出一组在应用上看来合理的条件.

定理 2.8 的证明

即要验证条件 (D*)、(2.85) 式和 (N*), 前者已做了 (见前页). 为后者, 要验证 (2.85), (2.107) 和 (2.108) 式.

1° (2.85) 式的验证, 与定理 2.7 相似: 引进

$$\xi_{ni} = \lambda' F_n^{-1/2} z_i U_i' (y_i - \mu_i) \quad (1 \leq i \leq n)$$

有 $\sum_{i=1}^n \xi_{ni} = \lambda' F_n^{-1/2} S_n$, $E(\xi_{ni}) = 0$, $\text{Var}(\xi_{n1}) + \cdots + \text{Var}(\xi_{nn}) = 1$. 另外, $\max_{1 \leq i \leq n} |\delta_{ni}| \rightarrow 0$. 这是因为由假定 5°, $\{|U_i'|\}$ 有界. 又若记 $\alpha_{ni} = F_n^{-1/2} z_i$, 则 $\max_{1 \leq i \leq n} \text{tr}(\alpha_{ni} \alpha_{ni}') = \max_{1 \leq i \leq n} \text{tr}(F_n^{-1/2} z_i z_i' F_n^{-1/2}) = \max_{1 \leq i \leq n} (z_i' F_n^{-1} z_i) \rightarrow 0$ (据条件 3° 用引理 2.9). 由此知 $\max_{1 \leq i \leq n} |\alpha_{ni}| \rightarrow 0$, 即 $\max_{1 \leq i \leq n} |F_n^{-1/2} z_i| \rightarrow 0$ 由以上及 y 的值域有界, 即得 $\max_{1 \leq i \leq n} |\xi_{ni}| \rightarrow 0$, 因此当 n 充分大时, $I(\max_{1 \leq i \leq n} |\xi_{ni}| \geq \epsilon) = 0 \Rightarrow \sum_{i=1}^n E[\xi_{ni}^2 I(|\xi_{ni}| \geq \epsilon)] = 0$. 这样得到 (2.103) 式, 因而 (2.85) 式也成立.

2° (2.107) 式的验证, 与定理 2.7 相同: 由条件 4°, 有

$$\begin{aligned} \sum_{i=1}^n \text{tr}(\alpha_{ni} \alpha_{ni}') &= \sum_{i=1}^n \text{tr}(F_n^{-1/2} z_i z_i' F_n^{-1/2}) = \text{tr}(F_n^{-1/2} \sum_{i=1}^n z_i z_i' F_n^{-1/2}) \\ &= \text{tr}(F_n^{-1/2} F_n^{-1/2} T_n) = \text{tr}(F_n^{-1} T_n), \quad \text{对 } n \text{ 有界} \end{aligned}$$

即 (2.112)、(2.113) 式刚才已证明. (2.114) 式下一行中的 y_{ir} 方差有界, 因为 y_i 本身有界, 不证自明, 其余诸如 $|u_r(z_i'\beta)|$ 有界, $\sup\{|u_r(z_i'\beta) - u_r(z_i'\beta_0)|: \beta \in N_n(\delta)\} \rightarrow 0$, 由假定 5° 及

$$\sup\{|z_i'(\beta - \beta_0)|: i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0$$

推出, 上式在本定理条件下的证明见 (2.59) 式.

3° (2.108) 式的验证.

定理 2.7 中的证法在此也适用, 不同的是引理 2.17 的证明方法在此不适用. 因为该处利用 $\{z_i'\beta: i \geq 1, \beta \in N_n(\delta)\}$ 处在一个有界闭集内, 在其上

$U'(t)\Sigma(t)U(t)$ 对 t 一致连续. 在此, 虽假定了 $U(t)$ 一致连续, 但 $\Sigma(t)$ 不必一致连续, 故不能肯定 $U'(t)\Sigma(t)U(t)$ 对 t 一致连续. 可以用下面的证法:

$$\begin{aligned} & |U'(z_i'\beta)\Sigma(z_i'\beta)U(z_i'\beta) - U'(z_i'\beta_0)\Sigma(z_i'\beta_0)U(z_i'\beta_0)| \\ & \leq |U'(z_i'\beta) - U'(z_i'\beta_0)|\Sigma(z_i'\beta)U(z_i'\beta) \\ & \quad + |U'(z_i'\beta_0)(\Sigma(z_i'\beta) - \Sigma(z_i'\beta_0))U(z_i'\beta)| \\ & \quad + |U'(z_i'\beta_0)\Sigma(z_i'\beta_0)(U(z_i'\beta) - U(z_i'\beta_0))| \equiv J_1 + J_2 + J_3. \end{aligned}$$

因 y 的值域有界, 故 y 的协方差阵有界, $\Sigma(z_i'\beta)$ 有界. 由此及 U 有界并一致连续, 即得 $J_1 \rightarrow 0, J_3 \rightarrow 0$. 若能证明

$$\sup\{|\Sigma(z_i'\beta) - \Sigma(z_i'\beta_0)| : i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0, \quad (2.124)$$

则也有 $J_2 \rightarrow 0$.

为证 (2.124) 式, 注意到例如 $\Sigma(z_i'\beta) - \Sigma(z_i'\beta_0)$ 的 (1,1) 元有形式

$$d \equiv b_{11}(u(z_i'\beta)) - b_{11}(u(z_i'\beta_0)),$$

其中, $\dot{b}_{11}$ 为 b 的 (1,1) 元, 有 (中值公式)

$$d = \frac{\partial \dot{b}_{11}(t)}{\partial t'} \bigg|_{t=u(z_i'\beta)} \frac{\partial u(y)}{\partial y} \bigg|_{y=z_i'\beta} z_i'(\beta - \beta_0).$$

已设 $\dot{u} = U$ 有界, 并已证 $\sup\{|z_i'(\beta - \beta_0)| : i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0$. 故为证

(2.124) 式, 只需证 $\partial \ddot{b}_{11}(t)/\partial t'$ 有界. 按 $\dot{b}_{11}(t)$ 为 $(y = (y_1, \dots, y_q)')$

$$b_{11}(t) = \int y_1^2 \exp(y't - b(t)) c(y) d\nu(y) - (\partial b(t)/\partial t_1)^2,$$

得

$$e^{b(t)} \dot{b}_{11}(t) = \int y_1^2 e^{y't} c(y) d\nu(y) - e^{b(t)} (\partial b(t)/\partial t_1)^2,$$

对 t 的分量 t_j 求导, 得

$$\begin{aligned} & e^{b(t)} \partial \dot{b}_{11}(t)/\partial t_j + e^{b(t)} \partial b(t)/\partial t_j \ddot{b}_{11}(t) \\ & = \int y_1^2 y_j \exp(y't) c(y) d\nu(y) - e^{b(t)} \partial b(t)/\partial t_j (\partial b(t)/\partial t_1)^2 \\ & \quad - e^{b(t)} 2(\partial b(t)/\partial t_1) \partial b(t)/\partial t_1 \partial t_j, \end{aligned}$$

遍乘 $e^{-b(t)}$, 得

$$\begin{aligned} \partial \dot{b}_{11}(t)/\partial t_j & = \int y_1^2 y_j \exp(y't - b(t)) c(y) d\nu(y) - \partial b(t)/\partial t_j b_{11}(t) \\ & \quad - \partial b(t)/\partial t_j (\partial b(t)/\partial t_1)^2 - 2(\partial b(t)/\partial t_1) \partial b(t)/\partial t_1 \partial t_j \end{aligned}$$

$$= E(y_1^2 y_j | t) - E(y_j | t) \text{Var}(y_1 | t) \\ - E(y_j | t)(E(y_1 | t))^2 - 2E(y_j | t) \text{Cov}(y_1 \cdot y_j | t).$$

由于 y 有界, 此式右边各项都有界, 由此证明了 $\partial \ddot{b}_{11}(t)/\partial t_j$ 有界. 这证明了 (2.124) 式, 故 $J_2 \rightarrow 0$. 这完成了定理 2.8 的证明.

例 2.5 设自变量 z 只在一个固定的有限集 $\{W_1, \dots, W_m\}$ 中取值. 假定

$$\sum_{i=1}^m W_i W_i' \equiv W > 0,$$

以 n_j 记 $z_1, \dots, z_n$ 中取值 W_j 的个数. 设存在 $\varepsilon > 0$, 使当 n 充分大时, $n_j/n \geq \varepsilon$ ($j = 1, \dots, m$), 或更一般地, 设

$$n_j \rightarrow \infty \quad (n \rightarrow \infty); \quad (j = 1, \dots, m),$$

则

$$T_n \geq \sum_{i=1}^n z_i z_i' \geq (\min_{1 \leq k \leq m} n_k) \sum_{i=1}^m W_i W_i' \equiv c_n W.$$

因 $c_n \equiv \min_{1 \leq k \leq m} n_k \rightarrow \infty$ ($n \rightarrow \infty$), 而 $W > 0$, 有

$$\lambda(T_n) \geq c_n \lambda(W) \rightarrow \infty,$$

故定理 2.7 的条件 2° 满足. 对条件 1°, 因 $z_1, z_2, \dots$ 只取有限个值, 自然满足. 故当 u 在 G 内有 2 阶连续导数且 $\det(\dot{u}(t)) \neq 0$, 对任何 $t \in G$ 时, 定理 2.7 的一切

条件满足. 此例 $F_n = \sum_{j=1}^m n_j w_j U'(w_j' \beta_0) \Sigma(w_j' \beta_0) U(w_j' \beta_0) w_j'$.

例 2.6 y 取 0, 1 两值, $P(y=1) = \mu, P(y=0) = 1-\mu$, 此例 $\theta = \log \frac{\mu}{1-\mu}$

($0 < \mu < 1$), $\Theta = \Theta^o = (-\infty, \infty), b(\theta) = \log(1+e^\theta), \dot{b}(\theta) = e^\theta/(1+e^\theta)$, 而

$$\dot{b}^{-1}(t) = \log \frac{t}{1-t} \quad (0 < t < 1),$$

$$u(t) = \dot{b}^{-1}(h(t)) = \log \frac{h(t)}{1-h(t)},$$

$h(t)$ 是联系函数的反函数, 即

$$\mu = h(z'\beta)$$

通常取 $h(t)$ 为一分布函数^①; $h(t)$ 随 t 上升而增加, $h(-\infty) = 0, h(\infty) = 1$, h 有直到 2 阶为止的导数. 把 $h(t)$ 改记为 $F(t)$, 并记 $f(t) = dF(t)/dt$, 则

① 也可以 $h(-\infty) \geq 0, h(\infty) \leq 1$. 这时 μ 只能取 $(h(-\infty), h(\infty))$ 内之值.

$$\begin{aligned} du(t)/dt &= \frac{f(t)}{F(t)(1-F(t))}, \\ d^2u(t)/dt^2 &= \frac{f'(t)}{F(t)(1-F(t))} - \frac{f^2(t)}{F^2(t)[1-F(t)]^2} \\ &\quad + \frac{2f^2(t)}{F(t)[1-F(t)]^2} \quad \left(f'(t) = \frac{df(t)}{dt}\right). \end{aligned}$$

故为使定理2.8的条件5°满足,则必须取这样 F ,使上述表达式在 $-\infty < t < \infty$ 有界.一个这样的例子当然是

$$F(t) = \frac{e^t}{1+e^t} \quad (-\infty < t < \infty).$$

这导致 $u(t) = t$,即自然联系.一个较广的情况是

$$F(t) = \frac{b+ce^t}{a+e^t} \quad (a > b \geq 0, 1 > c > 0, -\infty < t < \infty),$$

相应的 $u(t)$ 为

$$u(t) = \log \frac{b+ce^t}{(a-b)+(1-c)e^t} \quad (-\infty < t < \infty),$$

联系函数 g (即 F^{-1})为

$$g(\mu) = \log \frac{a\mu - b}{c - \mu},$$

其定义域必须使 $a\mu - b$ 和 $c - \mu$ 同号,即为

$$\begin{aligned} b/a < \mu < c, \quad b < ac; \\ c < \mu < b/a, \quad b > ac. \end{aligned}$$

(b 不能为 ac ,因若 $b = ac$,则 $F(t) = \frac{ac+ce^t}{a+e^t} \equiv c$,无意义.)这表明:所取的模型限制了 $P(y=1)$ 这概率不能遍取 $(0,1)$ 内一切值,除非 $b=0, c=1$.这回到自然联系情况.

极小值模型

$$F(t) = 1 - \exp(-e^t) \quad (-\infty < t < \infty)$$

不满足条件.因 $f(t) = \exp(-e^t)e^t$,有

$$du(t)/dt = e^t/(1 - \exp(-e^t)) \text{ 在 } (-\infty, \infty) \text{ 不为有界.}$$

另一个重要例子是 Probit 模型

$$F(t) = \Phi(t), \quad \Phi: N(0,1) \text{ 的分布函数.}$$

则 $f(t) = \varphi(t) = e^{-t^2/2} / \sqrt{2\pi}$,而

$$du(t)/dt = \frac{1}{\sqrt{2\pi}} e^{-t^2/2} / [\Phi(t)(1 - \Phi(t))].$$

由

$$1 - \Phi(t) = \frac{1}{\sqrt{2\pi}} \int_t^\infty e^{-x^2/2} dx \leq \frac{1}{\sqrt{2\pi}} \int_t^\infty \frac{x}{t} e^{-x^2/2} dx = \frac{1}{t} \cdot \frac{1}{\sqrt{2\pi}} e^{-t^2/2},$$

得

$$du(t)/dt \geq t/\Phi(t) \rightarrow \infty \quad (t \rightarrow \infty),$$

故 $du(t)/dt$ 不为有界, 定理 2.8 的条件不满足.

由这些例子看出, 定理 2.8 还不能说已妥善解决了 y 的值域有界时, $\hat{\beta}_n$ 大样本理论的基本问题^①. 与定理 2.5 的条件比较, 定理 2.5 假定了

$$\lambda(T_n) \rightarrow \infty, \quad T_n = \sum_{i=1}^n z_i z_i' \quad (\text{A})$$

这条件结合 $\{z_i\}$ 有界^② 保证了条件(D) 成立. 条件(A) 形式上比定理 2.6 的条件 1° 简单, 因为条件(A) 只涉及 $\{z_i\}$, 而定理 2.6 的条件 1° 涉及 $\Sigma(z_i' \beta_0)$ 因而与未知数有关.

但在不假定 $\{z_i\}$ 有界时, 即使有“ y 有界”的条件, 由条件(A) 也推不出(D), 可举出反例. 故必须把“(D) 成立”列为一个条件.

至于条件 2°, 是为了保证当 $n \rightarrow \infty$ 时

$$\sup\{\|z_i'(\beta - \beta_0)\| : i \geq 1, \beta \in N_n(\delta)\} \rightarrow 0.$$

这一条件在 $\{z_i\}$ 有界时, 由条件(D) 推出, 而(D) 由(A) (加上 $\{z_i\}$ 有界) 推出. 故在定理 2.5 中不需列为一个条件.

关于似然方程 $S_n(\beta) = 0$ 根的存在, 相结合性与渐近正态性, 其证明的思想如下:

β 为 p 维, 在 $\mathbb{R}^p$ 中作一个以真值 β_0 为中心椭圆 $A \subset B^\circ$, 如图 2.6. 以 $l_n(\beta)$ 记对数似然函数, $S_n(\beta) = \partial \ln(\beta) / \partial \beta$. 设法证明:

$$\sup\{l_n(\beta) : \beta \in \partial A\} < l_n(\beta_0).$$

① 若取

$$F(t) = a + bG(t) \quad (a > 0, b > 0, a + b < 1).$$

其中, G 为分布函数, $g_1 = G'$ 及 $g_2 = G''$ 在 $(-\infty, \infty)$ 有界, 则定理 2.8 的条件 5° 满足, 因

$$0 < a \leq F(t) \leq a + b < 1.$$

但这时 $\mu = P(Y = 1) = F(Z'\beta)$ 只能取 $[a, a + b]$ 上的值, 而不能取 $[0, 1)$ 内的一切值.

② 更确切地说是 $Z'\beta \in \Theta^\circ$, 当 $z \in A, \beta \in B^\circ$




图 2.6

由此式知, $l_n(\beta)$ 在 $\beta \in A$ 上的(局部)极大值不能在边界 ∂A 上达到, 而必在 A 内部某点 $\hat{\beta}_n$ 处达到. 因此在 $\hat{\beta}_n$ 点处, l_n 对 β 的偏导数为 0:

$$S_n(\hat{\beta}_n) = \partial l_n(\beta) / \partial \beta |_{\hat{\beta}_n} = 0,$$

即 $\hat{\beta}_n$ 为似然方程的一根. 这证明了似然解的存在性, 据前述, 在似然联系下, 似然解唯一且就是 MLE.

适当取 A , 使它随样本量 n 增加而缩小

至 β_0 一点, 则将得 $\hat{\beta}_n \rightarrow \beta_0 (n \rightarrow \infty)$. 这证明了 $\hat{\beta}_n$ 为 β_0 的相合估计.

为证 $\hat{\beta}_n$ 渐近正态, 注意 $S_n(\hat{\beta}_n) = 0$, 故

$$\begin{aligned} S_n(\beta_0) &= S_n(\beta_0) - S_n(\hat{\beta}_n) \quad (\text{用积分公式}) \\ &= \left[\int_0^1 -\dot{S}_n(\beta_0 + (\hat{\beta}_n - \beta_0)u) du \right] (\hat{\beta}_n - \beta_0) \\ &\equiv B_n(\hat{\beta}_n - \beta_0) \Rightarrow (\hat{\beta}_n - \beta_0) = B_n^{-1} \cdot S_n(\beta_0). \end{aligned}$$

因已证 $\hat{\beta}_n$ 相合而 $0 \leq u \leq 1$, 知

$$\beta_0 + (\hat{\beta}_n - \beta_0)u \approx \beta_0,$$

故

$$-\dot{S}_n(\beta_0 + (\hat{\beta}_n - \beta_0)u) \approx -\dot{S}_n(\beta_0).$$

而在自然联系下

$$-\dot{S}(\beta_0) = \sum_{i=1}^n z_i \Sigma_i z_i' \begin{pmatrix} z_i = z(x_i) \\ \Sigma_i = \Sigma(z_i, \beta_0) \end{pmatrix}$$

为非随机方阵, 故

$$\hat{\beta}_n - \beta_0 \approx \left(\sum_{i=1}^n z_i \Sigma_i z_i' \right)^{-1} S_n(\beta_0),$$

而

$$S_n(\beta_0) = \sum_{i=1}^n z_i (y_i - \mu(z_i' \beta_0)), \quad (2.125)$$

其中, $y_i - \mu(z_i' \beta_0)$ ($i = 1, 2, \dots$), 独立具有均值 0, 按中心极限定理, 在一定的条件下, 其线性组合, 即(2.125)式的右边, 有渐近正态性. 这就证明了 $\hat{\beta}_n - \beta_0$ 的渐近正态性.

似然方程迭代求解.

要解 $S_n(\beta) = 0$, 即 $\sum_{i=1}^n z_i H(z_i' \beta) \Sigma^{-1}(z_i' \beta) (y_i - \mu(z_i' \beta)) \Sigma(z_i' \beta)$, 即

$$\text{Cov}(y_i) = b(u(z_i' \beta)) = 0 \quad (\mu(t) = h(t), H(t) = \dot{h}(t)).$$

设在迭代的某一阶段得到当时的 β 值 β , 而新值为 $\beta_{..}$. 记 $\Delta = \beta_{..} - \beta$, 则

$$0 \approx S_n(\beta_{..}) = S_n(\beta + \Delta) \approx S_n(\beta) + \dot{S}_n(\beta) \Delta.$$

$\dot{S}_n(\beta_{..})$ 的表达式很复杂. 为简化计算, 用其均值 $E(\dot{S}_n(\beta_{..}))$ 取代. 注意到 S_n 的形状, 我们看出, 在求导得出的一些成分中, 有一大部分是 $A_i(y_i - \mu(z_i' \beta))$ 的形状, A_i 为与 y_i 无关的矩阵, 此种项的期望近似为 0 (因 $E(y_i) = \mu(z_i' \beta_0)$), 而真参数值 β_0 与 β 的当前值 β 有些差距, 故

$$E[y_i - \mu(z_i' \beta_{..})] = \mu(z_i' \beta_0) - \mu(z_i' \beta_{..}) \approx 0,$$

即只是近似为 0 而非严格为 0.) 这样一来, (近似地) $E(\dot{S}_n(\beta_{..}))$ 只剩下一项

$$\begin{aligned} & \sum_{i=1}^n z_i H'(z_i' \beta_{..}) \Sigma^{-1}(z_i' \beta_{..}) \frac{\partial(y_i - \mu(z_i' \beta_{..}))}{\partial \beta'} \Big|_{\beta=\beta_{..}} \\ &= - \sum_{i=1}^n z_i H'(z_i' \beta_{..}) \Sigma^{-1}(z_i' \beta_{..}) H(z_i' \beta_{..}) z_i' \equiv -\Lambda. \end{aligned}$$

这样, 近似地有 $0 \approx S_n(\beta_{..}) - \Lambda \Delta$, 而 $\Delta \approx \Lambda^{-1} S_n(\beta)$. 因此得到 β 的新值 $\beta_{..} = \beta + \Delta$:

$$\beta_{..} = \beta + \Lambda^{-1} S_n(\beta). \quad (\text{a})$$

下面是一个很有用的变换: 令

$$y_i^* = z_i' \beta - H^{-1}(z_i' \beta) (y_i - \mu(z_i' \beta)) \quad (i = 1, \dots, n),$$

$$\Omega_i = H'(z_i' \beta) \Sigma^{-1}(z_i' \beta) H(z_i' \beta) \quad (i = 1, \dots, n),$$

则可将 $\beta_{..}$ 写为

$$\beta_{..} = \left(\sum_{i=1}^n z_i \Omega_i z_i' \right)^{-1} \sum_{i=1}^n z_i \Omega_i y_i^*. \quad (\text{b})$$

此因 $z_i \Omega_i y_i^* = z_i \Omega_i z_i' \beta + z_i H'(z_i' \beta) \Sigma^{-1}(z_i' \beta) (y_i - \mu(z_i' \beta))$, 代入(b)式, 并注意到

$$\sum_{i=1}^n z_i H'(z_i' \beta) \Sigma^{-1}(z_i' \beta) (y_i - \mu(z_i' \beta)) = S_n(\beta),$$

即知(a)和(b)一致.

(b)式右边正好是下述加权最小二乘问题

$$\min_{\beta} \sum_{i=1}^n (y_i^* - z_i' \beta)' \Omega_i (y_i^* - z_i' \beta) \quad (c)$$

的解(Ω_i 为权矩阵).这使我们把广义线性回归求解的问题转化为通常线性回归的加权二乘求解问题:设有当前值 β .

1. 利用 β 值,算 $H(z_i' \beta) = \mu(z_i' \beta) \Sigma^{-1}(z_i' \beta)$,因而算出 $y_i^*, \Omega_i (i = 1, \dots, n)$.

2. 调用解问题(c)的程序,得新值 $\beta \dots$

在自然联系情况下, $h = b'$,故 $\dot{h} \equiv H = b$ 且 $z_i' \beta = \theta_i$ (严格讲,是 $z_i' \beta_0 = \theta_i$,近似地 $\beta \approx \beta_0$,故 $z_i' \beta \approx z_i' \beta_0 = \theta_i$).所以

$H(z_i' \beta) = b(z_i' \beta) \approx \dot{b}(z_i' \beta_0) = \dot{b}(\theta_i) = \text{Cov}(y_i) = \Sigma(z_i' \beta_0) \approx \Sigma(z_i' \beta)$,
所以

$$\begin{aligned} \Omega_i &= H_i'(z_i' \beta) \Sigma^{-1}(z_i' \beta) H(z_i' \beta) \\ &\approx \Sigma(z_i' \beta) \Sigma^{-1}(z_i' \beta) \Sigma(z_i' \beta) \Sigma(z_i' \beta) \\ &= \Sigma(z_i' \beta) = b(z_i' \beta). \end{aligned}$$

而(a)式中的 $\Lambda = \sum_{i=1}^n z_i b(z_i' \beta) z_i'$.

这程序的收敛性没有得到证明.据称实际使用时一般能在几次以内达到极限,这很取决于初始值的取法.

2.4 拟似然估计

2.4.1 引言

以上两节是在 Y 服从指数分布的假定下去讨论的.在实际问题中,有时这种假定不现实,但在一定的条件下,仍可以模仿极大似然法以求得参数的一种估计,即所谓“拟似然估计”(Quasi MLE, QMLE),“拟”,即模仿的意思.其实,在某些重要的统计问题中,我们早已这样做了.

例如正态线性回归 $y_i = x_i' \beta_0 + e_i (1 \leq i \leq n)$, $e_1, \dots, e_n$ 为 iid. $N(0, \sigma^2)$, 则 $(Y_1, \dots, Y_n)$ 的似然函数为

$$(\sqrt{2\pi}\sigma)^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - x_i' \beta_0)^2\right).$$

所以, β_0 的 MLE, 就是使 $\sum_{i=1}^n (Y_i - x_i' \beta_0)^2$ 达到最小的 β 值, 即最小二乘 (LS) 估计, 但 LS 估计并不只用在误差为正态时, 且一般讲, 即使误差不为正态, LS 估计也可以有比较好的性质. 这样, 当误差分布不为正态时, LS 估计为 QMLE. 从这个例子我们也领悟到, QMLE 也可以有比较好的表现.

前面提到过的所谓“超散布性”(over-dispersion) 是 Y 不服从指数型分布的一个例子: $Y = Y^{(1)} + \dots + Y^{(m)}$, $Y^{(j)}$ 都是取值 0, 1 的变量, $P(Y^{(j)} = 1) = p$ 与 j 无关, 若 $Y^{(1)}, \dots, Y^{(m)}$ 独立, 则 Y 服从二项分布 $B(m, p)$, 它属于指数型分布, 方差为 $mp(1-p)$, 但在有些情况下 $Y^{(1)}, \dots, Y^{(m)}$ 之间存在某种相依 (如 $Y^{(1)}, \dots, Y^{(m)}$ 是同一家庭内各个体同一指标之值, 而个体之间存在正相关) 而使方差大于 $mp(1-p)$. 最简单的假定是存在因子 $\phi > 0$, 使

$$\text{Var}(Y) = \phi \cdot mp(1-p) = \phi \cdot E(Y)(1 - E(Y)/m). \quad (2.126)$$

不难证明: 不存在指数型分布

$$P_\theta(Y = k) = C(\theta)d(k)e^{k\theta}, \quad (k = 0, 1, \dots, m, \theta \in \text{开集 } \Theta),$$

其中, $d(k) > 0 (k = 0, 1, \dots, m)$, 其均值方差符合关系 (2.126) 式. 事实上, 有

$$\begin{aligned} E_\theta(Y) &= C(\theta) \sum_{i=1}^m id(i)e^{i\theta} \\ \text{Var}_\theta(Y) &= C(\theta) \left(\sum_{i=1}^m i^2 d(i)e^{i\theta} - C^2(\theta) \sum_{i=1}^m id(i)e^{i\theta} \right)^2, \end{aligned}$$

其中, $C(\theta) = \left(\sum_{i=0}^m d(i)e^{i\theta} \right)^{-1}$. 若 (2.126) 式成立, 则有

$$\begin{aligned} & \sum_{i=0}^m d(i)e^{i\theta} \sum_{i=1}^m i^2 d(i)e^{i\theta} - \left(\sum_{i=1}^m id(i)e^{i\theta} \right)^2 \\ &= \phi \left\{ \left(\sum_{i=0}^m d(i)e^{i\theta} \sum_{i=1}^m id(i)e^{i\theta} \right) - \left(\sum_{i=1}^m id(i)e^{i\theta} \right)^2 / m \right\}. \end{aligned}$$

比较上式两边 $e^{i\theta}$ 的系数 (因上式对 θ 属于一开集成立, 两边 $e^{i\theta}$ 的系数必相同), 有 $d(0)d(1) = \phi d(0)d(1)$. 因 $d(0) \neq 0 \neq d(1)$, 得 $\phi = 1$. 这证明了所要的结果.

注 2.7 在没有 $d(i) > 0$ ($i = 0, 1, \dots, m$) 的限制时, 满足(2.126)式(其中, $\phi > 0$)的指数型分布可能存在. 一个简单的例子如下:

$$P(Y = 0) = 1 - p, \quad P(Y = 1) = 0, \quad P(Y = 2) = p.$$

此处 $m = 2$, $E(Y) = 2p$, $\text{Var}(Y) = 4p(1 - p)$, 有

$$\text{Var}(Y) = 2 \cdot E(Y)[1 - E(Y)/2],$$

相当于(2.126)式 $\phi = 2$ 的情况. 一般地, 令

$$P(Y = 0) = 1 - p,$$

$$P(Y = 1) = \dots = P(Y = m - 1) = 0, \quad P(Y = m) = p,$$

得到(2.126)式对一般 $m, \phi = m$ 的情况.

又如对 Poisson 分布, 应有 $\text{Var}(Y) = E(Y)$. 在实际问题中, 有时这一点与实际不合, 这时分布就不是指数型.

在 GLM 中用拟似然法是基于以下的事实: 似然方程(2.16)只涉及 Y 的期望与协方差. 这是因为由 $u(t) = b^{-1}(h(t))$, 按复合求导的规则、公式(2.7)及在指数分布 $C(\theta)e^{\theta'y - b(\theta)}d\mu$ 中 $\text{Cov}(Y) = b(\theta)$ 和 $E(Y_i) = \mu_i = b(\theta_i)$ 的事实, 有

$$U(z_i, \beta)$$

$$= \left. \frac{\partial u(t)}{\partial t'} \right|_{t=z_i, \beta} = \{b[b^{-1}(h(z_i, \beta))]\}^{-1} H(z_i, \beta) \quad \left(H(t) = \frac{\partial h(t)}{\partial t'} \right)$$

$$= \{b(b^{-1}(\mu_i))\}^{-1} H(z_i, \beta) = (b(\theta_i))^{-1} H(z_i, \beta) = \text{Cov}_\beta^{-1}(Y_i) H(z_i, \beta) \\ \equiv \Sigma^{-1}(z_i, \beta) H(z_i, \beta)$$

$$(\Sigma^{-1}(z_i, \beta) = b^{-1}(h(z_i, \beta))).$$

故在不知 Y 的分布但对其均值和协方差阵有正确设定时, 我们仍可构成方程(2.16), 即

$$\sum_{i=1}^n z_i H'(z_i, \beta) \Sigma^{-1}(z_i, \beta) (Y_i - h(z_i, \beta)) = 0. \quad (2.127)$$

(2.127)式就称为拟似然方程, 其根 $\hat{\beta}_n$ 作为参数真值 β_0 的估计, 称为 β_0 的 QMLE.

然而, 在实际问题中要正确设定协方差不易做到. 拟似然法有力之处在于,

对协方差的设定可以不要求正确^①——我们可以根据所了解的程度对 Y_i 的协方差作一设定 $\Lambda_i(z_i'\beta)$, 而将方程(2.127) 改为

$$\sum_{i=1}^n z_i H'(z_i'\beta) \Lambda_i^{-1}(z_i'\beta) (Y_i - h(z_i'\beta)) = 0, \quad (2.128)$$

它仍称为拟似然方程, 其根为 QMLE. 但对期望 $h(z_i'\beta)$ 的设定则要求正确, 若这一点作不到, 建模就无法进行.

作了以上的引言后, 下面转到方程(2.128) 的求解, 以及解的大样本性质问题.

2.4.2 方法——拟似然函数法(Wedderburn, 1974)

此方法的思想是: 设法造一个函数 Q , 与样本及参数 β 有关, 使 $\partial Q / \partial \beta$ 恰好是方程(2.128) 的左边. 然后, 设法证明 β 在真值 β_0 的某个很小的邻域 N_n (N_n 随样本量 $n \rightarrow \infty$ 而收缩到 β_0) 内有一局部极值点 $\hat{\beta}_n$, 则 $\hat{\beta}_n$ 为(2.128) 式的根且有相合性. 在已证相合性的基础上再想法证明其渐近正态性.

在 Y 为 1 维时, 这种函数 Q 存在:

$$Q(\beta) = \sum_{i=1}^n W_i(h(z_i'\beta), Y_i), \quad W(t_1, t_2) = \int_{t_2}^{t_1} \frac{t_2 - t}{\Lambda_i(t)} dt.$$

简单推导表明: $\partial Q(\beta) / \partial \beta =$ (2.128) 式左边. 为证 Q 在 β_0 很小的邻域内有局部极值点, 有一个必不可少的条件, 即 $\partial^2 Q(\beta) / \partial \beta \partial \beta' \big|_{\beta=\beta_0}$ (注意它是随机的), 当 $n \rightarrow \infty$ 时, 以任意接近 1 的概率为正(负)定, 因为

$$\begin{aligned} Q(\beta) - Q(\beta_0) &= \dot{Q}(\beta_0)(\beta - \beta_0) + (\beta - \beta_0)' \int_0^1 Q(\beta_0 + (\beta - \beta_0)u) du \cdot (\beta - \beta_0), \quad (2.129) \end{aligned}$$

当 β 接近 β_0 时, $Q(\beta_0 + (\beta - \beta_0)u) \approx Q(\beta_0)$. Q 在 β_0 附近有一局部极大或极小点, (2.129) 式右边第 2 项必须控制其第 1 项, 而这必须 $Q(\beta_0) > 0$ 或 < 0 , 不然, 就不能借助 Q 的极值点去证明方程有根, 而这个方法就不可行.

至于 Y 为多维的情况, 连满足 $\partial Q(\beta) / \partial \beta =$ (2.129) 式左边的 Q 的存在, 往往都成问题. 因这必须(2.128) 式作为 β 的函数为全微分才行.

为克服这一困难, Fahrmeir 在 1990 年一篇文章 (MLE in Misspecified

^① 这在前面的例子中可以看到, 在该例中不要求方差已知.

GLM, Statistics, 1990:487 ~ 502) 中提供了一种作法,其要旨是回归到指数型分布,然后再用前两节的方法处理.由于此处样本 Y_i 并非果真服从指数分布,有关的条件也就要复杂些.

设对样本 Y_i 的期望有了确切的规定: $E_{\beta}(Y_i) = h(z_i'\beta)$. 选个指数型分布 $C(\theta)\exp(\theta'y - b(\theta))d\mu$, 若赋予联系函数 $g = h^{-1}$ (不用挂心 h^{-1} 的存在与否, 实际只用到 h), 则按此指数分布和联系函数所决定的样本 Y_i 的期望, 与我们的规定 $h(z_i'\beta)$ 同. 但这样也就规定了其“working covariance matrix”为 $\ddot{b}(\dot{b}^{-1}(h(z_i'\beta)))$, 而不能再由我们随意指定了. 这是本法的一个局限性. 因为在有些情况下, 我们对样本的协方差有些了解, 因而本可提供一个较好的选择 (即选择(2.128)式中的 Λ 使之尽量接近(2.127)式中的 Σ . 以后将指明, 这将有利于缩小 QMLE 的渐近协方差阵), 但由于挑选指数型分布为“working distribution”, 把这个可能性丧失了——总之, 这使我们必须挑选(2.128)式中的 Λ_i 为

$$\Lambda(z_i'\beta) = b(\dot{b}^{-1}(h(z_i'\beta))) \quad (\Lambda_i(\cdot) = \dot{b}(\dot{b}^{-1}(h(\cdot))), \text{与 } i \text{ 无关})$$

分两种情况来讨论:

I. 在所选的“working distribution” $C(\theta)\exp(\theta'y - b(\theta))d\mu$ 之下为自然联系, 即 $h = \dot{b}'$, 这时方程(2.128)简化为

$$\sum_{i=1}^n z_i(Y_i - h(z_i'\beta)) = 0. \quad (2.130)$$

然后按 2.1 节的方法来进行.

1. 弱相合性

$S_n(\beta)$ 的协方差阵, 在 Y_i 为其真实分布时, 为 $V_n(\beta) = \sum_{i=1}^n z_i \Sigma \cdot (z_i'\beta) z_i'$ ($V_n = V_n(\beta_0)$, $\Sigma_i = \Sigma(z_i'\beta_0)$), 在 Y_i 为其工作分布时是 $F_n(\beta)$ 记

$$\Sigma_i = \text{Cov}_{\beta_0}(Y_i) \quad (\text{真确协差阵}), \quad (2.131)$$

$$V_n = \sum_{i=1}^n z_i \Sigma_i z_i' \quad (V_n \text{ 通过真确协差阵定义}), \quad (2.132)$$

$$\Lambda_i(\beta) = \dot{b}(z_i'\beta) \quad (\text{工作协差阵, 即工作分布的协方差阵}), \quad (2.133)$$

$$F_n(\beta) = \sum_{i=1}^n z_i \Lambda_i(\beta) z_i' \quad (F_n \text{ 通过工作协差阵定义}); \quad (2.134)$$

(D')

$$\underline{\lambda}(V_n) \rightarrow \infty; \quad (2.135)$$

(C') 存在 $c > 0$, 对任给 $\delta > 0$ 存在 $n_1(\delta)$, 使当 $n \geq n_1(\delta)$ 时, 有 $F_n(\beta) \geq cV_n$, 对一切 $\beta \in N_n^*(\delta) = \{\beta: \|V_n^{1/2}(\beta - \beta_0)\| \leq \delta\}$.

定理 2.9 若条件(D'), (C') 成立, 则存在一串估计量 $\hat{\beta}_n$, 满足

$$P \mid \hat{\beta}_n \text{ 为 (2.128 式的根)} \rightarrow 1 \quad (n \rightarrow \infty),$$

$$\hat{\beta}_n \rightarrow \beta_0 \quad \text{in pr. .}$$

证明与定理 2.2 的证明完全类似.

条件(D') 要求 Y_i 的协方差阵要比较大, 但从直观上说, Y_i 协方差阵小时, 不必妨碍甚至有助于 $\hat{\beta}_n$ 为 WC. 为对付这一情况, 引进以下的定理. 记 $F_n = F_n(\beta_0)$, 以及

(D̃)

$$\underline{\lambda}(F_n) \rightarrow \infty$$

(C̃) 存在 $c > 0$: 对任给 $\delta > 0$ 存在 $n_1(\delta)$, 使当 $n \geq n_1(\delta)$ 时, 有

$$F_n(\beta) \geq cF_n, \quad \beta \in \tilde{N}_n(\delta) = \{\beta: \|F_n^{1/2}(\beta - \beta_0)\| \leq \delta\}.$$

定理 2.10 若条件(D̃), (C̃) 成立, 且存在常数 $d > 0$, 使

$$\Sigma_i \leq d\Lambda_i \quad (i \geq 1), \quad (2.136)$$

则定理 2.9 的结论成立.

证明与定理 2.2 类似, 只是要取 $\beta \in \tilde{N}_n(\delta)$ 去讨论 (定理 2.9 取 $\beta \in N_n^*(\delta)$). 又注意

$$E(\|F_n^{-1/2}S_n\|^2) \leq \text{tr}(F_n^{-1}V_n)$$

由(2.131)、(2.132) 及(2.136) 式, 有 $V_n \leq dF_n$. 故由上式有

$$E(\|F_n^{-1/2}S_n\|^2) \leq d\text{tr}(F_n^{-1}F_n) = dp.$$

其余一切与定理 2.2 的证明同. 又(2.136) 式可以用 $V_n \leq dF_n$ 取代 ($d > 0$).

2. 强相合性

(S_δ') 存在 β_0 之邻域 N , 常数 $c > 0, \delta > 0$, 自然数 n_1 , 使

$$\underline{\lambda}(F_n(\beta)) \geq c(\bar{\lambda}(V_n))^{1/2+\delta} \quad (\beta \in N, n \geq n_1)$$

定理 2.11 若条件(D') 与(S_δ') 满足 (对某个 $\delta > 0$), 则存在一串估计量

$\hat{\beta}_n$, 使

$P(\hat{\beta}_n \text{ 为 (2.93) 的根当 } n \text{ 充分大}) = 1, \hat{\beta}_n \rightarrow \beta_0, \text{ a. s.}$

3. 中心极限定理

情况与定理 2.4 有些差别. 首先, 引进

$$(\tilde{N}) \sup\{|F_n^{-1/2} F_n(\beta) F_n^{-1/2} - I|; \beta \in \tilde{N}_n(\delta)\} \rightarrow 0 (n \rightarrow \infty).$$

检查导致 (2.50) 式的推理, 知在此处的情况下仍成立 (这里当然要补上条件 $(\tilde{D})$, 在 $(\tilde{N})$ 成立时 $(\tilde{C})$ 成立. 由 $(\tilde{D})$ 、 $(\tilde{C})$ 成立知 QMLE $\hat{\beta}_n$ 为 WC, 且以接近 1 的概率 $\hat{\beta}_n \in \tilde{N}_n(\delta)$. 这对推出 (2.50) 式是必须的. 下一步, 假定 (2.136) 式成立, 则

$$\text{Cov}(F_n^{-1/2} S_n) = F_n^{-1/2} V_n F_n^{-1/2} \leq d F_n^{-1/2} F_n F_n^{-1/2} = dI, \quad (2.137)$$

于是 $F_n^{-1/2} S_n = O_p(1)$, 而由 (2.50) 式有

$$F_n^{1/2}(\hat{\beta}_n - \beta_0) = F_n^{-1/2} S_n + o_p(1). \quad (2.138)$$

再假定存在常数 $d_1 > 0$, 使

$$\Sigma_i \geq d_1 \Lambda_i \quad (i \geq 1), \quad (2.139)$$

则有 $F_n^{-1/2} V_n F_n^{-1/2} \geq d_1 I$, 而 $(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} \leq d_1^{-1/2} I$. 由此及 (2.138) 式, 有

$$\begin{aligned} & (F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{1/2}(\hat{\beta}_n - \beta_0) \\ &= (F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{1/2} S_n + o_p(1). \end{aligned} \quad (2.140)$$

右边第一项有协方差阵 I , 且为独立和, 在一定条件下有

$$(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{1/2} S_n \xrightarrow{d} N(0, I), \text{ 即 } (F_n^{1/2} V_n F_n^{-1/2})^{-1/2} S_n \xrightarrow{d} N(0, I). \quad (2.141)$$

由 (2.140) 式, 知 (2.140) 式左边有同一极限分布.

总结以上, 得

定理 2.12 设条件 $(\tilde{D})$ 、 $(\tilde{N})$, (2.136) 式和 (2.139) 式成立, 又 (2.140) 式成立, 则

$$(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{1/2}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I). \quad (2.142)$$

注 2.8 条件 (2.136) 和 (2.139) 式可用以下条件取代:

$$d_1 F_n' \leq V_n \leq d_2 F_n', \quad 0 < d_1 \leq d_2 < \infty \quad (n \text{ 充分大}). \quad (2.143)$$

注 2.9 在定理 2.4 中, 相当于 (2.141) 式的是 (2.46) 式, 在该处可以证明而不需作为假定. 在此不然: 一则 Y_i 此处已不必为指数型分布, 再则此处还多了

一个方阵 $(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2}$, 它是由 Y_i 的真实协差阵 Σ_i 与其“工作协差阵” Δ_i 可以不一致而来.

与 2.1.3 节相似, 在若干特例下, 定理 2.12 的条件能满足.

首先是 $\{z_i\}$ 有界的情况, 有:

定理 2.13 设定理 2.5 的条件 $1^\circ \sim 3^\circ$ 满足.

a. 若存在常数 $d > 0$, 使 $V_n \leq d F_n$, n 充分大, 则存在一串估计量 $\hat{\beta}_n$, 使定理 2.9 的结论成立.

b. 若存在常数 $c > 0, \delta > 0$, 使当 n 充分大时, 有

$$\underline{\lambda}(T_n)/(\bar{\lambda}(T_n))^{1/2+\delta} \geq c,$$

则存在一串估计量 $\hat{\beta}_n$, 使定理 2.11 的结论成立.

c. 若条件 (2.143) 式满足, 且 $\{\|Y_i\|^2, i \geq 1\}$ 一致可积 (即 $\sup_{i \geq 1} E(\|Y_i\|^2 \cdot I(\|Y_i\| \geq a)) \rightarrow 0, a \rightarrow \infty$), 则 (2.142) 式成立.

证 a 和 b 的证明, 以及 c 中关于条件 $(\tilde{N})$ 的证明, 与定理 2.5 一样. 剩下要验证 (2.140) 式, 即对任何单位向量 λ , 去验证

$$\lambda'(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{-1/2} s_n \equiv a_n' e_i \equiv \sum_{i=1}^n \xi_{ni}$$

满足 Lindeberg 条件, 此处 $a_n' = \lambda'(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{-1/2} z_i, e_i = Y_i - h(z_i, \beta_0)$.

$\xi_{ni} (1 \leq i \leq n)$ 独立, 有期望 0, 且 $\sum_{i=1}^n \text{Var}(\xi_{ni}) = 1$, 故只需验证: 对任给 $\varepsilon > 0$, 有

$$\sum_{i=1}^n E(\xi_{ni}^2 I(|\xi_{ni}| \geq \varepsilon)) \rightarrow 0 \quad (n \rightarrow \infty) \quad (2.144)$$

$$\sum_{i=1}^n \|a_n\|^2 = \lambda'(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{-1/2} \sum_{i=1}^n z_i z_i' F_n^{-1/2} (F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} \lambda \quad (2.145)$$

由定理的假定, 知存在 $c_1 > 0, c_2 > 0$, 使 $c_2 \sum_{i=1}^n z_i z_i' \geq F_n \geq c_1 \sum_{i=1}^n z_i z_i'$, 再由

(2.143) 式, 知 $V_n \geq d_1 c_1 \sum_{i=1}^n z_i z_i'$. 由此及 (2.145) 式知

$$\sum_{i=1}^n \|a_n\|^2 \leq (d_1 c_1)^{-1} \lambda'(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} (F_n^{-1/2} V_n F_n^{-1/2}) (F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} \lambda'$$

$$= (d_1 c_1)^{-1}. \quad (2.146)$$

由定理 2.5 的条件 3° 及 $F_n \geq c_1 \sum_1^n z_i z_i'$, 知 $\lambda(F_n) \rightarrow \infty$, 故 $F_n^{-1/2} \rightarrow 0$. 再由 $\{z_i\}$ 有界, 以及 $(F_n^{-1/2} V_n F_n^{-1/2}) \geq d_1 I \Rightarrow (F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} \leq d_1^{-1/2} I$, 知 $\max_{1 \leq i \leq n} \|a_{ni}\| \rightarrow 0$. 于是

$$\sum_{i=1}^n E\left(\xi_{ni}^2 I(|\xi_{ni}| \geq \epsilon)\right) \leq \sum_{i=1}^n \|a_{ni}\|^2 E(\|e_i\|^2 I(\|e_i\| \geq \frac{\epsilon}{\|a_{ni}\|})). \quad (2.147)$$

由 $\{\|Y_i\|^2, i \geq 1\}$ 一致可积, $\max_{1 \leq i \leq n} \|a_{ni}\| \rightarrow 0$, 知

$$\max_{1 \leq i \leq n} E\left(\|e_i\|^2 I\left(\|e_i\| \geq \frac{\epsilon}{\|a_{ni}\|}\right)\right) \rightarrow 0.$$

此式与 (2.146) 式结合, 由 (2.147) 式即得 (2.144) 式.

这后一部分的证明只用了条件 (2.143) 式的左半, 其右半是用在 $\hat{\beta}_n$ 为 WC, 而这在导出 (2.138) 式是需要的.

定理 2.14 设对 $E_\theta(Y_i)$ 有确切设定 $b(z_i'\beta)$, 而在指数型分布 $C(\theta)\exp(\theta'y - b(\theta))d\mu(y)$ 中, μ 的支撑有界, 又条件 $(\tilde{D})$ 成立.

a. 若存在常数 $d > 0$ 使 $V_n \leq dF_n$ 当 n 充分大, 且 $\text{tr}(z_n'F_n^{-1}z_n) \rightarrow 0$ 时, 则有 $\hat{\beta}_n$ 使定理 2.9 的结论成立.

b. 若条件 (2.143) 式满足, $\{\|Y_i\|^2, i \geq 1\}$ 一致可积, 条件 $(\tilde{D})$ 成立且 $\text{tr}(z_n'F_n^{-1}z_n) \rightarrow 0$,

$$(2.148)$$

$$\text{tr}(F_n^{-1}T_n) \leq c < \infty, \quad n \text{ 充分大}, c \text{ 为常数}, (T_n = \sum_{i=1}^n z_i z_i'), \quad (2.149)$$

则 (2.142) 式成立.

证 利用引理 2.4 (但其中的 Y_i 应理解为“工作变量”, 即具有指数型分布 $C(\theta)\exp(y'\theta - b(\theta))d\mu$ 的变量, 而非此处的样本 Y_i) 证明条件 $(\tilde{N})$ 成立, 因而 $(\tilde{C})$ 成立. 因已假定 $(\tilde{D})$ 成立, 按定理 2.9, a 得证.

按定理 2.13 的 c 的证明, 为证 b, 只需证 $\sum_{i=1}^n \|a_{ni}\|^2$ 有界及 $\max_{1 \leq i \leq n} \|a_{ni}\| \rightarrow 0$, a_{ni} 的意义同前 (注意: 条件 $(\tilde{N})$ 之证明已在 a 中指出). 为证前者, 注意在 (2.145) 式中 $F_n^{-1/2} T_n F_n^{-1/2}$ 有界, 此因由 (2.149) 式有

$$\text{tr}(F_n^{-1/2} T_n F_n^{-1/2}) = \text{tr}(F_n^{-1} T_n) \leq c,$$

且由(2.143)式知 $F_n^{-1/2} V_n F_n^{-1/2} \geq d_1 I, d_1 > 0$. 为证后者, 注意在

$\|a_n\|^2 = \lambda'(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{-1/2} z_i z_i' F_n^{-1/2} (F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} \lambda$
 中, $\max_{1 \leq i \leq n} |F_n^{-1/2} z_i z_i' F_n^{-1/2}| \rightarrow 0$, 此因 $\text{tr}(F_n^{-1/2} z_i z_i' F_n^{-1/2}) = \text{tr}(z_i' F_n^{-1} z_i)$,
 而由(2.148)式推出 $\max_{1 \leq i \leq n} z_i' F_n^{-1} z_i \rightarrow 0$. 再加上由(2.143)式推出的 $d_1 I \leq$
 $F_n^{-1/2} V_n F_n^{-1/2}$ 即可得到 $\max_{1 \leq i \leq n} \|a_n\| \rightarrow 0$. 证毕((2.108)式的右半用于证明 $\hat{\beta}_n$
 为 WC).

定理 2.14 的 c 相关于定理 2.6, 不同的是此处只要求“工作样本”有界, 而在定理 2.6 中则要求“真实样本”有界. 从实用的观点看, 这个差别也许不像表面上看来那么重要, 因为定理 2.14 中关于 $E_\beta(Y_i)$ 的假定往往是这样产生的: 一开始认为真实样本 Y_i 有指数型分布 $C(\theta) \exp(\theta'y - b(\theta)) d\mu$, 其中, μ 的支撑有界; 后来觉得, 虽则仍有理由假定 Y_i 的期望与此分布规定的一致, 但其方差(或协差阵)可能不然(有如在二项分布可能有超散布的情形). 在这种情况下, “真实样本”已先就知道为有界的.

II. h 在所选的“working distribution”

$$c(\theta) \exp(\theta'y - b(\theta)) d\mu \quad (2.150)$$

之下, 非自然联系. 就是说, 在设定: $E_\beta(Y_i) = h(z_i' \beta)$ (这个设定认为是确切的!) 中, h 并不等于由工作分布(2.150)式所决定的 $\dot{b}$.

2.2 节开始处有很多叙述可移植于此:

(2.75) 式, 包括其下的 $R_n(\beta)$ 的定义. 但要注意:

- $F_n(\beta)$ 是在工作分布下的 $\text{Cov}_\beta(S(\beta))$; 其表达式中的 Σ 此处为 Λ ①;
- $R_n(\beta)$ 中的 $u = (u_1, \dots, u_q)'$, 仍是 $u(t) = \dot{b}^{-1}(h(t))$;
- $R_n(\beta)$ 表达式中的 Y_{ir} 是真实样本而非工作样本.

2.2.3 节中的条件(D)、(C)、 (S_δ) 和(N) 仍一字不改地移植于此②, (N) 中的 $V_n(\beta)$ 仍按(2.24)定义, 且 $F_n F_n(\beta_0)$. 条件(C)的 $N_n(\delta)$ 理解为前面条件($\tilde{C}$)中定义的 $\tilde{N}_n(\delta)$. 条件(N)则废弃不用.

由于此处工作分布与真实分布不一致, 不能像 2.2 节那样由上述这些条件推出关于 QMLE $\hat{\beta}_n$ 的类似于定理 2.2' 等的定理, 需加上涉及“真实协差阵”与

① $\Lambda(t) = b(\dot{b}^{-1}(h(t)))$.

② 不要与本节中的条件(D')等混淆

“工作协差阵”的关系的条件——这一点在自然联系时也是如此.

在作了以上的准备后,可以提出以下的结论((D*)):

1. (D) + (C) + “ $V_n \leq dF_n$ ” $\Rightarrow \hat{\beta}_n$ 为 WC;
2. (D) + (S _{δ}) + “ $V_n \leq dF_n$ ” $\Rightarrow \hat{\beta}_n$ 为 SC;
3. (D) + (N) + (2.141) 式 $\Rightarrow$ (2.142).

这些条件在具体情况下的验证都不易.下面两个情况即 2.2 节所讨论的.

定理 2.15 设定理 2.7 的条件 1° ~ 5° 及 (2.143) 式成立,又 $\{\|Y_i\|^2, i \geq 1\}$ 一致可积.则如前所定义的 QMLE $\hat{\beta}_n$ 为 WC 且 (2.142) 式成立.

定理 2.16 设对 $E_\beta(Y_i)$ 有确切设定 $\dot{b}(u(z_i'\beta))$, 其“工作分布”(2.150) 式中的 μ 的支撑有界,定理 2.8 的条件 1° ~ 5° 成立,又 (2.143) 式成立,则如前所定义的 QMLE $\hat{\beta}_n$ 为 WC 且 (2.142) 式成立.

证明仿定理 2.7 和 2.8, 细节不赘述.

注 2.10 (2.142) 式中 $\hat{\beta}_n - \beta_0$ 的系数矩阵 $(F_n^{-1/2} V_n F_n^{-1/2})^{-1/2} F_n^{-1/2}$ 一般不是对称的,但可以用一个对称方阵去取代它.事实上,若 ξ_n 为随机向量而 A_n 为常数满秩方阵,有 $A_n \xi_n \xrightarrow{d} N(0, I)$, 则必有

$$(A_n A_n')^{1/2} \xi_n \xrightarrow{d} N(0, I). \quad (2.151)$$

事实上, $(A_n A_n')^{1/2} \xi_n = (A_n A_n')^{1/2} A_n^{-1} A_n \xi_n$. 由

$$\begin{aligned} (A_n A_n')^{1/2} A_n^{-1} ((A_n A_n')^{1/2} A_n^{-1})' &= (A_n A_n')^{1/2} A_n^{-1} A_n'^{-1} (A_n A_n')^{1/2} \\ &= (A_n A_n')^{1/2} (A_n A_n')^{-1} (A_n A_n')^{1/2} = I \end{aligned}$$

及 $A_n \xi_n \xrightarrow{d} N(0, I)$, 即得 (2.151) 式. 在 (2.151) 式中, ξ_n 的系数方阵为对称的.

例 1.1(续) 对 1.1 节的例 1.1, 采用自然联系, 利用下表的数据, 去估计在 logistic 回归方程 $\log \frac{\pi(x)}{1-\pi(x)} = \beta_0 + \beta_1 x_{(1)} + \beta_2 x_{(2)} + \beta_3 x_{(3)}$ 中的回归系数 $\beta_0, \dots, \beta_3$ ($\pi(x) = P(Y=1|x)$, 即自变量为 x 时受感染的概率), 见表 2.1.

得到回归系数的估计为(此处用 $\hat{\beta}_{(j)}$ 记 $\beta_{(j)}$ 的估计)

$$\hat{\beta}_{(0)} = -1.89, \quad \hat{\beta}_{(1)} = 1.07, \quad \hat{\beta}_{(2)} = 2.03, \quad \hat{\beta}_{(3)} = -3.25.$$

表 2.1 各种感染情况

		剖腹产事先计划		临时决定	
		感 染		感 染	
		有	无	有	无
用抗生素	有危险因子	1	17	11	87
	无危险因子	0	2	0	0
不 用	有危险因子	28	30	23	3
	无危险因子	8	32	0	9

于是得到估计

$$\log \frac{\text{感染概率}}{\text{不感染概率}} = -1.89 + 1.07x_{(1)} + 2.03x_{(2)} - 3.25x_{(3)}.$$

(回顾:临时决定 $x_{(1)} = 1$; 有危险因子 $x_{(2)} = 1$; 服用抗生素 $x_{(3)} = 1$.)
暂把感染概率 / 不感染概率称为“危险比”, 则由上式

$$\text{危险比} = e^{-1.89} e^{1.07x_{(1)}} e^{2.03x_{(2)}} e^{-3.25x_{(3)}}, \quad \text{愈小愈好}$$

可知最有利的组合是 $x_{(1)} = x_{(2)} = 0, x_{(3)} = 1$. 它的危险比, 比之“最不利组合” $x_{(1)} = x_{(2)} = 1, x_{(3)} = 0$ 要小 $e^{6.35}$ 倍或 572 倍. 有危险因子其危险比增大(较之无危险因子但其他因素相同) $e^{2.03} \approx 7.6$ 倍. 关系最大的是是否服用抗生素, 服用者, 其危险比缩小 $e^{3.25} \approx 26$ 倍, 而临时仓促决定剖腹产, 其危险比增大 $e^{1.07} \approx 3$ 倍.

如果采用 Probit 模型, 即

$$\text{感染概论} = \Phi(\beta_0 + \beta_1 x_{(1)} + \beta_2 x_{(2)} + \beta_3 x_{(3)}), \Phi: \sim N(0, 1),$$

则将得 $\beta_0, \dots, \beta_3$ 的估计分别为

$$\tilde{\beta}_0 = -1.09, \quad \tilde{\beta}_1 = 0.61, \quad \tilde{\beta}_2 = 1.20, \quad \tilde{\beta}_3 = -1.90,$$

而得

$$\text{危险比} = \frac{\Phi}{1 - \Phi} = \frac{\Phi(-1.09 + 0.61x_{(1)} + 1.2x_{(2)} + 1.9x_{(3)})}{1 - \Phi(-1.09 + 0.61x_{(1)} + 1.2x_{(2)} - 1.9x_{(3)})}.$$

现把由上述两种模型算出的危险比列于表 2.2.

表 2.2 由 logit, probit 模型算术的危险比

	(000)	(001)	(010)	(100)	(011)	(101)	(110)	(111)
logit	0.1511	0.0059	1.1503	0.4404	0.0446	0.0171	3.3535	0.1300
probit	0.1515	0.0014	1.1731	0.4612	0.0381	0.0087	3.2416	0.1351

可以看出,虽则回归系数估计相差甚多,但危险比的估计却很接近,说明采用哪一模型不很重要.其理由在前面(1.1.3 节结尾)已指出过了(表头上,例如,(011)表示 $x_1 = 0, x_2 = x_3 = 1$).

$\text{Cov}(\hat{\beta}_n)$ 用 Δ_n^{-1} 去估计, $\hat{\Delta}_n$ 是(2.27)式,标出 $\hat{\beta}_n$ 各分量的方差及其 t 值,见表 2.3.所有的 t 值都显著.

表 2.3 感染概率估值及经验值

$\beta_{(i)}$	$\hat{\beta}_{(i)}$	$(\widehat{\text{Var}}(\hat{\beta}_{(i)}))^{1/2}$	t 值
$i = 0$	-1.89	0.41	-4.61
$i = 1$	1.07	0.43	2.49
$i = 2$	2.03	0.46	4.41
$i = 3$	-3.25	0.48	-6.77

表 2.4 给出由 logit 模型给出的感染概率估值及由数据得出的经验值.

表 2.4 感染概论估值及经验值

	(0,0,0)	(0,0,1)	(0,1,0)	(1,0,0)	(0,1,1)	(1,0,1)	(1,1,0)	(1,1,1)
logit	$e^{1.89}/(1 + e^{-1.89})$		0.88	0.20	0.11	0.00	0.48	0.06
经验	0.30		0.77	0.13	0.11	0.01	0.53	0.04

例如,对 $x_{(1)} = 1, x_{(2)} = x_{(3)} = 0$ 一栏,若共有 $8 + 32 = 40$ 个样本,其中受感染者 8 人,频率(即经验概率)为 $8/40 = 0.20$.

考虑到样本总量 251 不算很大,表 2.4 的符合程度似乎还过得去.但(0,0,0)一栏很差,究竟如何,需要作拟合优度检验,见第 4 章.

例 1.6(续) 使用 logit 模型,即

$$\log \frac{P(\text{I 型感染})}{P(\text{不感染})} = \beta_{10} + \beta_{11} + \beta_{12}x_{(2)} + \beta_{13}x_{(3)},$$

$$\log \frac{P(\text{II 型感染})}{P(\text{不感染})} = \beta_{20} + \beta_{21}x_{(1)} + \beta_{22}x_{(2)} + \beta_{23}x_{(3)}.$$

使用例中的数据,估计结果为

$$\beta_{10} : -2.621; \quad \beta_{11} : 1.174 \quad \beta_{12} : 1.829; \quad \beta_{13} : -3.520;$$

$$\beta_{20} : -2.560; \quad \beta_{21} : 0.996; \quad \beta_{22} : 2.195; \quad \beta_{23} : -3.087.$$

按这个估计结果,在服用抗生素降低危险比的作用上, I 型比 II 型大,分别为

$e^{3.25} = 33.8$ 倍和 $e^{3.087} = 21.9$ 倍. 而对危险因子在升高危险比的作用上来说, 则 II 型比 I 型大, 分别为 $e^{2.195} = 9$ 和 $e^{1.829} = 6.2$ 倍.

例 1.7(续) $x = (x_{(1)}, x_{(2)}, x_{(3)})$, 都是哑变量:

$$\begin{aligned} x_{(1)} &= 1 \text{ 或 } -1, \text{ 视年龄 } < 40 \text{ 与否,} \\ x_{(2)} &= 1 \text{ 或 } -1, \text{ 视从不吸烟与否,} \\ x_{(3)} &= 1 \text{ 或 } -1, \text{ 视“以前吸烟, 现在不吸”, 与否,} \\ z_{(0)}(x) &= (x_{(1)}, x_{(2)}, x_{(3)}, x_{(1)}x_{(2)}, x_{(1)}x_{(3)})'. \end{aligned} \quad (2.152)$$

在 $z_0(x)$ 中有 x_1x_2 及 x_1x_3 的项, 表示考虑了“年龄”与“吸烟状态”之间的交互作用. 使用所给数据, 得到门限值 θ_1, θ_2 , 以及 $x_{(1)}, \dots, x_{(1)}x_{(3)}$ 的系数 $\beta_{(1)}, \dots, \beta_{(5)}$ 的估计值, 见表 2.5.

括号内的值是所谓“ p 值”. 它的意义如下: 例如, 在 logistic 模型下 $\beta_{(1)}$ 的 p 值为 0.29, 表示即使 $\beta_{(1)}$ 真值为 0, 那么纯粹由于随机的原因, 其“估计值的绝对值大于 0.114”这个事件的概率, 也有 0.29. 因此, 0.114 这个值不足以否定 $\beta_{(1)} = 0$ 这个假设, 或更确切地说, 现有数据没有支持“在模型中必须包含 $x_{(1)}$ 这项”的说法. 当然, 这不等于说证明了模型中确实不包含这项. 这需要有实际背景的参考或更多的数据.

表 2.5 系数估计值

	累积 logistic		分组 Cox		极大值分布	
θ_1	2.370	(0.0)	0.872	(0.0)	2.429	(0.0)
θ_2	3.844	(0.0)	1.377	(0.0)	3.843	(0.0)
$\beta_{(1)}(x_{(1)})$	0.114	(0.29)	0.068	(0.04)	0.095	(0.37)
$\beta_{(2)}(x_{(2)})$	0.905	(0.0)	0.318	(0.0)	0.866	(0.19)
$\beta_{(3)}(x_{(3)})$	-0.364	(0.01)	-0.110	(0.02)	-0.359	(0.14)
$\beta_{(4)}(x_{(4)})$	-0.557	(0.0)	-0.211	(0.00)	-0.529	(0.19)
$\beta_{(5)}(x_{(5)})$	0.015	(0.91)	0.004	(0.92)	0.021	(0.14)

从表 2.5 看出: 在 3 个模型之下, 同一系数的估值相差甚多. 其原因一定程度上可归于 1.1.3 节段中所说. 重要的是由不同模型算出的概率差异如何(差异必然存在, 因这 3 个模型彼此间并非就只差一个线性变换). 值得注意的是各系数估计值的符号都相同. 这表明: 虽然使用的模型不同, 其对各因素的作用的方向的估计是相同的(见下文的注).

注 2.11 在本例中, Y 取 3 个值: 1(正常), 2(边缘), 3(不正常). 按累积 logistic 模型有

$$P(Y \leq r) = \frac{\exp(\theta_r + z'(x)\beta)}{1 + \exp(\theta_r + z'(x)\beta)} \quad (r = 1, 2).$$

合乎 $\beta_{(1)}$ 这个分量来说, 因为 x_1 取 ± 1 两值, 而 $+1$ 相应于年龄 < 40 . 故如 $\beta_{(1)} > 0$, 则对年龄 < 40 一组而言, $x_{(1)}\beta_{(1)} > 0$. 由上式知 $P(Y \leq r)$ 之值升高. 即情况对 < 40 一组有利. 因为 $P(Y \leq r)$ 的升高表明 Y 取小值 (Y 取小值是好的情况) 的机会大. 相反, 对 ≥ 40 那组而言, $x_1 = -1$, $x_{(1)}\beta_{(1)} < 0$, $P(Y \leq r)$ 下降. 表明情况对年龄大的一组不利. 这就是上文“起作用的方向”一语的解释.

从表 2.5 看出, $\beta_{(4)}$, 即交互项 $x_{(1)}x_{(2)}$ 的系数, 其估值为负且为显著 (p 值为 0), 表明 $x_{(1)}$ 和 $x_{(2)}$ 这两个因素的影响是“反向拉动”的. 初一看这觉得有些不合情理, 因为年纪愈轻, 愈是不吸烟, 则应愈是对呼吸状况有利, 即两因素应是“正向拉动”. 解释是这样的: 孤立看 $x_{(1)}$, $x_{(2)}$ 两个因素, 都是“正向拉动”作用——它们取大值有利于呼吸状况改善. 如果无交互作用, 则这二因素联合起来其“拉动效应”, 应是各自的拉动效应之和, 负的交互效应表明, 实际上要扣掉一部分, 联合的拉动效应, 比之各自拉动效应之和要小一些, 而这是很正常的, 没有什么奇怪的地方.

另一点需要说明的是: 我们是按 (2.152) 式定义的 $x_{(1)}, x_{(2)}, x_{(3)}$, 如果在 (2.152) 式中把 -1 改为 0, 会不会得出不同的结果? 我们说不会, 二者等价. 理由如下:

设在 (2.152) 式中以 -1 代 0 的模型, 相应于 $\beta_{(1)}, \dots, \beta_{(5)}$ 的量记为 $\alpha_1, \dots, \alpha_5$, 则当 $x = (x_{(1)}, x_{(2)}, x_{(3)})$ 在旧、新模型中取各值时, 其回归值即 $(z_{(0)}'(x), \text{回归系数向量})$, 所取值列于表 2.6^①.

表 2.6 新旧模型不同取值的回归值

旧模型		新模型	
x 取值	回归值	x 取值	回归值
(1, 1, 1)	$\beta_{(1)} + \beta_{(2)} + \beta_{(3)} + \beta_{(4)} + \beta_{(5)}$	(1, 1, 1)	$\alpha_1 + \alpha_2 + \alpha_3 + \alpha_4 + \alpha_5$
(1, 1, -1)	$\beta_{(1)} + \beta_{(2)} - \beta_{(3)} + \beta_{(4)} - \beta_{(5)}$	(1, 1, 0)	$\alpha_1 + \alpha_2 \quad \alpha_4$

① 在本例中, $x_{(2)}, x_{(3)}$ 不能同时为 1, 故 (1, 1, 1) 和 (-1, 1, 1) 两个状态不存在. 表 2.6 计算未排除这二者, 以说明所作论断普遍成立

续表

旧模型		新模型	
x 取值	回归值	x 取值	回归值
$(1, -1, 1)$	$\beta_{(1)} - \beta_{(2)} + \beta_{(3)} - \beta_{(4)} + \beta_{(5)}$	$(1, 0, 1)$	$\alpha_1 + \alpha_3 + \alpha_5$
$(-1, 1, 1)$	$-\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}$	$(0, 1, 1)$	$\alpha_2 + \alpha_3$
$(1, -1, -1)$	$\beta_{(1)} - \beta_{(2)} - \beta_{(3)} - \beta_{(4)} - \beta_{(5)}$	$(1, 0, 0)$	α_1
$(-1, 1, -1)$	$-\beta_{(1)} + \beta_{(2)} - \beta_{(3)} - \beta_{(4)} + \beta_{(5)}$	$(0, 1, 0)$	α_2
$(-1, -1, 1)$	$-\beta_{(1)} - \beta_{(2)} + \beta_{(3)} + \beta_{(4)} - \beta_{(5)}$	$(0, 0, 1)$	α_3
$(-1, -1, -1)$	$-\beta_{(1)} - \beta_{(2)} - \beta_{(3)} + \beta_{(4)} + \beta_{(5)}$	$(0, 0, 0)$	0

把表 2.6 中右边(新模型)各回归值同加上 $-\beta_{(1)} - \beta_{(2)} - \beta_{(3)} + \beta_{(4)} + \beta_{(5)}$ ——这不影响模型,因为我们可以从 θ_1 和 θ_2 中各减去此值,即使模型恢复原状.经过这一加,右边一栏回归值依次为

$$\begin{aligned}
 &(\alpha_1 + \alpha_2 + \alpha_3 + \alpha_4 + \alpha_5) - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &(\alpha_1 + \alpha_2 + \alpha_4) - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &(\alpha_1 + \alpha_3 + \alpha_5) - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &(\alpha_2 + \alpha_3) - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &\alpha_1 - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &\alpha_2 - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &\alpha_3 - (\beta_{(1)} + \beta_{(2)} + \beta_{(3)} - \beta_{(4)} - \beta_{(5)}), \\
 &-(\beta_{(1)} - \beta_{(2)} - \beta_{(3)} + \beta_{(4)} + \beta_{(5)}),
 \end{aligned}$$

如果命上表中

左 = 右,

则方程无解.因为以 α_1, α_2 的表达式代入第 4 行右边,结果与左边不同,这是因为还有 θ_1 和 θ_2 的值起作用.

让这前面 7 个值依次等于表中左边(旧模型)中前 7 个回归值,可以解出

$$\begin{aligned}
 \alpha_1 &= 2\beta_{(1)} - 2\beta_{(4)} - 2\beta_{(5)}, & \alpha_2 &= 2\beta_{(2)} - 2\beta_{(4)}, & \alpha_3 &= 2\beta_{(3)} - 2\beta_{(5)} \\
 \alpha_4 &= 4\beta_{(4)}, & \alpha_5 &= 4\beta_{(5)}. & & (2.153)
 \end{aligned}$$

由此即看出新、旧模型等价,两模型下回归系数有关系(2.152)式:如果我们从一个模型出发得到其回归系数的估值,那么,利用(2.152)式可得到在另一模型下回归系数的估值.不论从那一模型出发,所得 $P(Y \leq r | x)$ 的估值完全一致(这是等价性的实质含义所在).

值得注意的是(2.152)式的后两个等式: $\beta_{(4)}, \beta_{(5)}$ 和 α_4, α_5 分别是旧、新模型下的两个交互效应,其值只相差一个倍数4.因此我们看出:关于交互效应存在与否及其量级的评估,不受我们采用何一模型的影响,即与(2.152)式中-1是否改为0无关.类似的推理指出,即使在(2.152)式中一部分-1改为0,另一部分不改,也没有影响.

还要注意一点:从(2.127)式看,在新模型中,交互作用系数 α_4, α_5 的数值,分别比其在旧模型中的数值 $\beta_{(4)}, \beta_{(5)}$ 扩大了4倍,因此怀疑是否有这种可能:原来一个交互作用系数的估值,在旧模型中未达到显著,而在新模型中却达到显著了?这显然不可能.因按(2.153式), $\beta_{(4)}, \alpha_4$ 的估值 $\hat{\beta}_{(4)}, \hat{\alpha}_4$ 有关系

$$\hat{\alpha}_4 = 4\hat{\beta}_{(4)}.$$

故其方差 $\text{Var}(\hat{\alpha}_4) = 16\text{Var}(\hat{\beta}_{(4)})$.因而 $\hat{\alpha}_4$ 的 t 值

$$\hat{\alpha}_4 / \sqrt{\text{Var}(\hat{\alpha}_4)} = \hat{\beta}_{(4)} / \sqrt{\text{Var}(\hat{\beta}_{(4)})},$$

即与 $\hat{\beta}_{(4)}$ 的 t 值同.因此,在 t 检验下,两假设“ $\alpha_4 = 0$ ”和“ $\beta_{(4)} = 0$ ”,或者同被接受,或者同被否定,不会出现一个被接受而另一个被否定的情况.在本例中,重要的研究对象是年龄与吸烟状态(不吸、过去吸、现在吸)对呼吸状态影响的交互作用,因为单一因子的作用是比较明显的.从所得的 $\beta_{(4)}, \beta_{(5)}$ 估值可得全部交互作用如表2.7(按分组Cox)所示.

表 2.7 年龄与吸烟状态对呼吸状态影响的交互作用

吸烟状态 年龄	1(不吸)	2(过去吸)	3(现在吸)
1(轻)	-0.211	0.004	0.207
2(老)	0.211	-0.004	-0.207

在表2.7中, -0.211和0.004两值是估计所得,其他各值则由“行和”=0与“列和”=0求出.从表2.7中看出,似乎(1,3)和(2,1)两个状态最有利,其实不然,因为还要把主效应结合在一起看,情况如表2.8(按分组Cox)所示.

表 2.8 各种状态对呼吸状态影响的交互作用

状 态	年轻,从不	年轻,过去	年轻,现在	年老,从不	年老,过去	年老,现在
$x = (x_{(1)}, x_{(2)}, x_{(3)})$	1, 1, -1	1, -1, 1	1, -1, -1	-1, 1, -1	-1, -1, 1	-1, -1, -1

续表

状 态		年轻,从不	年轻,过去	年轻,现在	年老,从不	年老,过去	年老,现在
$\sum_{j=1}^5 \hat{\beta}_{(j)} z_j \triangleq A(x)$		0.281	-0.145	0.067	0.575	-0.711	-0.548
概率 $P(Y=r x)$ $= P(Y \leq r x)$ $- P(Y \leq r-1 x)$ 的计算	$\hat{\theta}_1 + A(x)$	1.153	0.727	0.939	1.447	0.161	0.324
	$\hat{\theta}_2 + A(x)$	1.658	1.232	1.444	1.952	0.666	0.829
	$r = 1$	0.968	0.874	0.922	0.986	0.701	0.749
	$r = 2$	0.027	0.094	0.064	0.013	0.156	0.150
	$r = 3$	0.005	0.032	0.014	0.001	0.143	0.101

注: $z = (x_{(1)}, x_{(2)}, x_{(3)}, x_{(1)}x_{(2)}, x_{(1)}x_{(3)})$

$$P(Y=1|x) = (-\exp(-\exp(\hat{\theta}_1 + A(x)))) ,$$

$$P(Y=2|x) = (1 - \exp(-\exp(\hat{\theta}_2 + A(x)))) - (1 - \exp(-\exp(\hat{\theta}_1 + A(x)))) ,$$

$$P(Y=3|x) = \exp(-\exp(\hat{\theta}_2 + A(x))) .$$

从以上结果可看出以下几点结论:

一是 $|\hat{\beta}_{(1)}|$ 很小, 显示年龄这个因素对呼吸情况好坏影响不大.

二是 $\hat{\beta}_{(2)} > 0$ 且较大, 显示吸烟对呼吸情况有负面影响, 比年龄因素大.

三是不论在年轻一组和年老一组中, “过去吸烟” 比之 “现在吸烟”, 其呼吸情况更坏一些. 这可能是由于, 这中间一部分人是由于呼吸出了问题才戒烟的.

至于计算的过程. 对迭代计算求估计值, 令 $\gamma = (\theta_1, \theta_2, \beta')'$,

$$Z'(x) = \begin{pmatrix} 1 & 0 & z'(x) \\ 0 & 1 & z'(x) \end{pmatrix},$$

$$\mu = (\mu_1, \mu_2)' = (\pi_1, \pi_2)' = \pi,$$

$$g(\pi) = (g_1(\pi), g_2(\pi)) = \left(\log \log \frac{1}{1 - \pi_1}, \log \log \frac{1}{1 - \pi_1 - \pi_2} \right)' (= z(x)\gamma).$$

按 (2.72) 式, 先要算出 (2.66) 式右边, 这可按 (2.63) 式算 $W_i(\gamma)$. 在本例有 (注意 π 在以往的记号中为 $E(Y) = \mu$, 下文将 Y 的协方差阵记为 μ (即 π) 的函数的形式, 与以往记法不同):

$$\Sigma(\pi) \equiv \text{Cov}_{\pi}(Y) = - \begin{bmatrix} \pi_1(1 - \pi_1) & -\pi_1\pi_2 \\ -\pi_1\pi_2 & \pi_2(1 - \pi_2) \end{bmatrix}$$

$$\frac{\partial g(\pi)}{\partial \pi'} = \begin{pmatrix} \frac{1}{(1-\pi_1)\log \frac{1}{1-\pi_1}} & 0 \\ \frac{1}{(1-\pi_1-\pi_2)\log \frac{1}{1-\pi_1-\pi_2}} & \frac{1}{(1-\pi_1-\pi_2)\log \frac{1}{1-\pi_1-\pi_2}} \end{pmatrix}$$

再算

$$H_i \triangleq \left(\frac{\partial g(\pi)}{\partial \pi'} \Sigma(\pi) \frac{\partial g'(\pi)}{\partial \pi} \right)^{-1} \bigg|_{\substack{\pi_1 = 1 - \exp(-\exp(\theta_1 + z'(x_i)\beta)) \triangleq \pi_{1i} \\ \pi_2 = \exp(-\exp(\theta_1 + z'(x_i)\beta)) - \exp(-\exp(\theta_2 + z'(x_i)\beta)) \triangleq \pi_{2i}}} \quad (2.154)$$

样本 (y_i, x_i) ($i = 1, \dots, n$) $y_i = (y_{(1)i}, y_{(2)i})'$:

$y_{(1)i} = 1$, 若第 i 样本呼吸正常, 否则为 0;

$y_{(2)i} = 1$, 若第 i 样本呼吸正常, 否则为 0;

$$\dot{g}_i = \frac{\partial g(\pi)}{\partial \pi'} \bigg|_{\pi_1, \pi_2 \text{ 以 (2.154) 式中之值代入}}$$

$$s(\gamma) = \sum_{i=1}^n s_i(\gamma), \quad s_i(\gamma) = z'(x_i) H_i \dot{g}_i \begin{pmatrix} Y_{(1)i} - \pi_{1i} \\ Y_{(2)i} - \pi_{2i} \end{pmatrix}.$$

(π_{1i}, π_{2i} 以 (2.154) 式中之值代入.)

迭代公式

$$\hat{\gamma}^{(k+1)} = \hat{\gamma}^{(k)} + \left(\sum_{i=1}^n z'(x_i) H_i z(x_i) \right)^{-1} s(\hat{\gamma}^{(k)}).$$

初始值由^①

① 在 x 所能取的不同值的个数不多时, 一般在样本 $\{(x_i, y_i)\}$ 中会有一些样本有同一 x 值. 设全部样本分成 m 堆, 每堆依次有 $n_1, \dots, n_m$ 个样本, 第 j 堆 x 值为 x_j ($x_1, \dots, x_m$ 两两不同), y 值平均为 $\bar{y}_j$, 各分量之和小于 1, 则 $g(\bar{y}_j)$ 有意义, 而 (2.155) 式应以

$$\sum_{j=1}^m n_j \| \bar{y}_j g(\bar{y}_j) - z(x_j) \hat{\gamma}^{(0)} \|^2 = \min_{\gamma} \sum_{j=1}^m \| g(\bar{y}_j) - z(x_j) \gamma \|^2 n_j \quad (2.156)$$

所取代. 若 $\bar{y}_j$ 各分量和为 1, 则 (2.120) 式中的 $\bar{y}_j$ 改为 $\frac{n_j + 1}{n_j + 2} \hat{\gamma}_j$, 这当然也适合于 $n_j = 1$ 的情况.

$$\sum_{i=1}^n \|g(y_i) - z(x_i)\hat{\gamma}^{(0)}\|^2 = \min_{\gamma} \sum_{i=1}^n \|g(y_i) - z(x_i)\gamma\|^2 \quad (2.155)$$

确定 $\text{Cov}(\hat{\gamma})$ 的估计值由

$$\left(\sum_{i=1}^n z'(x_i)\hat{H}_i z(x_i)\right)^{-1}$$

确定.

$\hat{H}_i =$ 在 H_i 中以 $\hat{\theta}_1, \hat{\theta}_2, \hat{\beta}$ 分别取代 $\theta_1, \theta_2, \beta$.

例 1.7(续) 由于呼吸状况的恶化是依序的:正常 $\rightarrow$ 边缘 $\rightarrow$ 不正常,本例也可按 1.2.5 节的序贯模型处理.取序贯 logit 模型,即(当 $r = 1$ 时, $\pi_1 + \dots + \pi_{r-1}$ 理解为 0)

$$\frac{\pi_r}{1 - \pi_1 - \dots - \pi_{r-1}} = \frac{\exp(\theta_r + z'(x)\beta)}{1 + \exp(\theta_r + z'(x)\beta)} \quad (r = 1, \dots, q). \quad (2.157)$$

本例 $q = 2, \theta_1, \theta_2, z(x), \beta, \pi_1, \dots, \pi_q$ 的意义同前.利用例中的数据模型的 (2.157), 得到估值如下:

$$\hat{\theta}_1 = 2.379, \quad \hat{\theta}_2 = 1.516; \quad \hat{\beta}_1 = 0.094, \quad \hat{\beta}_2 = 0.882$$

$$\hat{\beta}_3 = -0.356, \quad \hat{\beta}_4 = -0.601, \quad \hat{\beta}_5 = 0.092.$$

与前面(非序贯)logit 模型的结果比较,发现基本相似.但在两模型中参数起的作用不同,故还不能以这个相似性来断言二者结果差不多.一切要以计算概率为准,即比较两模型下的 $P(\text{最终为 } r \text{ 级} | x) (r = 1, 2)$. 算法由 (2.157) 式易见:

$$P(\text{最终为 1 级(即正常)} | x) = \exp(\theta_1 + z'(x)\beta) / (1 + \exp(\theta_1 + z'(x)\beta)),$$

$$P(\text{最终为 2 级(边缘)} | x) = \frac{\exp(\theta_2 + z'(x)\beta)}{(1 + \exp(\theta_1 + z'(x)\beta))(1 + \exp(\theta_2 + z'(x)\beta))},$$

以 $\theta_1, \theta_2, \beta$ 的估值 $\hat{\theta}_1$ 等取代上式中的 θ_1 等,得到上述两个概率的估值,而 $P(\text{最终为 3 级(不正常)} | x)$ 的估值则由三者之和为 1 得出.

具体计算结果表明,二者有些差异,不算太显著,不过以后我们将指出:对本例数据而言,序贯模型的拟合较好.

具体计算与上例相似, $\Sigma(\beta)$ 一样,问题是求出 $g(\pi), \partial g(\pi)/\partial \pi'$ 及 $s(\gamma)$. 此处 $g = (g_1, g_2)'$ 而

$$g_1(\pi) = \log(\pi_1/(1 - \pi_1)),$$

$$g_2(\pi) = \log \frac{\pi_2}{1 - \pi_1 - \pi_2}, \text{ 由此算出 } \partial g(\pi)/\partial \pi', \quad (2.158)$$

$$s(\gamma) = \sum_{i=1}^n s_i(\gamma), \quad s_i(\gamma) = u'(x_i) H_i \dot{g}_i \begin{bmatrix} y_{(1)i} - \pi_{1i} \\ y_{(2)i} - \pi_{2i} \end{bmatrix}.$$

为算 π_{1i}, π_{2i} , 由(2.158)式,

$$\pi_{1i} = \frac{\exp(\theta_1 + z(x_i)\beta)}{1 + \exp(\theta_1 + z'(x_i)\beta)},$$

$$\pi_{2i} = \frac{\exp(\theta_2 + z'(x)\beta)}{(1 + \exp(\theta_1 + z'(x_i)\beta))(1 + \exp(\theta_2 + z'(x_i)\beta))}.$$

在迭代过程中, 当算 $\hat{\gamma}^{(k+1)}$ 时, $\gamma' = (\theta_1, \theta_2, \beta')$ 要以 $\hat{\gamma}^{(k)}$ 代入, 最后计算 $\hat{\gamma}$ 的协方差阵 $\text{Cov}(\hat{\gamma})$ 的估计值 $(\sum_{i=1}^n u(x_i) \hat{H}_i u'(x_i))^{-1}$ 时, $\hat{H}_i$ 是由在 H_i 中以 $\hat{\gamma}$ 代 γ 所得, 而 $\hat{\gamma}$ 则是上述求解迭代的结果.

例 1.9(续) 本例只有一个自变量: $x = 1$ (带菌), -1 (不带). 应用本例数据估计得门限 θ_1, θ_2 与回归系数 β 的值为

$$\hat{\theta}_1 = -0.809(\text{方差 } 0.013), \quad \hat{\theta}_2 = 1.061(\text{方差 } 0.014), \quad \hat{\beta} = -0.301(\text{方差 } 0.013)$$

(按非序贯 logit 处理)

以及

$$\tilde{\theta}_1 = -0.775(\text{方差 } 0.011), \quad \tilde{\theta}_2 = 0.468(\text{方差 } 0.012), \quad \tilde{\beta}_2 = -0.264(\text{方差 } 0.010).$$

(按序贯 logit 处理)

其估值有些差异, 不过由于模型不同, 不能看表面上的差异, 要比较其取各状态的概率才行, 结果列于表 2.9.

表 2.9

状态 \ 概率估值		1	2	3
非序贯	$x = 1$	0.248	0.512	0.240
	$x = -1$	0.376	0.497	0.127
序贯	$x = 1$	0.261	0.407	0.332
	$x = -1$	0.375	0.420	0.205

从表 2.9 看出, 用非序贯模型所得结果比较乐观一些, 即取正常一端的概率接近, 中间状态概率增大而“很肥大”的概率缩小. 以后将指明: 就本例而言, 序贯模型的拟合较好.

例 1.10(续) 这是一个两步模型的例子. 本例中, 决定所属类的有两个门限值 θ_1, θ_2 ——因一共有 3 类, 第 1、第 3 类各含两个状态, 各需一个门限值 θ_{11} 和 θ_{31} , 另外, 自变量只有一个 $x, x = 1$ (新药) 或 0 (对照), $z(x)$ 和 β 分别为

$$z(x) = \begin{pmatrix} 1 & 0 & x & 0 & 0 & 0 & 0 \\ 0 & 1 & x & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & x & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & x \end{pmatrix}, \quad \beta = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \beta_0 \\ \theta_{11} \\ \beta_1 \\ \theta_{31} \\ \beta_3 \end{pmatrix}, \quad (2.159)$$

β_0 : 分类的回归系数, β_{11}, β_{31} : 在第 1、第 3 类中分状态的回归系数.

样本量 $n = 219$, 其中 $x = 1$ 的有 107 个, $x = 0$ 的有 112 个.

把状态按表中的次序编号: $\tilde{Y} = 1, \dots, 5, \tilde{Y} = 1$ (大有好转). 则 $T_1 = \{1, 2\}$,

$T_2 = \{3\}, T_3 = \{4, 5\}$,

$$P(\tilde{Y} \in T_1 | x) \triangleq \pi_1(x) + \pi_2(x) = F(\theta_1 + x\beta_0)$$

$$P(\tilde{Y} \in T_2 | x) \triangleq \pi_3(x) = F(\theta_2 + x\beta_0)$$

$$P(\tilde{Y} = 1 | x, T_1) = \pi_1(x) / (\pi_1(x) + \pi_2(x)) = F(\theta_{11} + x\beta_{11})$$

$$P(\tilde{Y} = 4 | x, T_3) = \pi_4(x) / (1 - \pi_1(x) - \pi_2(x) - \pi_3(x)) = F(\theta_{31} + x\beta_{31}). \quad (2.160)$$

此处的安排是使 $P(\tilde{Y} = j | x) = \pi_j(x)$ ($j = 1, 2, 3, 4$). 上式中分布函数 F 的选择决定联系函数, 如果选 logit 模型即 $F(t) = e^t / (1 + e^t)$, 有

$$g(\pi) = (g_1(\pi), \dots, g_4(\pi))',$$

其中

$$\left. \begin{aligned} g_1(\pi) &= \log \frac{\pi_1 + \pi_2}{1 - \pi_1 - \pi_2}, \quad g_2(\pi) = \log \frac{\pi_3}{1 - \pi_3}, \\ g_3(\pi) &= \log \frac{\pi_1}{\pi_2}, \quad g_4(\pi) = \log \frac{\pi_4}{1 - \pi_1 - \pi_2 - \pi_3 - \pi_4}. \end{aligned} \right\} \quad (2.161)$$

注意 $g_1, \dots, g_4$ 的次序必须与 (2.159) 式中 $z(x)$ 各行的次序符合. 而这次序就是 (2.160) 式中 4 个等式的次序.

本例仍有

$$\text{Cov}\beta = \begin{bmatrix} \pi_1(1-\pi_1) & -\pi_1\pi_2 & -\pi_1\pi_3 & -\pi_1\pi_4 \\ -\pi_1\pi_2 & \pi_2(1-\pi_2) & -\pi_2\pi_3 & -\pi_2\pi_4 \\ -\pi_1\pi_3 & -\pi_2\pi_3 & \pi_3(1-\pi_3) & -\pi_3\pi_4 \\ -\pi_1\pi_4 & -\pi_2\pi_4 & -\pi_3\pi_4 & \pi_4(1-\pi_4) \end{bmatrix}.$$

而 $\partial g(\pi)/\partial \pi'$ 由 (2.160) 式算出, 再利用 (2.154) 式标出 H_i , 其中 $\pi_1, \dots, \pi_4$ 应以

$$\begin{aligned} \pi_1(x_i) &= e^{(\theta_1+x_i\beta_0)} / (1 + e^{(\theta_1+x_i\beta_0)})(1 + e^{(\theta_{11}+x_i\beta_{11})}) \\ \pi_2(x_i) &= e^{(\theta_1+x_i\beta_0)} e^{(\theta_{11}+x_i\beta_{11})} / (1 + e^{(\theta_1+x_i\beta_0)})(1 + e^{(\theta_{11}+x_i\beta_{11})}) \\ \pi_3(x_i) &= e^{(\theta_2+x_i\beta_0)} / (1 + e^{(\theta_2+x_i\beta_0)}) \\ \pi_4(x_i) &= [1 - \pi_1(x_i) - \pi_2(x_i) - \pi_3(x_i)] \frac{e^{(\theta_{31}+x_i\beta_{31})}}{1 + e^{(\theta_{31}+x_i\beta_{31})}}, \end{aligned}$$

代入, 其余一切与例 1.7(续) 同^①.

按此计算, 利用例中提供的数据, 得出 β_0, β_{11} 和 β_{31} 估值为

$$\begin{aligned} \hat{\beta}_0 &= 0.04 (t \text{ 值 } 0.28), \quad \hat{\beta}_{11} = 0.55 (t \text{ 值 } 2.60), \\ \hat{\beta}_{31} &= -0.03 (t \text{ 值 } -0.08). \end{aligned}$$

可以看出, 只 $\hat{\beta}_{11}$ 一个为显著, 这可解释为: 在有好转的条件下新药能增效, 或者也大致可解释为在病情较轻时有效.

注 2.12 比较定理 2.2 和 2.3:

$$\hat{\beta} \text{ 弱相合, } (D) + (C),$$

$$\hat{\beta} \text{ 强相合, } (D) + (S_\delta).$$

故条件 (S_δ) 应比条件 (C) 强才合理. 但其实不然: 很容易举出例子, 其中条件 (S_δ) 成立, 但条件 (C) 不成立.

例 2.7 $y | \theta \sim \exp(\theta y - b(\theta)) d\mu(y)$, 其中 μ 为

$$\mu(\{i\}) = 1/i! \quad (i = 0, -1, -2, \dots); \quad \text{其他处 } \mu \text{ 为 } 0$$

① 注本例中 $\hat{H}_i$ 为 4 阶方阵, 而

$$\sum_{i=1}^n z'(x_i, \hat{H}_i z(x_i))$$

为 7 阶方阵, $z(x_i)$ 为 (2.159) 式中令 $x = x_i$ 得.

$$\int e^{y\theta} d\mu(y) = \sum_{i=0}^{\infty} \frac{e^{-i\theta}}{i!} = \exp(e^{-\theta}) \quad (\theta > 0)$$

得 $e^{b(\theta)} = e^{e^{-\theta}}$, 而

$$b(\theta) = e^{-\theta}, \quad \text{Var}(y | \theta) = e^{-\theta}.$$

定义 $x_i, i \geq 1$ 于下:

$$i = [\exp(k^{3/2})], \quad k = 1, 2, \dots \text{ 时}, x_i = 1,$$

对其他 i , 取 x_i , 使 $x_i > 0$ 且

$$f(x_i) \equiv x_i^2 e^{-x_i} = 1/(2i)$$

这样的 $x_i > 0$ 有两个, 取其大者 (见图 2.7), 必有

$$\log i < x_i < 2 \log i \quad (i \text{ 充分大}).$$

因

$$f(\log i) = (\log i)^2 / i > 1/(2i),$$

$$f(2 \log i) = (2 \log i)^2 / i^2 < 1/(2i)$$

(i 充分大).




图 2.7

往证: 条件 (S_δ) 适合. 为此, 记

$$W = \{[\exp(k^{3/2})]; k = 1, \dots, n\},$$

$$W_{n1} = \{1, \dots, n\} \cap W, \quad b_{n1} = \#(W_{n1} \text{ 中数的个数}),$$

$$W_{n2} = \{1, \dots, n\} - W_{n1}, \quad b_{n2} = \#(W_{n2} \text{ 中数的个数}).$$

分 3 种情况:

1° $\beta_0 > 1$. 因 $i \notin W$, i 充分大时, 有 $e^{-x_i} < 1/i$, 故

$$\Sigma(x_i \beta_0) = e^{-x_i \beta_0} < i^{-\beta_0} \Rightarrow \Sigma_{i \in W_{n1}} x_i^2 \Sigma(x_i \beta_0) < c < \infty \quad (c \text{ 与 } n \text{ 无关})$$

又因 $b_{n1}/(\log n)^{2/3} \rightarrow 1$ ($n \rightarrow \infty$), 有

$$F_n = b_{n1} e^{-\beta_0} + \Sigma_{i \in W_{n1}} x_i^2 e^{-x_i \beta_0} \approx e^{-\beta_0} (\log n)^{2/3}.$$

($\approx$ 表示左、右两边的比 $\rightarrow 1$ ($n \rightarrow \infty$)).)

取 $\epsilon, 0 < \epsilon < \beta_0$, 在 $\beta \in [\beta_0 - \epsilon, \beta_0 + \epsilon]$ 内, 有

$$F_n(\beta) \geq \Sigma_{i \in W_{n1}} x_i^2 \Sigma(x_i \beta_0) \geq e^{-(\beta_0 + \epsilon)} (\log n)^{2/3}.$$

因而 (因是 1 维, $\lambda_{\min}$ 和 $\lambda_{\max}$ 无分别).

$$\inf\{\lambda_{\min}(F_n(\beta)): |\beta - \beta_0| \leq \epsilon\} > e^{-\epsilon} 2^{-1} \lambda_{\max} F_n.$$

故条件 (S_δ) 对 $\delta = 1/2$ 适合.

2° $\beta_0 = 1$. 与 $\beta_0 > 1$ 相似, 有

$$F_n \approx (\log n)/2$$

$$\inf\{F_n(\beta): |\beta - \beta_0| \leq \epsilon\} \approx e^{-(1+\epsilon)} (\log n)^{2/3}.$$

因而条件(S_δ)对 $0 < \delta < 1/6$ 适合.

3° $\beta_0 < 1$. 当 $i \notin W$, i 充分大时, 有 $e^{-x_i} < i^{-1}$, 故

$$\begin{aligned} \Sigma(x_i \beta_0) &< i^{-\beta_0} \Rightarrow \Sigma_{i \in W_{n1}} x_i^2 \Sigma(x_i \beta_0) \\ &< \sum_{i=1}^n 4(\log i)^2 \cdot i^{-\beta_0} \approx \frac{4}{1-\beta_0} (\log n)^2 n^{1-\beta_0}, \end{aligned}$$

因此

$$F_n \approx \frac{4}{1-\beta_0} (\log n)^2 n^{1-\beta_0}.$$

另一方面, 因对任何 $\alpha > 1$, 当 $i \notin W$, i 充分大时, 有 $\log i < x_i < \alpha \log i$, 有 $\Sigma(x_i \beta) > i^{-\alpha\beta}$, 故在 $|\beta - \beta_0| \leq \epsilon$, 有

$$\begin{aligned} F_n(\beta) &\geq \Sigma_{i \in W_{n2}} x_i^2 i^{-\alpha\beta} \geq \Sigma_{i \in W_{n2}} x_i^2 i^{-\alpha(\beta_0 + \epsilon)} \\ &\approx \frac{1}{1-\alpha(\beta_0 + \epsilon)} \log^2 n n^{1-\alpha(\beta_0 + \epsilon)}. \end{aligned}$$

找 $\alpha > 1$, 使 $\alpha - 1$ 充分小, $\epsilon > 0$ 充分小, 使 $1 - \alpha(\beta_0 + \epsilon) > \frac{2}{3}(1 - \beta_0)$, 则易见

$$\inf\{F_n(\beta): |\beta - \beta_0| \leq \epsilon\} > F_n^{2/3} \quad (n \text{ 充分大}).$$

因而条件(S_δ)对 $0 < \delta < 1/6$ 适合.

往下证明: 对 $\beta_0 = 1$, 条件(C) 不适合. 因 $\beta_0 = 1$ 时, $F_n \approx (\log n)/2$. 故 $\{\beta: |F_n^{1/2}(\beta - \beta_0)| \leq 1\}$ 内的 β 值, 有一个为 $\beta_0 + F_n^{-1/2} = 1 + F_n^{-1/2} > 1 + 1/\sqrt{\log n}$. 故对此 β 值, 有

$$\Sigma(x_i \beta) = e^{-x_i \beta} = e^{-x_i} e^{-x_i(\beta-1)} < e^{-x_i} e^{-\sqrt{\log i}} \quad (x \notin W),$$

故

$$\begin{aligned} \Sigma_{i \in W_{n2}} x_i^2 \Sigma(x_i \beta) &\leq \Sigma_{i \in W_{n2}} x_i^2 e^{-x_i} (\log i)^{-2} \\ &\leq \sum_{i=2}^n i^{-1} (\log i)^{-2} \leq d < \infty \quad (d \text{ 与 } n \text{ 无关}). \end{aligned}$$

所以

$$F_n(\beta) \leq d + (\log n)^{2/3}, \quad F_n(\beta)/F_n \rightarrow 0 \quad (n \rightarrow \infty).$$

因此不可能存在 $c > 0$, 使得 $F_n(\beta) \geq cF_n$ 对 $|\beta - \beta_0| \leq F_n^{-1/2}$ 及 n 充分大成立.

这说明定理 2.2 的条件提得太强. 下面往证:

定理 2.2' 若存在 $\delta > 0$, 使当 $n \rightarrow \infty$ 时

$$[(\bar{\lambda}(F_n))^{1/2}/\inf\{\underline{\lambda}(F_n(\beta)); \beta \in N_n(\delta)\}] \rightarrow 0,$$

则定理 2.2 的结论成立.

注意:

1° 由上式有 $\bar{\lambda}^{1/2}(F_n)/\underline{\lambda}(F_n) \rightarrow 0$, 故 $\underline{\lambda}(F_n) \rightarrow \infty$, 即条件(D) 成立.

2° 此条件也可表述为: 存在 $\delta > 0$, 使对任何常数 c , 当 n 充分大时, 有

$$F_n(\beta) \geq c F_n^{1/2} \quad (\beta \in N_n(\delta)).$$

证 由(2.134) 式及上式, 有

$$l_n(\beta) - l_n(\beta_0) < \|\beta - \beta_0\| \|S_n\| - \frac{1}{2} c \bar{\lambda}_n^{1/2} \|\beta - \beta_0\|^2,$$

故

$$\{\sup\{l_n(\beta): \beta \in N_n(\delta) < l_n(\beta_0)\} \supset \left\{ \|S_n\|^2 < \frac{c^2}{4} \delta^2 \right\},$$

其中, n 充分大(因 $\beta \in N_n(\delta) \Rightarrow \bar{\lambda}_n^{1/2} \|\beta - \beta_0\| \geq \delta$). 而因 $E(\|S_n\|^2) = p$,

有 $p\left(\|S_n\|^2 < \frac{c^2}{4} \delta^2\right) > 1 - \eta$, 对任给 $\eta > 0$, 只要取 c 充分大. 由此知 $S_n(\beta) = 0$ 有一解在 $N_n(\delta)$ 内的概率 $\geq 1 - \eta$, 其中, n 充分大, 证毕.

关于在非自然联系下 $\hat{\beta}_n$ 的强相合问题, 在定理 2.7 的条件下可以解决, 只要补充上定理 2.5 的条件 3°, 即: 存在 $\delta > 0$, 使

$$\bar{\lambda}(T_n)^{1/2+\delta} = O(\underline{\lambda}(T_n)), \quad \underline{\lambda}(T_n) \geq c(\bar{\lambda}(T_n))^{1/2+\delta} \quad (c > 0).$$

(2.162)

事实上, 由 $H_n(\beta) = F_n(\beta) - R_n(\beta)$, 以及

$$F_n^{-1/2} H_n(\beta) F_n^{-1/2} = F_n^{-1/2} F_n(\beta) F_n^{-1/2} - F_n^{-1/2} R_n(\beta) F_n^{-1/2},$$

(2.163)

取 β_0 的一个很小的邻域 N , 因为 $\{z_i\}$ 属于紧集, 对充分小的 $\epsilon > 0$ (使 $\|\beta - \beta_0\| \leq \epsilon \Rightarrow \beta \in B^o$, $\{\Sigma(z_i, \beta): i \geq 1\}$ 在集 $V_\epsilon = \{\beta: \|\beta - \beta_0\| \leq \epsilon\}$ 上等度连续, 即 $\beta_1, \beta_2 \in V_\epsilon, \|\beta_1 - \beta_2\| \leq \eta_1 \Rightarrow |\Sigma(z_i, \beta_1) - \Sigma(z_i, \beta_2)| \leq \eta_2 (i \geq 1)$. 给定 $\eta_2 > 0$, 必存在满足上述条件的 $\eta_1 > 0$), 知当 N 取得充分小时, 有

$$\Sigma(z_i, \beta) \geq \frac{1}{2} \Sigma(z_i, \beta_0) \quad (\beta \in N, i \geq 1). \quad (2.164)$$

于是有 $F_n(\beta) \geq \frac{1}{2} F_n, \beta \in N$, 即

$$F_n^{-1/2} F_n(\beta) F_n^{-1/2} \geq \frac{1}{2} I \quad (\beta \in N). \quad (2.165)$$

下面往证:对任给 $\varepsilon_1 > 0$, 存在 β_0 的邻域 N , 使

$$\lim_{n \rightarrow \infty} \sup_{\beta \in N} |F_n^{-1/2} R_n(\beta) F_n^{-1/2}| < \varepsilon_1, \quad \text{a.s.} \quad (2.166)$$

就是说, 存在 y^∞ (y 是 y 的值域, 即 μ 的负荷集) 中的一个零概率集 Q , 使当 $y^\infty = (y_1, y_2, \dots) \in Q$ 时, 有

$$\sup_{\beta \in N} |F_n^{-1/2} R_n(\beta, y^\infty) F_n^{-1/2}| < \varepsilon_1 \quad (n \text{ 充分大}). \quad (2.167)$$

其中, $R_n(\beta, y^\infty)$ 即 $R_n(\beta)$, 突出其与 y^∞ 的关系.

先指出: 若证明了 (2.166) 式, 则证明了 $\hat{\beta}_n$ 的强相结合性. 事实上, 取 $y^\infty \in Q$, 按 (2.167) 式, 对给定的 $\varepsilon_1 > 0$, 存在 $n_1 = n_1(y^\infty)$, 使当 $n \geq n_1$ 时, 有

$$|F_n^{-1/2} R_n(\beta, y^\infty) F_n^{-1/2}| \leq \varepsilon_1 \quad (\text{一切 } \beta \in N).$$

由此在

$$F_n^{-1/2} R_n(\beta, y^\infty) F_n^{-1/2} \leq \varepsilon_1 p I \quad (\text{一切 } \beta \in N, n \geq n_1). \quad (2.168)$$

由 (2.163)、(2.165)、(2.168) 式, 并取 (2.166) 式中的 $\varepsilon_1 = \frac{1}{4p}$, 有

$$F_n^{-1/2} H_n(\beta) F_n^{-1/2} \geq \frac{1}{2} I - \frac{1}{4} I = \frac{1}{4} I \quad (\text{一切 } \beta \in N, n \geq n_1),$$

即 $H_n(\beta) \geq F_n/4$, 一切 $\beta \in N, n \geq n_1$. 因此

$$\inf_{\beta \in N} \lambda_-(H_n(\beta)) \geq \lambda_-(F_n)/4 \quad (n \geq n_1) \quad (2.169)$$

由 $\{z_i\} \subset$ 紧集, 知存在 $0 < c_1 \leq c_2 < \infty$, 使 $c_1 I \leq \Sigma(z_i, \beta_0) \leq c_2 I (i \geq 1)$, 由此知 $c_1 T_n \leq F_n \leq c_2 T_n$, 故由 (2.169) 式得

$$\inf_{\beta \in N} \lambda_-(H_n(\beta)) \geq c_1 \lambda_-(T_n)/4 \quad (n \geq n_1), \quad (2.170)$$

而由 $F_n \leq c_2 T_n$ 得

$$\bar{\lambda}(F_n) \leq c_2 \bar{\lambda}(T_n). \quad (2.171)$$

由 (2.162)、(2.170)、(2.171) 式, 得

$$\inf_{\beta \in N} \lambda_-(H_n(\beta)) \geq c_0 c_1 (\bar{\lambda}(T_n))^{1/2+\delta}/4 \geq c_0 c_1 c_2^{-1/2-\delta} (\bar{\lambda}(F_n))^{1/2+\delta}/4 \quad (n \geq n_1).$$

这证明了条件 (S_δ^*) 满足, 因而证明了 $\hat{\beta}_n \rightarrow \beta_0$, a.s..

现在来证明 (2.166) 式. 回到 (2.77) 式的分解

$$F_n^{-1/2} R_n(\beta) F_n^{-1/2} = \sum_{i=1}^q (B_{nr} + C_{nr}(\beta) + D_{nr}(\beta)),$$

$$B_{nr} = \sum_{i=1}^n \alpha_{ni} (\dot{u}_r(z_i, \beta_0) \alpha_{ni}' (y_{ir} - \mu_{ir}), \quad \alpha_{ni} = F_n^{-1/2} z_i,$$

$$C_{nr}(\beta) = \sum_{i=1}^n \alpha_{ni} (\ddot{u}_r(z_i, \beta) - u_r(z_i, \beta_0)) (y_{ir} - \mu_{ir}),$$

$$D_{nr}(\beta) = \sum_{i=1}^n \alpha_{ni} u_r(z_i' \beta) \alpha_{ni}' (\mu_{ir} - \mu_{ir}(\beta)),$$

其中, $D_{nr}(\beta)$ 非随机, 容易处理. 因为 $\mu_i(\beta) = E_\beta(y_i) = \dot{b}(u(z_i' \beta))$, u 连续而 $\{z_i\} \subset$ 紧集, 知当取 N 充分小时, 对任给的 $\eta > 0$ 将有 $\sup\{|\mu_{ir} - \mu_{ir}(\beta)| : \beta \in N\} \leq \eta$. 又由 u_r 连续, 知存在常数 $M < \infty$, 使 $\|u_r(z_i' \beta)\| \leq M$ 对 $i \geq 1$ 及 $\beta \in N$, 因此

$$\sup_{\beta \in N} \|D_{nr}(\beta)\| \leq M \sum_{i=1}^n \|\alpha_{ni}\|^2 \eta.$$

而 $\{\sum_{i=1}^n \|\alpha_{ni}\|^2, n \geq 1\}$ 有界, 故可取 η 充分小 (相应取 N), 使

$$\sup_{\beta \in N} \|D_{nr}(\beta)\| < \frac{\epsilon_1}{2}. \quad (2.172)$$

以 z_{ij}' 记 z_i 的第 j 行, 则 $G_n \equiv \sum_{i=1}^n z_i(u_r(z_i' \beta)) z_i'(y_{ir} - \mu_{ir})$, 其 (j, k) 元 $G_n(j, k)$ 为

$$\begin{aligned} G_n(j, k) &= \sum_{i=1}^n z_{ij}' u_r(z_i' \beta_0) z_{ik} (y_{ir} - \mu_{ir}) \\ &\equiv \xi_n \equiv \sum_{i=1}^n a_i (y_{ir} - \mu_{ir}). \end{aligned}$$

分两种情况: ① $\sum_{i=1}^{\infty} a_i^2 < \infty$, 这时, 因 $\sup_{i \geq 1} \text{Var}(y_{ir}) < \infty$, 而 $E(y_{ir} - \mu_{ir}) = 0$ ($i \geq 1$), 据周知的定理 (若 $x_1, x_2, \dots$ 独立, $E(x_i) = 0$ ($i \geq 1$) 且 $\sum_{i=1}^{\infty} \text{Var}(x_i) < \infty$,

则 $\sum_{i=1}^{\infty} x_i$, a.s. 收敛) 有 $|\xi_n| = O(1)$, a.s., 而 $|B_{nr}(j, k)| = O(\lambda^{-1}(F_n))$, a.s.;

② $\sum_{i=1}^{\infty} a_i^2 = \infty$. 这时, 因 $\inf_{i \geq 1} \text{Var}(y_{ir}) > 0$ 而有 $V_n \equiv \text{Var}(\xi_n) \rightarrow \infty$, 且因

$\sup_{i \geq 1} \text{Var}(y_{ir}) < \infty$ 及 $\sup_{i \geq 1} \|u_r(z_i' \beta_0)\| < \infty$, 有 $V_n \leq M \sum_{i=1}^n \|z_{ij}\|^2 \|z_{ik}\|^2 \leq M_1 \sum_{i=1}^n \|z_i\|^2 = M_1 \text{tr}(\sum_{i=1}^n z_i z_i') \leq M p \bar{\lambda}_n (M_1 = M(\sup_{i \geq 1} \|z_i\|^2))$. 故按周知的定理:

若 $x_1, x_2, \dots$ 独立, $E(x_i) = 0$, $V_n = \sum_{i=1}^n \text{Var}(x_i) \rightarrow \infty$, 则对任何 $\epsilon > 0$ 有

$(\sum_{i=1}^n x_i)/V_n^{1/2+\varepsilon} \rightarrow 0, \text{ a.s.}$ 因此有 $|G_n(j, k)| = o(\bar{\lambda}_n^{1/2+\delta})$, 因 $F_n \geq c_1 T_n$, $c_1 > 0$, 故 $\underline{\lambda}^{-1}(F_n) \leq c_1^{-1} \underline{\lambda}_n^{-1}$ 再根据 (2.162) 式, 有 $\underline{\lambda}^{-1}(F_n) \leq c_1^{-1} c_0^{-1} (\bar{\lambda}_n)^{-1/2-\delta}$, 于是有

$$|B_{nr}(j, k)| = O(\bar{\lambda}_n^{-1/2-\delta}) o(\bar{\lambda}_n^{1/2+\delta}) = o(1), \text{ a.s.}$$

结合 ① 和 ② 两种情况, 有

$$|B_{nr}| \rightarrow 0, \text{ a.s. } (n \rightarrow \infty). \quad (2.173)$$

最后考虑 $C_{nr}(\beta)$. 在邻域 N 内取足够多的点 $\beta_1, \dots, \beta_m$, 使对任何 $\beta \in N$, 必存在 β_j 使 $\|\beta - \beta_j\| \leq \eta_1$, η_1 取得充分小, 使对给定的 $\eta_2 > 0$, 有

$$\beta_1, \beta_2 \in N, \|\beta_1 - \beta_2\| \leq \eta_1 \Rightarrow \|u_r(z_i, \beta_1) - u_r(z_i, \beta_2)\| \leq \eta_2 \quad (i \geq 1). \quad (2.174)$$

任取 $\beta \in N$, 找 $\beta_j \equiv \tilde{\beta}$, 使 $\|\beta - \beta_j\| \leq \eta_1$, 有

$$C_{nr}(\beta) = C_{nr}(\beta_j) + (C_{nr}(\beta) - C_{nr}(\tilde{\beta})) \equiv J_{1n}(\beta) + J_{2n}(\beta) \quad (2.175)$$

以及

$$\sup_{\beta \in N} |J_n(\beta)| = \max_{1 \leq j \leq m} |J_{1n}(\beta_j)|.$$

而对每个固定的 j , 按处理 B_{nr} 的方法得 $J_{1n}(\beta_j) \rightarrow 0, \text{ a.s.}$ 于是有

$$\sup_{\beta \in N} |J_{1n}(\beta)| \rightarrow 0, \text{ a.s. } (n \rightarrow \infty). \quad (2.176)$$

以 w_{nj}' 记 $F_n^{-1/2}$ 的第 j 行, 则 $J_{2n}(\beta)$ 的 (j, k) 元, 记为 $J_{2nj}(\beta)$, 有

$$\begin{aligned} |J_{2nj}(\beta)| &\leq \left| \sum_{i=1}^n w_{nj}' z_i (u_r(z_i, \beta) - u_r(z_i, \tilde{\beta})) z_i' w_{nk} (y_{ir} - \mu_{ir}) \right| \\ &\leq \sum_{i=1}^n |w_{nj}' z_i (u_r(z_i, \beta) - u_r(z_i, \tilde{\beta})) z_i' w_{nk}| |y_{ir} - \mu_{ir}|. \end{aligned}$$

由 $\|\beta - \tilde{\beta}\| \leq \eta_1$, 由 (2.174) 式有

$$\begin{aligned} |w_{nj}' z_i (u_r(z_i, \beta) - u_r(z_i, \tilde{\beta})) z_i' w_{nk}| &\leq \eta_2 \|w_{nj}' z_i\| \|w_{nk}' z_i\| \\ &\leq \frac{\eta_2}{2} (\|w_{nj}' z_i\|^2 + \|w_{nk}' z_i\|^2). \end{aligned}$$

故有

$$\begin{aligned} |J_{2nj}(\beta)| &\leq \eta_2 (w_{nj}' \sum_{i=1}^n z_i z_i' |y_{ir} - \mu_{ir}| w_{nj} + w_{nk}' \sum_{i=1}^n z_i z_i' |y_{ir} - \mu_{ir}| w_{nk}) \\ &\equiv \eta_2 (D_{nj} + D_{nk}). \end{aligned} \quad (2.177)$$

记 $a_i = E(|y_{ir} - \mu_{ir}|)$, $\xi_i = |y_{ir} - \mu_{ir}| - a_i$, 有 $\sup_{i \geq 1} a_i \equiv H < \infty$, 而

$$D_{nj} = w_{nj}' \sum_{i=1}^n z_i z_i' a_i w_{nj} + w_{nj}' \sum_{i=1}^n z_i z_i' \xi_i w_{nj} \equiv D_{nj1} + D_{nj2}, \quad (2.178)$$

$$\begin{aligned} D_{nj1} &\leq H \sum_{i=1}^n \|z_i' w_{nj}\|^2 \leq H \sum_{i=1}^n \|z_i' F_n^{-1/2}\|^2 \\ &= H \sum_{i=1}^n \text{tr}(F_n^{-1/2} z_i z_i' F_n^{-1/2}) = H \text{tr}(F_n^{-1/2} T_n F_n^{-1/2}). \end{aligned}$$

因 $T_n \leq c_1^{-1} F_n$, 有

$$D_{nj1} \leq H c_1^{-1} p, \quad (2.179)$$

现考虑 $\sum_{i=1}^n z_i z_i' \xi_i$, 取 $z_i z_i'$ 的 (j, k) 元, 记为 f_i , 则

$$\alpha_n \equiv \sum_{i=1}^n z_i z_i' \xi_i \text{ 的 } (j, k) \text{ 元} = \sum_{i=1}^n f_i \xi_i.$$

因 $E(\xi_i) = 0$, $\sup_{i \geq 1} \text{Var}(\xi_i) \equiv H_1 < \infty$, 分两种情况: ① $\sum_{i=1}^{\infty} f_i^2 < \infty$. 这时 $\sum_{i=1}^n f_i \xi_i$,

a.s. 收敛, 有 $\alpha_n = O(1)$, a.s.; ② $\sum_{i=1}^{\infty} f_i^2 = \infty$. 因 $f_i^2 \leq \|z_i\|^2$, 有 $\sum_{i=1}^n f_i^2 \leq$

$$\sum_{i=1}^n \|z_i\|^2 = \sum_{i=1}^n \text{tr}(z_i z_i') = \text{tr}(T_n) \leq p \bar{\lambda}_n, \text{ 而 } \text{Var}(\alpha_n) \leq p \bar{\lambda}_n H_1. \text{ 按周知的定}$$

理: “若 $x_1, x_2, \dots$ 独立, $E(x_i) = 0$, $V_n \equiv \sum_{i=1}^n \text{Var}(x_i) \rightarrow \infty$, 则 $\sum_{i=1}^n x_i / V_n^{1/2+\delta} \rightarrow 0$, a.s., 对任何 $\delta > 0$ ”, 得

$$\alpha_n / \bar{\lambda}_n^{1/2+\delta/2} \rightarrow 0, \quad \text{a.s.}$$

由此式及 (2.162) 式, 得 $\alpha_n / \underline{\lambda}_n \rightarrow 0$, a.s., 但由 $T_n \leq c_1^{-1} F_n$, 知 $\underline{\lambda}_n \leq c_1^{-1} \underline{\lambda}(F_n)$, 故有 $\alpha_n / \underline{\lambda}(F_n) \rightarrow 0$. 结合 ① 和 ② 两种情况, 有 $\alpha_n = o(\underline{\lambda}(F_n))$,

a.s., 由此得 $\sum_{i=1}^n z_i z_i' \xi_i = o(\underline{\lambda}(F_n))$, a.s., 因而

$$\begin{aligned} D_{nj2} &= w_{nj}' \sum_{i=1}^n z_i z_i' \xi_i w_{nj} \\ &= O(\underline{\lambda}^{-1/2}(F_n)) o(\underline{\lambda}(F_n)) O(\underline{\lambda}^{-1/2}(F_n)) \\ &= o(1), \quad \text{a.s.} \end{aligned} \quad (2.180)$$

结合 (2.177) ~ (2.180) 式, 得

$$\lim_{n \rightarrow \infty} (\sup_{\beta \in N} |J_{2nj}(\beta)|) \leq 2\eta_2 H c_1^{-1} p < \epsilon_1/2 \quad (\text{取 } \eta_2 > 0 \text{ 充分小, 相应取 } \eta_1).$$
(2.181)

这对任何 (j, k) 成立, 因此

$$\limsup_{n \rightarrow \infty} (\sup_{\beta \in N} |J_{2n}(\beta)|) < \epsilon_1/2, \quad \text{a.s..}$$
(2.182)

由(2.175)、(2.176) 和(2.182) 式, 得

$$\limsup_{n \rightarrow \infty} (\sup_{\beta \in N} |C_n(\beta)|) < \epsilon_1/2, \quad \text{a.s..}$$
(2.183)

结合(2.172)、(2.173) 和(2.182) 式, 得(2.166) 式. 于是完成了证明.

第 3 章

GLM 参数的假设检验

应用上常见的情况是关于 β 的线性假定

$$H: C\beta_0 = a \leftrightarrow K: C\beta_0 \neq a, \quad (3.1)$$

其中, β_0 为 p 维, C 为已知的 $r \times p$ 常数矩阵, 假定 C 为行满秩, 即其各行线性无关(不然可去掉 C 的若干行), 故 $r \leq p$, a 为已知的 r 维常向量. 例如若记 $\beta_0 = (\beta_{01}, \dots, \beta_{0p})'$ 而 $r \leq p$, 则假设 $\beta_{0j} = a_j (j = 1, \dots, r)$, 可记为 $(I_r \ 0)\beta_0 = a$.

3.1 Wald 检验

检验统计量为

$$W_n = (C\hat{\beta}_n - a)'(C\hat{\Omega}_n C')^{-1}(C\hat{\beta}_n - a), \quad (3.2)$$

这里 $\hat{\beta}_n$ 为 β_0 的 MLE 或 QMLE, $\hat{\Omega}_n$ 是 $\hat{\beta}_n$ 的协方差阵 Ω_n 的估计. W_n 的直观意义明显: 当 n 充分大时, $\hat{\beta}_n \approx \beta_0$. 故当原假设 H 成立时, $C\hat{\beta}_n \approx C\beta_0 = a$, 因而 W_n 倾向于取小值. 反之若 H 不成立, 则 W_n 倾向于取大值. 故一个合理的检验, 是当

$$W_n > c_n \quad (3.3)$$

时否定 H , 当 $W_n \leq c_n$ 时接受 H , c_n 依检验的水平而定.

为决定 c_n , 要求出在 H 成立时 W_n 的分布, 这难于做到而只能满足于当

$n \rightarrow \infty$ 时 W_n 的渐近分布. 可以证明: 在一定的条件下, 当 H 成立时, 有

$$W_n \xrightarrow{d} \chi_r^2, \quad (3.4)$$

其中, χ_r^2 是自由度 r 的中心 χ^2 分布(图 3.1), 按这个结果, 可以把(3.3)式中的常数 c_n 定义为

$$c_n = \chi_r^2(\alpha), \quad (3.5)$$

其中, $0 < \alpha < 1$, α 为给定的检验水平. $\chi_r^2(\alpha)$ 为分布 χ_r^2 的上 α 分位点.

检验(3.4)式, 其 c_n 由(3.5)式给出, 当 n 固定时其水平(犯第一类错误(弃真)的概率)将与给定的 α 有些差距, 但随着 $n \rightarrow \infty$, 这差距将 $\rightarrow 0$. 有时称这检




图 3.1 曲线为 χ_r^2 的密度函数

验有“渐近水平” α .

(3.4) 式证明的梗概如下: 首先, 按上一章的理论, 在一定的条件下有

$$\hat{\beta}_n \text{ 的分布接近 } N(\beta_0, \Omega_n), \quad (3.6)$$

故 $C\hat{\beta}_n - a = C(\hat{\beta}_n - \beta_0)$ 的分布接近 $N(0, C\Omega_n C')$. 据周知的结果:

$$X \text{ 有分布 } N(0, V), V > 0 \Rightarrow X'V^{-1}X \text{ 有分布 } \chi_r^2, \quad (3.7)$$

其中, r 为 X 的维数. 因此, 若近似地把 $C(\hat{\beta}_n - \beta_0)$ 的分布看成是 $N(0, C\Omega_n C')$, 则据 (3.7) 式, 将有

$$(C\hat{\beta}_n - a)'(C\Omega_n C')^{-1}(C\hat{\beta}_n - a) \approx \chi_r^2, \quad \text{当 } H \text{ 成立时,}$$

其中, r 是 C 的行数, 即 C 的秩. 由于 $C\hat{\beta}_n - a$ 的分布只是渐近于而非严格等于 χ_r^2 , 上式改为: 当 H 成立且 $n \rightarrow \infty$ 时, 有

$$(C\hat{\beta}_n - a)'(C\Omega_n C')^{-1}(C\hat{\beta}_n - a) \xrightarrow{d} \chi_r^2, \quad (3.8)$$

其中, $\hat{\Omega}_n$ 是 Ω_n 的估计. 如果它相合, 则 $\hat{\Omega}_n$ 当 n 大时接近 Ω_n . 于是, 在一定的条件下, 可以用 $\hat{\Omega}_n$ 取代 (3.8) 式中的 Ω_n , 这就得到 (3.4) 式.

下面我们来审视一下 (3.4) 式的严格证明, 从中可带出所需的条件.

首先, $\hat{\beta}_n$ 渐近正态的条件已在上一章仔细列出, 在此需全部移植过来. 在这些条件下, 有

$$\xi_n = A_n(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I), \quad (3.9)$$

其中, A_n 为一对称满秩方阵. (3.6) 式的 Ω_n 为 A_n^{-2} . 在 2.1 和 2.2 两节讨论的情况 ($\hat{\beta}_n$ 不是 QMLE), 有 $A_n = F_n^{1/2}$ ($F_n = F_n(\beta_0)$, 参见 (2.20) 式). 有

$$C(\hat{\beta}_n - \beta_0) = CA_n^{-1}A_n(\hat{\beta}_n - \beta_0) = CA_n^{-1}\xi_n.$$

记 $D_n = A_n^{-1}C'(CA_n^{-1} \cdot A_n^{-1}C')^{-1}CA_n^{-1}$. D_n 是一个投影阵 (注意因 A_n 对称, $(A_n^{-1})' = A_n^{-1}$), 秩为 r . 由此及 (3.9) 式, 知 $\xi_n'D_n\xi_n \xrightarrow{d} \chi_r^2$, 即

$$[C(\hat{\beta}_n - \beta_0)]'[CA_n^{-2}C']^{-1}[C(\hat{\beta}_n - \beta_0)] \xrightarrow{d} \chi_r^2,$$

这证明了 (3.8) 式.

由 (3.8) 式过渡到 (3.4) 式需要一定的条件. 例如:

条件 A 对任给 $\varepsilon > 0, \eta > 0$, 存在 $n(\varepsilon, \eta)$, 使当 $n \geq n(\varepsilon, \eta)$ 时, 以不小于 $1 - \eta$ 的概率成立

$$-\varepsilon(C\Omega_n C')^{-1} \leq (C\hat{\Omega}_n C')^{-1} - (C\Omega_n C')^{-1} \leq \varepsilon(C\Omega_n C')^{-1}. \quad (3.10)$$

此处 $\geq$ 是按正定的意义, 即 $(1 - \epsilon)(C\Omega_n C')^{-1} \leq (C\hat{\Omega}_n C')^{-1} \leq (1 + \epsilon)(C'\Omega_n C)^{-1}$.

证明简单. 由(3.10)式有: 当 $n \geq n(\epsilon, \eta)$ 时, 以概率不小于 $1 - \eta$ 成立

$$\begin{aligned} & |(C(\hat{\beta}_n - \beta_0))'(C\hat{\Omega}_n C')^{-1} C(\hat{\beta}_n - \beta_0) - (C(\hat{\beta}_n - \beta_0))'(C\Omega_n C')^{-1} C(\hat{\beta}_n - \beta_0)| \\ & \leq \epsilon (C(\hat{\beta}_n - \beta_0))'(C\Omega_n C')^{-1} C(\hat{\beta}_n - \beta_0). \end{aligned} \quad (3.11)$$

由(3.8)式, 有

$$(C(\hat{\beta}_n - \beta_0))'(C\Omega_n C')^{-1} C(\hat{\beta}_n - \beta_0) = O_p(1).$$

由此式与(3.11)式以及 $\epsilon > 0, \eta > 0$ 可任意小, 即得

$$\begin{aligned} & (C(\hat{\beta}_n - \beta))'(C\hat{\Omega}_n C')^{-1} C(\hat{\beta}_n - \beta_0) \\ & = (C(\hat{\beta}_n - \beta_0))'(C\Omega_n C')^{-1} C(\hat{\beta}_n - \beta_0) + o_p(1). \end{aligned}$$

因此, $(C(\hat{\beta}_n - \beta_0))'(C\hat{\Omega}_n C')^{-1} C(\hat{\beta}_n - \beta_0)$ 与 $(C(\hat{\beta}_n - \beta_0))'(C\Omega_n C')^{-1} C(\hat{\beta}_n - \beta_0)$ 有相同的极限分布. 由此及(3.8)式, 得到(3.4)式.

条件A的验证在一般情况下是复杂的. 在若干特殊情况下可以得到验证. 例如, 在定理2.5~2.8的条件下, 可以证明条件A成立(其中 Ω_n 被 F_n^{-1} 取代, $\hat{\Omega}_n$ 被 $F_n^{-1}(\hat{\beta}_n)$ 取代).

对 $\hat{\beta}_n$ 为 QMLE 的情况, 若工作分布为指数族, 则 F_n 仍可用 $F_n(\hat{\beta}_n)$ 去估计 ((2.106) 式中的 V_n 为已给定, 不需估计). 可以证明, 在定理2.13~2.16的条件下, 条件A仍满足.

这样, 在上面所指的情况及其相应的条件下, Wald 统计量 W_n 在原假设下的极限分布定理(3.4)得以严格建立.

对于最一般情况下的 QMLE, 由于每个样本的协方差阵 Σ_i 可以任意, 一般它们无法用样本去估计, 但我们的目的是估计(2.106)式中的 V_n 而非个别的 Σ_i , 这有时最可以做到的. 例如, (2.106) 式中的 $F_n^{-1/2} V_n F_n^{-1/2}$ 可用

$$F_n^{-1/2}(\hat{\beta}_n) \left(\sum_{i=1}^n z_i (y_i - \hat{\mu}_i) (y_i - \hat{\mu}_i)' z_i' \right) F_n^{-1/2}(\hat{\beta}_n)$$

去估计, 其中, $\hat{\mu}_i$ 为 $\mu_i = E(y_i) = h(z_i' \beta_0)$ 之估计:

$$\hat{\mu}_i = h(z_i' \hat{\beta}_n).$$

3.2 约束检验

考虑样本服从指数族分布的情况,以 $l_n(\beta)$ 记对数似然函数. 把原假设 $H: C\beta_0 = a$ 看作是对 β_0 的约束. 在这个约束下求 $l_n(\beta)$ 的极大点 $\tilde{\beta}_n$. 可视为 β_0 的在约束 $C\beta = a$ 之下的 MLE. 利用 $\tilde{\beta}_n$ 建立检验统计量

$$\omega_n = S_n'(\tilde{\beta}_n)F_n^{-1}(\tilde{\beta}_n)S_n(\tilde{\beta}_n), \quad S_n(\beta) = \partial l_n(\beta)/\partial \beta, \quad (3.12)$$

(因 $\hat{\beta}_n$ 为全局极值点, 若 $\hat{\beta}_n$ 满足约束, 则也是约束下的极值点, 即 $\hat{\beta}_n = \tilde{\beta}_n$) 并且当

$$\omega_n > c_n \quad (3.13)$$

时否定原假设.

统计量的直观背景很清楚: 因 $S_n(\beta) = \partial l_n(\beta)/\partial \beta$, 按 MLE $\hat{\beta}_n$ 的定义, 有 $S_n(\hat{\beta}_n) = 0$. 现 $\tilde{\beta}_n$ 为约束下的 MLE, 它会与无约束下的 MLE $\hat{\beta}_n$ 有差异. 但因 $\hat{\beta}_n \approx \beta_0$, 故若原假设成立, 即 β_0 满足约束, 则 $\hat{\beta}_n$ 也接近于满足约束, 而这意味着 $\tilde{\beta}_n$ 与 $\hat{\beta}_n$ 将接近, 因而 $S_n(\tilde{\beta}_n) \approx S_n(\hat{\beta}_n) = 0$, 故 ω_n 将倾向于取小值. 若原假设不成立, 则 $S_n(\tilde{\beta}_n)$ 将与 $S_n(\hat{\beta}_n)$ 有较大的差别, 而 ω_n 将倾向于取大值. 这表明了检验(3.13)式直观上的合理性.

往下将证明: 在一定的条件下, 当原假设成立时, 有

$$\omega_n \xrightarrow{d} \chi_r^2 \quad (n \rightarrow \infty), \quad (3.14)$$

其中, r 的意义同前, 即 C 为 $r \times p$ 的矩阵, 秩 r . 先考虑一个特例:

$$C = (I_r : 0) \quad (3.15)$$

即若把 β_0 表示为 $\beta_0 = (\beta_{(1)}' : \beta_{(2)}')$, $\beta_{(1)}$ 为 r 维, 则原假设有形式

$$\beta_{(1)} = a. \quad (3.16)$$

记

$$S_n(\beta) = \begin{bmatrix} S_{(1)}(\beta) \\ S_{(2)}(\beta) \end{bmatrix} = \begin{bmatrix} \partial l_n(\beta)/\partial \beta_{(1)} \\ \partial l_n(\beta)/\partial \beta_{(2)} \end{bmatrix}, \quad \tilde{\beta}_n = \begin{bmatrix} \tilde{\beta}_{(1)} \\ \tilde{\beta}_{(2)} \end{bmatrix},$$

则显然 $\beta_{(1)} = a$ (因约束(3.16)式已给出 $\beta_{(1)} = a$), 而 $\beta_{(2)}$ 则满足

$$S_{(2)} \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} = 0.$$

记

$$F_n = \begin{pmatrix} F(1,1) & F(1,2) \\ F(2,1) & F(2,2) \end{pmatrix}, \quad F(1,1) \text{ 为 } r \text{ 阶方阵.}$$

有

$$\begin{aligned} S_{(1)} \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} &= S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} + \left\{ S_{(1)} \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} - S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} \right\} \\ &= S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} + \left[\partial S_{(1)} \begin{bmatrix} a \\ \beta_{(2)}^* \end{bmatrix} / \partial \beta_{(2)}' \right] \cdot (\tilde{\beta}_{(2)} - \beta_{(2)}) \\ &\approx S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} - F(1,2)(\tilde{\beta}_{(2)} - \beta_{(2)}), \beta_{(2)}^* \in \overline{\beta_{(2)} \tilde{\beta}_{(2)}}. \quad (3.17) \end{aligned}$$

这一步就用了一些条件: 首先是需要 $\tilde{\beta}_{(2)} \approx \beta_{(2)}$. 在已定了 $\beta_{(1)} = a$ 后, 原参数 β_0 缩为 $\beta_{(2)}$, 其 MLE 即 $\tilde{\beta}_{(2)}$. 在上一章有关定理的条件下, $\tilde{\beta}_{(2)}$ 为 $\beta_{(2)}$ 的相合估计, 当 n 充分大时二者能接近. 这样一来, 可以近似地用 $\partial S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} / \partial \beta_{(2)}'$ 取代 $\partial S_{(1)} \begin{bmatrix} a \\ \beta_{(2)}^* \end{bmatrix} / \partial \beta_{(2)}$. 然后, 再进一步, 用 $-F(1,2)$ 取代 $\partial S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} / \partial \beta_{(2)}$ 得 (3.17) 式. 这后一取代就有条件. 因为按 (2.75) 式, $\partial S_{(1)} \begin{bmatrix} a \\ \beta_{(2)} \end{bmatrix} / \partial \beta_{(2)}$ 本是 $-H_n(\beta_0)$ 的右上块. 今以 $-F_n(\beta_0)$ 即 $-F_n$ 的右上块代之, 必须 $R_n(\beta_0)$ 的右上块当 n 大时, 可忽略不计.

因为 $S_n(\beta_0) = \begin{bmatrix} S_{(1)}(\beta_0) \\ S_{(2)}(\beta_0) \end{bmatrix}$ 的协方差阵为 F_n , 知

$$\text{Cov}(S_{(1)}(\beta_0)) = F(1,1), \quad (3.18)$$

且

$$\text{Cov}(\tilde{\beta}_{(2)}) \approx (F(2,2))^{-1}, \quad (3.19)$$

此式是因为:在 β_0 因约束 $\beta_{(1)} = a$ 而缩小为 $\beta_{(2)}$ 的模型里, F_n 的位置由 $F(2,2)$ 所取代. 按上一章有关定理, 在一定的条件下有

$$(F(2,2))^{1/2}(\tilde{\beta}_{(2)} - \beta_{(2)}) \xrightarrow{d} N(0, I).$$

故 $\tilde{\beta}_{(2)}$ 的渐近协方差阵为 $(F(2,2))^{-1}$, 即(3.19)式. 按(2.50)式, (2.50)式是在自然联系下得到, 只要相应的条件满足, 它对非自然联系也成立. 参看第2章有关部分), 并注意到在参数 β'_0 缩小为 $\beta_{(2)}$ 的模型中, (2.50)式中的 F_n 和 S_n 分别为 $F(2,2)$ 和 $S_{(2)}(\beta_0)$ 所取代, 得

$$\tilde{\beta}_{(2)} - \beta_{(2)} \approx (F(2,2))^{-1} S_{(2)}(\beta_0). \quad (3.20)$$

于是有

$$\begin{aligned} E(S_{(1)}(\beta_0)(\tilde{\beta}_{(2)} - \beta_{(2)})') &\approx E(S_{(1)}(\beta_0)S_{(2)}'(\beta_0))(F(2,2))^{-1} \\ &= F(1,2)(F(2,2))^{-1}. \end{aligned}$$

而由(3.20)式有

$$\text{Cov}(F(1,2)(\tilde{\beta}_{(2)} - \beta_{(2)})) \approx F(1,2)(F(2,2))^{-1}F(2,1). \quad (3.21)$$

由(3.17)式及其以下诸式, 有

$$\text{Cov}(S_{(1)}(\tilde{\beta}_n)) \approx F(1,1) - F(1,2)(F(2,2))^{-1}F(2,1) \equiv M \quad (3.22)$$

按(3.7)(取其渐近形式), 有

$$S_{(1)}' \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} M^{-1} S_{(1)} \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} \xrightarrow{d} \chi_r^2. \quad (3.23)$$

当 $n \rightarrow \infty$ 且原假设成立时(注意 $\tilde{\beta}_{(2)}$ 的定义及其性质都是在 $\beta_{(1)} = a$ 之下说的)(3.23)式成立. 因为按分(四)块方阵求逆的公式

$$\begin{aligned} F_n^{-1} &= \begin{pmatrix} F(1,2) & F(2,2) \\ F(2,1) & F(2,2) \end{pmatrix}^{-1} = \begin{pmatrix} M & * \\ * & * \end{pmatrix}, \\ S_n(\tilde{\beta}_n) &= \begin{bmatrix} S_{(1)} \begin{bmatrix} a \\ \tilde{\beta}_{(1)} \end{bmatrix} \\ S_{(2)} \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} \end{bmatrix} = \begin{bmatrix} S_{(1)} \begin{bmatrix} a \\ \tilde{\beta}_{(2)} \end{bmatrix} \\ 0 \end{bmatrix}, \end{aligned}$$

知(3.23)式可写为 $\left[\text{注意 } S_n(\hat{\beta}_n) = \begin{bmatrix} S_n(\tilde{\beta}_{(1)}) \\ S_n(\tilde{\beta}_{(2)}) \end{bmatrix} = \begin{bmatrix} S_n(\tilde{\beta}_{(2)}) \\ \mathbf{0} \end{bmatrix} \right]$

$$S_n'(\tilde{\beta}_n)F_n^{-1}S_n(\tilde{\beta}_n) \xrightarrow{d} \chi_r^2. \quad (3.24)$$

又因 $\tilde{\beta}_n \approx \beta_0$, 在一定的条件下, (3.24) 式中的 $F_n^{-1} = F_n^{-1}(\beta_0)$ 可以用 $F_n^{-1}(\tilde{\beta}_n)$ 取代. 这一取代得到 (3.14) 式.

以上对 C 有 (3.15) 式的形式的特例证明了 (3.14) 式. 一般情况容易化到此特例: 因 $C = (c_{ij})$ 有秩 r , 不失普遍性不妨设 C 的前 r 列 c_{11} 构成一个 r 阶满秩方阵. 令 (注意 $C = (c_{11} \quad c_{12})$)

$$D = \begin{bmatrix} C_{11} & C_{12} \\ O & I_{p-r} \end{bmatrix}, \quad C_{11} \text{ 为 } r \text{ 阶方阵, } \det(C_{11}) \neq 0,$$

则 p 阶方阵 D 为满秩的, 作变换

$$r_0 = \begin{bmatrix} \gamma_{(1)} \\ \gamma_{(2)} \end{bmatrix} = D\beta_0 \equiv D \begin{bmatrix} \beta_{(1)} \\ \beta_{(2)} \end{bmatrix} = \begin{bmatrix} C\beta_0 \\ \beta_{(2)} \end{bmatrix}.$$

于是原假设 $C\beta_0 = a$, 在新参数 γ_0 之下变为 $\gamma_{(1)} = a$, 即我们已讨论过的情况. 线性预测子 $z_i'\beta$ 则有

$$z_i'\beta = z_i'D^{-1}D\beta \equiv W_i'\gamma$$

的形状, $W_i = D^{-1}z_i$. 加在 $\{z_i\}$ 上的条件 (如 $\{z_i\}$ 有界), 对 $\{W_i\}$ 仍成立. 于是由已证的结果得出, (3.14) 式对一般的 C 成立.

要把以上的证明弄得完全严格, 就必须: ① 把证明中使用的结果的条件写下来. 例如用到 $\tilde{\beta}_{(2)}$ 渐近正态; ② 把证明中“近似相等” ($\approx$) 的地方改成严格的表述. 这不一定是通过补上剩余项以使近似相等成为严格相等. (3.21) 式就是一个例子. 对这个式子, 因 $\tilde{\beta}_{(2)}$ 的协方差阵存在与否尚是问题, 故无法从协方差阵的角度去修改. 正式的证明还要回到渐近正态性上去处理 (即证明 (3.17) 式右边为渐近正态以避免协方差阵). 严格的证明虽繁冗, 并无多少实质困难, 在此不展开叙述. 只指出: 在上一章讨论的特殊情况 ($\{z_i\}$ 有界及 $\{Y_i\}$ 有界以及有关的条件下, (3.14) 式成立.

在 (3.14) 式的基础上, 可以把 (3.13) 式中的常数 c_n 取为 $\chi_{r,2}^2(\alpha)$, 它使检验 (3.13) 式有渐近水平 α .

3.3 似然比检验

仍以 $l_n(\beta)$ 记对数似然函数, $\hat{\beta}_n$ 和 $\tilde{\beta}_n$ 分别记不受约束的 MLE 和在原假设 $C\beta_0 = a$ 约束下的 MLE. 检验统计量为对数似然比(乘 2 倍):

$$\lambda_n = 2[l_n(\hat{\beta}_n) - l_n(\tilde{\beta}_n)]. \quad (3.25)$$

因 $l_n(\hat{\beta}_n)$ 为 $l_n(\beta)$ 的最大值, 总有 $\lambda_n \geq 0$. 若原假设成立, 则如前节所指出, $\tilde{\beta}_n$ 将与 $\hat{\beta}_n$ 接近, 而 λ_n 倾向于取小值, 否则就倾向于取大值. 因此, 取

$$\lambda_n > c_n \quad (3.26)$$

为检验的否定域, 此即似然比检验, 可以证明: 在一定的条件下, 当原假设成立时, 有

$$\lambda_n \xrightarrow{d} \chi_r^2 \quad (n \rightarrow \infty). \quad (3.27)$$

证明的梗概如下: 把 $l_n(\tilde{\beta}_n)$ 在 $\hat{\beta}_n$ 点处作 Taylor 展开. 由于 $\frac{\partial l_n(\hat{\beta}_n)}{\partial \beta} = 0$, 有 (此式严格讲不正确, 可使用积分公式)

$$l_n(\tilde{\beta}_n) - l_n(\hat{\beta}_n) = (\hat{\beta}_n - \tilde{\beta}_n)' \left(\frac{1}{2} l_n(\beta_n^*) \right) (\hat{\beta}_n - \tilde{\beta}_n) \quad (\beta_n^* \in \overline{\hat{\beta}_n \tilde{\beta}_n}).$$

当 n 充分大时, $\hat{\beta}_n$ 和 $\tilde{\beta}_n$ 接近 β_0 , 因而 β_n^* 充分接近 β_0 , 故上式中的 β_n^* 可近似地用 β_0 取代, 接 (2.75) 式, 若 $R_n(\beta_0)$ 可以忽略不计, 则 $l_n(\beta_0)$ 又可近似地以 $F_n(\beta_0)$ 即 F_n 所取代, 于是有

$$\lambda_n \approx (\hat{\beta}_n - \tilde{\beta}_n)' F_n (\hat{\beta}_n - \tilde{\beta}_n). \quad (3.28)$$

记

$$F_n^{-1} = \begin{bmatrix} \bar{F}_{11} & \bar{F}_{12} \\ \bar{F}_{21} & \bar{F}_{22} \end{bmatrix}, \quad S_n(\beta_0) = \begin{bmatrix} S_{(1)} \\ S_{(2)} \end{bmatrix}, \quad \bar{F}_{11} \text{ 为 } r \times r, S_{(1)} \text{ 为 } r \text{ 维},$$

则近似地有

$$\hat{\beta}_n - \beta_0 \approx F_n^{-1} S_n = \begin{bmatrix} \tilde{F}_{11} S_{(1)} + \tilde{F}_{12} S_{(2)} \\ \tilde{F}_{21} S_{(1)} + \tilde{F}_{22} S_{(2)} \end{bmatrix}.$$

仍如前节,先考虑原假设有 $\beta_{(1)} = a$ 的情况, $\beta_0 = \begin{bmatrix} \beta_{(1)} \\ \beta_{(2)} \end{bmatrix}$. 则在前节已指出(参看(3.20)式)

$$\tilde{\beta}_n - \beta_0 \approx \begin{bmatrix} 0 \\ (F(2,2))^{-1} S_{(2)} \end{bmatrix} \quad (F(2,2) \text{ 的意义同 3.2 节}).$$

于是有

$$\begin{aligned} \hat{\beta}_n - \tilde{\beta}_n &= (\hat{\beta}_n - \beta_0) - (\tilde{\beta}_n - \beta_0) \\ &\approx \begin{bmatrix} \tilde{F}_{11} S_{(1)} + \tilde{F}_{12} S_{(2)} \\ \tilde{F}_{21} S_{(1)} + (\tilde{F}_{22} - (F(2,2))^{-1}) S_{(2)} \end{bmatrix} \\ &\equiv MS_n, \\ M &= \begin{bmatrix} \tilde{F}_{11} & \tilde{F}_{12} \\ \tilde{F}_{21} & \tilde{F}_{22} - (F(2,2))^{-1} \end{bmatrix}. \end{aligned}$$

而(3.28)式可改写为

$$\lambda_n \approx S_n' MF_n MS_n = (F_n^{-1/2} S_n)' F_n^{1/2} MF_n MF_n^{1/2} (F_n^{-1/2} S_n).$$

因 $F_n^{-1/2} S_n \xrightarrow{d} N(0, I)$, 为证(3.27)式, 只需证 $F_n^{1/2} MF_n F_n^{1/2}$ 为幂等阵且秩为 r :

$$F_n^{1/2} MF_n MF_n^{1/2} \cdot F_n^{1/2} MF_n MF_n^{1/2} = F_n^{1/2} MF_n MF_n^{1/2}, \quad (3.29)$$

$$\text{rank}(F_n^{1/2} MF_n MF_n^{1/2}) = r,$$

$$MF_n = \begin{bmatrix} \tilde{F}_{11} F_{11} + \tilde{F}_{12} F_{12} & \tilde{F}_{11} F_{21} + \tilde{F}_{12} F_{22} \\ \tilde{F}_{21} F_{11} + \tilde{F}_{22} F_{21} - (F(2,2))^{-1} F_{21} & \tilde{F}_{21} F_{12} + \tilde{F}_{22} F_{22} - (F(2,2))^{-1} F_{22} \end{bmatrix}. \quad (3.30)$$

而(3.29)式和(3.30)式分别等价于

$$MF_n MF_n MF_n M = MF_n M \quad (3.31)$$

和

$$\text{rank}(MF_n M) = r. \quad (3.32)$$

利用

$$I = F_n^{-1} F_n = \begin{bmatrix} \tilde{F}_{11} F(1,1) + \tilde{F}_{12} F(2,1) & \tilde{F}_{11} F(1,2) + \tilde{F}_{12} F(2,2) \\ \tilde{F}_{21} F(1,1) + \tilde{F}_{22} F(2,1) & \tilde{F}_{21} F(1,2) + \tilde{F}_{22} F(2,2) \end{bmatrix} = \begin{bmatrix} I_r & O \\ O & I_{p-r} \end{bmatrix},$$

易算得

$$MF_n = \begin{pmatrix} I & 0 \\ -(F(2,2))^{-1}F(2,1) & 0 \end{pmatrix}. \quad (3.33)$$

而易验证上式右边的方阵为幂等. 故 $MF_n = (MF_n)^3$, 而

$$(MF_n)^3 M = MF_n M \quad (\text{即(3.31)式}),$$

又由(3.33)式知 $\text{rank}(MF_n) = r$, 故 $\text{rank}(MF_n MF_n) = r$ (因 $(MF_n)^2 = MF_n$), 而 F_n 为满秩, 故得 $\text{rank}(MF_n M) = r$, 即(3.32)式.

与3.2节一样, 一般原假设容易转化为 $\beta_{(1)} = a$ 的特例.

为将上述证明严格化, 所涉及的问题与前面两个检验类似. 可以证明: 在上一章讨论的特殊情况 ($\{z_i\}$ 或 $\{Y_i\}$ 有界), 在各自有关的条件下, (3.27) 式成立.

我们注意到: 所讨论的3个检验统计量出发点不同, 形状不同, 但其渐近分布却相同. 这初看有些怪, 但有一个解释, 姑且假定 $l_n(\beta)$ 为 β 的二次型, 因其在 $\hat{\beta}_n$ 处达到最大值, 故可表为

$$l_n(\beta) = R - \frac{1}{2}(\beta - \hat{\beta}_n)' A (\beta - \hat{\beta}_n) \quad (A > 0, R \text{ 为常数}). \quad (3.34)$$

为找 $\tilde{\beta}_n$, 用乘数法. 作函数 $l_n(\beta) + \lambda'(C\beta - a)$, 对 β 求导并令结果为0, 得方程

$$\begin{aligned} C'\lambda &= A(\tilde{\beta}_n - \hat{\beta}_n) \\ \Rightarrow \tilde{\beta}_n &= \hat{\beta}_n + A^{-1}C'\lambda \Rightarrow a = C\tilde{\beta}_n = C\hat{\beta}_n + CA^{-1}C'\lambda \\ \Rightarrow \lambda &= (CA^{-1}C')^{-1}(a - C\hat{\beta}_n) \\ \Rightarrow \tilde{\beta}_n &= \hat{\beta}_n + A^{-1}C'(CAC')^{-1}(a - C\hat{\beta}_n) \end{aligned}$$

于是得似然比统计量

$$\begin{aligned} \lambda_n &= 2(l_n(\hat{\beta}_n) - l_n(\tilde{\beta}_n)) = (\tilde{\beta}_n - \hat{\beta}_n)' A (\tilde{\beta}_n - \hat{\beta}_n) \\ &= (C\hat{\beta}_n - a)' (CA^{-1}C')^{-1} (C\hat{\beta}_n - a). \end{aligned} \quad (3.35)$$

由(3.34)式有 $l_n(\beta) = A$, 故 $F_n(\beta) = A$, 与 β 无关, 故 Wald 检验统计量 W_n 中的 Ω_n 就是 $F_n^{-1}(\beta) = A$. 因 A 已知, 其估计 $\hat{\Omega}_n = \Omega_n = A^{-1}$. 比较(3.2)和(3.35)式, 知 $\lambda_n = W_n$.

再由(3.34)式, 有 $S_n(\tilde{\beta}_n) = l_n(\tilde{\beta}_n) = A(\hat{\beta}_n - \tilde{\beta}_n)$, 又 $F_n^{-1}(\tilde{\beta}_n) = A^{-1}$,

知约束检验统计量 $\omega_n = (\hat{\beta}_n - \tilde{\beta}_n)A(\hat{\beta}_n - \tilde{\beta}_n)$, 按(3.35)式, $\omega_n = \lambda_n$. 故3个统计量完全一致, 当然有相同的渐近分布.

当原假设成立而 n 很大时, $\hat{\beta}_n$ 和 $\tilde{\beta}_n$ 都与 β_0 接近, 因此 $\tilde{\beta}_n$ 也与 $\hat{\beta}_n$ 接近. 在计算 λ_n 和 ω_n 时, 只涉及 $\hat{\beta}_n$ 的很小邻域内 $l_n(\cdot)$ 之值, 而在此很小的邻域内, 可近似地把 $l_n(\cdot)$ 视为一个二次型, 因而按上述推理, 当 n 很大时, λ_n 和 ω_n 应接近. 至于 W_n , 据上面的证明, 只要 $\tilde{\beta}_n$ 和 $\hat{\beta}_n$ 接近, W_n 就和 λ_n 接近. 总结上述可知, 当原假设成立且 n 很大时, W_n , ω_n 和 λ_n 三个检验统计量本身就很接近, 不只其分布而已.

既然如此, 那为什么还要设这3个形式不同, 而实质没多大不同的检验? 何不只用一个算了? 这有一些原因. 一是从计算上看, 各有其方便和不便之处, 如Wald检验统计量 W_n 只涉及 $\hat{\beta}_n$, 若在作检验前, 已因估计 β_0 而算出了 $\hat{\beta}_n$, 则进一步算 W_n 省了不少事, 而算 ω_n 则要从头开始, 但如事先并未算出 $\hat{\beta}_n$, 则因计算 $\tilde{\beta}_n$ 有时比计算 $\hat{\beta}_n$ 省事, 因为受到约束后维数降低, 有时求极值容易些(例如, 若原假设为 $\beta_0 = a$, 则 $\tilde{\beta}_n = a$, 不待计算). 二是在功效上, 对有限样本(n 不太大), 一般似然比检验有较好的表现. 故虽然 λ_n 在计算上往往比计算 W_n 和 ω_n 都繁琐, 仍有其存在价值.

所用的方法也可用于讨论一般的非线性假设 $H(\beta) = 0$ 的检验问题, 得到的结果也相似.

第 4 章

模型的选择与诊断

4.1 p 值或拟合优度

从理论或实际的考虑选定了一个模型,现有了数据要有一个指标去衡量数据与所选模型“拟合”的程度如何,这就是所谓“拟合优度检验”(test of goodness of fit).通常是这样做的:找一个衡量数量与所选模型的差距的指标 d_n . $d_n \geq 0$, d_n 愈小,数据与模型拟合程度愈好(模型愈可接受).设在一具体场合算出 d_n 之值为 d° . 计算概率

$$p = P(d_n \geq d^\circ \mid \text{模型正确}) \quad (4.1)$$

p 愈大,则当模型正确时,得到像 d° 这么大或更大的差距愈不稀奇.反之,若 p 很小,例如小于 0.05, 0.01 以至 0.001,则在模型正确时发生这么大(d° 或大于 d°) 差距的机会很小.这表明有相当大的理由怀疑模型不正确.如果是前者(p 较大),则我们说“所得数据没有支持所选模型不正确”——注意我们不说“所得数据证明了所选模型的正确性”,尤其在数据量不大时更是如此:有可能所选模型相当程度上不正确,但因资料不够,差距无法显示出来.

由(4.1)式计算出的值常称为“ p 值”,或径直称为“拟合优度”.结论是: p 值愈大,我们对所选模型愈放心,一般在事先设下一个门限(如 0.05),当 p 值小于此门限时,就将模型否决.当 n 个可用的模型时, p 值最大的那一个最有理由被选(当然还要结合其他考虑).因此 p 值可用于模型选择.

要注意的是: p 值与所选差距指标 d_n 有关.但是,在现实应用中 d_n 的选择并非完全自由.因 d_n 的选择要符合一个条件,即其分布或其(当 $n \rightarrow \infty$ 时的)极限分布可以求出且是一个比较常见的分布,通常是 χ^2 分布.再则,如定下一个否定的门限(如 p 值 < 0.05 或 0.01),则其值应在算出 d_n 之前就定下来.在本节中,我们将考虑 d_n 的两种选择.

4.1.1 Pearson 统计量

设 $a_1, \dots, a_M$ 是自变量 x 的一切可能值.例如,若 $x = (x_{(1)}, x_{(2)}, x_{(3)})$,而每个 $x_{(j)}$ 只取 0,1 两值,则 $M = 8$.以 n_j 记在样本中 x 取值为 a_j 的个数.假定

$$n_j \rightarrow \infty \quad (j = 1, \dots, M), \text{ 样本量 } n \rightarrow \infty. \quad (4.2)$$

记样本为 $(y_1, x_1), \dots, (y_n, x_n)$, 暂设 y 为 1 维. 令

$$\xi_j = \sum_{i: x_i = a_j}^n y_i / n_j \quad (j = 1, \dots, M) \quad (\text{此值也常记为 } \bar{y}_j),$$

即其 x_i 为 a_j 的那些样本的 y 值的算术平均, 令

$$d_n = \sum_{j=1}^M n_j (\xi_j - \hat{\mu}(a_j))^2 / \hat{\sigma}^2(a_j), \quad (4.3)$$

记号意义解释如下(此处所用记号较第 2 章略有不同):

$$\mu(x) = E_{\beta_0}(y | x) \equiv E(y | x). \text{ 因 } h \text{ 为联系函数, 有 } \mu(x) \equiv h(z'(x)\beta_0),$$

以 a_j 代 x , 以 β_0 的 MLE $\hat{\beta}_n$ 代替 β_0 , 得 $\mu(a_j)$ 的估计 $\hat{\mu}(a_j) = h(z'(a_j)\hat{\beta}_n)$.

$\hat{\sigma}^2(a_j)$ 也一样: $\sigma^2(x) = \text{Var}_{\beta_0}(y | x)$. 有

$$\sigma^2(x) = b(\theta) = \dot{b}(\dot{b}^{-1}(\mu(x))) = b(\dot{b}^{-1}(h(z'(x)\beta))).$$

以 a_j 代 x , 以 β 的 MLE $\hat{\beta}_n$ 代 β , 得 $\sigma^2(a_j)$ 的估计 $\hat{\sigma}^2(a_j)$.

d_n 的意义可解释如下. 固定 $x = a_j$ 去估计 $E(y | x) = E(y | a_j)$, 得到两个估计: 一是 ξ_j , 按大数律, 当 n_j 很大时, $\xi_j \approx E(y | a_j)$, 这不依赖模型是否正确. 另一估计是 $\hat{\mu}(a_j)$, 它是根据所选模型得到的. 按相合性, 若所选模型正确则应有: $\hat{\mu}(a_j)$ 也接近 $E(y | a_j)$. ξ_j 和 $\hat{\mu}(a_j)$ 既然都接近 $E(y | a_j)$, 二者的差距 $[\xi_j - \hat{\mu}(a_j)]^2$ 应倾向于小. 反之, 若所选模型不正确, 则估计量 $\hat{\mu}(a_j)$ 一般会与 $E(y | a_j)$ 有相当的差距, 因而 $[\xi_j - \hat{\mu}(a_j)]^2$ 会倾向于大. 由此看出: 若模型正确, d_n 倾向于取小值, 否则倾向于取大值, 符合前述对 d_n 的要求, 至于 $[\xi_j - \hat{\mu}(a_j)]^2$ 乘以因子 $n_j / \hat{\sigma}^2(a_j)$, 是一种加权性质: n_j 愈大, $[\xi_j - \hat{\mu}(a_j)]^2$ 的差距愈说明问题. $\hat{\sigma}^2(a_j)$ 愈小也一样. 因这时 $[\xi_j - \hat{\mu}(a_j)]^2$ 受随机性影响较小, 其差距愈能说明模型本质上的缺陷.

接下去要考虑 d_n 的分布. 有: 在一定的条件下(包括(4.2)式), 当模型正确时, 有

$$d_n \xrightarrow{d} \chi_{M-p}^2, \quad (4.4)$$

其中, p 是参数 β 的维数(这里隐含了 $M > p$ 的要求).

这个结果成立的一个极粗略的推理如下: 若以 $\mu(a_j)$ 和 $\sigma^2(a_j)$ 分别取代 d_n 中的 $\hat{\mu}(a_j)$ 和 $\hat{\sigma}^2(a_j)$, 得

$$d_n^0 = \sum_{j=1}^M n_j (\xi_j - \mu(a_j))^2 / \sigma^2(a_j)$$

则

$$d_n^0 = \sum_{j=1}^M \eta_{nj}^2, \quad \eta_{nj} = \frac{\sqrt{n_j}(\xi_j - \mu(a_j))}{\sigma(a_j)} \quad (j = 1, \dots, M).$$

因 $n_j \rightarrow \infty$, 按中心极限定理, 有 $\eta_{nj} \xrightarrow{d} N(0, 1)$. 又因 $\xi_1, \dots, \xi_M$ 独立(它们所依赖的 y 值中没有公共的, 而 $y_1, \dots, y_n$ 独立), 故有 $d_n^0 \xrightarrow{d} \chi^2(M)$ ($n \rightarrow \infty$), 在模型正确时(注意: 只有在模型正确时我们才能断言 $E(\xi_j) = \mu(a_j)$), 因而 $E(\eta_{nj}) = 0$, 以及 $\text{Var}(\xi_j) = \sigma^2(a_j)/n_j$ (ξ_j) 是 n_j 个独立 y 值的平均, 每个有方差 $\sigma^2(a_j)$, 因而 $\text{Var}(\eta_{nj}) = 1$, 这是推导 $\eta_{nj} \xrightarrow{d} N(0, 1)$ 所必需的).

现在由 d_n^0 过渡到 d_n 时, 我们用 β^0 的估计值 $\hat{\beta}_n$ 取代 β^0 . 因 β^0 为 p 维, 这使自由度减少了 p ——由 M 变为 $M - p$, 于是得到(3.4) 式.

下面给出略为仔细的证明——但仍是 heuristic 性质的. 完全严格的证明不难在所提线索的基础上作出来.

首先, 可以用 $\sigma^2(a_j)$ 取代 $\hat{\sigma}^2(a_j)$:

$$d_n^* = \sum_{j=1}^M n_j [\xi_j - \hat{\mu}(a_j)]^2 / \sigma^2(a_j), \quad (4.5)$$

d_n^* 与 d_n 有相同的极限分布, 这是因为 $\hat{\beta}_n \rightarrow \beta^0$ (in pr.). 因而 $\hat{\sigma}^2(a_j) \rightarrow \sigma^2(a_j)$ (in pr.)^①, 所以

$$d_n^* = (1 + o_p(1)) d_n. \quad (4.6)$$

由(3.6) 式得出所作的断言. 这样, 只需证

$$d_n^* \xrightarrow{d} \chi_{M-p}^2. \quad (4.7)$$

记 $z_j = z(a_j)$. 有 $D_j = \dot{h}(t) \big|_{t=z_j'\beta_0}$, $\dot{h}(t) = \partial h(t) / \partial t'$, 以及

$$\begin{aligned} \xi_j - \hat{\mu}(a_j) &= [\xi_j - \mu(a_j)] - [\hat{\mu}(a_j) - \mu(a_j)] \\ &= [\xi_j - \mu(a_j)] - [h(z_j'\hat{\beta}_n) - h(z_j'\beta_0)] \\ &\approx [\xi_j - \mu(a_j)] - z_j'D_j(\hat{\beta}_n - \beta_0). \end{aligned} \quad (4.8)$$

(上式如 $\approx$ 改为等号, 则 D_j 应由 $dh(t)/dt \big|_{t=z_j'\beta^*}$ 取代, $\beta^* \in \beta_0\hat{\beta}_n$, 由于 $\hat{\beta}_n$ 接

① 利用 $\hat{\sigma}^2(a_j) = b(\dot{b}^{-1}(h(z'(a_j)\hat{\beta}_n)))$, $\dot{b}, \dot{b}^{-1}$ 连续, h 假定为连续.

近 β_0 , 知 β^* 也接近 β_0 . 以 β_0 取代 β^* , 即以 $D_j \equiv dh(t)/dt \Big|_{t=z_j\beta_0}$ 取代 $dh(t)/dt \Big|_{t=z_j\beta^*}$, 而得近似(4.8)式).

以(4.8)式代入(4.5)式, 得

$$\begin{aligned} d_n^* \approx & \sum_{j=1}^M \frac{n_j(\xi_j - \mu(a_j))^2}{\sigma^2(a_j)} - 2 \sum_{j=1}^M \frac{n_j z_j' D_j (\xi_j - \mu(a_j))}{\sigma^2(a_j)} (\hat{\beta}_n - \beta_0) \\ & + (\hat{\beta}_n - \beta_0)' \left(\sum_{j=1}^M \frac{n_j D_j^2 z_j z_j'}{\sigma^2(a_j)} \right) (\hat{\beta}_n - \beta_0) \equiv J_1 - 2J_2 + J_3. \quad (4.9) \end{aligned}$$

因

$$\begin{aligned} S_n(\beta_0) &= \sum_{i=1}^n z(x_i) \sigma^{-2}(x_i) \frac{dh(t)}{dt} \Big|_{t=z'(x_i)\beta_0} (y_i - \mu(x_i)) \\ &= \sum_{j=1}^M n_j z_j D_j \sigma^{-2}(a_j) (\xi_j - \mu(a_j)), \end{aligned} \quad (4.10)$$

$$\hat{\beta}_n - \beta_0 \approx F_n^{-1} S_n(\beta_0), \quad F_n = \sum_{j=1}^M \sigma^{-2}(a_j) n_j D_j^2 z_j z_j', \quad (4.11)$$

由(4.9) ~ (4.11)式, 有

$$J_2 = S_n'(\beta_0) (\hat{\beta}_n - \beta_0) \approx S_n'(\beta_0) F_n^{-1} S_n(\beta_0) \approx J_3. \quad (4.12)$$

故

$$d_n^* \approx J_1 - S_n'(\beta_0) F_n^{-1} S_n'(\beta_0). \quad (4.13)$$

记

$$Z = (z_1, \dots, z_M), \quad D = \begin{bmatrix} \frac{\sqrt{n_1} D_1}{\sigma(a_1)} & 0 \\ 0 & \frac{\sqrt{n_M} D_M}{\sigma(a_M)} \end{bmatrix}, \quad \eta_n = \begin{bmatrix} \eta_{n1} \\ \vdots \\ \eta_{nM} \end{bmatrix}.$$

有 $S_n(\beta_0) = ZD\eta_n$, 而

$$S_n'(\beta_0) F_n^{-1} S_n(\beta_0) = \eta_n' DZ' F_n^{-1} ZD\eta_n \equiv \eta_n' Q\eta_n, \quad Q = DZ F_n^{-1} Z' D.$$

由此及(4.13)式, 并注意到 $J_1 = \eta_n' \eta_n$, 有

$$d_n^* = \eta_n' (I_M - Q) \eta_n. \quad (4.14)$$

$I_M - Q$ 为幂等阵, 此是因 Q 为幂等阵:

$$Q^2 = DZ F_n^{-1} ZDDZ' F_n^{-1} ZD = DZ' F_n^{-1} ZD = Q,$$

这里用了 $F_n = ZDDZ'$. 又

$$\text{tr}(I_M - Q) = M - \text{tr}(Q) = M - \text{tr}(DZ' F_n^{-1} ZD)$$

$$\begin{aligned} &= M - \text{tr}(F_n^{-1} Z D D Z') = M - \text{tr}(F_n^{-1} F_n) \\ &= M - \text{tr}(I_p) = M - p, \end{aligned}$$

故 $\text{rank}(I_M - Q) = \text{tr}(I_M - Q) = M - p$. 由 (4.14) 式得, $I_M - Q$ 为幂等且有秩 $M - p$, 以及 $\eta_n \xrightarrow{d} N(0, I_M)$, 即得 $d_n^* \xrightarrow{d} \chi_{M-p}^2$. 这证明了 (4.7) 式如前所述, 也就证明了 (4.4) 式.

证明利用 $\hat{\beta}_n$ 的相合性及 (4.11) 式, 而后者是在证明 $\hat{\beta}_n$ 的渐近正态性中得出的. 由此可知, 在上一章关于 $\hat{\beta}_n$ 的渐近正态性定理的相应条件下, (4.4) 式成立, 完全严格的证明只需对上述证明略加修改即可得出.

以上的讨论限定 Y 为 1 维. 若 Y 的维数 $r > 1$, 则 d_n 定义修改为

$$d_n = \sum_{j=1}^M n_j (\xi_j - \hat{\mu}(a_j))' \hat{\Sigma}^{-1}(a_j) (\xi_j - \hat{\mu}(a_j)), \quad (4.15)$$

这里 $\Sigma_\beta(x) = \text{Cov}_\beta(Y | x)$, 而 $\hat{\Sigma}(a_j) =$ 在 $\Sigma_\beta(x)$ 表达式中用 $\hat{\beta}_n$ 代 β , a_j 代 x . (4.4) 式则为

$$d_n \xrightarrow{d} \chi_{rM-p}^2 \quad (n \rightarrow \infty, \text{且模型正确}) \quad (4.16)$$

所取代. 若 (4.2) 式只对 $j = 1, 2, \dots, M_1$ 成立. 则 (4.16) 式中的 M 要改为 M_1 (d_n 定义中求和范围也改为只对上述 M_1 个 j).

(4.16) 式的证明方法与 (4.4) 相似: 令 $(\Sigma(a_j))$ 指 $\Sigma_{\beta_0}(a_j)$

$$d_n^* = \sum_{j=1}^M n_j [\xi_j - \mu(a_j)]' \Sigma^{-1}(a_j) [\xi_j - \mu(a_j)].$$

在条件 (4.2) 之下, $n \rightarrow \infty$ 时, 和号下每一项 $\xrightarrow{d}$ 于 χ_r^2 , 而各项独立. 故 $d_n^* \xrightarrow{d} \chi_{rM}^2$. 当 d_n^* 过渡到 d_n 时, 因估计 β 用掉 p 个自由度 (β 为 p 维), 故 d_n 的极限分布的自由度减少 p , 为 $rM - p$.

统计量 d_n 常称为 Pearson 统计量, 以其外形与检验样本与理论分布拟合的 Pearson χ^2 统计量相似. 利用这个极限定理, 可以计算“模型正确”这一假设的 p 值 (渐近值).

4.1.2 Deviance

仍先设样本 Y_i 为 1 维, 以 $l_n(Y, \mu) = \sum_{i=1}^n l(Y_i, \mu_i)$ 记样本 $Y = (Y_1, \dots,$

Y_n ' 的对数似然函数, $\mu = E_\beta(Y) = [E_\beta(Y_1), \dots, E_\beta(Y_n)]' = (\mu_1, \dots, \mu_n)'$. 注意这里突出了对数似然函数与样本期望 μ_i 的关系, 而非其与参数 β 的关系. 但 $\mu_i = h(z'(x_i)\beta)^{\textcircled{1}}$, 故 $l_n(Y, \mu)$ 也可以表成 β 的函数的形式, 二者并无实质不同.

设 $a_j, n_j (j = 1, \dots, M)$ 有意义同前, 且 (4.2) 式成立. 注意到 μ 只是通过 x_i 依赖 i , 故在 $x_{i_1} = x_{i_2}$ 时, 有 $\mu_{i_1} = \mu_{i_2}$, 由此可以把使 $x_i = a_j$ 的那些 i 所对应的 μ_i 记为 $\mu_{(j)}: \mu_{(j)} = \mu_i, x_i = a_j$. 去掉一个与参数无关的项, 有

$$l(Y_i, \mu_i) = Y_i \theta_i - b(\theta_i) \quad (\theta_i = \dot{b}^{-1}(\mu_i)).$$

由此得 (ξ_j 所有那些 y_i 的平均, $x_i = a_j$)

$$\begin{aligned} l_n(Y, \mu) &= \sum_{j=1}^M n_j \xi_j \dot{b}^{-1}(\mu_{(j)}) - \sum_{j=1}^M n_j b(\dot{b}^{-1}(\mu_{(j)})) \\ &\equiv \sum_{j=1}^M l_j^*(\xi_j, \mu_{(j)}), \end{aligned}$$

$$l_j^*(\xi_j, \mu_{(j)}) = n_j \xi_j \dot{b}^{-1}(\mu_{(j)}) - n_j b(\dot{b}^{-1}(\mu_{(j)})).$$

定义

$$DE_n = 2 \sum_{j=1}^M [l_j^*(\xi_j, \xi_j) - l_j^*(\xi_j, \hat{\mu}_{(j)})], \quad (4.17)$$

这里 $\hat{\mu}_{(j)} = h(z'(a_j)\hat{\beta}_n)$, 即在 $\mu_{(j)} = h(z'(a_j)\beta)$ 中以 $\hat{\beta}_n$ 取代 β 的结果.

DE_n 称为 Deviance 统计量. 其意义可解释如下: 定义函数

$$f(t) = l_j^*(\xi_j, t) = n_j [\xi_j \dot{b}^{-1}(t) - b(\dot{b}^{-1}(t))],$$

易见其最大值在唯一点 $t = \xi_j$ 处达到. 事实上, 注意到

$$d[\dot{b}^{-1}(t)]/dt = [b(\dot{b}^{-1}(t))]^{-1},$$

知

$$n_j^{-1} df(t)/dt = [\xi_j - \dot{b}(\dot{b}^{-1}(t))]/\dot{b}(\dot{b}^{-1}(t)) = (\xi_j - t)/b(\dot{b}^{-1}(t)).$$

由指数族性质知 $b(\cdot)$ 总 > 0 , 故 $df(t)/dt = 0$ 的唯一解为 $t = \xi_j$. 此解为极大值点, 因

^① 所以, $\mu_1, \dots, \mu_n$ 与参数 β 有关, 但在记号上没有标出来

$$n_j^{-1} d^2 f(t)/dt^2 \Big|_{t=\xi_j} = - (b(\dot{b}^{-1}(\xi_j)))^{-1} < 0. \quad (4.18)$$

这就是说,如果容许 μ_i 不受限制地自由变化,则 $l_n(Y, \mu)$ 可达到最大值为 $\sum_{j=1}^M l_j^*(\xi_j, \xi_j)$. 但此处 μ_i 并非自由变化,而是受到模型约束 $\mu_i = h(z'(x_i)\beta)$ (若 $\mu_1, \dots, \mu_n$ 都能自由变化,则有 n 个自由度. 现它们都依赖 β 而 β 为 p 维,故 $\mu_1, \dots, \mu_n$ 只有 p 个自由度). 由于受到这一约束, $l_n(Y, \mu)$ 的最大值达不到 $\sum_{j=1}^M l_j^2(\xi_j, \xi_j)$, 而只能达到 $\sum_{j=1}^M l_j^*(\xi_j, \hat{\mu}_{(j)})$. 二者之差 $DE_n \geq 0$, 若模型正确,则 $\mu_1, \dots, \mu_n$ 自由变化时所算出的最大值,应与其在模型约束下所算出的最大值接近,从而二者之差即 DE_n 将倾向于取小值,否则倾向于取大值. 由此看出:根据 DE_n 的大小可判断数据与模型的拟合如何,这就是 Deviance 统计量 DE_n 的直观背景.

可以证明:在一定条件下(包括(4.2)),若模型正确,则有

$$DE_n \xrightarrow{d} \chi_{M-p}^2. \quad (4.19)$$

证明梗概:把 $l_j^*(\xi_j, t)$ 作为 t 的函数在 ξ_j 点附近展开. 利用(4.18)式,有

$$\begin{aligned} & \partial^2 [\xi_j \dot{b}^{-1}(t) - b(\dot{b}^{-1}(t))] / \partial t^2 \Big|_{t=\xi_j} \\ &= - [b(\dot{b}^{-1}(\xi_j))]^{-1} \approx - [b(\dot{b}^{-1}(\mu_{(j)}^0))]^{-1} = - \sigma^{-2}(a_j), \end{aligned} \quad (4.20)$$

其中, $\mu_{(j)}^0$ 是 $\mu_{(j)}$ 在 $\beta = \beta_0$ 时之值,式中的 $\approx$ 是因为(4.2)式成立,故当 $n \rightarrow \infty$ 时 $\xi_j \rightarrow E_{\beta_0}(Y | x = a_j) = \mu_{(j)}$. 故有(下式中的 i 满足 $x_i = a_j$)

$$b(\dot{b}^{-1}(\mu_{(j)})) = b(\theta_i) = \text{Var}_{\beta_0}(Y | x = x_i) = \sigma^2(x_i) = \sigma^2(a_j).$$

利用(4.20)式,把函数 $l_j^*(\xi_j, t)$ 在 $t = \xi_j$ 处作 Taylor 展开,有

$$l_j^*(\xi_j, \xi_j) - l_j^*(\xi_j, \hat{\mu}_{(j)}) \approx \frac{1}{2} \sigma^{-2}(a_j) n_j [\xi_j - \hat{\mu}_{(j)}]^2, \quad (4.21)$$

这里利用了 $l_j^*(\xi_j, t)$ 在 $t = \xi_j$ 处达到最大值,因而 $\partial l_j^*(\xi_j, t) / \partial t \Big|_{t=\xi_j} = 0$, 由(4.21)式得

$$DE_n \approx \sum_{j=1}^M \sigma^{-2}(a_j) n_j [\xi_j - \hat{\mu}_{(j)}]^2.$$

由此式看出(在上式中 $\approx$ 的范围内), DE_n 与 Pearson 统计量(4.3)式的差别,只在将彼处的 $\hat{\sigma}^2(a_j)$ 改为此处的 $\sigma^2(a_j)$. 如在(4.5)式下面指出的,这一取代不

影响极限分布,故由已证的关于 Pearson 统计量的结果(4.4)式,推出(4.19)式.严格证明所需之条件以及上述证明中需要精细化之处,也与 Pearson 统计量相似.

若(4.2)式只对 $j = 1, 2, \dots, M_1$ 成立,则(4.17)式 DE_n 作相应的修改,即只对上述 M_1 个 j 求和.极限定理(4.19)式中的 M 也要改为 M_1 .

从以上的讨论中看出, Pearson 统计量与 Deviance DE_n 之间无多大差别,但以后将看出, DE_n 可以用到某些问题,较 Pearson 统计量要灵活一些.

若 Y 的维数 $r > 1$,则与上类似的推导得出

$$de_n = \sum_{j=1}^M n_j [\xi_j - \hat{\mu}_{(j)}]' \hat{\Sigma}(a_j) [\xi_j - \hat{\mu}_{(j)}] + o_p(1)$$

$$\xrightarrow{d} \chi_{rM-p}^2 \quad (4.22)$$

(或 $\chi_{rM_1-p}^2$, 若(4.2)式只对 $j = 1, \dots, M_1$ 成立).

下面用所讲的方法来考察一下前面若干数字例子的情况.

对例 1.1:

若只要主效应(即模型中只取 x_1, x_2, x_3 的项),则 DE_n 值为 10.997, 自由度 3. 其 p 值, 即 $p(\chi^2(3) > 10.997)$, 在 0.01 到 0.02 之间, 拟合情况不好(本例取 $M_1 = 7$, 其实有一个组只有 2 个样本, 取 $M_1 = 6$ 更合理). 参数有 4 个——常数项及 x_1, x_2, x_3 的回归系数, 故自由度为 $7 - 4 = 3$. 若取 $M_1 = 6$, 自由度为 $6 - 4 = 2$, p 值将小于 0.005, 结果更坏.

若加进交互作用项 $x_1 x_2$, 则 DE_n 值变为 10.918, 降低有限, 显示这个交互作用不显著.

若加进交互效应 $x_1 x_3$, 则 DE_n 值变为 10.974, 比只取线性项时的值 10.997 降低很少, 显示这个交互作用也不显著.

对例 1.7, 此处 $M = 2 \times 3 = 6$, Y 的维数 $r = 2$, 参数个数 $p = 7$. 自由度 $rM - p = 12 - 7 = 5$. 对 3 种模型算出的 de 值为

累积 logistic: 8.146; 分组 Cox: 3.127; 极大值: 9.514,

它们都未超过 5% 的门限, 但以分组 Cox 的拟合情况最好(p 值: logistic 在 0.15 ~ 0.16 之间, Cox 在 0.67 ~ 0.70 之间, 极大值在 0.09 ~ 0.10 之间).

对例 1.9, $r = 2, M = 2, p = 3$ (两个门限值 θ_1, θ_2 及回归系数 β). 自由度 $rM - p = 1$. 用非序贯 logit, 得 Pearson 统计量 = 0.301, Deviance = 0.302, p

值约为 0.59; 用序贯 logit, 得 Pearson 和 DE_n 分别为 0.005 和 0.006, p 值 > 0.95 . 可见序贯模型的拟合优于非序贯.

对例 1.10, $r = 4, M = 2, p = 7$. 自由度 $rM - p = 1$. 用 logit 模型算出 de 值为 0.008, p 值 > 0.92 , 拟合很好.

如果 M 很大 (因自变量多) 而 n 不大, 则 (4.2) 式中的 n_j 不大. 这时, Pearson 统计量与 Deviance 的真确分布与其极限分布会有较大差异, 而据极限分布算出的 p 值可信度不高. 这种由于数据量不够而产生的问题没有根本的解决办法 (巧妇难为无米之炊). 可以从实际角度考虑提出若干看来合理的模型, 比较其 Pearson 统计量或 Deviance, 择其小者.

本例结果不理想可能与数据的畸形有关, 因为 (剖腹临时决定、服用抗生素、没有危险因子) 这一组中, 一个数据也没有, 如果把这组中的两个 0 (感染 0, 无感染 0) 改为两个 0.5, 则拟合有显著改善 (包含 $x_1 x_3$ 项及主效应项的模型), 且交互效应项 $x_1 x_3$ 是显著的.

4.2 模型选择

4.2.1 从若干个备选模型中选取一个

模型选择包含以下一些方面:

- 因变量 Y 分布的选择
 - 联系函数的选择
- 自变量的选择
 - $z(x)$ 的选择

先谈第一个问题, 对两点分布 (Y 取 0, 1 二值) 或取多个状态之一的情况, 分布自然决定, 无选择问题. 对稍复杂一点的情况就有选择问题. 例如 Y 取 0, 1, $\dots, m$ 等 $m+1$ 个值 (注意: 单变量取有限个值——如 m 个服药的人中有效的个数——与取有限个状态之一 (如考试结果有优、良、中、差 4 个状态) 不能混淆. 后者当转到哑变量时为多维的), 就有一个是否取二项分布为模型的问题, 例如当怀疑有“超散布性”存在时. 对可以取整数值 0, 1, $\dots$ 的变量, 有是否选

Poisson 分布为模型的问题等.

联系函数的选择,是选 $h(z'(x)\beta)$ 的形状,还是 $h(x, \beta)$ 的一般形式?若是前者, h 如何选?是选自然联系函数,或者其他形式?

自变量的选择,更多的是从实际角度考虑:从专业或经验的角度看,哪些变量对目标 Y 有重要的影响?当可能的候选者太多而希望从中挑出为数不多的最有影响的变量时,除专业的考虑外,也有些统计方法.

$z(x)$ 的选择也是从专业和实际的考虑居多.例如,一个常见的情况是:若 $x = (x_1, \dots, x_m)'$, 则 $z(x)$ 中将包含常数项.一部分主效应项,即 $x_1, \dots, x_m$ 中的一部分,以及一部分交互效应项.通常只涉及一级交互效应,即 $x_1 x_2, x_1 x_3, \dots, x_{m-1} x_m$ 这些项的一部分.选择哪一些,有专业的考虑,也有些统计方法(借助于样本).所以, $z(x)$ 的选择与自变量的选择,在某种情况下可以统一处理.例如 $x = (x_1, x_2, x_3)$, $z(x)$ 中可以包含的项(除常数项外)有 6 个: $x_1, x_2, x_3, x_1 x_2, x_1 x_3, x_2 x_3$. 可以把这 6 个全看成“自变量”,在其中进行选择.

对 Y 的分布的选择,可谈的很有限.如无特别理由反对选择指数型,则不必作其他考虑.在另外的情况,则属于拟似然的范围,其均值函数和方差函数的选择也多关乎专业和实际的考虑.有时,利用数据可帮助作这种选择,或者检验某种选择是否合适.

联系函数的选择也与此相似:有一个选择形状 $h(z'(x)\beta)$ 还是形状 $h(z(x), \beta)$ 的问题,后者属于非线性,甚至也可以不确定 h ——属于非参数的情形.后面这两种情况已超出这里所讲的“广义线性模型”的主题.因为如去掉了 $z'(x)\beta$ 这个元素,则模型中已没有了任何线性的色彩.

对分布及联系函数,以至一般而言的模型选择,如选择对象只有少数几个,则可比较其 Pearson 或 Deviance 统计量,择其小者.如例,3 个可供选择的联系函数,其 p 值分别为 $0.09 \sim 0.10$, $0.15 \sim 0.16$ 和 $0.67 \sim 0.70$. 后两个都可考虑.纯从 p 值出发,则选分组 Cox.

4.2.2 自变量选择

统一用 $x_1, \dots, x_m$ 记自变量,如上文所述,它们中有一些可能是原始自变量的交互效应.

常用的挑选自变量的方法有向前法、向后法与逐步法.

向前法是逐步增加,从开始只包含常数项出发,设在某个时候已有 $x_1, \dots,$

x_r 被选入, 尚有 $x_{r+1}, \dots, x_m$ 待选. 把包含自变量 $x_{i_1}, \dots, x_{i_k}$ 的模型记为 $MO(i_1, \dots, i_k)$, 此模型的对数似然函数最大值^①记为 $l(i_1, \dots, i_k)$. 如果在 $x_1, \dots, x_r$ 的基础上加进 $x_j (j = r+1, \dots, m)$, 则将有

$$a_j \triangleq l(1, \dots, r, j) - l(1, \dots, r) \geq 0$$

(因为变量多了, 求最大值时范围扩大, 最大值只能上升而不能下降.) 容易看出 a_j 也是 $MO(1, \dots, r)$ 的 Deviance 与 $MO(1, \dots, r, j)$ 的 Deviance 之差^②. a_j 愈大, 表示因 x_j 的加入, 模型 Deviance 缩小愈多, 即模型与数据拟合程度的改善愈多, 因而就愈有被选入的资格. 由此可知, 下一步应取有最大 a_j 的那个 x_j . 加入 x_j , 以 $x_1, \dots, x_r, x_j$ 为起点, 再按刚才的做法. 在剩下的 $m - (r+1)$ 个中挑出一个.

挑选何时结束? 有 2 种处理方法.

一是事先定下一个适当的数字 k , 直到挑出 k 个为止.

二是不事先定数目, 而是要在每一步考察, 新加入一个变量的收益如何, 即它能使 Deviance 下降多少. 若下降很小, 则不纳入而挑选停止. 但这“很小”的界线如何定呢? 这用得着一个不难证明的结果: 若 $MO(1, \dots, r)$ 正确, 则 a_j 近似有分布 $\chi^2(1)$. 因此可指定一个 $\alpha \in (0, 1)$, 当 $a_j > \chi_{\alpha}^2(1)$ 时, 接纳 x_j , 否则不接纳而挑选停止. α 的大小反映进入门槛. α 愈小 (因而 $\chi_{\alpha}^2(1)$ 愈大), 则门槛愈高 (新变量愈难再被接纳).

在实施上要注意一些问题. 例如, x_j 可能从问题的实际角度看有其重要性.

① $l(1, \dots, r)$ 是指对数似然函数

$$\begin{aligned} \sum_{i=1}^n (y_i \theta_i - b(\theta_i)) &= \sum_{i=1}^n y_i \dot{b}^{-1}(h(x_{i1}\beta_1 + \dots + x_{in}\beta_r + \beta_0)) \\ &\quad - \sum_{i=1}^n b(\dot{b}^{-1}(h(x_{i1}\beta_1 + \dots + x_{in}\beta_r + \beta_0))) \end{aligned}$$

的最大值 (对 $\beta_0, \dots, \beta_r$ 取). $(x_{i1}, \dots, x_{in})' = x_i$ 是 $x = (x_{(1)}, \dots, x_{(r)})'$ 在第 i 次观测中的取值. 如果增加一个自变量 $x_{(r)}$, 则上式中的 $\beta_1 x_{i1} + \dots + \beta_r x_{in} + \beta_0$ 要以 $\beta_1 x_{i1} + \dots + \beta_r x_{in} + \beta_j x_{in} + \beta_0$ 去取代. 最大值对 $\beta_0, \dots, \beta_r, \beta_j$ 求. 这最大值显然 $\geq$ 前一个最大值. 因为前一个最大值是后一模型在 $\beta_j = 0$ 的条件下取的.

② Deviance 定义为二项之差: $A - B$, B 是上一个注中定义的值, 而 A 则是

$$A = \sum_{i=1}^n \max_{\theta_i} (y_i \theta_i - b(\theta_i)) = \sum_{i=1}^n [y_i \dot{b}^{-1}(y_i) - b(\dot{b}^{-1}(y_i))],$$

与自变量取多少无关

这时,可以对它降低门槛,以便它有更多机会进入.可以把全部自变量按其重要性(从实际角度考虑估量的重要性,如问题的实际背景未提供这种可能,当然就无法实施)分成二、三类.每类中的变量各取一个不同的 α ,如 0.05, 0.10, 0.20. 也可以这样做:对一些认为很重要的变量实行“保底”,即不经任何检验就选入,在这个基础上再对剩余的变量用上述方法进行挑选.

还有一个问题:在一个包含较多自变量的问题中,有可能每个变量对模型的贡献比较均匀,即无很突出者.这时,一个新变量要超越选择门槛不易,因而可能造成选入变量过少的情况.一个办法是用 4.1 节的方法进行检验:设过程在选入 $x_1, \dots, x_r$ 后停止.用 Deviance(或 Pearson 统计量也可)检验模型 $MO(1, \dots, r)$ 的拟合程度.若能通过,则选择停止.若不能通过,则按上法继续挑选(而不管新进入者是否达到门槛),直到 Deviance 检验能通过为止.

在自变量选择问题上有一个基本的共识:既要使模型与数据拟合得好,又要使变量数目不太多.这二者是鱼与熊掌的关系,但不能以“舍鱼取熊掌”的方式去处理,而是要用中庸之道,即二者兼顾.日本学者赤池弘次提出了一个得到广泛使用的方法,即所谓 AIC 准则:

$AIC(\text{某模型}) = 2 \cdot \text{模型中参数个数} - 2 \cdot \text{模型的对数似然函数的最大值}$.
当模型中纳入新参数时,减号两边的量皆增加.赤池的准则是:两个模型, AIC 小者为优.

根据这个准则可得到下面的选择法:设 $x_1, \dots, x_r$ 是按上述方式挑选的.刚好能通过 Deviance 拟合检验的自变量集(它们必须被纳入).剩下的 $x_{r+1}, \dots, x_m$, 按前述计算 a_j 的方法,排出其依次进入(不计门槛)的先后,设 $x_{r+1}, \dots, x_m$. 计算

$$b_j = AIC(MO(x_1, \dots, x_r, \dots, x_j)) \quad (j = r, \dots, m).$$

设在 $j = j_0$ 时 b_j 首次达到最小,即

$$b_j > b_{j_0} \quad (j = r+1, \dots, j_0-1); \quad b_j \geq b_{j_0} \quad (j = j_0+1, \dots, m),$$

则选取自变量 $x_1, \dots, x_{j_0}$.

前面在已有 $x_1, \dots, x_r$ 而决定 $x_{r+1}, \dots, x_m$ 中何者应选入时,使用的方法是在模型

$$E(Y) = \mu = h(\beta_0 + \beta_1 x + \dots + \beta_r x_r + \beta_j x_j)$$

中,用拟似然法检验假设 $\beta_j = 0$ (注意 Deviance 之差即此假设的拟似然比统计量).此假设也可用 Wald 检验去处理.二者的极限分布相同($\chi^2(1)$).用 Wald 检验计算上可能有所方便.

以上讲的是向前法. 向后法则方向相反: 起始将全部变量收入, 再一个一个剔除. 设在某一阶段还剩下 $x_1, \dots, x_r$ (其余的已剔除出局), 去考虑其中哪一个该在下一步剔除或停止. 计算

$$a_j = l(1, \dots, r) - l(1, \dots, j-1, j+1, \dots, r) \quad (j = 1, \dots, r).$$

a_j 愈大, 表示剔除 x_j 后模型拟合的程度下降愈多, 因而它愈不应被剔除. 由此可知, 可能剔除的对象, 是使 a_j 最小的那个 x_j . 对这个 j , 看 a_j 是否超出 $\chi_{\alpha}^2(1)$ 的门槛. 若超出, 则它不应被剔除而过程停止. 否则剔除 x_j , 再按上述方法, 在剩余的变量中进行下一步剔除. 所有在向前法中讲到的那些注意之点, 如对不同重要性的变量使用不同的门槛, 对某些重要的变量实行保底, 最后选定的模型要通过 Deviance 拟合检验以及 AIC 准则的使用等, 在此全部有效.

逐步选择法则是上述两种操作交替使用. 设刚接纳一个新变量而得 $\{x_1, \dots, x_r\}$. 则下一步看 $x_1, \dots, x_r$ 中是否有可剔除者, 如有, 则剔除它, 否则维持 $\{x_1, \dots, x_r\}$ 不动, 而下一步看余下的 $x_{r+1}, \dots, x_m$ 中是否有可进入者, 如有, 则纳入它, 否则维持不动, 然后看已进入者中是否有可被剔除者, 一直进行到“既无可进, 也无可出”时为止.

最终进入的变量数与门槛有关: 门槛愈高, 易出难进; 愈低则易进难出. 因此可调整门槛, 使进入的变量构成的模型能通过 Deviance 拟合检验, 且变量数不超过. 这样做可能要用几个门槛试算, 计算量较大. 可以采用下面的变通做法: 设采用某一门槛由逐步法得到 $x_1, \dots, x_r$, 分 2 种情况.

1. $MO(x_1, \dots, x_r)$ 尚不能通过 Deviance 检验. 这时, 用向前法, 排定剩下的 $m-r$ 个变量的进入次序, 设为 $x_{r+1}, \dots, x_m$, 找最小的 r_1 , 使 $MO(x_1, \dots, x_{r_1})$ 能通过 Deviance 拟合检验. 再计算

$$b_j = \text{AIC}(MO(x_1, \dots, x_j)) \quad (j = r_1, r_1 + 1, \dots, m). \quad (4.23)$$

找最小的 $j = j_0$ 使 $b_{j_0} = \min(b_{r_1}, \dots, b_m)$, 以 $MO(x_1, \dots, x_{j_0})$.

2. $MO(x_1, \dots, x_r)$ 能通过 Deviance 检验. 这时, 用向后法, 排定 $x_1, \dots, x_r$ 剔除先后次序, 设为 $x_r, \dots, x_2, x_1$. 找最小的 r_1 , 使 $MO(x_1, \dots, x_{r_1})$ 能通过 Deviance 拟合检验. 然后用向前法排定 $x_{r_1+1}, \dots, x_m$ 的进入次序 (以 $\{x_1, \dots, x_{r_1}\}$ 为出发点), 设即为 $x_{r_1+1}, \dots, x_m$. 计算 (4.23) 式, 找最小的 $j = j_0$ 使 $b_{j_0} = \min(b_{r_1}, \dots, b_m)$, 取 $MO(x_1, \dots, x_{j_0})$.

注意在以上操作中, 变量进入或剔除都不设门槛, 只是按比较: 剩余变量中影响最大者进入; 已有变量中影响最小者剔除.

另外, 以上的做法隐含了这样的前提, 即: 全部自变量都收进的模型是可以

接受的(这一点要结合 4.1.1 小节末尾处的注解. 如果这一条不满足, 就应对模型的各个方面重新审视, 包括 4.2 节开头处提出的那些问题. 另外也要考察样本中是否有异常点或强影响点, 有否必要剔除个别样本, 或者必要时增加样本再重新考察等.

例 4.1 银行对申请贷款者要考察其信用以决定是否贷给. 目标 Y 取两值: 0(可信), 1(不可信). 提出了 20 个可能对此有影响的因素. 经研究后保留 8 个, 有

$x_{(1)}, x_{(2)}$: 银行存款, 分无、多、少三档: 无($x_{(1)} = 1, x_{(2)} = -1$)、多($x_{(1)} = -1, x_{(2)} = 1$)、少($x_{(1)} = x_{(2)} = -1$);

$x_{(3)}$: 借贷时间(以月计, 数量因素);

$x_{(4)}$: 借贷数量(数量因素);

$x_{(5)}$: 以往还贷情况: 好($x_{(5)} = 1$)、坏($x_{(5)} = -1$);

$x_{(6)}$: 借贷用途: 生活($x_{(6)} = 1$)、业务($x_{(6)} = -1$);

$x_{(7)}$: 性别: 男($x_{(7)} = -1$)、女($x_{(7)} = +1$);

$x_{(8)}$: 婚否: 已($x_{(8)} = 1$)、未($x_{(8)} = -1$).

总共样本有 1000 个. 对只含 $x_{(i)}$ 项而不含交互项的模型, 得估计值如表 4.1^①.

表 4.1 不同模型的估计值

变量	回归系数估值	p 值	变量	回归系数估值	p 值
总平均	-0.188 1	0.61	$x_{(5)}$	-0.988 4	0.00
$x_{(1)}$	0.634 6	0.00	$x_{(6)}$	-0.474 4	0.00
$x_{(2)}$	-1.317 0	0.00	$x_{(7)}$	0.223 5	0.31
$x_{(3)}$	0.035 0	0.00	$x_{(8)}$	-0.385 4	0.08
$x_{(4)}$	0.000 0	0.33			

从 p 值上看, $x_{(1)} \sim x_{(3)}, x_{(5)}, x_{(6)}$ 显著, $x_{(8)}$ 接近显著. 如以 p 值为依据, 可剔除的变量只有 $x_{(4)}$ 和 $x_{(7)}$. 在 $\alpha = 0.05$ 的门槛下, 用 logit 模型, 用向前和向后法, 也可得出这同一结论——剔除 $x_{(4)}, x_{(7)}$. 全子集回归(见后)结合 AIC 准则, 也得出这同一结论. 这表明: 性别与借贷数量这两个因素不重要, 而其他因素则有一定的重要性. 从回归系数估值的符号看, 这些情况倾向于不可靠: 未婚; 用于业务; 以往还贷情况不好; 借贷时间长; 银行无存款.

① 例如, $x_{(1)}$ 的回归系数 β_1 的估值 $\hat{\beta}_{1n}$ 的 p 值的意义是: 在 β_1 其实为 0 时, 得到 $|\hat{\beta}_{1n}| \geq 0.6346$ 的概率(这可由 $\hat{\beta}_n$ 的极限分布近似算出). p 值愈大, 表示“ $\beta_1 = 0$ ”愈可接受

4.3 诊断问题

这是一个内涵不很确定,方法也不很规范的问题.一般在讲到这个题目时多要涉及以下几方面的内容:① 强影响点,即样本中对决定模型参数有较强影响的那种点.这种点之值得注意,是因为万一它们有较大的误差,将使模型产生较大的偏差.② 残差分析.残差是指因变量观测值 y_i 与其由模型估计的“理论值” $\hat{y}_i$ 的差.残差的整体状况对研判模型的正确性及数据中是否有异常有用,这后一方面就是.③ 异常值检测.所谓“异常值”是指那种样本点,它因受到某种系统性因素的影响(如记录错误)而带有很大的误差,表现为其取值远离其他样本之值.这种值起的作用总是负面的.异常值检测的目的就是发现这种值并将其从样本中剔除.

即使在最简单的正态线性回归场合,也不能说对以上几个问题有了理论上坚实且(尤其重要的)在应用上行行之有效的整套方法,更遑论远为复杂的广义线性模型了.因此,以下所讲的只宜被看作一些原则性的指点.其成功的使用在很大程度上依赖于经验以及对所论问题的专业知识和实际背景的了解.

4.3.1 帽子矩阵与高杠杆点

先从最简单的线性回归来讲,比较容易理解.设有模型

$$y_i = \alpha_0 + x_i' \beta_0 + e_i \quad (i = 1, \dots, n). \quad (4.24)$$

记

$$\gamma_0 = \begin{bmatrix} \alpha_0 \\ \beta_0 \end{bmatrix}, \quad X^* = \begin{bmatrix} 1 & x_1' \\ \vdots & \vdots \\ 1 & x_n' \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad e = \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix}.$$

可将(4.24)式写为

$$Y = X^* \gamma_0 + e. \quad (4.25)$$

按LS估计,得 γ_0 的估计

$$\hat{\gamma} = S^{*-1} X^{*'} Y, \quad S^* = X^{*'} X^*.$$

于是由(4.25)式,得 Y 依模型得到的估计,即其“理论值”,为

$$\hat{Y} = X^* S^{*-1} X^{*'} Y = P_{X^*} Y, \quad (4.26)$$

其中, P_{X^*} 为向 X^* 的列向量空间的投影阵. 因为它是 Y 产生“ Y 加帽子”的矩阵, 故常称为“帽子矩阵”并记为 H :

$$H = P_{X^*}. \quad (4.27)$$

假定(4.24)式中的 e_i 满足 Gauss-Markov 条件:

$$E(e) = 0, \quad \text{Cov}(e) = \sigma^2 I_n \quad (I_n: n \text{ 阶单位阵}), \quad (4.28)$$

则残差

$$\delta \triangleq Y - \hat{Y} = (I - H) Y \quad (4.29)$$

的期望为 0, 因 $E(\delta) = (I - H)E(Y) = (I - H)X^* \gamma_0 = 0$ (后一式由于 $X^* = HX$), 而协方差阵为

$$\text{Cov}(\delta) = \sigma^2(I - H), \quad (4.30)$$

这里用到 $I - H$ 为幂等阵. 特别地, 记 $\delta = (\delta_1, \dots, \delta_n)'$, $\delta_i = Y_i - \hat{Y}_i$, 记 $H = (h_{ij})$, 有

$$\text{Var}(\delta_i) = \sigma^2(1 - h_{ii}) \quad (i = 1, \dots, n). \quad (4.31)$$

(因 H 为投影阵, 有 $0 \leq h_{ii} \leq 1$, 故 $0 \leq \text{Var}(\delta_i) \leq \sigma^2$.)

从(4.31)式看出: 若 $h_{ii} \approx 1$, 则 $\text{Var}(\delta_i) = \text{Var}(y_i - \hat{y}_i) \approx 0$. 结合 $E(y_i - \hat{y}_i) = 0$, 有 $y_i - \hat{y}_i \approx 0$. 这意思是: 在 (x_i, y_i) 这个点, 经验值 y_i 与其理论值 $\hat{y}_i$ 拟合得特别好, 或者说, 这样的点有把经验回归平面 (即由数据估计得的回归平面) 拖向自己的倾向. 它被称为高杠杆点. 名词的直观理由见下面的解释. 往证 (记号意义见下)

$$h_{ii} = (1, x_i') S^{*-1} \begin{pmatrix} 1 \\ x_i \end{pmatrix} = \frac{1}{n} + (x_i - \bar{x})' \tilde{S}^{-1} (x_i - \bar{x}). \quad (4.32)$$

为此, 记

$$\mathbf{1} = (1, 1, \dots, 1)', \quad x = \begin{bmatrix} x_1' \\ \vdots \\ x_n' \end{bmatrix}, \quad \bar{x}' = \frac{1}{n} \sum_{i=1}^n x_i' = \mathbf{1}' X / n,$$

并利用分块求逆公式:

$$\begin{pmatrix} A & B \\ B' & C \end{pmatrix}^{-1} = \begin{bmatrix} A^{-1} + A^{-1} B G B' A^{-1} & -A^{-1} B G \\ -G B' A^{-1} & G \end{bmatrix}, \quad (4.33)$$

其中, A, C 为对称方阵, 而 $G = (C - B' A^{-1} B)^{-1}$. 利用此公式, 注意到

$$S^* = \begin{pmatrix} n & \mathbf{1}'X \\ X'\mathbf{1} & X'X \end{pmatrix}, \quad (4.34)$$

以及

$$X'X - X'\mathbf{1}\mathbf{1}'X/n \triangleq \tilde{S} = \sum_{i=1}^n (x_i - \bar{x})', \quad (4.35)$$

有

$$S^{*-1} = \begin{bmatrix} \frac{1}{n} + \bar{x}\tilde{S}^{-1}\bar{x} & -\bar{x}\tilde{S}^{-1} \\ -\tilde{S}^{-1}\bar{x} & \tilde{S}^{-1} \end{bmatrix}. \quad (4.36)$$

因此

$$\begin{aligned} h_u &= \frac{1}{n} + \bar{x}'\tilde{S}^{-1}\bar{x} - 2x_i'\tilde{S}^{-1}\bar{x} + x_i'\tilde{S}^{-1}x_i \\ &= \frac{1}{n} + (x_i - \bar{x})'\tilde{S}^{-1}(x_i - \bar{x}), \quad \text{即(4.37)式.} \end{aligned}$$

$\bar{x}$ 是数据 $x_1, \dots, x_n$ 的中心. (4.32) 式显示: 某点 x_i 距此中心愈远, 则 h_u 之值愈高——如前所述, 它愈有把经验回归拉向自己的倾向. 这一点在 x 为 1 维时, 不难从图形得到理解:

看图 4.1, x_i 远离 $\bar{x}$, 其 h_u 接近 1, 是一个高杠杆点. 如果 (x_i, y_i) 在 A 点处




图 4.1

(属正常状态), 则尚不致太影响经验回归线的基本走向. 反之, 若 (x_i, y_i) 在 B 处, 则它把经验回归线由 l 拖至 l' (拖向自己), 而大为影响了经验回归线的走向.

看图上,好像有一股力把 l 的右端抬上去,好像以 $(\bar{x}, \bar{y})$ 为心的一个杠杆作用. 这正是高杠杆点这一名称的由来.

反观图 4.2, x_i 离 $\bar{x}$ 近, 非高杠杆点. 这时, 如果 (x_i, y_i) 处在离开样本群体较远的位置 B , 其作用大略是把 l 平行地带上一点, 而方向变化不大, 意味着这不太会影响对回归系数的估计而只是影响了其常数项. 从实用上看, 回归系数比模型中的常数项更重要, 因它反映了所考虑的因素对目标变量的影响, 而常数项则只反映原点位置. 因此, 高杠杆点的影响值得注意. 这一点到后面再谈.




图 4.2

对高杠杆点要避免一种误解, 即认为它是不好的. 情况不尽然, 一则样本 x_i 离中心 $\bar{x}$ 有远有近. 在样本量大时, 高杠杆点的存在无可避免. 二则由于 x_i 离中心远, 除非 y_i 异乎寻常地“出格”很多, 它也不足以使经验回归线转动一个太大的角度. 三则如果一切样本 x_i 都云集在其中心 $\bar{x}$ 附近, 情况反而不好. 因为在 GM 模型下有

$$\text{Cov}(\hat{\gamma}) = \sigma^2 S^{*-1}.$$

由此式及 (4.37) 式看出: $\text{Cov}(\hat{\beta}) = \sigma^2 \bar{S}^{-1}$, 而 $\bar{S} = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'$. 当 x_i

都与 $\bar{x}$ 接近时, $\bar{S}$ 会偏小而 $\bar{S}^{-1}$ 偏大, 即 $\text{Cov}(\hat{\beta})$ 偏大. 这意味着 $\hat{\beta}$ 的精度低, 高杠杆点的意义只在于, 在这个点异常的 y 值会对回归系数的估值造成重大影响, 因而值得注意.

h_u 要多大才能算是高杠杆点?这并无公认的规定. 根据 H 为幂等, 有

$$\begin{aligned}\sum_{i=1}^n h_{ii} &= \text{tr}(H) = \text{tr}(X^* S^{*-1} X^{*'}) = \text{tr}(S^{*-1} X^{*'} X^*) \\ &= \text{tr}(S^{*-1} S^*) = \text{tr}(I_{p+1}) = p+1 \quad (p \text{ 为 } \beta \text{ 的维数}).\end{aligned}$$

这里假定了 $n \times (p+1)$ 矩阵 X^* 的秩为 $p+1$ (否则 S^{*-1} 不存在, H 也就只能通过广义逆表示: $H = X^* S^{*-1} X^{*'}$). 这时仍可证明 H 为幂等. 但其 tr 即其秩是等于 X^* 秩 $< p+1$. 因此, $h_{11}, \dots, h_{nn}$ 的平均值为 $(p+1)/n$. 有一种约定是当 $h_{ii} > 2(p+1)/n$ 时认此点为高杠杆点. 如果 n 相对于 p 很大, 则甚至接近于 0 的 h_{ii} 也可能被认为是高杠杆点, 不甚合理. 另一种判法根据如下的结果: 若 (4.25) 式中的 $(y_1, x_1), \dots, (y_n, x_n)$ 为 iid. 正态, 则利用多元分析中 T^2 统计量与 F 分布的关系

$$F \triangleq \frac{n-p-1}{p} \frac{h_{ii}-1/n}{1-h_{ii}} \sim F(p, n-p-1), \quad (4.37)$$

选定 $\alpha \in (0, 1)$ (如 $\alpha = 0.05, 0.01$). 当 $F > F_\alpha(p, n-p-1)$ 时, 认为 F 值因而 h_{ii} 值异常之高, 即当

$$h_{ii} > \left(\frac{n-p-1}{n} + pF_\alpha(p, n-p-1) \right) / (n-p-1 + pF_\alpha(p, n-p-1)) \quad (4.38)$$

时, 认为该点为高杠杆点.

对广义线性模型, 则是移植以上的想法. 当自变量取离散值时, 在 x 的一个值 x_j 处有若干个 (n_j 个) Y 值 $Y_{j1}, \dots, Y_{jn_j}$. 起作用的是其平均 $\bar{Y}_j = n_j^{-1} \sum_{k=1}^{n_j} Y_{jk}$, 这是因为样本有指数型分布, 故其似然函数只依赖于 $\bar{Y}_1, \dots, \bar{Y}_g$. 以下先考虑 1 维的情况.

$$\begin{aligned}\text{按模型有 } \mu_j^0 &= E(\bar{Y}_j) = h(z_j' \beta_0), z_j = z(x_j), \hat{\mu}_j = h(z_j' \hat{\beta}_n). \text{ 有} \\ E(\bar{Y}_j - \hat{\mu}_j)^2 &= E(\bar{Y}_j - \mu_j^0)^2 + E(\hat{\mu}_j - \mu_j^0)^2 \\ &\quad - 2E[(\bar{Y}_j - \mu_j^0)(\hat{\mu}_j - \mu_j^0)] \\ &\equiv J_1 + J_2 - 2J_3,\end{aligned} \quad (4.39)$$

有(回忆前已定义 $\sigma^2(x_j) = \sigma_{\beta_0}^2(x_j)$)

$$J_1 = \sigma^2(x_j)/n_j \quad (4.40)$$

当 n 充分大时, $\hat{\beta}_n \approx \beta_0$. 故近似地有

$$\begin{aligned}
\hat{\mu}_j - \mu_j^0 &= h(z_j' \hat{\beta}_n) - h(z_j' \beta_0) \approx D_j z_j' (\hat{\beta}_n - \beta_0) \approx D_j z_j' F_n^{-1} S_n(\beta_0) \\
&= D_j z_j' F_n^{-1} \sum_{t=1}^g z_t D_t \sigma^{-2}(x_t) n_t (\bar{Y}_t - \mu_t^0)
\end{aligned} \quad (4.41)$$

此处 $D_j = \mathrm{d}h(t)/\mathrm{d}t|_{t=z_j' \beta_0}$. 注意到当 $t \neq j$ 时, $\bar{Y}_j$ 与 $\bar{Y}_t$ 独立, 因而

$$E[(\bar{Y}_j - \mu_j^0)(\bar{Y}_t - \mu_t^0)] = 0.$$

由(4.41)式有

$$J_3 \approx D_j^2 z_j' F_n^{-1} z_j, \quad (4.42)$$

$$\begin{aligned}
J_2 &\approx D_j^2 z_j' F_n^{-1} \left(\sum_{t=1}^g D_t^2 n_t \sigma^{-2}(x_t) z_t z_t' \right) F_n^{-1} z_j \\
&= D_j^2 z_j' F_n^{-1} F_n F_n^{-1} z_j = D_j^2 z_j' F_n^{-1} z_j.
\end{aligned} \quad (4.43)$$

由(4.39) ~ (4.43)式, 得

$$E(\bar{Y}_j - \hat{\mu}_j)^2 \approx n_j^{-1} \sigma^2(x_j) (1 - n_j D_j^2 \sigma^{-2}(x_j) z_j' F_n^{-1} z_j). \quad (4.44)$$

令(g 为 x 取不同值的个数) $\sigma_j^2 = \sigma^2(a_j)$ ($1 \leq j \leq g$), 以及

$$\begin{aligned}
Z &= \begin{bmatrix} z_1' \\ \vdots \\ z_g' \end{bmatrix}, \quad D = \begin{bmatrix} D_1^2 & & 0 \\ & \ddots & \\ 0 & & D_g^2 \end{bmatrix}, \\
\Sigma &= \begin{bmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_g^2 \end{bmatrix}, \quad N = \begin{bmatrix} \sqrt{n_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{n_g} \end{bmatrix}.
\end{aligned}$$

而作方阵

$$K = N D^{1/2} \Sigma^{-1/2} Z \Lambda_n^{-1} Z' \Sigma^{-1/2} D^{1/2} N, \quad (4.45)$$

则易见

$$n_j D_j^2 \sigma_j^{-2} z_j' \Lambda_n^{-1} z_j = K \text{ 的 } (j, j) \text{ 元}. \quad (4.46)$$

而 K 为幂等阵, 此因

$$\begin{aligned}
K^2 &= N D^{1/2} \Sigma^{1/2} Z \Lambda_n^{-1} Z' \Sigma^{1/2} D^{1/2} N \cdot N D^{1/2} \Sigma^{1/2} Z \Lambda_n^{-1} Z' \Sigma^{1/2} D^{1/2} N \\
&= \sum_{t=1}^g n_t D_t^2 \sigma_t^{-2} z_t z_t' = \Lambda_n \\
&= N D^{1/2} \Sigma^{1/2} Z \Lambda_n^{-1} Z' \Sigma^{1/2} D^{1/2} N = K.
\end{aligned} \quad (4.47)$$

在线性回归(且 GM 条件满足), 有 $E(y_j - \hat{y}_j)^2 = \sigma^2(1 - h_{jj})$, 而 h_{jj} 为一幂等阵 H 的 (j, j) 元. 由(4.46)式知, 广义线性模型之下的公式(4.44)形式上与之完全

相似,而我们可以把

$$n_j D_j^2 \sigma_j^{-2} z_j' \Lambda_n^{-1} z_j \approx 1 \quad (4.48)$$

的点 $(\bar{y}_j, x_j)$ 称为高杠杆点 ($D_j, \sigma_j^2, \Lambda_n$ 与 β_0 有关,可用 $\hat{\beta}_n$ 代 β_0). 不同的是:

1. (4.46) 式左边不只依赖 z_j (z_j 相当于线性模型中的 $(1, x_j')$), 还依赖于未知的参数真值 β_0 , 需用其估计值 $\hat{\beta}_n$ 替代;
2. 公式(4.44)只是近似而非严格成立;
3. (4.44) 式右边还有因子 σ_j^2, n_j^{-1} .

因此,除了高杠杆点((4.48)式成立之点)有“把经验回归拖向自己”的效应外, σ_j^2 很小或 n_j 很大之点,也有这种效应,即后两种情况也是值得重视之点. 或者看其综合效应:使(4.44)式右边很小之点有把经验回归拖向自己的效应,即为“高杠杆点”. 以上讲的是 y 为1维的情况. 若 y 为 q 维,则仍以 $\bar{y}_j = (\bar{y}_{j1}, \dots, \bar{y}_{jq})'$ 记自变量 x 取值 a_j 时 y 的所有观察值的算术平均: $z_j = z(x_j)$ 有形状

$$z_j = \begin{bmatrix} z_{j1}' \\ \vdots \\ z_{jq}' \end{bmatrix}, \text{ 每个 } z_{jk}' \text{ 为 } p \text{ 维行向量, } p: \beta \text{ 的维数,}$$

替代一维 $E(\bar{y}_j - \hat{\mu}_j)^2$, 取 $\text{Cov}(\bar{y}_j - \hat{\mu}_j)$. 此处 $\mu_j^0 = E_{\beta_0}(\bar{y}_j) = (\mu_{j1}^0, \dots, \mu_{jq}^0)'$,

它依赖于参数真值 β_0 , 而 $\hat{\mu}_j = (\hat{\mu}_{j1}, \dots, \hat{\mu}_{jq})'$ 则是以 $\hat{\beta}_n$ 以代 β_0 的结果. 有

$$\text{Cov}(\bar{y}_j - \hat{\mu}_j) = \text{Cov}(\bar{y}_j - \mu_j^0) + \text{Cov}(\hat{\mu}_j - \mu_j^0) - E[(\bar{y}_j - \mu_j^0)(\hat{\mu}_j - \mu_j^0)'] \\ - E[(\hat{\mu}_j - \mu_j^0)(\bar{y}_j - \mu_j^0)'] \quad (\text{Cov, E 即 } \text{Cov}_{\beta_0}, E_{\beta_0}, \text{下同}).$$

使用类似于(4.39) ~ (4.44)式的推理,易得

$$\text{Cov}(\bar{y}_j - \hat{\mu}_j) = \Sigma_j^{1/2} (I_q - n_j \Sigma_j^{-1/2} D_j z_j F_n^{-1} z_j' D_j' \Sigma_j^{-1/2}) \Sigma_j^{1/2} / n_j. \quad (4.49)$$

此处

$$D_j = \left. \frac{\partial h(t)}{\partial t'} \right|_{t=z_j \beta_0} \quad (h = g^{-1}, g \text{ 为联系函数}), \quad \Sigma_t = \text{Cov}(y_t | x_t = a_j).$$

令

$$z = \begin{bmatrix} z_1 \\ \vdots \\ z_g \end{bmatrix}, \quad D = \begin{bmatrix} D_1 & & 0 \\ & \ddots & \\ 0 & & D_g \end{bmatrix},$$

$$\Sigma = \begin{bmatrix} \Sigma_1 & & 0 \\ & \ddots & \\ 0 & & \Sigma_g \end{bmatrix}, \quad N = \begin{bmatrix} \sqrt{n_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{n_g} \end{bmatrix},$$

而作方阵

$$K = N\Sigma^{-1/2}DzF_n^{-1}z'D'\Sigma^{-1/2}N,$$

其中, K 为 gq 阶方阵, 将其分块为 g^2 个 q 阶方阵, 则主对角线上第 j 块即为 $n_j\Sigma_j^{-1/2}D_jz_jF_n^{-1}z_j'D_j'\Sigma_j^{-1/2}$, 且 K 为幂等阵. 这个形式统一了 $q=1$ 和 $q>1$ 两种情况.

由 (4.49) 式, 仿照 $q=1$ 时 (4.44) 式的情况, 可以把满足

$$n_j\Sigma_j^{-1/2}D_jz_jF_n^{-1}z_j'D_j'\Sigma_j^{-1/2} \approx I_q \quad (4.50)$$

的点称为高杠杆点. 由于 $n_j\Sigma_j^{-1/2}d_jz_j\Lambda_n^{-1/2}z_j'D_j'\Sigma_j^{1/2} \leq I_q$, 也可以用

$$\text{tr}(n_j\Sigma_j^{-1/2}D_jz_jF_n^{-1}z_j'D_j'\Sigma_j^{-1/2}) \approx g \quad (4.51)$$

来取代 (4.50) 式. 与 $q=1$ 的情况一样, 一个点对经验回归影响的大小, 还与 Σ_j 与 n_j 有关.

4 3 2 强影响点

一个样本点 (y_i, x_i) 对回归系数 β_0 的估计有多大的影响? 考察此问题的一个方法是: 把该样本点剔除, 用剩下的样本点对 β_0 作一估计, 记为 $\hat{\beta}_{(i)}$, 与原来 (使用全部样本) 的估计 $\hat{\beta}$ 比较. 若二者差距不大, 则认为此样本点影响不大, 否则就比较大.

对简单线性模型 (4.24) 式, 容易证明

$$\hat{\gamma} - \hat{\gamma}_{(i)} = (X_{(i)}^*{}'X_{(i)}^*)^{-1}x_{(i)}^*Y_i - S^{*-1}x_{(i)}^*\hat{Y}_i/(1-h_{ii}), \quad (4.52)$$

这里 $X_{(i)}^*$ 是在 X^* (见 (4.24) 式中删去第 i 个行向量 $x_{(i)}^*$ 所得的矩阵. $\hat{Y}_i$ 是 (4.26) 式的 $\hat{Y}$ 的第 i 分量, h_{ii} 见 (4.32) 式. 在误差 $e_1, \dots, e_n$ 为 iid. 且有公共分布 $N(0, \sigma^2)$, 则有 $\hat{\gamma} - \hat{\gamma}_{(i)} \sim N(0, \sigma^2 M)$, M 是某个只与 $x_1, \dots, x_n$ 有关的矩阵.

故 $\frac{1}{\sigma^2}(\hat{\gamma} - \hat{\gamma}_{(i)})'M^{-1}(\hat{\gamma} - \hat{\gamma}_{(i)}) \sim \chi^2(p+1)$. 用 $L^2 = \frac{1}{n-p-1} \|Y - \hat{Y}\|^2$ 估计 σ^2 , 于是当 n 充分大时, 有

$$(\hat{\gamma} - \hat{\gamma}_{(i)})'M^{-1}(\hat{\gamma} - \hat{\gamma}_{(i)})/L^2 \sim \chi^2(p+1) \quad (\text{近似}). \quad (4.53)$$

(p 是 β 的维数, $(\alpha, \beta')' = \gamma$ 的维数为 $p+1$.) 注意此处我们不能断言 (4.53) 式左边有 F 分布 $F(p+1, n-p-1)$. 因为, 虽则 L^2 与 $\hat{\gamma}$ 独立, 但与 $\hat{\gamma}_{(i)}$ 并非独立.

有了 (4.53) 式, 我们可以计算任一个样本点的“ p 值”. 设 (3.54) 式左边之值记为 a , 则 $P(\chi^2(p+1) > a)$ 称为该样本点的 p 值. p 值愈小, 表示 $\hat{\gamma}_{(i)}$ 离 $\hat{\gamma}$

愈远,而 (y_i, x_i) 对决定回归系数估计的影响愈强,若取 $\alpha = 0.1$,则大致可以说,样本点中大约只有10%,其 $\hat{y}_{(i)}$ 值能达到与 $\hat{y}$ 如此距离的位置.可以约定取一个适当的 α ($0 < \alpha < 1$),称凡是带 p 值 $\leq \alpha$ 的点为强影响点.如果 α 很小,如 $\alpha = 0.05$ 或 0.01 ,而 p 值 $\leq \alpha$,则此点有可能是异常点.

单从统计分析的角度看,我们不希望样本中有个别点对估计结果施加太大的影响.这种情况意味着一种不稳定性,而使我们估计结果缺乏信任感.但也不能一般地说:凡是强影响点都应从样本中剔除.应检查一下该样本的获得情况,如有异常,则该剔除.否则不应仓促剔除.因为有时这种点可能提供某种启示,或有事先未曾估计到的某种新现象的线索.

对广义线性模型,原则上也可建立类似于(4.53)式的极限定理.此处我们只指出方法而不写出全部细节:

$$\begin{aligned}\hat{\beta}_n - \beta_0 &\approx F_n^{-1} S_n(\beta_0), \\ \hat{\beta}_{(i)} - \beta_0 &\approx F_{(i)}^{-1} S_{(i)}(\beta_0),\end{aligned}$$

此处 $\hat{\beta}_{(i)}$, $F_{(i)}$ 和 $S_{(i)}$ 是从样本中去掉 (y_i, x_i) 后算出的 $\hat{\beta}_n$, F_n 和 S_n .于是有

$$\hat{\beta}_n - \hat{\beta}_{(i)} \approx F_n^{-1} S_n(\beta_0) - F_{(i)}^{-1} S_{(i)}(\beta_0). \quad (4.54)$$

(4.54)式右边是 $y_i - \mu_i$ ($1 \leq i \leq n$)的线性函数,可表示为

$$\hat{\beta}_n - \hat{\beta}_{(i)} \approx A_n(\beta_0) T_n,$$

其中, $T_n = (y_1 - \mu_1, \dots, y_n - \mu_n)'$,而 $A_n(\beta_0)$ 为 $p \times n$ 常数矩阵,有

$$E(T_n) = 0, \quad \text{Cov}(T_n) \equiv \Sigma(\beta_0) = \text{diag}(\sigma^2(x_1), \dots, \sigma^2(x_n)) \big|_{\beta=\beta_0}.$$

当 n 充分大时

$$\hat{\beta}_n - \hat{\beta}_{(i)} \sim N(0, A_n(\beta_0) \Sigma(\beta_0) A_n'(\beta_0)) \quad (\text{近似}),$$

以 $\hat{\beta}_n$ 代上式的 β_0 ,得知当 n 充分大时

$$(\hat{\beta}_n - \hat{\beta}_{(i)})' [A_n(\hat{\beta}_n) \Sigma(\hat{\beta}_n) A_n'(\hat{\beta}_n)]^{-1} (\hat{\beta}_n - \hat{\beta}_{(i)}) \sim \chi_p^2 \quad (\text{近似}). \quad (4.55)$$

其作用与意义,一如简单线性模型中的(4.53)式.

我们提到过3个概念:高杠杆点、强影响点、异常点.高杠杆点大体上^①只与

① 在简单线性回归的情况,“大体上”三字可取消.对广义线性模型,因(4.48)式左边的量与真参数值有关而需要用其估计值 $\hat{\beta}$ 取代,而 $\hat{\beta}_n$ 依赖于全体样本,故不能绝对地说只依赖 x_i 的位置.但在 n 较大而 $\hat{\beta}$ 甚接近 β^0 时,这个说法“大体上”正确.

x_i 的位置有关,而后二者则尚依赖于 y_i (以及一定程度上依赖其他样本).高杠杆点是“对回归估计可能有较大影响”的点,而强影响点则是“对回归估计确实有较大影响”的点,它可以是也可以不是高杠杆点.至于异常点,则是指其取得的过程可能带有某种系统性的错误,其外表的表征则往往是孤悬一方而脱离样本的主体,故也有人主张称其为“离群值”.仅从某样本点“离群”尚不足以判定它可能受到系统性误差的污染,这需要付诸检验.从统计分析的角度,重要的是该样本点是否对回归估计产生重大的影响.以此看,所谓“强影响点”也好,“异常值”也好,其涵义基本一致.如果说有何区别,那就是“强影响点”的称谓并不暗示此样本点“来历不正”,而“异常点”的称呼就带有这种怀疑.所以,如果有条件对该样本的获得过程进行仔细的考察,以弄清其操作过程“有无异常”,那就最好,免得把一个正常产生的强影响点当作异常点看待.如果这一点没条件做到,那就只能付诸统计检验.比如说,基于(4.55)式的检验即为一可用的方法.还可以用另外的方法.例如,计算 $u_j = \sqrt{n_j} | \bar{Y}_j - \hat{\mu}_j | / \sigma_j(\hat{\beta})$ (记号的意义见前).当 n_j 较大时,此量 $\sim N(0,1)$,故当它取超过某指定数的值时,有理由判它为异常.实际使用这一方法时要注意:我们一般总是在 $u_1, \dots, u_g$ 等 g 个值中排最大的去检验,而这个最大值已不再服从分布 $N(0,1)$.故严格讲,判定其为“异常”的界限,要比按分布 $N(0,1)$ 所定的大一些.比方说,若指定水平 α ,这界限可限为 $\Phi^{-1}\left(\frac{1}{2} + \frac{1}{2}(1-\alpha)^{1/g}\right)$, Φ 为 $N(0,1)$ 的分布函数^①.

4.3.3 残差

样本 y_i 与其从模型中估得的“理论值”之差,称为(该样本点的)残差.所谓“理论值”,即 $E(y_i) \triangleq \mu_i$ 的估计 $\hat{\mu}_i$.在简单线性模型且误差 $e_1, \dots, e_n$ 为 iid. $\sim N(0, \sigma^2)$ 的场合,残差的确切分布不难求得,对广义线性模型则只能满足于近似结果.

残差分析的目的,一是根据全部样本的残差的整体表现,去研判模型是否存

① 若 $u_1, \dots, u_g$ iid, 有公共分布 $N(0,1)$, $u = \max_{1 \leq j \leq g} |u_j|$, 则 $P(u \leq c) = P(|u_j| \leq c, j = 1, \dots, g) = [\Phi(c) - \Phi(-c)]^g = [2\Phi(c) - 1]^g$ 当 $c = \frac{1}{2} + \frac{1}{2}(1-\alpha)^{1/g}$ 时,此值为 $1-\alpha$,故 $P(u > c) = \alpha$.

在问题和存在哪种问题.一般地,当模型没有严重的系统性错误(如,假定回归函数为线性,其实是二次的或周期的;假定误差为等方差,其实误差方差是随 x 的值增长而增长等)时,残差在整体表现上应给人一种杂乱无章的印象,从中看不出什么明显的倾向性.从这也可领悟到,残差分析是一种 informal 的工具.专家告诫要避免“Overinterpretation”(“过度解释”、“求甚解”,陶渊明:“好读书,不求甚解”).此语大体上可理解为:只有那种一眼望去就能感觉到的(残差图上的)倾向性,才是比较可靠的.如残差图呈明显的弯曲形态,可判断线性假设可能有问题.残差沿某一方向系统地增大表明等方差假设可能有问题等.这都无明确的规律可循.使用者依自己对问题背景的了解和经验,结合某些统计知识,去进行研判.它说到底只是一种辅助性的工具,其作用是有限的,不能对之期望太高.另外,残差有多种类型(上面提到的 $y - \hat{y}$ 只是其一,且不是最常用的一种),有时需要进行适当的变换后才计算残差,这些问题的恰当处理无不依赖使用者的经验(以及有关的专业知识,当然也包括有关的统计理论和方法).不列颠百科全书称统计学是一门“science and art”.art 这个词用在残差分析上是再贴切不过的了.

残差分析的另一个目的是根据个别点的残差去研判该点是否为异常点,这通常是指那种点,其残差(绝对值)与其他点的残差比较起来是突出地大.这个问题已在上面 4.3.2 小节中提到过了.

在广义线性模型中,最常用的残差有两种:

1. 学生化残差

$$r_{ip} = (y_i - \hat{\mu}_i) / \sigma(\hat{\mu}_i),$$

又称 Pearson 残差,其中, $\mu_i = E(y_i) = h(z_i' \beta_0)$, $\hat{\mu}_i = h(z_i' \hat{\beta}_n)$, $z_i = Z(x_i)$, $\hat{\beta}_n$ 为 β_0 的 MLE, $\sigma^2(\mu)$ 为方差函数: $E(y) = \mu$, $\text{Var}(y) = \sigma(\mu)$. 这是一种中心化和标准化: $(y_i - \mu_i) / \sigma(\mu_i)$ 有均值 0 方差 1, 而 μ_i 用其估计值 $\hat{\mu}_i$ 取代. 这样做是为了有一个统一的比较标准, 如果单看 $|y_i - \hat{\mu}_i|$, 则这个值大不一定意味着 (y_i, x_i) 这个点可能有问题, 而有可能是由于 y_i 的方差大. 如果在同一个 x_i 处有多个 (n_i 个) y 值, 则通常考察其平均 $\bar{y}_i$, 而定义

$$r_{ip} = \frac{\sqrt{n_i}(\bar{y}_i - \hat{\mu}_i)}{\sigma(\hat{\mu}_i)}.$$

当 n_i 很大时, 如果模型没有错误, 将有 $r_{ip} \xrightarrow{d} N(0, 1)$, 可在这一背景下去研判残差图的表现.

当 n_i 不很大时, r_{ip} 不仅与正态有距离, 且其分布也往往是偏斜(非对称)的. 有的作者设计了一些变换以纠正之, 就是以 y_i 的某个函数取代 y_i . 例如在 y 为两点分布($\pi = P(y = 1) = 1 - P(y = 0)$)时, 取

$$\bar{r}_{ip} = \sqrt{n_i} \frac{t(\bar{y}_i) - t(\hat{\pi}_i) + \{\hat{\pi}_i(1 - \hat{\pi}_i)\}^{-1/3}(2\hat{\pi}_i - 1)/6n_i}{\hat{\pi}_i(1 - \hat{\pi}_i)^{1/6}};$$

在 y 为 Poisson 分布时, 取

$$\bar{r}_{ip} = \frac{3}{2} \sqrt{n_i} \frac{\bar{y}_i^{2/3} - (\hat{\mu}_i^{2/3} - \hat{\mu}_i^{-1/3}/q)}{\hat{\mu}_i^{1/6}}.$$

2. Deviance 残差

把 Deviance 定义(4.17) 式中每一项的平方根定义为该点的残差:

$$r_{id} = \text{sgn}(\bar{y}_i - \hat{\mu}_i) \sqrt{2(\bar{l}_i(\xi_i, \xi_i) - \bar{l}_i(\xi_i, \hat{\mu}_{(i)}))}.$$

当 $\bar{y}_i \geq \hat{\mu}_i$ 时, 取正值或 0, 当 $\bar{y}_i < \hat{\mu}_i$ 时取负值. 按导致(4.19) 式的推理, 可知当 n_i 甚大时, 基本上有 $r_{ip} = r_{id}$.

因 $\hat{\sigma}^2(a_j) \rightarrow \sigma^2(a_j)$, 有

$$\hat{\sigma}^2(a_j) = \sigma^2(a_j) + o_p(1) \quad (j = 1, \dots, M).$$

($o_p(1)$ 表示一个依概率收敛于 0 的量).

因 $\sigma^2(a_j) > 0$, 且只有 M 个 j , 故

$$\begin{aligned} \hat{\sigma}^2(a_j) &= \sigma^2(a_j) + \sigma^2(a_j) o_p(1) = (1 + o_p(1)) \sigma^2(a_j) \\ \Rightarrow \frac{1}{\hat{\sigma}^2(a_j)} &= \frac{1}{\sigma^2(a_j)} \frac{1}{1 + o_p(1)} = \frac{1}{\sigma^2(a_j)} (1 + o_p(1)), \end{aligned}$$

(不同位置出现的 $o_p(1)$ 不必相同).

故

$$\begin{aligned} d_n &= \sum_{j=1}^M n_j (\xi_j - \hat{\mu}(a_j))^2 / \hat{\sigma}^2(a_j) \\ &= \sum_{j=1}^M \frac{n_j (\xi_j - \hat{\mu}(a_j))^2}{\sigma^2(a_j)} + o_p(1) \sum_{j=1}^M \frac{n_j (\xi_j - \hat{\mu}(a_j))^2}{\sigma^2(a_j)} \\ &\equiv d_n^* + o_p(1) d_n^*. \end{aligned}$$

若能证明

$$d_n^* \xrightarrow{d} \chi_r^2,$$

则 $d_n^* = O_p(1)$ (在概率上有界). 故

$$o_p(1) d_n^* = o_p(1) O_p(1) = o_p(1).$$

因此, d_n^* 与 $d_n^* + o_p(1)d_n^*$ 有相同的极限分布, 即 d_n^* 与 d_n 有相同的极限分布. 为了把这个证明弄得严格, 需要对 (4.8) 式及以下的证明做更精细的处理.

记 $D_j^* = dh(t)/dt|_{t=z_j\beta^*}$, (4.8) 式改为

$$\begin{aligned}\xi_j - \hat{\mu}(a_j) &= [\xi_j - \mu(a_j)] - z_j' D_j^* (\hat{\beta}_n - \beta_0) \\ &= [(\xi_j - \mu(a_j) - z_j D_j (\hat{\beta}_n - \beta_0))] + z_j (D_j - D_j^*) (\hat{\beta}_n - \beta_0) \\ &\equiv A_j + B_j.\end{aligned}\quad (4.56)$$

假定 $dh(t)/dt$ 连续, 则因 $\hat{\beta}_n$ 相合, 而 $\{z_j, j = 1, \dots, M\}$ 有界, 有

$$\max_{1 \leq j \leq M} \|z_j(\beta^* - \beta_0)\| = o_p(1).$$

故有 $D_j - D_j^* = o_p(1)$ ($j = 1, \dots, M$), 而 $\{z_j\}$ 为有界. 故

$$z_j(D_j - D_j^*) = o_p(1) \quad (j = 1, \dots, M). \quad (4.57)$$

另一方面

$$F_n = \sum_{j=1}^M \sigma^{-2}(a_j) n_j \nu_j^2 z_j z_j'.$$

因 $D_j > 0, 0 < \sigma^{-2}(a_j) < \infty$ ($j = 1, \dots, M$), $\sum_{j=1}^M z_j z_j' > 0$ 以及 $\sum_{j=1}^M n_j = n$, 有

$F_n \geq cnI$, 对某个 $c > 0$ 与 n 无关. 再由 $F_n^{1/2}(\hat{\beta}_n - \beta_0) \xrightarrow{d} N(0, I)$, 知 $\hat{\beta}_n - \beta_0 = O_p(F_n^{-1/2}) = O_p(n^{-1/2})$, 于是由此及 (4.57) 式, 知

$$(4.56) \text{ 式中的 } B_j = o_p(1) O_p(n^{-1/2}) = o_p(n^{-1/2}) \quad (j = 1, \dots, M), \quad (4.58)$$

有

$$\begin{aligned}d_n^* &= \sum_{j=1}^M \frac{n_j (A_j + B_j)^2}{\sigma^2(a_j)} \\ &= \sum_{j=1}^M \frac{n_j A_j^2}{\sigma^2(a_j)} + \sum_{j=1}^M 2 \frac{n_j A_j B_j}{\sigma^2(a_j)} + \sum_{j=1}^M \frac{n_j B_j^2}{\sigma^2(a_j)} \\ &\equiv G_1 + G_2 + G_3.\end{aligned}\quad (4.59)$$

按讲义上的证明, 有

$$G_1 \xrightarrow{d} \chi_r^2 \textcircled{1}. \quad (4.60)$$

按 Schwartz 不等式:

$$\begin{aligned} \left(\sum_{j=1}^M \frac{n_j A_j B_j}{\sigma^2(a_j)} \right)^2 &= \left(\sum_{j=1}^M \frac{\sqrt{n_j} A_j}{\sigma^2(a_j)} \frac{\sqrt{n_j} B_j}{\sigma(a_j)} \right)^2 \leq \sum_{j=1}^M \frac{n_j A_j^2}{\sigma^2(a_j)} \sum_{j=1}^M \frac{n_j B_j^2}{\sigma^2(j)} \\ &= G_1 K. \end{aligned} \quad (4.62)$$

因(4.58)式, $B_j^2 = o_p(n^{-1})$, 而 $\sum_{j=1}^M \frac{n_j}{\sigma^2(a_j)} = O(n)$. 故

$$G_3 = o_p(n^{-1}) O(n) = o_p(1). \quad (4.63)$$

由(4.60)式,有

$$G_1 = O_p(1). \quad (4.64)$$

结合(4.62) ~ (4.64)式,知

$$G_2^2 \leq 4G_1 = 4O_p(1) o_p(1) = o_p(1). \quad (4.65)$$

而 $G_2 = o_p(1)$. 由此及(4.63)式,知

$$G_2 + G_3 = o_p(1).$$

此与(4.59)和(4.60)式结合,得 $d_n^* \xrightarrow{d} \chi_r^2$.

暂设 y_i 为 1 维,有指数型分布

$$\exp(\theta_i y_i - b(\theta_i)) d\nu(y_i) \quad (i = 1, \dots, n).$$

对数似然函数

$$l_n = \sum_{i=1}^n [\theta_i y_i - b(\theta_i)].$$

① 在书中证明(4.60)式的过程中还有一个所似之处,即(4.12)式在证明 $\hat{\beta}_n$ 的渐近正态性时曾得出 $F_n^{-1/2}(\hat{\beta}_n - \beta_0) = F_n^{-1/2} S_n(\beta_0) + o_p(1)$ (见(2.47)式)

故有

$$\begin{aligned} J_2 &= (F_n^{-1/2} S_n(\beta_0))' F_n^{-1/2} (\hat{\beta}_n - \beta_0) = (F_n^{-1/2} S_n(\beta_0))' [F_n^{-1/2} S_n(\beta_0) + o_p(1)] \\ &= S_n'(\beta_0) F_n^{-1} S_n(\beta_0) + o_p(F_n^{-1/2} S_n(\beta_0)). \end{aligned} \quad (4.61)$$

因 $F_n^{-1/2} S_n(\beta_0) \xrightarrow{d} N(0, I)$ (讲义(2.41)式,此处 $S_n(\beta_0)$ 即该处的 S_n). 故 $F_n^{-1/2} S_n(\beta_0) = O_p(1)$, 因而 $o_p(F_n^{-1/2} S_n(\beta_0)) = o_p(1)$. 因此有

$$J_2 = J_3 + o_p(1)$$

这样, (4.13) 式改为 $d_n^* = J_1 - S_n'(\beta_0) F_n^{-1} S_n(\beta_0) + o_p(1)$. 书中已证 $T_n - S_n'(\beta_0) F_n^{-1} S_n(\beta_0) \xrightarrow{d} \chi_r^2$, 故 $d_n^* \xrightarrow{d} \chi_r^2$ (d_n^* 相当此处的 G_1), 即(4.60)式.

考虑 l_n 的不受限制(即 $\theta_1, \dots, \theta_n$ 自由变化)的极大值,

$$\partial l_n / \partial \theta_i = y_i - \dot{b}(\theta_i) = 0.$$

最大值在 $\theta_i^* = \dot{b}^{-1}(y_i)$ 处达到. 因 $\partial^2 l_n / \partial \theta_i^2 = -b''(\theta_i) < 0$ ($b''(\theta_i) = \text{Var}(y_i) > 0$), 知 θ_i^* 确为极大值点. 而 l_n 的不受限制的极大值为

$$l_n^* = \sum_{i=1}^n [y_i \dot{b}^{-1}(y_i) - b(\dot{b}^{-1}(y_i))].$$

另一方面, 在广义线性模型下, $\theta_i = u(z_i' \beta)$. θ_i 不能自由变化(原来 $\theta_1, \dots, \theta_n$ 自由变化, 有 n 个自由度. 现都通过 β 表出, β 为 p 维, 故 $\theta_1, \dots, \theta_n$ 只剩下 p 个自由度). l_n 表达式

$$l_n = \sum_{i=1}^n [y_i u(z_i' \beta) - b(u(z_i' \beta))],$$

其极大值在 $\beta = \text{MLE } \hat{\beta}_n$ 处达到, 为

$$\tilde{l}_n = \sum_{i=1}^n [y_i u(z_i' \hat{\beta}_n) - b(u(z_i' \hat{\beta}_n))].$$

二者之差

$$\begin{aligned} DE_n &\equiv 2(l_n^* - \tilde{l}_n) \\ &= 2 \sum_{i=1}^n \{ [y_i \dot{b}^{-1}(y_i) - b(\dot{b}^{-1}(y_i))] - [y_i u(z_i' \hat{\beta}_n) - b(u(z_i' \hat{\beta}_n))] \} \\ &\equiv \sum_{i=1}^n DE_{ni}, \end{aligned}$$

必 ≥ 0 . 且每一项 $DE_{ni} \geq 0$. 这个差反映数据与模型的偏离程度: 如模型正确, 则因 θ_i 确有 $u(z_i' \beta)$ 的形状, l_n 的无限制和有限制极值应比较接近, 这时 DE_n 应倾向于小. 反之, 若模型不正确, 则会倾向于大——注意这里所说模型正确与否, 不是指 y_i 是否有指数分布(因这一点已作为假定, 认为是正确的), 而只是指 $\theta_i = u(z_i' \beta)$ 这一设定是否正确.

因此 DE_n , 称为(由给定数据算出的)Deviance. 每个 DE_{ni} 称为该样本点的 Deviance. 在 x 为连续变量时, $x_1, x_2, \dots, x_n$ 各个不同, DE_n 的(极限)分布不知. 在 $x_1, x_2, \dots$ (直至 ∞) 中只有有限个不同值 $\{a_j\}$, 且在 $\{a_j\}$ 中恰有 M 个, 其被取到的次数随 $n \rightarrow \infty$ 而 $\rightarrow \infty$, 则在模型正确时, 有

$$DE_n \xrightarrow{d} \chi_{M-p}^2 \quad (p \text{ 为 } \beta \text{ 的维数, } M > p).$$

多维情况与此完全类似. 只是 $\theta_i y_i - b(\theta_i)$ 改为

$$\theta_i' y_i - b(\theta_i).$$

对 θ_i 求导数, 得 $y_i - \dot{b}'(\theta_i)$ 而极大值点为 $\theta_i = \dot{b}'^{-1}(y_i)$. Deviance 的定义完全一样. 只是(在模型正确时) DE_n 极限分布为 χ_{qM-p}^2 , q 为 y 的维数, M, p 的意义同前.

为证明这一结果, 按书中的做法, 把 l_n 表为 y_i 与 $\mu_i (= E_\beta(y_i) = \dot{b}'(\theta_i))$ 的函数:

$$\begin{aligned} l_n &= \sum_{i=1}^n (y_i' \dot{b}'^{-1}(\mu_i) - b(\dot{b}'^{-1}(\mu_i))) \\ &\equiv \sum_{j=1}^M (n_j \xi_j \dot{b}'^{-1}(\mu_{(j)}) - n_j b(\dot{b}'^{-1}(\mu_{(j)}))), \\ \xi_j &= \frac{1}{n_{j_i}} \sum_{x_i = a_j} y_i' \quad (x_1, \dots, x_n \text{ 中有 } n_j \text{ 个 } a_j), \end{aligned}$$

则

$$\begin{aligned} l_n^* &= \sum_{j=1}^M n_j (\xi_j \dot{b}'^{-1}(\xi_j) - b(\dot{b}'^{-1}(\xi_j))), \\ \bar{l}_n &= \sum_{j=1}^M n_j (\xi_j \dot{b}'^{-1}(\hat{\mu}_{(j)}) - b(\dot{b}'^{-1}(\hat{\mu}_{(j)}))). \end{aligned}$$

$\hat{\mu}_j = \mu_i$ 的估计 $= \dot{b}'(u(z_i' \hat{\beta}_n))$, $x_i = a_j$. 用中值定理, 得到 $2(l_n^* - \bar{l}_n)$ 的表达式渐近地与 Pearson 统计量相同. 检验非线性假设

$$H: f(\beta) = a, \quad f \text{ 为 } r \text{ 维函数: } f = \begin{bmatrix} f_1 \\ \vdots \\ f_r \end{bmatrix}.$$

当 H 成立时, 即 $f(\beta_0) = a$ 时, 有

$$\begin{aligned} f(\hat{\beta}_n) - a &= f(\hat{\beta}_n) - f(\beta_0) \\ &= \left. \frac{\partial f}{\partial \beta'} \right|_{\beta=\beta_0} (\hat{\beta}_n - \beta_0) + o_p(\hat{\beta}_n - \beta_0) \\ &\approx D(\hat{\beta}_n - \beta_0), \\ D &= \left. \frac{\partial f}{\partial \beta'} \right|_{\beta=\beta_0} = DF^{-1/2} F_n^{1/2} (\hat{\beta}_n - \beta_0) \approx DF_n^{-1/2} Z, \\ Z &\sim N(0, I) \sim N(0, C), \quad C = DF_n^{-1} D'. \end{aligned}$$

故当 H 成立, 而样本量 $n \rightarrow \infty$ 时, 有

$$T_n \equiv [f(\hat{\beta}_n) - a]'(DF_n^{-1}D')^{-1}[f(\hat{\beta}_n) - a] \xrightarrow{d} \chi_r^2.$$

于是可取

$$T_n > \chi_r^2(\alpha)$$

作为否定域.

上述推导可以在一定的条件下严格化. 为了作统计量 T_n , $DF_n^{-1}D'$ 必须可逆. 这要求 $r \leq \beta$ 的维数 p , 且 $r \times p$ 矩阵 D 必须“行满秩”, 即某秩 = D 的行数 r .

注 在文献中对指数族常写成形式

$$\exp\left(\frac{y\theta - b(\theta)}{\phi}\right) d\mu(\phi, y), \quad (4.66)$$

其中, ϕ 为 (θ 以外的) 另一参数, 其所以这样写, 理由是此分布的期望为 $\dot{b}(\theta)$ 而方差为 $\phi b(\theta)$, 多了一个调节因子 ϕ , 以适应这样的情况: 数据的均值方差与指数分布族拟合不好 (如此处“超散布性”所显示的情况), 需要通过一个因子来调节之.

但要注意, (4.66) 式的形状不是普通成立. 因其积分为 1 推出

$$\int_y \exp\left(\frac{y\theta}{\phi}\right) d\mu(\phi, y) = e^{b(\theta)/\phi}. \quad (4.67)$$

这就要求, 对给定的 $b(\theta)$, 都有不依赖于 θ 的测度族 $\{\mu(\phi, y)\}$ 使 (4.67) 式成立. 除少数例外 (正态、Gamma 等), 这不成立.

另外, 即使从 (4.67) 式出发, 所写出的似然方程, 仍与从 $\exp(y\theta - b(\theta)) \cdot d\mu(y)$ 出发写出的一致. 即: 引进形式 (4.67) 对估计 θ 毫无影响, 而 MLE 法也不足以估计 ϕ (要另想办法). 这表明: 形式 (4.67) 实质无用.


因此本书不采用这个形式. 又以上所讲对 y 为多维也有效.

陈希孺文集

《陈希孺统计文选》
《高等数理统计学》
《概率论与数理统计》
《数理统计学教程》
《非参数统计》
《广义线性模型的拟似然法》

定价：25.00元

ISBN 978-7-312-02284-5



9 787312 022845 >