


陈希孺 方兆本
李国英 陶 波 / 著
中国科学技术大学出版社


非参数统计

陈希孺文集



陈希孺 方兆本
李国英 陶 波 / 著
中国科学技术大学出版社

非参数统计



陈希孺文集

内 容 简 介

非参数统计是数理统计学中一个体系博大、理论精深且富有实用价值的分支,本专著对非参数统计的理论和方法进行了系统的论述,内容上有一定的广度和深度,经典全面,反映了本学科的现代面貌,语言表达具有简洁、朴实的特点,适合于高等学校概率和统计专业的本科生、研究生与老师,数理统计研究工作者以及具有相当数学水平的实用统计工作者阅读.

图书在版编目(CIP)数据

非参数统计/陈希孺,方兆本,李国英,陶波著. —合肥:中国科学技术大学出版社,2012.4

(陈希孺文集)

ISBN 978-7-312-02283-8

I. 非… II. ①陈…②方…③李…④陶… III. 非参数统计—高等学校—教材 IV. O212.7

中国版本图书馆 CIP 数据核字(2011)第 227889 号

出版 中国科学技术大学出版社

安徽省合肥市金寨路 96 号,邮编:230026

网址: <http://press.ustc.edu.cn>

印刷 合肥晓星印刷有限责任公司

发行 中国科学技术大学出版社

经销 全国新华书店

开本 710 mm×960 mm 1/16

印张 20.25

插页 1

字数 370 千

版次 2012 年 4 月第 1 版

印次 2012 年 4 月第 1 次印刷

定价 38.00 元

总 序

陈希孺先生是我国杰出的数理统计学家和教育家,1934年2月出生于湖南望城,1956年毕业于武汉大学数学系,先后在中国科学院数学研究所、中国科学技术大学数学系和中国科学院研究生院工作,1980年晋升为教授,1997年当选为中国科学院院士,并先后当选为国际统计学会(ISI)的会员和国际数理统计学会(IMS)的会士.陈先生的毕生精力都贡献给了我国的科学事业和教育事业,取得了令人瞩目的成就,做出了若干具有国际影响的重要工作,这些基本上反映在他颇丰的著述中:出版专著和教科书14部,统计学科普读物3部.在陈先生的诸多著作中,教科书占据重要的位置,一直被广泛用作本科生和研究生的基础课教材,在青年教师和研究人员中也拥有众多读者,影响了我国统计学界几代人.

陈希孺先生多年来一直参与概率统计界的学术领导工作,尤其致力于人才培养和统计队伍的建设.在经过“文革”十年的停顿,我国统计队伍十分衰微的情况下,他多次主办全国性的统计讲习班,带领、培养和联系了一批人投入研究工作,这对于我国数理统计队伍的振兴和壮大起到了重要作用.陈先生在中国科学技术大学数学系任教长达26年之久,在教书育人和学科建设等方面做出了重要贡献.中国科学技术大学概率统计学科及其博士点能有今天

这样的发展,毋庸置疑,是与陈先生奠基性的工作以及一贯的悉心指导和关怀完全分不开的。

陈希孺先生是我十分敬重的一位数学家。1983年我国首批授予博士学位的18人中,就有3位出自他的门下,一时传为佳话。令人扼腕浩叹的是,陈先生已于3年前过早地离开了我们。我坚信,陈先生在逆境中奋发求学的坚强意志,敦厚的为人品格,严谨的治学态度,奖掖后学的高尚风范,连同他的大量著作,将会成为激励我们前行的一笔非常宝贵的精神财富。

这次出版的《陈希孺文集》,是在陈希孺先生的夫人朱锡纯先生授权下,由中国科学技术大学出版社编辑出版的。该文集收集了陈先生在各个时期已出版的著述和部分遗稿,迄今最为全面地反映了陈先生一生的科研和教学成果,一定会对学术界和教育界具有重要的参考价值。值得一提的是,中国科学技术大学出版社决定以该文集出版的经营收益设立“陈希孺统计学奖”,我想,这应该可以看做我们全体中国科学技术大学师生员工对为学校的发展做出贡献的老一辈科学家和教育家的一种敬仰和感念吧!

中国科学技术大学校长
中国科学院院士

2008年初冬于中国科学技术大学

前 言

非参数统计是数理统计学的一个分支,它形成于 20 世纪 40 年代,而在第二次世界大战以后得到迅速发展,至今已成长为一个体系博大、理论精深且富有实用价值的分支,受到数理统计学者和应用工作者的重视.

本书的目的是对非参数统计的理论和方法作一比较严格而系统的论述.本书属于专著性质,我们的主观愿望是在取材上能有一定的广度和深度,以反映本学科的现代面貌;另一方面,我们也希望本书的读者面能尽量广一些,因而在预备知识的要求方面以及在使用数学工具的深度方面,不能不加以一定的限制,并舍弃一些过于专业的材料.因此,本书也带有“非参数统计引论”的性质.

本书的读者对象是高等学校概率和统计专业的本科生、研究生与教师,数理统计研究工作者以及具有相当数学水平的实用统计工作者.本书绝大部分内容所需要的预备知识是大学数学系的微积分(或比较扎实的非数学系的高等数学)及少量的矩阵知识,以及相当于复旦大学数学系主编的《概率论与数理统计》一书中的概率与统计知识,个别地方用到一点测度论和分析概率论的知识.

本书是根据我们以往在学习、讲授和研究这个分支过程中所积累的一些笔记资料并参考了国外近年出版的一些专著编写而成的.1982 年夏初稿完成,曾在四川大学

一个讲习班上试用过,在此基础上,我们又分头收集材料,做了整理和加工,最后由陈希孺执笔定稿,以利于在表述方式、行文和符号等方面达到统一.本书是集体工作的成果,但在最后定稿中出现的问题,由执笔者负责.由于作者们的水平所限,书中不妥之处在所难免,希望同行学者、专家及其他读者不吝指正.

作 者

目 次

001 总序

003 前言

001 引言

007 第 1 章 次序统计量

008 1.1 基本分布

014 1.2 渐近分布

032 1.3 次序统计量的充分性与完全性

034 1.4 次序统计量的应用

047 第 2 章 U 统计量

048 2.1 基本概念

054 2.2 U 统计量的渐近正态性

063 2.3 多样本 U 统计量

068 2.4 若干补充知识

073 第3章 秩统计量的极限理论

074 3.1 引言与例子

081 3.2 同分布情况下线性秩统计量的渐近正态性

109 3.3 不同分布情况下线性秩统计量的渐近正态性

114 3.4 结存在的情况

123 第4章 秩方法

124 4.1 检验的渐近相对效率

149 4.2 局部最优的秩检验

158 4.3 对称中心与位置参数的估计

178 4.4 多样本问题与随机区组

194 4.5 随机性与独立性的检验

211 4.6 Смирнов 检验与 Колмогоров 检验

219 第5章 条件检验与置换检验

220 5.1 定义与例子

230 5.2 置换检验的渐近性状

256 5.3 检验的渐近功效

267 第6章 稳健性概念

268 6.1 稳健性概念的一般描述

274	6.2	稳健性概念的数学描述
286	6.3	位置参数的稳健估计
307		参考文献

引 言

本书是一本非参数统计的专著.开宗明义第一件事,就是解释什么是非参数统计和非参数统计方法.不过,这个问题不是三言两语能说清楚的.关于本书在取材上的考虑、各章内容的安排及所用的符号也需作说明,故写了这篇引言.其中有的内容,须具备一些非参数统计的基础知识才能理解,不过初次接触时,浏览一遍就可以了.

先谈第一个问题.

顾名思义,“非参数统计”是“参数统计”的对立面.所谓参数统计,粗略地说,就是在一般教程中常见的一套基于正态假定的统计方法,如 χ^2 检验、 t 检验和 F 检验,正态线性回归,狭义的多元分析等.Fraser的著作^[68]有一个副标题,意谓非参数方法是当正态假定被一般假定取代时的统计方法.这种说法作为一个初步的解释是可以的,但作为非参数统计的正式定义则不可以.因为正态分布族固然是最重要的参数分布族,但不是唯一的重要参数分布族.

把以上的说法加以引申,并适当抽象化,就可以提出下面的说法,以作为划分参数统计问题与非参数统计问题的分界线:如果在一个统计问题中,所假定的总体分布族的数学形式已知,而只包含有限个(通常为少数)未知的实参数,则这个统计问题是参数性的;否则,就是非参数性的.诸如可靠性统计中估计负指数分布和Weibull分布参数的问题,产品抽样验收中对二项分布参数的检验问题等,都是参数统计问题.而确定连续分布的容忍限,一般的两样本检验问题(检验两组样本所来自的总体有相同分布),对称分布(形式未知)的对称中心的估计及形状未知的回归函数的估计问题等等,则都是非参数统计问题.常见的拟合优度检验问题也是非参数性的,因为在此问题中,理论分布是一个有待检验的假设而并非假定.

这个划分的准则是合理且明确易行的,在统计文献中多采取这个说法.本书作者也同意这一观点,但认为还不可完全拘泥于文字.例如,在Gauss-Markov线性模型 $\{Y = X\beta + e, E(e) = 0, \text{Cov}(e) = \sigma^2 I\}$ 中,并未对模型中的随机误差向量 e 的分布的具体形式作什么假定,故按上述准则,这模型的统计问题应是非参数性的,但一般并不这样看:在非参数统计著作中,都不把用最小二乘法处理这个模型的理论和方法包括进去.这是因为,在这个模型中,人们感兴趣的是回归系数向量 β ,它只涉及有限个实参数,且 $X\beta$ 是一个简单的线性形式.又如极值统计,根据极值统计方法中对底分布(参看1.2.3小节)并无特定要求一节,可将其归入非参数统计范围,但是,极值分布只有三种简单的参数族,因此,把它列入参数统计范围,也言之成理.我们的结论是:在多数情况下,参数问题和非参数问题的划分是明确的;在少数情况下,则可因人的看法及侧重点的不同而异,这还要

考虑到习惯.

除了统计问题有参数与非参数之分以外,在文献中,也常把一定的统计方法划为“参数性”的或“非参数性”的.然而,要对此定出合理的划分标准,则问题更复杂了.大体上说,可以把非参数统计方法理解为“处理非参数统计问题的统计方法”.但取之作为正式定义,仍觉有所不足.因为有些重要的统计方法在参数和非参数统计问题中都有用,矩法就是一个例子.又如最小二乘估计法,在形式上看更适合用于参数问题.但如把 Gauss-Markov 模型视为一种非参数模型,这个方法的主要应用则在非参数统计中.

本书作者倾向于采取一种较有伸缩性的观点:一种统计方法,如果主要用于非参数性的统计问题(包括其属性可有争议,但习惯上认为是非参数性的统计问题),则这个方法称为是非参数性的;否则是参数性的.按照这种观点,一个非参数统计方法也可以用于典型的参数统计问题中(反之亦然),但不是它的主要用武之地.一个典型的例子是秩方法(第4章),它是非参数统计的主要方法.但秩方法不仅可以而且确实也用于一些典型的参数统计问题中.置换检验(第5章)按其方法的性质及 Fisher 引进这种思想,是非参数性的统计方法.又如,用次序统计量去构造连续分布的容忍区间,是一种非参数方法,但它也可用于正态分布的情况.不过对后者而言,人们一般使用形如 $\bar{x} \pm cs$ 的区间.又如,由于考虑到 Gauss-Markov 模型在习惯上并不视为非参数性的,故最小二乘估计法就不宜看作是一种非参数方法.

有的统计方法,在参数和非参数问题中都有重要应用,不能勉强将其划入某一类.这时,只好就具体情况而言:该方法适于参数应用还是非参数应用.例如矩估计法,在参数估计中是一个重要方法,但若只假定总体分布有均值,而其他一无所知,则除了用样本均值去估计总体均值外,别无其他良法,这种性质的应用并不限于直接用样本矩估计总体矩,例如,概率密度函数的核估计法(见6.1节),可以认为是一种导源于矩估计思想的方法.所有这都可以说是“矩方法的非参数性应用”.又如,二项分布的概率 p 的检验,无疑是一种参数统计方法,但它在非参数性的对比试验模型中也有重要应用(即符号检验,见3.1节),这可以说是二项分布参数检验法的非参数应用.

下面谈一下文献中关于这个问题的一些值得注意的观点:

Walsh 在文献[172]中把一个方法的非参数性归结为在应用上的广泛性.按照这种观点,二项分布参数的检验法是一种非参数方法,因为有许多问题最后都归结到这个检验问题.本书作者认为,应用的广泛性确实是非参数方法的一个特点(因为它对模型的要求少,应用自然就广了),但以此作为划分标准则不恰当,

因为,一种方法在应用上是否“广泛”,其看法因人而异,尤其重要的是:划分的标准应当着重于方法的性质,而不在于应用上是否广泛.

在另一个极端,Kendall 等^[98]主张,只能讲统计假设的“参数”或“非参数”性,而不能将这些形容词用于检验、统计量等.换句话说,问题有参数与非参数之分,而统计方法则否.他们认为,将一个检验称为“参数”或“非参数”这种提法,已造成了不少混乱.按照这种观点,下面这个两样本问题: $\{X_1, \dots, X_m$ 和 $Y_1, \dots, Y_n$ 分别是取自总体分布 F 和 G 的随机样本,要检验假设 $F \equiv G$ 可称为非参数性的.而一个具体的检验方法,例如 Смирнов 检验(见 4.6 节)则不能冠之以“参数性”或“非参数性”.本书作者认为:这种看法似乎过于绝对化.因为大多数统计方法的应用有其重点所在.据此对方法的性质(参数或非参数)进行划分,不仅可能而且是有益的.

Conovor 在文献[49]中提出如下的看法:一个统计方法,如果适合下述条件之一,就可以称为非参数方法:① 它可用于属性数据;② 它可用于只分别大小次序而不计具体数值的数据;③ 它可用于通常的数据(有具体数值的),其所来自的分布族不能用有限个实参数刻画.我们认为:Conovor 这个提法明确指出了非参数统计方法的主要应用所在.但以此作为定义则似乎欠妥.比方说:最大似然估计与似然比检验可用于属性数据,但这些方法是参数性的.按 Conovor 的观点,最小二乘估计法是非参数方法,因为这方法主要用于 Gauss-Markov 模型,而后的分布族不能用有限个实参数刻画.因此,我们认为 Conovor 的定义有些失之过宽.

美国统计学家常使用一个被称为“分布无关”(distribution-free)的概念,并理解为“非参数性”的同义语.所谓“分布无关”,一般是指下述情况:设样本 X 的分布 F 属于分布族 $\mathcal{F}$,而 $\mathcal{F}_0 \subset \mathcal{F}$.设 $T = T(X)$ 为一统计量,若当 $F \in \mathcal{F}_0$ 时, T 的分布不依赖于 F ,则称 T 相对于 $\mathcal{F}_0$ 为“分布无关”的,例如设 $X = (X_1, \dots, X_n) \sim N(\mu, \sigma^2)$, $\mathcal{F} = \{N(\mu, \sigma^2): -\infty < \mu < \infty, \sigma^2 > 0\}$,指定 μ_0 ,而作 t 统计量 $T = \sqrt{n}(\bar{X} - \mu_0)/s$,则对 $\mathcal{F}_0 = \{N(\mu_0, \sigma^2): \sigma^2 > 0\}$ 而言, T 是分布无关的.因此,“分布无关”这个概念并不专用于非参数性的分布族,对参数族也很重要和常见.这个概念主要用于假设检验, $\mathcal{F}_0$ 是原假设,如果检验统计量 T 相对于原假设 $\mathcal{F}_0$ 为分布无关,就可以作出基于 T 的相似检验.一个显著的例子是秩统计量.在一些非参数检验问题中,往往在原假设成立之下,样本 $X_1, \dots, X_n$ 为独立同分布且分布连续.这时秩统计量相对于原假设下的分布族为“分布无关”的.秩统计量的重要性正在于此.“分布无关”与“非参数”这两个概念不能混同(前者是指统计量的某种性质;后者是指统计问题和方法的性质).不过,“分布无

关”这个概念更多的是用于非参数分布族之中,且在非参数方法中使用的统计量往往有“分布无关”性.因此,“分布无关”这个概念确实从一个重要侧面刻画了“非参数性”的含义.

关于将统计问题和统计方法划分为“参数”或“非参数”的标准问题,以上讲了作者自己的看法及文献中的一些提法.但我们并不是要把某一种意见(包括我们自己的意见)作为结论性的观点推荐给读者,而只是想提供一些材料,供读者思考这个问题时参考.

现在转到第二个问题.

由于对非参数统计和非参数方法的含义有不同的理解,故对于非参数统计中应当包含哪些题材的问题,看法也就不尽一致了.本书在取材问题上的指导思想,除了考虑到对非参数统计的理解及材料在理论和应用上的价值外,也还在一定程度上考虑到习惯与叙述上的方便,而不拘泥于一种想法.例如有关拟合优度的 χ^2 检验和列联表的内容,在性质上可归入非参数统计的范围,但在习惯上则多数是放到其他著作中论述.所以在本书中不包括这一内容.次序统计量的有些内容虽然明显地属于参数统计的范围,但为了照顾到系统性与叙述上的方便,也将其收进本书中,又如第6章中的稳健统计,有一种观点认为这个题材不属于非参数统计,作者也基本上同意这个观点,但考虑到稳健性与非参数的概念有密切联系,并且这方面的材料较新,而在中文文献中介绍得很少,因此将这一题材也收进本书.下面简介各章的内容.

第1章是次序统计量.把一组样本 $X_1, \dots, X_n$ 按大小次序排列为 $X_{(1)} \leq \dots \leq X_{(n)}$, 后者(或其一部分)就称为次序统计量.这一章叙述了这种统计量的分布和渐近分布及其在统计问题上的重要应用.渐近理论方面包含3个内容:样本分位数的渐近正态性;极值($X_{(1)}$ 和 $X_{(n)}$) 的渐近分布;次序统计量的线性组合 $\sum_{i=1}^n C_{ni} X_{(i)}$ 的渐近正态性.这些结果有很强的理论和实际意义.

第2章是 $\bar{U}$ 统计量.它是 Hoeffding 在 1948 年引进的一类统计量(定义见 2.1 节),在一些非参数性的估计和检验问题中 useful.这一章介绍了这种统计量的定义、方差的计算与渐近正态性定理,列举了一些例子并说明其应用.同时介绍了关于其极限理论的若干深入结果,但由于它们的统计意义较小,因此不予详细论证.

第3、4章是基于秩的统计方法.这是非参数统计的中心内容.因此在本书中也给予了较大的篇幅.所谓秩,就是指各样本在其大小比较中所占的位次:若将样本 $X_1, \dots, X_n$ 按大小排列为 $X_{(1)} < \dots < X_{(n)}$, 而 $X_i = X_{(R_i)}$, 则称 X_i 的秩

为 R_i , 而 $(R_1, \dots, R_n)$ 称为秩统计量. 第 3 章主要讨论线性秩统计量的极限分布. 对于同分布的情况做了严格的论证; 对不同分布和结存在的情况则只介绍有关结果 (因为严格的证明过于繁复). 第 4 章可分为两部分: 前两节是讨论秩检验在两种准则 (渐近相对效率与局部最优) 下的优良性. 总的结论是: 秩检验与传统的参数检验相比, 处于有利的地位. 本章后四节讨论秩方法在各种统计问题中的应用——估计问题、方差分析模型、独立性检验、Kolmogorov 与 Smirnov 检验等. 应当指出: Kolmogorov 检验并不是秩方法, 因其与 Smirnov 检验 (它是一个秩检验) 的密切联系而放在这里.

第 5 章的主要内容是置换检验, 又称随机化检验, 是 Fisher 1935 年在其名著^[66]中引进的, 它基于 Fisher 所提出的试验设计三原则之一——随机化原则. 置换检验有重要的理论意义, 因为它把方差分析的理论置于更现实的基础上. 本章通过较多的例子详细分析了条件检验与置换检验的基本思想, 对其大样本理论 (包括大样本极限分布及渐近效率) 作了严格的处理.

第 6 章是关于稳健统计. 这也是比较新的题材. 本章所选择的材料, 主要是关于稳健性的基本概念以及较富于实际意义的理论和结果. 这方面的材料可认为是比较定型的.

本书所用的符号, 大多数在统计文献中是标准的, 例如用 $E, \text{Var}, \text{Cov}$ (或 COV) 记随机变量的均值、方差与协方差 (协方差阵). 用

$$X_n \xrightarrow{P} X, X_n \xrightarrow{a.s.} X, \text{a.s.} \text{ (或 } \lim_{n \rightarrow \infty} X_n = X, \text{a.s.})$$

分别表示: 当 $n \rightarrow \infty$ 时, 变量 X_n 依概率或以概率 1 收敛于变量 X , 若 X_n 的分布为 F_n , 而 F 为一分布函数, 则以 $F_n \xrightarrow{\mathcal{L}} F$ 或 $X_n \xrightarrow{\mathcal{L}} F$ 表示 F_n 或 X_n 依分布收敛于 F ; 以缩写记号“iid.” (independently-identically distributed) 表示“独立同分布”. 若某一总体的总体分布为 F , 而 $X_1, \dots, X_n$ 为取自该总体的独立随机样本, 则常记为 $X_1, \dots, X_n \sim F$. 有时也用记号“ $X \sim F$ ”表示“变量 X 有分布函数 F ”; $X \stackrel{d}{=} Y$ 表示 X 与 Y 的分布相同; 又 I_A 或 $I_A(x)$ 表示集 A 的指示函数, 即在 A 上的值为 1 而在 A 外为 0.

本书也涉及少量的矩阵向量运算, 按一般的表示法: 当将 X 视为向量时, 总是看作列向量, 向量或矩阵 A 的转置记为 A' , 故 X' 表示行向量. 向量 a 与 b 的内积记为 $a'b$. 向量 a 的长度常记为 $\|a\|$. 在任何特定意义下, 两点 x 与 y 的距离也常记以 $\|x - y\|$.

第 1 章

次序统计量

设有样本 $X = (X_1, \dots, X_n)$. 把 $X_1, \dots, X_n$ 按由小到大的次序排列为

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}, \quad (1.1)$$

则 $(X_{(1)}, \dots, X_{(n)})$ 称为样本 X 的次序统计量 (order statistics). 习惯上也常把序列 (1.1) 式的一部分称为次序统计量. 特别, $X_{(i)}$ 常称为第 i 个次序统计量. 在文献中, 有时把 (1.1) 式称为“次序样本” (ordered sample). 如果 $X_1, \dots, X_n$ 是从总体分布 F 中抽出的 iid. 样本, 则称 (1.1) 式是从 F 中抽出的 (大小为 n 的) 次序样本.

次序统计量在统计问题中有广泛的应用, 其理论也有深入的发展. 二十多年来, 出现了不少这方面的专著, 如文献 [53]、[71]、[140]、[83] 和 [132]. 在一定程度上可以说: 次序统计量的研究已形成数理统计学和概率论的一个分支. 本章的目的就是介绍次序统计量的初步理论及其若干应用. 有兴趣的读者可在本章内容的基础上阅读上面提到的专著.

有一点需要明确一下: 次序统计量既可用于典型的非参数统计问题, 如找连续分布函数的分位数的置信区间; 也可用于典型的参数统计问题, 如用极差 (见下面定义 1.1) 的一适当倍数去估计正态分布的标准差. 因此, 从学科角度看: 不好把次序统计量的理论与方法说成是非参数统计的一部分. 但一些作者在撰写非参数统计的著作时, 却往往把次序统计量这个题目纳入其范围内, 这主要是因为: 如在本章 1.4 节中将看到的, 次序统计量有一系列的重要应用确是属于非参数的性质. 但与次序统计量的专著不同, 在非参数统计著作中介绍次序统计量的应用时, 一般不去深入讨论那种纯参数性质的应用. 本章的叙述也遵循这个原则.

本章共分为四节: 1.1 节叙述有关次序统计量分布的若干基本事实; 1.2 节是关于次序统计量的渐近分布的几个重要定理; 1.3 节讨论这种统计量的充分性与完全性; 最后在 1.4 节中, 介绍次序统计量的一些重要应用.

1.1 基本分布

在应用上, 最常见的情况是: $X_1, \dots, X_n$ 是从一个有分布 F 的总体中抽出的 iid. 样本. 本节就在这个假定下来讨论问题.

1.1.1 $X_{(r)}$ 的分布

以 F_r 记 $X_{(r)}$ 的分布函数,依定义有

$$\begin{aligned}
 F_r(x) &= P(X_{(r)} < x) = P(X_1, \dots, X_n \text{ 中至少有 } r \text{ 个小于 } x) \\
 &= \sum_{j=r}^n P(X_1, \dots, X_n \text{ 中恰有 } j \text{ 个小于 } x) \\
 &= \sum_{j=r}^n \binom{n}{j} F^j(x) (1-F(x))^{n-j} \\
 &= \frac{n!}{(r-1)!(n-r)!} \int_0^{F(x)} t^{r-1} (1-t)^{n-r} dt. \quad (1.2)
 \end{aligned}$$

(1.2) 式中最后一式是基于恒等式

$$\sum_{j=r}^n \binom{n}{j} p^j (1-p)^{n-j} = \frac{n!}{(r-1)!(n-r)!} \int_0^p t^{r-1} (1-t)^{n-r} dt, \quad (1.3)$$

$$r = 1, \dots, n, \quad 0 \leq p \leq 1.$$

(1.3) 式不难用下法证明:首先,当 $p = 0$ 时,两边皆为 0;其次,(1.3) 式左边对 p 求导,再经过简单的整理,就得到

$$\frac{n!}{(r-1)!(n-r)!} p^{r-1} (1-p)^{n-r}.$$

若分布 F 有概率密度函数 f ,则由 (1.2) 式易知 $F_r(x)$ 也有概率密度函数 $f_r(x)$,且

$$f_r(x) = \frac{n!}{(r-1)!(n-r)!} F^{r-1}(x) (1-F(x))^{n-r} f(x). \quad (1.4)$$

有两个重要情况对应于 $r = n$ 和 $r = 1$. $X_{(n)}$ 和 $X_{(1)}$ 分别是样本 $X_1, \dots, X_n$ 中的极大和极小值,统称为极值.由 (1.2) 式与 (1.4) 式知

$$F_n(x) = F^n(x), \quad f_n(x) = nF^{n-1}(x)f(x). \quad (1.5)$$

$$F_1(x) = 1 - (1-F(x))^n, \quad f_1(x) = n(1-F(x))^{n-1}f(x). \quad (1.6)$$

1.1.2 多个次序统计量的联合分布

设 $1 \leq r < s \leq n$, 要求 $(X_{(r)}, X_{(s)})$ 的联合分布函数 $F_{rs}(x, y)$ 及密度函数 $f_{rs}(x, y)$, 方法可仿照上一段:为要 $X_{(r)} < x$ 且 $X_{(s)} < y$, 需要在 $X_1, \dots, X_n$ 中恰有 i 个小于 x , 有 $j-i$ 个小于 y , 但不小于 x , 有 $n-j$ 个不小于 y , 这里 $r \leq i \leq j, s \leq j \leq n$. 由此, 利用多项分布, 易得

$$F_{rs}(x, y) = \begin{cases} \sum_{j=s}^n \sum_{i=r}^j \frac{n!}{i!(j-i)!(n-j)!} F^i(x) [F(y) - F(x)]^{j-i} \\ \quad \times [1 - f(y)]^{n-j}, & x < y; \\ F_s(y), & x \geq y. \end{cases} \quad (1.7)$$

再通过求偏导数, 得到 $f_{rs}(x, y)$ 为

$$f_{rs}(x, y) = \begin{cases} \frac{n!}{(r-1)!(s-r-1)!(n-s)!} F^{r-1}(x) [F(y) - F(x)]^{s-r-1} \\ \quad \times [1 - F(y)]^{n-s} f(x) f(y), & x < y; \\ 0, & x \geq y. \end{cases} \quad (1.8)$$

这样的推导在理论上是严格的, 但略繁琐些. 一般说, 仅 $f_{rs}(x, y)$ 有较大的意义, 它可直接推导如下: 因为总有 $X_{(s)} \geq X_{(r)}$, 在 $x \geq y$ 时必有 $f_{rs}(x, y) = 0$. 若 $x < y$, 则为了使 $X_{(r)}$ 落在 $(x, x + \Delta x)$ 内, $X_{(s)}$ 落在 $(y, y + \Delta y)$ 内, 需要在 $(-\infty, x]$ 内有 $X_1, \dots, X_n$ 中的 $r-1$ 个, 在 $(x, x + \Delta x)$ 内有一个, 在 $[x + \Delta x, y]$ 内有 $s-r-1$ 个, 在 $(y, y + \Delta y)$ 内有一个, 而在 $[y + \Delta y, \infty)$ 内有 $n-s$ 个. 另外的情况是: 在 $(x, x + \Delta x)$ 或 $(y, y + \Delta y)$ 中包含不止一个. 这种情况的概率是 $\Delta x \Delta y$ 的高阶无穷小, 由多项式分布得

$$\begin{aligned} f_{rs}(x, y) \Delta x \Delta y &\approx P(x < X_{(r)} < x + \Delta x, y < X_{(s)} < y + \Delta y) \\ &= \frac{n!}{(r-1)!1!(s-r-1)!1!(n-s)!} F^{r-1}(x) \\ &\quad \times [F(y) - F(x)]^{s-r-1} [1 - F(y)]^{n-s} \\ &\quad \times f(x) f(y) \Delta x \Delta y + o(\Delta x \Delta y). \end{aligned}$$

两边除以 $\Delta x \Delta y$, 再令 $\Delta x \rightarrow 0, \Delta y \rightarrow 0$, 即得 (1.8) 式.

有一个重要情况是 $r = 1, s = n$, 有

$$f_{1n}(x, y) = \begin{cases} n(n-1)(F(y) - F(x))^{n-2} f(x) f(y), & x < y; \\ 0, & x \geq y. \end{cases} \quad (1.9)$$

仿此可求出任意个次序统计量的联合分布函数与密度函数, 但这些没有多少实用意义, 故不列出了. 有一个值得注意的情况是: 全体 $(X_{(1)}, \dots, X_{(n)})$ 的密度函数 $f_{12\dots n}(x_1, \dots, x_n)$ 是

$$f_{12\dots n}(x_1, \dots, x_n) = \begin{cases} n! f(x_1) \cdots f(x_n), & x_1 < \cdots < x_n; \\ 0, & \text{其他}. \end{cases} \quad (1.10)$$

1.1.3 总体分布为(0,1)内均匀分布的情况

当总体分布 F 为(0,1)均匀分布 $R(0,1)$, 即有密度函数

$$f(x) = I_{(0,1)}(x)$$

时, 上两段的公式取很简单的形式. 例如(1.4)式成为

$$f_r(x) = \frac{n!}{(r-1)!(n-r)!} x^{r-1} (1-x)^{n-r} I_{(0,1)}(x). \quad (1.11)$$

(1.5) 式和(1.6)式有相应的形式. 又(1.8)式成为

$$f_{rs}(x, y) = \begin{cases} \frac{n!}{(r-1)!(s-r-1)!(n-s)!} x^{r-1} (y-x)^{s-r-1} \\ \quad \times (1-y)^{n-s}, & 0 < x < y < 1; \\ 0, & \text{其他.} \end{cases} \quad (1.12)$$

(1.9) 式有相应的形式. 又全体 $(X_{(1)}, \dots, X_{(n)})$ 密度函数为

$$f_{12\dots n}(x_1, \dots, x_n) = \begin{cases} n!, & 0 < x_1 < \dots < x_n < 1; \\ 0, & \text{其他.} \end{cases} \quad (1.13)$$

这个情况的重要性是基于下面的简单定理:

定理 1.1^① 设随机变量 X 的分布函数 F 处处连续, 则

$$Y \triangleq F(X) \sim R(0,1).$$

证 记 $G(y) = P(Y < y)$, 则由分布函数的性质知: 当 $y \leq 0$ 时, $G(y) = 0$; 当 $y \geq 1$ 时, $G(y) = 1$. 现设 $0 < y < 1$. 记 $x_0 = \sup\{x; F(x) < y\}$, 则 x_0 有限, 且由 F 的连续性知 $F(x_0) = y$. 于是易见 $\{Y < y\} = \{X < x_0\}$, 因而

$$G(y) = P(Y < y) = P(X < x_0) = F(x_0) = y.$$

证毕.

由此定理可知: 若 $X_{(1)} \leq \dots \leq X_{(n)}$ 为从一个有连续分布 F 中抽出的次序样本, 则 $(F(X_{(1)}), \dots, F(X_{(n)}))$ 的分布就是 $R(0,1)$ 中抽出的大小为 n 的次序样本的分布. 这个结果可直接用于求解某些非参数统计推断问题(如 1.4.2 小节), 在理论上则使对某些问题而言可以只考虑总体分布为 $R(0,1)$ 的情况. 这一点使均匀分布在非参数统计中有特殊的地位.

均匀分布的另一个有趣且有用的性质如下:

^① 易证本定理的逆, 也是一个有用的结果: 设 X 的分布函数 F 处处连续. 按定理 1.7 条件 3° 中定义 F 的反函数 F^{-1} , 则 $F^{-1}(U)$ 有分布 F , 此处 $U \sim R(0,1)$.

定理 1.2 以 $X_{(1)} \leq \cdots \leq X_{(n)}$ 记 $R(0,1)$ 中大小为 n 的次序样本. 又 $Z_1, \cdots, Z_n$ 为 iid., Z_1 有负指数分布, 其密度为 $e^{-x}I_{(x>0)}$. 记 $Y_r = \sum_{i=1}^{n+1-r} Z_i / (n+1-i), r = 1, \cdots, n$. 则

$$(-\log X_{(1)}, \cdots, -\log X_{(n)}) \stackrel{d}{=} (Y_1, \cdots, Y_n). \quad (1.14)$$

证 因为 $(X_{(1)}, \cdots, X_{(n)})$ 有密度函数(1.13), 利用概率密度变换公式, 易算出 $(-\log X_{(1)}, \cdots, -\log X_{(n)})$ 的概率密度函数为

$$\begin{cases} n! \exp(-(x_1 + \cdots + x_n)), & x_1 > \cdots > x_n > 0; \\ 0, & \text{其他.} \end{cases} \quad (1.15)$$

又因 $(Z_1, \cdots, Z_n)$ 的密度函数为

$$\exp(-(x_1 + \cdots + x_n))I_{x_1 > 0, \cdots, x_n > 0},$$

由 $(Z_1, \cdots, Z_n)$ 到 $(Y_1, \cdots, Y_n)$ 的变换的 Jacobi 行列式为 $\frac{1}{n!}$, 且 $Y_1 > \cdots > Y_n$,

$\sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i$. 于是由密度变换公式得出 $(Y_1, \cdots, Y_n)$ 的密度函数仍为(1.15)式. 这就证明了(1.14)式.

1.1.4 次序统计量的条件分布

设 $X_{(1)} \leq \cdots \leq X_{(n)}$ 为从总体分布 F 中抽出的次序样本. 固定其中的一个, 例如 $X_{(r)}$ 的值. 要在这个条件下, 求剩下的 $n-1$ 个的条件分布.

为简单计, 我们在 F 处处连续的假定下来讨论: 设给定 $X_{(r)} = t$. 记

$$\begin{cases} \bar{F}(x) = \frac{F(x) - F(t)}{(1 - F(t))}, & x \geq t; \\ \bar{F}(x) = 0, & x < t. \end{cases}$$

$$\begin{cases} \underline{F}(x) = \frac{F(x)}{F(t)}, & x \leq t; \\ \underline{F}(x) = 0, & x > t. \end{cases}$$

$\bar{F}$ 和 $\underline{F}$ 分别是在给定 $X \geq t$ 和 $X \leq t$ (X 有分布 F) 的条件下 X 的条件分布. 根据(1.2)式, 并考虑到 F 处处连续知: X_r 和 $(X_{(1)}, \cdots, X_{(n)})$ 的概率元分别是

$$\frac{n!}{(r-1)!(n-r)!} F^{r-1}(x) [1 - F(x)]^{n-r} dF(x)$$

以及

$n! dF(x_1) \cdots dF(x_n)$, 当 $x_1 < \cdots < x_n$ 时, 他处为 0.

由此知:在给定 $X_{(r)} = t$ 时, $(X_{(1)}, \dots, X_{(r-1)}, X_{(r+1)}, \dots, X_{(n)})$ 的条件概率元为

$$\begin{aligned} & \frac{n! dF(x_{(1)}) \cdots dF(x_{(r-1)}) dF(t) dF(x_{(r+1)}) \cdots dF(x_{(n)})}{(r-1)!(n-r)! F^{r-1}(t)[1-F(t)]^{n-r} dF(t)} \\ &= \{(r-1)! dF(x_{(1)}) \cdots dF(x_{(r-1)})\} \times \{(n-r)! d\bar{F}(x_{(r+1)}) \cdots d\bar{F}(x_{(n)})\}. \end{aligned} \quad (1.16)$$

当 $x_{(1)} < \cdots < x_{(r-1)} < t < x_{(r+1)} < \cdots < x_{(n)}$ 时,而在他处为 0. (1.16) 式可以表述为以下在直观上看很明显的定理:

定理 1.3 设 $X_{(1)} \leq \cdots \leq X_{(n)}$ 是从总体分布 F 中抽出的次序样本. 则在给定 $X_{(r)} = t$ 的条件下, $(X_{(1)}, \dots, X_{(r-1)}, X_{(r+1)}, \dots, X_{(n)})$ 的条件分布由以下三个性质确定:

1° $(X_{(1)}, \dots, X_{(r-1)})$ 与 $(X_{(r+1)}, \dots, X_{(n)})$ 条件独立;

2° $(X_{(1)}, \dots, X_{(r-1)})$ 的条件分布就是从截断分布 $\underline{F}$ 中抽出的大小为 $r-1$ 的次序样本的分布.

3° $(X_{(r+1)}, \dots, X_{(n)})$ 的条件分布就是从截断分布 $\bar{F}$ 中抽出的大小为 $n-r$ 的次序样本的分布.

在定理的叙述中,没有提到 F 的连续性. 因为可以证明:即使 F 不连续,本定理的结论仍真. 但在 F 不连续时,次序统计量的概率元很复杂,因而 (1.16) 式已不成立,且定理 1.3 的证明较繁.

1.1.5 极差和样本分位数的分布

在实际问题中,次序统计量的某些简单函数有重要的应用,其中尤其重要的是极差(range)和样本分位数.

定义 1.1 设样本 $(X_1, \dots, X_n)$ 的次序计量是 $X_{(1)} \leq \cdots \leq X_{(n)}$, 则称 $R = X_{(n)} - X_{(1)}$ 为样本 $(X_1, \dots, X_n)$ 的极差.

定义 1.2 以 $[\alpha]$ 记不超过 α 的最大整数, $0 < p < 1$, 则称

$$\xi_{np} = X_{([\ np])} + (n+1) \left(p - \frac{[\ np]}{n+1} \right) (X_{([\ np]+1)} - X_{([\ np])}). \quad (1.17)$$

为样本 $(X_1, \dots, X_n)$ 的 p 分位数. 当 $p = 1/2$ 时, 特称为样本中位数(sample median), 并记为 m_n . 易见

$$m_n = \begin{cases} X_{(m+1)}, & n = 2m+1; \\ \frac{1}{2}(X_{(m)} + X_{(m+1)}), & n = 2m. \end{cases} \quad (1.18)$$

当 n 较大时,常将样本 p 分位数的定义简化为 $X_{([np]+1)}$ 或 $X_{([n+1)p]}$.

样本 p 分位数常用于估计总体 p 分位数,后者是满足条件 $F(\xi_p) \leq p \leq F(\xi_p + 0)$ 的任何 ξ_p (F 是总体分布).而极差则用于估计总体分布的散布度.

不论是极差或是样本分位数,都有

$$Y = aX_{(r)} + bX_{(s)}, \quad 1 \leq r < s \leq n \quad (1.19)$$

的形式,其中 a, b 为常数.假定 $X_1, \dots, X_{(n)} \sim F$, 而 F 有密度 f . 为求 Y 的密度,不妨设 $a \neq 0 \neq b$. 令 $Z = X_{(r)}$. 则这与 (1.19) 式构成 $(X_{(r)}, X_{(s)})$ 到 (Y, Z) 的一一变换. 根据 (1.8) 式,并利用密度变换公式,易得 (Y, Z) 的密度函数为

$$\begin{aligned} g(y, z) &= \frac{1}{|b|} \frac{n!}{(r-1)!(s-r-1)!(n-s)!} F^{r-1}(z) \\ &\quad \times \left[F\left(\frac{y-az}{b}\right) - F(z) \right]^{s-r-1} \\ &\quad \times \left[1 - F\left(\frac{y-az}{b}\right) \right]^{n-s} f(z) f\left(\frac{y-az}{b}\right) \times I_{(z < (y-az)/b)}. \quad (1.20) \end{aligned}$$

因而得到 Y 的密度为 $\int_{-\infty}^{\infty} g(y, z) dz$.

在 (1.19) 式中令 $a = -1, b = 1, r = 1, s = n$, 得极差 R 的密度为

$$w(y) = n(n-1) \int_{-\infty}^{\infty} [F(y+z) - F(z)]^{n-2} f(y+z) f(z) dz \cdot I_{(y>0)}. \quad (1.21)$$

ξ_{np} 和 m_n 的密度也可以通过在 (1.19) 式中适当选择 a, b 和 r, s 而得出,但其形式很繁,故不在此写出了. 又当 $a = b = 1/2, r = 1, s = n$ 时,由 (1.19) 式定义的 Y 称为中程(midrange),其密度也可如上算出.

若总体分布为 $R(0, 1)$, 则 (1.21) 式不难算出为

$$w(y) = n(n-1)y^{n-2}(1-y)I_{(0<y<1)}. \quad (1.22)$$

1.2 渐近分布

1.2.1 引言

设 $X_1, \dots, X_n \sim F$, F 有密度函数 f . 本节要研究当样本大小 $n \rightarrow \infty$ 时,

$(X_1, \dots, X_n)$ 的次序统计量和它们的线性函数的渐近分布. 这一研究是基于次序统计量的大样本方法的基础. 为了强调与 n 的关系, 将 $(X_1, \dots, X_n)$ 的次序统计量写为

$$X_{n1} \leq X_{n2} \leq \dots \leq X_{nn} \quad (1.23)$$

对每个自然数 n , 选取一个不超过 n 的自然数 k_n , 比值 k_n/n 称为次序统计量 X_{nk_n} 的秩. 若 $\lim_{n \rightarrow \infty} k_n/n$ 存在并记为 λ ($0 \leq \lambda \leq 1$), 则 λ 称为序列

$$X_{1k_1}, X_{2k_2}, \dots, X_{nk_n}, \dots \quad (1.24)$$

的极限秩. 序列 (1.24) 的渐近分布与 λ 有关. 因此, 按 λ 的值将序列 (1.24) 分类.

1° 若 $0 < \lambda < 1$, 则称 (1.24) 为中心项 (central term) 序列, 一个重要的特殊情况是当 $k_n/n - \lambda = o(n^{-1/2})$. 这时称 (1.24) 为正则 (regular) 中心项序列. 例如取定 $p \in (0, 1)$, 则简化形式的样本 p 分位数

$$\xi_{np} = X_{n, [np]+1}, \quad n = 1, 2, \dots \quad (1.25)$$

是一个正则中心项序列.

2° 若 $\lambda = 0$ 但 $k_n \rightarrow \infty$, 或 $\lambda = 1$ 但 $n - k_n \rightarrow \infty$, 则称 (1.24) 为中间项 (intermediate term) 序列.

3° 若 $\{k_n\}$ 有界或 $\{n - k_n\}$ 有界, 则称 (1.24) 为边项 (extreme term) 序列.

近几十年来, 对上述种种情况下的序列 (1.24) 的渐近分布的研究, 获得许多深入的结果. 但对统计应用而言, 重要的只有两种情况: 一是正则中心项序列; 二是边项序列中当 k_n 与 n 无关, 或 $n - k_n$ 与 n 无关的情况, 尤其是 $k_n = n$ 及 $k_n = 1$ 的情形. 在本节中, 只讨论这两个情况, 其他情况可参见有关文献. 如一般中心项的情况可参看文献 [29], 中间项的情况可参看文献 [28]、[150]、[151] 和 [35].

次序统计量的线性函数在应用上有重要意义. 关于其渐近理论, 近十余年来也有很多学者在研究. 本节介绍其中某些结果.

1.2.2 正则中心项序列的渐近正态性

为行文简单计, 下面对序列 (1.25) 进行讨论. 但易看出, 所作的论证适用于一般的正则中心项.

定理 1.4 设 $X_1, \dots, X_n \sim F$, 其次序统计量如 (1.23) 式. 固定 k 个数 $\lambda_1, \dots, \lambda_k$, $0 < \lambda_1 < \dots < \lambda_k < 1$. 设 F 有密度函数 f , f 在 F 的 λ_j 分位数 ξ_j ($j = 1, \dots, k$) 处连续且大于 0. 记

$$\hat{\xi}_n = (\hat{\xi}_{n\lambda_1}, \dots, \hat{\xi}_{n\lambda_k}), \quad \xi = (\xi_{\lambda_1}, \dots, \xi_{\lambda_k}).$$

则当 $n \rightarrow \infty$ 时,有

$$\sqrt{n}(\hat{\xi}_n - \xi) \xrightarrow{\mathcal{L}} N(0, \mathbf{A}). \quad (1.26)$$

此处 $\mathbf{A}$ 为 k 阶方阵,其 (i, j) 元为

$$\lambda_{ij} = \frac{\lambda_i(1 - \lambda_j)}{f(\xi_i)f(\xi_j)}, \quad i \leq j, \lambda_{ji} = \lambda_{ij} \quad (1.27)$$

我们将证明的主要部分分解为几条引理如下:

引理 1.1 设 $\{V_n\}$ 与 $\{T_n\}$ 为两串随机变量,满足以下的条件:

1° $\{T_n\}$ 依概率有界. 也就是说,对任给的 $\epsilon > 0$, 存在 M_ϵ , 使对一切 $n, P(|T_n| \geq M_\epsilon) < \epsilon$ 成立.

2° 对任意指定的常数 a 及 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(V_n \leq a, T_n \geq a + \epsilon) = 0, \quad \lim_{n \rightarrow \infty} P(V_n \geq a + \epsilon, T_n \leq a) = 0,$$

则当 $n \rightarrow \infty$ 时,有

$$V_n - T_n \xrightarrow{P} 0, \quad (1.28)$$

证 任给 $\epsilon > 0, \delta > 0$. 根据条件 1°, 存在自然数 m (与 ϵ, δ 有关), 使对一切 n , 有 $P(|T_n| \geq m\epsilon) < \delta$ 成立.

故

$$\begin{aligned} & P(|T_n - V_n| > 2\epsilon) \\ & < \delta + P(|T_n| \leq m\epsilon, |T_n - V_n| > 2\epsilon) \\ & \leq \delta + \sum_{i=-m+1}^m P((i-1)\epsilon \leq T_n \leq i\epsilon, |T_n - V_n| > 2\epsilon) \\ & \leq \delta + \sum_{i=-m+1}^m P(T_n \leq i\epsilon, V_n \geq i\epsilon + \epsilon) \\ & \quad + \sum_{i=-m+1}^m P(T_n \geq (i-1)\epsilon, V_n \leq (i-1)\epsilon - \epsilon). \end{aligned} \quad (1.29)$$

在 (1.29) 式两边令 $n \rightarrow \infty$, 根据条件 2°, 得

$$\limsup_{n \rightarrow \infty} P(|T_n - V_n| > 2\epsilon) \leq \delta.$$

因为 $\delta > 0$ 是任意的, 从而证明了本引理.

引理 1.2 (样本分位数的 Bahadur 表示) 以 F_n 记 $X_1, \dots, X_n$ 的经验分布函数, 即 $F_n(x) = \frac{1}{n} \{X_1, \dots, X_n \text{ 中小于 } x \text{ 的个数}\}$. 给定 $p \in (0, 1)$, 定义 R_n 如下:

$$R_n = \hat{\xi}_{np} - \left(\xi_p - \frac{F_n(\xi_p) - p}{f(\xi_p)} \right). \quad (1.30)$$

设 $f(\xi_p) > 0$ 且 f 在 ξ_p 处连续, 则当 $n \rightarrow \infty$ 时,

$$\sqrt{n}R_n \xrightarrow{P} 0. \quad (1.31)$$

证 令 $V_n = \sqrt{n}(\hat{\xi}_{np} - \xi_p)$, $T_n = \sqrt{n}(p - F_n(\xi_p))/f(\xi_p)$, 则 (1.31) 式转化为

$$V_n - T_n \xrightarrow{P} 0. \quad (1.32)$$

令 $Z_n = \sqrt{n}(F(\xi_p + an^{-1/2}) - F_n(\xi_p + an^{-1/2}))/f(\xi_p)$, $U_n = n(F_n(\xi_p + an^{-1/2}) - F_n(\xi_p))$, 此处 a 为给定的常数, 则有

$$\sqrt{n}(Z_n - T_n) = -\frac{U_n - E(U_n)}{f(\xi_p)}.$$

注意到 U_n 服从二项分布 $B(n, p_n^*)$ 其中

$$p_n^* = F(\xi_p + an^{-1/2}) - F(\xi_p) \rightarrow 0, \quad n \rightarrow \infty.$$

故

$$E(Z_n - T_n)^2 = \frac{1}{n}np_n^* \frac{1 - p_n^*}{f^2(\xi_p)} \rightarrow 0.$$

因而 $Z_n - T_n \xrightarrow{P} 0$ (当 $n \rightarrow \infty$). 令

$$a_n = \{\sqrt{n}F(\xi_p + an^{-1/2}) - n^{-1/2}([np])\}/f(\xi_p),$$

由 $F'(\xi_p) = f(\xi_p)$ 且 f 在 ξ_p 点连续, 易见 $\lim_{n \rightarrow \infty} a_n = a$. 又

$$\begin{aligned} \{V_n \leq a\} &= \{\hat{\xi} \leq \xi_p + an^{-1/2}\} \\ &\subset \{nF_n(\xi_p + an^{-1/2}) \geq nF_n(X_{n, [np]+1})\} \\ &\subset \{nF_n(\xi_p + an^{-1/2}) \geq [np]\} \\ &= \{Z_n \leq a_n\}, \end{aligned} \quad (1.33)$$

故对任给的 $\epsilon > 0$, 有

$$\begin{aligned} P(V_n \leq a, T_n \geq a + \epsilon) &\leq P(Z_n \leq a_n, T_n \geq a + \epsilon) \\ &\leq P(|T_n - Z_n| > \epsilon - |a_n - a|). \end{aligned}$$

由 $a_n \rightarrow a$ 及 $T_n - Z_n \xrightarrow{r} 0$, 知

$$\lim_{n \rightarrow \infty} P(V_n \leq a, T_n \geq a + \epsilon) = 0. \quad (1.34)$$

由此知引理 1.1 的条件 2° 是适合的. 又因

$$E(T_n^2) = \frac{p(1-p)}{f^2(\xi_p)}$$

与 n 无关, 易见引理 1.1 的条件 1° 也适合. 故由引理 1.1 知 (1.32) 式成立, 因而证明了 (1.31) 式. 引理证毕.

引理 1.3 设 $Y_1, Y_2, \dots$ 为一串 iid. 的 k 维随机向量, Y_1 有均值向量 μ , 协方差阵 Σ , 则当 $n \rightarrow \infty$ 时,

$$n^{-1/2} \left(\sum_{i=1}^n Y_i - n\mu \right) \xrightarrow{\mathcal{L}} N(O, \Sigma).$$

这就是 iid. 情况下的多维中心极限定理. 证明与一维的情况一样, 用特征函数即可得出.

定理 1.4 的证明 由 (1.30) 式与 (1.31) 式知, 当 $n \rightarrow \infty$ 时, $\sqrt{n}(\hat{\xi}_n - \xi)$ 的极限分布与

$$S_n \triangleq \frac{\sqrt{n}(\lambda_1 - F(\xi_1))}{f(\xi_1)}, \dots, \frac{\sqrt{n}(\lambda_k - F(\xi_k))}{f(\xi_k)}$$

的极限分布相同. 记 $Y_i = (Y_{i1}, \dots, Y_{ik})$, 其中

$$Y_{ji} = \frac{1}{f(\xi_j)} \text{ 或 } 0, \text{ 视 } X_i = \lambda_j (j = 1, \dots, k) \text{ 或否而定.}$$

则 $Y_1, Y_2, \dots$ 为 iid., 其均值向量为 $(\lambda_1/f(\xi_1), \dots, \lambda_k/f(\xi_k))$, 协方差阵就是 (1.26) 式中的 Λ . 又

$$S_n = -n^{-1/2} \left(\sum_{i=1}^n (Y_i - E(Y_i)) \right).$$

由引理 1.3 知, $-S_n \xrightarrow{\mathcal{L}} N(0, \Lambda)$, 即 $S_n \xrightarrow{\mathcal{L}} N(0, \Lambda)$. 因而 $\sqrt{n}(\hat{\xi}_n - \xi)$ 也有极限分布 $N(0, \Lambda)$. 定理证毕.

注 1.1 若在定理 1.4 中把 $\hat{\xi}_n$ 的定义改为

$$\hat{\xi}_n = (X_{nk_{n1}}, \dots, X_{nk_{nk}}), \quad (1.35)$$

其中, $k_{nj}/n - \lambda_j = o(n^{-1/2})$ ($j = 1, \dots, k$), $\lambda_1, \dots, \lambda_k$ 满足定理 1.3 的一切条件, 易见定理的结论仍成立. 为此, 只需在 (1.30) 式中把 $\hat{\xi}_{np}$ 改为 X_{nk_n} , 其中 $k_n/n - p = o(n^{-1/2})$, 现证明 (1.31) 式仍成立. 这个证明与引理 1.2 的证明完全相似, 只需将 V_n 改为 $\sqrt{n}(X_{nk_n} - p)$, T_n 与 Z_n 不动. 将 (1.33) 式修改为

$$\{V_n \leq a\} \subset \left\{ Z_n \leq a_n + \frac{n^{-1/2}[np] - \frac{(k_n - 1)}{\sqrt{n}}}{f(\xi_p)} \right\}$$

由于 $n^{-1/2}[np] - (k_n - 1)/\sqrt{n} \rightarrow 0$, 同样的证法可得出(1.34)式.

在(1.35)中取 $k_{nj} = [n\lambda_j]$ 或 $[n\lambda_j] + 1$, 则条件 $k_{nj}/n - \lambda_j = O(n^{-1/2})$ 都满足. 再注意到由定义1.2中(1.17)式知, 样本 p 分位数介于 $X_{nj[np]}$ 与 $X_{nj[np]+1}$ 之间, 于是得到: 若记 $\hat{\xi}_n = (\xi_{n\lambda_1}, \dots, \xi_{n\lambda_k})$, $\lambda_1, \dots, \lambda_k$ 满足定理1.3的条件, 则(1.26)式仍成立.

定理1.4有两个特例值得注意:

1) $k = 1$, 设 $0 < p < 1$, f 在 ξ_p 处连续且 $f(\xi_p) > 0$, 则当 $n \rightarrow \infty$ 时, 有

$$\sqrt{n}(\tilde{\xi}_{np} - \xi_p) \xrightarrow{\mathcal{L}} N\left(0, \frac{p(1-p)}{f^2(\xi_p)}\right). \quad (1.36)$$

此处 $\tilde{\xi}_{np}$ 为由(1.17)式定义的 ξ_{np} 或由(1.25)式定义的 $\hat{\xi}_{np}$. 特别, 取 $p = 1/2$, 得到由(1.18)式定义的样本中位数 m_n 的下述极限分布:

$$\sqrt{n}(m_n - m) \xrightarrow{\mathcal{L}} N\left(0, \frac{1}{4f^2(m)}\right). \quad (1.37)$$

当然, 此处要求 f 在 F 的中位数 m 处连续, 且大于0.

2) 取 $k = 2$, $0 < p_1 < p_2 < 1$. 设 $f(\xi_{p_1}) > 0$, $f(\xi_{p_2}) > 0$, 且 f 在 ξ_{p_1} 与 ξ_{p_2} 处连续. 根据(1.26)式可写出 $\sqrt{n}(\hat{\xi}_{np_1} - \xi_{p_1}, \hat{\xi}_{np_2} - \xi_{p_2})$ 的极限分布, 由此易得: 当 $n \rightarrow \infty$ 时, 有

$$\sqrt{n}((\hat{\xi}_{np_1} \pm \xi_{p_1}) - (\hat{\xi}_{np_2} \pm \xi_{p_2})) \xrightarrow{\mathcal{L}} N(0, \sigma^2). \quad (1.38)$$

其中

$$\sigma^2 = \frac{p_2(1-p_2)}{f^2(\xi_{p_2})} \pm \frac{2p_1(1-p_2)}{f(\xi_{p_1})f(\xi_{p_2})} + \frac{p_1(1-p_1)}{f^2(\xi_{p_1})} \quad (1.39)$$

这些结果可用于总体分布的分位数的大样本统计推断问题中.

1.2.3 极值的渐近分布

仍设 $X_1, X_2, \dots$ 为抽自分布 F 的 iid. 样本, 本段为方便计, 记

$$Y_n = \max(X_1, \dots, X_n), \quad Z_n = \min(X_1, \dots, X_n).$$

定义1.3 若存在正常数串 $\{C_n\}$ 及常数串 $\{d_n\}$, 使 $C_n Y_n + d_n$ 依分布收敛于一分布函数 G , 则称 G 为一个“极大值分布”. F 称为“底分布”. 且称 F 属于 G 的“吸引场”. 类似地, 可定义“极小值分布”. 极大值分布与极小值分布统称“极值分布”.

极值分布理论的基本问题是: ① 有哪些分布可作为极值分布? ② F 属于极值

分布 G 的吸引场的条件如何? 这问题经过几十年的研究, 已大体上得到了圆满的解决. 有关的细节可以参看文献[3] 中第 549 ~ 565 页. 这里只把结果叙述一下.

先引进一个概念: 两个分布函数 F_1 和 F_2 称为是**同类的**, 若存在常数 $a > 0$ 及 b , 使 $F_1(x) \equiv F_2(ax + b)$. 显然, 这个关系具有自反、对称和传递的性质. 因此, 它把全体一维分布函数剖分为一些不相交的子集, 使属于同一子集的两分布为同类的; 否则, 为不同类的. 例如, 全体非退化正态分布是一个这样的子集, 即正态分布类. 全体退化分布也构成一类.

有了这些准备以后, 可以叙述下面的基本定理:

定理 1.5(极值分布的三大类型) 若 G 为一个连续的极大值分布, 则它必与下列三种类型的分布函数之一同类:

$$\text{I 型: } G_1(x) = \exp(-e^{-x});$$

$$\text{II 型: } G_2(x) = \exp\left(-\frac{1}{x^\alpha}\right)I_{(x>0)}, \quad \alpha > 0 \text{ 为参数};$$

$$\text{III 型: } G_3(x) = \begin{cases} \exp(-|x|^\alpha), & x < 0, \\ 1, & x \geq 0. \end{cases} \quad \alpha > 0 \text{ 为参数}.$$

若 G 为一个连续的极小值分布, 则它必与下列三种类型的分布函数之一同类:

$$\text{I 型: } G_1(x) = 1 - \exp(-e^x);$$

$$\text{II 型: } G_2(x) = \begin{cases} 1 - \exp(-|x|^{-\alpha}), & x < 0, \\ 1, & x \geq 0. \end{cases} \quad \alpha > 0 \text{ 为参数};$$

$$\text{III 型: } G_3(x) = \{1 - \exp(-x^\alpha)\}I_{(x>0)}, \quad \alpha > 0 \text{ 为参数}.$$

这个基本定理是 Гнеденко 在 1943 年证明的. 他也得出了底分布属于各型极值分布吸引场的充要条件.

定理 1.6 1° 若底分布 F 满足条件: 存在 $c < 1$, 使当 $F(x) > c$ 时, F 在 x 点连续, 则 F 属于 I 型极大值分布吸引场的充要条件是: 对一切 x , 有

$$\lim_{n \rightarrow \infty} n \left[1 - F\left(u_n + \frac{x}{v_n}\right) \right] = e^{-x}.$$

此处 u_n 和 v_n 由关系式

$$F(u_n) = 1 - \frac{1}{n}$$

与

$$F\left(u_n + \frac{1}{v_n}\right) = 1 - \frac{1}{ne}$$

决定.

2° F 属于 II 型极大值分布吸引场的充要条件是:对一切 $x, F(x) < 1$, 且存在 $\alpha > 0$, 使对任何 $c > 0$, 有

$$\lim_{x \rightarrow 0} \frac{1 - F(x)}{1 - F(cx)} = c^\alpha.$$

3° F 属于 III 型极大值分布吸引场的充要条件是:存在有限的 ω , 使 $F(\omega) = 1$, 且对 $\omega_1 < \omega$, 有 $F(\omega_1) < 1$. 并存在 $\alpha > 0$, 使对任何 $c > 0$, 有

$$\lim_{n \rightarrow \infty} \frac{1 - F(cx + \omega)}{1 - F(x + \omega)} = c^\alpha.$$

对极小值的情况有类似的定理. 从统计应用的观点看: 由于在实际问题中总体分布 F (即底分布) 不知道, 不能直接使用这些结果去决定在一具体问题中该用哪一类型的极值分布. 但如有足够多的样本, 则可由之得出 F 的较确切的估计. 因而可以拿来与以上各组条件作比较, 以决定取舍. 在实用上, I 型使用最多. 也可以不先对 F 作出估计 (在有些问题中, 只有极值的观测数据, 例如一年内某地发生的地震的最大震级, 这时 F 无法估计), 而直接用极值数据去拟合各型极值分布, 择其拟合较优者而从之. 有时问题的专业知识有助于决定选择何种类型.

1.2.4 次序统计量的线性函数的渐近分布

设 $X_1, \dots, X_n \sim F$, 仍以 $X_{n1} \leq X_{n2} \leq \dots \leq X_{nn}$ 记 $X_1, \dots, X_n$ 的次序统计量. 设对任何 n 给定了常数 $c_{1n}, \dots, c_{nn}$, 记

$$T_n = \sum_{i=1}^n c_{ni} X_{ni}. \quad (1.40)$$

这种形式的统计量在应用上很重要. 前面提到的样本 p 分位数、极值、极差等, 都是这种形式. 在以下例 1.2 和例 1.3 中, 还要提出两个重要的情况.

在一定的条件下, 可以证明 T_n 为渐近正态. 这个问题在文献中有大量的研究. 一些作者在种种形式 (不少是大同小异) 的条件下给出过证明. 可惜的是, 在这些证明中, 没有一个是初等而不甚繁琐的. 因此, 我们只给出 Moore 在 1968 年得出的一个结果的证明. 此证明相对说来还比较简单, 但也要用到 Колмогоров 的一个重要结果.

引理 1.4 (Колмогоров 定理) 设 $X_1, \dots, X_n \sim F$, F 处处连续, 又以 F_n 记 $X_1, \dots, X_n$ 的经验分布函数. 则当 $n \rightarrow \infty$ 时, $\sqrt{n} \sup_x |F_n(x) - F(x)|$ 依分布

收敛于分布函数 K , 此处当 $x \leq 0$ 时, 有 $K(x) = 0$, 而当 $x > 0$ 时,

$$K(x) = \sum_{i=-\infty}^{\infty} (-1)^i \exp(-2i^2 x^2). \quad (1.41)$$

其证明参看文献[3] 中第 319 ~ 324 页.

现考虑(1.40) 式的一种特殊情况: 设存在定义于 $(0, 1)$ 区间的函数 J , 使

$$c_{ni} = J\left(\frac{i}{n+1}\right) / n, \quad i = 1, \dots, n.$$

定理 1.7(Moore^[127]) 设分布 F 处处连续, F 的期望存在, 即

$$\int_{-\infty}^{\infty} |x| dF(x) < \infty$$

又设函数 J 满足以下三个条件:

1° J 在 $[0, 1]$ 上, 除可能有有限个第一类间断点外, 处处连续.

2° 除了可能有有限个例外点 $a_1, \dots, a_m$ 之外, J' 在 $[0, 1]$ 上处处存在连续. 在 $a_1, \dots, a_m$ 各点处指定 J' 的值为 0, 则 J' 在 $[0, 1]$ 上为界变差.

3° 记 $G(x) = F^{-1}(x) = \inf\{y: F(y) \geq x\}$, 有下式成立.

$$\int_0^1 \int_0^1 |J(s)J(t)| \min(s, t)[1 - \max(s, t)] dG(s) dG(t) < \infty \quad (1.42)$$

则有

$$\sqrt{n}(T_n - \int_{-\infty}^{\infty} xJ(F(x))dF(x)) \xrightarrow{\mathcal{L}} N(0, \sigma^2). \quad (1.43)$$

此处

$$\sigma^2 = \int_0^1 \int_0^1 J(s)J(t) \min(s, t)[1 - \max(s, t)] dG(s) dG(t) \quad (1.44)$$

注 1.2 由条件 2° 知 J 在 $[0, 1]$ 有界. 又因 $\int_{-\infty}^{\infty} |x| dF(x) < \infty$, 知

$\int_{-\infty}^{\infty} xJ(F(x))dF(x)$ 存在有限.

定理 1.7 的证明 为避免一些繁琐的细节, 我们补充假定 J' 在 $(0, 1)$ 处处存在连续. 在定理所设的较一般的条件下, 只需对证明作些例行的修改, 主要的是关于下文 I_{2n} 的处理.

记 $u_i = F(X_i)$ ($i = 1, \dots, n$), 因为 F 处处连续, 根据定理 1.1 知, $u_1, \dots, u_n$ 为 iid. 各有 $R(0, 1)$ 分布. 因此, 以概率 1 有 $u_1, \dots, u_n$ 两两不同. 用 $U_n(x)$ 记 $u_1, \dots, u_n$ 的右连续经验分布函数, 即 $U_n(x) = \{u_1, \dots, u_n\}$ 中小于等于 x 的个数 ζ/n , 由于 $u_1, \dots, u_n$ 两两不同, 可将 T_n 写为

$$T_n = \frac{1}{n} \sum_{i=1}^n J\left(\frac{i}{n+1}\right) X_{ni} = \int_0^1 G(u) J\left(\frac{n}{n+1} U_n(u)\right) dU_n(u).$$

又,注意到集合 $\{x: x \neq G(F(x))\}$ 的 F 测度为0,且 F 处处连续,有

$$\int_{-\infty}^{\infty} x J(F(x)) dF(x) = \int_{-\infty}^{\infty} G(F(x)) J(F(x)) dF(x) = \int_0^1 G(u) J(u) du.$$

于是得到

$$\begin{aligned} & \sqrt{n} \left(T_n - \int_{-\infty}^{\infty} x J(F(x)) dF(x) \right) \\ &= \sqrt{n} \left(\int_0^1 G(u) J\left(\frac{n}{n+1} U_n(u)\right) dU_n(u) - \int_0^1 G(u) J(u) du \right) \\ &= \sqrt{n} \int_0^1 G(u) \left[J\left(\frac{n}{n+1} U_n(u)\right) - J(U_n(u)) \right] dU_n(u) \\ &\quad + \sqrt{n} \left(\int_0^1 G(u) J(U_n(u)) dU_n(u) - \int_0^1 G(u) J(u) du \right). \end{aligned} \quad (1.45)$$

根据中值定理,有

$$J(U_n(u)) - J(u) = J'(V_n(u))(U_n(u) - u),$$

其中

$$V_n(u) = \theta U_n(u) + (1 - \theta)u, \quad 0 < \theta < 1.$$

引进 $W_n(u) = \sqrt{n}(U_n(u) - u)$, 不难将(1.45)式改写为

$$I_n = I_n' + I_{1n} + I_{2n} + I_{3n}. \quad (1.46)$$

其中 I_n' 为(1.45)式最后一等号右边的第一项,而

$$I_{1n} = \int_0^1 G(u) J'(u) W_n(u) du + \int_0^1 G(u) J(u) dW_n(u);$$

$$I_{2n} = \int_0^1 G(u) [J'(V_n(u)) - J'(u)] W_n dU_n(u);$$

$$I_{3n} = \frac{1}{\sqrt{n}} \int_0^1 G(u) J'(u) W_n(u) dW_n(u).$$

将 I_{1n} 第一项积分号下的量写为 $GW_n dJ$ 而作分部积分. 注意由条件 2° 知 J 有界, 在0附近和1附近分别有 $W_n(u) = -\sqrt{nu}$ 及 $\sqrt{n}(1-u)$, 且 $\lim_{n \rightarrow \infty} u \downarrow G(u) = \lim_{u \uparrow 1} (1-u)G(u) = 0$ (此由 $\int_{-\infty}^{\infty} |x| dF(x) < \infty$, 因而 $\lim_{n \rightarrow \infty} xF(x) = \lim_{n \rightarrow \infty} x[1 - F(x)] = 0$ 得出), 即得

$$I_{1n} = - \int_0^1 J(u) W_n(u) dG(u). \quad (1.47)$$

记 $\tilde{U}_i(u) = 1$ 或 0 , 视 $u_i \leq u$ 或否而定, 又

$$H_i = - \int_0^1 J(u) [\tilde{U}_i(u) - u] dG(u), \quad 1 \leq i \leq n. \quad (1.48)$$

则(1.47)式可写为

$$I_{1n} = \frac{H_1 + \cdots + H_n}{\sqrt{n}}. \quad (1.49)$$

因为 $|J|$ 在 $(0, 1)$ 区间有界(设 $\leq K$), 有

$$\int_0^1 |J(u)| E(|\tilde{U}_i(u) - u|) dG(u) \leq 2K \int_0^1 u(1-u) dG(u) < \infty$$

知 $E(H_i)$ 存在, 且

$$E(H_i) = - \int_0^1 J(u) E(\tilde{U}(u) - u) dG(u) = 0.$$

同样, 当 $0 \leq s \leq i \leq 1$ 时, 有

$$E(|\tilde{U}_i(s) - s| \cdot |\tilde{U}_i(t) - t|) = s(1-t)[1 + 2(t-s)] \leq 3s(1-t);$$

$$E\{(\tilde{U}_i(s) - s)(\tilde{U}_i(t) - t)\} = s(1-t).$$

由 H_i 的表达式(1.48), 根据条件(1.42)及 σ^2 的定义(1.44), 有 $\text{Var}(H_i) = \sigma^2$. 再考虑到 $H_1, \dots, H_n$ 为 iid. 按(1.49)式, 根据 Lindeberg 中心极限定理, 即得

$$I_{1n} \xrightarrow{\mathcal{L}} N(0, \sigma^2). \quad (1.50)$$

由(1.50)式知: 为证本定理, 只需让当 $n \rightarrow \infty$ 时, (1.46)式中的 I_n' 、 I_{2n} 和 I_{3n} 都依概率趋于 0. 记 $M = \sup_{0 < u < 1} |J'(u)|$, 考虑到 $0 \leq U_n(u) \leq 1$, 根据中值定理, 有

$$\left| J\left(\frac{n}{n+1}U_n(u)\right) - J(U_n(u)) \right| \leq M/n.$$

故有

$$|I_n'| \leq Mn^{-3/2} \sum_{i=1}^n |G(u_i)|. \quad (1.51)$$

因为 $G(u_1), \dots, G(u_n)$ 为 iid., 且

$$E|G(u_1)| = \int_{-\infty}^{\infty} |x| dF(x) < \infty.$$

由(1.51)式及强大数定律, 知

$$\lim_{n \rightarrow \infty} I_n' = 0, \text{ a.s.} \quad (1.52)$$

现有

$$|I_{2n}| \leq \sup_{0 < u < 1} |J'(V_n(u)) - J'(u)| \sup_{0 < u < 1} |W_n(u)|$$

$$\times \int_0^1 |G(u)| dU_n(x). \quad (1.53)$$

由 $J'(u)$ 在 $(0,1)$ 内连续且有界变差, 知它在 $(0,1)$ 内一致连续, 又根据 Глиньвенко 定理, 有 $\lim_{n \rightarrow \infty} (\sup_{0 < u < 1} |U_n(u) - u|) = 0, \text{ a.s.}$ (这是引理 1.4 的推论). 故

$$\lim_{n \rightarrow \infty} (\sup_{0 < u < 1} |J(V_n'(u)) - J'(u)|) = 0, \text{ a.s.}$$

又由强大数定律, 有

$$\int_0^1 |G(u)| dU_n(x) = \frac{1}{n} \sum_{i=1}^n |G(u_i)| \rightarrow \int_{-\infty}^{\infty} |x| dF(x) < \infty, \text{ a.s.},$$

再由引理 1.4, 知 $\sup_{0 < u < 1} |W_n(u)|$ 依分布收敛. 结合这些事实, 由 (1.53) 式即得

$$\text{当 } n \rightarrow \infty \text{ 时, } I_{2n} \xrightarrow{P} 0. \quad (1.54)$$

最后处理 I_{3n} . 先注意

$$I_{3n} = \frac{1}{2\sqrt{n}} \int_0^1 G(u) J'(u) d[W_n^2(u)] + \frac{1}{2} n^{-3/2} \sum_{i=1}^n G(u_i) J'(u_i). \quad (1.55)$$

上式的得来, 是因为在 $W_n(u)$ 的连续点处有

$$d[W_n^2(u)] = 2W_n(u) dW_n(u),$$

而在 $W_n(u)$ 不连续的点, 即 $u = u_i$ 时, 有

$$\begin{aligned} d[W_n^2(u_i)] &= W_n^2(u_i) - W_n^2(u_i - 0) \\ &= (W_n(u_i) + W_n(u_i - 0)) dW_n(u_i) \\ &= 2W_n(u_i) dW_n(u_i) - (W_n(u_i) - W_n(u_i - 0)) dW_n(u_i) \\ &= 2W_n(u_i) dW_n(u_i) - \frac{1}{n}. \end{aligned}$$

由于 J' 在 $(0,1)$ 有界, 可用同前面类似的方法证明

$$\lim_{n \rightarrow \infty} n^{-3/2} \sum_{i=1}^n G(u_i) J'(u_i) = 0, \text{ a.s.} \quad (1.56)$$

用 $V_a^b f$ 记 f 在 $[a, b]$ 区间的全变差. 取定 G 的一个连续点 $p \in (0,1)$. 先按分部积分法将 (1.55) 式右边第一项写为

$$\begin{aligned} I_{4n} &\triangleq \frac{1}{2\sqrt{n}} \int_0^1 G(u) J'(u) d[W_n^2(u)] \\ &= -\frac{1}{2\sqrt{n}} \int_0^1 W_n^2(u) d[G(u) J'(u)], \end{aligned} \quad (1.57)$$

$$W_n^2(u)J'(u) \Big|_0^1 = 0,$$

是用与处理 I_{1n} 同样的方法证明的. 有 $E(W_n^2(u)) = u(1-u)$, 因此

$$\begin{aligned} E \left| \frac{1}{\sqrt{n}} \int_p^1 W_n^2(u) d[G(u)J'(u)] \right| \\ \leq E \left\{ \frac{1}{\sqrt{n}} \int_p^1 W_n^2(u) dV_p^u(GJ') \right\} \\ = \frac{1}{\sqrt{n}} \int_p^1 u(1-u) dV_p^u(GJ'). \end{aligned} \quad (1.58)$$

往下证明

$$\int_p^1 u(1-u) dV_p^u(GJ') < \infty.$$

若 $G(1) < \infty$, 则此显然的. 若不然, 可取 $r \in (p, 1)$, 使 $G(r) > |G(p)|$. 当 $u \geq r$ 时, 有

$$\begin{aligned} V_p^u(GJ') &\leq G(u) V_p^u(J') + M V_p^u(G) \\ &= G(u) V_p^u(J') + M(G(u) - G(p)) \\ &\leq M^* G(u). \end{aligned}$$

此处 $M = \sup_{0 < u < 1} |J'(u)|$, $M^* = 3M + V_0^1(J')$. 根据此式, 对

$$\int_p^1 u(1-u) dV_p^u(GJ')$$

作分部积分, 并注意到

$$\int_0^1 |G(u)| du < \infty,$$

即得

$$\int_p^1 u(1-u) dV_p^u(GJ') < \infty,$$

由此及(1.58)式, 即得

$$\lim_{n \rightarrow \infty} E \left| \frac{1}{\sqrt{n}} \int_p^1 W_n^2(u) d(G(u)J'(u)) \right| = 0.$$

用同法可证明

$$\lim_{n \rightarrow \infty} E \left| \frac{1}{\sqrt{n}} \int_p^0 W_n^2(u) d(G(u)J'(u)) \right| = 0,$$

故由(1.57)式得 $\lim_{n \rightarrow \infty} E |I_{4n}| = 0$, 因而

$$\text{当 } n \rightarrow \infty \text{ 时, } I_{4n} \xrightarrow{P} 0. \quad (1.59)$$

由(1.55) ~ (1.57) 式和(1.59) 式, 即得

$$\text{当 } n \rightarrow \infty \text{ 时, } I_{sn} \xrightarrow{P} 0.$$

从而完成了定理的证明.

注 1.3 Moore^[126] 把 σ^2 的表达式写为

$$2 \iint_{-\infty < s < t < \infty} J(F(s))J(F(t))F(s)[1 - F(t)]dsdt. \quad (1.60)$$

通过简单推理可说明: 这与表达式(1.44) 是一样的.

例 1.1 令 $J(u) \equiv 1$, 则 $T_n = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. 设 F 的方差 $\text{Var}(X_1)$ 存在, 有限. 这时有

$$\lim_{x \rightarrow -\infty} x^2 F(x) = \lim_{x \rightarrow \infty} x^2 [1 - F(x)] = 0, \quad (1.61)$$

从而有

$$\begin{aligned} \iint_{-\infty < s < t < \infty} F(s)[1 - F(t)]dsdt &= \int_{-\infty}^{\infty} [1 - F(t)]dt \int_{-\infty}^t F(s)ds \\ &= \int_{-\infty}^{\infty} tF(t)[1 - F(t)]dt \\ &\quad - \int_{-\infty}^{\infty} [1 - F(t)] \int_{-\infty}^t s dF(s)dt. \end{aligned} \quad (1.62)$$

将上式右边第一项中的 $t dt$ 写为 $\frac{1}{2} dt^2$, 作分部积分, 并注意(1.61) 式, 得

$$\int_{-\infty}^{\infty} tF(t)[1 - F(t)]dt = -\frac{1}{2} \int_{-\infty}^{\infty} t^2 dF(t) + \int_{-\infty}^{\infty} t^2 F(t) dF(t). \quad (1.63)$$

又

$$\begin{aligned} &\int_{-\infty}^{\infty} [1 - F(t)] \int_{-\infty}^t s dF(s)dt \\ &= \int_{-\infty}^{\infty} s dF(s) \int_s^{\infty} [1 - F(t)]dt \\ &= - \int_{-\infty}^{\infty} s^2 [1 - F(t)]dF(s) + \iint_{-\infty < s < t < \infty} s t dF(s) dF(t) \\ &= - \int_{-\infty}^{\infty} s^2 dF(s) + \int_{-\infty}^{\infty} s^2 F(s) dF(t) + \frac{1}{2} \left(\int_{-\infty}^{\infty} s dF(s) \right)^2. \end{aligned} \quad (1.64)$$

由(1.62) ~ (1.64) 式, 得

$$\begin{aligned}
 \sigma^2 &= 2 \iint_{-\infty < s < t < \infty} F(s)[1 - F(t)] ds dt \\
 &= \int_{-\infty}^{\infty} s^2 dF(s) - \left(\int_{-\infty}^{\infty} s dF(s) \right)^2 \\
 &= \text{Var}(X_1).
 \end{aligned}$$

又

$$\int_{-\infty}^{\infty} xJ(F(x))dF(x) = \int_{-\infty}^{\infty} x dF(x) = E(X_1).$$

于是(1.43)式转化为通常的 Lindeberg 中心极限定理. 不过应注意, 在通常的 Lindeberg 定理中不必假定 F 处处连续.

例 1.2 切尾均值(trimmed mean). 令

$$J(u) = \begin{cases} \frac{1}{1-2\alpha}, & \alpha < u < 1-\alpha; \\ 0, & u \in (0,1) - (\alpha, 1-\alpha). \end{cases} \quad (1.65)$$

此处 $0 < \alpha < 1/2$. 有

$$T_n = \frac{1}{n(1-2\alpha)} \sum_{(n+1)\alpha < i < (n+1)(1-\alpha)} X_{ni} \quad (1.66)$$

T_n 称为(样本)切尾均值, 意即将原样本切去其上、下端各 $100\alpha\%$ 的数目的样本, 将余下的取平均值. 当总体分布对称时, T_n 可用于估计分布的对称中心. 与 $\bar{X}_n$ 相比, T_n 的优点在于它不受个别异常值(outlier, 指样本中因受过失性误差的影响而呈特大或特小的值)的影响, 因此是一个在实用上有重要意义的估计量. 在实际使用时, (1.66) 式中的 $n(1-2\alpha)$ 可代之以和号下的项数.

先设总体分布 $F(x)$ 处处连续, 关于 0 对称

$$\int_{-\infty}^{\infty} |x| dF(x) < \infty$$

(参看注 1.4). 易见

$$\int_{-\infty}^{\infty} xJ(F(x))dF(x) = 0.$$

通过与例 1.1 类似的计算, 可得出

$$\sigma^2 = \left\{ \int_{-\xi_{1-\alpha}}^{\xi_{1-\alpha}} x^2 dF(x) + \alpha \xi_{1-\alpha}^2 \right\} / (1-2\alpha)^2. \quad (1.67)$$

此处 $\xi_{1-\alpha} = \sup\{y; F(y) < 1-\alpha\}$. 我们将这一计算留给读者作为练习.

若总体分布为 $F(x-\theta)$, 此处 $F(x)$ 满足上述一切条件, 则

$$\tilde{T}_n = \frac{1}{n(1-2\alpha)} \sum_{(n+1)\alpha < i < (n+1)(1-\alpha)} (X_{ni} - \theta)$$

相当于 $\theta = 0$ 时的 T_n , 于是得到

$$\frac{\sqrt{n}(T_n - \theta)}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1). \quad (1.68)$$

σ 仍由 (1.67) 式确定,

注 1.4 在本例中, $J(u)$ 在 $u = 0$ 和 $u = 1$ 的领域内为 0. 仔细检查定理的证明, 不难发现:

$$\int_{-\infty}^{\infty} |x| dF(x) < \infty$$

的条件没有必要. 建议读者自己补出有关的细节.

在定理 1.7 的证明中, 将所讨论的量分解为若干项之和, 其中一项为独立和, 其渐近正态性由独立和的中心极限定理处理; 而另一些项在概率上为无穷小. 这是在证明非独立和的渐近正态时常用的方法. 在这种方法可用 (即具有上述性质的分解能作出) 时, 存在的困难常在于证明分解式中某些项在概率上为无穷小, 如在定理 1.7 中所看到的, 使用这种方法, Chernoff 等在文献 [45] 中讨论了更一般形式的统计量

$$T_n^* = \frac{1}{n} \sum_{i=1}^n C_{ni} h(X_{ni})$$

的渐近正态性. 当 $h(x) \equiv x$ 时, T_n^* 转化为 T_n . Shorack^[145]、Stigler^[156]、Boos^[40] 等用种种方法研究过 T_n 的渐近正态性.

定理 1.7 的缺点在于: 虽然样本分位数本身是重要的一种 (次序统计量的) 线性函数, 但定理 1.7 不能应用于它. 不过, 不难把定理 1.4 和定理 1.7 的证法结合起来. 可得出下面的定理:

定理 1.8 设定理 1.7 的条件全部满足, 又设 F 有密度函数 f , 它在 F 的 p_j 分位点 ξ_j ($1 \leq j \leq k$) 处连续且大于 0, 此处 $0 < p_1 < \cdots < p_k < 1$. 又设 $c_1, \cdots, c_k$ 为常数. 定义

$$\tilde{T}_n = \frac{1}{n} \sum_{i=1}^n J\left(\frac{i}{n+1}\right) X_{ni} + \sum_{j=1}^k c_j \hat{\xi}_{np_j} \quad (1.69)$$

其中 $\hat{\xi}_{np}$ 由 (1.25) 式定义. 则当 $n \rightarrow \infty$ 时, 有

$$\frac{\sqrt{n}(\tilde{T}_n - \mu)}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1) \quad (1.70)$$

此处

$$\mu = \int_{-\infty}^{\infty} xJ(F(x))dF(x) + \sum_{j=1}^k c_j \xi_j \quad (1.71)$$

$$\begin{aligned} \sigma^2 = & 2 \iint_{-\infty < s < t < \infty} J(F(s))J(F(t))F(s)[1-F(t)]dsdt + c'Ac \\ & + 2 \sum_{j=1}^k \frac{c_j}{f(\xi_j)} \int_{-\infty}^{\infty} \min(F(x), p_j)[1 - \max(F(x), p_j)] \times J(F(x))dx \end{aligned} \quad (1.72)$$

上式中 $c' = (c_1, \dots, c_k)$, A 为 k 阶方阵, 其 (i, j) 元 λ_{ij} 由将 (1.27) 式中的 λ_i 、 λ_j 换成 p_i 、 p_j 而得出.

证 本定理的证明结合定理 1.4 和定理 1.7 的论证即可得出; 将表达式 (1.30) 与 (1.46) 结合, 得

$$\sqrt{n}(\tilde{T}_n - \mu) = I_n' + \left(I_{1n} - \frac{1}{\sqrt{n}} \sum_{i=1}^n Q_i\right) + I_{2n} + I_{3n} + \sqrt{n}R_n. \quad (1.73)$$

此处

$$Q_i = \sum_{j=1}^n c_j \frac{\tilde{U}_i(p_j) - p_j}{f(\xi_j)},$$

$\tilde{U}_i$ 的定义已在定理 1.7 的证明中给出过. 于是,

$$I_{1n} - \sum_{i=1}^n \frac{Q_i}{\sqrt{n}} = \sum_{i=1}^n \frac{H_i - Q_i}{\sqrt{n}}.$$

H_i 的定义见 (1.48) 式. 因为 $H_1 - Q_1, \dots, H_n - Q_n$ 为 iid., $H_1 - Q_1$ 的均值为 0, 而其方差不难算出为 (1.72) 式右边. 故由 Lindeberg 定理得

$$\left(I_{1n} - \sum_{i=1}^n \frac{Q_i}{\sqrt{n}}\right) / \sigma \xrightarrow{\mathcal{L}} N(0, 1).$$

又由 (1.31) 式及定理 1.7 的证明知: 表达式 (1.73) 式右边其余各项都依概率收敛于 0. 从而证明了本定理.

注 1.5 若在 (1.69)、(1.71) 式中改 c_j 为 c_{nj} , 但 $\lim_{n \rightarrow \infty} c_{nj} = c_j$ 存在有限, 易见定理的结论仍成立. 若 $c_{nj} - c_j = o(n^{-1/2})$ ($j = 1, \dots, k$). 则 (1.71) 式中的 c_j 不必改为 c_{nj} .

下例是本定理的一个重要应用.

例 1.3 Winsor 化均值 (Winsorized mean). 指定 $\alpha \in (0, 1/2)$. 取 $J(u) = I_{(\alpha, 1-\alpha)}$, $c_1 = c_2 = \alpha$. 有

$$\tilde{T}_n = \frac{1}{n} \left(\sum_{(n+1)\alpha < i < (n+1)(1-\alpha)} X_{ni} + n\alpha \hat{\xi}_{n,\alpha} + n\alpha \hat{\xi}_{n,1-\alpha} \right) \quad (1.74)$$

此处 $\hat{\xi}_{np}$ 由 (1.25) 式定义. 在实际应用中, 可将 $\tilde{T}_n$ 调整为

$$\tilde{T}_n' = \frac{1}{n} \left(\sum_{(n+1)\alpha < i < (n+1)(1-\alpha)} X_{ni} + c_{n1} \alpha \hat{\xi}_{n,\alpha} + c_{n2} \alpha \hat{\xi}_{n,1-\alpha} \right) \quad (1.75)$$

此处 $c_{n1} = (n+1)\alpha, c_{n2} = n - [(n+1)(1-\alpha)]$ 或 $n - [(n+1)(1-\alpha)] + 1$, 视 $(n+1)(1-\alpha)$ 是否为整数而定. 依据定理 1.4, 这不会影响 T_n 的极限分布.

表达式 (1.75) 等于对通常的样本均值作了一个调整, 即把样本中最小的 $100\alpha\%$ 部分调整到 $\hat{\xi}_{1\alpha}$ (接近这一部分样本中的最大者); 把样本中最大的 $100\alpha\%$ 部分调整到 $\hat{\xi}_{n,1-\alpha}$ (接近这一部分样本中的最小者). 当总体分布对称时, $\tilde{T}_n$ 和 $\tilde{T}_n'$ 可用于估计分布的对称中心. 同切尾均值一样, 它可以削弱样本中异常值的影响. Winsor 化均值与切尾均值相比较, 前者在摆脱异常值影响时不如后者彻底, 但在样本中有某些个被误作为异常值处理时, 前者保留了样本中部分信息; 而后者则完全损失了. 两者都在应用上有重要意义.

先设总体分布关于 0 对称, 有密度函数 f (因对称性, 有 $f(-x) = f(x)$), 且 f 在 F 的 α 分位数 ξ_α 处连续, $f(\xi_\alpha) > 0$. 由这些条件可知 ξ_α 是唯一的, $\xi_{1-\alpha}$ 也是唯一的, 且等于 $-\xi_\alpha$, 因而 $f(\xi_{1-\alpha}) = f(\xi_\alpha)$, f 在 $\xi_{1-\alpha}$ 处连续. 用这些条件, 并注意 $J(u) = I_{(\alpha, 1-\alpha)}$, 经过简单计算得出表达式 (1.72) 等于

$$\sigma^2 = \int_{-\xi_{1-\alpha}}^{\xi_{1-\alpha}} x^2 dF(x) + 2\alpha \left(\xi_{1-\alpha} + \frac{\alpha}{f(\xi_{1-\alpha})} \right)^2. \quad (1.76)$$

建议读者自己验证这个公式. 另外, 显然 (1.71) 式中的 μ 为 0. 于是根据 (1.70) 式有

$$\frac{\sqrt{n} \tilde{T}_n}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1).$$

一般, 设总体分布为 $F(x - \theta)$, 其中 $F(x)$ 满足以上列举的全部条件. 这时 θ 为总体分布的对称中心. 以 X_i' 记 $X_i - \theta$, 并注意

$$\tilde{T}_n(X_1', \dots, X_n') = \tilde{T}_n(X_1, \dots, X_n) - \theta.$$

得到

$$\frac{\sqrt{n} [\tilde{T}_n(X_1, \dots, X_n) - \theta]}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1). \quad (1.77)$$

σ^2 的表达式仍为 (1.76). 但应注意: 此时 (1.76) 式中的 $\xi_{1-\alpha}$ 是指分布 $F(x)$ 的 $1-\alpha$ 分位数, 而非 $F(x - \theta)$ 的 $1-\alpha$ 分位数. 在对 σ^2 作估计时尤应注意这一点.

另有一些作者探讨了由(1.40)式定义的 T_n (经过标准化) 的分布趋于标准正态分布 Φ 的速度问题. 例如 Helmers^[85] 对

$$T_n = \sum_{i=1}^n J\left(\frac{i}{n+1}\right) X_{ni}$$

的情况, 在 F 和 J 满足一定条件时, 得到了理想的结果:

$$\sup_x \left| P\left(\frac{T_n - E(T_n)}{\sqrt{\text{Var}(T_n)}} < x\right) - \Phi(x) \right| = O(n^{-1/2}).$$

1.3 次序统计量的充分性与完全性

1.3.1 充分性

设有样本 X , 而 $T(X)$ 为统计量, 即 $T(X)$ 是一个只依赖于 X 而不依赖于任何其他未知量的函数. 由 X 得出 $T(X)$, 相当于对样本 X 进行加工整理, 其目的是简化样本, 计算出样本的某些特征量, 以把其所含的关于总体的某些方面的信息集中反映出来, 并在这个基础上进行统计推断. 当样本 X 加工为统计量 $T(X)$ 时, X 中所含的信息量一般会有所损失. 如果毫无损失, 则称 $T(X)$ 是一个充分统计量. 一个统计量 T 是否为充分的, 不仅取决于 T 的形状, 也与样本 X 的分布族有密切关系.

经过理论上的分析, 把上述关于统计量的充分性概念用严格的数学定义表达出来(参看文献[3]中第60~62页). 就是说: 若当给定 $T(X) = t$ 时, 样本 X 的条件分布只依赖于 t 而与 X 的(无条件)分布无关, 则称统计量 T 是充分的. 此处提到的条件分布有专门的严格定义. 因为一般说来, 事件 $\{T(X) = t\}$ 的概率多为0, 初等概率论中条件概率的定义不适用.

现设有样本 $X = (X_1, \dots, X_n)$, $X_1, \dots, X_n \sim F$. 设总体分布 F 属于分布族 $\mathcal{F}$. 样本 X 的分布为 $F^{(n)} = F \times F \times \dots \times F$, 它构成一个分布族 $\mathcal{F}^{(n)} = \{F^{(n)}; F \in \mathcal{F}\}$. 将 $X_1, \dots, X_n$ 的次序统计量记为 $T(X)$.

定理 1.9 不论分布族 $\mathcal{F}$ 如何, 次序统计量 $T(X)$ 必是充分的.

证 给定 $T(X) = t = (t_1, \dots, t_n)$. 先设 $t_1 < \dots < t_n$ 在给定 $T(X) = t$ 的条件下, X 只能取 $(t_1, \dots, t_n)$ 的任一置换为值. 这样的置换共有 $n!$ 个. 因为

$X_1, \dots, X_n$ 为 iid., 这 $n!$ 个置换的地位是平等的. 即对 $(1, \dots, n)$ 的任一置换 $(i_1, \dots, i_n)$, 有

$$P(X = (t_{i_1}, \dots, t_{i_n}) \mid T = t) = \frac{1}{n!}$$

成立. 若 $t_1, \dots, t_n$ 不全相异, 一般, 设它们可分成 k 组, 各组依次包含 $n_1, \dots, n_k$ 个元使同一组内的 t_i 值相同, 不同组内的 t_i 值不同. 则在 $(t_1, \dots, t_n)$ 的一切置换中, 只有 $\frac{n!}{n_1! \cdots n_k!}$ 个不同, 而 X 取其中任一个的条件概率都是 $n_1! \cdots n_k! / n!$.

不论是哪种情况, X 的条件分布都只依赖于 t 而与总体分布 F 无关. 这就证明了要证的结果. 以上的证明, 从表面上看, 是基于直观推理, 它可以严格化. 见文献 [3] 中第 32 和 63 页.

根据这个定理, 只要样本是 iid. 的, 则可舍弃原样本而只使用其次序统计量. 由于 iid. 样本是最常见的, 在这个极端的意义上, 可以说常见的统计方法大多是次序统计量的方法. 例如, 一个样本 t 检验统计量 $\sqrt{n} \bar{X}/S$, 其中 $\bar{X} =$

$$\frac{1}{n} \sum_{i=1}^n X_i, \text{ 而}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

只依赖于 $X_1, \dots, X_n$ 的次序统计量. 但通常不采取这种极端看法, 而只将那些使用少数几个次序统计量的方法, 或者是其所用统计量只有通过次序统计量才能自然表出的方法, 算作次序统计量方法的范围. 前者例如用样本分位数估计总体分布位数; 后者例如用切尾均值去估计分布的对称中心.

1.3.2 完全性

完全性也是统计量的一个重要性质, 它虽然不如充分性那样基本, 但却在一些统计问题中很有用. 完全性概念不像充分性那样直观. 我们先给出其形式定义, 然后再作些解释.

设有样本 X , 统计量 $T = T(X)$. 样本 X 的分布为 F 时, $T(X)$ 的分布记为 P_F . 这样, 若样本 X 的分布构成一个族 $\mathcal{F}$ 时, 则 $T(X)$ 的分布构成一个族 $\mathcal{T} = \{P_F : F \in \mathcal{F}\}$. 如果对任意的函数 g , 只要对于任何 $F \in \mathcal{F}$, 有

$$E_F g(T) = \int g(t) dP_F(t) = 0, \quad (1.78)$$

则必有对于任何 $F \in \mathcal{F}$, $P_F\{t : g(t) \neq 0\} = 0$. 则称统计量 T 在样本分布族 $\mathcal{F}$ 之

下为完全的.

为了解释这一定义,不妨设分布 P_F 有概率密度函数 $p_F(t)$. $\{p_F: F \in \mathcal{F}\}$ 构成一个密度族. (1.78) 式可写为: 对任何 $F \in \mathcal{F}$, 有

$$\int g(t) dp_F(t) dt = 0. \quad (1.79)$$

像在正交函数中那样, 把 $\int g(t) p_F(t) dt = 0$ 解释为“ g 与 p_F 正交”: $g \perp p_F$ 则 T 在 $\mathcal{F}$ 之下有完全性可表为

$$g \perp \{p_F: F \in \mathcal{F}\} \Rightarrow g = 0.$$

也就是说, 找不到一个非零“向量” g 与“向量集” $\{p_F: F \in \mathcal{F}\}$ 中的每一个都正交. 我们知道, 在正交函数论中, 类似的函数集称为完全的. 关于统计量 T 的完全性就是借用这个名称.

同充分性一样, 统计量 T 的完全性不仅取决于 T 的形状, 且与样本分布族 $\mathcal{F}$ 有关. 对次序统计量而言, 没有像定理 1.9 那种一般性的结果, 而必须对 $\mathcal{F}$ 加些限制. 下面的定理引自文献[3](见文献[3] 中第 82 ~ 86 页), 对常见的问题已够用了.

定理 1.10 设样本 $X = (X_1, \dots, X_n)$, $X_1, \dots, X_n \sim F$, $F \in \mathcal{F}$. 如果分布族 $\mathcal{F}$ 满足以下两个条件, 则次序统计量 $T(X)$ 在分布族 $\mathcal{F}$ 之下是完全的:

1° 设 F_1, F_2 都属于 $\mathcal{F}$, $a \in [0, 1]$ 为常数, 则由公式 $F(S) = aF_1(S) + (1 - a)F_2(S)$ 定义的 F 也属于 $\mathcal{F}$.

2° 设 $F \in \mathcal{F}$, $F(S) > 0$, 则由公式 $F_s(A) = F(A \cap S)/F(S)$ 定义的 F_s 也属于 $\mathcal{F}$.

常见的非参数性质的分布族大多满足这两个条件, 但参数族则不然(参见文献[3]).

1.4 次序统计量的应用

次序统计量的应用很广泛, 本节选择性地作一些介绍, 对进一步的知识和细节感兴趣的读者可参看 David 的专著^[53]. 而关于极值统计方面, 则可参看

Gumbel 的专著^[76].

1.4.1 总体分位数的估计

设 $X_1, \dots, X_n \sim F$, F 属于分布族 $\mathcal{F}$. F 的 p 分位数仍记为 ξ_p . 仍以 $X_{(1)} \leq \dots \leq X_{(n)}$ 记次序统计量.

作为点估计, ξ_p 的一个自然的估计量是样本 p 分位数, 取其正式定义(1.17)或简化定义(1.25)均可(当 n 较小时, 以用(1.17)式为宜). 不难证明: 若分布 F 的 p 分位数 ξ_p 唯一, 则必有

$$\lim_{n \rightarrow \infty} \tilde{\xi}_{np} = \xi_p, \text{ a. s.} \quad (1.80)$$

此处 $\tilde{\xi}_{np}$ 为 ξ_{np} 或 $\hat{\xi}_{np}$. 也就是说, 在所述条件下, $\tilde{\xi}_{np}$ 是 ξ_p 的强相合估计.

事实上, 任给 $\epsilon > 0$, 由 ξ_p 唯一, 知 $F(\xi_p - \epsilon) < p < F(\xi_p + \epsilon)$. 记 $\eta = \min\{F(\xi_p + \epsilon) - p, p - F(\xi_p - \epsilon)\}$. 由强大数定律, 有 $P\{\text{当 } n \text{ 充分大时, } X_1, \dots, X_n \text{ 中小于 } \xi_p - \epsilon \text{ 的个数不超过 } n(p - \eta/2), \text{ 小于 } \xi_p + \epsilon \text{ 的个数不少于 } n(p + \eta/2)\} = 1$. 因此

$$P\{\text{当 } n \text{ 充分大时 } |\tilde{\xi}_{np} - \xi_p| \leq \epsilon\} = 1.$$

由 $\epsilon > 0$ 的任意性, 就证明了要证的结果.

若进一步假定 F 有密度函数 f , f 在 ξ_p 点连续且 $f(\xi_p) > 0$, 则由(1.36)式知估计量 $\tilde{\xi}_{np}$ 有渐近正态性, 其渐近方差为 $p(1-p)/nf^2(\xi_p)$. 通过对密度函数 f 作出适当的估计 $\hat{f}_n$ (估计方法参看本书中第 6.1 节), 可以用 $\hat{f}_n(\tilde{\xi}_{np})$ 估计 $f(\xi_p)$. 利用这个事实, 可以作出 ξ_p 的具有渐近置信系数 $1 - \alpha$ 的大样本区间估计为

$$\tilde{\xi}_{np} \pm \frac{u_{\alpha/2} \sqrt{p(1-p)}}{\sqrt{n\hat{f}_n(\tilde{\xi}_{np})}}.$$

下面给出求 ξ_p 的置信区间的其他方法.

当 $p = 1/2$ 时, ξ_p 是总体分布 F 的中位数 m . 如果 F 关于某点 θ 对称, 则 $m = \theta$. 因此, $\xi_{n,1/2}$ 即由(1.18)式定义的 m_n 可用于估计对称中心 θ . 当总体均值存在时, θ 也是总体均值. 故 θ 也可用样本均值 $\bar{X}_n$ 去估计. m_n 及 $\bar{X}_n$ 的渐近方差孰大孰小, 取决于 F 的方差及 F 的密度 f 在 θ 点之值 $f(\theta)$. 当总体为正态分布时, m_n 的渐近方差为 $\bar{X}_n$ 的渐近方差的 $\pi/2$ 倍. 但若总体分布有密度函数 $\frac{1}{4} \exp(-\sqrt{|x - \theta|})$, 则 m_n 的渐近方差只有 $\bar{X}_n$ 的三十分之一. 当总体分布为

Cauchy 分布(密度为 $[\pi(1+(x-\theta)^2)]^{-1}$)时, $\bar{X}_n$ 的方差不存在,但 m_n 作为 θ 的无偏估计,有渐近方差 $\pi^2/(4n)$.根据Cramer-Rao不等式,在这一场合下 θ 的无偏估计的方差不能小于 $2/n$.二者的比值为

$$\frac{2}{n} : \frac{\pi^2}{4n} = \frac{8}{\pi^2} = 0.8106.$$

因此, m_n 还是一个效率相当高的估计(参见文献[51]中第490页).

别处,前在例1.2和例1.3中已经提到过,对称中心也可以用切尾均值 T_n 和Winsor化均值 $\tilde{T}_n$ 去估计.其中,切尾均值可看作为介于样本均值(它使全部次序统计量平均)与样本中位数(它只用一个次序统计量)之间的一种估计.但(1.68)和(1.77)式都不能直接用于作对称中心 θ 的大样本区间估计,而必须先通过样本对由(1.67)和(1.76)式所定义的 σ^2 进行估计.注意到 $X_1 - \theta, \dots, X_n - \theta$ 为iid.,且各有分布函数 $F(x)$,并且 $X_1 - \theta, \dots, X_n - \theta$ 的样本 $1-\alpha$ 分位数等于 $X_1, \dots, X_n$ 的样本 $1-\alpha$ 分位数减去 θ ,得出(1.67)式中的 σ^2 的一个可用的估计为

$$\sigma_n^2 = (1-2\alpha)^{-2} \left\{ \frac{1}{n} \sum_{(n+1)\alpha < i < (n+1)(1-\alpha)} (X_{ni} - T_n)^2 + \alpha (\xi_{n,1-\alpha} - T_n)^2 \right\}.$$

此处仍以 $\xi_{n,1-\alpha}$ 记 $X_1, \dots, X_n$ 的样本 $1-\alpha$ 分位数.同样,(1.76)式中的 σ^2 可用

$$\tilde{\sigma}_n^2 = \frac{1}{n} \sum_{(n+1)\alpha < i < (n+1)(1-\alpha)} (X_{ni} - T_n)^2 + 2\alpha \left((\xi_{n,1-\alpha} - T_n)^2 + \frac{\alpha}{\hat{f}_n(\xi_{n,1-\alpha})} \right)^2$$

估计,其中 $\hat{f}_n(x)$ 是由样本 $X_1, \dots, X_n$ 作出的总体密度 $f(x-\theta)$ 的一个估计. θ 的渐近置信系数为 $1-\epsilon$ 的大样本区间估计,可取 $T_n \pm u_{\epsilon/2} \sigma_n / \sqrt{n}$ 或者 $\tilde{T}_n \pm u_{\epsilon/2} \tilde{\sigma}_n / \sqrt{n}$.

对称中心的估计是非参数统计中的一重要问题,在本书中将多次提到它.

现在我们来考虑 ξ_p 的形如 $[X_{(r)}, X_{(s)}]$ 的区间估计:指定置信系数 $1-\alpha$,需要决定这样的 r 和 s ,使

$$P(X_{(r)} > \xi_p) = P(X_{(s)} < \xi_p) = \frac{\alpha}{2}. \quad (1.81)$$

假定总体分布 F 处处连续,则 $F(\xi_p) = p$ (这是唯一用到 F 连续的地方,故只须假定 F 在 ξ_p 点连续即可).由(1.2)式有

$$P(X_{(r)} > \xi_p) = 1 - P(X_{(r)} \leq \xi_p) = \sum_{j=0}^{r-1} \binom{n}{j} p^j (1-p)^{n-j}. \quad (1.82)$$

同样

$$P(X_{(s)} < \xi_p) = \sum_{j=s}^n \binom{n}{j} p^j (1-p)^{n-j}. \quad (1.83)$$

由(1.82)与(1.83)式,可根据二项分布表决定 r 与 s 的值.一般,不见得有 r 或 s 恰好满足(1.82)或(1.83)式,这时只好将 α 的值略加调整,当 n 很大时,可利用正态分布逼近二项分布:

$$\sum_{j=0}^{r-1} \binom{n}{j} p^j (1-p)^{n-j} \approx \Phi \left(\frac{r - \frac{1}{2} - np}{\sqrt{np(1-p)}} \right).$$

为使此值等于 $\alpha/2$,应取

$$r = np + \frac{1}{2} - u_{\alpha/2} \sqrt{np(1-p)}.$$

类似地,得

$$s = np - \frac{1}{2} - u_{\alpha/2} \sqrt{np(1-p)}.$$

当这些数不为整数时,则以其最接近的整数代替之.

由(1.81)式决定的 $X_{(r)}$ 和 $X_{(s)}$ 分别是 ξ_p 的置信系数 $1 - \alpha/2$ 的置信下、上限.

1.4.2 连续分布的容忍区间与容忍限

设 $X_1, \dots, X_n \sim F$, F 处处连续.在 $(0, 1)$ 内给定两个数 β, γ .统计量 $T = T(X_1, \dots, X_n)$ 称为总体分布 F 的 (β, γ) 容忍下(上)限,若

$$P(F(T(X_1, \dots, X_n)) \geq \gamma) \leq \beta, P(F(T(X_1, \dots, X_n)) \leq (1 - \gamma)) \leq \beta. \quad (1.84)$$

又若 $T_1(X_1, \dots, X_n) \leq T_2(X_1, \dots, X_n)$,而

$$P(F(T_2(X_1, \dots, X_n)) - F(T_1(X_1, \dots, X_n))) \leq (1 - \gamma) \leq \beta. \quad (1.85)$$

就是说,可以用不小于 $1 - \beta$ 概率保证在区间 $[T_1, T_2]$ 内至少包含了总体分布的 $100(1 - \gamma)\%$ 的概率.如果 X 是一种产品的质量指标,则意味着:可以用不小于 $1 - \beta$ 的概率保证:在全部产品中,至少有 $100(1 - \gamma)\%$,其质量指标在 T_1 和 T_2 之间.因此,容忍区间回答的是“总体概率分布集中在何处”的问题,而不是为了估计总体参数(如其 p 分位数 ξ_p).

现在来找形如 $X_{(r)}$ 的 (β, γ) 容忍下限,有

$$P(F(X_{(r)}) \geq \gamma) \leq \beta. \quad (1.86)$$

因为 $F(X_{(r)}) \stackrel{d}{=} U_{(r)}$, 此处 $U_{(1)} \leq \cdots \leq U_{(n)}$ 是 $R(0,1)$ 的次序样本, 故由 (1.86) 式得

$$\sum_{j=r}^n \binom{n}{j} \gamma^j (1-\gamma)^{n-j} \geq 1-\beta \quad (1.87)$$

根据二项分布表, 在满足 (1.87) 式的 r 中找出其最大者即可. 同样, 形如 $X_{(s)}$ 的 (β, γ) 容忍上限由公式

$$\sum_{j=s}^n \binom{n}{j} \gamma^j (1-\gamma)^{n-j} \leq \beta \quad (1.88)$$

确定. 正如在求 $\hat{\epsilon}_p$ 的置信区间的情况, 当 n 很大时, r 和 s 可用正态逼近法决定.

显然, 若 $X_{(r)}$ 和 $X_{(s)}$ 分别是 $(\beta/2, \gamma/2)$ 容忍下、上限, 则 $[X_{(r)}, X_{(s)}]$ 是 (β, γ) 容忍区间.

1.4.3 位置参数差的区间估计和检验

设随机变量 X 有分布函数 $F(x)$, 而 $Y = X + \theta$, θ 为一常数, 则 Y 有分布函数 $F(x - \theta)$. 这里的 θ 常称为“位置参数”(location parameter), 因为由 X 到 Y 的变换, 反映了原点位置的变化. 由此, 分布族 $\{F(x - \theta)\}$ 常称为位置参数族. 作为一个实例, 可以设想 X 表示一种产品在原生产条件下的质量指标. 经过改进后, 在新生产条件下, 该产品的质量指标提高了 θ , 因而其分布也由 $F(x)$ 变为 $F(x - \theta)$.

设 $X_1, \dots, X_{n_1}$ 和 $Y_1, \dots, Y_{n_2}$ 分别是 X 和 Y 的 iid. 样本, 要由它们去估计 θ , 或检验有关 θ 的假设. 这种问题称为位置参数的两样本问题, 在非参数统计中这是一个典型的问题, 在本书中将要多次提到它.

我们假定 F 连续但未知. 分别以 $X_{(1)} \leq \cdots \leq X_{(n_1)}$ 和 $Y_{(1)} \leq \cdots \leq Y_{(n_2)}$ 表示 X 样本和 Y 样本的次序统计量. 指定 $\alpha \in (0, 1)$, 先来求 θ 的形如 $Y_{(s)} - X_{(r)}$ 的置信上限, 其置信系数为 $1 - \alpha/2$.

记 $Z_{(j)} = Y_{(j)} - \theta$ ($j = 1, \dots, n_2$), 则 $Z_{(1)} \leq \cdots \leq Z_{(n_2)}$ 也是从 $F(x)$ 中抽出的次序样本, 且与 $X_{(1)} \leq \cdots \leq X_{(n_1)}$ 独立. 故由公式 (1.2) 易得

$$\begin{aligned} P(Y_{(s)} - X_{(r)} < \theta) &= P(X_{(r)} > Z_{(s)}) \\ &= \int_{-\infty}^{\infty} \sum_{i=0}^{r-1} \binom{n_1}{i} F^i(x) [1 - F(x)]^{n_1-i} S \binom{n_2}{s} \\ &\quad \times F^{s-1}(x) [1 - F(x)]^{n_2-s} dF(x) \end{aligned}$$

$$= \sum_{i=0}^{r-1} s \binom{n_1}{i} \binom{n_2}{i} \int_0^1 t^{s+i-1} (1-t)^{n-s-i} dt.$$

此处 $n = n_1 + n_2$. 将积分用 Γ 函数表出并适当化简, 即得

$$P(Y_{(s)} - X_{(r)} < \theta) = \sum_{i=0}^{r-1} \binom{s+i-1}{s-1} \binom{n-s-i}{n_2-s} / \binom{n}{n_1}. \quad (1.89)$$

于是, 可考虑选择 r 和 s , 使上式右边为 $\alpha/2$ (尽量接近 $\alpha/2$), 则 $Y_{(s)} - X_{(r)}$ 即为所求的置信上限. 但由于 (1.89) 式右边很难算, 又因为由一式同时决定 r 和 s 还有一个选择问题, 故在 n 很大时, Mood 提出了下面的近似方法:

首先注意组合公式

$$\sum_{i=0}^{n_1} \binom{s+i-1}{s-1} \binom{n-s-i}{n_2-s} = \binom{n}{n_1}, \quad (1.90)$$

此式可由在 $(1-x)^{-c} \sum_{k=0}^{\infty} \binom{c+k-1}{k} x^k$ 中分别令 c 为 n_2-s+1 , s 和 n_2+1 , 得三个级数, 由前两个相乘得第三个, 比较两边的 x^{n_1} 的系数即得. 由此, 可引进随机变量 ξ , 其分布为

$$P(\xi = i) = \binom{s+i-1}{s-1} \binom{n-s-i}{n_2-s} / \binom{n}{n_1}, \quad i = 0, 1, \dots, n_1. \quad (1.91)$$

而 (1.89) 式可写为

$$P(Y_{(s)} - X_{(r)} < \theta) = P(\xi < \gamma) \quad (1.92)$$

利用 (1.90) 式经过较繁但初等的计算, 得

$$E(\xi) = sn_1 / (n_2 + 1),$$

$$\text{Var}(\xi) = \frac{sn_1}{n_2 + 1} \left\{ \frac{(s+1)(2n_2+3)}{n_2+2} + \frac{(s+1)n_1}{n_2+2} - (2s+1) - \frac{sn_1}{n_2+1} \right\}, \quad (1.94)$$

且运用 Stirling 公式与用正态分布逼近二项分布时的论证方法, 可以证明: 若存在 $\epsilon > 0$ 使对一切 n , 有

$$\frac{n_1}{n} = a_n \in (\epsilon, 1-\epsilon), \quad \frac{s}{n_2} = c_n \in (\epsilon, 1-\epsilon). \quad (1.95)$$

则

$$\frac{\xi - E(\xi)}{\sqrt{\text{Var}(\xi)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

由此可利用 (1.92) 式, 在已知 s 时, 近似地决定 r , 即

$$r \approx E(\xi) - u_{\alpha/2} \sqrt{\text{Var}(\xi)}. \quad (1.96)$$

还有选择 s 的问题. 从直观上考虑, 选择 $s > n_2/2, r < n_1/2$, 并使

$$\left(s - \frac{n_2}{2}\right) : \left(\frac{n_1}{2} - r\right) = \sqrt{n_2} : \sqrt{n_1}$$

为好. 这个条件与(1.96)式联立, 可同时决定 r 和 s . 但这样解方程太繁, 因而再作一点近似: 记

$$b_n = 1 - a_n, \quad A = u_{1-\alpha/2} = -u_{\alpha/2},$$

则 $E(\xi) \approx na_n c_n$, $\text{Var}(\xi) \approx na_n c_n (1 - c_n)/b_n$. 由(1.96)式得

$$r \approx na_n c_n - \sqrt{\frac{na_n c_n (1 - c_n)}{b_n}} A. \quad (1.97)$$

将 c_n 表为 $\frac{1}{2} + \frac{d_n}{\sqrt{n}}$, 以此式(1.97)式及 $s = \left(\frac{1}{2} + \frac{d_n}{\sqrt{n}}\right)n_2$ 代入关系式

$$\frac{\frac{n_1}{2} - r}{\sqrt{n_1}} = \frac{s - \frac{n_2}{2}}{\sqrt{n_2}},$$

并作近似

$$c_n(1 - c_n) = \frac{1}{4} - \frac{d_n^2}{n} \approx \frac{1}{4},$$

可解出

$$d_n = \frac{A}{2(b_n + \sqrt{a_n b_n})},$$

再用 n_1/n 和 n_2/n 代 a_n 和 b_n , 最后得到

$$r \approx \frac{n_1}{2} - \frac{\sqrt{n_1 n}}{2(\sqrt{n_1} + \sqrt{n_2})} u_{\alpha/2}; \quad (1.98)$$

$$s \approx \frac{n_2}{2} + \frac{\sqrt{n_2 n}}{2(\sqrt{n_1} + \sqrt{n_2})} u_{\alpha/2}; \quad (1.99)$$

用类似的方法可得到 θ 的置信下限(置信系数 $1 - \alpha/2$) 为 $Y_{(s')} - X_{(r')}$, 而和 s' 可近似地由公式

$$r' \approx \frac{n_1}{2} + \frac{\sqrt{n_1 n}}{2(\sqrt{n_1} + \sqrt{n_2})} u_{\alpha/2}; \quad (1.100)$$

$$s' \approx \frac{n_2}{2} - \frac{\sqrt{n_2 n}}{2(\sqrt{n_1} + \sqrt{n_2})} u_{\alpha/2}; \quad (1.101)$$

决定. θ 的一个置信系数 $1 - \alpha$ 的区间估计是

$$[Y_{(s')} - X_{(r')}, Y_{(s)} - X_{(r)}]. \quad (1.102)$$

这样也就决定了假设 $\theta = 0$ 的检验方法: 设检验水平为 α , 作置信区间 (1.102). 当它包含 0 时接受原假设, 不然, 就否定原假设. 若要检验的原假设为 θ 小于等于 0, 则也可以按上述思想作出检验, 它当然有单边的形式. 建议读者自己写出这个检验.

1.4.4 位置与刻度参数的估计

设总体分布为 $F\left(\frac{x - \mu}{\sigma}\right)$, 此处 $F(x)$ 为已知的分布函数, μ 和 $\sigma > 0$ 为未知参数. 分别称为位置参数与刻度 (Scale) 参数. 这名称的由来是因为若 $X \sim F(x)$ 而 $Y = \sigma X + \mu$, 则 $Y \sim F\left(\frac{x - \mu}{\sigma}\right)$. 由 X 到 Y 的变换相当于数轴上的原点位置及刻度单位的变化. 若分布 F 的方差存在非零, 不失普遍性, 可设

$$\int_{-\infty}^{\infty} x dF(x) = 0, \quad \int_{-\infty}^{\infty} x^2 dF(x) = 1.$$

因而 μ 和 σ^2 分别是总体分布的均值和方差. 一般, 当总体分布的均值不必存在时, 可适当调整 $F(x)$, 以使 μ 为总体中位数, 而 σ 是总体分布的“四分区间”的长, 即 $\xi_{3/4} - \xi_{1/4}$.

现设 $X_1, \dots, X_n \sim F\left(\frac{x - \mu}{\sigma}\right)$, 要由它估计 μ 和 σ . 当 $F(x)$ 为标准正态分布时, 也可以考虑某些估计量, 它们是次序统计量 $X_{(1)} \leq \dots \leq X_{(n)}$ 的线性函数. 例如, 当 $F(x)$ 关于 0 对称, 或一般地, 当 $F(x)$ 的中位数为 0 时, 可用样本中位数 m_n 估计 μ (一般, 若 $F(0) = p$, 可用样本 p 分位数 ξ_{np} 估计 μ), 而极差 (乘以适当倍数) 可用于估计 σ . 由此得到启发: 在一切形如 $\sum_{i=1}^n c_i X_{(i)}$ 的估计中, 寻求在某种意义上最优的估计量. 例如, 一致最小方差的无偏估计量.

记 $Z_{(i)} = (X_{(i)} - \mu)/\sigma$ ($i = 1, \dots, n$), 则 $(Z_{(1)}, \dots, Z_{(n)})$ 的分布等于在 $F(x)$ 中抽取的大小为 n 的次序样本的分布. 因此, 量

$$E(Z_{(i)}) = \alpha_i, \quad \text{Cov}(Z_{(i)}, Z_{(j)}) = \sigma_{ij}, \quad 1 \leq i, j \leq n \quad (1.103)$$

原则上可由 n 及 $F(x)$ (注意 $F(x)$ 已知) 定出来. 记

$$e_i = \sigma(Z_{(i)} - \alpha_i), \quad i = 1, \dots, n,$$

有

$$X_{(i)} = \mu + \alpha_i \sigma + e_i, \quad i = 1, \dots, n. \quad (1.104)$$

其中 $e = (e_1, \dots, e_n)'$ 有均值向量 0 , 协方差阵

$$\text{Cov}(e) = \sigma^2 V = \sigma^2 (\sigma_{ij})_{i,j=1,\dots,n}.$$

(1.104) 式构成一个推广的 Gauss-Markov 模型 (见文献[3] 中第 462 页). 根据关于这种模型的熟知理论知: 在一切形如 $\sum_{i=1}^n C_i X_{(i)}$ 的估计中, 一致最小方差的无偏估计为

$$\begin{pmatrix} \hat{\mu} \\ \hat{\sigma} \end{pmatrix} = \begin{pmatrix} l' V^{-1} l & \alpha' V^{-1} l \\ \alpha' V^{-1} l & \alpha' V^{-1} \alpha \end{pmatrix}^{-1} \begin{pmatrix} l' \\ \alpha' \end{pmatrix} V^{-1} \tilde{X}. \quad (1.105)$$

此处 $l = (1, \dots, 1)'$, $\alpha = (\alpha_1, \dots, \alpha_n)'$, $\tilde{X} = (X_{(1)}, \dots, X_{(n)})'$. 此估计的协方差阵为

$$\text{Cov} \begin{pmatrix} \hat{\mu} \\ \hat{\sigma} \end{pmatrix} = \begin{pmatrix} \alpha' V^{-1} \alpha - \alpha' V^{-1} l \\ -\alpha' V^{-1} l & l' V^{-1} l \end{pmatrix} / \{ l' V^{-1} l \alpha' V^{-1} \alpha - (\alpha' V^{-1} l)^2 \}. \quad (1.106)$$

若 $F(x)$ 关于 0 对称, 则有

$$\alpha_{n+1-i} = -\alpha_i, \quad \sigma_{n+1-i, n+1-j} = \sigma_{ij}.$$

利用这些事实, 不难证明 $l' V^{-1} \alpha = 0$. 因而 (1.105) 式可简化为

$$\hat{\mu} = \frac{l' V^{-1} \tilde{X}}{l' V^{-1} l}, \quad \hat{\sigma} = \frac{\alpha' V^{-1} \tilde{X}}{\alpha' V^{-1} \alpha}. \quad (1.107)$$

而 (1.106) 式简化为

$$\text{Var}(\hat{\mu}) = \frac{\sigma^2}{l' V^{-1} l}, \quad \text{Var}(\hat{\sigma}) = \frac{\sigma^2}{\alpha' V^{-1} \alpha}, \quad \text{Cov}(\hat{\mu}, \hat{\sigma}) = 0. \quad (1.108)$$

如果 $X_{(1)}, \dots, X_{(n)}$ 中有一部分没有观察到或被舍去了, 则只需在模型 (1.104) 式中删去相应 i , 剩下的观察值仍按同法处理 (当然, V 已不是 $(\sigma_{ij})_{i,j=1,\dots,n}$ 而只是它的一个子阵). 这是本法的一个优点. 但是, 本法在实际应用时有一个严重的障碍, 即 (1.103) 式中的 α_i 和 σ_{ij} 不易得到.

1.4.5 截尾数据

一般地说, 如果在次序统计量 $X_{(1)} \leq \dots \leq X_{(n)}$ 中只观察了 $X_{(r)}, \dots, X_{(s)}$ 的值, 而其余的则没有观察或不能观察, 则称 $X_{(r)}, \dots, X_{(s)}$ 为截尾样本或截尾数据 (Censored data).

例如, 观测所用仪器的显示范围为 (a, b) . 凡是小于 a (大于 b) 的观测值, 在仪器上指示为 $a(b)$. 将这些舍去, 就得到截尾数据, 即落在 (a, b) 内的那些

$X_{(r)}, \dots, X_{(s)}$. 除此以外, 截尾数据最常见的情况是出现在可靠性和寿命试验中. 例如 n 个元件从时刻 0 开始工作. 预定到有 r 个失效后, 即停止试验, 因而只观测了 $X_{(1)} \leq \dots \leq X_{(r)}$ (注意: 它们是大小为 n 的次序样本的前 r 个, 按 (1.23) 式的记号是 $X_{n1}, \dots, X_{nr}$, 不要把它们与“大小为 r 的次序样本”混为一谈, 后者按 (1.23) 式的记法应为 $X_{r1}, \dots, X_{rr}$). 也可能先定下一个时刻 $t_0 > 0$, 到这个时刻就停止试验. 若这时已有 r 个失效, 则只观测 $X_{(1)} \leq \dots \leq X_{(r)}$. 在前一情况, r 事先给定, 但试验时间为随机变量; 后一情况则正相反: r 为随机变量, 而试验时间事先指定. 它们分别称为 **I 型** 和 **II 型截尾**. 又如, 医生对同时开始治疗的一批胃癌患者, 观察其五年生存率, 五年以后就不管了, 这也是一种 **II 型截尾**.

截尾数据的统计推断问题也有参数和非参数两种情况. 在非参数情况, 由于所用的方法不取决于总体分布的形式, 故只要在所用统计量中不涉及未观察到的那些次序统计量, 则一切均无问题. 例如若已观察 $X_{(1)}, \dots, X_{(r)}$, 而 $r > n/2$, 则样本中位数 m_n 仍可算出, 可用于估计总体中位数 m . 在作总体分位数的区间估计以及总体分布的容忍区间时, 情况也一样. 在参数情况, 则因所用的方法取决于总体分布, 因而处理截尾数据时, 或者所用的方法将与非截尾数据不同, 或者即使方法的思想相同, 而所涉及的计算和论证不同 (一般是复杂些). 下面举几个情况来说明这一点.

例如考察 1.4.4 节中估计 μ 和 σ 的方法, 当只有截尾数据 $X_{(r)}, \dots, X_{(s)}$ 时, 如 1.4.4 节末尾处提到的, 1.4.4 节中的方法仍可用, 但该处的协方差阵 V 与 r, s 有关.

又如极大似然估计, 截尾数据情况下的极大似然估计, 在文献中有不少讨论. 一般, 设总体有概率密度 $f(x, \theta)dx$. 原定样本大小 n , 实际只观察了 $X_{(1)} \leq \dots \leq X_{(r)}$. 则易见 $(X_{(1)}, \dots, X_{(r)})$ 的概率元为

$$n(n-1)\cdots(n-r+1) \prod_{i=1}^r (f(X_{(i)}, \theta) dX_{(i)}) \left(\int_{X_{(r)}}^{\infty} f(x, \theta) dx \right)^{n-r}.$$

于是找 $\theta = \theta^*$, 使表达式

$$f(X_{(1)}, \theta) \cdots f(X_{(r)}, \theta) \left(\int_{X_{(r)}}^{\infty} f(x, \theta) dx \right)^{n-r} \quad (1.109)$$

达到最大, 则 θ^* 是 θ 的基于 $X_{(1)}, \dots, X_{(r)}$ 的极大似然估计. 它依赖于 f 的形式, 而且一般很难计算. 有一个重要的特例, 可以得到很好的结果, 这就是在可靠性统计中很重要的负指数分布: $\theta = (\alpha, \sigma)$, 而

$$f(x, \theta) = \frac{1}{\sigma} e^{-(x-\alpha)/\sigma} \cdot I_{(\alpha, \infty)}, \quad (1.110)$$

令

$$T_1 = X_{(1)}, \quad T_2 = \sum_{i=2}^r (X_{(i)} - X_{(i-1)})(n - i + 1). \quad (1.111)$$

可将表达式(1.109)式写为

$$\sigma^{-r} e^{na/\sigma} \exp\left[-\frac{1}{\sigma}(nT_1 + T_2)\right] \cdot I_{(T_1 > \alpha, T_2 > 0)}. \quad (1.112)$$

由(1.112)式,用因子分解定理(见文献[3],第67页),即知 (T_1, T_2) 为 θ 的充分统计量.也可以证明 (T_1, T_2) 是完全的.于是根据 Lehmann-Scheffe 定理(见文献[3]中第95页)可知,只要找到 $\theta = (\alpha, \sigma)$ 的基于 T_1, T_2 的无偏估计,则它就是 (α, σ) 的一致最小方差无偏估计.这样的估计是

$$\hat{\alpha} = T_1 - \frac{T_2}{n(r-1)}, \quad \hat{\sigma} = \frac{T_2}{r-1}. \quad (1.113)$$

这一点可证明如下 $(X_{(1)}, \dots, X_{(n)})$ 的密度函数为

$$\begin{cases} n! \sigma^{-n} \exp\left(-\sum_{i=1}^n \frac{x_{(i)} - \alpha}{\sigma}\right), & \alpha < x_{(1)} < \dots < x_{(n)}; \\ 0, & \text{其他.} \end{cases}$$

作变换 $Y_1 = n(X_{(1)} - \alpha)$, $Y_i = (n - i + 1)(X_{(i)} - X_{(i-1)})$ ($i = 2, \dots, n$),根据密度变换公式,易知 $(Y_1, \dots, Y_n)$ 有密度函数

$$\begin{cases} \sigma^{-n} \exp\left(-\sum_{i=1}^n \frac{y_i}{\sigma}\right), & y_i > 0 (i = 1, \dots, n); \\ 0, & \text{其他.} \end{cases}$$

由此可知, $Y_1, \dots, Y_n$ 为iid., Y_1 的密度函数为 $\frac{1}{\sigma} e^{-x/\sigma} I_{(0, \infty)}$,有 $E(Y_1) = \sigma$.于是 $E(T_1) = \alpha + \sigma/n$, $E(T_2) = (r-1)/\sigma$,因而得出 $E(\hat{\alpha}) = \alpha$, $E(\hat{\sigma}) = \sigma$.由上述论证还可附带得出 $2T_2/\sigma = 2(Y_2 + \dots + Y_r)/\sigma$ 服从自由度为 $2(r-1)$ 的中心 χ^2 分布,即 $\chi_{2(r-1)}^2$.利用这个事实可作 σ 的区间估计及检验关于 σ 的假设.

除了负指数分布以外,在可靠性统计中还用到其他一些重要分布,如 Weibull分布、Gamma分布、对数正态分布等等.对这些分布的截尾样本问题,有关文献中已有不少讨论,这比负指数分布的情况复杂得多.

1.4.6 极值统计

在1.2.3节中已给出了极值分布的标准形式.极值在实际问题中的应用大

都采取如下的形式. 设有从某一未知分布 $F(x)$ 中, 抽出的大批样本 $X_1, X_2, \dots, X_{mn}$, 按某种自然的或人为的方式将其分为 m 组, 每组 n 个:

$$\begin{aligned} & X_1, X_2, \dots, X_{ni}; \\ & X_{n+1}, X_{n+2}, \dots, X_{2ni}; \\ & \dots; \\ & X_{(m-1)n+1}, X_{(m-1)n+2}, \dots, X_{mn}, \end{aligned} \quad (1.114)$$

每组取其最大(或最小值, 视问题按需要而定), 得 $Y_1, \dots, Y_m$ (Y_i 为第 i 组的最大值).

例如设 $X_1, X_2, \dots$ 是一条河在某一点处逐日的水位值, 则可以把一年 365 天的数据分在一组, 而 Y_i 是第 i 年的最高水位. 又如 $X_1, X_2, \dots$ 是某地一日内地震的最大震级, 把一年 365 天的数据分在一组, 则 Y_i 是一年内该地的地震最大震级, 我们假定每组内的数据个数 n 足够大, 可以认为其最大值近似地服从极值分布. 但究竟是哪种类型, 则要根据数据和其他方面的知识去考虑(见 1.2.3 小节末尾处的说明). 在应用上, 以 I 型使用最多, 以下就这个情况来讨论:

由极值分布的定义与定理 1.5, 可以把 $Y_1, \dots, Y_m$ 看成是从极值分布

$$F_{u, \alpha}(x) = \exp(-e^{-\alpha(x-u)}) \quad (1.115)$$

中抽出的 iid. 样本. 其统计上的问题, 主要是由 $Y_1, \dots, Y_m$ 去估计(1.115) 式中的参数 α 和 u . 一旦 α 和 u 已有了估计 $\hat{\alpha}$ 和 $\hat{u}$, 则可以把 $F_{\hat{\alpha}, \hat{u}}(x)$ 取为极值的分布. 例如可以由 $F_{\hat{\alpha}, \hat{u}}(x)$ 决定 x_0 , 使 $F_{\hat{\alpha}, \hat{u}}(x_0) = 0.99$, 表示超过 x_0 的极值, 其可能性只有百分之一. 在上两例中, x_0 可分别解释为“百年一遇”的洪水和地震量级. 在设计一项工程时, 往往需要对这种参数作出适当的估计.

为估计 α 和 u , 在有关文献中提出了很多方法. 较重要的有:

1° 样本分位数法: 以 $x = u$ 代入(1.115) 式, 有 $F_{u, \alpha}(u) = \exp(-1) = 0.3679 = p_1$, 故可以用 $Y_1, \dots, Y_m$ 的 p_1 分位数估计之. 有

$$F_{u, \alpha}\left(u + \frac{1}{\alpha}\right) = \exp(-e^{-1}) = 0.6922 = p_2.$$

故可用 $Y_1, \dots, Y_m$ 的 p_2 分位数估计 $u + 1/\alpha$. 与前一估计相结合, 得出 α 的估计.

2° 最小二乘法(线性回归法): 以 $Y_{(1)} \leq \dots \leq Y_{(m)}$ 记 $Y_1, \dots, Y_m$ 的次序统计量. 因为 $F_{u, \alpha}(x)$ 处处连续, 由定理 1.1 知: $F_{u, \alpha}(Y_{(1)}), \dots, F_{u, \alpha}(Y_{(m)})$ 的分布与 $R(0, 1)$ 中大小为 m 的次序样本的分布相同. 特别, 有

$$E(F_{u, \alpha}(Y_{(i)})) = \frac{i}{m+1}, \quad i = 1, \dots, m.$$

且 $\text{Var}(F_{u,a}(Y_{(i)})) = \frac{i(m+1-i)}{(m+1)^2(m+2)}$, 当 m 较大时很小, 因此, 近似地可以把 $i/(m+1)$ 就作为 $F_{u,a}(Y_{(i)})$ 的值, 而得

$$\alpha(Y_{(i)} - u) = -\log\left(-\log\frac{i}{m+1}\right), \quad i = 1, \dots, m.$$

此式两边当然不会绝对相同. 取其差的平方和

$$\sum_{i=1}^m \left[\alpha Y_{(i)} + \beta \log\left(-\log\frac{i}{m+1}\right) \right]^2$$

找 $\hat{\alpha}, \hat{\beta}$, 使之达到最小, 则 $\hat{\alpha}$ 和 $u = -\hat{\beta}/\hat{\alpha}$ 可作为 α 和 u 的估计. 如有极值概率低, 则可将 m 个点 $\left(Y_{(i)}, -\log\left(-\log\frac{i}{m+1}\right)\right) (1 \leq i \leq m)$ 描在这种纸上, 用目测法划一条与这 m 个点接近的直线, 从而即可定出 $\hat{\alpha}$ 和 $\hat{u}$.

3° 极大似然估计法: 此法效率较高, 但计算也较繁.

似然函数为

$$L = \alpha^m \exp\left[-\sum_{i=1}^m e^{-\alpha(Y_{(i)}-u)}\right] \exp\left[-\alpha \sum_{i=1}^m (Y_{(i)} - u)\right].$$

记 $h = e^{-\alpha u}$, $Z = \frac{1}{m} \sum_{i=1}^m e^{-\alpha Y_i}$, $\bar{Y} = \frac{1}{m} \sum_{i=1}^m Y_i$, 有

$$\log L = m(\log \alpha - \alpha(\bar{Y} - u) - Z/h).$$

注意到

$$\partial\left(\frac{Z}{h}\right)/\partial\alpha = \left(\frac{Z}{h}\right)\left(u - \sum_{i=1}^m Y_i e^{-\alpha Y_i} / \sum_{i=1}^m e^{-\alpha Y_i}\right).$$

由 $\partial \log L / \partial u = 0$, $\partial \log L / \partial \alpha = 0$, 得到决定 u, α 的极大似然估计 (u^*, α^*) 的方程组为

$$e^{\alpha u} \sum_{i=1}^m e^{-\alpha Y_i} = m, \quad \left(\sum_{i=1}^m Y_i e^{-\alpha Y_i} / \sum_{i=1}^m e^{-\alpha Y_i}\right) + \frac{1}{\alpha} = \bar{Y}. \quad (1.116)$$

用数值方法, 由(1.116)式的第二方程解出 α^* , 代入第一方程解出 u^* .

关于极值统计究竟应视为参数方法还是非参数方法的问题, 不好作断然的回答. 从一方面看, 极值统计中只与三种类型的极值分布打交道, 它们都是典型的参数分布族, 因而可把极值统计视为参数统计的一部分. 从另一个角度看: 在极值统计中对底分布的数学形式并未作任何特定要求, 由此, 将极值统计视为非参数性的也有道理. 如同在其他类似情况下一样, 这不是有必要作出一个硬性回答的问题.

第 2 章

U 统 计 量

在上一章中,讨论了一类重要的统计量及其在种种统计问题中的应用.它们是次序统计量本身或是其线性函数.1948 上, Hoeffding 在其重要工作^[88] 中,提出了一类重要的统计量—— U 统计量,它们是次序统计量的非线性函数.自此,这种统计量的研究受到概率统计学者们很大重视,积累了丰富的成果.

本章的目的,就是介绍在 U 统计量理论中与统计应用关系较为密切的那些部分.主要是其基本的极限定理,并通过一些例子说明它在统计问题中的应用.许多学者,其中也包括我国的学者,对 U 统计量的大样本理论作了深入的研究,得出了不少内容深刻而形式完美的结果.但因为这些与统计应用关系不大,故在本书中从略.

2.1 基本概念

2.1.1 U 统计量的定义

设 $X_1, \dots, X_n$ 都是 d 维随机向量($d \geq 1$), m 为不超过 n 的自然数, $\psi(y_1, \dots, y_m)$ 为变元 $y_1, \dots, y_m$ 的 Borel 可测函数,此处每个 y_i 都在 d 维欧氏空间 $\mathbb{R}^d$ 上取值.

定义 2.1 令

$$\begin{aligned} U_n &= U_n(X_1, \dots, X_n) \\ &= \{n(n-1)\cdots(n-m+1)\}^{-1} \sum_{j_1, \dots, j_m}^* \psi(y_{j_1}, \dots, y_{j_m}). \end{aligned} \quad (2.1)$$

此处 $\sum_{j_1, \dots, j_m}^*$ 表示求和的范围为: $1 \leq j_k \leq n$ ($k = 1, \dots, m$), $j_1, \dots, j_m$ 两两不相同.则称 U_n 为以 ψ 为核的、基于 $X_1, \dots, X_n$ 的 U 统计量.

若令

$$\varphi(y_1, \dots, y_m) = \frac{1}{m!} \sum_{(j_1, \dots, j_m)} \psi(y_{j_1}, \dots, y_{j_m}), \quad (2.2)$$

此处 $\sum_{(j_1, \dots, j_m)}$ 表示求和的范围为: $1 \leq j_k \leq m$ ($k = 1, \dots, m$), $j_1, \dots, j_m$ 两两不相同(换句话说,求和的范围是 $\{1, 2, \dots, m\}$ 的一切可能的置换),则(2.1)式

可表为

$$U_n = U_n(X_1, \dots, X_n) = \binom{n}{m}^{-1} \sum_{1 \leq a_1 < \dots < a_m \leq n} \varphi(y_{a_1}, \dots, y_{a_m}). \quad (2.3)$$

形式(2.3)式优于(2.1)式的地方在于, φ 为 $y_1, \dots, y_m$ 的对称函数, 即 $\varphi(y_{j_1}, \dots, y_{j_m}) = \varphi(y_1, \dots, y_m)$ 对 $\{1, 2, \dots, m\}$ 的任一置换都成立. 通常都直接以(2.3)式作为 U 统计量的定义, 其中的 φ 是对称核.

关于 U 统计量定义中的随机向量 $X_1, \dots, X_n$, 最常见的情况是这样: 有一个由某些 d 维分布构成的分布族 $\mathcal{F}$, F 是 $\mathcal{F}$ 的一个成员, 而 $X_1, \dots, X_n$ 是抽自 F 的 iid. 样本, 即 $X_1, \dots, X_n$ 独立同分布, 每一个都有分布 F . 其统计背景是: $\mathcal{F}$ 是某个统计问题的基本分布族, F 是未知的总体分布. 统计推断的对象是 F 的某一特定方面(如估计 F 的均值, 检验有关 F 的某个假设等). 引进 U 统计量 U_n , 正是服务于推断的目的. U_n 的具体形式, 即其核如何选择, 当然取决于推断的具体内容. 下面, 我们局限于 $X_1, \dots, X_n$ 为 iid. 这一简单情况. 而在纯理论性的研究中可以有更宽的假设, 例如只假定 $X_1, \dots, X_n$ 独立, 而不必同分布, 甚至可以是相依的.

2.1.2 U 统计量之用于统计问题

基本形式有以下两种:

1. 估计 沿用 2.1.1 小节中的记号, 设有一个定义在 $\mathcal{F}$ 上的函数 $\theta = \theta(F)$, 要求根据样本 $X_1, \dots, X_n$ 估计 θ . 步骤如下: 找一个适当的(对称)核 $\varphi(y_1, \dots, y_m)$, 满足条件

$$E_F \varphi(X_1, \dots, X_m) = \theta(F), \quad F \in \mathcal{F}. \quad (2.4)$$

以 φ 为核作出 U 统计量 U_n (见(2.3)式), 即以 U_n 作为 θ 的估计.

由(2.3)、(2.4)式可知, U_n 是 θ 的无偏估计, 且只依赖于 $X_1, \dots, X_n$ 的次序统计量 $X_{(1)} \leq \dots \leq X_{(n)}$. 由定理 1.10 可知: 只要分布族 $\mathcal{F}$ 满足某些一般性条件, 例如在定理 1.10 中指出的条件, 以使 $(X_{(1)}, \dots, X_{(n)})$ 为完全统计量, 则由 Lehmann-Scheffe 定理(见文献[3]中第 95 页)知 U_n 是 θ 的“方差一致最小无偏估计”(UMVUE).

例 2.1 设 $\mathcal{F}$ 为一维分布族, 且对任何 $F \in \mathcal{F}$, 均值

$$\theta = \theta(F) = \int_{-\infty}^{\infty} x dF(x)$$

存在有限. 这个分布族 $\mathcal{F}$ 适合定理 1.10 中指出的条件. 又 $\varphi(y_1) = y_1$ 显然适合

(2.4) 式,对这个 φ ,有

$$U_n = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

因此, $\bar{X}$ 就是 θ 的 UMVUE.

应注意的是:“样本均值是总体均值的 UMVUE”,这一论断的正确性取决于分布 $\mathcal{F}$. 在初等统计中,已知当 $\mathcal{F}$ 为正态分布族、二项分布族、负指数分布族等时,此论断是正确的. 本例的结果为非参数性的,因为它不要求 $\mathcal{F}$ 有确定的数学形式. 但此论断并非对一切 $\mathcal{F}$ 都正确. 例如当 $\mathcal{F}$ 为均匀分布族 $\{R(a, b): -\infty < a < b < \infty\}$ 时,总体均值 $\frac{1}{2}(a+b)$ 的 UMVUE 为 $\frac{1}{2}(X_{(1)} + X_{(n)})$,而非 $\bar{X}$.

关键在于:此处 $(X_{(1)}, \dots, X_{(n)})$ 并非完全统计量.

例 2.2 设 $\mathcal{F} = \{F: F \text{ 为一维分布}, \int_{-\infty}^{\infty} x^2 dF(x) < \infty\}$, $\theta = \theta(F) =$ 分布 F 的方差. 此 $\mathcal{F}$ 适合定理 1.10 中指出的条件,且

$$\varphi(y_1, y_2) = \frac{1}{2}(y_1 - y_2)^2$$

适合(2.4)式. 通过简单计算表明:以此 φ 为核的 U 统计量

$$U_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

即通常的样本方差. 于是对所定义的 $\mathcal{F}$ 而言,样本方差是总体方差的 UMVUE. 上例中提出的注意也适用于本例.

用这种方法找 UMVUE,关键在于找到满足(2.4)式的 φ . 但应注意的是:并非对一切 $\theta(F)$ 都存在这样的 φ . 例如,留给读者证明:若在例 2.1 中改 $\theta(F)$ 为 $\left| \int_{-\infty}^{\infty} x dF(x) \right|$,则这种 φ 就不存在,如果满足(2.4)式的 φ 存在,则称 $\theta(F)$ 为可估的. 这时能使(2.4)式成立的最小的 m 称为 $\theta(F)$ 的“级”. 据此,例 2.1 中的 $\theta(F)$ 当然是一级,而例 2.2 中的 $\theta(F)$ 的级不超过 2. 读者不难自证:例 2.2 中 $\theta(F)$ 的级就是 2. 又如,若 $\mathcal{F}$ 为 Cauchy 分布族

$$\left\{ \frac{dx}{\pi(1+(x-\theta)^2)}: -\infty < \theta < \infty \right\}, \quad (2.5)$$

则 θ 的级不超过 3, 因为易证:若 X_1, X_2, X_3 是从(2.5)式中抽出的 iid. 样本,则其样本中位数(即 $X_{(2)}$)是 θ 的一个无偏估计. 可以证明: θ 的级就是 3.

2. 检验 设有样本 $X_1, \dots, X_n \sim F \in \mathcal{F}$, $\mathcal{F}_0$ 为 $\mathcal{F}$ 的一个非空真子集. 要检

验假设 $H: F \in \mathcal{F}_0$. 方法如下: 找一个适当的 $\theta(F)$, 使当 $F \in \mathcal{F}_0$ 时, $\theta(F) = \theta_0$ 已知且与 F 无关, 而当 $F \in \mathcal{F} - \mathcal{F}_0$ 时, $\theta(F) > \theta_0$ (在 $\mathcal{F} - \mathcal{F}_0$ 上, $\theta(F)$ 的值一般与 F 无关). 找适当的核 φ 满足 (2.4) 式, 以它的核的 U 统计量 U_n 是 $\theta(F)$ 的无偏估计. 算出偏差 $U_n - \theta_0$, 当它足够大时, 就否定原假设 H . 也有可能在 $\mathcal{F} - \mathcal{F}_0$ 上 $\theta(F) < \theta_0$ 或 $\neq \theta_0$, 或者在 $\mathcal{F}_0$ 上 $\theta(F) \leq \theta_0$, 而在 $\mathcal{F} - \mathcal{F}_0$ 上 $\theta(F) > \theta_0$. 这时只需将上述作法作明显的修改即可.

例 2.3 设 $X_1, \dots, X_n \sim F$, F 属于分布族

$$\mathcal{F} = \{F = (G, \tilde{\theta}) = G(x - \tilde{\theta}); G(x) \text{ 为关于原点对称的一维连续分布函数, } -\infty < \tilde{\theta} < \infty\}. \quad (2.6)$$

要检验的假设是 $H: \tilde{\theta} = 0$. 换句话说, 在知道总体分布是对称的前提下, 检验其对称中心为 0, 为此, 令

$$\theta(F) = \theta(G, \tilde{\theta}) = \int_{-\infty}^{\infty} G(x + 2\tilde{\theta}) dG(x). \quad (2.7)$$

因为 G 是连续分布, 易证当 $\tilde{\theta} = 0$ 时, $\theta(F) = 1/2$, 且当 $\tilde{\theta} < 0 (> 0)$ 时, $\theta(F) < 1/2 (> 1/2)$. 记

$$\Psi(x) = I_{(x>0)} = \begin{cases} 1, & x > 0; \\ 0, & x \leq 0. \end{cases} \quad (2.8)$$

而 $\varphi(y_1, y_2) = \Psi(y_1 + y_2)$ 时, 则由 $1 - G(x) = G(-x)$, 得

$$\begin{aligned} E_F \varphi(X_1, X_2) &= P_F(X_1 + X_2 > 0) \\ &= \int_{-\infty}^{\infty} \{1 - G(-x - \tilde{\theta})\} dG(x - \tilde{\theta}) \\ &= \int_{-\infty}^{\infty} G(x + 2\tilde{\theta}) dG(x) = \theta(F). \end{aligned}$$

即所定义的 φ 满足 (2.4) 式. 通过简单推理可得: 以这个 φ 为核的 U 统计量是

$$U_n = (R_1^* + \dots + R_n^* - r) / \binom{n}{2}. \quad (2.9)$$

此处 r 为 $X_1, \dots, X_n$ 中大于 0 的个数, 而

$$R_i^* = \begin{cases} 0, & X_i \leq 0; \\ k, & X_i > 0, \text{ 且在 } |X_1|, \dots, |X_n| \text{ 中恰有 } k \text{ 个不超过 } X_i. \end{cases} \quad (2.10)$$

为检验假设 $H: \tilde{\theta} = 0$, 若对立假设为 $K: \tilde{\theta} > 0$, 则可取否定域为

$$\left\{ (X_1, \dots, X_n) : \left(\sum_{i=1}^n R_i^* - r \right) / \left(\binom{n}{2} - \frac{1}{2} \right) > C \right\}. \quad (2.11)$$

其中的 C 与所选的检验水平有关. 要定出 C 的确切值, 需要知道检验统计量在原假设 $\tilde{\theta} = 0$ 之下的分布. 就本例而言, 这个问题在原则上是可以解决的. 因为由 G 的连续性, 容易证明: (2.11) 式中的检验统计量在 $\tilde{\theta} = 0$ 时的分布与 G 无关 (参看定理 3.2). 但除非 n 很小, 要通过这个分布去决定 C 也很困难, 一般只能参考大样本方法 (见例 3.9).

例 2.4 设 $X_1, \dots, X_n \sim F$ 属于分布族

$$\mathcal{F} = \{F: F \text{ 为一维分布, 方差非 } 0 \text{ 有限}\},$$

要检验的假设是 $H: F$ 的均值 $\theta(F) = 0$.

根据前面描述的一般方法, 先作出 $\theta(F)$ 的 UMVUE, 即

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

然后若对立假设为 $K: \theta(F) \neq 0$, 则取 $|\bar{X}_n| > C$ 为否定域. 本例的情况比上例复杂, 因为即使 H 成立, $\bar{X}_n$ 的分布仍依赖于 F 的具体形式. 不难证明: 不论 $\alpha \in (0, 1)$ 是多少, 无法确定这样的 C 使

$$P_F\{|\bar{X}_n| > C\} \leq \alpha, \quad \text{当 } \theta(F) = 0.$$

因此, 除非 n 很大, 这方法不能用. 当 n 很大时, 由极限理论可知, 统计量

$$T_n = \frac{\sqrt{n} \bar{X}_n}{S_n} \left(S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right)$$

当 $\theta(F) = 0$ 时的分布渐近于标准正态分布. 由此提供了一个大样本检验方法.

这两个例子的差别有着原则性的重要意义. 一般, 设有统计量 $Q = Q(X_1, \dots, X_n)$, $X_1, \dots, X_n \sim F \in \mathcal{F}$, 而 $\mathcal{F}_0 \subset \mathcal{F}$. 若当 $F \in \mathcal{F}_0$ 时, Q 的分布不依赖于 F , 则称统计量 Q 在 $\mathcal{F}_0$ 上为“分布无关”的 (distribution-free). 因此, 例 2.3 中的检验统计量在原假设下为分布无关的, 而例 2.4 则否. 典型的非参数检验统计量都具有在原假设下与分布无关的特性. 例如在后面第 4 章中将要仔细讨论的秩检验. U 统计量则不常具有这个性质, 而且那些具有这一性质的 U 统计量本身往往也是秩统计量. 因此, 就在假设检验中的应用而言, U 统计量的重要性不如秩统计量.

2.1.3 U 统计量的数字特征

设 $X_1, \dots, X_n \sim F$, $\varphi(y_1, \dots, y_m)$ 为对称核, 按 (2.3) 式定义 U 统计量 U_n ,

则易见

$$E_F(U_n) = E_F\varphi(X_1, \dots, X_m) = \theta(F).$$

为计算 U_n 的方差 $\text{Var}_F(U_n)$, 令

$$\begin{aligned}\varphi_c(y_1, \dots, y_c) &= \varphi_{cF}(y_1, \dots, y_c) \\ &= E_F\{\varphi(y_1, \dots, y_c, X_{c+1}, \dots, X_m)\} \\ &= E_F\{\varphi(X_1, \dots, X_m) \mid X_1 = y_1, \dots, X_c = y_c\}, \quad c = 1, \dots, m.\end{aligned}\quad (2.12)$$

且记

$$\sigma_c^2 = \sigma_c^2(F) = \text{Var}_F\varphi_c(X_1, \dots, X_c), \quad c = 1, \dots, m. \quad (2.13)$$

不难证明: 若假定

$$E_F\varphi^2(X_1, \dots, X_m) < \infty, \quad (2.14)$$

则(2.13)式定义的 σ_c^2 存在且有限. 事实上, 由(2.12)式有

$$\varphi_c^2(y_1, \dots, y_c) \leq E_F\{\varphi^2(X_1, \dots, X_m) \mid X_1 = y_1, \dots, X_c = y_c\}.$$

于是

$$\sigma_c^2 \leq E_F\varphi_c^2(X_1, \dots, X_c) \leq E_F\varphi^2(X_1, \dots, X_m) < \infty.$$

不失普遍性, 可设 $\theta(F) = 0$. 用条件期望的方法, 易见若 $\{\alpha_1, \dots, \alpha_m\}$ 和 $\{\beta_1, \dots, \beta_m\}$ 恰有 c 个公共足标, 则

$$E_F\{\varphi(X_{\alpha_1}, \dots, X_{\alpha_n})\varphi(X_{\beta_1}, \dots, X_{\beta_m})\} = \sigma_c^2.$$

由此, 注意到 U_n 的定义, 按简单的组合事实, 易得

$$\text{Var}_F(U_n) = \binom{n}{m}^{-1} \sum_{c=1}^m \binom{m}{c} \binom{n-m}{m-c} \sigma_c^2. \quad (2.15)$$

由此式易知, 当 $n \rightarrow \infty$ 时, 有

$$\text{Var}_F(U_n) = \frac{m^2}{n} \sigma_1^2 + O(n^{-2}). \quad (2.16)$$

例 2.5 考虑例 2.2, 假定 F 的四阶矩有限, 以 μ_k 记 F 的 k 阶中心矩. 则易见

$$\varphi_1(y_1) = \frac{1}{2}\{\mu_2 + (y_1 - \theta(F))^2\}, \quad \sigma_1^2 = \frac{1}{4}(\mu_4 - \mu_2^2),$$

而

$$\sigma_2^2 = \text{Var}_F \frac{1}{2}(X_1 - X_2)^2 = \frac{1}{2}(\mu_4 - \mu_2^2).$$

于是由(2.15)式得

$$\text{Var}_F \left\{ \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right\} = \frac{1}{n} \mu_4 - \frac{n-3}{n(n-1)} \mu_2^2.$$

例 2.6 考虑例 2.3. 易见若记

$$\theta = \int_{-\infty}^{\infty} G(x + 2\tilde{\theta}) dG(x),$$

则

$$\varphi_1(y_1) = P_F(y_1 + X_2 > 0) = G(y_1 + \tilde{\theta}),$$

$$\sigma_1^2 = \int_{-\infty}^{\infty} G^2(x + 2\tilde{\theta}) dG(x) - \theta^2,$$

又 $\sigma_2^2 = \theta(1 - \theta)$. 于是由 (2.15) 式有

$$\text{Var}_F(U_n) = \frac{2}{n(n-1)} \left\{ 2(n-2) \int_{-\infty}^{\infty} G^2(x + 2\tilde{\theta}) dG(x) - (2n-3)\theta^2 + \theta \right\}. \quad (2.17)$$

特别, 当 $\tilde{\theta} = 0$ 时, 有 $\theta = 1/2$, 而

$$\sigma_1^2 = \frac{1}{12}, \quad \sigma_2^2 = \frac{1}{4}, \quad \text{Var}_F(U_n) = \frac{2n-1}{6n(n-1)}. \quad (2.18)$$

2.2 U 统计量的渐近正态性

例 2.1 表明: 在古典概率论中讨论最多且在数理统计中有广泛应用的 iid. 变量算术平均, 是 U 统计量的一个特例. 有趣的是, 近代研究表明: 不仅从形式上而言 U 统计量是 iid. 和的一种推广, 在实质上也是如此. 就是说, iid. 和的许多重要性质对 U 统计量也成立 (参看 2.4 节). 一般地讲: 把 iid. 和的性质推广到 U 统计量需要技巧及繁复的论证. 但迄今为止, 还没有发现这样的反例: 对 iid. 和成立的某一重要性质对 U 统计量不成立. 当然, 现在要作出一般性的正面或反面结论, 为时尚早, 因为有不少重要问题尚悬而未决. 例如, 至今还不知道 U 统计量分布的渐近展开问题能否达到与 iid. 和同样水平的解决.

U 统计量理论中一个核心的重要事实是: Hoeffding 在文献 [88] 中证明的渐近正态性. 这个结果不仅有很大的理论和方法上的意义 —— Hoeffding 在证

明中使用了一种有普遍意义的方法:用独立和去逼近一个想要证明其渐近正态性的变量——而且也很有应用价值.因为如在前面所指出的:当用 U 统计量进行假设检验时,其临界值大多难以确定,而 U 统计量的渐近正态性提供了一种方便的近似方法.

2.2.1 Hoeffding 定理

定理 2.1(Hoeffding^[89]) 沿用 2.1 节的记号,并假定 (2.14) 式成立,且 $\sigma_1^2 > 0$, 则当 $n \rightarrow \infty$ 时,有

$$\sqrt{n}(U_n - \theta) \xrightarrow{\mathcal{L}} N(0, m^2 \sigma_1^2). \quad (2.19)$$

注意:此处 m 为核函数所含变元的个数, σ_1^2 由 (2.12) 及 (2.13) 式确定(取 $c = 1$), 而 $\theta = \theta(F) = E_F \varphi(X_1, \dots, X_m) = E_F(U_n)$. 在下面当不致引起混淆时,我们去掉记号 E_F, Var_F 中的 F .

定理 2.1 的证明基于下面的简单引理:

引理 2.1 以 $\sigma^2(\xi)$ 记变量 ξ 的方差. 设 $\{V_n\}$ 和 $\{W_n\}$ 为两串随机变量, $0 < \sigma^2(V_n) < \infty$, G 为分布函数, 又设当 $n \rightarrow \infty$ 时,

$$\frac{V_n}{\sigma(V_n)} \xrightarrow{\mathcal{L}} G, \quad \frac{E(W_n - V_n)^2}{\sigma^2(V_n)} \rightarrow 0. \quad (2.20)$$

则有 $V_n/\sigma(W_n) \xrightarrow{\mathcal{L}} G, W_n/\sigma(V_n) \xrightarrow{\mathcal{L}} G$.

证 易见若变量 ξ, η 都具有有限方差, 则

$$|\sigma(\xi) - \sigma(\eta)| \leq \sigma(\xi - \eta).$$

事实上,

$$\begin{aligned} |\sigma(\xi) - \sigma(\eta)|^2 &= \sigma^2(\xi) + \sigma^2(\eta) - 2\sigma(\xi)\sigma(\eta) \\ &\leq \sigma^2(\xi) + \sigma^2(\eta) - 2\text{Cov}(\xi, \eta) \\ &= \sigma^2(\xi - \eta). \end{aligned}$$

现注意

$$\frac{W_n}{\sigma(V_n)} = \frac{V_n}{\sigma(V_n)} + \frac{W_n - V_n}{\sigma(V_n)}.$$

由 (2.20) 式的后一式知

$$\frac{W_n - V_n}{\sigma(V_n)} \xrightarrow{P} 0.$$

因此, 由 (2.20) 式的第一式推出

$$\frac{W_n}{\sigma(V_n)} \xrightarrow{\mathcal{L}} G.$$

又因

$$\begin{aligned} \left| \frac{\sigma(W_n)}{\sigma(V_n)} - 1 \right|^2 &= \left| \sigma(W_n) - \frac{\sigma(V_n)^2}{\sigma^2(V_n)} \right| \\ &\leq \frac{\sigma^2(W_n - V_n)}{\sigma^2(V_n)} \rightarrow 0 \end{aligned}$$

知 $\sigma(W_n)/\sigma(V_n) \rightarrow 1$. 将此式与已证的

$$\frac{W_n}{\sigma(V_n)} \xrightarrow{\mathcal{L}} G$$

相结合, 即得

$$\frac{W_n}{\sigma(W_n)} \xrightarrow{\mathcal{L}} G$$

引理证毕.

回到定理 2.1 的证明. 不失普遍性, 设 $\theta = 0$. 令

$$W_n = \sqrt{n}U_n, \quad V_n = \frac{m}{\sqrt{n}} \sum_{i=1}^n \varphi_1(X_i). \quad (2.21)$$

上式中 φ_1 的定义见 (2.12) 式 (取 $c = 1$). 因为 $E\varphi_1(X_i) = E\varphi(X_1, \dots, X_m) = 0$, 且 $\text{Var}\varphi_1(X_i) = \sigma_1^2$ 非 0 有限. 根据古典中心极限定理有

$$\frac{V_n}{\sigma(V_n)} \xrightarrow{\mathcal{L}} N(0, 1).$$

又

$$E(W_n - V_n)^2 = n \text{Var}(U_n) + m^2 \sigma_1^2 - 2m \sum_{i=1}^n E(U_n \varphi_1(X_i)). \quad (2.22)$$

在 U_n 的表达式中, 凡不含 X_i 的项与 $\varphi_1(X_i)$ 相乘后, 其积的均值为 0; 含 X_i 的项则有

$$\begin{aligned} &E\{\varphi(X_{a_1}, \dots, X_i, \dots, X_{a_m}) \varphi_1(X_i)\} \\ &= EE\{\varphi(X_{a_1}, \dots, X_i, \dots, X_{a_m}) \varphi_1(X_i) \mid X_i\} \\ &= E\{\varphi_1(X_i) E\{(X_{a_1}, \dots, X_i, \dots, X_{a_m}) \mid X_i\}\} \\ &= E\varphi_1^2(X_i) = \sigma_1^2. \end{aligned}$$

且这样的项共有 $\binom{n-1}{m-1}$ 个. 因此

$$E(U_n \varphi_1(X_i)) = \binom{n}{m}^{-1} \binom{n-1}{m-1} \sigma_1^2 = \frac{m}{n} \sigma_1^2.$$

将上式代入(2.22)式,并注意(2.16)式,得

$$E(W_n - V_n)^2 = O(n^{-1}). \quad (2.23)$$

由于 $\sigma^2(V_n) = m^2 \sigma_1^2 > 0$, 由(2.23)式知 $E(W_n - V_n)^2 / \sigma^2(V_n) \rightarrow 0$. 将此式与已证的

$$\frac{V_n}{\sigma(V_n)} \xrightarrow{\mathcal{L}} N(0, 1)$$

相结合,根据引理 2.1,即得

$$\frac{W_n}{\sigma(V_n)} = \frac{\sqrt{n}U_n}{m\sigma_1} \xrightarrow{\mathcal{L}} N(0, 1).$$

定理证毕.

注 2.1 由(2.16)式知 $n \text{Var}(U_n) / (m\sigma_1)^2 \rightarrow 1$. 因此,在本定理的条件下有

$$\frac{U_n - E(U_n)}{\sigma(U_n)} \xrightarrow{\mathcal{L}} N(0, 1).$$

注 2.2 本定理证明的基本思想是用 iid. 和 V_n 去逼近非独立和 W_n . (2.23)式表明,当 n 很大时, V_n 与 W_n 相差甚微. 不难证明:在均方误差最小的意义下,在一切形如 $\sum_{i=1}^n a_i(X_i)$ 的独立和中, V_n 是与 W_n 最接近者. 换句话说, V_n 是 W_n 在“独立和空间”中的“投影”. 由此缘故,此法也称为“投影法”(可参见 Hajek^[79] 关于此问题的论述).

例 2.7 考虑例 2.3 所定义的 U 统计量(2.9)式. 设 $\tilde{\theta} = 0$, 即总体分布 F 连续且关于原点对称, 则 $\theta = E(U_n) = 1/2$, 又由(2.18)式知 $\sigma_1^2 = 1/12$. 于是由(2.19)式有

$$\sqrt{n} \left(U_n - \frac{1}{2} \right) \xrightarrow{\mathcal{L}} N \left(0, \frac{1}{3} \right). \quad (2.24)$$

记

$$W_n^+ = R_1^+ + \cdots + R_n^+. \quad (2.25)$$

W_n^+ 称为“Wilcoxon 符号秩统计量”(参看(3.16)式). 将(2.24)式写为

$$\left(W_n^+ - r - \frac{1}{2} \binom{n}{2} \right) / \left\{ \binom{n}{2} \sqrt{\frac{1}{3n}} \right\} \xrightarrow{\mathcal{L}} N(0, 1),$$

并注意到 $0 \leq r \leq n$, 因而

$$r / \left\{ \binom{n}{2} \sqrt{\frac{1}{3n}} \right\} \rightarrow 0,$$

有

$$\left(W_n^+ - \frac{1}{2} \binom{n}{2} \right) / \left\{ \binom{n}{2} \sqrt{\frac{1}{3n}} \right\} \xrightarrow{\mathcal{L}} N(0, 1). \quad (2.26)$$

当然, (2.26) 式只有 $\tilde{\theta} = 0$ 成立. 利用 (2.26) 式可作出假设 $H: \tilde{\theta}$ (即对称中心在原点) 的大样本检验: 若对立假设为 $K: \tilde{\theta} \neq 0$, 则取否定域为

$$\sqrt{3n} \left| W_n^+ - \frac{1}{2} \binom{n}{2} \right| \geq u_{\alpha/2} \binom{n}{2}. \quad (2.27)$$

这里 $0 < \alpha < 1$, α 为特定的检验水平, u_α 由关系式

$$\frac{1}{\sqrt{2\pi}} \int_{u_\alpha}^{\infty} e^{-x^2/2} dx = \alpha$$

确定. 此检验为相似检验, 其水平当 n 很大时接近 α . 其非参数性表现为在总体分布 $F = (G, \tilde{\theta})$ 中, 只要求 G 连续且关于 0 对称, 而不要求其有特定的数学形式. 若假定 $G \sim N(0, \sigma^2)$ (σ 未知), 则是一个典型的参数检验问题. 在初等统计中, 此问题通常用“一样本 t 检验”去处理.

例 2.8 设某种元件的寿命 X 有分布 F . 记 $\bar{F} = 1 - F$. 则 $s > 0, t > 0$, 有

$$P(X > s + t \mid X > t) = \bar{F}(s + t) / \bar{F}(t).$$

上式左边表示“当一个元件在 t 时尚未失效的条件下, 它至少能再使用 s 这么长一段时间”的条件概率. 若元件无老化作用, 则此条件概率应与从 $t = 0$ 时起算者相同, 即 $\bar{F}(s + t) / \bar{F}(t) = \bar{F}(s)$. 故

$$H: \text{“元件无老化”} \sim \bar{F}(s + t) = \bar{F}(t) \bar{F}(s).$$

反之, 若有老化, 则 $\bar{F}(s + t) / \bar{F}(t)$ 将小于 $\bar{F}(s)$. 即

$$K: \text{“元件有老化”} \sim \bar{F}(s + t) < \bar{F}(t) \bar{F}(s).$$

现在要根据寿命 X 的 iid. 观测结果 $X_1, \dots, X_n$ 去检验假设 $H \longleftrightarrow K$.

设 F 属于分布族 $\mathcal{F} = \{F: F(0) = 0, F \text{ 在 } \mathbb{R}^1 \text{ 处处连续}\}$. 在 $\mathcal{F}$ 上定义

$$\begin{aligned} \theta &= \theta(F) = \int_0^\infty \int_0^\infty \{\bar{F}(s) \bar{F}(t) - \bar{F}(s + t)\} dF(s) dF(t) \\ &= \frac{1}{4} - \int_0^\infty \int_0^\infty \bar{F}(s + t) dF(s) dF(t) \end{aligned}$$

$$= \frac{1}{4} - P_F(X_1 > X_2 + X_3). \quad (2.28)$$

令 $\theta^* = \theta^*(F) = P_F(X_1 > X_2 + X_3)$, 则由 (2.28) 式知: 当 H 成立时, $\theta^*(F) = 1/4$. 否则, $\theta^*(F) < 1/4$. 因而问题 $H \longleftrightarrow K$ 转化为

$$\theta^*(F) = \frac{1}{4} \longleftrightarrow \theta^*(F) < \frac{1}{4}.$$

令

$$\varphi(y_1, y_2, y_3) = \frac{1}{3} [\Psi(y_1 - y_2 - y_3) + \Psi(y_2 - y_3 - y_1) + \Psi(y_3 - y_1 - y_2)].$$

此处 Ψ 由 (2.28) 式定义. 则易见 φ 为 y_1, y_2, y_3 的对称函数, 且

$$E_F \varphi(X_1, X_2, X_3) \neq \theta^*(F).$$

用 U_n 记以 φ 为核的 U 统计量. 经过容易但较繁复的计算, 易得在 H 成立时, 有 $\sigma_1^2 = 5/432$. 此处 $m = 3$. 故由 (2.19) 式知, 在 H 成立时, 有

$$\sqrt{n} \left(U_n - \frac{1}{4} \right) \xrightarrow{\mathcal{L}} N \left(0, \frac{5}{48} \right).$$

由此可作出 $H \longleftrightarrow K$ 的渐近水平为 α 的大样本检验, 其否定域为

$$U_n < \frac{1}{4} - \sqrt{\frac{5}{48n}} u_\alpha.$$

2.2.2 σ_1^2 的估计

在例 2.6 和例 2.7 中, σ_1^2 在 H 成立时为已知常数. 在不少情况下 (如例 2.4) 即使在 H 成立时 σ_1^2 的值也与 F 有关. 这时 (2.19) 式不能直接用于检验假设 H . 解决这个困难的方法是利用样本 $X_1, \dots, X_n$ 对 σ_1^2 作出一个相合估计 σ_{1n}^2 , 以它代替 (2.19) 式中的 σ_1^2 而得

$$\frac{\sqrt{n}(U_n - \theta)}{m\sigma_{1n}} \xrightarrow{\mathcal{L}} N(0, 1). \quad (2.29)$$

此式可直接用于作 H 的大样本检验.

因为 $\sigma_1^2 = E\varphi_1^2(X_1) - \theta^2$. 为作 σ_1^2 的相合估计, 只需分别作出 $E\varphi_1^2(X_1)$ 与 θ^2 相合估计. 假定 (2.14) 式成立, 则有 (2.16) 式, 因为 U_n 为 θ 的无偏估计, 由 (2.16) 式知有 $U_n \xrightarrow{P} \theta$, 则 U_n 为 θ 的 (弱) 相合估计, 因而 U_n^2 为 θ^2 的弱相合估计, 为估计 $E\varphi_1^2(X_1)$, 注意由 φ_1 的定义易得

$$E\varphi_1^2(X_1) = E\{\varphi(X_1, X_2, \dots, X_m)\varphi(X_1, X_{m+1}, \dots, X_{2m+1})\}.$$

故若取

$$\varphi^*(y_1, \dots, y_{2m+1}) = \frac{1}{(2m-1)!} \sum_{(j_1, \dots, j_{2m-1})} \varphi(y_{j_1}, y_{j_2}, \dots, y_{j_m}) \times \varphi(y_{j_1}, y_{j_{m+1}}, \dots, y_{j_{2m-1}}) \quad (2.30)$$

(右边和号的意义参看(2.2)式) 则 φ^* 为其 $2m-1$ 个变元的对称函数, 且 $E\varphi^*(X_1, \dots, X_{2m-1}) = E\varphi_1^2(X_1)$. 易见, 若假定

$$E\varphi^4(X_1, \dots, X_m) < \infty. \quad (2.31)$$

则将有 $E(\varphi^*(X_1, \dots, X_{2m-1}))^2 < \infty$. 于是, 以 φ^* 为核构成的 U 统计量 U_n^* 是 $E\varphi_1^2(X_1)$ 的弱相合估计. 易见

$$U_n^* = \left\{ \binom{n}{2m-1} (2m-1) \binom{2m-2}{m-1} \right\}^{-1} \sum_{\varphi}^* (X_{\alpha_1}, \dots, X_{\alpha_n}) \times \varphi(X_{\beta_1}, \dots, X_{\beta_m}). \quad (2.32)$$

$\sum^*$ 表示求和的范围为: $1 \leq \alpha_1 < \dots < \alpha_m \leq n, 1 \leq \beta_1 < \dots < \beta_m \leq n$, 且 $\{\alpha_1, \dots, \alpha_m\}$ 与 $\{\beta_1, \dots, \beta_m\}$ 中恰有一个公共元.

以上讨论总结为下面的定理:

定理 2.2 设(2.31)式成立, 则

$$\sigma_{1n}^2 = U_n^* - U_n^2 \quad (2.33)$$

是 σ_1^2 的一弱相合估计. 此处 U_n 为以 φ 为核的 U 统计量, 而 U_n^* 由(2.32)式给出.

在此有一个细节应注意: σ_1^2, θ 等都与分布 F 有关, 应写为 $\sigma_1^2(F), \theta(F)$ 等, 又(2.31)式的左端也应写为 $E_F(\varphi^4)$. 因此, 所谓“(2.31)式成立”一语, 更确切地说, 是“(2.31)式在 $F \in \mathcal{F}$ 或 $\mathcal{F}$ 的某子集 $\mathcal{F}_0$ 上成立”, 而定理 2.2 的结论相应地确切化为: “在 $\mathcal{F}$ 或 $\mathcal{F}_0$ 上, σ_{1n}^2 为 $\sigma_1^2(F)$ 的弱相合估计”.

注 2.3 若当原假设 H 成立时有 $E(U_n) = \theta_0$ (已知), 则在(2.33)式中可以用 θ_0^2 代替 U_n^2 . 这样作出的 σ_{1n}^2 只在 H 成立时才是 σ_1^2 的相合估计, 因而(2.29)式也只在 H 成立时才有效. 但这对作 H 的大样本检验已足够了.

另一个问题是: 虽然 U_n 是 θ 的无偏估计, 但 U_n^2 不是 θ^2 的无偏估计. 故由(2.33)式定义的 σ_{1n}^2 也不是 σ_1^2 的无偏估计. 不难直接作出 θ^2 的无偏且相合的估计, 例如, 以

$$\tilde{\varphi}(y_1, \dots, y_{2m}) = \frac{1}{(2m)!} \sum_{(j_1, \dots, j_{2m})} \varphi(y_{j_1}, \dots, y_{j_m}) \varphi(y_{j_{m+1}}, \dots, y_{j_{2m}})$$

(和号意义参看(2.2)式) 为核的 U 统计量 $\tilde{U}_n$ 即为其一. 这一简单事实的验证留给读者.

2.2.3 一致收敛性问题

设 $X_1, \dots, X_n \sim F \in \mathcal{F}$, $\varphi(y_1, \dots, y_m)$ 为对称核, U_n 为以 φ 为核且基于 $X_1, \dots, X_n$ 的 U 统计量. 设条件 (2.14) 对一切 $F \in \mathcal{F}$ 成立. 按 (2.12)、(2.13) 式定义 α_1^2 , 并为明确计, 将其记为 $\sigma_1^2(F)$. 设 $\sigma_1^2(F) > 0$ 对一切 $F \in \mathcal{F}$ 成立. 以 $H_{n,F}(X)$ 记 $\sqrt{n}(U_n - E_F(U_n)) / (m\sigma_1(F))$ 的分布函数, 以 $\Phi(x)$ 记标准正态分布函数. 则由 (2.19) 式知: 对任何 $F \in \mathcal{F}$, 当 $n \rightarrow \infty$ 时, 有

$$\|H_{n,F} - \Phi\| = \sup_x |H_{n,F}(x) - \Phi(x)| \rightarrow 0. \quad (2.34)$$

在第 4 章讨论检验的“渐近相对效率”问题时, 有必要确定 (2.34) 式中的收敛性对适当选定的分布族 $\mathcal{F}$ 是一致的, 即

$$\sup_{F \in \mathcal{F}} \|H_{n,F} - \Phi\| \rightarrow 0, \quad n \rightarrow \infty. \quad (2.35)$$

下面是关于这一问题的一个简单而有用的结果:

定理 2.3 设存在常数 $M, \delta > 0$ 及 $\eta > 0$, 使

$$1^\circ E_F |\varphi(X_1, \dots, X_m)|^{2+\delta} \leq M, \quad \text{对一切 } F \in \mathcal{F}; \quad (2.36)$$

$$2^\circ \sigma_1^2(F) \geq \eta, \quad \text{对一切 } F \in \mathcal{F}. \quad (2.37)$$

则 (2.35) 式成立.

定理的证明基于极限理论中的下述重要事实:

引理 2.2 设随机变量 $\xi_1, \dots, \xi_n$ 相互独立, $E(\xi_1) = \dots = E(\xi_n) = 0$, 且对某个 $\delta \in (0, 1]$ 有 $E|\xi_i|^{2+\delta} < \infty$ ($i = 1, \dots, n$), 记

$$B_n^2 = \sum_{i=1}^n \text{Var}(\xi_i),$$

设 $B_n^2 > 0$. 以 F_n 记变量 $\frac{1}{B_n} \sum_{i=1}^n \xi_i$ 的分布函数, 则存在绝对常数 A , 使

$$\|F_n - \Phi\| \leq AB_n^{-(2+\delta)} \sum_{i=1}^n E|\xi_i|^{2+\delta}. \quad (2.38)$$

证明见文献 [132] 中第五章.

现在转到定理的证明. 不失普遍性, 可设 (2.36) 式中的 $\delta \in (0, 1]$. 由 (2.36) 式易知, 存在常数 M' , 使

$$\begin{aligned} \text{Var}_F \varphi(X_1, \dots, X_m) &\leq E_F \varphi^2(X_1, \dots, X_m) \\ &\leq M', \quad \text{对一切 } F \in \mathcal{F}'. \end{aligned} \quad (2.39)$$

由 (2.15)、(2.39) 式, 注意到 $\text{Var}_F(U_n)$ 的表达式, 知存在常数 M'' , 使

$$| \text{Var}_F(U_n) - \frac{m^2}{n} \sigma_1^2(F) | \leq M'' n^{-2}, \quad \text{对一切 } F \in \mathcal{F}. \quad (2.40)$$

记

$$W_{nF} = \frac{\sqrt{n}(U_n - \theta(F))}{m\sigma_1(F)},$$

$$V_{nF} = \sum_{i=1}^n \frac{\varphi_{1F}(X_i) - \theta(F)}{\sqrt{n}\sigma_1(F)}.$$

由定理 2.1 的证明, 结合 (2.40) 式及条件 (2.37), 易得

$$\begin{aligned} E_F(W_{nF} - V_{nF})^2 &\leq \frac{M''}{n\sigma_1^2(F)} \\ &\leq \frac{M'}{n\eta}, \quad \text{对一切 } F \in \mathcal{F}. \end{aligned} \quad (2.41)$$

由 (2.41) 式可知, 若以 G_{nF} 记 V_{nF} 的分布函数, 则

$$\lim_{n \rightarrow \infty} \left\{ \sup_{F \in \mathcal{F}} \|H_{nF} - G_{nF}\| \right\} = 0. \quad (2.42)$$

令 $\xi_i = \varphi_{1F}(X_i) - \theta(F)$ ($i = 1, \dots, n$), 则 $\xi_1, \dots, \xi_n$ 为 iid., 均值为 0, $B_n^2 = \sum_{i=1}^n \text{Var}(\xi_i) = n\sigma_1^2(F)$. 又因为 $\theta(F) = E_F \varphi(X_1, \dots, X_m) = E_F \varphi_{1F}(X_i)$, 并注意

到 φ_{1F} 的定义, 由 Jensen 不等式得

$$|\theta(F)|^{2+\delta} \leq E |\varphi_{1F}(X_i)|^{2+\delta} \leq E_F |\varphi(X_1, \dots, X_m)|^{2+\delta} \leq M.$$

于是得

$$\begin{aligned} E_F |\xi_i|^{2+\delta} &= E_F |\varphi_{1F}(X_i) - \theta(F)|^{2+\delta} \\ &\leq 2^{2+\delta} [E_F |\varphi_{1F}(X_i)|^{2+\delta} + |\theta(F)|^{2+\delta}] \\ &\leq 2^{2+\delta} M, \quad i = 1, \dots, n; \text{ 对一切 } F \in \mathcal{F}. \end{aligned} \quad (2.43)$$

由 (2.38)、(2.43) 式, 并注意到

$$V_{nF} = \frac{1}{B_n} \sum_{i=1}^n \xi_i$$

及 $B_n^2 \geq n\eta$, 得

$$\|G_{nF} - \Phi\| \leq AM 2^{2+\delta} \eta^{-1-\delta/2} n^{-\delta/2}. \quad (2.44)$$

将 (2.42) 式与 (2.44) 式结合即得 (2.35) 式. 定理证毕.

例 2.9 就例 2.3 而言, 由于核函数 φ 有界, 条件 (2.36) 满足. 取 $\mathcal{F}$ 为 $\mathcal{F} = \{F = (G, \tilde{\theta}) = G(x - \tilde{\theta}); G(x) \text{ 已知, 在 } \mathbb{R}^1 \text{ 连续且关于 } 0 \text{ 对称, 而 } |\tilde{\theta}| \leq a\}$.

(2.45)

此处 $a > 0$ 为常数. (2.45) 式与 (2.6) 式不同之处在于 (2.6) 式中的 G 可以变化, 而在 (2.45) 式中 G 是固定的.

在例 2.6 中已证得

$$\sigma_1^2(F) = \int_{-\infty}^{\infty} G^2(x + 2\tilde{\theta}) dG(x) - \left(\int_{-\infty}^{\infty} G(x + 2\tilde{\theta}) dG(x) \right)^2.$$

由 G 为连续有界, 按控制收敛定理, 知 $\sigma_1^2(F)$ 为 $\tilde{\theta}$ 的连续函数. 又当 $\tilde{\theta} = 0$ 时, $\sigma_1^2(F) = 1/12$. 于是当 $a > 0$ 充分小时, 有 $\sigma_1^2(F) \geq 1/13$ ($|\tilde{\theta}| \leq a$). 这表明: 当 a 充分小时, 由 (2.45) 式定义的 $\mathcal{F}$ 满足条件 (2.37) 式. 因此, 定理 2.2 的结论适用于本例 (当 $\mathcal{F}$ 由 (2.45) 式定义而 $a > 0$ 充分小时).

2.3 多样本 U 统计量

前两节讨论的 U 统计量可称为一样本 U 统计量, 因为它是基于从一个总体中抽出的 iid. 样本 $X_1, X_2, \dots$. 这种 U 统计量适用于一样本统计问题. 为处理数理统计中的多样本问题, 要把 U 统计量相应地推广到多样本的情况, 为了书写简单, 此处只以两样本为例来讨论, 推广到多组样本的情况是没有困难的.

定义 2.2 设 $X_1, \dots, X_{n_1}$ 为 iid., $Y_1, \dots, Y_{n_2}$ 为 iid., 且 $X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}$ 相互独立 (X_1, Y_1 的维数不必相同). 设 $m_1 \leq n_1, m_2 \leq n_2$ 是自然数, $\varphi(x_1, \dots, x_{m_1}; y_1, \dots, y_{m_2})$ 为其所含变元的 Borel 可测函数, 且 φ 分别对各 x 变元和各 y 变元为对称, 即

$$\varphi(x_{i_1}, \dots, x_{i_{m_1}}; y_{j_1}, \dots, y_{j_{m_2}}) = \varphi(x_1, \dots, x_{m_1}; y_1, \dots, y_{m_2})$$

对 $\{1, \dots, m_1\}$ 的任一置换 $\{i_1, \dots, i_{m_1}\}$ 和 $\{1, \dots, m_2\}$ 的任一置换 $\{j_1, \dots, j_{m_2}\}$ 都成立. 令

$$\begin{aligned} U_{n_1 n_2} &= U_{n_1 n_2}(X_1, \dots, X_{n_1}; Y_1, \dots, Y_{n_2}) \\ &= \left\{ \binom{n_1}{m_1} \binom{n_2}{m_2} \right\}^{-1} \sum_{1 \leq \alpha_1 < \dots < \alpha_{m_1} \leq n_1, 1 \leq \beta_1 < \dots < \beta_{m_2} \leq n_2} \varphi(X_{\alpha_1}, \dots, X_{\alpha_{m_1}}; \\ &\quad Y_{\beta_1}, \dots, Y_{\beta_{m_2}}). \end{aligned} \quad (2.46)$$

则称 $U_{n_1 n_2}$ 为以 φ 为核且基于 $X_1, \dots, X_{n_1}$ 和 $Y_1, \dots, Y_{n_2}$ 的 U 统计量.

在统计问题中,一般情况是

$$X_1, \dots, X_{n_1} \sim F \in \mathcal{F}, \quad y_1, \dots, y_{n_1} \sim G \in \mathcal{G}$$

即 $\{X_1, \dots, X_{n_1}\}$ 和 $\{Y_1, \dots, Y_{n_2}\}$ 是两组样本,分别抽自具分布 F 和 G 的总体,而 F 和 G 则分别属于给定的分布族 $\mathcal{F}$ 和 $\mathcal{G}$. 这样, (2.46) 式定义了一个“两样本 U 统计量”. 推广到多组样本是显然的.

这种 U 统计量的应用,在原则上与一样本的情况毫无区别. 以估计问题来说:设想有一个使人感兴趣的函数 $\theta(F, G)$ 定义于 $\mathcal{F} \times \mathcal{G}$ 上,要通过样本去估计它. 为此设法找到一个对称核 $\varphi(x_1, \dots, x_{m_1}; y_1, \dots, y_{m_2})$, 使对任何 $F \in \mathcal{F}$ 及 $G \in \mathcal{G}$, 有

$$E_{F, G} \varphi(X_1, \dots, X_{m_1}; Y_1, \dots, Y_{m_2}) = \theta(F, G).$$

然后以 φ 为核作出 U 统计量 (2.46) 式, 则 $U_{n_1 n_2}$ 是 $\theta(F, G)$ 的无偏估计, 且可以证明: 在 $\mathcal{F}$ 和 $\mathcal{G}$ 满足某些一般性条件时, $U_{n_1 n_2}$ 是 $\theta(F, G)$ 的 UMVUE.

多样本 U 统计量的性质及其证明与一样本的情况完全类似. 故以下只列出有关结果. 我们固定 F 与 G 来讨论. 从而有关记号中本应标明的 F, G 都可省略.

1. $U_{n_1 n_2}$ 的方差

定义 2.3 $\varphi_{c_1 c_2}(x_1, \dots, x_{c_1}; y_1, \dots, y_{c_2})$

$$= E \varphi(x_1, \dots, x_{c_1}, X_{c_1+1}, \dots, X_{m_1}; y_1, \dots, y_{c_2}, Y_{c_2+1}, \dots, Y_{m_2}), \quad (2.47)$$

并以 $\sigma_{c_1 c_2}^2$ 记 $\varphi_{c_1 c_2}(X_1, \dots, X_{c_1}; Y_1, \dots, Y_{c_2})$ 的方差. 有

$$\text{Var}(U_{n_1 n_2}) = \left\{ \begin{bmatrix} n_1 \\ m_1 \end{bmatrix} \begin{bmatrix} n_2 \\ m_2 \end{bmatrix} \right\}^{-1} \sum_{c_1=1}^{m_1} \sum_{c_2=1}^{m_2} \begin{bmatrix} m_1 \\ c_1 \end{bmatrix} \begin{bmatrix} n_1 - m_1 \\ m_1 - c_1 \end{bmatrix} \begin{bmatrix} m_2 \\ c_2 \end{bmatrix} \times \begin{bmatrix} n_2 - m_2 \\ m_2 - c_2 \end{bmatrix} \sigma_{c_1 c_2}^2. \quad (2.48)$$

当然, (2.48) 式的成立要求下述条件:

$$E \varphi^2(X_1, \dots, X_{m_1}; Y_1, \dots, Y_{m_2}) < \infty. \quad (2.49)$$

同样, 类似于 (2.16) 式, 当 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, 有

$$\text{Var}(U_{n_1 n_2}) = \frac{m_1^2}{n_1} \sigma_{10}^2 + \frac{m_2^2}{n_2} \sigma_{01}^2 + O\left(\frac{1}{n_1^2} + \frac{1}{n_2^2}\right) \quad (2.50)$$

2. $U_{n_1 n_2}$ 的渐近正态性

定理 2.4 设 (2.49) 式成立, 且

$$\sigma_{10}^2 > 0, \quad \sigma_{01}^2 > 0. \quad (2.51)$$

记 $\theta(F, G)$ 为 θ , 以及

$$N = n_1 + n_2, \quad \sigma_N^2 = N \left(\frac{m_1^2}{n_1} \sigma_{10}^2 + \frac{m_2^2}{n_2} \sigma_{01}^2 \right). \quad (2.52)$$

则当 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, 有

$$\frac{\sqrt{N}(U_{n_1 n_2} - \theta)}{\sigma_N} \xrightarrow{\mathcal{L}} N(0, 1). \quad (2.53)$$

证明梗概如下: 不失普遍性, 设 $\theta = 0$. 令

$$V_{n_1 n_2} = \frac{\sqrt{N}}{\sigma_N} \left(\frac{m_1}{n_1} \sum_{i=1}^{n_1} \varphi_{10}(X_i) + \frac{m_2}{n_2} \sum_{j=1}^{n_2} \varphi_{01}(Y_j) \right).$$

易证当 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, $V_{n_1 n_2} \xrightarrow{\mathcal{L}} N(0, 1)$. 故为证本定理, 只需证 $E(\sqrt{N}U_{n_1 n_2}/\sigma_N - V_{n_1 n_2})^2 \rightarrow 0$. 易见 $E(V_{n_1 n_2}^2) = 1$, 又由 (2.50) 式易见当 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, $E(\sqrt{N}U_{n_1 n_2}/\sigma_N)^2 \rightarrow 1$. 又由 $\varphi_{10}, \varphi_{01}$ 和 $U_{n_1 n_2}$ 的定义, 经过简单计算, 易见

$$E \left[\frac{\sqrt{N}U_{n_1 n_2} V_{n_1 n_2}}{\sigma_N} \right] = 1.$$

这就证明了要证的结果.

注 2.4 若 $\sigma_{10}^2 > 0$, 但 $\sigma_{01}^2 = 0$, 则附加条件 $n_1 = o(n_2^2)$ 后, 定理 2.4 的结论仍成立. 若 $\sigma_{10}^2 = 0$, 但 $\sigma_{01}^2 > 0$, 则须附加条件 $n_2 = o(n_1^2)$. 读者自验证之.

3. σ_{10}^2 和 σ_{01}^2 的估计

与一样本的情况相似, 为将 (2.53) 式用于检验问题, 有时需通过样本去估计 σ_{10}^2 和 σ_{01}^2 . 方法与 2.2.2 小节中估计 σ_1^2 相似, 为估计 σ_{10}^2 只需估计 $E\varphi_{10}^2(X_1)$, 易见

$$\begin{aligned} E\varphi_{10}^2(X_1) &= E\{\varphi(X_1, \dots, X_{m_1}; Y_1, \dots, Y_{m_2}) \\ &\quad \times \varphi(X_1, X_{m_1+1}, \dots, X_{2m_1-1}; Y_{m_2+1}, \dots, Y_{2m_2})\}. \end{aligned}$$

于是, 若定义

$$\begin{aligned} \varphi^*(x_1, \dots, x_{2m_1-1}; y_1, \dots, y_{2m_2}) \\ &= \{(2m_1 - 1)!(2m_2)!\}^{-1} \sum^* \varphi(x_{i_1}, \dots, x_{i_{m_1}}; y_{j_1}, \dots, y_{j_{m_2}}) \\ &\quad \times \varphi(x_{i_1}, x_{i_{m_1+1}}, \dots, x_{i_{2m_1-1}}; y_{j_1}, y_{j_{m_2+1}}, \dots, y_{j_{2m_2}}) \end{aligned}$$

($\sum^*$ 求和范围是: $\{i_1, \dots, i_{2m_1-1}\}$ 取 $\{1, \dots, 2m_1 - 1\}$ 的一切置换, $\{j_1, \dots, j_{2m_2}\}$ 取 $\{1, \dots, 2m_2\}$ 的一切置换) 以 φ^* 为核作 U 统计量 $U_{n_1 n_2}^*$. 则当

$$E\varphi^4(X_1, \dots, X_{m_1}; Y_1, \dots, Y_{m_2}) < \infty \quad (2.54)$$

时 $U_{n_1 n_2}^*$ 为 $E\varphi_{10}^2(X_1)$ 的一(弱)相合估计. 所以在条件(2.54)之下, $U_{n_1 n_2}^* - (U_{n_1 n_2})^2$ 为 σ_{10}^2 的一相合估计. 类似地, 取

$$\begin{aligned} & \tilde{\varphi}(x_1, \dots, x_{2m_1}; y_1, \dots, y_{2m_2-1}) \\ &= \{(2m_1)!(2m_2-1)!\}^{-1} \sum \varphi(x_i, \dots, x_{i_{m_1}}; y_{j_1}, \dots, y_{j_{m_2}}) \\ & \quad \times \varphi(x_{i_{m_1}+1}, \dots, x_{i_{2m_1}}; y_{j_1}, y_{j_{m_2}+1}, \dots, y_{j_{2m_2-1}}) \end{aligned}$$

(求 $\sum$ 求和范围是: $\{i_1, \dots, i_{2m_1}\}$ 取 $\{1, \dots, 2m_1\}$ 的一置换, $\{j_1, \dots, j_{2m_2-1}\}$ 取 $\{1, \dots, 2m_2-1\}$ 的一切置换) 并用它为核作 U 统计量 $\tilde{U}_{n_1 n_2}$, 则在条件(2.54)之下, $\tilde{U}_{n_1 n_2} - (U_{n_1 n_2})^2$ 为 σ_{01}^2 的一相合估计.

4. 一致收敛性

结合定理 2.3 与定理 2.4 的证法, 很容易证明下面的结果:

定理 2.5 设存在常数 $M, \delta > 0, \eta > 0$, 使对一切 $(F, G) \in M$, 有

$$\begin{aligned} E_{F,G} |\varphi(X_1, \dots, X_{m_1}; Y_1, \dots, Y_{m_2})|^{2+\delta} &\leq M, \\ \sigma_{10}^2(F, G) &\geq \eta, \sigma_{01}^2(F, G) \geq \eta. \end{aligned} \quad (2.55)$$

记 $\theta(F, G) = E_{F,G} \varphi(X_1, \dots, X_{m_1}; Y_1, \dots, Y_{m_2})$. 以 $H_{n_1 n_2 FG}$ 记变量 $\sqrt{N}(U_{n_1 n_2} - \theta(F, G))/\sigma_N(F, G)$ 的分布函数, 则当 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, 有

$$\sup_{(F,G) \in M} \|H_{n_1 n_2 FG} - \Phi\| \rightarrow 0. \quad (2.56)$$

例 2.10(位置参数的两样本检验问题) 设有样本

$$X_1, \dots, X_{n_1} \sim F, \quad Y_1, \dots, Y_{n_2} \sim G. \quad (2.57)$$

并设 $X_1, \dots, Y_{n_2}$ 全体独立, F, G 为一维连续分布, 要检验假设

$$H: F \equiv G. \quad (2.58)$$

以后还多次将碰到这个问题. 在此讨论一个特例: 假定

$$G(x) = F(x - a),$$

a 为未知参数, F 也未知. 这时(2.58)式转化为 $H: a = 0$. 在这种情况下, 分布 G 是由分布 F “往右移动” 距离 a 而得到. 就是说, 两总体分布 F, G 尽管可以不同, 但只有一个位置上的差别. 由此缘故, a 常被称为位置参数.

为检验 $a = 0$, 我们注意, 若 $a > 0$, 是 $P(Y_1 > X_1)$ 将大于 $1/2$, 而当 $a < 0$ 时, 则小于 $1/2$. 故可把此概率作为检验的对象. 引进核

$$\varphi(x; y) = I_{(y > x)}. \quad (2.59)$$

则由它作成的 U 统计量, 即

$$U_{n_1 n_2} = \frac{1}{n_1 n_2} \{ \text{使 } Y_j > X_i \text{ 的 } (i, j) \text{ 组数}, 1 \leq i \leq n_1, 1 \leq j \leq n_2 \} \quad (2.60)$$

是上述概率的相合无偏估计. 当 H 成立, 即 $a = 0$ 时, 有

$$E_{\varphi}(X_1; Y_1) = \frac{1}{2},$$

又

$$\sigma_{10}^2 = \int_{-\infty}^{\infty} [1 - F(x)]^2 dF(x) - \left(\frac{1}{2}\right)^2 = \frac{1}{12}, \quad \sigma_{01}^2 = \frac{1}{12}.$$

这与 F 无关(但要求 F 连续, F 不连续时参看 3.4 节), 于是根据定理 2.4 知, 当 H 成立, 而 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, 有

$$\left(U_{n_1 n_2} - \frac{1}{2} \right) / \sqrt{\frac{n}{12 n_1 n_2}} \xrightarrow{\mathcal{L}} N(0, 1). \quad (2.61)$$

由此得出 $H: a = 0$ 的水平 α 大样本检验如下:

$$\text{对立假设 } K: a > 0: \text{否定域 } U_{n_1 n_2} > \frac{1}{2} + \sqrt{\frac{n}{12 n_1 n_2}} u_{\alpha}; \quad (2.62)$$

$$\text{对立假设 } K: a \neq 0: \text{否定域 } \left| U_{n_1 n_2} - \frac{1}{2} \right| > \sqrt{\frac{n}{12 n_1 n_2}} u_{\alpha/2}.$$

由 (2.60) 式定义的量 $n_1 n_2 U_{n_1 n_2}$ 称为 Mann-Whitney 统计量(见文献[117]). 这与 Wilcoxon 在文献[175]中提出的检验是一致的. 后者涉及样本的“秩”(rank), 将在下两章讨论.

例 2.11 (Lehmann^[109]) 设有样本 (2.57), 且

$$G(x) = F\left(\frac{x-a}{b}\right).$$

此处 a, b 为未知参数, $b > 0, F$ 连续. 要检验假设

$$H: b = 1 \longleftrightarrow K: b \neq 1. \quad (2.63)$$

易见, Y_1 的分布与 $a + bX_1$ 的分布相同. 故 a, b 分别是位置和刻度参数. 而本例属于“带赘余位置参数的刻度参数两样本检验问题”. 位置参数 a 之所以被称为“赘余”(nuisance), 是因为检验的对象不涉及它, 但它使问题复杂化.

由于 $Y_2 - Y_1 \stackrel{d}{=} b(X_2 - X_1)$ ($\stackrel{d}{=}$ 表示同分布). 因此, b 愈大, $|Y_2 - Y_1|$ 愈倾向于取大值, 基于这个考虑, Lehmann 在文献[109]中提出将概率

$$P(|Y_2 - Y_1| > |X_2 - X_1|)$$

作为检验的对象: 当 H 成立时, 此概率为 $1/2$. 而当 K 成立时, 则大于 $1/2$. 引进核

$$\varphi(x_1, x_2; y_1, y_2) = I_{(|y_2 - y_1| > |x_2 - x_1|)}.$$

用它作 U 统计量 $U_{n_1 n_2}$. 按定理 2.4 知, 当 H 成立, 且 $n_1 \rightarrow \infty, n_2 \rightarrow \infty$ 时, 有

$$\left(U_{n_1 n_2} - \frac{1}{2} \right) / \left\{ 2 \left(\frac{\sigma_{10}^2}{n_1} + \frac{\sigma_{01}^2}{n_2} \right)^{1/2} \right\} \xrightarrow{\mathcal{L}} N(0, 1). \quad (2.64)$$

此处

$$\begin{aligned} \sigma_{10}^2 &= P(|Y_1 - Y_2| > |X_1 - X_2|, |Y_3 - Y_4| > |X_1 - X_3| \mid H) - \frac{1}{4} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \{1 - F^*(|x_1 - x_2|) + F^*(-|x_1 - x_2|)\} \\ &\quad \times \{1 - F^*(|x_1 - x_3|) + F^*(-|x_1 - x_3|)\} dF(x_1) \times dF(x_2) dF(x_3) - \frac{1}{4}; \end{aligned}$$

$$\begin{aligned} \sigma_{01}^2 &= P(|Y_1 - Y_2| > |X_1 - X_2|, |Y_1 - Y_3| > |X_3 - X_4| \mid H) - \frac{1}{4} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \{F^*(|y_1 - y_2|) - F^*(-|y_1 - y_2|)\} \\ &\quad \times \{F^*(|y_1 - y_3|) - F^*(-|y_1 - y_3|)\} dF(y_1) dF(y_2) dF(y_3) - \frac{1}{4} \\ &\quad \left(F^*(x) = \int_{-\infty}^{\infty} F(x+y) dF(y) \right). \end{aligned}$$

其值与 F 有关. 故 (2.64) 式尚不能即用于检验假设 (2.63) 式. 引进核函数

$$\varphi^*(x_1, x_2, x_3; y_1, y_2, y_3, y_4) = \frac{1}{4!3!} \sum^* I_{(|y_{j_1} - y_{j_2}| > |x_{i_1} - x_{i_2}|)} I_{(|y_{j_3} - y_{j_4}| > |x_{i_1} - x_{i_3}|)};$$

$$\tilde{\varphi}(x_1, x_2, x_3, x_4; y_1, y_2, y_3) = \frac{1}{4!3!} \sum \widetilde{I}_{(|y_{j_1} - y_{j_2}| > |x_{i_1} - x_{i_2}|)} I_{(|y_{j_1} - y_{j_3}| > |x_{i_3} - x_{i_4}|)}.$$

用它为核作 U 统计量 $U_{n_1 n_2}^*$ 和 $\tilde{U}_{n_1 n_2}$, 则

$$\hat{\sigma}_{10}^2 = U_{n_1 n_2}^* - \frac{1}{4} \quad \text{及} \quad \hat{\sigma}_{01}^2 = \tilde{U}_{n_1 n_2} - \frac{1}{4}$$

分别是 σ_{10}^2 和 σ_{01}^2 的相合估计. 用它们代替 (2.64) 式中的 σ_{10}^2 和 σ_{01}^2 , 所得结果可用于决定 (2.63) 式的一水平 α 大样本检验的否定域.

2.4 若干补充知识

几十年来, U 统计量的研究在文献中受到很大的注意, 得出了不少深刻的结

果. 这些结果的证明很繁复, 且多数并无显著的统计意义. 故只择其重要者略加介绍.

2.4.1 U 统计量的 a. s. 收敛性

设 U_n 是以 $\varphi(y_1, \dots, y_m)$ 为核且基于样本 $X_1, \dots, X_n$ 的 U 统计量. 记 $\theta = E\varphi(X_1, \dots, X_m)$. 在 2.2.2 小节中已指出, 当条件

$$E\varphi^2(X_1, \dots, X_m) < \infty \quad (2.65)$$

成立时, 有 $U_n \xrightarrow{P} \theta$. 事实上, 在条件 (2.65) 之下不难证明更强的结论:

$$U_n \rightarrow \theta, \text{ a. s. } \quad (2.66)$$

为证 (2.66) 式, 先不失普遍性设 $\theta = 0$. 引进变量 W_n, V_n 如 (2.21) 式. 则 (2.23) 式成立. 此式可写为

$$E(U_n - m \frac{1}{n} \sum_{i=1}^n \varphi_1(X_i))^2 = O\left(\frac{1}{n^2}\right).$$

由此易知 (用 Chebyshev 不等式), 对任给的 $\epsilon > 0$, 有

$$\sum_{n=1}^{\infty} P\left(\left|U_n - \frac{m}{n} \sum_{i=1}^n \varphi_1(X_i)\right| \geq \epsilon\right) < \infty.$$

因而由 Borel-Cantelli 引理知

$$U_n - \frac{m}{n} \sum_{i=1}^n \varphi_1(X_i) \rightarrow 0, \text{ a. s. } \quad (2.67)$$

又由 (2.65) 式知 $E|\varphi_1(X_i)| < \infty$. 因为 $E\varphi_1(X_i) = \theta = 0$, 由 Kolmogorov 强大数律, 有

$$\frac{1}{n} \sum_{i=1}^n \varphi_1(X_i) \rightarrow 0, \text{ a. s. },$$

将此式与 (2.67) 结合, 即得 $U_n \rightarrow 0, \text{ a. s. }$

从理论的观点看这个结果仍不理想. 因为 θ 是 $\varphi(X_1, \dots, X_m)$ 的一阶矩, 而条件 (2.65) 涉及 φ 的二阶矩. 在 iid. 变量算术平均这一特例, Kolmogorov 强大数律只要求一阶矩存在. 对一般 U 统计量的问题, 直到 1961 年才由 Hoeffding 给予肯定的回答. 1966 年 Berk^[37] 发现 U 统计量序列构成“逆鞅”(Reversed martingale), 因而利用鞅收敛定理立即解决了上述问题. Berk 的这个发现使有可能把鞅论的方法用于 U 统计量的研究, 有重要的理论意义.

定理 2.6 设 $X_1, X_2, \dots$ 为 iid. 序列, $\varphi(x_1, \dots, x_m)$ 为对称核. $\{U_n, n \geq m\}$ 是以 φ 为核基于 $X_1, X_2, \dots$ 的 U 统计量序列. 若

$$E|\varphi(X_1, \dots, X_m)| < \infty, \quad (2.68)$$

则 $\{U_n, n \geq m\}$ 构成逆鞅, 且 $U_n \rightarrow \theta, \text{a.s.}$

证 以 $\mathcal{B}^1$ 表示 $\mathbb{R}^1$ 中一切 Borel 集构成的 σ 域. 并记

$$(\mathbb{R}^\infty, \mathcal{B}^\infty) = (\mathbb{R}^1, \mathcal{B}^1) \times (\mathbb{R}^1, \mathcal{B}^1) \times \dots$$

引进 $\mathcal{B}^\infty$ 的子 σ 域 $\mathcal{B}_{(n)}$ 如下: 集 $B \in \mathcal{B}_{(n)}$, 当且仅当 $B \in \mathcal{B}^\infty$ 且 B 关于前 n 个坐标对称 (即 $(x_1, \dots, x_n, x_{n+1}, \dots) \in B \Rightarrow (x_{i_1}, \dots, x_{i_n}, x_{n+1}, \dots) \in B$, 对 $\{1, 2, \dots, n\}$ 的任一置换 $\{i_1, i_2, \dots, i_n\}$ 成立). 显然有

$$\mathcal{B}^\infty = \mathcal{B}_{(1)} \supset \mathcal{B}_{(2)} \supset \mathcal{B}_{(3)} \supset \dots,$$

且当 $n \geq m$ 时, 有

$$E(\varphi(X_1, \dots, X_m) | \mathcal{B}_{(n)}) = U_n \quad (2.69)$$

如前所述, 由 (2.69) 式及 $\mathcal{B}_{(1)} \supset \mathcal{B}_{(2)} \supset \dots$, 即推出 $\{U_n, n \geq m\}$ 构成逆鞅. 根据鞅收敛定理, 知当 $n \rightarrow \infty$ 时, 有

$$U_n \rightarrow E(\varphi(X_1, \dots, X_m) | \mathcal{B}^*), \quad \text{a.s.} \quad (2.70)$$

此处

$$\mathcal{B}^* = \bigcap_{n=1}^{\infty} \mathcal{B}_{(n)},$$

为 $\mathcal{B}^\infty$ 中的对称集构成的 σ 域. 根据 Hewitt-Savage 0-1 律 (见文献 [158], 第 97 页), $\mathcal{B}^*$ 中的集的概率只能为 0 或 1. 故

$$E(\varphi(X_1, \dots, X_m) | \mathcal{B}^*) = E\varphi(X_1, \dots, X_m) = \theta, \quad \text{a.s.}$$

将此式与 (2.70) 式结合即证明了本定理.

2.4.2 U 统计量依分布收敛于正态分布的速度

设 $\xi_1, \dots, \xi_n, \dots$ 为 iid., $E(\xi_1) = a$, $E(|\xi_1|^3) < \infty$, $\text{Var}(\xi_1) = \sigma^2 > 0$. 根据著名的 Berry-Esseen 定理, 若以 $G_n(x)$ 记变量 $(\sum_{i=1}^n \xi_i - na) / (\sqrt{n}\sigma)$ 的分布函数, 则

$$\|G_n - \Phi\| = O\left(\frac{1}{\sqrt{n}}\right). \quad (2.71)$$

(注意: 此结果是引理 2.2 的特例) 对 U 统计量而言, 相应的结果应当是:

定理 2.7 设 $X_1, X_2, \dots$ 为 iid. 序列, $\varphi(x_1, \dots, x_m)$ 为对称核, U_n 为以 φ 为核且基于 $X_1, \dots, X_n$ 的 U 统计量. 记

$$\theta = E\varphi(X_1, \dots, X_m),$$

α_1^2 依(2.13)式定义. 设

$$E|\varphi(X_1, \dots, X_m)|^3 < \infty, \quad \sigma_1^2 > 0. \quad (2.72)$$

以 $G_n(x)$ 记 $\sqrt{n}(U_n - \theta)/(m\sigma_1)$ 的分布函数, 则(2.71)式成立.

此定理的证明有相当的难度, 在一些学者作出若干中间结果后, 直到 1978 年才由 Calleary 等^[43] 证得了这个最后的形式.

要深入一层, 有所谓“非一致性速度”. (2.71)式中的 $O\left(\frac{1}{\sqrt{n}}\right)$ 是 $G_n(x)$ 收敛于 $\Phi(x)$ 的速度. 这速度对全体 $x \in \mathbb{R}^1$ 是一致的. 但是显然, 若 x 很接近 $\infty (-\infty)$ 时, 则 $G_n(x)$ 和 $\Phi(x)$ 都很接近 1(0). 因而 $G_n(x)$ 接近 $\Phi(x)$ 的程度比单由 $\frac{1}{\sqrt{n}}$ 反映的要大些. 就是说, 在收敛速度中应包含有一个依赖于 x 的项. 这称为“非一致性速度”.

在 iid. 序列的情况, 20 世纪 60 年代 Osibov 等人曾加以研究(见文献[132], 第六章), 在只要求三阶矩有限的条件下, 将(2.71)式的右边改进为 $O\left(\frac{1}{\sqrt{n}(1+|x|)^3}\right)$. 对一般 U 统计量的情况, 由赵林城等解决了. 他们在文献[27]中得到了下面的定理:

定理 2.8 在定理 2.7 同样的条件与记号下, 存在常数 A 与 n, x 无关, 使对一切 x 和 n , 有

$$|G_n(x) - \Phi(x)| \leq \frac{A}{\sqrt{n}(1+|x|)^3}. \quad (2.73)$$

由于, 一致性收敛速度 $\frac{1}{\sqrt{n}}$ 不能再有任何改进. 即不可能存在这样的常数序

列 $\{b_n\}$, $b_n > 0$, $\sqrt{n}/b_n \rightarrow 0$, 使 $\|G_n - \Phi\| = O(1/b_n)$ 对任何它的三阶矩有限且方差大于 0 的 iid. 序列 $\{\xi_n\}$ 都成立. 因此, 自然产生这样一个问题: (2.73) 式右边给出的非一致性速度是否最佳的? 苏淳在文献[23]中对此问题作了回答. 他证明了: 不可能存在这样的函数 $b(x) > 0$, 使 $\lim_{|x| \rightarrow \infty} |x|^3/b(x) = 0$, 且对任何它的三阶矩有限而方差非 0 的 iid. 序列都有常数 A 存在, 使

$$|G_n(x) - \Phi(x)| \leq \frac{A}{\sqrt{nb(x)}}$$

对一切 x 和 n 成立.

2.4.3 Von-Mises 统计量

在 Hoeffding 发表关于 U 统计量的奠基性工作的前一年, Von-Mises 在文献[168] 中引进了下述形式的一类统计量:

$$V_n = V_n(X_1, \dots, X_n) = \frac{1}{n^m} \sum_{i_1=1}^n \cdots \sum_{i_m=1}^n \varphi(X_{i_1}, \dots, X_{i_m}).$$

它可称为以 $\varphi(x_1, \dots, x_m)$ 为核且基于样本 $X_1, \dots, X_n$ 的 Von-Mises 统计量.

这类统计量的用途不如 U 统计量广. 但因它在形式上与 U 统计量很相近, 故在研究 U 统计量的文献中, 常附带论及有关它的问题. 1980 年陈希孺^[1] 在条件 $(\{X_n\})$ 为 iid. 序列)

$$E |\varphi(X_{i_1}, \dots, X_{i_m})|^r < \infty, \quad i_j = 1, \dots, m, j = 1, \dots, m$$

对某个 $r \geq 1$ 之下, 找到了 V_n 与以 φ 为核的 U 统计量 U_n 之间的联系:

$$V_n = U_n + \frac{a}{n} + W_n. \quad (2.74)$$

此处 a 为常数, 而 W_n 为一定阶数的无穷小随机变量. 利用(2.74)式, 可以将 U 统计量大样本理论中的一些结果转移到 Von-Mises 统计量. 例如证明了: 在条件

$$E |\varphi(X_1, \dots, X_m)|^3 < \infty,$$

$$E |\varphi(X_1, X_2, X_3, \dots, X_m)|^{3/2} < \infty$$

之下, 将 V_n 适当规则化后, 其分布以 $O\left(\frac{1}{\sqrt{n}}\right)$ 的速度收敛于标准正态分布 $\Phi(x)$.

第 3 章

秩统计量的极限理论

3.1 引言与例子

定义 3.1 设 $x_1, \dots, x_n$ 都是实数, 且互不相等, 若在 $x_1, \dots, x_n$ 中, 恰有 r_i 个其值不超 x_i , 则称 r_i 为 x_i 的秩. 换句话说, 若将 $x_1, \dots, x_n$ 由小到大排序, 而 x_i 占据第 r_i 位 (最小的占据第一位), 则称 x_i 的秩为 r_i .

设 $X_1, \dots, X_n$ 为样本, 暂设它们总是互不相等的. 以 R_i 记 X_i 的秩 (更确切地说: 是 X_i 在 $\{X_1, \dots, X_n\}$ 中的秩), 则

$$R = (R_1, \dots, R_n)$$

构成一个统计量, R 本身及由它派生出来的任何统计量都称为秩统计量 (rank statistics). 有的作者也称之为秩次统计量 (rank order statistics). 一个统计方法, 如果其中只用到秩统计量, 则该方法称为秩方法 (rank method).

秩方法在非参数统计中占有极重要的地位. 著名统计学者 Hajek 写过一本初等的非参数统计教科书^[80], 其内容全部是秩方法. 他还在 Sidak 合写了一本关于秩检验的专著^[78]. 著名统计学者 Lehmann 有一本带应用性质的专著^[112], 书名为《非参数统计》, 副题是“基于秩的统计方法”. 由此可见秩方法在非参数统计中的重要地位. 也应当指出, 有许多重要的非参数性统计方法并非基于秩或非完全基于秩, 例如非参数回归与非参数判别.

秩方法的重要性在相当程度上来源于下面的简单事实:

定理 3.1 设 $X_1, \dots, X_n \sim F$, F 为一维连续分布. 以 R 记 $(X_1, \dots, X_n)$ 的秩 (定义见前), 则对 $(1, \dots, n)$ 的任一置换 $(i_1, \dots, i_n)$ 有

$$P(R = (i_1, \dots, i_n)) = \frac{1}{n!}.$$

证明由对称性可立即得出. 事实上, 定义 j_k , 使

$$i_{j_k} = k, \quad k = 1, \dots, n,$$

则 $(j_1, \dots, j_n)$ 为 $(1, \dots, n)$ 的一置换. 因为 $X_1, \dots, X_n$ 为 iid., 有

$$(X_{j_1}, \dots, X_{j_n}) \stackrel{d}{=} (X_1, \dots, X_n). \quad (3.1)$$

故若以 R_i' 记 X_{j_i} 在 $(X_{j_1}, \dots, X_{j_n})$ 中的秩, 则 $(R_1', \dots, R_n')$ 应与 $(R_1, \dots, R_n)$ 同分布. 因此

$$\begin{aligned} P(R_1 = i_1, \dots, R_n = i_n) &= P(R_1' = 1, \dots, R_n' = n) \\ &= P(R_1 = 1, \dots, R_n = n). \end{aligned}$$

即概率 $P(R = (i_1, \dots, i_n))$ 与置换 $(i_1, \dots, i_n)$ 无关. 一共有 $n!$ 个不同的置换, 故此概率只能为 $1/n!$.

在许多假设检验问题中, 在原假设成立之下, 样本往往为 iid. 的. 由定理 3.1 知, 若检验是基于秩统计量, 则检验统计量在原假设下有与分布无关的性质. 正是这一点决定了秩统计量的重要地位.

在定理 3.1 中假定了 F 连续. 这保证了

$$P(X_1, \dots, X_n \text{ 互不相等}) = 1. \quad (3.2)$$

因此, 不必担心诸样本可能有相同的情况, 而秩统计量 R 以概率 1 有明确的定义. 以后还要讨论连续性条件不满足的情况.

下面举一些例子说明秩方法在检验问题中的应用. 其他应用将在下章及以后章节中论述之.

1. 两样本位置参数检验

设有样本

$$X_1, \dots, X_m \sim F(x), Y_1, \dots, Y_n \sim G(x) = F(x - a). \quad (3.3)$$

此处 F 和 a 都未知, 但假定 F 在 $\mathbb{R}^1$ 上处处连续. 要检验假设 $H: a = 0$ (也可以考虑 $H: a \leq 0$. 作法相似).

设对立假设为 $K: a > 0$. 以 R_i 表示 $Y_i (i = 1, \dots, n)$ 在“合样本” $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 中的秩. 若 $a > 0$ 成立, 则相对于 X -样本而言, Y -样本倾向于取较大的值, 因而 $R_1, \dots, R_n$ 也倾向于取大的值. 这启示了这样一个检验法: 令

$$W = R_1 + \dots + R_n, \quad (3.4)$$

而当

$$W > C \quad (3.5)$$

时, 否定原假设 H . C 为一适当选择的常数. 这个著名检验称为“Wilcoxon 两样本秩和检验”, 是 Wilcoxon 在 1945 年^[175] 提出来的. 不难看出, 统计量 W 与 (2.60) 式引进的 Mann-Whitney 统计量有如下的关系:

$$\begin{aligned} &\{\text{使 } Y_i > X_i \text{ 的 } (i, j) \text{ 组数 } 1 \leq i \leq m, 1 \leq j \leq n\} \\ &= W - \frac{n(n+1)}{2}. \end{aligned} \quad (3.6)$$

因此, Mann-Whitney 检验与 Wilcoxon 检验是一回事. 在文献中有时称为 Wilcoxon-Mann-Whitney 检验.

若对立假设为 $K: a \neq 0$, 则当 K 成立时, W 倾向于取较大的值或较小的值. 因此, 检验的否定域应取为

$$\{W > C_2\} \cup \{W < C_1\}. \quad (3.7)$$

C_1, C_2 是适当选定的常数.

为确定 (3.5)、(3.7) 式中的常数, 要计算 W 在原假设 $a = 0$ 成立时的分布, 原则上这可按定理 3.1 算出为

$$P_{a=0}(W = i) = t_{mn}(i) / \binom{N}{n}, \quad N = m + n, \quad (3.8)$$

$$i = \frac{1}{2}n(n+1), \frac{1}{2}n(n+1)+1, \dots, \frac{1}{2}n(N+m+1).$$

这里 $t_{mn}(i)$ 等于从 $1, 2, \dots, N$ 中取出 n 个数, 使其和恰为 i 的取法. 例如, 当 $m = 3, n = 2$ 时, 有

$$\begin{aligned} P_{a=0}(W = i) &= \frac{1}{10}, \quad i = 3, 4, 8, 9 \\ &= \frac{2}{10}, \quad i = 5, 6, 7. \end{aligned}$$

故如取显著性水平为 $\alpha = 0.2$, 而对立假设为 $a > 0$, 则否定域为 $\{8, 9\}$. 若对立假设为 $a \neq 0$, 则否定域为 $\{3, 9\}$. 若取 $\alpha = 0.05$, 而对立假设为 $a > 0$, 则当 $W \leq 8$ 时, 接受原假设, $W = 9$ 时以概率 $1/2$ 接受原假设.

当 m, n 都相当小时, 这种直接计算的方法是可行的. 事实上, 不少统计表上都对 m, n 较小的情况列出了 W 的临界值. 当 m, n 较大时, 直接计算难以施行. 这时, 需要求助于 W 的极限分布. 这是本章要讨论的主题. 当然, 对其他秩检验也存在这样的问题.

从直观上看, 没有必要取 R_i 本身的和, 而可以考虑其某一非降函数之和; 选择定义于集 $\{1, 2, \dots, N\} (N = m + n)$ 上的非降函数 $a_N(\cdot)$ 常称之为“计分函数”), 而令

$$S = \sum_{i=1}^n a_N(R_i) \quad (3.9)$$

然后取 $\{S > C\}$ 或 $\{S > C_2\} \cup \{S < C_1\}$ 为 $a = 0$ 的否定域. 在历史上, 不同的作者曾考虑不同的选择 $a_N(\cdot)$, 因而有关的检验有时也冠以他们的名字, 例如:

Fisher-Yates 检验: $a_N(i) = E(\xi_{N_i}) (i = 1, \dots, N)$. 此处 $\xi_{N_1} \leq \dots \leq \xi_{N_N}$ 是 $N(0, 1)$ 中抽出的次序样本, 这个检验是 Fisher 和 Yates 在文献[67]中提出的, 他们给出了当 $N \leq 50$ 时 $E(\xi_{N_i})$ 的表, 1952 年 Terry 在文献[162]中讨论了这个问题.

检验.

Van der Waerden 检验:

$$a_N(i) = \Phi^{-1}\left(\frac{i}{N+1}\right), \quad i = 1, \dots, N.$$

此处 Φ^{-1} 是标准正态分布函数 Φ 的反函数. 这个检验是 Van der Waerden 在文献[164]中提出的.

以上这两个检验是一类检验的特例. 设 $Q(x)$ 为一维分布函数, 在区间 $\{x: 0 < Q(x) < 1\}$ 内连续严增. 取

$$a_N(i) = Q^{-1}\left(\frac{i}{N+1}\right)$$

或

$$a_N(i) = E(\xi_{N_i}),$$

其中 $\xi_{N_1} \leq \dots \leq \xi_{N_N}$ 是从分布 Q 中抽出的次序样本. 它们分别称为“ Q 的分位计分”(quantile Q scores) 和“ Q 的期望计分”(expected Q scores).

为什么要考虑 $a_N(\cdot)$ 的种种不同的选择呢? 这是因为: 针对不同的总体分布 F , 为使检验取得更好的效果, 要相应地选择适当的计分函数 $a_N(\cdot)$. 例如, 以后 (见例 4.3) 将指出: 若 F 为正态, 则在一定意义下, Fisher-Yates 和 Van der Waerden 检验是最好的选择. 又如, 若 F 为“轻尾”(light-tailed) 分布, 即其尾部概率很小, 则在选择 $a_N(\cdot)$ 时, 强调极端值的作用更有利 (就是说, $a_N(i)$ 在 i 很小和很大时的变化速度应比当 i 取中间值时大一些), 比方说, 取

$$a_N(i) = \begin{cases} i - (N+1)/4, & 1 \leq i \leq (N+1)/4; \\ 0, & (N+1)/4 < i < 3(N+1)/4; \\ i - 3(N+1)/4, & 3(N+1)/4 \leq i \leq N. \end{cases} \quad (3.10)$$

而当 F 为“厚尾”(heavy-tailed) 分布时, 则应降低极端值的作用. 比方说, 取

$$a_N(i) = \begin{cases} -(N+1)/4, & 1 \leq i \leq (N+1)/4; \\ i - (N+1)/2, & (N+1)/4 < i < 3(N+1)/4; \\ (N+1)/4, & 3(N+1)/4 \leq i \leq N. \end{cases} \quad (3.11)$$

又如, 根据总体分布 F 可能是右偏或左偏, 在选择 $a_N(\cdot)$ 时强调小值或大值更为有利. 如对右偏分布, 可取

$$a_N(i) = \begin{cases} i - (N+1)/2, & i \leq (N+1)/2; \\ 0, & i > (N+1)/2; \end{cases} \quad (3.12)$$

而对左偏分布则可取

$$a_N(i) = \begin{cases} 0, & i \leq (N+1)/2; \\ i - (N+1)/2, & i > (N+1)/2. \end{cases} \quad (3.13)$$

等.也许有人会问:既然不假定知道 F ,那么又怎样根据上述考虑去选择适当的 $a_N(\cdot)$ 呢?问题在于:虽则在非参数的提法下并不假定 F 已知,但这不等于在任何情况下都对可能的 F 一无所知,在许多情况下,我们诚然对总体分布类型无确切的知识,但根据理论或以往的经验,有相当理由可以认为总体分布可能近似地属于某种类型——如正态类型、右偏类型等.这些知识可用于帮助我们选择 $a_N(\cdot)$.因此,尽管非参数方法的使用不要求对总体分布类型有完全的了解,但这不等于说:当使用非参数方法时,可以不用搜集关于总体分布尽可能多的先验知识.相反,这步工作做得愈充分,所选择的方法就愈有针对性,从而愈有希望作出正确的结论.这一点自然并不限于此处讨论的问题.

在有些情况下,样本数据可用来确定总体分布的性质,以帮助选择适当的 $a_N(\cdot)$.在这种做法下,样本被利用了两次:首先用于决定模型及使用统计方法,其次用于具体的检验.这种性质的方法称为是“自适应”(adaptive)的.

2. 两样本刻度参数检验

设有样本

$$X_1, \dots, X_m \sim F(x), Y_1, \dots, Y_n \sim G(x) = F\left(\frac{x}{b}\right). \quad (3.14)$$

此处 F 和 b 都未知, F 连续,关于 0 对称,或至少其中位数为 0.要检验假设 $H: b = 1$ (或 $H: 0 < b \leq 1$ 也可以).

设对立假设为 $K: b > 1$.注意到 $Y_j \stackrel{d}{=} bX_i$, 由于 F 的中位数为 0, 在 $X_1, \dots, X_m$ 中,大约有半数取正值,另一半数取负值,乘以 $b > 1$ 后,正的那一半更大,而负的那一半更小.由此可知,若仍以 R_j 记 Y_j 的全样本中的秩,则在 $R_1, \dots, R_n$ 中,应以在 1 附近及 N 附近的居多.由这个考虑,选定一个计分函数 $a_N(\cdot)$,满足“两头大中间小”的条件:

$$a_N(1) \geq a_N(2) \geq \dots \geq a_N\left(\left[\frac{N+1}{2}\right]\right) \leq \dots \leq a_N(N-1) \leq a_N(N).$$

按(3.9)式算出秩统计量 S 的值.然后以 $\{S > C\}$ 为否定域.若对立假设为 $K: b \neq 1$,则否定域应取为 $\{S > C_2\} \cup \{S < C_1\}$.所有关于位置参数情况下的讨论在此都适用,因此不再细述,只举几个例子如下:

Mood 检验^[125]:

$$a_N(i) = \left(i - \frac{N+1}{2}\right)^2.$$

Ansary-Bradley 检验^[34]:

$$a_N(i) = \left| i - \frac{N+1}{2} \right|.$$

Copan 检验^[44]: $a_N(i) = E(\xi_{N_i}^2)$, 此处 ξ_{N_i} 的意义与 Fisher-Yates 检验相同.

Klotz 检验^[100]:

$$a_N(i) = \left[\Phi^{-1} \left(\frac{i}{N+1} \right) \right]^2.$$

Siegel-Turkey 检验^[146]:

$$\begin{aligned} a_N(1) &= N, a_N(N) = N-1, a_N(N-1) = N-2, \\ a_N(2) &= N-3, a_N(3) = N-4, a_N(N-2) = N-5, \\ a_N(N-3) &= N-6, a_N(4) = N-7, a_N(5) = N-8, \dots \end{aligned}$$

在以上这些检验中, $a_N(\cdot)$ 的选择都满足 (3.15) 式. 在 Siegel-Turkey 检验中, $a_N(\cdot)$ 的选择有一个有利的特点: 当原假设成立时, S 的分布与 Wilcoxon 秩和统计量的分布一样. 这些不同的选择当然也是为了适应不同的总体分布 F 的情况.

下面通过对称性检验问题来引进所谓“符号秩统计量”(Signed rank statistic).

对称性检验问题: 设有样本 $X_1, \dots, X_N \sim F(x - \theta)$, F 和 θ 都未知, 但假定 F 在 $\mathbb{R}^1$ 上处处连续且关于 0 对称. 要检验假设 $H: \theta = 0$. 这个问题曾在例 2.3 中讨论过.

设对立假设为 $K: \theta > 0$. 如果 K 成立, 则不仅在样本 $X_1, \dots, X_N$ 中, 大于 0 的个数会倾向于偏多, 而且它们在 $\{|X_1|, \dots, |X_N|\}$ 中的秩也倾向于偏大. 所以在这里需要同时考虑每个样本 X_i 的符号及 $|X_i|$ 的秩, 因而产生了符号秩的概念.

定义 3.2 设 $x_1, \dots, x_N$ 都是实数, 且 $|x_1|, \dots, |x_N|$ 互不相同. 记

$$\psi_i = I_{(x_i > 0)},$$

$R_i^+ = |x_i|$ 在 $\{|x_1|, \dots, |x_N|\}$ 中的秩, 则

$$R^+ = (\psi_1 R_1^+, \dots, \psi_n R_n^+)$$

称为 $(x_1, \dots, x_N)$ 的符号秩.

设 $X_1, \dots, X_N \sim F$, F 为一维连续分布, 则以概率 1, $|X_1|, \dots, |X_N|$ 互不相同, 因而按概率 1 可由 $X_1, \dots, X_N$ 决定其符号秩 R^+ , R^+ 称为 $X_1, \dots, X_N$ 符

号秩统计量.这个名词也可用于任何由 R^+ 派生出来的统计量.

定理3.1对 R^+ 不成立:符号秩 R^+ 的分布一般与总体分布 F 有关.但易证明如下的结果:

定理 3.2 若 F 连续且关于 0 对称,则

$$\psi_1, |X_1|, \dots, \psi_N, |X_N|$$

相互独立, $(\psi_1, R_1^+, \dots, \psi_N, R_N^+)$ 的分布,因而 R^+ 的分布,与 F 无关.实际上, $\psi_1, \dots, \psi_N, (R_1^+, \dots, R_N^+)$ 这 $N+1$ 个变量独立, $\psi_i (i=1, \dots, N)$ 取 1, 0 的概率都是 $1/2$, 而 $(R_1^+, \dots, R_N^+)$ 取 $(1, \dots, N)$ 的任一置换的概率都是 $1/(N!)$.

证 首先验证 ψ_i 与 $|X_i|$ 独立:事实上,在 $(0, \infty)$ 内任取 Borel 集 S , 由于分布 F 连续,且关于 0 对称,有

$$P(\psi_i = 1, |X_i| \in S) = P(X_i \in S);$$

$$P(\psi_i = 1) = \frac{1}{2}, \quad P(|X_i| \in S) = 2P(X_i \in S).$$

故

$$P(\psi_i = 1, |X_i| \in S) = P(\psi_i = 1)P(|X_i| \in S).$$

$\psi_i = -1$ 的情况类似处理.这证明了 ψ_i 与 $|X_i|$ 独立.由此即推出定理的全部结论.

由此定理推出:为检验对称性,基于符号秩的检验是一类可取的检验.因为它们的原假设下有“分布无关”性.例如,取

$$W^+ = \sum_{i=1}^N \psi_i R_i^+ \quad (3.16)$$

而以 $\{W^+ > C\}$ 作为否定域(若对立,假设为 $K: \theta \neq 0$, 取 $\{W^+ > C_2\} \cup \{W^+ < C_1\}$ 为否定域).当 N 较小时, C 可以通过直接计算定出,当 N 较大时,则要用极限定理.这个检验称为“一样本 Wilcoxon 检验”或“Wilcoxon 符号秩和检验”.不难看出,它就是例 2.3 中引进的那个检验.

我们也可以直接取诸 $\psi_i R_i^+$ 之和,而先在集 $\{1, \dots, N\}$ 上定义一个非降函数 $a_N(\cdot)$. 令

$$S_N^+ = \sum_{i=1}^N a_N^+(\psi_i R_i^+) = \sum_{i=1}^N \psi_i a_N^+(R_i^+) \quad (\text{约定 } a_N^+(0) = 0). \quad (3.17)$$

然后以 $\{S_N^+ > C\}$ 或 $\{S_N^+ > C_2\} \cup \{S_N^+ < C_1\}$ 为否定域.在文献中提到的重要特例有:

符号检验(Sign test): $a_N^+(i) = 1$.

正态期望计分: $a_N^+(i) = E(|\xi|_{N_i})$. $|\xi|_{N_i}$ 定义为: 从 $N(0, 1)$ 中抽大小为 N 的样本 $Z_1, \dots, Z_N$. 把 $|Z_1|, \dots, |Z_N|$ 由小到大排序, 结果依次记为 $|\xi|_{N_1}, \dots, |\xi|_{N_N}$.

正态分位计分:

$$a_N^+(i) = \Phi^{-1}\left(\frac{1}{2} + \frac{i}{2(N+1)}\right).$$

等. 其他关于轻尾重尾左偏右偏的考虑, 也与两样本情况相似.

3.2 同分布情况下线性秩统计量的渐近正态性

3.2.1 线性秩统计量的初等性质

定义 3.3 设 $X_1, \dots, X_N$ 为样本, R_i 为 X_i 在 $\{X_1, \dots, X_N\}$ 中的秩, 又 $a_N(\cdot)$ 和 $c_N(\cdot)$ 是两个定义在集 $\{1, \dots, N\}$ 上的函数, 则

$$S_N = \sum_{i=1}^N c_N(i) a_N(R_i) \quad (3.18)$$

称为线性秩统计量.

通常称 $a_N(\cdot)$ 为计分函数, 而 $c_N(i)$ ($i = 1, \dots, N$) 为“回归系数”. (3.9) 式定义 S 是线性秩统计量的特例. 在此样本为 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$, 相当于定义 3.3 中的 $(X_1, \dots, X_N)$, 而 $c_N(i) = 0$ 或 1 , 视 $i \leq m$ 与否而定, 在其他的问题中用到形式更为复杂的线性秩统计量.

线性秩统计量是最重要的一类秩统计量. 在常见的统计问题中, 用到的就是这类秩统计量. 本节的目的主要是研究在

$$X_1, \dots, X_N, \dots \text{ 为 iid. 序列, } X_1 \text{ 的分布连续.} \quad (3.19)$$

的条件下, 且当 $N \rightarrow \infty$ 时 S_N 的极限分布. 后面将证明 Hajek 的一个基本定理 (定理 3.6), 并作为其推论, 导出几个易于应用的结果. 在本段中先证明线性秩统计量的几个初等性质. 它们有独立的意义, 并将在下面讨论极限定理时用到.

我们申明: 本节中总假定条件 (3.19) 成立而不再每次都明确交代. 又在本段中固定 N , 因此将 (3.18) 式中 $S_N, a_N(\cdot)$ 和 $c_N(\cdot)$ 的足标 N 略去.

定理 3.3 记

$$\bar{a} = \frac{1}{N} \sum_{i=1}^N a(i), \quad \bar{c} = \frac{1}{N} \sum_{i=1}^N c(i). \quad (3.20)$$

则有

$$E(S) = N\bar{c}\bar{a}, \quad \text{Var}(S) = \frac{1}{N-1} \sum_{i=1}^N (a(i) - \bar{a})^2 \sum_{i=1}^N (c(i) - \bar{c})^2. \quad (3.21)$$

证 根据定理 3.1, 有

$$P(R_i = j) = \frac{1}{N}, \quad i, j = 1, \dots, N; \quad (3.22)$$

$$P(R_i = u, R_j = v) = \frac{1}{N(N-1)}, \quad i, j, u, v = 1, \dots, N, i \neq j, u \neq v. \quad (3.23)$$

由(3.22)式得 $E(a(R_i)) = \bar{a}$, 于是即得(3.21)式的第一式. 又

$$\text{Var}(a(R_i)) = \frac{1}{N} \sum_{j=1}^N a^2(j) - \bar{a}^2 = \frac{1}{N} \sum_{j=1}^N (a(j) - \bar{a})^2;$$

$$\begin{aligned} \text{Cov}(a(R_i), a(R_j)) &= \frac{1}{N(N-1)} \sum_{u \neq v}^N a(u)a(v) - \bar{a}^2 \\ &= -\frac{1}{N(N-1)} \sum_{k=1}^N (a(k) - \bar{a})^2. \end{aligned}$$

由此两式用 $\text{Var}(S) = \sum_{i,j=1}^N c(i)c(j)\text{Cov}(a(R_i), a(R_j))$ 经过初等计算, 即得(3.21)式的第二式.

例 3.1 对 Wilcoxon 秩和统计量 W , 有 $a(i) = i, c(i) = 0$ 或 1 , 视 $i \leq m$ 或否, 有

$$\begin{aligned} \bar{a} &= \frac{N+1}{2}, \quad \bar{c} = \frac{n}{N}, \\ \sum_{i=1}^N (a(i) - \bar{a})^2 &= \frac{N(N^2-1)}{12}, \\ \sum_{i=1}^N (c(i) - \bar{c})^2 &= \frac{mn}{N}. \end{aligned}$$

故有

$$E(W) = \frac{n(N+1)}{2}, \quad \text{Var}(W) = \frac{mn(N+1)}{12}. \quad (3.24)$$

定理 3.4 设以下两条件至少有一个成立:

$$a(i) + a(N+1-i) \text{ 与 } i \text{ 无关}; \quad (3.25)$$

$$c(i) + c(N+1-i) \text{ 与 } i \text{ 无关}. \quad (3.26)$$

则 S 的分布关于其均值 $N\bar{c}\bar{a}$ 对称.

证 设 (3.25) 式成立, 则对 $i = 1, \dots, N$, 有

$$a(i) + a(N+1-i) = 2\bar{a}.$$

故

$$\begin{aligned} S - N\bar{c}\bar{a} &= \sum_{i=1}^N c(i)(a(R_i) - \bar{a}) \\ &= \sum_{i=1}^N c(i)(\bar{a} - a(N+1-R_i)). \end{aligned}$$

由定理 3.1 易见

$$(R_1, \dots, R_N) \stackrel{d}{=} (N+1-R_1, \dots, N+1-R_N),$$

故

$$S - N\bar{c}\bar{a} \stackrel{d}{=} \sum_{i=1}^N c(i)(\bar{a} - a(R_i)) = N\bar{c}\bar{a} - S.$$

这就证明了要证的结果.

例 3.2 对两样本秩统计量 (3.9) 而言, 当 $m = n$ 时, 条件 (3.26) 适合. 对 Wilcoxon 秩和统计量 W , 条件 (3.25) 适合.

定理 3.4 有实际意义. 因为当分布对称时, 造表可以只考虑一端. 这定理可推广为下述形式:

定理 3.5 以 $\mathcal{H}$ 记 $\{1, 2, \dots, N\}$ 的一切置换的集 ($\mathcal{H}$ 共有 $N!$ 个元素). f 为由 $\mathcal{H}$ 到 $\mathcal{H}$ 的一一对应. 设 V 为一个定义在 $\mathcal{H}$ 上的函数, 满足条件

$$V(r) + V(f(r)) = \text{常数 } c, \quad \text{对一切 } r \in \mathcal{H}. \quad (3.27)$$

以 $R = (R_1, \dots, R_N)$ 记 $(X_1, \dots, X_N)$ 的秩统计量, 则 $V(R)$ 的分布关于 $c/2$ 对称. 反过来, 若 $V(R)$ 的分布关于 $c/2$ 对称, 则必存在 $\mathcal{H} \rightarrow \mathcal{H}$ 一变换 f , 使 (3.27) 式成立.

证 充分性由 $V(R) - c/2 = c/2 - V(f(R))$ 及 $R \stackrel{d}{=} f(R)$ 得出.

为证必要性, 任取 $d > 0$ 使

$$P\left(V(R) = \frac{c}{2} + d\right) > 0.$$

由对称性知:

$$P\left(V(R) = \frac{c}{2} - d\right) = P\left(V(R) = \frac{c}{2} + d\right) > 0.$$

因此,两集合

$$\left\{r: V(r) = \frac{c}{2} - d\right\} \text{ 和 } \left\{r: V(r) = \frac{c}{2} + d\right\}$$

所含元素的个数相同. 在这两集之间任意建立一个一一对应, 并对一切可能的 $d > 0$ 都这样作, 则得到 $\mathcal{H}-\mathcal{H}$ 的一个一一对应 f , 满足 (3.27) 式.

不难验证, 定理 3.4 可由本定理推出. 细节留给读者.

例 3.3 考虑样本 (3.3) 式. 记 $N = m + n$. 以 $R_1, \dots, R_N$ 分别记 $X_1, \dots, X_m, Y_1, \dots, Y_n$ 在合样本 $\{X_1, \dots, X_m, Y_1, \dots, Y_n\}$ 中的秩, $R = (R_1, \dots, R_N)$. 定义 $V(R) = \text{med}(R_{m+1}, \dots, R_N) - \text{med}(R_1, \dots, R_m)$ (用 $\text{med}(x_1, \dots, x_k)$ 记 $x_1, \dots, x_k$ 的样本中位数). 若令

$$f(r_1, \dots, r_n) = (N + 1 - r_1, \dots, N + 1 - r_n),$$

则 f 为 $\mathcal{H}-\mathcal{H}$ 一一对应, 且 $V(f(r)) = -V(r)$.

因此, 在 (3.3) 式中的 $a = 0$ 时, $V(R)$ 的分布关于 0 对称.

3.2.2 条件 N, M 与平方可积积分函数

本段的目的是为下面两段提出 Hajek 定理及其若干推论作准备. 所得结果也将用于第 5 章.

定义 3.4 设 $\{\nu_N, N = 1, 2, \dots\}$ 为一串自然数,

$$\lim_{N \rightarrow \infty} \nu_N = \infty.$$

对每个 N 给定了实数集 $A_N = \{a_{N_1}, \dots, a_{N_{\nu_N}}\}$. 记

$$a_N = \frac{1}{\nu_N} \sum_{i=1}^{\nu_N} a_{N_i},$$

$$\mu_{2N}(A) = \frac{1}{\nu_N} \sum_{i=1}^{\nu_N} (a_{N_i} - a_N)^2.$$

若当 $N \rightarrow \infty$ 时,

$$\max_{1 \leq i \leq \nu_N} \frac{(a_{N_i} - a_N)^2}{\mu_{2N}(A)} = O(\nu_N) \quad (3.28)$$

则称 A_N 满足条件 N .

这个条件是 Noether 于 1949 年在文献 [129] 中提出来的. 进一步的讨论见 5.2 节.

例 3.4 满足条件 N 的一个重要例子如下: 对每个自然数 N 定义了自然数 $m_N, n_N, \nu_N = m_N + n_N$. 令 $a_{N_i} = 0$ 或 1 , 视 $i \leq m_N$ 与否而定. 则 A_N 满足条件 N 的充要条件是:

$$\lim_{N \rightarrow \infty} \{\min(m_N, n_N)\} = \infty.$$

又若取 $\nu_N = N, a_{N_i} = i$, 则 A_N 满足条件 N . 这些简单事实的证明留给读者.

定义 3.5 沿用定义 3.4 的记号, 并设对每个 N , 除 A_N 外还给定了另一实数集 $B_N = \{b_{N_1}, \dots, b_{N_{\nu_N}}\}$. b_N 与 $\mu_{2N}(B)$ 的意义类似定义 3.4. 令

$$d_{N_{ij}} = |(a_{N_i} - \bar{a})(b_{N_j} - \bar{b})|, \quad i, j = 1, \dots, \nu_N;$$

$$d_N^2 = \frac{1}{\nu_N} \sum_{i,j=1}^{\nu_N} d_{N_{ij}}^2 = \nu_N \mu_{2N}(A) \mu_{2N}(B).$$

若对任给的 $\epsilon > 0$, 有

$$\sum_{|d_{N_{ij}}| > \epsilon d_N} \frac{d_{N_{ij}}^2}{d_N^2} = o(\nu_N),$$

则称 (A_N, B_N) 满足条件 M (Motoo, 1955 年).

引理 3.1 若 (A_N, B_N) 满足条件 M , 则 A_N 和 B_N 都满足条件 N .

证 用反证法: 设 B_N 不满足条件 N , 则存在 $\epsilon > 0$ 及自然数子序列 $\{N'\}$, 使对每个 N' , 存在 $j = j_{N'}$, 使

$$|b_{N'_j} - \bar{b}_{N'}| \geq 2\epsilon \sqrt{\nu_{N'}} \sqrt{\mu_{2N'}(B)}.$$

由此易见

$$(3.29) \text{ 式左边} \geq 4\epsilon^2 \cdot \sum_{|a_{N'_i} - \bar{a}_{N'}| \geq \frac{1}{2} \sqrt{\mu_{2N'}(A)}} \frac{(a_{N'_i} - \bar{a}_{N'})^2}{\mu_{2N'}(A)}. \quad (3.30)$$

从而易见

$$\sum_{|a_{N'_i} - \bar{a}_{N'}| < \frac{1}{2} \sqrt{\mu_{2N'}(A)}} (a_{N'_i} - \bar{a}_{N'})^2 \leq \frac{1}{4} \nu_{N'} \mu_{2N'}(A),$$

故

$$\sum_{|a_{N'_i} - \bar{a}_{N'}| \geq \frac{1}{2} \sqrt{\mu_{2N'}(A)}} (a_{N'_i} - \bar{a}_{N'})^2 \geq \frac{3}{4} \nu_{N'} \mu_{2N'}(A).$$

以此代入 (3.30) 式, 得

$$(3.29) \text{ 式左边} \geq 3\epsilon^2 \nu_{N'}, \quad \text{对一切 } N'$$

这与 (3.29) 式矛盾, 从而证明了本引理.

本引理的逆不真: 由 A_N 和 B_N 都满足条件 N , 推不出 (A_N, B_N) 满足条件

M. 反例不难举出, 请读者试作.

在实用上, 常见到的线性秩统计量(3.18)式中的计分函数 $a_N(\cdot)$ 常用下述方法确定:

$$a_N(i) = \phi\left(\frac{i}{N+1}\right), \quad i = 1, \dots, N. \quad (3.31)$$

此处 ϕ 为一个定义于 $(0, 1)$ 区间的实函数. 这种 ϕ 也称为记分函数. 一类重要的记分函数有:

定义 3.6 设 ϕ 可表为 $\phi_1 - \phi_2$ 的形式, 其中 ϕ_1 与 ϕ_2 都是 $(0, 1)$ 区间内的非降平方可积实函数, 且 ϕ 在 $(0, 1)$ 内不几乎处处 (Lebesgue 测度) 等于一常数, 则称 ϕ 为一“平方可积计分函数”.

特别, 当 ϕ 本身在 $(0, 1)$ 内非常数、单调 (升或降) 且平方可积时, ϕ 是平方可积计分函数.

例 3.5 不论是用于假设检验或其他统计问题以及考虑其极限分布, 当对线性秩统计量(3.18)式作一线性变换时, 其作用无变化. 因此, 可以把(3.18)式定义的 S_N 与 $e_N S_N + d_N$ 看作是等价的, 此处 $e_N \neq 0$ 和 d_N 都是常数. 由这一观点, 可以把 Wilcoxon 统计量 W (见 3.4 式) 的计分函数视为

$$\phi(u) = u, \quad 0 < u < 1 \quad (3.32)$$

又 Van der Waerden 检验统计量的计分函数为

$$\phi(u) = \Phi^{-1}(u), \quad 0 < u < 1. \quad (3.33)$$

易见(3.32)式与(3.33)式都是平方可积计分函数.

又 Westenberg^[174] 和 Mood^[124] 曾引进一个两样本位置参数检验如下:

设有样本(3.30)式, 记

$$S_N = Y_1, \dots, Y_n \text{ 中大于合样本中位数的个数.} \quad (3.34)$$

若对立假设为 $K: a > 0$ 用((3.3)式的记号), 则以 $\{S_N > C\}$ 为否定域. 不难看出, 统计量(3.34)式可由下述计分函数产生:

$$\phi(u) = 0 \text{ 或 } 1, \quad \text{视 } 0 < u \leq \frac{1}{2} \text{ 或 } \frac{1}{2} < u < 1 \text{ 而定.} \quad (3.35)$$

(3.35)式显然也是平方可积计分函数.

下面的引理很重要:

引理 3.2 设 $A_N = \{a_{N1}, \dots, a_{NN}\}$ 满足条件 N ,

$$B_N = \left\{ \phi\left(\frac{1}{N+1}\right), \dots, \phi\left(\frac{N}{N+1}\right) \right\},$$

ϕ 为平方可积积分函数, 则 (A_N, B_N) 满足条件 M .

系 3.1 B_N 满足条件 N (据引理 3.1).

此引理的证明依赖于下面两个引理:

引理 3.3 设 E 为 $\mathbb{R}^1$ 上的 L 可测集, $t(x), t_n(x) (n = 1, 2, \dots)$ 是 E 上的平方可积函数, 且

$$\begin{aligned}\lim_{n \rightarrow \infty} \int_E t_n^2(x) dx &= \int_E t^2(x) dx, \\ \lim_{n \rightarrow \infty} t_n(x) &= t(x) \text{ a.s. 于 } E \text{ 上.}\end{aligned}$$

则

$$\left. \begin{aligned}\lim_{n \rightarrow \infty} \int_E t_n(x) t(x) dx &= \int_E t^2(x) dx, \\ \lim_{n \rightarrow \infty} \int_E (t_n(x) - t(x))^2 dx &= 0.\end{aligned}\right\} \quad (3.36)$$

证 记 $s_n = t_n t = s_n^+ - s_n^-$, 则易见 $s_n^+ \rightarrow t^2, s_n^- \rightarrow 0$, a.s. 于 E 上. 因而

$$\begin{aligned}\limsup_{n \rightarrow \infty} \left(\int_E s_n^+ dx + \int_E s_n^- dx \right) &= \limsup_{n \rightarrow \infty} \int_E |s_n| dx \\ &\leq \limsup_{n \rightarrow \infty} \left(\int_E t_n^2 dx \int_E t^2 dx \right)^{1/2} \\ &= \int_E t^2 dx < \infty.\end{aligned} \quad (3.37)$$

由此知

$$\limsup_{n \rightarrow \infty} \int_E s_n^+ dx \leq \int_E t^2 dx < \infty.$$

另一方面, 由 Fatou 引理知

$$\liminf_{n \rightarrow \infty} \int_E s_n^+ dx \geq \int_E t^2 dx.$$

故有

$$\lim_{n \rightarrow \infty} \int_E s_n^+ dx = \int_E t^2 dx.$$

将此式与 (3.37) 式结合, 得

$$\lim_{n \rightarrow \infty} \int_E s_n^- dx = 0.$$

于是

$$\int_E t_n t dx = \int_E s_n^+ dx - \int_E s_n^- dx \rightarrow \int_E t^2 dx. \quad (3.38)$$

即(3.36)式的第一式,由(3.38)式及假定

$$\int_E t_n^2 dx \rightarrow \int_E t^2 dx,$$

得

$$\int_E (t_n - t)^2 dx = \int_E t_n^2 dx + \int_E t^2 dx - 2 \int_E t_n t dx \rightarrow 0.$$

引理证毕.

引理 3.4 设 ϕ 为平方可积积分函数,则

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=1}^N \phi^k \left(\frac{i}{N+1} \right) = \int_0^1 \phi^k(u) du, \quad k = 1, 2. \quad (3.39)$$

证 只讨论 $k = 2$ 的情况,因为 $k = 1$ 的情况完全类似.先设 ϕ 在 $(0,1)$ 非降非负,则有

$$\frac{1}{N} \phi^2 \left(\frac{i}{N+1} \right) \leq \int_{i/N}^{(i+1)/N} \phi^2(u) du, \quad i = 1, \dots, N-1;$$

$$\frac{1}{N} \phi^2 \left(\frac{N}{N+1} \right) \leq \frac{N+1}{N} \int_{N/(N+1)}^1 \phi^2(u) du.$$

故若当 $\frac{i-1}{N} \leq u < \frac{i}{N}$ ($i = 1, \dots, N$) 时,

记

$$q_N(u) = \phi \left(\frac{i}{N+1} \right).$$

则

$$\begin{aligned} \int_0^1 q_N^2 du &= \sum_{i=1}^N \frac{1}{N} \phi^2 \left(\frac{i}{N+1} \right) \\ &\leq \int_{1/N}^1 \phi^2(u) du + \frac{N+1}{N} \int_{N/(N+1)}^1 \phi^2(u) du. \end{aligned}$$

当 $N \rightarrow \infty$ 时,上式右边趋于 $\int_0^1 \phi^2 du$. 故

$$\limsup_{n \rightarrow \infty} \int_0^1 q_N^2 du = \int_0^1 \phi^2 du. \quad (3.40)$$

另一方面,因为 ϕ 单调,故只有可列个不连续点.所以

$$q_N(u) \rightarrow \phi(u), \quad \text{a.s.}$$

于 $(0,1)$. 由 Fatou 引理又有

$$\liminf_{N \rightarrow \infty} \int_0^1 q_N^2 du \geq \int_0^1 \phi^2 du.$$

结合(3.40)式即得(3.39)式(当 $k=2$). 易见, 上述证法对 ϕ 在 $(0,1)$ 非负非增平方可积的情况, 只需做适当的修改.

现在考虑一般情况: 由于 ϕ 可表为两个非降平方可积函数的差, 而一个非降平方可积函数可表为两个平方可积函数的差, 其一非负非降, 而另一非负非增. 故 ϕ 可表为 $\pm\phi_1 \pm \phi_2 \pm \phi_3 \pm \phi_4$ 的形式, 其中 $\phi_i (i=1, \dots, 4)$ 都是单调非负平方可积函数. 对每个 ϕ_i , 依照上文由 ϕ 作出 q_N 的方法而作出定义于 $(0,1)$ 的函数 q_{Ni} . (3.39)式($k=2$ 的情况)归结为证明

$$\lim_{N \rightarrow \infty} \int_0^1 \left(\sum_{i=1}^4 \pm q_{Ni} \right)^2 du = \int_0^1 \left(\sum_{i=1}^4 \pm \phi_i \right)^2 du. \quad (3.41)$$

由已证明的部分, 有

$$\lim_{N \rightarrow \infty} \int_0^1 q_{Ni}^2 du = \int_0^1 \phi_i^2 du, \quad i=1, \dots, 4. \quad (3.42)$$

故为证(3.41)式, 只需证

$$\lim_{N \rightarrow \infty} \int_0^1 q_{Ni} q_{Nj} du = \int_0^1 \phi_i \phi_j du, \quad i \neq j. \quad (3.43)$$

前已指出 $q_{Ni}(u) \rightarrow \phi_i(u)$, a.s. 于 $(0,1)$. 结合(3.42)式, 应用引理3.3, 得

$$\lim_{N \rightarrow \infty} \int_0^1 (q_{Ni} - \phi_i)^2 du = 0, \quad i=1, \dots, 4. \quad (3.44)$$

由(3.42)式知存在常数 M^2 , 使对 $i=1, \dots, 4, N=1, 2, \dots$, 有

$$\int_0^1 q_{Ni}^2 du \leq M^2.$$

因此由(3.44)式知当 $N \rightarrow \infty$ 时, 有

$$\begin{aligned} & \left| \int_0^1 q_{Ni} q_{Nj} du - \int_0^1 \phi_i \phi_j du \right| \\ & \leq \int_0^1 |q_{Ni} - \phi_i| \cdot |q_{Nj}| du + \int_0^1 |q_{Nj} - \phi_j| \cdot |\phi_i| du \\ & \leq \left(\int_0^1 (q_{Ni} - \phi_i)^2 du \right)^{1/2} \left(\int_0^1 q_{Nj}^2 du \right)^{1/2} + \left(\int_0^1 |q_{Nj} - \phi_j|^2 du \right)^{1/2} \left(\int_0^1 \phi_i^2 du \right)^{1/2} \\ & \leq M \left\{ \left(\int_0^1 (q_{Ni} - \phi_i)^2 du \right)^{1/2} + \left(\int_0^1 (q_{Nj} - \phi_j)^2 du \right)^{1/2} \right\} \rightarrow 0. \end{aligned}$$

这即证明了(3.43)式, 从而证明了本引理.

注 3.1 由本引理及其证明过程容易推出如下结论: 设 ϕ 为平方可积记分函数. 取定 $a, b, 0 \leq a < b \leq 1$, 记

$$\bar{\phi} = \int_0^1 \phi du, \quad \bar{\phi} = \frac{1}{N} \sum_{i=1}^N \phi\left(\frac{i}{N+1}\right),$$

$$\phi_N(a, b) = \frac{1}{N} \sum_{\{i: a < \phi(\frac{i}{N+1}) < b\}} \left(\phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N \right)^2,$$

则

$$\phi_N(a, b) \rightarrow \int_a^b (\phi(u) - \bar{\phi})^2 du, \quad N \rightarrow \infty.$$

又对任何 $\eta > 0$, 有

$$\{u: |\phi(u) - \bar{\phi}_N| \geq m\} \subset (0, \eta) \cup (1 - \eta, 1) \\ (\text{对一切 } N, \text{ 当 } m \text{ 充分大}).$$

由此立见, 若 $\lim_{N \rightarrow \infty} m_N = \infty$, 则

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{\{i: |\phi(\frac{i}{N+1}) - \bar{\phi}_N| \geq m_N\}} \left(\phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N \right)^2 = 0. \quad (3.45)$$

现在回证引理 3.2: 易见若 e_N, f_N, g_N, h_N 都是常数, $e_N \neq 0 \neq g_N$, 则

$$A_N \text{ 满足条件 } N \Leftrightarrow e_N A_N + (f_N, \dots, f_N) \text{ 满足条件 } N; \quad (3.46)$$

$$(A_N, B_N) \text{ 满足条件 } M \Leftrightarrow (e_N A_N + (f_N, \dots, f_N), g_N B_N \\ + (h_N, \dots, h_N)) \text{ 满足条件 } M. \quad (3.47)$$

不失普遍性可设 $a_N = 0$,

$$\mu_{2N}(A) = \frac{1}{N}, \quad \text{对一切 } N.$$

这时由 A_N 满足条件 N 得

$$a_N^* \triangleq \max_{1 \leq i \leq N} |a_{Ni}| \rightarrow 0, \quad N \rightarrow \infty. \quad (3.48)$$

记

$$b_{Ni} = \phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N, \quad B_N = (b_{N1}, \dots, b_{NN}).$$

由注 3.1, 有

$$\lim_{N \rightarrow \infty} \mu_{2N}(B) = \int_0^1 (\phi(u) - \bar{\phi})^2 du \triangleq h^2, \quad 0 < h < \infty. \quad (3.49)$$

因而 $\lim_{N \rightarrow \infty} d_N^2 = h^2$, 且当 N 充分大时, 有

$$\sum_{\{i: |d_{Nij}| \geq \varepsilon d_N\}} \frac{d_{Nij}^2}{d_N^2} \leq 2h^{-2} \sum_{i=1}^N \{a_{Ni}^2 \sum_{\{j: |b_{Nj}| \geq \varepsilon h / (2a_N^*)\}} b_{Nj}^2\}. \quad (3.50)$$

由 (3.45) 式、(3.48) 式, 知

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{\{j: |b_{Nj}| \geq \varepsilon h / (2a_N^*)\}} b_{Nj}^2 = 0.$$

将此式与 (3.50) 式结合, 并注意到因 $\mu_{2N}(A) = N^{-1}$ 而有

$$\sum_{i=1}^N a_{Ni}^2 = 1,$$

有

$$\sum_{\{|d_{Nij}| \geq \varepsilon d_N\}} \frac{d_{Nij}^2}{d_N^2} \leq 2h^{-2} o(N) \sum_{i=1}^N a_{Ni}^2 = o(N).$$

即(3.29)式. 这就证明了引理 3.2.

3.3.3 Hajek 的基本定理

本段的目的是证明下面的重要定理.

定理 3.6^[77] 设条件(3.19)式成立, $R_{N1}, \dots, R_{NN}$ 分别是 $X_1, \dots, X_N$ 在 $\{X_1, \dots, X_N\}$ 中的秩. 而

$$S_N = \sum_{i=1}^N c_N(i) a_N(R_{Ni}).$$

记 $\lambda_N = E(S_N)$, $\sigma_N^2 = \text{Var}(S_N)$, $L_N = (S_N - \lambda_N)/\sigma_N$. 又

$$A_N = \{a_N(1), \dots, a_N(N)\},$$

$$C_N = \{c_N(1), \dots, c_N(N)\}, \quad N = 1, 2, \dots.$$

若 A_N, C_N 都满足条件 N , 则

$$L_N = \frac{S_N - \lambda_N}{\sigma_N} \xrightarrow{\mathcal{L}} N(0, 1) \quad (3.51)$$

成立的充要条件是: (A_N, C_N) 满足条件 M .

证明基于下面几个引理.

引理 3.5 设有常数 $a_1 \leq a_2 \leq \dots \leq a_N$, 定义 $(0, 1]$ 上的函数

$$a(\lambda) = a_i, \quad \frac{i-1}{N} < \lambda \leq \frac{i}{N}, \quad i = 1, \dots, N.$$

又设 $U_1, \dots, U_N \sim R(0, 1)$, 用 $U_{(1)} \leq \dots \leq U_{(N)}$ 记 $U_1, \dots, U_N$ 的次序统计量, R_i 为 U_i 在 $\{U_1, \dots, U_N\}$ 中的秩. 则

$$E \left\{ a(U_1) - a\left(\frac{R_1}{N}\right) \right\}^2 \leq 2 \max_{1 \leq i \leq N} |a_i - \bar{a}| \cdot \frac{1}{N} \left\{ 2 \sum_{i=1}^N (a_i - \bar{a})^2 \right\}^{1/2}. \quad (3.52)$$

证 在给定 $U_{(1)}, \dots, U_{(N)}$ 的条件下, $U_1 = U_{(i)}$ 即 $R_1 = i$ 的条件概率为 $\frac{1}{N}$ ($i = 1, \dots, N$). 于是有

$$\begin{aligned} E\left\{a(U_1) - a\left(\frac{R_1}{N}\right)\right\}^2 &= E\left[E\left\{\left(a(U_1) - a\left(\frac{R_1}{N}\right)\right)^2 \mid U_{(1)}, \dots, U_{(N)}\right\}\right] \\ &= \frac{1}{N} \sum_{i=1}^N E\left\{a(U_{(i)}) - a\left(\frac{i}{N}\right)\right\}^2. \end{aligned} \quad (3.53)$$

下面分三种情况来讨论:

1° 存在自然数 $m \leq N$, 使

$$a_1 = \dots = a_m = 0, \quad a_{m+1} = \dots = a_N = 1.$$

令 $\epsilon(\lambda) = I_{(\lambda > 0)}$, 则与此 $\{a_i\}$ 相应的函数

$$a(\lambda) = \epsilon\left(\lambda - \frac{m}{N}\right).$$

而 $\tilde{m}$ 记 $U_1, \dots, U_N$ 中小于 m/N 的个数, 则 $\tilde{m}$ 服从二项分布 $B(N, m/N)$, 且

$$U_{(\tilde{m})} < \frac{m}{N} < U_{(\tilde{m}+1)}.$$

易见

$$\sum_{i=1}^N \left\{ \epsilon\left(U_{(i)} - \frac{m}{N}\right) - \epsilon\left(\frac{i-m}{N}\right) \right\}^2 = |\tilde{m} - m|. \quad (3.54)$$

由(3.53)式、(3.54)式得

$$\frac{1}{N} E|\tilde{m} - m| = E\left\{a(U_1) - a\left(\frac{R_1}{N}\right)\right\}^2$$

再注意

$$E^2|\tilde{m} - m| \leq E(\tilde{m} - m)^2 = m\left(1 - \frac{m}{N}\right),$$

故得

$$\begin{aligned} E\left\{a(U_1) - a\left(\frac{R_1}{N}\right)\right\}^2 &= E\left\{\epsilon\left(U_1 - \frac{m}{N}\right) - \epsilon\left(\frac{R_1 - m}{N}\right)\right\}^2 \\ &\leq \frac{1}{N} \left(m\left(1 - \frac{m}{N}\right)\right)^{1/2} \end{aligned} \quad (3.55)$$

易见, 由(3.55)式得出(3.52)式.

2° $a_1 = 0$. 这时有

$$a(\lambda) = \sum_{m=1}^{N-1} (a_{m+1} - a_m) \epsilon\left(\lambda - \frac{m}{N}\right).$$

再注意 $a_i = a\left(\frac{i}{N}\right)$, 有

$$\sum_{i=1}^N a_i^2 = \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) \sum_{i=1}^N \epsilon\left(\frac{i-m}{N}\right) \epsilon\left(\frac{i-j}{N}\right)$$

$$= \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j)(N - \max(m, j)). \quad (3.56)$$

又

$$\left\{ a(U_{(i)}) - a\left(\frac{i}{N}\right) \right\}^2 = \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) \left(\epsilon\left(U_{(i)} - \frac{m}{N}\right) - \epsilon\left(\frac{i-m}{N}\right) \right) \left(\epsilon\left(U_{(i)} - \frac{j}{N}\right) - \epsilon\left(\frac{i-j}{N}\right) \right). \quad (3.57)$$

由于 $\epsilon(\lambda)$ 只取 0 与 1 两个值, 有

$$\begin{aligned} & \left(\epsilon\left(U_{(i)} - \frac{m}{N}\right) - \epsilon\left(\frac{i-m}{N}\right) \right) \left(\epsilon\left(U_{(i)} - \frac{j}{N}\right) - \epsilon\left(\frac{i-j}{N}\right) \right) \\ & \leq \left(\epsilon\left(U_{(i)} - \frac{\max(m, j)}{N}\right) - \epsilon\left(\frac{i - \max(m, j)}{N}\right) \right)^2. \end{aligned} \quad (3.58)$$

由 (3.55) 式、(3.57) 式、(3.58) 式得

$$\begin{aligned} E\left\{ a(U_1) - a\left(\frac{R_1}{N}\right) \right\}^2 &= \frac{1}{N} \sum_{i=1}^N E\left\{ a(U_{(i)}) - a\left(\frac{i}{N}\right) \right\}^2 \\ &\leq \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) \frac{1}{N} \\ &\quad \times E\left\{ \sum_{i=1}^N \left(\epsilon\left(U_{(i)} - \frac{\max(m, j)}{N}\right) - \epsilon\left(\frac{i - \max(m, j)}{N}\right) \right)^2 \right\} \\ &= \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) \\ &\quad \times E\left\{ \epsilon\left(U_i - \frac{\max(m, j)}{N}\right) - \epsilon\left(\frac{R_i - \max(m, j)}{N}\right) \right\}^2 \\ &\leq \frac{1}{N} \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) \\ &\quad \times \left(\max(m, j) \frac{N - \max(m, j)}{N} \right)^{1/2} \\ &\leq \frac{1}{N} \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j)(N - \max(m, j))^{1/2} \\ &\leq \frac{1}{N} \left\{ \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) \right. \\ &\quad \times \left. \sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j)(N - \max(m, j)) \right\}^{1/2}, \end{aligned} \quad (3.59)$$

又

$$\sum_{m=1}^{N-1} \sum_{j=1}^{N-1} (a_{m+1} - a_m)(a_{j+1} - a_j) = (a_N - a_1)^2 = a_N^2. \quad (3.60)$$

由(3.56)式、(3.59)式、(3.60)式得

$$E \left\{ a(U_1) - a \left(\frac{R_1}{N} \right) \right\}^2 \leq \frac{a_N}{N} \left(\sum_{i=1}^N a_i^2 \right)^{1/2}. \quad (3.61)$$

(3.61)式是在 $a_1 = 0$ 的条件下获得的.若 $a_1 \neq 0$,以 $a_i - a_1$ 代 a_i .这一代替不影响(3.61)式左边,故得

$$E \left\{ a(U_1) - a \left(\frac{R_1}{N} \right) \right\}^2 \leq \frac{1}{N} (a_N - a_1) \left\{ \sum_{i=1}^N (a_i - a_1)^2 \right\}^{1/2}. \quad (3.62)$$

将(3.62)式用于数列 $-a_N \leq \dots \leq -a_1$,这相当于以 $-a(1-\lambda)$ 代替 $a(\lambda)$.由于 $U \sim R(0,1) \Rightarrow 1-U \sim R(0,1)$,这一代替不影响(3.62)式左边.故有

$$E \left\{ a(U_1) - a \left(\frac{R_1}{N} \right) \right\}^2 \leq \frac{1}{N} (a_N - a_1) \left\{ \sum_{i=1}^N (a_i - a_N)^2 \right\}^{1/2}. \quad (3.63)$$

3° 现考虑一般的 $a(\lambda)$.令

$$a^+(\lambda) = \max(a(\lambda), \bar{a}), \quad a^-(\lambda) = \min(a(\lambda) - \bar{a}, 0).$$

则 $a^\pm(\lambda)$ 皆在 $(0,1]$ 内非降,且

$$a(\lambda) = a^+(\lambda) + a^-(\lambda).$$

故由(3.62)式、(3.63)式得

$$\begin{aligned} E \left\{ a(U_1) - a \left(\frac{R_1}{N} \right) \right\}^2 &\leq 2E \left\{ a^+(\lambda) - a^+ \left(\frac{R_1}{N} \right) \right\}^2 + 2E \left\{ a^-(\lambda) - a^- \left(\frac{R_1}{N} \right) \right\}^2 \\ &\leq 2(a_N - \bar{a}) \frac{1}{N} \left(\sum_{a_i > \bar{a}} (a_i - \bar{a})^2 \right)^{1/2} \\ &\quad + 2(\bar{a} - a_1) \frac{1}{N} \left(\sum_{a_i < \bar{a}} (a_i - \bar{a})^2 \right)^{1/2} \\ &\leq 2 \max_{1 \leq i \leq N} |a_i - \bar{a}| \frac{1}{N} \left\{ 2 \sum_{i=1}^N (a_i - \bar{a})^2 \right\}^{1/2}. \end{aligned}$$

引理证毕.

下一引理是弱极限理论中的周知结果:

引理 3.6 设对每个 $N = 1, 2, \dots$ 给出独立变量 $\xi_{N1}, \dots, \xi_{NN}$,满足条件

$$E(\xi_{N1}) = \dots = E(\xi_{NN}) = 0, \quad \sum_{i=1}^N \text{Var}(\xi_{Ni}) = \sum_{i=1}^N \sigma_{Ni}^2 = 1.$$

则

$$\max_{1 \leq i \leq N} \sigma_{N_i}^2 \rightarrow 0, \quad \sum_{i=1}^N \xi_{N_i} \xrightarrow{\mathcal{L}} N(0, 1) \quad (3.64)$$

同时成立的充要条件为:对任给的 $\epsilon > 0$, 有

$$\lim_{N \rightarrow \infty} \sum_{i=1}^N \int_{|x| > \epsilon} x^2 dF_{N_i}(x) = 0. \quad (3.65)$$

此处 F_{N_i} 为 ξ_{N_i} 的分布函数.

证明见文献[115] 中第 295 页.

定理 3.6 的证明 因为将 $a_N(i)$ 和 $c_N(i)$ 分别用 $e_N a_N(i) + f_N$ 和 $g_N c_N(i) + h_N$ 代替 ($e_N \neq 0 \neq g_N$) 时, (3.51) 式定义的 L_N 不变. 故不失普遍性, 可设

$$\bar{a}_N = \frac{1}{N} \sum_{i=1}^N a_N(i) = 0, \quad \bar{c}_N = \frac{1}{N} \sum_{i=1}^N c_N(i) = 0, \\ \sum_{i=1}^N a_N^2(i) = N, \quad \sum_{i=1}^N c_N^2(i) = 1, \quad a_N(1) \leq \cdots \leq a_N(N). \quad (3.66)$$

用 $a_N(1), \dots, a_N(N)$ 造出的函数 (相当于引理 3.5 中由 $a_1 \leq \cdots \leq a_N$ 造出的 $a(\lambda)$) 记为 $a_N^*(\lambda)$. 改以 $R_{N_i}^*$ 记 U_i 在 $\{U_1, \dots, U_N\}$ 中的秩 (U_i 见引理 3.5). 则易见

$$L_N \stackrel{d}{=} \sum_{i=1}^N c_N(i) a_N^*\left(\frac{R_{N_i}^*}{N}\right).$$

记

$$T_N = \sum_{i=1}^N c_N(i) a_N^*(U_i). \quad (3.67)$$

现证

$$\lim_{N \rightarrow \infty} E(L_N - T_N)^2 = 0. \quad (3.68)$$

有

$$L_N - T_N = \sum_{i=1}^N c_N(i) \left\{ a_N^*\left(\frac{R_{N_i}^*}{N}\right) - a_N^*\left(\frac{U_{(R_{N_i}^*)}}{N}\right) \right\}^2.$$

易见 $(R_{N_1}^*, \dots, R_{N_N}^*)$ 与 $(U_{(1)}, \dots, U_{(N)})$ 独立, 根据 (3.21) 式、(3.66) 式, 得

$$\begin{aligned} E\{(L_N - T_N)^2 \mid U_{(1)}, \dots, U_{(N)}\} &= \text{Var}\{L_N - T_N \mid U_{(1)}, \dots, U_{(N)}\} \\ &= \frac{1}{N-1} \sum_{i=1}^N \left\{ a_N^*(U_{(i)}) - a_N^*\left(\frac{i}{N}\right) \right\}^2 \\ &= \frac{1}{N-1} \sum_{i=1}^N \left\{ a_N^*(U_i) - a_N^*\left(\frac{R_{N_i}^*}{N}\right) \right\}^2. \end{aligned}$$

由此得

$$\begin{aligned} E(L_N - T_N)^2 &= \frac{1}{N-1} \sum_{i=1}^N E\left(a_N^*(U_i) - a_N^*\left(\frac{R_{Ni}^*}{N}\right)\right)^2 \\ &= \frac{N}{N-1} E\left(a_N^*(U_1) - a_N^*\left(\frac{R_{N1}^*}{N}\right)\right)^2. \end{aligned}$$

应用(3.52)式,并注意(3.66)式,得

$$\begin{aligned} E(L_N - T_N)^2 &\leq \frac{N}{N-1} 2 \max_{1 \leq i \leq N} |a_N(i)| \frac{1}{N} \sqrt{2N} \\ &\leq 6 \max_{1 \leq i \leq N} |a_N(i)| / \sqrt{N}. \end{aligned} \quad (3.69)$$

由 $\{a_N(1), \dots, a_N(N)\}$ 满足条件 N ,又由(3.66)式知当 $N \rightarrow \infty$ 时,(3.69)式的右边趋于0,于是证明了(3.68)式.

由(3.68)式知 $L_N \xrightarrow{\mathcal{L}} N(0,1)$ 与 $T_N \xrightarrow{\mathcal{L}} N(0,1)$ 等价. T_N 为独立和,由(3.66)式易见其各项的均值为0,各项方差之和

$$\sum_{i=1}^N \sigma_{Ni}^2 = \sum_{i=1}^N \text{Var}(c_N(i) a_N^*(U_i)) = 1,$$

且由 $\{c_N(1), \dots, c_N(N)\}$ 满足条件 N 及(3.66)式,易见

$$\max_{1 \leq i \leq N} \sigma_{Ni}^2 = \max_{1 \leq i \leq N} c_N^2(i) \rightarrow 0, \quad N \rightarrow \infty.$$

以 F_{Ni} 记 $c_N(i) a_N^*(U_i)$ 的分布,根据引理3.6,得

$$\begin{aligned} T_N \xrightarrow{\mathcal{L}} N(0,1) &\Leftrightarrow \sum_{i=1}^N \int_{|x| > \varepsilon} x^2 dF_{Ni}(x) \\ &= \sum_{\{a_N^2(i) c_N^2(j) \geq \varepsilon^2\}} a_N^2(i) c_N^2(j) \rightarrow 0. \end{aligned}$$

由于

$$d_N^2 = \frac{1}{N} \sum_{i,j=1}^N a_N^2(i) c_N^2(j) = 1.$$

知上式右边等价于 (A_N, C_N) 满足条件 M (A_N, C_N 见定理3.6的陈述).这就完成了定理3.6的证明.

注3.2 由于仅由 A_N 和 C_N 都满足条件 N 还推不出 (A_N, C_N) 满足条件 M ,故定理3.6的充分性部分的条件下不能减弱为只要求 A_N 和 C_N 满足条件 N .事实上,陈希孺在文献[5]中曾证明了:在 A_N 和 C_N 都满足条件 N 时,(3.51)式定义的 L_N 可以没有极限分布,而其一切可能的极限分布类与方差有界时的无穷可分分布类重合.

定理3.6可用于确定大样本秩检验的临界值.

例 3.6 对 Wilcoxon 两样本秩和检验统计量 W 而言, 只要两样本的大小 m, n 都趋于 ∞ , 则定理 3.6 的条件是适合的. 由此定理并注意到 (3.24) 式即得: 当原假设成立时, 有

$$\left(W - \frac{n(m+n+1)}{2}\right) / \sqrt{\frac{mn(m+n+1)}{12}} \xrightarrow{\mathcal{L}} N(0,1) \quad (3.70)$$

用 (3.3) 式的记号, 当对立假设为 $\alpha > 0$ 时, 取否定域为

$$W > \frac{n(m+n+1)}{2} + u_{\alpha} \sqrt{\frac{mn(m+n+1)}{12}}. \quad (3.71)$$

若对立假设为 $\alpha \neq 0$, 则取否定域为

$$\left|W - \frac{n(m+n+1)}{2}\right| > u_{\frac{\alpha}{2}} \sqrt{\frac{mn(m+n+1)}{12}}, \quad (3.72)$$

当 m, n 都 $\rightarrow \infty$ 时, 这些检验有渐近水平 α .

3.2.4 Hajek 定理的推论和推广

在定理 3.6 中关于“ (A_N, C_N) 满足条件 M ”一事验证不便, 而常见的线性秩统计量中的计分函数常有 (3.31) 式形式, 故下述定理有重要意义.

定理 3.7 设线性秩统计量 (3.18) 式中的 $a_N(i)$ 由 (3.31) 式确定. ϕ 为平方可积计分函数. 又假定 $C_N = \{c_N(1), \dots, c_N(N)\}$ 满足条件 N , 则 (3.51) 式成立.

证 由定理 3.6 及引理 3.2 即得出.

另一类与 (3.31) 式有密切关系的计分函数由下式给出:

$$a_N(i) = E\phi(U_{(i)}), \quad i = 1, \dots, N, \quad (3.73)$$

此处 $U_{(1)} \leq \dots \leq U_{(N)}$ 为 $R(0,1)$ 中抽出的次序样本, 而 ϕ 为平方可积计分函数.

定理 3.8 设线性秩统计量 (3.18) 中的 $a_N(i)$ 由 (3.73) 式给出, ϕ 为平方可积计分函数, 而 C_N 满足条件 N , 则 (3.51) 式成立.

证 记

$$S_N^* = \sum_{i=1}^N c_N(i) \phi\left(\frac{R_i}{N+1}\right),$$

$$\lambda_N^* = E(S_N^*), \quad (\sigma_N^*)^2 = \text{Var}(S_N^*).$$

由 (3.21) 式有

$$\begin{aligned} E\{(S_N - \lambda_N) - (S_N^* - \lambda_N^*)\}^2 &= \text{Var}(S_N - S_N^*) \\ &\leq \frac{1}{N-1} \sum_{i=1}^N (c_N(i) - \bar{c}_N)^2 \sum_{i=1}^N \left\{ \phi\left(\frac{i}{N+1}\right) - E\phi(U_{(i)}) \right\}^2, \end{aligned}$$

故

$$\begin{aligned} E\{(S_N - \lambda_N) - (S_N^* - \lambda_N^*)\}^2 / \text{Var}(S_N^*) \\ \leq \sum_{i=1}^N \left\{ \phi\left(\frac{i}{N+1}\right) - E\phi(U_{(i)}) \right\}^2 / \sum_{i=1}^N \left\{ \phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N \right\}^2 \quad (3.74) \end{aligned}$$

$\bar{\phi}_N$ 的定义见注 3.1. 根据引理 2.1 及引理 3.4, 由 (3.74) 式知: 为证本定理, 只需证明

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=1}^N \left\{ \phi\left(\frac{i}{N+1}\right) - E\phi(U_{(i)}) \right\}^2 = 0. \quad (3.75)$$

为此注意

$$\begin{aligned} \frac{1}{N} \sum_{i=1}^N \left\{ \phi\left(\frac{i}{N+1}\right) - E\phi(U_{(i)}) \right\}^2 &\leq \frac{1}{N} \sum_{i=1}^N E \left\{ \phi\left(\frac{i}{N+1}\right) - \phi(U_{(i)}) \right\}^2 \\ &= \frac{1}{N} \sum_{i=1}^N E \left\{ \left(\phi\left(\frac{R_1}{N+1}\right) - \phi(U_1) \right)^2 \mid R_1 = i \right\} \\ &= E \left\{ \left(\phi\left(\frac{R_1}{N+1}\right) - \phi(U_1) \right)^2 \right\}, \quad (3.76) \end{aligned}$$

先设 ϕ 在 $(0, 1)$ 非降. 定义函数 ϕ_1 :

$$\phi_1(u) = \phi\left(\frac{i}{N+1}\right), \quad \frac{i-1}{N} < u \leq \frac{i}{N}, i = 1, \dots, N.$$

注意到 R_1 只取 $1, \dots, N$ 为值, 有

$$\phi\left(\frac{R_1}{N+1}\right) = \phi_1\left(\frac{R_1}{N+1}\right).$$

于是

$$E \left\{ \phi\left(\frac{R_1}{N+1}\right) - \phi(U_1) \right\}^2 = E \left\{ \phi_1\left(\frac{R_1}{N+1}\right) - \phi_1(U_1) + \phi_1(U_1) - \phi(u_1) \right\}^2. \quad (3.77)$$

由 (3.52) 式, 得

$$\begin{aligned} E \left\{ \phi_1\left(\frac{R_1}{N+1}\right) - \phi_1(U_1) \right\}^2 &\leq 4 \max_{1 \leq i \leq N} \left| \phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N \right| \\ &\quad \times \frac{1}{N} \left(\sum_{i=1}^N \left(\phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N \right)^2 \right)^{\frac{1}{2}}. \quad (3.78) \end{aligned}$$

根据引理 3.4 及注 3.1, 有

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=1}^N \left(\phi \left(\frac{i}{N+1} \right) - \bar{\phi}_N \right)^2 = \int_0^1 (\phi(u) - \bar{\phi})^2 du < \infty,$$

$$\bar{\phi}_N \rightarrow \bar{\phi} = \int_0^1 \phi(u) du$$

有限. 故为证当 $N \rightarrow \infty$ 时, (3.78) 式的右端趋于 0, 只需证

$$\max_{1 \leq i \leq N} \phi^2 \left(\frac{i}{N+1} \right) / N \rightarrow 0.$$

由于 ϕ 在 $(0, 1)$ 内非降, 这等价于

$$\phi^2 \left(\frac{1}{N+1} \right) / N \rightarrow 0,$$

$$\phi^2 \left(\frac{N}{N+1} \right) / N \rightarrow 0.$$

此两式显然是 ϕ 在 $(0, 1)$ 非降且平方可积的推论. 这即证明了当 $N \rightarrow \infty$ 时, (3.78) 式的右边趋于 0, 故

$$\lim_{N \rightarrow \infty} E \left\{ \phi_1 \left(\frac{R_1}{N+1} \right) - \phi_1(U_1) \right\}^2 = 0. \quad (3.79)$$

由 (3.76)、(3.77)、(3.79) 式可知, 为证 (3.75) 式, 只需证

$$\lim_{N \rightarrow \infty} E \{ \phi(U_1) - \phi_1(U_1) \}^2 = 0, \quad (3.80)$$

有

$$\begin{aligned} \int_0^\epsilon (\phi(u) - \phi_1(u))^2 du &\leq 2 \int_0^\epsilon \phi^2(u) du + 2 \int_0^\epsilon \phi_1^2(u) du \\ &\leq 2 \int_0^\epsilon \phi^2(u) du + 2 \sum_{(i, (i-1)/N \leq \epsilon)} \phi^2 \left(\frac{i}{N+1} \right) / N \\ &\rightarrow 2 \int_0^\epsilon \phi^2(u) du + 2 \int_0^\epsilon \phi^2(u) du \\ &= 4 \int_0^\epsilon \phi^2(u) du, \quad N \rightarrow \infty. \end{aligned}$$

同样考虑区间 $(1-\epsilon, 1)$, 得

$$\begin{aligned} \limsup_{N \rightarrow \infty} \left\{ \int_0^\epsilon (\phi(u) - \phi_1(u))^2 du + \int_{1-\epsilon}^1 (\phi(u) - \phi_1(u))^2 du \right\} \\ \leq 4 \left\{ \int_0^\epsilon \phi^2(u) du + \int_{1-\epsilon}^1 \phi^2(u) du \right\} \rightarrow 0, \quad \epsilon \rightarrow 0. \end{aligned} \quad (3.81)$$

又在区间 $[\epsilon, 1-\epsilon]$ 内 $\phi(u) - \phi_1(u)$ 有界. 且

$$\phi(u) - \phi_1(u) \rightarrow 0, \text{ a.s. },$$

因而

$$\lim_{N \rightarrow \infty} \int_{\varepsilon}^{1-\varepsilon} \{\phi(u) - \phi_1(u)\}^2 du = 0.$$

将此式与(3.81)式结合,得

$$\lim_{N \rightarrow \infty} \int_0^1 \{\phi(u) - \phi_1(u)\}^2 du = 0, \text{ 即(3.80)式.}$$

这就在 ϕ 于 $(0,1)$ 内非降的情况下证明了本定理. 对于一般情况, ϕ 可表为 $\phi_1 - \phi_2$, ϕ_1, ϕ_2 都在 $(0,1)$ 非降且平方可积, 故由已证明的

$$\lim_{N \rightarrow \infty} E \left\{ \phi \left(\frac{R_1}{N+1} \right) - \phi_i(U_1) \right\}^2 = 0, \quad i = 1, 2$$

即得

$$\lim_{N \rightarrow \infty} E \left\{ \phi \left(\frac{R_1}{N+1} \right) - \phi(U_1) \right\}^2 = 0,$$

从而在一般情况下证明了本定理.

注 3.3 根据引理 2.1, 本定理的结论也可写为

$$\frac{S_N - \lambda_N}{\sigma_N^*} \xrightarrow{\mathcal{L}} N(0, 1) \quad (3.82)$$

σ_N^* 的定义在本定理证明开始时已给出. 这个形式比较方便, 因为 σ_N^* 的计算比 σ_N 容易.

进一步可以问, 在(3.82)式的左边能否将 $\lambda_N (= E(S_N))$ 换为 $\lambda_N^* (= E(S_N^*))$? 留给读者验证下述简单事实: 只要

$$\left\{ N | \bar{c}_N | / \sqrt{\sum_{i=1}^N (c_N(i) - \bar{c}_N)^2} \right\}$$

有界, 这样做是可以的.

例 3.7 考虑 3.1 节中给出的 Van der Waerden 统计量和 Fisher-Yates 统计量. 它们分别相应于 $a_N(i)$ 由(3.31)式和(3.73)式给出的情况, 而 ϕ 是 $N(0,1)$ 分布的反函数 Φ^{-1} . 不难验证, 这个 ϕ 为平方可积积分函数

$$\sum_{i=1}^N \phi \left(\frac{i}{N+1} \right) = 0 = \sum_{i=1}^N E \phi(U_{(i)}),$$

又

$$\frac{1}{N} \sum_{i=1}^N \phi^2 \left(\frac{i}{N+1} \right) \rightarrow \int_0^1 \phi^2 du = 1.$$

应用定理 3.7 及 3.8 得出: 若两样本大小分别为 m, n , 又记 $N = m + n$, 则在

$\min(m, n) \rightarrow \infty$ 时, 在原假设成立(即(3.3)式中的 $a = 0$) 之下有

$$S_N / \sqrt{\frac{mn}{N}} \xrightarrow{\mathcal{L}} N(0, 1) \quad (3.83)$$

此处 S_N 为 Var der Waerden 或 Fisher-Yates 统计量都可以. 一如例 3.6, (3.83) 式可用于确定大样本 Van der Waerden 或 Fisher-Yates 检验的临界值.

有时需要同时考虑几个线性秩统计量. 对此可将定理 3.6 推广为下面的定理.

定理 3.9 设有 m 个形如(3.18)式的线性秩统计量

$$S_{N_k} = \sum_{i=1}^N c_{N_k}(i) a_N(R_i), \quad k = 1, \dots, m.$$

记 $A_N = \{a_N(1), \dots, a_N(N)\}$, $C_{N_k} = \{c_{N_k}(1), \dots, c_{N_k}(N)\}$ ($k = 1, \dots, m$). 记 $S_{N_k}^* = (S_{N_k} - \lambda_{N_k}) / \sigma_{N_k}$, 此处 $\lambda_{N_k}, \sigma_{N_k}^2$ 分别是 S_{N_k} 的均值方差. 又令

$$c_{N_k}^*(i) = \frac{c_{N_k}(i) - \bar{c}_{N_k}}{\sqrt{N\mu_{2N}(c_k)}},$$

$$\bar{c}_{N_k} = \frac{1}{N} \sum_{i=1}^N c_{N_k}(i),$$

$$\mu_{2N}(c_k) = \frac{1}{N} \sum_{i=1}^N (c_{N_k}(i) - \bar{c}_{N_k})^2.$$

假定:

1° (A_N, C_{N_k}) 满足条件 $M(k = 1, \dots, m)$;

2° 对任何 $r, s = 1, \dots, m$, $\lambda_{rs} = \lim_{N \rightarrow \infty} \sum_{i=1}^N c_{N_r}^*(i) c_{N_s}^*(i)$ 存在, 且方阵 $\mathbf{A} = (\lambda_{rs})_1^m$ 满秩.

则当 $N \rightarrow \infty$ 时, 有

$$S_N^* \triangleq (S_{N_1}^*, \dots, S_{N_m}^*) \xrightarrow{\mathcal{L}} N(0, \mathbf{A}).$$

$N(0, \mathbf{A})$ 表示均值为 0, 协方差阵为 $\mathbf{A}$ 的 m 维正态分布.

证 不失普遍性, 可设

$$\bar{c}_{N_k} = 0, \quad \mu_{2N}(c_k) = \frac{1}{N}, \quad k = 1, \dots, m$$

以及

$$\sum_{i=1}^N a_N(i) = 0, \quad \sum_{i=1}^N a_N^2(i) = N - 1.$$

这时有 $S_{N_k}^* = S_{N_k}$, 还需要下述引理:

引理 3.7 设有一串 m 维随机向量 $\xi_n (n = 1, 2, \dots)$, 则

$$\xi_n \xrightarrow{\mathcal{L}} N(0, \Lambda)$$

的充要条件为: 对任何 m 维常向量 b , 有

$$b' \xi_n \xrightarrow{\mathcal{L}} N(0, b' \Lambda b).$$

证明由特征函数的极限定理即得出. 事实上, 有

$$\{b' \xi_n \xrightarrow{\mathcal{L}} N(0, b' \Lambda b) \text{ 对任何 } b\} \Leftrightarrow E(e^{itb' \xi_n}) \rightarrow e^{-b' \Lambda b t^2 / 2}$$

$$(\text{对任何 } b, t) \Leftrightarrow E(e^{ia' \xi_n}) \rightarrow e^{-a' \Lambda a / 2} (\text{对任何 } a)$$

$$\Leftrightarrow \xi_n \xrightarrow{\mathcal{L}} N(0, \Lambda)$$

根据这个引理, 为证定理 3.9, 只需对任意的 m 维常向量 $b' = (b_1, \dots, b_m)$, 证明

$$b' S_N^* \xrightarrow{\mathcal{L}} N(0, b' \Lambda b).$$

但

$$b' S_N^* = \sum_{i=1}^N c_N(i) a_N(R_i),$$

其中

$$c_N(i) = \sum_{k=1}^m b_k c_{N_k}(i).$$

记

$$C_N = \{c_N(1), \dots, c_N(N)\}.$$

只需证明:

$$(A_N, C_N) \text{ 满足条件 } M. \quad (3.84)$$

事实上, 若 (3.84) 式已证, 则根据定理 3.6 知

$$\frac{b' S_N^*}{\sigma_N} \xrightarrow{\mathcal{L}} N(0, 1),$$

此处

$$\begin{aligned} \sigma_N^2 &= \sum_{i=1}^N c_N^2(i) \\ &= \sum_{r,s=1}^m \left(\sum_{i=1}^N c_{N_r}(i) c_{N_s}(i) \right) b_r b_s \longrightarrow \sum_{r,s=1}^m \lambda_{rs} b_r b_s = b' \Lambda b, \end{aligned}$$

因而 $\mathbf{b}'\mathbf{S}_N^* \xrightarrow{\mathcal{L}} N(0, \mathbf{b}'\mathbf{A}\mathbf{b})$. 依引理 3.7, 这就证明了定理 3.9.

现在证(3.84)式. 依(3.47)式, 不失普遍性, 可设

$$\|\mathbf{b}\|^2 = \sum_{k=1}^m b_k^2 = 1.$$

记

$$\mathbf{d}_{Ni} = (c_{N1}(i), \dots, c_{Nm}(i))', \quad i = 1, \dots, N,$$

则由条件 2°, 方阵 $\mathbf{A}$ 是非负定方阵 $\sum_{i=1}^N \mathbf{d}_{Ni} \mathbf{d}_{Ni}'$ 当 $N \rightarrow \infty$ 时的极限, 故 $\mathbf{A}$ 为非负定. 又因 $\mathbf{A}$ 满秩, 故 $\mathbf{A}$ 为正定. 因此, $\mathbf{b}'\mathbf{A}\mathbf{b}$ 在单位球面上有大于 0 的下界与有限的上界. 再由

$$\sum_{i=1}^N c_N^2(i) \rightarrow \mathbf{b}'\mathbf{A}\mathbf{b}$$

知存在常数 Q_1, Q_2 ($0 < Q_1 \leq Q_2 < \infty$), 使当 N 充分大时, 有

$$Q_1 \leq \sum_{i=1}^N c_N^2(i) \leq Q_2.$$

再注意

$$\bar{a}_N = 0 \quad \text{及} \quad \sum_{i=1}^N a_N^2(i) = N - 1,$$

即知为证(3.84)式只需证明对任给的 $\epsilon > 0$, 有

$$\lim_{N \rightarrow \infty} \sum_{((i,j), |a_N(i)c_N(j)| \geq \epsilon/\sqrt{N})} a_N^2(i) c_N^2(j) = 0. \quad (3.85)$$

因为

$$a_N(i) c_N(j) = \sum_{k=1}^m a_N(i) b_k c_{N_k}(j),$$

对每组满足条件

$$|a_N(i) c_N(j)| \geq \frac{\epsilon}{\sqrt{N}} \quad (3.86)$$

的 (i, j) , 集 $H_{ij} = \{k: |a_N(i) b_k c_{N_k}(j)| \geq \epsilon_1 \sqrt{N}\}$ 非空, 此处 $\epsilon_1 = \epsilon/m$. 由于

$$\begin{aligned} \sum_{k \in H_{ij}} (a_N(i) b_k c_{N_k}(j))^2 &\leq \frac{(m-1)\epsilon_1^2}{N} \\ &\leq (m-1) \sum_{k \in H_{ij}} (a_N(i) b_k c_{N_k}(j))^2 \end{aligned}$$

知对每组满足条件(3.86)的 (i, j) 有

$$\begin{aligned} a_{N^2}(i) c_{N^2}(j) &\leq m \sum_{k=1}^m a_{N^2}(i) b_k^2 c_{N_k^2}(j) \\ &\leq m^2 \sum_{k \in H_{ij}} a_{N^2}(i) c_{N_k^2}(j) \end{aligned}$$

(这里用了 $\|b\| = 1$, 因而 $|b_k| \leq 1$) 因而(3.85)式左边的极限号下的量不超过

$$m^2 \sum_{k=1}^m \sum_{((i,j), |a_{N^2}(i) c_{N_k^2}(j)| \geq \varepsilon_1 \sqrt{N})} a_{N^2}(i) c_{N_k^2}(j). \quad (3.87)$$

由本定理条件1'知, 当 $N \rightarrow \infty$ 时表达式(3.87)趋于0. 这即证明了(3.85)式, 从而证明了(3.84)式. 定理证毕.

注 3.4 在实际应用时, 可使用形式

$$S_N^* \sim N(0, \Lambda_N) \quad (3.88)$$

即以 $N(0, \Lambda_N)$ 为 S_N^* 的近似分布. 此处 Λ_N 为一个 m 阶方阵, 其 (r, s) 元

$$\text{为 } \sum_{i=1}^N c_{N_r}^*(i) c_{N_s}^*(i).$$

例 3.8 给定自然数 m, N 表为 m 个自然数 $n_1, \dots, n_m$ 之和. 设

$$a_N(i) = \phi\left(\frac{i}{N+1}\right), \quad i = 1, \dots, N, \phi \text{ 为平方可积积分函数}, \quad (3.89)$$

而(约定当 $k = 1$ 时, $n_1 + \dots + n_{k-1} = 0$.)

$$C_{N_k}(i) = \begin{cases} 1, & i = n_1 + \dots + n_{k-1} + 1, \dots, n_1 + \dots + n_k; \\ 0, & \text{其他的 } i \leq N. \end{cases} \quad (3.90)$$

则易见

$$\lambda_{N_{rs}} \triangleq \sum_{i=1}^N c_{N_r}^*(i) c_{N_s}^*(i) = \begin{cases} 1, & r = s; \\ -\left(\frac{n_r n_s}{(N - n_r)(N - n_s)}\right)^{1/2}, & r \neq s. \end{cases} \quad (3.91)$$

设

$$\lim_{N \rightarrow \infty} \frac{n_r}{N} = \rho_r > 0, \quad r = 1, \dots, m. \quad (3.92)$$

则由(3.91)式得

$$\lambda_{rs} = \lim_{N \rightarrow \infty} \lambda_{N_{rs}} = \begin{cases} 1, & r = s; \\ -\sqrt{\frac{\rho_r \rho_s}{(1 - \rho_r)(1 - \rho_s)}}, & r \neq s. \end{cases} \quad (3.93)$$

下面证 $\Lambda = (\lambda_{rs})^{m-1}$ 为满秩方阵. 事实上, $\Lambda = B - uu'$, 此处 B 为对角阵

$$\text{diag}\left(\frac{1}{1-\rho_1}, \dots, \frac{1}{1-\rho_{m-1}}\right),$$

$$u = \left(\sqrt{\frac{\rho_1}{1-\rho_1}}, \dots, \sqrt{\frac{\rho_{m-1}}{1-\rho_{m-1}}}\right).$$

易见

$$1 - u' B^{-1} u = 1 - (\rho_1 + \dots + \rho_{m-1}) = \rho_m > 0.$$

故由文献[135]中第33页的2.8题知

$$A^{-1} = B^{-1} + \frac{dd'}{\rho_m}, \quad d' = (\sqrt{\rho_1(1-\rho_1)}, \dots, \sqrt{\rho_{m-1}(1-\rho_{m-1})}) \quad (3.94)$$

由(3.89)、(3.90)式,用公式(3.21),经过初等计算,得

$$S_{Nk} = \sum_{i=n_1+\dots+n_{k-1}+1}^{n_1+\dots+n_k} \phi\left(\frac{R_i}{N+1}\right) \quad (3.95)$$

$$\lambda_k \triangleq E(S_{Nk}) = n_k \bar{\phi}_N, \quad \sigma_{Nk}^2 \triangleq \text{Var}(S_{Nk}) = \frac{n_k(N-n_k)}{N(N-1)} D_{N\#}, \quad (3.96)$$

其中

$$\bar{\phi}_N = \frac{1}{N} \sum_{i=1}^N \phi\left(\frac{i}{N+1}\right), \quad D_{N\#} = \sum_{i=1}^N \left(\phi\left(\frac{i}{N+1}\right) - \bar{\phi}_N\right)^2. \quad (3.97)$$

记

$$L_N = \left(\frac{S_{N1} - \lambda_1}{\sigma_{N1}}, \dots, \frac{S_{N,m-1} - \lambda_{m-1}}{\sigma_{N,m-1}}\right)', \quad (3.98)$$

由定理3.9知,当 $N \rightarrow \infty$ 时,有

$$L_N \xrightarrow{\mathcal{L}} N(0, \Lambda),$$

或写为

$$L_N \approx N(0, \Lambda_N). \quad (3.99)$$

Λ_N 为 $m-1$ 阶方阵 (λ_{Nrs}) ($r, s = 1, \dots, m-1$). λ_{Nrs} 由(3.91)式确定.

由(3.99)式得知,若以 χ_{m-1}^2 记自由度 $m-1$ 的 χ^2 分布,则

$$L_N' \Lambda_N^{-1} L_N \xrightarrow{\mathcal{L}} \chi_{m-1}^2, \quad N \rightarrow \infty. \quad (3.100)$$

Λ_N^{-1} 显然是由在 Λ^{-1} 的表达式中将 ρ_k 换为 n_k/N 而得到,这只要比较(3.91)式和(3.93)式就可以看出.由 Λ_N^{-1} 的这个表达式并注意(3.95)~(3.98)式,经过简单的代数运算,不难得到

$$L_N' \Lambda_N^{-1} L_N = (N-1) \sum_{k=1}^m n_k \frac{\left(\frac{S_{Nk}}{n_k} - \bar{\phi}_N\right)^2}{D_{N\#}} \xrightarrow{\mathcal{L}} \chi_{m-1}^2. \quad (3.101)$$

这个结果对多样本问题的秩检验很有用(参看 4.4 节).

特别,对 $\phi(u) = u$ 的情况,有

$$\bar{\phi}_N = \frac{1}{2}, \quad D_{N\phi}' = \frac{N^3 - N}{12}.$$

记

$$R_k^* = \sum_{i=n_1+\dots+n_{k-1}+1}^{n_1+\dots+n_k} \frac{R_i}{n_k}, \quad (3.102)$$

而(3.101)式有形状

$$\frac{12}{N(N+1)} \sum_{k=1}^m n_k \left(R_k^* - \frac{N+1}{2} \right)^2 \xrightarrow{\mathcal{L}} \chi_{m-1}^2. \quad (3.103)$$

(3.103) 式左边的统计量常称为 Kruskal-Wallis 统计量. 参看文献 [106] 和 [107].

3.2.5 符号秩统计量

设 $X_1, \dots, X_N \sim F$, F 为关于 0 对称的一维连续分布. $\psi_i, R_i^+ (i = 1, \dots, N)$ 在定义 3.2 中已给出. 设 $a_N^+(\cdot)$ 为记分函数. 考虑由 (3.17) 式定义的线性符号秩统计量 S_N^+ , 易证下面的定理:

定理 3.10 设 $\{a_N^+(1), \dots, a_N^+(N)\}$ 满足条件 N , 则当 $N \rightarrow \infty$ 时, 有

$$\left(S_N^+ - \frac{N}{2} \bar{a}_N^+ \right) / \sqrt{\frac{1}{4} A_N} \xrightarrow{\mathcal{L}} N(0, 1). \quad (3.104)$$

此处

$$\bar{a}_N^+ = \frac{1}{N} \sum_{i=1}^N a_N^+(i), \quad A_N = \sum_{i=1}^N a_N^{+2}(i). \quad (3.105)$$

证 据定理 3.2, $\psi_1, \dots, \psi_N$ 与 $(R_1^+, \dots, R_N^+)$ 独立, 且 $\psi_1, \dots, \psi_N$ 为 iid., ψ_i 的分布为

$$P(\psi_1 = 0) = P(\psi_1 = 1) = \frac{1}{2}.$$

故对 $(1, \dots, N)$ 的任一置换

$$(i_1, \dots, i_N), \quad (\Psi_{i_1}, \dots, \Psi_{i_N}) \stackrel{d}{=} (\Psi_1, \dots, \Psi_N).$$

由此即得

$$S_N^+ \stackrel{d}{=} \sum_{i=1}^N a_N^+(i) \psi_i. \quad (3.106)$$

根据 Liapunov 定理, 要证(3.104) 式, 只需证明

$$\lim_{N \rightarrow \infty} \sum_{i=1}^N \mathbb{E} \left| a_N^+(i) \psi_1 - \frac{1}{2} a_N^+(i) \right|^3 / \left(\frac{1}{4} A_N \right)^{3/2} = 0. \quad (3.107)$$

为此注意

$$\begin{aligned} & \sum_{i=1}^N \mathbb{E} \left| a_N^+(i) \psi_i - \frac{1}{2} a_N^+(i) \right|^3 / \left(\frac{A_N}{4} \right)^{3/2} \\ &= \sum_{i=1}^N |a_N^+(i)|^3 A_N^{-3/2} \leq (\max_{1 \leq i \leq N} a_N^{+2}(i))^{1/2} A_N^{-1/2}. \end{aligned} \quad (3.108)$$

因为

$$\max_{1 \leq i \leq N} a_N^{+2}(i) \leq 2 \max_{1 \leq i \leq N} \{a_N^+(i) - \bar{a}_N^+\}^2 + 2\bar{a}_N^{+2},$$

$$A_N = N\bar{a}_N^{+2} + \sum_{i=1}^N \{a_N^+(i) - \bar{a}_N^+\}^2,$$

有

$$(\max_{1 \leq i \leq N} a_N^{+2}(i))^{1/2} A_N^{-1/2} \leq 2 \left\{ \max_{1 \leq i \leq N} \{a_N^+(i) - \bar{a}_N^+\}^2 / \sum_{i=1}^N \{a_N^+(i) - \bar{a}_N^+\}^2 \right\}^{1/2} + \sqrt{\frac{2}{N}}.$$

由 $\{a_N^+(1), \dots, a_N^+(N)\}$ 满足条件 N 知, 上式右边当 $N \rightarrow \infty$ 时趋于 0. 从而证明了(3.107) 式, 因而即证明了本定理.

例 3.9 对符号检验统计量, 有

$$a_N^+(1) = \dots = a_N^+(N) = 1.$$

这时(3.104) 式成为

$$\left(S_N^+ - \frac{N}{2} \right) / \sqrt{\frac{N}{4}} \xrightarrow{\mathcal{L}} N(0, 1) \quad (3.109)$$

对 Wilcoxon 符号秩和检验统计量(3.16), 有 $a_N^+(i) = i$. 这时(3.104) 式成为

$$\left(S_N^+ - \frac{N(N+1)}{4} \right) / \sqrt{\frac{1}{24} N(N+1)(2N+1)} \xrightarrow{\mathcal{L}} N(0, 1). \quad (3.110)$$

在结束这一节之前, 我们略提一下这样一个问题: 本节所得出的极限定理其精确程度如何? 以定理 3.6 来说, (3.51) 式中的统计量 L_N 分布函数记为 $P(L_N < x) = G_N(x)$. 问 $|G_N(x) - \Phi(x)|$ 能大到多少? 这自然与 $a_N(i)$ 和 $c_N(i)$ ($i = 1, \dots, N$) 有关. 这种问题能否在理论上取得一般性的有用结果? 难于预估. 但 L_N 是一个离散型分布, 当 N 不太大时 (例如, $N \leq 30$), 借助于计算机, 不难直接算出一些 L_N 的分布, 拿它和 $\Phi(x)$ 比较, 可以使我们对这种逼近的精度得到一些概念. 因为若在 N 较小时, 逼近还可以, 故在 N 较大时肯定不错.

对 Wilcoxon 统计量 W 的情况, Lehmann 的专著^[112] 中有所介绍(文献 [112] 中第 14~18, 40~41 页及其所引文献). 现引述其中若干数字结果. 以 m 、 n 记两组样本的大小, $N = m + n$. 当 $\min(m, n) \rightarrow \infty$ 时, 有(参看(3.24)式, 例 3.4 及定理 3.6)

$$P(W \leq c) \approx \Phi \left(\frac{c - \frac{n(N+1)}{2}}{\sqrt{\frac{mn(N+1)}{12}}} \right). \quad (3.111)$$

因为 W 只取正整数值, 可以对(3.111)式作下述连续性修正:

$$P(W \leq c) \approx \Phi \left(\frac{c - \frac{n(N+1)}{2} + \frac{1}{2}}{\sqrt{\frac{mn(N+1)}{12}}} \right). \quad (3.112)$$

对几组 m, n , $P(W \leq c)$ 的真值以及由(3.111)、(3.112)式所确定的近似值如下表 3.1 所示.

表 3.1

 $m = 3, n = 6$

c	6	7	8	9	10
确值	0.012	0.024	0.048	0.083	0.131
(111)	0.010	0.019	0.035	0.061	0.098
(112)	0.014	0.026	0.047	0.078	0.123

 $m = 4, n = 12$

c	13	15	20	23	25
确值	0.004	0.010	0.052	0.106	0.158
(111)	0.005	0.011	0.045	0.091	0.138
(112)	0.006	0.012	0.051	0.102	0.151

 $m = n = 8$

c	44	46	48	52	56
确值	0.005	0.010	0.019	0.052	0.117
(111)	0.006	0.010	0.018	0.047	0.104
(112)	0.007	0.012	0.020	0.052	0.114

由这些数字结果可看出: 即使 m, n 都较小, 用(3.112)式逼近的结果总的还是

令人满意的.一般说来,(3.112)式优于未作修正的(3.111)式,但在 W 取两端值时,情况却未必如此.所得结果使我们有理由相信:对两样本线性统计量(3.9)式而言,若 $\{a_N(i), i = 1, \dots, N\}$ 的性状与 $\{1, \dots, N\}$ 大体相似(例如 $a_N(i) = \phi(i/(N+1))$, ϕ 在 $(0,1)$ 单调有界)且两样本大小 m, n 相差不甚大时,正态逼近在实用上是可行的.

3.3 不同分布情况下线性秩统计量的渐近正态性

设 $Z_1, \dots, Z_N$ 为独立样本,假定它们的分布都连续,因而可假定它们的值总是两两不同.以 R_i 记 Z_i 在 $\{Z_1, \dots, Z_N\}$ 中的秩,按定义3.3作成线性秩统计量 S_N 如(3.18)式.若 $Z_1, \dots, Z_N$ 同分布,则 $(R_1, \dots, R_N)$ 的分布如定理3.1所示.这个分布不仅与 Z_i 的分布无关,且形式甚简单.因此,在这种情况下, S_N 的极限分布问题还不太复杂.这在3.2节中已作了仔细论述.

在秩检验的理论和应用中,有时需要考虑在 $Z_1, \dots, Z_N$ 不同分布的条件下, S_N 的极限分布问题.这主要是为了估计或比较秩检验的功效.这种问题涉及在对立假设之下.亦即在 $Z_1, \dots, Z_N$ 不同分布时 S_N 的分布.当考虑大样本性质时,就涉及 S_N 的极限分布问题.

当 $Z_1, \dots, Z_N$ 不同分布时, $(R_1, \dots, R_N)$ 的分布依赖于 $Z_1, \dots, Z_N$ 的分布,且形式很复杂.因此,即使在比较简单的情况下(例如在两样本问题中,这时 $Z_1, \dots, Z_N$ 的分布只有两个不同的), S_N 的极限分布问题也很困难.当然,在某些特例中,例如 S_N 等价于一个 U 统计量的情形(Wilcoxon统计量 W 是一个例子,见例2.9),问题不难解决.但是,只是在Chernoff和Savage的工作^[46]发表后,这方面的研究才有了突破性的进展.他们的工作只涉及两样本情况,其后在1968年,在Hajek在一项重要工作^[79]中考虑了较一般的情况.从20世纪60年代以来,大体上可以说,直到在线性秩统计量的极限理论问题在文献中经历了一个较活跃的时期.一部分工作是上述工作在具体情况下的应用或推广改进性质的;另一些工作则将问题提法引向深入,如讨论正态逼近的收敛速度和渐近展开

等. 总的来说, 后一类型工作的统计意义已不显著.

本节中要介绍在不同分布情况下, 线性秩统计量渐近正态性的若干结果, 主要是 Chernoff 和 Savage 的工作. 在此只叙述结果而不作仔细证明. 因为严格的证明很繁冗, 要占据很多的篇幅. 对这方面的论述有兴趣的读者, 可查阅前面提到的 Chernoff 和 Savage、Hajek 等的原始论文. 也可以参考文献[3]的 6.3 节, 其中对 Chernoff 等的工作作了仔细的介绍, 并在个别地方作了发挥.

3.3.1 Chernoff-Savage 定理的简单形式

设有样本

$$(Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n),$$

此处 $X_1, \dots, X_m$ 取自总体分布 F ; $Y_1, \dots, Y_n$ 取自总体分布 G , 而 $X_1, \dots, Y_n$ 全体独立. F 和 G 都是一维分布函数, 都在区间 $(-\infty, \infty)$ 内处处连续.

仍以 R_i 记 Z_i 在 $(Z_1, \dots, Z_N)$ 中的秩 ($i = 1, \dots, N$). 又设函数 $\phi(u)$ 定义于 $0 < u < 1$. 考虑统计量

$$S_N = \frac{1}{m} \sum_{i=1}^m \phi\left(\frac{R_i}{N+1}\right), \quad (3.113)$$

也可以考虑统计量

$$T_N = \frac{1}{n} \sum_{i=1}^n \phi\left(\frac{R_{m+i}}{N+1}\right).$$

因为

$$mS_N + nT_N = \sum_{i=1}^N \phi\left(\frac{i}{N+1}\right)$$

为常数, 两者在本质上无区别, 记 $\lambda_N = m/N$,

$$H_N(x) = \lambda_N F(x) + (1 - \lambda_N) G(x),$$

而

$$\mu_N = \int_{-\infty}^{\infty} \phi(H_N(x)) dF(x), \quad (3.114)$$

$$\sigma_N^2 = 2(1 - \lambda_N) \left\{ \sigma_{N_1}^2 + \frac{1 - \lambda_N}{\lambda_N} \sigma_{N_2}^2 \right\}. \quad (3.115)$$

其中

$$\begin{aligned} \sigma_{N_1}^2 = & \iint_{-\infty < x < y < \infty} G(x)(1 - G(y)) \phi'(H_N(x)) \\ & \times \phi'(H_N(y)) dF(x) dF(y), \end{aligned} \quad (3.116)$$

$$\sigma_{N2}^2 = \iint_{-\infty < x < y < \infty} F(x)(1-F(y))\phi'(H_N(x)) \times \phi'(H_N(y))dG(x)dG(y). \quad (3.117)$$

定理 3.11 设以下条件成立.

1° 存在 $\lambda_0 > 0$, 使 $\lambda_0 \leq \lambda_N \leq 1 - \lambda_0$, 对一切 N ;

2° $\phi(u)$ 在任何闭区间 $[a, b] \subset (0, 1)$ 上绝对连续, 且存在常数 K 及 $\delta > 0$, 使对 $i = 0, 1$, 有

$$|\phi^{(i)}(u)| \leq K\{u(1-u)\}^{-i-1/2+\delta}, \text{ a.s., } 0 < u < 1. \quad (3.118)$$

此处 $\phi^{(i)}$ 表 ϕ 的 i 阶导数, 而 $\phi^{(0)} = \phi$.

3° 存在 $\eta > 0$, 使对一切 N , 有 $\max(\sigma_{N1}^2, \sigma_{N2}^2) \geq \eta$, 则当 $N \rightarrow \infty$ 时, 有

$$\frac{\sqrt{N}(S_N - \mu_N)}{\sigma_N} \xrightarrow{\mathcal{L}} N(0, 1). \quad (3.119)$$

对这个定理现作以下几点说明: a) μ_N 和 σ_N^2/N 一般并非 S_N 的均值方差, 虽然在许多常见情况下相差不多. 可以证明: 在一定条件下, 可以分别用 $E(S_N)$ 和 $\sqrt{N\text{Var}(S_N)}$ 代替 (3.119) 式中的 μ_N 和 σ_N ; b) 不难证明, 在定理的条件 1°、2° 之下, σ_{N1}^2 和 σ_{N2}^2 都存在有限并非负; c) Chernoff 和 Savage 在其工作^[46] 中假定了 $\phi^{(2)}(u)$ 在 $0 < 1$ 处处存在, 且 (3.118) 式对 $i = 0, 1, 2$ 成立. 此处经过改进的条件 2° 是 Govindarajulu 等的工作^[74].

定理证明的基本思想, 就是前面在证明 U 统计量的渐近正态性时所交代的, 即将 S_N 分解为两部分, 一部分是一个独立和, 其渐近正态性可用通常的中心极限定理去处理 ((3.119) 式中的 μ_N 及 σ_N^2/N , 就是这个独立和的均值方差); 另一部分是余项. 证明的关键在于验证这后一部分当 $N \rightarrow \infty$ 时可忽略不计. 然而, 与 U 统计量的情况不同, 在此余项的处理甚为复杂.

本定理的条件 2° 对一些常见的情况都能适合. 例如, 对 'Wilcoxon 统计量有 $\phi(u) = u$, 当然适合 2° 对 Van der Waerden 统计量有 $\phi(u) = \Phi^{-1}(u)$. 这函数也满足条件 2°. 在文献 [3] 的例 6.3.1 中给出了这个事实的证明.

3.3.2 Chernoff-Savage 定理的一般形式

在一般情况下, S_N 有

$$S_N = \frac{1}{m} \sum_{i=1}^m \phi_N\left(\frac{R_i}{N+1}\right) \quad (3.120)$$

的形式, 这里 $\phi_N(u)$ 定义在 $0 < u < 1$ 内, 如果只给出了

$$\phi_N\left(\frac{i}{N+1}\right), \quad i = 1, \dots, N$$

的值,则可任意将其扩充到整个 \$(0,1)\$ 区间上.

定理 3.12 设存在定义于 \$(0,1)\$ 的函数 \$\phi\$, 使

$$1^\circ \lim_{N \rightarrow \infty} \phi_N(u) = \phi(u), \text{ 对一切 } u \in (0,1);$$

2° 当 \$N \rightarrow \infty\$ 时,

$$\frac{1}{\sqrt{N}} \sum_{i=1}^m \left\{ \phi_N\left(\frac{R_i}{N+1}\right) - \phi\left(\frac{R_i}{N+1}\right) \right\} \xrightarrow{p} 0;$$

3° 定理 3.11 的条件 \$1^\circ \sim 3^\circ\$ 都满足.

则 (3.119) 式仍成立.

在应用上最重要的一种情况是

$$\phi_N(u) = \begin{cases} E(\xi_{N_i}), & \frac{i-1}{N+1} < u \leq \frac{i}{N+1}, \quad i = 1, \dots, N \\ E(\xi_{N_N}), & \frac{N}{N+1} < u < 1. \end{cases} \quad (3.121)$$

此处 \$\xi_{N_1} \leq \dots \leq \xi_{N_N}\$ 为从一分布 \$Q\$ 抽出的 iid. 样本的次序统计量. 设 \$Q\$ 在 \$\mathbb{R}^1\$ 处处连续, 且在区间 \$\{x: 0 < Q(x) < 1\}\$ 上严格上升, 因而可在 \$0 < u < 1\$ 定义 \$Q\$ 的反函数 \$\phi(u) = Q^{-1}(u)\$, \$\phi\$ 在 \$(0,1)\$ 连续严格上升.

注意: 有

$$\phi_N\left(\frac{i}{N+1}\right) = E\phi(U_{(i)}),$$

其中 \$U_{(1)} \leq \dots \leq U_{(N)}\$ 是 \$R(0,1)\$ 中抽出的 iid. 样本的次序统计量. 因此, (3.120) 式无非就是在定理 3.8 中讨论过的那种线性秩统计量.

定理 3.13 若 \$Q\$ 满足上文指出的条件, 则:

$$1^\circ \lim_{N \rightarrow \infty} \phi_N(u) = \phi(u), \text{ 对一切 } u \in (0,1) \text{ (注意: } \phi_N \text{ 由 (3.121) 式定义而 } \phi = Q^{-1} \text{)};$$

2° 若对 \$i = 1, 2, \dots, \phi = Q^{-1}\$ 满足 (3.118) 式, 则 \$\phi\$ 必满足定理 3.12 的条件 2°.

例如, Fisher-Yates 统计量相当于 \$\phi = \Phi^{-1}\$ 的情况. 在 3.3.1 小节末尾处曾指出, 此函数满足 (3.118) 式. 因此, 结合定理 3.12 和定理 3.13 可知, 在对立假设下 Fisher-Yates 统计量也保持渐近正态性.

3.3.3 收敛的一致性

在 2.2.3 小节中曾指出: 在讨论检验的渐近相对效率问题时, 要求在总体分

布属于一定范围 $\mathcal{F}$ 内时, 有关统计量收敛于正态分布相对于 $\mathcal{F}$ 的一致性. 在这里考虑的情况下, 可以把 (F, G) 看作为总体分布. 注意: 这时 (3.114) ~ (3.117) 诸式定义的量都与 (F, G) 有关, 因此更清楚地应写为 $\mu_N(F, G)$ 等等. 但为了书写简单计, 仍保持原记号.

定理 3.14 设 $\mathcal{F}$ 为分布偶 (F, G) 的一个族, 满足以下条件:

- 1° 定理 3.11 的条件 3° 对一切 $(F, G) \in \mathcal{F}$ 成立, 且 $\eta > 0$ 与 (F, G) 无关;
2° 存在定义于 $(0, 1)$ 的函数 ϕ , 满足 (3.118) 式 ($i = 1, 2$), 使

$$\lim_{N \rightarrow \infty} \phi_N(u) = \phi(u)$$

对一切 $u \in (0, 1)$ 成立, 且定理 3.12 的条件 2° 在 $\mathcal{F}$ 上一致成立, 即: 对任给的 $\epsilon > 0$, 有

$$\lim_{N \rightarrow \infty} \left\{ \sup_{(F, G) \in \mathcal{F}} P_{F, G} \left(\left| \frac{1}{\sqrt{N}} \sum_{i=1}^m \left(\phi_N \left(\frac{R_i}{N+1} \right) - \phi \left(\frac{R_i}{N+1} \right) \right) \right| \geq \epsilon \right) \right\} = 0; \quad (3.122)$$

3° 存在 $\lambda_0 > 0$, 使

$$\lambda_0 \leq \lambda_N \leq 1 - \lambda_0, \quad N = 1, 2, \dots.$$

以 $J_{N, F, G}(x)$ 记 (3.119) 式左边量的分布函数, 其中 S_N 由 (3.120) 式定义, 则当 $N \rightarrow \infty$ 时, 有

$$\sup_{(F, G) \in \mathcal{F}} \|J_{N, F, G} - \Phi\| \rightarrow 0. \quad (3.123)$$

如果 S_N 由 (3.113) 式定义 (其中 ϕ 满足定理 3.11 的条件), 则本定理的条件 2° 自然满足. 另一满足条件 2° 的重要情况是 $\phi_N(u)$ 由 (3.121) 式给定的情况: 只要定理 3.13 的条件满足, 则本定理 2° 的条件满足. 这是因为在证明定理 3.13 的 2° 时, 证明了

$$\left| \frac{1}{\sqrt{N}} \sum_{i=1}^m \left(\phi_N \left(\frac{R_i}{N+1} \right) - \phi \left(\frac{R_i}{N+1} \right) \right) \right| \leq \frac{1}{\sqrt{N}} \sum_{i=1}^m \left| \phi_N \left(\frac{i}{N+1} \right) - \phi \left(\frac{i}{N+1} \right) \right| \rightarrow 0.$$

这是一个纯分析的事实 (后一表达式非随机的), 与 (F, G) 完全无关.

至于条件 1°, 也可以给出某些使用较方便的检定方法. 这里提出一个在两样本位置和刻度参数检验的理论中有用的结果:

定理 3.15 设 $Q(x)$ 为一在 $\mathbb{R}^1$ 处处连续的分布函数.

$$\mathcal{F}_1 = \{(F(x) = Q(x + \theta_1), G(x) = Q(x + \theta_2)) : |\theta_1 - \theta_2| < a\};$$

$$\mathcal{F}_2 = \left\{ \left(F(x) = Q\left(\frac{x}{\theta_1}\right), G(x) = Q\left(\frac{x}{\theta_2}\right) \right) : \left| \frac{\theta_1}{\theta_2} - 1 \right| < a, \theta_1 > 0, \theta_2 > 0 \right\}.$$

又设

$$0 < \lambda_0 \leq \lambda_N \leq 1 - \lambda_0, \quad N = 1, 2, \dots.$$

则当 $a > 0$ 充分小时, $\mathcal{F}_1$ 和 $\mathcal{F}_2$ 都满足定理 3.14 的条件 1°.

定理 3.11 ~ 3.15 的证明, 除定理 3.13 的 2° 以外, 都可以在文献 [3] 中找到.

也可以讨论若干个形如 (3.120) 式的线性秩统计量的联合极限分布的问题.

3.4 结存在的情况

设 $X_1, \dots, X_N \sim F$, F 为一维分布. 若 F 有不连续点, 则以概率大于 0, 样本 $X_1, \dots, X_N$ 中可以有相同的. 这种情况称为“结”(tie). 例如, 设有样本 $X_1, \dots, X_9$, 其值依次为

$$0.45, 0.20, 0.80, 0.20, 0.34, 0.45, 0.15, 0.56, 0.20. \quad (3.124)$$

此样本中有两个结: 一是 X_2, X_4 和 X_9 都取 0.20, 其大小为 3; 另一是 X_1 和 X_6 都取 0.45, 其大小为 2. 为方便计, 也可以把不重复的样本值算作大小为 1 的结. 这样, 在样本 (3.124) 中有 4 个大小为 1 的结.

当结 (大小比 1 大) 出现时, 样本的秩的定义变得不明确, 而必须引入某种补充规定, 这使秩统计量的分布问题变得复杂起来. 由于这个原因, 在不少非参数统计著作中往往是假定分布是连续的, 以回避这个结的问题. 但是, 这样做不一定总是合适的. 一则因为在有些问题中总体分布确可不连续; 一则在实际观测中, 所用单位可能较粗, 使只有较小差别的数值在读数上相同 (这可视为总体分布的离散化). 因此, 在使用秩方法时, 对结的问题加以妥善处理是必要的.

处理结的方法一般有如下两种:

1. 随机化法

当若干个样本形成一个结时, 它们的秩用“抽签”的方法来确定. 以样本 (3.124) 为例, X_2, X_4 和 X_9 构成一个结. 这三个样本占据位次 2、3 和 4. 但 X_2 的秩 R_2 究竟为 2、3 或 4, 则以随机的方式而定, 对 X_4 和 X_9 也一样. 即

$$P(R_2 = i, R_4 = j, R_9 = k) = \frac{1}{3!}.$$

此处 (i, j, k) 为 $(2, 3, 4)$ 的任一置换, 对由 X_1, X_6 构成的另一个结也可类似处

理.推广到一般情况是显然的.因为这种处理方法对所有的变量都是“一视同仁”,故由对称性的考虑,即得到下面的结果:

定理 3.16 设 $X_1, \dots, X_N \sim F$ (F 不必连续). 用随机化方法所定出的 $X_1, \dots, X_N$ 的秩, 仍记为 $R_1, \dots, R_N$, 则 $(R_1, \dots, R_N)$ 仍服从定理 3.1 中给出的分布 (3.1) (改其中的 n 为 N).

由这个结果可知, 若用随机化的方法定秩, 则 3.2 节的全部理论仍有效. 这是此方法的一个优点. 但从应用角度看, 此方法引进了一种外来的随机化手续, 故从同一组样本 (如 (3.124) 式) 出发, 不同的人可定出不同的秩, 基于这些而算出的线性秩统计量可以取不同的值. 这最终可以导致在同一问题中, 由同一组样本出发用同一种方法处理时, 得出不同的结论. 比方说, 从同一组样本 (3.124) 式出发, 甲、乙两人都在同一水平 α 之下, 用两样本 Wilcoxon 秩和检验, 则有可能甲否定了原假设而乙接受了. 这对应用者来说可能会感到难于接受.

2. 平均法

如在样本 (3.124) 中, X_2, X_4, X_9 应占据秩 2, 3, 4. 我们不必用人为的方法再对它们加以区别, 而把它们看成是完全平等的. 这种“平等”是体现在当计算秩统计量的值时, 它们起的作用完全相同. 下面以线性秩统计量 (3.18) 的计算来说明这一点:

设样本 $X_1, \dots, X_N$ 中“结”的情况是:

$$\begin{aligned} X_{i_2} &= X_{i_2} = \dots = X_{i_{r_1}} \\ &< X_{i_{r_1+1}} = X_{i_{r_1+2}} = \dots = X_{i_{r_1+r_q}} \\ &< \dots \\ &< X_{i_{r_1+\dots+r_{q-1}+1}} = \dots = X_{i_{r_1+\dots+r_q}}, \quad r_1 + \dots + r_q = N. \end{aligned}$$

这里一共有 q 个结 (注意: 在此, 结的大小为 1), 其大小按样本值的顺序排列, 依次为 $\tau_1, \dots, \tau_q$. 自然 q 及 $\tau_1, \dots, \tau_q$ 都是随机变量. 称 $\tau = (\tau_1, \dots, \tau_q)$ 为结统计量.

在此, $X_{i_1}, \dots, X_{i_{r_1}}$ 占有秩 $1, \dots, \tau_1$. 其在表达式 (3.18) 中的 $a_N(\cdot)$ 取的平均值为

$$\sum_{j=1}^{\tau_1} \frac{a_N(j)}{\tau_1}.$$

对其余各结也类似处理. 在形式上, 可以定义一个新函数 $\bar{a}_N(\cdot)$ 如下:

$$\bar{a}_N(i) = \frac{1}{\tau_1} \sum_{j=1}^{\tau_1} a_N(j), \quad 1 \leq i \leq \tau_1.$$

$$= \frac{1}{\tau_k} \sum_{j=\tau_1+\dots+\tau_{k-1}+1}^{\tau_1+\dots+\tau_k} a_N(j), \quad \tau_1 + \dots + \tau_{k-1} + 1 \leq i \leq \tau_1 + \dots + \tau_k, \quad k = 2, \dots, q \quad (3.125)$$

而将(3.18)式定义的 S_N 修改为

$$S_N = \sum_{i=1}^N c_N(i) \bar{a}_N(R_i). \quad (3.126)$$

由于在每个结上 $\bar{a}_N(\cdot)$ 取同一个值, 在计算(3.126)式的值时, R_i 在所定范围内怎么规定都可以. 例如, $X_{i_1}, \dots, X_{i_{\tau_1}}$ 的秩可在 $\{1, 2, \dots, \tau_1\}$ 内随意取. 今后为了某种理论上的需要, 可以用随机化的方法规定. 但应注意, 这里的随机化手续对计算统计量(3.126)的值并无影响. 还需注意, 函数 $\bar{a}_N(\cdot)$ 的随机性, 因为其定义依赖于样本中“结”的情况. 当所有的结的大小都是1时,

$$\bar{a}_N(\cdot) = a_N(\cdot),$$

而(3.126)式回归于(3.18)式.

这个方法避免了随机化方法的缺点——统计量的值与外加的随机化的结果有关, 且在直观上自然. 是一个较好的方法. 在 Wilcoxon 两样本秩和统计量的场合, 研究结果表明: 平均法的效率的确较随机化方法高. 但是由于 $\bar{a}_N(\cdot)$ 本身也是随机性, 故这样定义的统计量(3.126)的分布理论就比较复杂.

在 Hajek 的著作^[80]中, 有一章专门讨论在 $X_1, \dots, X_N$ 为 iid. 的情况下, 用平均法定义的线性秩统计量(3.126)的极限分布问题. 他罗列了一些结果, 但未给出其中任何结果的证明. 下面将引述其主要结果. 注意, 在本节中, 都是讨论样本 $X_1, \dots, X_n$ 为 iid. 的情况.

先提出下面的引理:

引理 3.8 以 $\tau = (\tau_1, \dots, \tau_q)$ 记结统计量, 以 $(R_1, \dots, R_N)$ 记用随机化方法确定的秩统计量, 则 $(R_1, \dots, R_N)$ 与 τ 相互独立. 又对由(3.126)式定义的 S_N 有

$$\left. \begin{aligned} E(S_N | \tau) &= N \bar{c}_N \bar{a}_N, \\ \text{Var}(S_N | \tau) &= \frac{1}{N-1} \sum_{i=1}^N (c_N(i) - \bar{c}_N)^2 \sum_{i=1}^N (\bar{a}_N(i) - \bar{a}_N)^2. \end{aligned} \right\} \quad (3.127)$$

证 前一事实的证明, 最简单的方法是基于对称性: 因为在给定 τ 的条件下, $X_1, \dots, X_N$ 的地位仍是完全平等的 (此语当然不难以数学的形式精密化起来, 这一点留给读者). (3.127) 式是这一事实及(3.21)式的推论. 因为在给定 τ

时, $(R_1, \dots, R_N)$ 的条件分布即为其无条件分布(3.1).

Hajek 提出的下述结果将定理 3.6 推广到结存在的情况, 如以下定理所述.

定理 3.17 设

1° $\{c_N(1), \dots, c_N(N)\}$ 满足条件 N ;

2° $a_N(i) = \phi\left(\frac{i}{N+1}\right)$, ϕ 为平方可积记分函数;

3° 当 $N \rightarrow \infty$ 时, 有

$$\sum_{i=1}^N (a_N(i) - \bar{a}_N)^2 / \sum_{i=1}^N (\bar{a}_N(i) - \bar{a}_N)^2 = O_p(1). \quad (3.128)$$

则当 $N \rightarrow \infty$ 时, 有

$$\sup_{\omega} \left| P(S_N < x) - \Phi\left(\frac{x - E(S_N | \tau)}{\sqrt{\text{Var}(S_N | \tau)}}\right) \right| \xrightarrow{P} 0. \quad (3.129)$$

注 3.5 设 $\{\xi_N\}$ 为一串随机变量, 记 $\xi_N = O_p(1)$, 若对任给的 $\epsilon > 0$, 存在 M , 使 $P(|\xi_N| \geq M) \leq \epsilon$ 对一切 N 成立. 又依据引理 3.4 及注 3.1, 知条件 3° 可简化为

$$N / \sum_{i=1}^N (\bar{a}_N(i) - \bar{a}_N)^2 = O_p(1).$$

对符号秩统计量可类似处理. 设对每个自然数 N , 给了

$$a_N^+(i), \quad i = 1, \dots, N.$$

设 $X_1, \dots, X_N \sim F$, F 关于 0 对称, 且

$$P(X_1 = 0) < 1.$$

以 $\tilde{X}_i (i = 1, \dots, \nu)$ 记 $X_1, \dots, X_N$ 中不为 0 的那些, 以 R_i^+ 记 $|\tilde{X}_i|$ 在 $(|\tilde{X}_1|, \dots, |\tilde{X}_\nu|)$ 中按随机化方法决定的秩, 而

$$\psi_i = I_{(\tilde{X}_i > 0)}$$

以

$$\tau^+ = (\tau_1^+, \dots, \tau_q^+)$$

记

$$|\tilde{X}_1|, \dots, |\tilde{X}_\nu|$$

的结统计量. 依据 τ^+ , 按(3.125)式的方式将 $a_i^+(\cdot)$ 改造为 $\bar{a}_i^+(\cdot)$. 然后将线性符号秩统计量(3.17)式的定义修改为

$$S_N^+ = \sum_{i=1}^{\nu} \psi_i \bar{a}_i^+(R_i^+). \quad (3.130)$$

易见

$$\left. \begin{aligned} E(S_N^+ | \nu, \tau^+) &= \frac{1}{2} \sum_{i=1}^{\nu} a_{\nu}^+(i), \\ \text{Var}(S_N^+ | \nu, \tau^+) &= \frac{1}{4} \sum_{i=1}^{\nu} \{\bar{a}_{\nu}^+(i)\}^2. \end{aligned} \right\} \quad (3.131)$$

定理 3.18 设当 $N \rightarrow \infty$ 时,

$$\max_{1 \leq j \leq \nu} \bar{a}_{\nu}^{+2}(j) / \sum_{i=1}^{\nu} \bar{a}_{\nu}^{+2}(i) \xrightarrow{P} 0. \quad (3.132)$$

则当 $N \rightarrow \infty$ 时,有

$$\sup_x \left| P(S_N^+ < x) - \Phi \left(\frac{x - E(S_N^+ | \nu, \tau^+)}{\sqrt{\text{Var}(S_N^+ | \nu, \tau^+)}} \right) \right| \xrightarrow{P} 0. \quad (3.133)$$

在已发表的证明结果方面, Lehmann 在文献[112]第352~362页中讨论了 Wilcoxon 两样本秩和统计量 W . 陈希孺在文献[11]中讨论了形如(3.9)式的情况,这相当于(3.126)式中的

$$c_N(i) = \begin{cases} 0, & 1 \leq i \leq m; \\ 1, & m+1 \leq i \leq N. \end{cases}$$

且记 $n = N - m$. 在 $X_1, \dots, X_N$ 为 iid. 在假定下,有

$$E(S_N | \tau) = n\bar{a}_N, \quad \text{Var}(S_N | \tau) = \frac{mn}{N(N-1)} \sum_{i=1}^N (\bar{a}_N(i) - \bar{a}_N)^2. \quad (3.134)$$

在文献[11]中证明了以下几个结果:

定理 3.19 设

$$a_N(i) = \phi \left(\frac{i}{N+1} \right),$$

ϕ 为单调的平方可积分函数,而 X_1 的分布是非退化的,则当下述两条件中成立一个时:

1° ϕ 在 $(0,1)$ 有界而 $\min(m, n) \rightarrow \infty$;

2° $0 < \liminf \frac{n}{m} \leq \limsup \frac{n}{m} < \infty$.

必有

$$\lim_{N \rightarrow \infty} P \left(\frac{S_N - E(S_N | \tau)}{\sqrt{\text{Var}(S_N | \tau)}} < x \right) = \Phi(x), \quad -\infty < x < \infty. \quad (3.135)$$

ϕ 单调的要求在位置参数的情况一般都满足,而在刻度参数的情况则否. 对

此,有下面的定理:

定理 3.20 设

$$a_N(i) = \phi\left(\frac{i}{N+1}\right),$$

ϕ 满足以下条件:

1° $\phi^2(x)$ 在 $(0,1)$ 上 L 可积,在 $[\varepsilon, 1-\varepsilon]$ 上 R 可积,对任何 $\varepsilon > 0$. 又

$$\int_0^1 \phi(x) dx = 0, \quad \int_0^1 \phi^2(x) dx > 0.$$

2° 存在有限个点 $0 = b_0 < b_1 < \cdots < b_k < b_{k+1} = 1$, 使在每个开区间 (b_i, b_{i+1}) 内, $\phi(x)$ 不为 0 且不变号, 且对任给的 $\varepsilon > 0$ 充分小, 有

$$\inf\{|\phi(x)| : b_i + \varepsilon \leq x \leq b_{i+1} - \varepsilon\} > 0, \quad i = 0, 1, \dots, k.$$

3° 存在 $\varepsilon > 0$, 使在 $(0, \varepsilon)$ 和 $(1-\varepsilon, 1)$ 内, $\phi(x)$ 是单调的.

又设 $X_1, \dots, X_N \sim F$, F 的负荷集多于 k 个点, 且定理 3.19 中的条件 1°, 2° 中至少有一条成立, 则 (3.135) 式成立.

另一个重要情况是 $a_N(i) = E\phi(U_{(i)})$, 这里 $U_{(1)} \leq \cdots \leq U_{(N)}$ 是 $R(0,1)$ 中抽出的次序样本. 有

定理 3.21 设 ϕ 满足定理 3.19 或定理 3.20 中的条件, 且上述定理中的其他条件也相应满足, 则 (3.135) 式成立.

这些结果可用于确定两样本秩检验的临界值. 下面举两个例子作具体计算 (这些例子取自文献[80], 例 3.10 作了一处小改动).

例 3.10 设 $m = n = 10$, X 样本为 7, 6, 7, 5, 4, 6, 5, 6, 6, 5, 总体分布为 $F(x)$; Y 样本为 5, 6, 6, 3, 4, 7, 4, 5, 5, 6. 总体分布为 $F(x-a)$. 要检验假设 $a = 0$, 对立假设为 $a < 0$.

列出如表 3.2.

表 3.2

	7	6	7	5	4	6	5	6	6	5	5	6	6	3	4	7	4	5	5	6
	3	<u>4</u>	<u>4</u>	<u>4</u>	5	<u>5</u>	<u>5</u>	<u>5</u>	<u>5</u>	<u>5</u>	6	<u>6</u>	<u>6</u>	<u>6</u>	<u>6</u>	<u>6</u>	<u>6</u>	<u>7</u>	<u>7</u>	<u>7</u>
τ_k	1	3			6						7						3			
ν_k	1	2			3						3						1			
W	1	9			45						98						57			
Van	- 1.67	- 3.26			2.25						3.13						4.05			

表中第一行为合样本, 前 10 个为 X , 后 10 个为 Y ; 第二行为其次序统计量;

第三行为样本中各结的大小;第四行是各结内 Y 样本的个数;第五行是针对 Wilcoxon 统计量中 $a_N(i) = i$ 算出各结内 $a_N(i)$ 之和.例如,第三个结内六个位置占的秩是 5 ~ 10, 其和为 45. 这样,按 (3.126) 式算出的(即基于平均法的)Wilcoxon 统计量 W 的值为

$$W = 1 \times \frac{1}{1} + 2 \times \frac{9}{3} + 3 \times \frac{45}{6} + 3 \times \frac{98}{7} + 1 \times \frac{57}{3} = 90.5.$$

按 (3.127) 式第一式,算出在 $a = 0$ 成立时有

$$E(W) = E(W | \tau) = 105.$$

$\text{Var}(W | \tau)$ 可按 (3.127) 式第二式计算.在 $a_N(i) = i$ 的场合,通过简单的计算得到

$$\sum_{i=1}^N (\bar{a}_N(i) - \bar{a}_N)^2 = \frac{N(N^2 - 1)}{12} - \frac{1}{12} \sum_{k=1}^q (\tau_k^2 - 1) \tau_k. \quad (3.136)$$

由 (3.127) 式和 (3.136) 式算出 $\text{Var}(W | \tau) = 161.97$. 用正态逼近,查表得

$$\Phi\left(\frac{90.5 - 105}{\sqrt{161.97}}\right) = 0.127.$$

因此,只有在所定的显著性水平 $\alpha > 0.127$ 时,才能否定原假设 $a = 0$.

表中最后一行是为使用 Van der Waerden 检验而设.例如,第三个数是

$$\sum_{i=5}^{10} \Phi^{-1}\left(\frac{i}{21}\right) = -2.25.$$

按此行算出经平均法修正后的 Van der Waerden 统计量的值为

$$V = \frac{-1.67 \times 1}{1} + \frac{-3.26 \times 2}{3} + \frac{-2.25 \times 3}{6} + \frac{3.13 \times 3}{7} + \frac{4.05 \times 1}{3} = -2.27,$$

在原假设 $a = 0$ 下有

$$E(V) = E(V | \tau) = 0.$$

按 (3.127) 式,易算出 $\text{Var}(V | \tau) = 3.717$. 用正态逼近算出

$$\Phi\left(-\frac{2.27}{\sqrt{3.717}}\right) = 0.119,$$

与用统计量 W 得出者相似.就是说,对本例数据而言,用 Wilcoxon 或 Van der Waerden 检验得出同样的结论,除非显著性水平 α 取在 0.119 与 0.127 之间.

例 3.11 对称性检验: 设大小为 $N = 12$ 的样本值为 $-20, -40, -10, -15, 20, 0, -15, -25, -50, -55, 0, 10$. 其总体分布已知关于某点 a 对称. 要

检验假设 $a = 0$, 对立假设为 $a > 0$. 仿上例列表如下(表 3.3):

表 3.3

	- 20	- 40	- 10	- 15	20	0	- 15	- 25	- 50	- 55	0	10
	<u>10</u>		<u>15</u>		<u>20</u>		25	40	50	55		
τ_k	2		2		2		1	1	1	1		
ν_k	1		0		1		0	0	0	0		
W^+	3		7		11		7	8	9	10		
V^+	0.34		0.82		1.35		0.91	1.10	1.34	1.69		

表中第一行为原样本;第二行为删去 0 以后余下各样本的绝对值按次序排列;第三行为各结的大小;第四行为各结内大于 0 的样本数;第五行为针对 Wilcoxon 符号检验统计量 $a_N^+(i) = i$ 而设;第六行为针对“正态分位计分”检验统计量

$$a_N^+(i) = \Phi^{-1}\left(\frac{1}{2} + \frac{i}{2(N'+1)}\right)$$

而设(此处 $N' =$ 非 0 样本的个数,在本例为 $N' = 10$). 算出这两个统计量的值为

$$W^+ = \frac{3 \times 1}{2} + \frac{11 \times 1}{2} = 7;$$

$$V^+ = \frac{0.34 \times 1}{2} + \frac{1.35 \times 1}{2} = 0.845.$$

依公式(3.131),算出

$$E(W^+ | N', \tau^+) = 27.5, \quad \text{Var}(W^+ | N', \tau^+) = 95.88;$$

$$E(V^+ | N', \tau^+) = 3.775, \quad \text{Var}(V^+ | N', \tau^+) = 1.9988.$$

此处计算 $\text{Var}(W^+ | N', \tau^+)$ 时可使用容易证明的公式

$$\text{Var}(W^+ | N', \tau^+) = \frac{1}{24} N'(N'+1)(2N'+1) - 12 \sum_{i=1}^q \tau_i(\tau_i^2 - 1).$$

依正态逼近,计算出:

$$\text{用 } W^+ : \Phi\left(\frac{7 - 27.5}{\sqrt{95.88}}\right) = 0.018;$$

$$\text{用 } V^+ : \Phi\left(\frac{0.845 - 3.775}{\sqrt{1.9988}}\right) = 0.019.$$

二者很接近,按 0.02 或更大的显著性水平,应否定原假设 $a = 0$,而按 0.01 的水平则不行.

若用符号检验,则因 $N' = 10$, 大于 0 的样本个数为 2, 而

$$\sum_{i=0}^2 \binom{10}{i} \left(\frac{1}{2}\right)^{10} = 0.055.$$

因此,若用此检验则在 0.05 的水平上尚不能否定原假设. 在此不能贸然地作出结论说:符号检验不如 W^+ 或 V^+ 灵敏. 这一点依赖于我们总体分布有关信息的了解. 在下一章中要讨论这个问题.

第 4 章

秩 方 法

本章的内容是讨论秩方法(基于样本的秩的统计推断法)在各种统计问题中的应用.在上一章讨论线性秩统计量的渐近分布理论时,已从直观的想法出发提出过一些重要的秩检验,如 Wilcoxon 检验, Fisher-Yates 检验,符号检验等.但我们所做的,只不过根据检验统计量在原假设下的极限分布形式定出检验的大样本临界值,而对所提出检验的优良性问题没有作任何讨论.这是本章中要研究的一个重要课题.另外,在上一章中只涉及对称中心及位置和刻度参数的检验问题,这些问题还要在本章中做深入研究.但除此以外,还要考虑一些其他的问题,如方差分析,相关分析中的一些问题.我们也要讨论一些估计方面的问题.特别是对于分布的对称中心及位置参数的点估计和区间估计问题,要做较仔细的讨论.

4.1 检验的渐近相对效率

设 T_1 和 T_2 是某假设的基于同一样本和具有同一水平的两个检验.根据 Neyman-Pearson 理论的思想,若在对立假设处 T_1 和功率比 T_2 的功效大,则可以说,相对于 T_2 而言 T_1 有更大的效率.

也可以换一个说法: T_1 和 T_2 有同一水平 α .指定 $\beta(0 < \alpha < \beta < 1)$,为了使在对立假设处功率能达到 β 这样大,用 T_1 时样本大小需要 N_1 ;用 T_2 时则需要 N_2 .若 $N_1 < N_2$,则有理由说, T_1 的效率比 T_2 大.且可用比值 N_2/N_1 作为 T_1 和 T_2 的“相对效率”.例如,用 Wilcoxon 检验和 t 检验去检验“两总体分布相同”的假设,对立假设是 $\{N(a, 2), N(a + \theta, 2)\}$.取定 $\alpha = 2/63$,并对 Wilcoxon 检验取定 $m = n = 5$.经实际计算,在 $\theta = 0.5, 1.0, 1.5$ 时,这 Wilcoxon 检验的功效分别为 0.072, 0.210, 0.431.要 t 检验在上述对立假设处达到同一功率值, $m = n$ 的值应分别取为 4.480, 4.890, 4.805(t 检验的功效是通过非中心 t 分布算出的,其表达式为 m, n 不是整数时也有意义).由此得出,在上述诸对立假设之下,且在 α 取为 $2/63$ 而 β 取为 0.072, 0.210 和 0.431 时, Wilcoxon 检验对 t 检验的相对效率分别为 0.968, 0.978, 0.961.值得注意的是这些数值很接近 1.如果把水平 α 由 $2/63$ 改为别的数,则在这同一些对立假设下,相对效率也会有不同.因此,相对效率所选的水平 α .对立假设 θ 及在 θ 处所要达到的功效值 β 都有

关,这对相互比较不方便.为克服这一困难,通过极限过程引进了一种指标,就是所谓“渐近相对效率”(Asymptotic Relative Efficiency,简记 ARE),如下所述:

设有样本 $Z_1, \dots, Z_N$, 其联合分布依赖于 $F \in \mathcal{F}$ 及某参数 $\theta \geq \theta_0$ (θ_0 已知). 固定 F (即认为 F 为已知)、 N , 考虑假设检验问题

$$H: \theta = \theta_0 \leftrightarrow K: \theta > \theta_0, \quad (4.1)$$

以 S 和 T 表示这问题的两个检验,也用它来记检验统计量本身,当样本大小为 N 时, S 和 T 分别具体化为 S_N 和 T_N , 而检验的否定域有 $\{S_N > C_N\}$ 及 $\{T_N > d_N\}$ 的形式. 分别以 $\beta_S(N, F, \theta)$ 和 $\beta_T(N, F, \theta)$ 表示其功效函数.

定义 4.1 设对任何指定的 α, β ($0 < \alpha < \beta < 1$) 及任一串 $\theta_k \downarrow \theta_0$ (确切地说, 是 $\theta_1 \geq \theta_2 \geq \dots > \theta_0, \theta_k \rightarrow \theta_0$), 均可找到两个自然数子列 $\{N_k\}, \{N_k'\}$ 以及临界值序列 $\{C_N\}, \{d_N\}$, 使

$$\lim_{k \rightarrow \infty} \beta_S(N_k, F, \theta_0) = \lim_{k \rightarrow \infty} \beta_T(N_k', F, \theta_0) = \alpha; \quad (4.2)$$

$$\lim_{k \rightarrow \infty} \beta_S(N_k, F, \theta_k) = \lim_{k \rightarrow \infty} \beta_T(N_k', F, \theta_k) = \beta. \quad (4.3)$$

若对任何满足 (4.2)、(4.3) 式的自然数子序列 $\{N_k\}$ 和 $\{N_k'\}$, 有极限

$$\lim_{k \rightarrow \infty} \frac{N_k'}{N_k}$$

存在(可为 ∞), 且与 α, β 及 $\{\theta_k\}$ 的选择无关, 则称它为 S 对 T 的 ARE. 记为 $\text{ARE}(S, T, F)$.

这个定义 Pitman 于 1948 年在文献[134]中引进的, 故常称为 Pitman 效率, 以别于其他的效率概念——在文献中也出现过其他的效率概念, 但都不如 Pitman 效率重要与常用(参看文献[130]).

这个定义通过极限手续以摆脱相对效率对样本大小及 α, β 的依赖, 因而也只反映了样本大小很大时检验效率的比较. 在样本大小不很大时, ARE 的数值有参考意义且往往与实际的相对效率相关不多. 例如前面在 $m = n = 5$ 时举出了 Wilcoxon 检验对 t 检验的几个效率值 0.968, 0.978 等. 在下一段将证明 ARE 为 $3/\pi \approx 0.955$. 二者相差很小.

在定义 4.1 中要求 $\theta_k \downarrow \theta_0$, 这是因为若固定一个 $\theta > \theta_0$, 则当样本大小无限增加时, 在 θ 点处的功效值一般会趋于 1, 与样本大小趋于 ∞ 的速度无关, 这会使比较无法进行. 另外, 所定义的 ARE 与分布 F 有关. 这一点不仅不是本定义的缺陷, 相反, 正是我们所预期的. 因为一个检验的优劣, 理应取决于模型的性质, 即分布 F . 例如, 两样本 t 检验在模型为正态时, 是一个优良的检验, 而在其他情

况下则不一定. 通过弄清 ARE 与 F 的关系, 可以判明在何种情况下应选用何种检验.

关于 ARE 的计算, 有下面的基本结果是:

定理 4.1 沿用前面的记号, 设存在函数 $\mu(S, N, \theta, F)$ 、 $\mu(T, N, \theta, F)$ 、 $\sigma(S, N, \theta, F) > 0$ 、 $\sigma(T, N, \theta, F) > 0$, 满足以下条件:

1° 对任一串 $\theta_k \downarrow \theta_0$ (包括 $\theta_1 = \theta_2 = \cdots = \theta_0$ 的情况, 下同), 当 $\{N_k\}$ 与 $\{N'_k\}$ 满足 (4.2)、(4.3) 式时, 令 $k \rightarrow \infty$, 有

$$\frac{S_{N_k} - \mu(S, N_k, \theta_k, F)}{\sigma(S, N_k, \theta_k, F)} \xrightarrow{\mathcal{L}} N(0, 1); \quad (4.4)$$

$$\frac{T_{N'_k} - \mu(T, N'_k, \theta_k, F)}{\sigma(T, N'_k, \theta_k, F)} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.5)$$

2° 作为 θ 的函数, 当 $\varepsilon > 0$ 充分小时, μ 为 θ 的导数 μ' 的导数 μ' 在 $[\theta_0, \theta_0 + \varepsilon]$ 内存在连续, 且当 $k \rightarrow \infty$ 时, 有

$$\frac{\mu'(S, N_k, \theta_k, F)}{\mu'(S, N_k, \theta_0, F)} \rightarrow 1; \quad (4.6)$$

$$\frac{\mu'(T, N'_k, \theta_k, F)}{\mu'(T, N'_k, \theta_0, F)} \rightarrow 1. \quad (4.7)$$

3° 当 $k \rightarrow \infty$ 时, 有

$$\frac{\sigma(S, N_k, \theta_k, F)}{\sigma(S, N_k, \theta_0, F)} \rightarrow 1; \quad (4.8)$$

$$\frac{\sigma(T, N'_k, \theta_k, F)}{\sigma(T, N'_k, \theta_0, F)} \rightarrow 1 \quad (4.9)$$

4° 当 $N \rightarrow \infty$ 时, 有

$$\frac{\mu'(S, N, \theta_0, F)}{\sqrt{N}\sigma(S, N, \theta_0, F)} \rightarrow K_S(F) \text{ 存在}, \quad (4.10)$$

$$\frac{\mu'(T, N, \theta_0, F)}{\sqrt{N}\sigma(T, N, \theta_0, F)} \rightarrow K_T(F) \text{ 存在}. \quad (4.11)$$

且 $K_S(F)$ 与 $K_T(F)$ 不同时为 0 及 ∞ , 则

$$\text{ARE}(S, T, F) = \frac{K_S^2(F)}{K_T^2(F)}. \quad (4.12)$$

证 由 (4.2) ~ (4.5) 式, 得

$$\lim_{k \rightarrow \infty} \frac{c_{N_k} - \mu(S, N_k, \theta_k, F)}{\sigma(S, N_k, \theta_k, F)} = \lim_{k \rightarrow \infty} \frac{d_{N'_k} - \mu(T, N'_k, \theta_k, F)}{\sigma(T, N'_k, \theta_k, F)} (= \Phi^{-1}(1 - \beta)); \quad (4.13)$$

$$\lim_{k \rightarrow \infty} \frac{c_{N_k} - \mu(S, N_k, \theta_0, F)}{\sigma(S, N_k, \theta_0, F)} = \lim_{k \rightarrow \infty} \frac{d_{N_k'} - \mu(S, N_k', \theta_0, F)}{\sigma(T, N_k', \theta_0, F)} (= \Phi^{-1}(1 - \alpha)). \quad (4.14)$$

由(4.8)、(4.9)式知,在(4.13)式两极限号下的表达式中,分母可以分别用 $\sigma(S, N_k, \theta_0, F)$ 和 $\sigma(T, N_k', \theta_0, F)$ 代替,以由此得出的式子和(4.14)式相减,得

$$\begin{aligned} & \lim_{k \rightarrow \infty} \frac{\mu(S, N_k, \theta_k, F) - \mu(S, N_k, \theta_0, F)}{\sigma(S, N_k, \theta_0, F)} \\ &= \lim_{k \rightarrow \infty} \frac{\mu(T, N_k', \theta_k, F) - \mu(T, N_k', \theta_0, F)}{\sigma(T, N_k', \theta_0, F)} \end{aligned}$$

将极限号下的量用中值定理并利用(4.6)、(4.7)、(4.10)、(4.11)式,即得

$$\lim_{k \rightarrow \infty} \frac{\sqrt{N_k} K_s(F)}{\sqrt{N_k'} K_T(F)} = 1.$$

因此

$$\lim_{k \rightarrow \infty} \frac{N_k'}{N_k} = \frac{K_s^2(F)}{K_T^2(F)}. \quad (4.15)$$

由(4.15)式,根据 $\text{ARE}(S, T, F)$ 的定义,即得(4.12)式.定理证毕.

由(4.12)式看出,检验 S 对其他检验的 ARE 值与 $K_s^2(F)$ 成正比.故可将它称为 S 的“效率因子”.

注意:在(4.4)、(4.5)两式中, S_{N_k} 和 $T_{N_k'}$ 的分布与样本 $(Z_1, Z_2, \dots)$ 有关,而后者的分布依赖于 θ (在已给定 F 时),这里 θ 的值应取为 θ_k ,即在 μ 的表达式中的 θ 值.另外,在(4.4)、(4.5)两式中要求极限分布为标准正态分布.这一点在定理证明中并不必要,只需极限分布存在且极限分布函数 $H(x)$ 在区间 $\{x: 0 < H(x) < 1\}$ 上严格增加即可.当然,在具体问题中,此极限分布多为正态的.

在本定理中, μ, σ^2 一般是有关统计量的均值方差,但不必一定如此,在定理诸条件中,最难验证的是条件1°.显然有:

引理 4.1 以 $H_N(x | \theta, S)$ 记

$$\frac{S_N - \mu(S, N, \theta, F)}{\sigma(S, N, \theta, F)}$$

的分布函数.若存在 $\varepsilon > 0$,使在 $\theta_0 \leq \theta \leq \theta_0 + \varepsilon$ 内变量

$$\frac{S_N - \mu(S, N, \theta, F)}{\sigma(S, N, \theta, F)}$$

依分布一致收敛于 $N(0, 1)$,也就是说,当 $N \rightarrow \infty$ 时,有

$$\sup\{|H_N(x | \theta, S) - \Phi(x)| : -\infty < x < \infty, \theta_0 \leq \theta \leq \theta_0 + \varepsilon\} \rightarrow 0.$$

则定理 4.1 条件 1° 中关于 S 的部分是满足的, 即 (4.4) 式成立.

注 4.1 定理 4.1 只处理了单边检验问题. 对双边问题 $\theta = \theta_0 \leftrightarrow \theta \neq \theta_0$, 也可以导出类似的结果. 但对检验的形式要施加一定的限制.

沿用定理 4.1 中的一切记号, 并假设该定理中的一切条件都成立, 为检验 $\theta = \theta_0 \leftrightarrow \theta \neq \theta_0$, 引进两个检验 S 和 T , 其接受域分别为

$$S: \{c_N' \leq S_N \leq c_N\}, \quad T: \{d_N' \leq T_N \leq d_N\},$$

其中

$$c_N = \mu(S, N, \theta_0, F) + \mu_{\alpha/2} \sigma(S, N, \theta_0, F);$$

$$c_N' = \mu(S, N, \theta_0, F) - \mu_{\alpha/2} \sigma(S, N, \theta_0, F);$$

$$d_N = \mu(T, N, \theta_0, F) + \mu_{\alpha/2} \sigma(T, N, \theta_0, F);$$

$$d_N' = \mu(T, N, \theta_0, F) - \mu_{\alpha/2} \sigma(T, N, \theta_0, F).$$

这种取法的特殊性就在于接受区间关于 μ 点对称. 如果不这样取, 则 ARE 一般不存在.

有一点需要注意: 上面定义的 c_N 等依赖于分布 F . 所以必须假定 F 为已知, 或者假定 $\mu(S, N, \theta_0, F)$ 、 $\sigma(S, N, \theta_0, F)$ 等都与 F 无关, 幸好在一些重要情况下, 如 S 的秩检验、 t 检验等, 这后一假定往往成立.

现设 $\theta_k \rightarrow \theta_0$, $\theta_k - \theta_0$ ($k = 1, 2, \dots$), 不必保持同一符号. 设 (4.3) 式成立. 注意: 由于 c_N 等的取法及定理 4.1 的假定 1°, (4.2) 式必然成立. (4.3) 式可写为

$$\lim_{k \rightarrow \infty} P_{\theta_k}(c_N' \leq S_{N_k} \leq c_N) = \lim_{k \rightarrow \infty} P_{\theta_k}(d_N' \leq T_{N_k} \leq d_N) = 1 - \beta.$$

由 c_N 、 c_N' 的表达式, 有

$$\begin{aligned} P_{\theta_k}(c_N' \leq S_{N_k} \leq c_N) &= P_{\theta_k} \left(\frac{\mu(S, N_k, \theta_0, F) - \mu(S, N_k, \theta_k, F)}{\sigma(S, N_k, \theta_k, F)} \right. \\ &\quad \left. - \mu_{\alpha/2} \frac{\sigma(S, N_k, \theta_0, F)}{\sigma(S, N_k, \theta_k, F)} \right. \\ &\leq \frac{S_{N_k} - \mu(S, N_k, \theta_k, F)}{\sigma(S, N_k, \theta_k, F)} \\ &\leq \frac{\mu(S, N_k, \theta_0, F) - \mu(S, N_k, \theta_k, F)}{\sigma(S, N_k, \theta_k, F)} \\ &\quad \left. + \mu_{\alpha/2} \frac{\sigma(S, N_k, \theta_0, F)}{\sigma(S, N_k, \theta_k, F)} \right). \end{aligned}$$

由 $P_{\theta_k}(c_N' \leq S_{N_k} \leq c_N) \rightarrow 1 - \beta$, 利用定理 4.1 的条件 1° 和条件 3°, 不难得出

$$\lim_{k \rightarrow \infty} \frac{|\mu(S, N_k, \theta_k, F) - \mu(S, N_k, \theta_0, F)|}{\sigma(S, N_k, \theta_0, F)} = \delta > 0,$$

其中 δ 是方程 $\Phi(u_{\alpha/2} + \delta) - \Phi(-u_{\alpha/2} + \delta) = 1 - \beta$ 的唯一的正根, 依定理 4.1 的条件 2° 和 4°, 可将此式写为

$$\lim_{k \rightarrow \infty} N_k (\theta_k - \theta_0)^2 K_S^2(F) = \delta^2.$$

对检验 T 重复上述讨论, 得

$$\lim_{k \rightarrow \infty} N_k' (\theta_k - \theta_0)^2 K_T^2(F) = \delta^2.$$

于是得到

$$\lim_{k \rightarrow \infty} \frac{N_k'}{N_k} = \frac{K_S^2(F)}{K_T^2(F)},$$

即 (4.15) 式, 也就是与单边情况下得出的 ARE 完全一样.

以后在所举的例子中只讨论单边的情况, 由此注解可知, 这些例子的结果也可转移到双边的情形, 我们不一一指出了.

4.1.1 若干例子

例 4.1 设 $Z_1, \dots, Z_N \sim F(x - \theta)$, 此处 $F(x)$ 为关于原点对称的分布函数, 其密度 f 存在. 假定 f 在 0 点连续, $f(0) > 0$,

$$\int_{-\infty}^{\infty} x^2 f(x) dx < \infty > \int_{-\infty}^{\infty} f^2(x) dx \quad (4.16)$$

考虑假设检验问题

$$H: \theta = 0 \leftrightarrow K: \theta > 0, \quad (4.17)$$

这问题在第 3 章中已经多次提及了, 此处的目的是依据 ARE 的准则来比较下面三个常用的检验:

T^+ : 一样本 t 检验:

$$T_N^+ = \frac{\sqrt{N} \bar{Z}_N}{S_N},$$

其中

$$\bar{Z}_N = \frac{1}{N} \sum_{i=1}^N Z_i,$$

$$S_N^2 = \frac{1}{N-1} \sum_{i=1}^N (Z_i - \bar{Z}_N)^2.$$

否定域为

$$T_N^+ > t_{N-1, \alpha} \triangleq c_N.$$

B : 符号检验:

$$B_N = \sum_{i=1}^N I_{(Z_i > 0)},$$

否定域可取为

$$B_N > \frac{N}{2} + \frac{\sqrt{N}}{2} u_\alpha \triangleq d_N.$$

W^+ : 一样本 Wilcoxon 检验:

$$W_N^+ = \sum_{i=1}^N \psi_i R_i^+$$

(见定义 3.2) 否定域可取为

$$W_N^+ > \frac{N(N+1)}{4} + \frac{1}{\sqrt{3N}} \binom{N}{2} u_\alpha \triangleq e_N.$$

我们要仔细验证, 对这几个统计量来说, 定理 4.1 的条件都满足. 先考虑 T : 取

$$\mu(T^+, N, \theta, F) = \frac{\sqrt{N}\theta}{\sigma}, \quad \sigma(T, N, \theta, F) = 1.$$

此处 σ^2 为分布 F 的方差, 由 (4.16) 式知 $0 < \sigma^2 < \infty$. 定理 4.1 的条件 $2^\circ \sim 4^\circ$ 显然成立, 且

$$K_{T^+}^2(F) = \frac{1}{\sigma^2}. \quad (4.18)$$

现验证条件 1° : 任取 $\theta_k \downarrow 0$. 因为当 $N \rightarrow \infty$ 时, 自由度 $N-1$ 的 t 分布收敛于正态分布, 从而知: 为要 $\beta_{T^+}(N_k, F, \theta_k) \rightarrow \beta$, 充要条件是 $\sqrt{N_k}\theta_k/\sigma \rightarrow u_\alpha - u_\beta$ (注意 $u_\alpha = \Phi^{-1}(1-\alpha)$). 又因

$$\begin{aligned} & \frac{T_{N_k}^+ - \mu(T^+, N_k, \theta_k, F)}{\sigma(T^+, N_k, \theta_k, F)} \\ &= \frac{\sqrt{N_k}(\bar{Z}_{N_k} - \theta_k)}{S_{N_k}} + \frac{\sqrt{N_k}\theta_k(\sigma - S_{N_k})}{\sigma S_{N_k}}. \end{aligned} \quad (4.19)$$

由于 $\sqrt{N_k}\theta_k$ 趋于有限极限, 而 $S_{N_k} \rightarrow \sigma, a.s.$, 从而知 (4.19) 式右边第二项以概率 1 趋于 0, 而第一项则趋于 $N(0, 1)$. 这证明了定理 4.1 的条件 1° 也满足.

其次考虑 B : 注意到 B_N 服从二项分布 $B(N, p_\theta)$, 其中

$$p_\theta = 1 - F(-\theta) = F(\theta) \rightarrow F(0) = \frac{1}{2}, \quad \theta \rightarrow 0.$$

注意到条件 (4.16), 从而知若取

$$\mu(B, N, \theta, F) = NF(\theta), \quad \sigma(B, N, \theta, F) = \frac{1}{2} \sqrt{N}.$$

则定理 4.1 的条件 $1^\circ \sim 4^\circ$ 全满足, 且

$$K_B^2(F) = 4f^2(0). \quad (4.20)$$

最后讨论 W^+ : 根据 (2.9) 式, 有

$$W_N^+ = \sum_{i=1}^N I_{(z_i > 0)} + \binom{N}{2} U_N. \quad (4.21)$$

此处 U_N 是以 $\varphi(x_1, x_2) = I_{(x_1 + x_2 > 0)}$ 为核的 U 统计量. 由例 2.8, 此核满足定理 2.3 的条件. 若取

$$\begin{aligned} \mu(W^+, N, \theta, F) &= \binom{N}{2} \int_{-\infty}^{\infty} F(x + 2\theta) f(x) dx; \\ \sigma(W^+, N, \theta, F) &= \frac{2}{\sqrt{N}} \binom{N}{2} \left\{ \int_{-\infty}^{\infty} F^2(x + 2\theta) dF(x) \right. \\ &\quad \left. - \left(\int_{-\infty}^{\infty} F(x + 2\theta) dF(x) \right)^2 \right\}^{1/2}. \end{aligned}$$

则由定理 2.3 知, 对充分小的 $a > 0$, 在 $|\theta| \leq a$ 的范围内当 $N \rightarrow \infty$ 时, 一致地有

$$\frac{\binom{N}{2} U_N - \mu(W^+, N, \theta, F)}{\sigma(W^+, N, \theta, F)} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.22)$$

(详细讨论见例 2.8).

由于 F 连续, 从而有

$$\lim_{\theta \rightarrow 0} \sigma(W^+, N, \theta, F) = \frac{2}{\sqrt{N}} \binom{N}{2} \sqrt{\frac{1}{12}} = \frac{1}{\sqrt{3N}} \binom{N}{2}, \quad (4.23)$$

为 $N^{3/2}$ 的量级, 但

$$0 \leq \sum_{i=1}^N I_{(z_i > 0)} \leq N,$$

故由 (4.21)、(4.22) 式知, 对充分小的 $a > 0$, 在 $|\theta| \leq a$ 的范围内当 $N \rightarrow \infty$ 时, 一致地有

$$\frac{W_N^+ - \mu(W^+, N, \theta, F)}{\sigma(W^+, N, \theta, F)} \xrightarrow{\mathcal{L}} N(0, 1).$$

再根据引理 4.1, 即知定理 4.1 的条件 1° 满足.

由 (4.23) 式知定理 4.1 的条件 3° 满足, 要证条件 2° 和 4° , 只需证明

$$\frac{d}{d\theta} \int_{-\infty}^{\infty} F(x+\theta)f(x)dx = \int_{-\infty}^{\infty} f(x+\theta)f(x)dx, \quad (4.24)$$

且(4.24)式右边为 θ 的连续函数.

先证连续性:记 $\Delta = \theta - \varphi$, 有

$$\begin{aligned} & \left| \int_{-\infty}^{\infty} f(x+\theta)f(x)dx - \int_{-\infty}^{\infty} f(x+\varphi)f(x)dx \right|^2 \\ & \leq \int_{-\infty}^{\infty} |f(x+\Delta) - f(x)|^2 dx \int_{-\infty}^{\infty} f^2(x)dx \\ & \leq \int_{-\infty}^{\infty} |f^2(x+\Delta) - f^2(x)| dx \int_{-\infty}^{\infty} f^2(x)dx. \end{aligned}$$

由假定(4.16)式知

$$\int_{-\infty}^{\infty} f^2(x)dx < \infty,$$

因为 f^2 在 $(-\infty, \infty)$ 可积, 根据实变函数论中众所周知的结果知: 当 $\Delta \rightarrow 0$ 时,

$$\int_{-\infty}^{\infty} |f^2(x+\Delta) - f^2(x)| dx \rightarrow 0.$$

由(4.24)式即知(4.23)式右边为 θ 的连续函数. 故为证(4.24)式, 只需证明对任一实数 φ , 有

$$\int_{-\infty}^{\varphi} d\theta \int_{-\infty}^{\infty} f(x+\theta)f(x)dx = \int_{-\infty}^{\infty} F(x+\varphi)f(x)dx,$$

但这是 Fubini 定理的直接推论. 这证明了(4.23)式, 因而证明了 W^+ 满足定理 4.1 的一切条件. 且易见

$$K_{w^+}^2(F) = 12 \left(\int_{-\infty}^{\infty} f^2(x)dx \right)^2. \quad (4.25)$$

根据(4.18)、(4.20)、(4.25)式, 可以算出所讨论的三个检验的 ARE(要求 F 满足条件(4.16)). 下面表 4.1 是几个分布的计算结果.

表 4.1

分布 F	密度	$\text{ARE}(W^+, T^+, F)$	$\text{ARE}(B, T^+, F)$
$R(-1, 1)$	$\frac{1}{2} I_{(-1 < x < 1)}$	1	$\frac{1}{3}$
正态	$\frac{1}{\sqrt{2\pi}} e^{-x^2/2}$	$\frac{3}{\pi}$	$\frac{2}{\pi}$
Logistic	$e^{-x}(1+e^{-x})^{-2}$	$\frac{\pi^2}{9}$	$\frac{\pi^2}{12}$
重指数	$\frac{1}{2} e^{- x }$	$\frac{3}{2}$	2

由此表看出,秩检验虽然只用到了样本中大小次序方面的信息,但一般说来却具有良好的性能.以 W^+ 与 T^+ 的对比来说,在所列的四个较常见的分布中,有三个是 W^+ 优于 T^+ 或与 T^+ 相当.即使在正态分布下(这时在几个准则之下 T^+ 有最优性), W^+ 比 T^+ 在效率上相差甚微,而 W^+ 还具有在广泛的原假设之下保持“与分布无关”的性质,而 T 却没有这个性质.就是以看起来更粗的符号检验 B 与 T^+ 作比较,情况也是有好有坏的.这些结果增强了人们对非参数方法的信心.

下面进一步证明:对任何满足条件(4.16)的对称分布 F ,有

$$\text{ARE}(W^+, T^+, F) \geq 0.864. \quad (4.26)$$

由(4.18)式、(4.25)式知,这相当于证明:在条件

$$\left. \begin{aligned} f(x) \geq 0, f(-x) = f(x), \int_{-\infty}^{\infty} xf(x)dx = 0, \\ \int_{-\infty}^{\infty} x^2 f(x)dx = \int_{-\infty}^{\infty} f(x)dx = 1 \end{aligned} \right\} \quad (4.27)$$

之下,积分 $\int_{-\infty}^{\infty} f^2(x)dx$ 的最小值为 0.864. 为此,取

$$f_0(x) = \frac{3}{20\sqrt{5}}(5 - x^2)I_{(|x| < \sqrt{5})},$$

有

$$\begin{aligned} \int_{-\infty}^{\infty} f^2(x)dx &= \int_{-\infty}^{\infty} f_0^2(x)dx + \int_{-\infty}^{\infty} \{f(x) - f_0(x)\}^2 dx \\ &\quad + 2 \int_{-\infty}^{\infty} f_0(x) \{f(x) - f_0(x)\} dx. \end{aligned}$$

最后一项等于

$$2 \int_{-\infty}^{\infty} f_0(x)f(x)dx - 2 \int_{-\infty}^{\infty} f_0^2(x)dx.$$

令

$$f_1(x) = \frac{3}{20\sqrt{5}}(5 - x^2), \quad -\infty < x < \infty,$$

由(4.27)式不难知道

$$\int_{-\infty}^{\infty} f_1(x)f(x)dx = \frac{3}{5\sqrt{5}} = \int_{-\infty}^{\infty} f_0^2(x)dx.$$

因为 $f(x) \geq 0$ 且当 $|x| > \sqrt{5}$ 时, $f_1(x) < 0$, 有

$$\int_{-\infty}^{\infty} f_1(x)f(x)dx \leq \int_{-\infty}^{\infty} f_0(x)f(x)dx.$$

故对任何满足(4.27)式的 f , 有

$$\int_{-\infty}^{\infty} f_0(x)\{f(x) - f_0(x)\}dx \geq 0.$$

因而

$$\int_{-\infty}^{\infty} f^2(x)dx \geq \int_{-\infty}^{\infty} f_0^2(x)dx.$$

显然 f_0 满足(4.27)式. 这证明了 $\text{ARE}(W^+, T^+, F)$ 在 $F' = f_0$ 时达到最小值. 此值为

$$12\left(\int_{-\infty}^{\infty} f_0^2(x)dx\right)^2 = 12\left(\frac{3}{5\sqrt{5}}\right)^2 = \frac{108}{125} = 0.864.$$

从而证明了(4.26)式(注意:在推导中并未用到 $f(-x) = f(x)$).

因此,在任何情况下,用 W^+ 比用 T^+ 在效率上至多损失 14%. 易见 $\text{ARE}(W^+, T^+, F)$ 可以取任意大的值. 因此,在某些情况下, W^+ 的大样本性能可比 T^+ 优越很多.

例 4.2 设 $(Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n), X_1, \dots, X_m \sim F(x), Y_1, \dots, Y_n \sim F(x - \theta)$, 且 $X_1, \dots, X_m, Y_1, \dots, Y_n$ 相互独立. 这里 F 是一维连续分布, θ 为实参数. 考虑假设检验问题 $H: \theta = 0 \leftrightarrow K: \theta > 0$. 比较下面两个检验:

T : 两样本 t 检验:

$$T_N = \sqrt{\frac{mn}{N}} \cdot \frac{\bar{Y}_n - \bar{X}_m}{S_{mn}},$$

此处

$$\bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i; \quad \bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i,$$

而

$$S_{mn}^2 = \frac{1}{N-2} \left\{ \sum_{i=1}^m (X_i - \bar{X}_m)^2 + \sum_{i=1}^n (Y_i - \bar{Y}_n)^2 \right\}.$$

W : 两样本 Wilcoxon 检验: $W_N = R_1 + \dots + R_n$ (见(3.4)式).

两检验的否定域分别为

$$T_N > t_{N-2, \alpha} \triangleq c_N$$

及

$$W_N > \frac{n(N+1)}{2} + u_\alpha \sqrt{\frac{mn(N+1)}{12}} \triangleq d_N$$

((3.71) 式).

本例的讨论过程与上例完全相似. 对 T 而言, 先注意到若以 σ^2 记分布 F 的方差(应假定 $\sigma^2 < \infty$), 则相当 $m, n \rightarrow \infty$ 时, 有

$$S_{mn} \rightarrow \sigma, \text{ a.s. .}$$

又若 $\theta_k \downarrow 0$ 而 $\beta_T(N_k, F, \theta_k) \rightarrow \beta$, 则

$$\sqrt{\frac{m_k n_k}{N_k}} \theta_k$$

当 $k \rightarrow \infty$ 时有有限的极限. 令

$$\mu(T, N, \theta, F) = \sqrt{\frac{mn}{N}} \frac{\theta}{\sigma}, \quad \sigma(T, N, \theta, F) = 1.$$

则由

$$\begin{aligned} & \frac{T_{N_k} - \mu(T, N_k, \theta_k, F)}{\sigma(T, N_k, \theta_k, F)} \\ &= \sqrt{\frac{m_k n_k}{N_k}} \frac{\bar{Y}_{n_k} - \bar{X}_{m_k} - \theta_k}{S_{m_k n_k}} + \sqrt{\frac{m_k n_k}{N_k}} \theta_k \frac{\sigma - S_{m_k n_k}}{\sigma S_{m_k n_k}} \end{aligned}$$

与上例关于 $T_{N_k}^+$ 同样的推理证明: 定理 4.1 的条件 $1^\circ \sim 3^\circ$ 对 T 都成立. 而为要条件 4° 成立, 还须假定

$$\lambda \triangleq \lim_{N \rightarrow \infty} \frac{m}{N} \text{ 存在, 且 } 0 < \lambda < 1. \quad (4.28)$$

这时有

$$K_T^2 = \frac{\lambda(1-\lambda)}{\sigma^2}. \quad (4.29)$$

对于 W_N , 利用例 2.9 及 (3.6) 式知:

$$W_N = \frac{1}{2} n(n+1) + mnU_{mn},$$

其中 U_{mn} 是以 $\varphi(x; y) = I_{(x < y)}$ 为核的(两样本) U 统计量. 有

$$E\varphi(X_1; Y_1) = P(X_1 < Y_1) = \int_{-\infty}^{\infty} \{1 - F(x - \theta)\} dF(x) \triangleq a(\theta),$$

又

$$\varphi_{10}(x) = E\varphi(x; Y_1) = P(x < Y_1) = 1 - F(x - \theta),$$

$$\varphi_{01}(y) = E\varphi(X_1; y) = P(X_1 < y) = F(y).$$

其方差分别为

$$\begin{aligned}\sigma_{10}^2 &= \text{Var}\varphi_{10}(X_1) = \int_{-\infty}^{\infty} \{1 - F(x - \theta)\}^2 dF(x) \\ &\quad - \left\{ \int_{-\infty}^{\infty} \{1 - F(x - \theta)\} dF(x) \right\}^2; \\ \sigma_{01} &= \text{Var}\varphi_{01}(Y_1) = \int_{-\infty}^{\infty} F^2(x + \theta) dF(x) \\ &\quad - \left\{ \int_{-\infty}^{\infty} F(x + \theta) dF(x) \right\}^2.\end{aligned}$$

由(2.52)式,算出(注意:该式中 $m_1 = m_2 = 1$)

$$\sigma_N^2 = N \left(\frac{1}{m} \sigma_{10}^2 + \frac{1}{n} \sigma_{01}^2 \right).$$

由于 F 连续,当 $\theta \rightarrow 0$ 时,

$$\sigma_{10}^2 \rightarrow \frac{1}{12} > 0, \quad \sigma_{01}^2 \rightarrow \frac{1}{12} > 0.$$

故存在 $\varepsilon > 0$, 使若取

$$M = \{(F(x), F(x - \theta)); |\theta| \leq \varepsilon\},$$

则定理 2.5 的条件全适合,就是说,当 $|\theta| \leq \varepsilon$ 时,一致地有

$$\frac{\sqrt{N}(U_{mn} - a(\theta))}{\sigma_N} \xrightarrow{\mathcal{L}} N(0, 1), \quad N \rightarrow \infty.$$

即

$$\sqrt{N} \left\{ \left(W_N - \frac{1}{2} n(n+1) \right) / mn - a(\theta) \right\} / \sigma_N \xrightarrow{\mathcal{L}} N(0, 1)$$

一致地于 $|\theta| \leq \varepsilon$.

考虑到当 $\theta \rightarrow 0$ 时,

$$\sigma_N^2 \rightarrow \frac{N^2}{12mn},$$

据引理 4.1, 易见若取

$$\mu(W, N, \theta, F) = \frac{1}{2} n(n+1) + mna(\theta);$$

$$\sigma(W, N, \theta, F) = \sqrt{\frac{mnN}{12}}.$$

则定理 4.1 的条件 1° 满足. 条件 3° 自然满足. 为验证条件 2°, 与上例一样, 只需假定

$$\int_{-\infty}^{\infty} f^2(x) dx < \infty$$

即可,证法也完全一样,要验证条件 4°,则须假定条件(4.28)成立.这时不难算得:

$$K_W^2(F) = 12\lambda(1-\lambda) \left(\int_{-\infty}^{\infty} f^2(x) dx \right)^2. \quad (4.30)$$

结合(4.29)、(4.30)式,我们证明了:若(4.28)式成立,且假定

F 有密度 f ,

$$\int_{-\infty}^{\infty} x^2 f(x) dx < \infty, \quad \int_{-\infty}^{\infty} f^2(x) dx < \infty. \quad (4.31)$$

则

$$\text{ARE}(W, T, F) = 12\sigma^2 \left(\int_{-\infty}^{\infty} f^2(x) dx \right)^2, \quad (4.32)$$

其中 σ^2 是分布 F 的方差.这个表达式与上例中求得的 $\text{ARE}(W^+, T^+, F)$ 的完全一样.以后可看到,这并非偶然的巧合.

4.1.2 一般的两样本秩检验的 ARE

仍设 $(Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n), X_1, \dots, X_m \sim F(x), Y_1, \dots, Y_n \sim F(x - \theta)$. 检验问题是

$$H: \theta = 0 \leftrightarrow K: \theta > 0.$$

在(3.9)式中定义了一般的秩检验统计量

$$S_N = \sum_{i=1}^n a_N(R_i),$$

而否定域为 $\{S_N > c_N\}$.

为了对这种检验计算其 $K_S^2(F)$,需要对定理 4.1 逐条作验证.而这涉及一系列复杂的分析问题.主要的工具是定理 3.12 ~ 3.15(还有些问题不在这些定理的范围内).由于我们并未给出这些定理的详细证明,故在下面也就不打算像在例 4.1 和例 4.2 中那样,把每一步细节仔细写出来,而只能满足一种基本上是形式的推导.

主要步骤如下:

1° 利用 $a_N(i)$ 的值在 $0 < u < 1$ 定义 $\phi_N(u)$ 如下:

$$\phi_N(u) = a_N(i),$$

当

$$\frac{i-1}{N+1} < u \leq \frac{i}{N+1}, \quad i = 1, \dots, N;$$

$$\phi_N(u) = a_N(N),$$

当

$$\frac{N}{N+1} < u < 1.$$

要求存在定义于(0,1)的函数 $\phi(u)$ 满足条件(3.118),使

$$\lim_{N \rightarrow \infty} \phi_N(u) = \phi(u)$$

对任何 $u \in (0,1)$ 成立.又假定存在 $\varepsilon > 0$,使当 $N \rightarrow \infty$ 时,在 $|\theta| \leq \varepsilon$ 的范围内一致地有

$$\frac{1}{\sqrt{N}} \sum_{i=1}^n \left\{ \phi_N\left(\frac{R_i}{N+1}\right) - \phi\left(\frac{R_i}{N+1}\right) \right\} \xrightarrow{P} 0,$$

即对任给的 $\eta > 0$,有

$$\lim_{N \rightarrow \infty} \sup_{|\theta| \leq \varepsilon} P \left\{ \frac{1}{\sqrt{N}} \sum_{i=1}^n \left| \phi\left(\frac{R_i}{N+1}\right) - \phi\left(\frac{R_i}{N+1}\right) \right| \geq \eta \right\} = 0.$$

2° 定义

$$\mu(S, N, \theta, F) = n \int_{-\infty}^{\infty} \phi\left(\frac{m}{N}F(x+\theta) + \frac{n}{N}F(x)\right) dF(x);$$

$$\sigma(S, N, \theta, F) = n \left\{ \frac{2m}{N} \left(\sigma_{N_1}^2 + \frac{m}{n} \sigma_{N_2}^2 \right) \right\}^{1/2}$$

其中

$$\sigma_{N_1}^2 = \iint_{-\infty < x < y < \infty} F(x+\theta)[1-F(y+\theta)]M_N(x,y)dF(x)dF(y);$$

$$\sigma_{N_2}^2 = \iint_{-\infty < x < y < \infty} F(x-\theta)[1-F(y-\theta)]M_N(x,y)dF(x)dF(y).$$

$$\left(M_N(x,y) = \phi' \left(\frac{m}{N}F(x+\theta) + \frac{n}{N}F(x) \right) \cdot \phi' \left(\frac{m}{N}F(y+\theta) + \frac{n}{N}F(y) \right) \right).$$

这些表达式都是根据(3.114)~(3.117)式导来.但应注意:由于这里所用的统计量 S_N 的定义与(3.113)式不同,在使用以上诸式时,应将其中 G 与 F 的位置对换, m 与 n 对换,且

$$G(x) = F(x - \theta),$$

又 μ_N 和 σ_N 都要乘以 n .

3° 再假定

$$\lim_{N \rightarrow \infty} \frac{m}{N} = \lambda \text{ 存在, 且 } 0 < \lambda < 1. \quad (4.33)$$

则定理 3.13 和 3.15 保证了: 在 $\epsilon > 0$ 充分小时, 变量

$$\frac{S_N - \mu(S, N, \theta, F)}{\sigma(S, N, \theta, F)} \xrightarrow{\mathcal{L}} N(0, 1)$$

对 $|\theta| \leq \epsilon$ 一致成立. 依引理 4.1, 这保证了定理 4.1 的条件 1° 成立.

4° 为验证定理 4.1 的条件 3°, 需要证明

$$\begin{aligned} \lim_{\theta \rightarrow 0} \sigma_{N1}^2 &= \lim_{\theta \rightarrow 0} \sigma_{N2}^2 = \iint_{-\infty < x < y < \infty} F(x)[1 - F(y)]\phi'(F(x))\phi'(F(y))dF(x)dF(y) \\ &= \iint_{0 < u < v < 1} u(1 - v)\phi'(u)\phi'(v)dudv \\ &= \frac{1}{2} \int_0^1 [\phi(u) - \bar{\phi}]^2 du, \end{aligned}$$

此处

$$\bar{\phi} = \int_0^1 \phi(u)du.$$

这个证明在文献[3]的定理 6.3.4 中已详细写出.

5° 要验证定理 4.1 的条件 2° 和条件 4°, 首先要证 μ 对 θ 可导, 形式地在积分号下求导, 有

$$\frac{d}{d\theta} \mu(S, N, \theta, F) = \frac{mn}{N} \int_{-\infty}^{\infty} \phi\left(\frac{m}{N}F(x + \theta) + \frac{n}{N}F(x)\right)f(x + \theta)f(x)dx. \quad (4.35)$$

此处 $f = F'$ 为 F 的密度. (4.35) 式的成立要有一些条件, 在一般情况下难于方便地写出来. 但对一些常见的特例可直接验证. 在 (4.35) 式成立时, 要验证定理 4.1 的条件 2°, 只需证明: 当 $\theta \rightarrow 0$ 时, (4.35) 式右边有极限

$$\frac{mn}{N} \int_{-\infty}^{\infty} \phi(F(x))f^2(x)dx. \quad (4.36)$$

对具体的 ϕ , 这一点通常不难验证. 当然, 对分布 F 及其密度 f 要有些条件.

6° 如果以上各点都能通过, 则根据 (4.33) 式, 不难证明定理 4.1 的条件 4° 成立, 且

$$K_s^2(F) = \lambda(1 - \lambda) \left(\int_{-\infty}^{\infty} \phi'(F(x))f^2(x)dx \right)^2 / \int_0^1 (\phi(x) - \bar{\phi})^2 dx. \quad (4.37)$$

(4.37) 式提供了计算线性秩检验的效率因子的公式. 由这公式即得出以下两点推论:

1. 若 $F_1(x) = F\left(\frac{x-a}{b}\right)$ ($b > 0$), 则

$$K_s^2(F_1) = \frac{1}{b} K_s^2(F);$$

2. 由 $a_N(i) = \phi\left(\frac{i}{N+1}\right)$ 和 $\bar{a}_N(i) = E\phi(U_{(i)})(U_{(1)} \leq \dots \leq U_{(N)})$ 是 $R(0,1)$ 的次序样本) 所定义的线性秩统计量 S 与 $\bar{S}$ 有同一的效率因子: $K_s^2(F) = K_{\bar{s}}^2(F)$. 这一点由定理 3.13 得出. 据此可知: Fisher-Yates 检验与 Van der Waerden 检验有同一效率因子.

在 Wilcoxon 检验的情况, 有 $\phi(u) = u$. 由 (4.37) 式得

$$K_w^2(F) = 12\lambda(1-\lambda) \left(\int_{-\infty}^{\infty} f^2(x) dx \right)^2.$$

这与在例 4.2 中得出的相同. 公式 (4.37) 的一个重要例子如下:

例 4.3 对 Van der Waerden 检验有 $\phi(u) = \Phi^{-1}(u)$, 若记

$$\varphi(x) = \frac{d\Phi(x)}{dx},$$

则易见

$$\phi'(u) = \{\varphi(\Phi^{-1}(u))\}^{-1}.$$

又

$$\bar{\phi} = \int_0^1 \phi(u) du = \int_{-\infty}^{\infty} x\varphi(x) dx = 0,$$

$$\int_0^1 (\phi(u) - \bar{\phi})^2 du = \int_{-\infty}^{\infty} x^2 \varphi(x) dx = 1.$$

于是由 (3.37) 式得 (以下简记 Van der Waerden 检验为 V)

$$K_v^2(F) = \lambda(1-\lambda) \left\{ \int_{-\infty}^{\infty} \frac{f^2(x)}{\varphi(\Phi^{-1}(F(x)))} dx \right\}^2. \quad (4.38)$$

特别, 若 F 为正态分布 $N(a, \sigma^2)$, 则由 (4.38) 式算出

$$K_v^2(F) = \frac{\lambda(1-\lambda)}{\sigma^2}$$

以 T 记两样本 t 检验, 由 (4.29) 式得

$$K_T^2(F) = \frac{\lambda(1-\lambda)}{\sigma^2}.$$

于是有

$$\text{ARE}(V, T, N(a, \sigma^2)) = 1. \quad (4.39)$$

就是说,在总体分布为正态时,与最优的参数检验—— t 检验相比, V 检验的渐近效率并不差.一个有趣的结论是:

$$\text{ARE}(V, T, F) \geq 1. \quad (4.40)$$

对于任何满足一定条件的 F (F 的方差有限,且满足导致公式(4.37)的一切条件),这个不等式的严格证明可参看文献[3]的第 680 ~ 682 页.更进一步,(4.40)式中的等号只在 F 为正态时才成立,这意味着:从大样本角度看, V 在任何时候都不劣于 T ,且当总体分布非正态时, V 优于 T .如果考虑到 V 在广泛的原假设下有“与分布无关”的性质,而 T 则没有这样的性质,则有充分的理由可认为 V 确是优于 T .当然,要使这种结论更有说服力,有必要在样本大小不太大时,考察 V 和 T 在效率上的比较.这种工作之不易进行,在于有关检验的功效不易计算,且这项计算需要对许多不同的 F 进行.另外,还需考虑到,两总体的不同不一定限于位置参数上的不同(参见文献[3]第 682 页).

根据前面所指出的,本例的结果对 Fisher-Yates 检验也成立.

用公式(4.37)可以解决下面的问题:给定分布 F ,寻找针对这个 F 的效率因子最高的秩检验.有以下定理:

定理 4.2 设 F 的密度 f 存在.令

$$\phi_F(u) = -\frac{f'(F^{-1}(u))}{f(F^{-1}(u))}, \quad 0 < u < 1. \quad (4.41)$$

则在一定条件下,以 ϕ_F 为记分函数的秩统计量所决定的秩检验 S^* 的效率因子,在一切秩检验中达到最大值.

证 设变量 $U \sim R(0,1)$,则

$$\int_0^1 (\phi(u) - \bar{\phi})^2 du = \text{Var} \phi(U). \quad (4.42)$$

任取一个秩检验 S ,其效率因子由(4.37)式给出.令

$$\phi(u, f) = -\frac{f'(F^{-1}(u))}{f(F^{-1}(u))}. \quad (4.43)$$

则

$$E\phi(U, f) = \int_0^1 -\frac{f'(F^{-1}(u))}{f(F^{-1}(u))} du.$$

作变数代换 $x = F^{-1}(u)$,得

$$E\phi(U, f) = -\int_{-\infty}^{\infty} f'(x) dx = 0. \quad (4.44)$$

严格说来,(4.44)式的成立需要以下的条件:在任何有界区间内 f 为绝对连续,

且

$$\lim_{|x| \rightarrow \infty} f(x) = 0.$$

又

$$\begin{aligned} \text{Var} \phi(U, f) &= E \phi^2(U, f) \\ &= \int_{-\infty}^{\infty} \left\{ \frac{f'(F^{-1}(u))}{f(F^{-1}(u))} \right\}^2 du \\ &= \int_{-\infty}^{\infty} \left\{ \frac{f'(x)}{f(x)} \right\}^2 f(x) dx \triangleq I(F). \end{aligned} \quad (4.45)$$

$I(F)$ 是分布 F 的 Fisher 信息量, 又

$$\begin{aligned} \text{Cov}(\phi(U), \phi(U, f)) &= E\{\phi(U)\phi(U, f)\} \\ &= \int_0^1 \phi(u)\phi(u, f) du \\ &= - \int_0^1 \frac{\phi(u)f'(F^{-1}(u))}{f(F^{-1}(u))} du \\ &= - \int_0^1 \phi(u) df(F^{-1}(u)) \\ &= - \phi(u)f(F^{-1}(u)) \Big|_0^1 + \int_0^1 f(F^{-1}(u)) d\phi(u) \\ &= \int_0^1 f(F^{-1}(u)) d\phi(u). \end{aligned} \quad (4.46)$$

上式最后一步的成立有赖于

$$\lim_{u \downarrow 0} \phi(u)f(F^{-1}(u)) = 0, \quad \lim_{u \uparrow 1} \phi(u)f(F^{-1}(u)) = 0. \quad (4.47)$$

当 $u \rightarrow 0$ 时, $F^{-1}(u) \rightarrow -\infty$, 一般地有 $f(F^{-1}(u)) \rightarrow 0$. 但 $\phi(u)$ 可能趋于 $\pm\infty$. 故 (4.47) 式要求 $f(F^{-1}(u))$ 趋于 0 的速度要比 $\phi(u)$ 趋于 $\pm\infty$ 的速度快. 设 (4.47) 式成立, 再假定 ϕ' 存在, 则由 (4.48) 式得

$$\begin{aligned} \text{Cov}(\phi(U), \phi(U, f)) &= \int_0^1 \phi'(u)f(F^{-1}(u)) du \\ &= \int_{-\infty}^{\infty} \phi'(F(x))f(x) dF(x) \\ &= \int_{-\infty}^{\infty} \phi'(F(x))f^2(x) dx. \end{aligned} \quad (4.48)$$

结合 (4.42)、(4.45)、(4.48) 式, 由公式 (4.37) 得

$$K_s^2(F) = \lambda(1-\lambda)I(F) \cdot (\phi(U) \text{ 与 } \phi(U, f) \text{ 的相关系数})^2. \quad (4.49)$$

由于相关系数的绝对值不超过 1, 知 $K_s^2(F)$ 的最大值为

$$\max_s K_s^2(F) = \lambda(1 - \lambda)I(F). \quad (4.50)$$

而这个最大值只在 $\phi(u)$ 与 $\phi(u, f)$ 成比例, 即

$$\phi(u) = \phi_F(u)$$

时达到. 定理证毕.

在定理 4.2 的叙述中, 用了“在一定条件下”这个含糊的提法而没有一一列出确切的条件. 这样做的原因不难从定理证明过程中看出来, 检查一下证明过程, 看出需要以下一些条件:

1° 公式(4.37)有效. 这条件既涉及 F , 也涉及 ϕ . 涉及 ϕ 一点表明寻找最大值的范围受到了限制.

2° 为使 $F^{-1}(u)$ 在 $0 < u < 1$ 存在, F 必须在区间

$$\{x: 0 < F(x) < 1\}$$

上严增.

3° $I(F) < \infty$.

4° 为使(4.44)式成立, f 应在有界区间绝对连续, 且

$$\lim_{|x| \rightarrow \infty} f(x) = 0.$$

5° 为使(4.46)式独立, ϕ 必须满足(4.47)式; 又为把(4.46)式中的 $d\phi(u)$ 转化为(4.48)式中的 $\phi'(u)du$. 要假定 $\phi(u)$ 在 $(0, 1)$ 内任一闭区间上绝对连续. 这进一步限制了 ϕ 的范围.

因此, 确切地说, 我们真正证明了的结论是: 设分布 F 满足上述条件 1° ~ 4°, 则在由上述条件 1°, 5° 所决定的 ϕ 的集合内, 效率因子不能超过(4.50)式右边. 若由(4.41)式定义的 ϕ_F 属于上述 ϕ 集合, 则 ϕ_F 在这集合内达到最大的效率因子.

例 4.4 取 $F \sim N(0, 1)$. 有

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

易见 $\phi_F(u) = \Phi^{-1}(u)$. 因此根据定理 4.2 知, 针对正态分布的位置参数的线性秩检验中 Van der Waerden 检验的效率因子达到最大. 自然, Fisher-Yates 检验也有这一性质.

又如, 设 F 为 logistic 分布函数,

$$F(x) = \frac{e^x}{1 + e^x}.$$

有

$$-\frac{f'(x)}{f(x)} = 2F(x) - 1.$$

于是得 $\phi_F(u) = 2u - 1$. 由它产生的秩统计量等价于 Wilcoxon 秩和统计量 W . 因此, 对检验 logistic 分布的位置参数而言, 在线性秩检验中以 Wilcoxon 检验的效率因子最大.

可以进一步提出这样的问题: 是否在秩检验以外存在效率因子更高的检验? 下面的论证表明了“在一定的条件下”问题的回答是否定的. 就是说, 在一定条件下, 由 ϕ_F 决定的秩检验在所有两样本检验中有最大的效率因子.

为讨论这个问题, 不能再从模型

$$X_1, \dots, X_m \sim F(x), Y_1, \dots, Y_n \sim F(x - \theta), \theta = 0 \leftrightarrow \theta > 0 \quad (4.51)$$

出发. 这是因为在 (4.51) 式中 F 完全是已知的. 从一般检验的角度看, 在其中抽样 $X_1, \dots, X_m$ 毫无必要. 而且这只会增加不确定性 (因为 F 本为已知, 无任何不确定性), 从而使效率降低. 但在秩检验中, 关于 θ 的信息只能由比较 Y 样本与 X 样本的大小而得到. 就是说, 当使用秩检验时, 虽明知使用 X_i 只会不必要地增加不确定性, 也不能不用它. 因此, 为了在同等的基礎上作比较, 需使用一种模型, 使 X 样本和 Y 样本都有用. 下面是这样一种提法:

$$X_1, \dots, X_m \sim F(x + (1 - \lambda)\theta), \quad Y_1, \dots, Y_n \sim F(x - \lambda\theta),$$

$$N = m + n, \lim_{N \rightarrow \infty} \frac{m}{N} = \lambda \in (0, 1), F(x) \text{ 已知}, \theta = 0 \leftrightarrow \theta > 0. \quad (4.52)$$

任取检验统计量 $Q_N = Q_N(X_1, \dots, X_m, Y_1, \dots, Y_n)$ (不必为秩统计量), 否定域为 $Q_N > c_N$. 设 F 有密度 f . 以

$$h = h(x_1, \dots, x_m, y_1, \dots, y_n, \theta)$$

记

$$(X_1, \dots, X_m, Y_1, \dots, Y_n)$$

的密度

$$\prod_{i=1}^m f(x_i + (1 - \lambda)\theta) \prod_{j=1}^n f(y_j - \lambda\theta).$$

根据 Cramer-Rao 不等式 (见文献 [3] 第 2.2 节), 有

$$\text{Var}_{\theta=0}(Q_N) \geq \left(\frac{d}{d\theta} E_{\theta}(Q_N) \right)^2 \Big|_{\theta=0} / E_{\theta=0} \left\{ \frac{\partial}{\partial \theta} \log h \Big|_{\theta=0} \right\}^2. \quad (4.53)$$

但易见

$$E_{\theta=0} \left\{ \frac{\partial}{\partial \theta} \log h \Big|_{\theta=0} \right\}^2 = \{m(1 - \lambda)^2 + n\lambda^2\} I(F)$$

$$= \{1 + o(1)\} N \lambda (1 - \lambda) I(F).$$

此处

$$\lim_{N \rightarrow \infty} o(1) = 0.$$

由此式及(4.53)式知

$$\begin{aligned} K_{Q^2}(F) &= \lim_{N \rightarrow \infty} \left\{ \left(\frac{d}{d\theta} E_{\theta}(Q_N) \right)^2 \Big|_{\theta=0} / (N \text{Var}_{\theta=0}(Q_N)) \right\} \\ &\leq \lambda(1 - \lambda) I(F). \end{aligned} \quad (4.54)$$

结合(4.50)式和(4.54)式就证明了所要结果.

所证的结果也只是“在一定的条件下”成立. 例如证明中用到 Cramer-Rao 不等式, 不需要一些正则性条件. 另外, Q_N 必须适合定理 4.1 的条件. 总之, 对定理 4.2 以及上述结果, 可以把它一般地看成秩检验优良性的一种论据, 而不必过分拘泥于其数学细节. 事实上, 虽然这些结果并不能排斥存在一个比 ϕ_F 更有效的检验的可能性, 但恐怕永远也举不出这方面有实用价值的例子.

4.1.3 一般的一样本对称性秩检验的 ARE

设 $X_1, \dots, X_N \sim F(x - \theta)$, $F(x)$ 关于 0 对称, 检验问题是 $\theta = 0 \leftrightarrow \theta > 0$.

按定义 3.2, 确定 ψ_i 及 R_i^+ . 给定实数 $a_N^+(i)$ ($i = 1, \dots, N$). 设

$$a_N^+(1) \leq \dots \leq a_N^+(N), \quad a_N^+(1) < a_N^+(N).$$

而定义线性符号秩统计量

$$S_N^+ = \sum_{i=1}^N \psi_i a_N^+(R_i^+),$$

然后取 $\{S_N^+ > c_N\}$ 为否定域.

要计算这种检验的效率因子 $K_{S^2}(F)$ 所经历的步骤大体上与 4.1.2 小节中对两样本秩检验所描述的相似. 其中最关键的一条, 就是验证 S_N^+ 经适当规则化后, 在 $|\theta| \leq \epsilon$ 的范围内一致地收敛于标准正态分布 (当 $\epsilon > 0$ 充分小). 然而, 虽然如在定理 3.10 中指出的, 在原假设 $\theta = 0$ 之下 S_N^+ 的极限定理很简单, 但当 $\theta \neq 0$ 时却十分复杂. 在此只能不加证明地引述某些此处需要的结果, 有兴趣的读者可参考文献[143].

由给定的 $a_N^+(i)$, 按 4.1.2 小节的步骤 1° 中的方法, 扩充为 $(0, 1)$ 上的函数 $\phi_N^+(u)$. 要求当 $N \rightarrow \infty$ 时, $\phi_N^+(u)$ 在 $(0, 1)$ 内点点收敛于函数 $\phi^+(u)$. 要求这个 ϕ^+ 满足定理 3.12 中关于 ϕ 的条件. 假定 F 在区间 $\{x: 0 < F(x) < 1\}$ 内严增, 且 F 的密度 f 存在. 定义

$$\phi^+(u, f) = -f' \left(F^{-1} \left(\frac{1+u}{2} \right) \right) / f \left(F^{-1} \left(\frac{1+u}{2} \right) \right), \quad (4.55)$$

取

$$\mu(S^+, N, \theta, F) = \frac{N}{2} \int_0^1 \phi^+(u) du + \frac{1}{2} N \theta \int_0^1 \phi^+(u) \phi^+(u, f) du, \quad (4.56)$$

$$\sigma(S^+, N, \theta, F) = \left\{ \frac{N}{4} \int_0^1 \phi^{+2}(u) du \right\}^{1/2}.$$

在一定条件下可以证明:当 $N \rightarrow \infty$ 时,在 $|\theta| \leq \varepsilon$ ($\varepsilon > 0$ 充分小) 的范围内一致地有

$$\frac{S_N^+ - \mu(S, N, \theta, F)}{\sigma(S^+, N, \theta, F)} \xrightarrow{\mathcal{L}} N(0, 1).$$

据此就可以算出

$$K_{S^{+2}}(F) = \left\{ \int_0^1 \phi^+(u) \phi^+(u, f) du \right\}^2 / \int_0^1 \phi^{+2}(u) du. \quad (4.57)$$

因为 $f(x) = f(-x)$, $F(x) = 1 - F(-x)$, 作变换 $u = 2F(v) - 1$, 易知

$$\int_0^1 \{\phi^+(u, f)\}^2 du = I(F).$$

又假定 f 满足

$$\int_{-\infty}^{\infty} f'(x) dx = 0,$$

则有

$$\int_0^1 \phi^+(u) \phi^+(u, f) du = 0.$$

据此可将(4.57)式改写为

$$K_{S^{+2}}(F) = I(F) r^2(\phi^+(U), \phi^+(u, f)). \quad (4.58)$$

此处 $U \sim R(0, 1)$, 而 $r(\xi, \eta)$ 为随机变量 ξ, η 的相关系数. 由此得到类似于定理 4.2 的结论如下:

定理 4.3 令

$$\phi_F^+(u) = \phi^+(u, f), \quad 0 < u < 1. \quad (4.59)$$

则在一定条件下, 以 ϕ_F^+ 为记分函数的线性符号秩统计量所决定的秩检验 S^+ 的效率因子, 在一切秩检验中达到最大值 $I(F)$.

注意到 logistic 分布与标准正态分布都关于原点对称, 例 4.4 的结果也适用于此处的对称性检验问题. 例如, 为检验 $N(\theta, \sigma^2)$ (σ^2 已知或未知均可) 中的 $\theta = 0$ (对立假设 $\theta > 0$), 由

$$a_N^+(i) = \Phi^{-1} \left(\frac{1}{2} + \frac{i}{2(N+1)} \right)$$

决定的符号秩检验有最大的效率因子.

又与两样本问题相似,可以证明,在一定条件下,由(4.59)式所决定的秩检验是在一切检验(秩与非秩)中效率因子最大者.

根据定理 3.13,由

$$\bar{a}_N^+(i) = E(\phi^+(U_{(i)})), \quad i = 1, \dots, N$$

决定的符号秩检验 $\bar{S}^+$ 与由

$$a_N^+(i) = \phi^+ \left(\frac{i}{N+1} \right)$$

所决定的符号秩检验 S^+ 有同一效率因子. 因此,由 $\phi^+ = \phi_F^+$ 所决定的 $\bar{S}^+$ 也具有最大效率因子,因为 $X_1, \dots, X_N \sim F$, 而 $F(x)$ 关于 0 对称, 知 $|X_1|, \dots, |X_N| \sim F^*$, 其中

$$F^*(x) = F(x) - F(-x) = 2F(x) - 1, \quad x \geq 0,$$

$$F^*(x) = 0, \quad x < 0.$$

以

$$|X|_{(1)} \leq \dots \leq |X|_{(N)}$$

记

$$|X_1|, \dots, |X_N|$$

的次序统计量,则

$$F^*(|X|_{(i)}) = U_{(i)}, \quad i = 1, \dots, N,$$

而 $U_{(1)} \leq \dots \leq U_{(N)}$ 为 $R(0,1)$ 的次序样本. 由

$$U_{(i)} = F^*(|X|_{(i)}) = 2F(|X|_{(i)}) - 1$$

解出 $|X|_{(i)} = F^{-1} \left(\frac{1 + U_{(i)}}{2} \right)$. 再由(4.55)、(4.59)式,得

$$E(\phi_F^+(U_{(i)})) = - \frac{E(f'(|X|_{(i)}))}{f(|X|_{(i)})}.$$

例如,对 F 为标准正态分布,即

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad -\infty < x < \infty$$

的场合,有 $E(\phi_F^+(U_{(i)})) = E(|X|_{(i)})$, $|X|_{(1)} \leq \dots \leq |X|_{(N)}$ 是 $N(\theta, 1)$ 样本 $X_1, \dots, X_N$ 绝对值的次序统计量. 这可称为一样本的 Fisher-Yates 检验.

由定理 4.2 和 4.3 看出:一、二样本秩检验的最大效率因子只相差一个常数

因子 $\lambda(1-\lambda)$. 又在例 4.1 和 4.2 中, 一、两样本 Wilcoxon 检验也只相差同一个因子 $\lambda(1-\lambda)$. 现在证明: 这一点不是偶然的巧合, 而是在一定条件下成立的一种普遍现象.

设 ϕ 为关于 $1/2$ 奇对称的、两样本秩统计量的计分函数, 即

$$\phi\left(\frac{1}{2}\right) - \phi(u) = \phi(1-u) - \phi\left(\frac{1}{2}\right), \quad 0 < u < 1. \quad (4.60)$$

又设 ϕ 在 $(0,1)$ 内为非降. 令

$$\phi^+(u) = \phi\left(\frac{1+u}{2}\right) - \bar{\phi}, \quad 0 < u < 1. \quad (4.61)$$

注意

$$\bar{\phi} = \int_0^1 \phi(u) du = \phi\left(\frac{1}{2}\right).$$

由 (4.60)、(4.61) 式, 有

$$\begin{aligned} \int_0^1 (\phi(u) - \bar{\phi})^2 du &= \frac{1}{2} \int_{-1}^1 \left(\phi\left(\frac{1+u}{2}\right) - \bar{\phi} \right)^2 du \\ &= \int_0^1 (\phi^+(u))^2 du. \end{aligned} \quad (4.62)$$

因为 F 关于 0 对称, 有

$$f(-x) = f(x), \quad F^{-1}(1-u) = -F^{-1}(u),$$

故

$$\begin{aligned} \phi(u, f) &\triangleq -\frac{f'(F^{-1}(u))}{f(F^{-1}(u))} \\ &= \frac{f'(F^{-1}(1-u))}{f(F^{-1}(1-u))} = -\phi(1-u, f). \end{aligned} \quad (4.63)$$

由此易见

$$\int_0^1 (\phi(u, f))^2 du = 2 \int_{1/2}^1 \frac{f'(F^{-1}(u))}{f(F^{-1}(u))} du.$$

注意到 (4.55) 式, 由 (4.63) 式得

$$\int_0^1 (\phi(u, f))^2 du = \int_0^1 (\phi^+(u, f))^2 du. \quad (4.64)$$

若假定

$$\int_{-\infty}^{\infty} f'(x) dx = 0$$

(由 $f(-x) = f(x)$ 知这一要求相当于 $\int_0^{\infty} |f'(x)| dx < \infty$), 则

$$\int_0^1 \phi(u, f) du = 0,$$

而

$$\int_0^1 \phi(u) \phi(u, f) du = \int_0^1 (\phi(u) - \bar{\phi}) \phi(u, f) du.$$

由此式及(4.60)、(4.63)式,得

$$\int_0^1 \phi(u) \phi(u, f) du = 2 \int_{1/2}^1 (\phi(u) - \bar{\phi}) \phi(u, f) du. \quad (4.65)$$

作变数代换 $u = (1 + v)/2$, 注意到(4.55)、(4.60), 由(4.65)式得

$$\int_0^1 \phi(u) \phi(u, f) du = \int_0^1 \phi^+(u) \phi^+(u, f) du. \quad (4.66)$$

由(4.37)、(4.57)、(4.62)、(4.64)和(4.66)式,即得

$$K_S^2(F) = \lambda(1 - \lambda) K_{S^+}^2(F). \quad \lambda(4.67)$$

这就是所要证的结果.

4.2 局部最优的秩检验

4.2.1 一般概念

上一节论述了检验的渐近相对效率,并给出了在一定条件下一定范围内效率因子最大的检验的形状. ARE 是一个大样本性质的准则. 本节要讨论一个小样本性质的准则——局部最优性.

一般,设样本 $(Z_1, \dots, Z_N)$ 的分布为单参数族 $\{F_\theta: \theta \in I\}$, I 为一开区间. 设 $\theta_0 \in I$. 考虑检验问题.

$H: \theta = \theta_0 \leftrightarrow K: \theta \in I, \theta > \theta_0$ (或 $H: \theta \in I, \theta \leq \theta_0$, 讨论是一样的).

在一般情况下,此问题的一致最优检验不存在,可以将要求放低些,即不是在对立假设 $\theta > \theta_0$ 上同时达到最优,而只要求在 θ_0 的一个充分小的邻近 $\theta_0 < \theta < \theta_0 + \epsilon$ 内同时达到最优. 若这样的检验存在,有理由称之为“局部一致最优”的. 可惜的是,即使将要求像这样减轻,局部一致最优检验也一般不存在. 因此我们把要求再降低,即把一充分小的但长度仍为有限的邻近改为“ θ_0 的无限小邻近”. 这一改即导致局部最优检验的概念.

设有两个定义于 I 上的函数 f_1 和 f_2 . 设 $f_1(\theta_0) = f_2(\theta_0)$, $f_1'(\theta_0)$ 和 $f_2'(\theta_0)$ 都存在且 $f_1'(\theta_0) \geq f_2'(\theta_0)$. 如果 $f_1'(\theta_0) > f_2'(\theta_0)$, 则当 $\theta > \theta_0$ 且 $\theta - \theta_0$ 充分小时, 有 $f_1(\theta) > f_2(\theta)$. 若

$$f_1'(\theta_0) = f_2'(\theta_0),$$

则无论 $\theta - \theta_0$ 怎么小, 不能保证 $f_1(\theta) - f_2(\theta) \geq 0$. 但是, $f_1(\theta) - f_2(\theta)$ 尽管可以大于 0, $|f_1(\theta) - f_2(\theta)|$ 也只能是高阶无穷小 $o(\theta - \theta_0)$. 在这个意义上我们说: 在 θ_0 的右边邻近处, $f_1(\theta)$ 局部大于 $f_2(\theta)$. 这个思想是局部最优检验定义的基础.

定义 4.2 设 S 为 $\theta = \theta_0 \leftrightarrow \theta > \theta_0$ 的一检验. 以 $\beta_s(\theta)$ 记其功效函数. 称 S 的“真实水平”为 α , 若 $\beta_s(\theta_0) = \alpha$ (若原假设为 $\theta \leq \theta_0$, 真实水平定义为 $\sup_{\theta \leq \theta_0} \beta_s(\theta)$). 设 $\mathcal{T}_\alpha$ 为一族真实水平为 α 的检验, $S \in \mathcal{T}_\alpha$. 若 $\beta_s'(\theta_0)$ 存在, 且对任何 $T \in \mathcal{T}_\alpha$, 只要 $\beta_T'(\theta_0)$ 存在就必有 $\beta_s'(\theta_0) \geq \beta_T'(\theta_0)$. 则称 S 是族 $\mathcal{T}_\alpha$ 中的局部最优检验. 当 $\mathcal{T}_\alpha$ 中的检验全是秩检验时, 可称为“局部最优秩检验”, 简记为 LMPRT (Local Most Powerful Rank Test).

4.2.2 两样本问题 LMPRT

这一段讨论两样本位置参数检验问题(4.51). 仍以 $(Z_1, \dots, Z_N)$ 记 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$. 我们要求出此问题的 LMPRT. 为此需要下面的结果:

引理 4.2 设 $X_1, \dots, X_m \sim F$, $Y_1, \dots, Y_n \sim G$. 又设 H 为一分布, 有密度 h . 设

$$\{x: f(x) + g(x) > 0\} \subset (a, b), \quad h(x) > 0, \quad a < x < b. \quad (4.68)$$

记

$$(Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n),$$

并以 R_i 记 Z_i ($i = 1, 2, \dots, N$) 的秩, $R^* = (R_1, \dots, R_N)$. 则对 $(1, \dots, N)$ 的任一置换 $r^* = (r_1, \dots, r_N)$, 有

$$P(R^* = r^*) = \frac{1}{N!} E \left\{ \frac{\prod_{i=1}^m f(V_{(r_i)}) \prod_{j=1}^n g(V_{(r_{m+j})})}{\prod_{i=1}^N h(V_{(i)})} \right\}. \quad (4.69)$$

此处 $V_{(1)} \leq \dots \leq V_{(N)}$ 是由分布 H 中抽出的次序样本.

证 记 $B = \{(Z_1, \dots, Z_N): Z_1 < Z_2 < \dots < Z_N\}$. 有

$$P(R^* = r^*) = \int_B \prod_{i=1}^m f(Z_{r_i}) \prod_{j=1}^n g(Z_{r_{m+j}}) dZ_1 \cdots dZ_N. \quad (4.70)$$

由假定(4.68)式,可将(4.70)式写为

$$P(R^* = r^*) = \frac{1}{N!} \int_B \frac{\prod_{i=1}^m f(Z_{r_i}) \prod_{j=1}^n g(Z_{r_{m+j}})}{\prod_{i=1}^N h(Z_i)} \times N! \prod_{i=1}^N h(Z_i) dZ_1 \cdots dZ_N. \quad (4.71)$$

因为在 B 内, $N! \prod_{i=1}^N h(Z_i)$ 就是 $(V_{(1)}, \dots, V_{(N)})$ 的密度函数,故由(4.71)式直接推得(4.69)式.

对本段讨论的情况有 $g(x) = f(x - \theta)$. 若假定 f 在 $(-\infty, \infty)$ 上处处大于 0,则可取 $h(x) = f(x)$. 仍以 R_i 记 $Z_i (i = 1, \dots, N)$ 在合样本 $(Z_1, \dots, Z_N)$ 中的秩(注意, R_{m+j} 是 Y_j 在合样本中的秩),则由(4.70)式推得

$$P_\theta(R = r) = \frac{1}{N!} E \left\{ \prod_{j=1}^n \frac{f(V_{(r_{m+j})} - \theta)}{f(V_{(r_{m+j})})} \right\}, \quad (4.72)$$

此处 $r = (r_1, \dots, r_N)$ 为 $(1, 2, \dots, N)$ 的任一置换,而

$$V_{(1)} \leq \dots \leq V_{(N)}$$

为抽自分布 $F(x)$ 的次序样本.

由公式(4.72)不难得到下面的定理:

定理 4.4 若对 $(1, \dots, n)$ 的任一置换 $r = (r_1, \dots, r_n)$, 表达式(4.72)可对 θ 在 $\theta = 0$ 处于期望号下求导,则检验问题(4.51)的 LMPRT 存在且有如下的形式:令

$$a_N(i) = -E \frac{f'(V_{(i)})}{F(V_{(i)})}, \quad i = 1, \dots, N. \quad (4.73)$$

$V_{(1)} \leq \dots \leq V_{(N)}$ 为抽自分布 $F(x)$ 的次序样本,令

$$S_N = \sum_{j=1}^n a_N(R_{m+j}),$$

取 $\{S_N > c_N\}$ 为否定域.

证 任一秩检验 T 的否定域都是某一个集合 D , D 中的元素 r 是 $(1, \dots, n)$ 的置换. 这样的 T 的功效函数为

$$\beta_T(\theta) = \sum_{r \in D} P_\theta(R = r).$$

因而

$$\beta_T'(\theta) = \sum_{r \in D} \frac{d}{d\theta} P_\theta(R = r) \big|_{\theta=0}. \quad (4.74)$$

为使检验 T 有给定的水平 α , D 中必须恰好有 $N!\alpha$ 个元素. 由 (4.74) 式知, 为使 $\beta_T'(\theta)$ 最大, 在 D 中包含的 r 应使

$$\frac{d}{d\theta} P_\theta(R = r) \big|_{\theta=0}$$

取尽可能大的值. 因此, 若将 $N!$ 个 r 按

$$\frac{d}{d\theta} P_\theta(R = r) \big|_{\theta=0}$$

由大到小排列, 则 LMPRT 的否定域应包含最前面的 $N!\alpha$ 个点. 由定理的假定有

$$\frac{d}{d\theta} P_\theta(R = r) \big|_{\theta=0} = \frac{1}{N!} \sum_{j=1}^n E \left\{ - \frac{f'(V_{(r_{m+j})})}{f(V_{(r_{m+j})})} \right\}. \quad (4.75)$$

由此即得到本定理的结论.

若以 $U_{(1)} \leq \dots \leq U_{(N)}$ 记 $R(0,1)$ 的次序样本, 则

$$V_{(i)} \stackrel{d}{=} F(U_{(i)}), \quad i = 1, \dots, N.$$

由 (4.73) 式得 LMPRT 的计分函数为

$$a_N(i) = -E \left\{ \frac{f'(F^{-1}(U_{(i)}))}{f(F^{-1}(U_{(i)}))} \right\}. \quad (4.76)$$

按 (4.41) 式, 上式右边正是 $E(\phi_F(U_{(i)}))$. 于是由定理 4.2 及公式 (4.37) 后面的推论 2, 得到如下的结果:

定理 4.5 由定理 4.4 决定的 LMPRT 也是使效率因子达到最大的秩检验.

从某种意义上说, 定理 4.5 的结论是可以预见的. 因为“效率因子大”所要求的是: 当 θ 很接近 θ_0 时, 为在 θ 处达到一定的功效, 样本数目需要得少, 换一种方式说, 在给定样本大小之后, 对接近于 θ_0 的 θ 处功效值尽可能大, 而这正是 LMPRT 所要求的.

定理 4.4 给出了下述有趣的事实: 根据定理 4.2 及 (4.37) 式后面的推论 2, 由以下两个计分函数

$$\phi_F\left(\frac{i}{N+1}\right), \quad i = 1, \dots, N \quad \text{及} \quad E(\phi_F(U_{(i)})), \quad i = 1, \dots, N$$

所确定的秩检验,同时具有最大的效率因子.根据这个准则,二者无优劣之分,但根据定理 4.4,后者是 LMPRT,而前者则不然.因此按局部最优的准则而言,可以说后者优于前者.

回到定理 4.4,这个定理的主要条件是(4.72)式右边在 $\theta = 0$ 处能在期望号下对 θ 求导,即(4.75)式成立.满足这条件的一个比较容易验证的情况如下:

引理 4.3 设存在函数 g_1, g_2 及常数 $\delta > 0$, 使对一切的 x 及 $|\theta| \leq \delta$, 有

$$|f'(x - \theta)| \leq g_1(x), \quad f(x - \theta) \leq g_2(x). \quad (4.77)$$

以及

$$E\left\{g_1(V_1) \prod_{i=2}^N g_2(V_i) / \prod_{i=1}^N f(V_i)\right\} < \infty \quad (4.78)$$

($V_1, \dots, V_N \sim F(x)$), 则对 $(1, \dots, N)$ 的任一置换 r , (4.75) 式成立.

证 以 K 记 $(1, \dots, N)$ 的一切置换的集, 则由(4.78)式,

$$\begin{aligned} E\left\{g_1(V_1) \prod_{i=2}^N g_2(V_i) / \prod_{i=1}^N f(V_i)\right\} &< \infty \\ &= \sum_{r \in K} P(R = r) E\left\{g_1(V_1) \prod_{i=2}^N g_2(V_i) / \prod_{i=1}^N f(V_i) \mid R = r\right\}. \end{aligned} \quad (4.79)$$

式中 $R = (R_1, \dots, R_N)$, 而 R_i 是 V_i 在 $V_1, \dots, V_N$ 中的秩. 由于 $V_1, \dots, V_N$ 为 iid. 且分布连续, 知 $P(R = r) = 1/N!$ 对任何 $r = (r_1, \dots, r_N) \in K$ 成立. 故由(4.79)式, 得

$$\frac{1}{N!} \sum_{r \in K} E\left\{g_1(V_{(r_1)}) \prod_{i=2}^N g_2(V_{(r_i)}) / \prod_{i=1}^N f(V_{(r_i)})\right\} < \infty. \quad (4.80)$$

$V_{(1)} \leq \dots \leq V_{(N)}$ 为 $V_1, \dots, V_N$ 的次序统计量. 由(4.80)式即得对任何 $r \in K$, 有

$$E\left\{g_1(V_{(r_1)}) \prod_{i=2}^N g_2(V_{(r_i)}) / \prod_{i=1}^N f(V_{(r_i)})\right\} < \infty. \quad (4.81)$$

现以 $\frac{1}{N!} q(\theta)$ 记(4.72)式的右边, 则有

$$\begin{aligned} \frac{q(\theta) - q(0)}{\theta} &= E\left\{\frac{1}{\theta} \left[\prod_{j=1}^n f(V_{(r_{m+j})}) - \theta \right] - \prod_{j=1}^n f(V_{(r_{m+j})}) \right\} / \prod_{j=1}^n f(V_{(r_{m+j})}) \\ &= \sum_{j=1}^n E\left\{f'(V_{(r_{m+j})}) - \theta^* \right\} \prod_{\substack{i=1 \\ i \neq j}}^n f(V_{(r_{m+i})}) / \prod_{i=1}^n f(V_{(r_{m+i})}), \end{aligned} \quad (4.82)$$

式中 $0 \leq \theta^* \leq \theta$. 根据(4.77)式, 当 $0 < \theta < \delta$ 时, 有

$$\begin{aligned} & \left| f'(V_{(r_{m+j})} - \theta^*) \prod_{\substack{i=1 \\ i \neq j}}^n f(V_{(r_{m+i})} - \theta^*) / \prod_{i=1}^n f(V_{(m+i)}) \right| \\ & \leq g_1(V_{(r_{m+j})}) \prod_{\substack{i=1 \\ i \neq j}}^n g_2(V_{(r_{m+i})}) / \prod_{i=1}^n f(V_{(r_{m+j})}). \end{aligned} \quad (4.83)$$

因为(4.77)式对 $\theta = 0$ 成立, 知 $f(x) \leq g_2(x)$. 故若记

$$\tilde{r} = (\tilde{r}_1, \dots, \tilde{r}_N) = (r_{m+j}, \dots, r_N, r_1, \dots, r_{m+j-1}).$$

则(4.83)式右边不超过

$$g_1(V_{(\tilde{r}_1)}) \prod_{i=2}^N g_2(V_{(\tilde{r}_i)}) / \prod_{i=1}^N f(V_{(\tilde{r}_i)}). \quad (4.84)$$

而根据(4.81)式知(4.84)式的期望有限. 这表明(4.83)式左边被一与 θ 无关且可积的量所控制. 利用控制收敛定理, 在(4.82)式中令 $\theta \rightarrow 0$ 即得(4.75). 引理证毕.

注意 条件(4.78)可写为更明白的形式:

$$\int_{-\infty}^{\infty} \cdots \int g_1(x_1) g_2(x_2) \cdots g_2(x_n) dx_1 \cdots dx_n < \infty. \quad (4.85)$$

例 4.5 设 $F(x) = \Phi(x)$, 则

$$f(x) = F'(x) + \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

取

$$g_1(x) = g_2(x) = M e^{-x^2/3},$$

M 为充分大的常数. 不难验证(4.85)式成立. 且当 $\delta > 0$ 充分小时, (4.77)式成立.

又如, 设

$$F(x) = \frac{e^x}{1 + e^x} \text{ (logistic 分布)},$$

则

$$f(x) = e^{-x} (1 + e^{-x})^{-2}.$$

取

$$g_1(x) = g_2(x) = M e^{-|x|/2},$$

不难验证(4.85)式成立, 且当 $\delta > 0$ 充分小时, (4.77)式成立.

因此, 对上述 F 而言, Fisher-Yates 检验和 Wilcoxon 检验 LMPRT.

4.2.3 对称性检验问题的 LMPRT

设 $Z_1, \dots, Z_N \sim F(x - \theta)$, $F(x)$ 是关于 0 对称的分布函数, F 的密度记为 f . 本段讨论检验问题

$$H: \theta = 0 \leftrightarrow K: \theta > 0 \quad (4.86)$$

的 LMPRT. 引进以下的记号:

$$R_i^+ = |Z_i| \text{ 在 } (|Z_1|, \dots, |Z_n|) \text{ 中的秩}, R^+ = (R_1^+, \dots, R_N^+);$$

$$\phi_i = I_{(Z_i > 0)}, \Psi = (\phi_1, \dots, \phi_N);$$

$$d_i = 1 \text{ 或 } 0, d = (d_1, \dots, d_N), |d| = d_1 + \dots + d_N;$$

$F_\theta(x | 0) = P_\theta(-Z_1 < x | Z_1 < 0)$, 即在 $Z_1 < 0$ 的条件下, $-Z_1$ 的条件分布函数. 由于 $Z_1 \sim F(x - \theta)$, 有

$$F_\theta(x | 0) = \begin{cases} \frac{F(x + \theta) - F(\theta)}{1 - F(\theta)}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

其密度函数为

$$F_\theta(x | 0) = \begin{cases} \frac{f(x + \theta)}{1 - F(\theta)}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

(在推导中用到了 $F(x)$ 连续且关于 0 对称.)

$$\begin{aligned} F_\theta(x | 1) &= P_\theta(Z_1 < x | Z_1 > 0) \\ &= \begin{cases} \frac{F(x - \theta) - f(-\theta)}{F(\theta)}, & x > 0; \\ 0, & x \leq 0. \end{cases} \end{aligned}$$

它是在 $Z_1 > 0$ 的条件下, Z_1 的条件分布函数, 其密度函数为

$$F_\theta(x | 1) = \frac{f(x - \theta)}{F(\theta)} \text{ 或 } 0.$$

视 $x > 0$ 或 $x \leq 0$ 而定.

$K = (1, \dots, N)$ 的一切置换的集.

注意当 $\theta = 0$ 时, 两分布 $F_0(x | 0)$ 与 $F_0(x | 1)$ 有相同的支撑 (即 $f_0(x | 0)$ 与 $f_0(x | 1)$ 大于 0 的集相同).

引理 4.4 对任何 $r = (r_1, \dots, r_N) \in K$ 及 $d = (d_1, \dots, d_N)$ 记

$$\{i: d_i = 1\} = \{w_1, \dots, w_{|d|}\};$$

$$\{i: d_i = 0\} = \{1, \dots, N\} - \{w_1, \dots, w_{|d|}\} \triangleq \{q_1, \dots, q_t\};$$

$$u_i = r_{w_i} (i = 1, \dots, |d|); \quad v_j = r_{q_j} (j = 1, \dots, t).$$

则有

$$P_\theta(\Psi = d, R^+ = r) = \frac{1}{N!2^N} \mathbf{E} \left\{ \frac{\prod_{i=1}^{|d|} f(V_{(u_i)} - \theta) \prod_{j=1}^t f(V_{(v_j)} + \theta)}{\prod_{i=1}^N f(V_{(i)})} \right\}, \quad (4.87)$$

式中 $V_{(1)} \leq \dots \leq V_{(N)}$ 为自分布 $F^*(x) = \max(0, 2F(x) - 1)$ 中抽出的次序样本.

证 因为

$$P_\theta(\Psi = d, R^+ = r) = P_\theta(\Psi = d) P_\theta(R^+ = r | \Psi = d), \quad (4.88)$$

而

$$P_\theta(\Psi = d) = (F(\theta))^{|d|} (1 - F(\theta))^t; \quad (4.89)$$

$$P_\theta(R^+ = r | \Psi = d) = \int_A \dots \int \prod_{i=1}^N f_\theta(x_i | d_i) \cdot dx_1 \dots dx_N. \quad (4.90)$$

此处

$$A = \{(x_1, \dots, x_N) : x_i > 0, x_i \text{ 在 } x_1, \dots, x_N \text{ 中的秩为 } r_i (i = 1, \dots, N)\}.$$

$F^*(x)$ 有密度函数 $f^*(x) = 2f(x)I_{(x>0)}$. 将(4.90)式改写为

$$P_\theta(R^+ = r | \Psi = d) = \frac{1}{N!} \int_{0 < x_1 < \dots < x_N} \dots \int \prod_{i=1}^N \frac{f_\theta(x_{r_i} | d_i)}{2f(x_{r_i})} \cdot N! \prod_{i=1}^N f^*(x_i) dx_1 \dots dx_N. \quad (4.91)$$

因为 $N! \prod_{i=1}^N f^*(x_i)$ 是 $(V_{(1)}, \dots, V_{(N)})$ 在 $0 < x_1 < \dots < x_N$ 上的密度函数, 可将(4.91)式写为

$$P_\theta(R^+ = r | \Psi = d) = \frac{1}{N!} \mathbf{E} \left\{ \prod_{i=1}^N \frac{f_\theta(V_{(r_i)} | d_i)}{2f(V_{(r_i)})} \right\}. \quad (4.92)$$

由 u_i, v_j 的定义及 $f_\theta(x | 0)$ 和 $f_\theta(x | 1)$ 的表达式, 得

$$P_\theta(R^+ = r | \Psi = d)$$

$$= \frac{1}{N!2^N(1 - F(\theta))^t(F(\theta))^{|d|}} \mathbf{E} \left\{ \frac{\prod_{i=1}^{|d|} f(V_{(u_i)} - \theta) \prod_{j=1}^t f(V_{(v_j)} + \theta)}{\prod_{i=1}^N f(V_{(i)})} \right\}. \quad (4.93)$$

结合(4.88)、(4.89)和(4.93)式,即得(4.87)式.引理证毕.

特别,当 $\theta = 0$ 时,得到

$$P_0(\Psi = d, R^+ = r) = (N!2^N)^{-1}. \quad (4.94)$$

这从对称性的角度看是一目了然的.

如果(4.87)式右边能在 $\theta = 0$ 处在期望号下求导,则可得

$$\begin{aligned} & \frac{d}{d\theta} P_\theta(\Psi = d, R^+ = r) |_{\theta=0} \\ &= \frac{1}{N!2^N} \left\{ - \sum_{i=1}^{|d|} E \left(\frac{f'(V_{(u_i)})}{f(V_{(u_i)})} \right) + \sum_{j=1}^t E \left(\frac{f'(V_{(v_j)})}{f(V_{(v_j)})} \right) \right\} \\ &= \frac{1}{N!2^N} \sum_{i=1}^N E \left(\frac{f'(V_{(i)})}{f(V_{(i)})} \right) - \frac{2}{N!2^N} \sum_{i=1}^{|d|} E \left(\frac{f'(V_{(u_i)})}{f(V_{(u_i)})} \right). \end{aligned} \quad (4.95)$$

(4.95)式最后一等式后面第一项只与 N 有关.因此,

$$\frac{d}{d\theta} P_\theta(\Psi = d, R^+ = r) |_{\theta=0}$$

的大小完全取决于

$$- \sum_{i=1}^{|d|} E \frac{f'(V_{(u_i)})}{f(V_{(u_i)})}$$

的大小.由此,按与定理4.4完全一样的推理,得到下面的定理:

定理4.6 若对任何 $r \in K$ 及 d , (4.95)式成立,则检验问题(4.86)式的LMPRT存在且有如下的形式:令

$$a_N^+(i) = -E \left\{ \frac{f'(V_{(i)})}{f(V_{(i)})} \right\}, \quad i = 1, \dots, N, \quad (4.96)$$

$V_{(1)} \leq \dots \leq V_{(N)}$ 的意义如引理4.4中所示,令

$$S_N^+ = \sum_{i=1}^N \psi_i a_N^+(R_i^+)$$

(R_i^+ 与 ψ_i 的意义见本段开始处),取 $\{S_N^+ > c_N\}$ 为否定域, c_N 的取法由检验水平 α 确定(利用(4.94)式).

将此定理与定理4.3对照并注意(4.55)及(4.37)式的推论2(这个推论对于对称性检验问题也有效),即见:由本定理决定的LMPRT也是使效率因子达到最大的符号秩检验.

关于(4.95)式成立的条件有下述引理,它的形式和证明与引理4.3完全相似.

引理4.5 设存在函数 g_1, g_2 及常数 $\delta > 0$, 使(4.77)和(4.78)式成立,但

在(4.78)式中 $V_1, \dots, V_N \sim F^*(x)$, 则对任何 $r \in K$ 及 d , (4.95) 式成立.

例 4.5 的讨论也可以移用于此处(注意, $N(0,1)$ 和 logistic 分布是关于 0 对称的).

4.3 对称中心与位置参数的估计

上面讨论了一个分布的对称中心的检验问题以及两个分布的位置参数差的检验问题. 利用估计和检验之间的一般联系, 可以把前面讨论中引进的概念和方法用于这些参数的估计问题.

4.3.1 对称中心的区间估计

设 $Z_1, \dots, Z_N \sim F(x - \theta)$, $F(x)$ 为关于 0 对称的连续分布函数, 要作对称中心 θ 的区间估计. 给定置信系数 $1 - \alpha$ ($0 < \alpha < 1$).

此处 θ 是分布的中位数, 故在第 1 章中提出的用次序统计量作总体 p 分位数区间估计的方法也适用于此处. 但此处由于假定了分布的对称性, 故能从更多的途径来处理 θ 的估计问题.

找统计量 $T = T(Z_1, \dots, Z_N)$, 具以下两个性质:

1° 当参数值为 0 时, $T(Z_1, \dots, Z_N)$ 的分布与 F 无关(当然, F 应连续且关于 0 对称);

2° 当 θ 增加时, $T(Z_1 - \theta, \dots, Z_N - \theta)$ 非增, 对一切 $(Z_1, \dots, Z_N)$ 成立.

换常数 d_1, d_2 , 使

$$P_0(T < d_1) = \frac{\alpha}{2}, \quad P_0(T > d_2) = \frac{\alpha}{2}. \quad (4.97)$$

P_θ 表示概念是在 $Z_1, \dots, Z_N \sim F(x - \theta)$ 的条件下计算的. 另外, 在 T 是秩统计量的情况, 往往不存在 d_1, d_2 使 (4.97) 式确切地成立. 这时, 可找 d_1, d_2 , 使 $P_0(T < d_1)$ 和 $P_0(T > d_2)$ 尽可能地接近 $\alpha/2$, 而把置信系数 $1 - \alpha$ 的值略加调整, 也可以用随机化方法. 参看文献[110] 中第 3 章.

根据对 T 的假定 2°, 可找到 $\hat{\theta}_i = \hat{\theta}_i(Z_1, \dots, Z_N)$, 使

$$T(Z_1 - \theta, \dots, Z_N - \theta) \leq d_2 \Leftrightarrow \theta \geq \hat{\theta}_1; \quad (4.98)$$

$$T(Z_1 - \theta, \dots, Z_N - \theta) \geq d_1 \Leftrightarrow \theta \leq \hat{\theta}_2. \quad (4.99)$$

这时有

$$\begin{aligned} P_\theta(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) &= P_\theta(d_1 \leq T(Z_1 - \theta, \dots, Z_N - \theta) \leq d_2) \\ &= P_0(d_1 \leq T(Z_1, \dots, Z_N) \leq d_2) = 1 - \alpha. \end{aligned} \quad (4.100)$$

即 $[\hat{\theta}_1, \hat{\theta}_2]$ 是 θ 的置信系数为 $1 - \alpha$ 的区间估计. 若(4.97)式不是严格的等式, 则(4.100)式的最后一步也只能是近似成立而非严格相等.

另外, 在具体问题中, (4.98)式和(4.99)式的右边有可能会改为 $\theta > \hat{\theta}_1$ 和 $\theta < \hat{\theta}_2$ (也可以一个改, 一个不改), 这样, θ 的置信区间也要相应地改为 $(\hat{\theta}_1, \hat{\theta}_2)$ 或 $[\hat{\theta}_1, \hat{\theta}_2)$ 或 $(\hat{\theta}_1, \hat{\theta}_2]$. 但在许多情况下这一修改并无必要, 见下例的说明.

例 4.6 取 $T(Z_1, \dots, Z_N)$ 为 Wilcoxon 符号秩统计量

$$W^+ = W^+(Z_1, \dots, Z_N).$$

它适合对 T 的两条要求: 第一条要求由(4.94)式直接推出. 为验证要求2°, 根据(2.9)式, 由此得出

$$\begin{aligned} W^+(Z_1, \dots, Z_N) &= \sum_{1 \leq i \leq j \leq N} \Psi(Z_i + Z_j) \\ &= \sum_{1 \leq i \leq j \leq N} \Psi\left(\frac{Z_i + Z_j}{2}\right). \end{aligned}$$

此处 $\Psi(x) = I_{(x > 0)}$. 由此得

$$W^+(Z_1 - \theta, Z_N - \theta) = \sum_{1 \leq i \leq j \leq N} \Psi\left(\frac{Z_i + Z_j}{2} - \theta\right). \quad (4.101)$$

由此即看出条件2°成立.

W^+ 只取整数 $0, 1, \dots, N(N+1)/2$ 为值, 且易见当 $\theta = 0$ 时, W^+ 的分布关于 $N(N+1)/4$ 对称(这个简单事实的证明留给读者). 找 d_2 , 使

$$\sum_{i=d_2+1}^{N(N+1)/2} P_0(W^+ = i) = \frac{\alpha}{2} \quad (\text{或近似相等}). \quad (4.102)$$

令

$$d_1 = \frac{N(N+1)}{2} - (d_2 + 1),$$

则由上述对称性有

$$\sum_{i=0}^{d_1} P_0(W^+ = i) = \sum_{i=d_2+1}^{N(N+1)/2} P_0(W^+ = i) = \frac{\alpha}{2}.$$

现在要定出集合

$$A_1 = \{\theta: W^+(Z_1 - \theta, \dots, Z_N - \theta) \leq d_2\}$$

及

$$A_2 = \{\theta: W^+(Z_1 - \theta, \dots, Z_N - \theta) > d_1\}.$$

为此, 把 $N(N+1)/2 \triangleq N'$ 个数 $\{(Z_i + Z_j)/2; 1 \leq i \leq j \leq N\}$ 按大小排列为 $W_{(1)} \leq \dots \leq W_{(N')}$. 则见

$$A_1 = \{\theta: \theta \geq W_{(N'-d_2)}\}, \quad A_2 = \{\theta: \theta < W_{(d_2+1)}\}.$$

于是得到 θ 的一个置信系数 $1 - \alpha$ 的区间估计为

$$[W_{(N'-d_2)}, W_{(d_2+1)}]. \quad (4.103)$$

其中, d_2 由 (4.102) 式决定, 若 (4.102) 式只是近似成立, 则 (4.103) 式的置信系数也只是近似地为 $1 - \alpha$.

因为假定了 F 是连续分布, 故对任何固定的 i , $W_{(i)}$ 的分布连续, 从而 $P_\theta(W_{(i)} = \theta) = 0$. 由此可知

$$P_\theta(W_{(N'-d_2)} \leq \theta < W_{(d_2+1)}) = P_\theta(W_{(N'-d_2)} \leq \theta \leq W_{(d_2+1)}).$$

这说明: 若把半开半闭的置信区间 (4.103) 式修改为两端都闭的区间时, 置信系数无变化. 这一论证适合于许多类似的情况.

在此例中使用了 Wilcoxon 符号秩统计量, 自然是由 $\theta = 0$ 的检验问题启发而来, 但检验 $\theta = 0$ 的符号秩统计量有很多, 因而可以构造出许多这样的区间估计. 这些区间估计的优劣取决于分布 $F(x)$ 的性质. 这与检验问题相似. 下面还要回到这个问题.

如上所述, 在样本大小 N 固定时, 不一定能造出 θ 的区间估计使其置信系数确切地等于所给定的 $1 - \alpha$. 但在 $N \rightarrow \infty$ 时, 不难造出 θ 的置信区间. 其置信系数趋于给定的 $1 - \alpha$. 为此, 设统计量 $T_N = T_N(Z_1, \dots, Z_N)$ 除满足前述性质 1°, 2° 外, 还具有渐近正态性: 存在常数 μ_N 及 σ_N^2 (都已知), 使当 $N \rightarrow \infty$ 而参数 $\theta = 0$ 时, 有

$$\frac{T_N - \mu_N}{\sigma_N} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.104)$$

令

$$d_{1N} = \mu_N - \sigma_N u_{\alpha/2}, \quad d_{2N} = \mu_N + \sigma_N u_{\alpha/2}.$$

将 (4.98) 式与 (4.99) 式中的 T 改为 T_N , d_i 改为 d_{iN} ($i = 1, 2$), 而决定 $\hat{\theta}_{iN}$ ($i = 1, 2$). 则有

$$\begin{aligned} P_\theta(\hat{\theta}_{1N} \leq \theta \leq \hat{\theta}_{2N}) &= P_\theta(d_{1N} \leq T_N(Z_1 - \theta, Z_N - \theta) \leq d_{2N}) \\ &= P_0(d_{1N} \leq T_N(Z_1, \dots, Z_N) \leq d_{2N}) \\ &= P_0(-u_{\alpha/2} \leq (T_N - \mu_N)/\sigma_N \leq u_{\alpha/2}) \rightarrow 1 - \alpha. \end{aligned}$$

即 $[\hat{\theta}_{1N}, \hat{\theta}_{2N}]$ 是渐近置信系数 $1 - \alpha$ 的区间估计.

这结果的优点在于(4.104)式只要求在 $\theta = 0$ 一点处成立. 而由于统计量 T_N 在 $\theta = 0$ 时的分布与 F 无关, 其均值 μ_N 和方差 σ_N^2 只依赖于 N , 因而是已知的. 就是说(4.104)式中 μ_N 和 σ_N^2 为已知这一点, 是一个可以由基本假定推出的事实, 而不是一项附加要求.

例 4.7 回到例 4.6. 根据例 3.9((3.110)式)知对 Wilcoxon 符号秩统计量 W_N^+ 而言, 条件(4.104)满足, 且

$$\mu_N = \frac{N(N+1)}{4},$$

$$\sigma_N^2 = \frac{N(N+1)(2N+1)}{24}$$

于是可取

$$d_{1N} = \frac{N(N+1)}{4} - u_{\alpha/2} \left(\frac{N(N+1)(2N+1)}{24} \right)^{1/2},$$

$$d_{2N} = \frac{N(N+1)}{4} + u_{\alpha/2} \left(\frac{N(N+1)(2N+1)}{24} \right)^{1/2},$$

并记 $q_N = [d_{2N}]$. 根据(4.103)式, 得 $[W_{(N'-q_N)}, W_{(q_N+1)}]$ 为 θ 的一个渐近置信系数 $1 - \alpha$ 的区间估计.

若从符号检验出发, 则取

$$T_N = T_N(Z_1, \dots, Z_N) = \sum_{i=1}^N I_{(Z_i > 0)},$$

当 $\theta = 0$ 时, T_N 服从二项分布 $B(N, 1/2)$. (4.97)式中的 d_2 由等式

$$\sum_{i=d_2+1}^N \binom{N}{i} 2^{-N} = \frac{\alpha}{2} \quad (4.105)$$

决定, 而 $d_1 = N - d_2$. 按(4.98)式与(4.99)式决定的置信区间是 $[Z_{(N-d_2)}, Z_{(d_2+1)}]$ (其真实的置信系数是(4.105)左边的两倍, 若(4.105)式只是近似成立), 此处 $Z_{(1)} \leq \dots \leq Z_{(N)}$ 是 $Z_1, \dots, Z_N$ 的次序统计量. 由于分布连续, 将置信区间改为 $[Z_{(N-d_2)}, Z_{(d_2+1)}]$ 并不改变置信系数. 这与在第1章中用次序统计量方法得到的结果一样.

在 $\theta = 0$ 时, 有

$$\left(T_N - \frac{N}{2} \right) / \sqrt{\frac{N}{4}} \xrightarrow{\mathcal{L}} N(0, 1).$$

故可以取

$$d_{1N} = \frac{N}{2} - u_{\alpha/2} \sqrt{\frac{N}{4}}, \quad d_{2N} = \frac{N}{2} + u_{\alpha/2} \sqrt{\frac{N}{4}}.$$

记 $q_N = [d_{2N}]$, 作出 θ 的一个渐近置信系数 $1 - \alpha$ 的区间估计是

$$[Z_{(N-q_N)}, Z_{(q_N+1)}].$$

4.3.2 位置参数的区间估计

设 $X_1, \dots, X_m \sim F(x), Y_1, \dots, Y_n \sim F(x - \theta)$. $F(x)$ 为连续分布函数, 要作位置参数 θ 的区间估计, 给定置信系数 $1 - \alpha$.

步骤与估计对称中心相似: 找统计量

$$T = T(X_1, \dots, X_m, Y_1, \dots, Y_n),$$

具有以下两个性质:

1° 当 $\theta = 0$ 时, T 的分布与 F 无关(当然, F 应为连续的);

2° 当 θ 增加时, $T(X_1, \dots, X_m, Y_1 - \theta, \dots, Y_n - \theta)$ 非增.

找常数 d_1, d_2 , 使(4.97)式成立. 再根据性质 2°, 找出

$$\hat{\theta}_i = \hat{\theta}_i(X_1, \dots, X_m, Y_1, \dots, Y_n), \quad i = 1, 2$$

使

$$T(X_1, \dots, X_m, Y_1 - \theta, \dots, Y_n - \theta) \leq d_2 \Leftrightarrow \theta \geq \hat{\theta}_1; \quad (4.106)$$

$$T(X_1, \dots, X_m, Y_1 - \theta, \dots, Y_n - \theta) \geq d_1 \Leftrightarrow \theta \leq \hat{\theta}_2. \quad (4.107)$$

则与对称中心情况同样的推理, 知 $[\hat{\theta}_1, \hat{\theta}_2]$ 为 θ 的一个置信系数 $1 - \alpha$ 的区间估计. 若(4.97)式只是近似成立, 则将置信系数作相应调整. 又(4.106)式和(4.107)式的右边都可以是开的, 这时 θ 的置信区间也相应地改为开或半开的, 在一般情况下, 这一改动不影响置信系数.

大样本区间估计的做法也与对称中心的情况相似: 设存在 μ_{mn} 和 σ_{mn}^2 , 使在 $m, n \rightarrow \infty$ 而参数值 $\theta = 0$ 时, 有(改写 T 为 T_{mn})

$$\frac{T_{mn} - \mu_{mn}}{\sigma_{mn}} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.108)$$

则取

$$d_{1mn} = \mu_{mn} - \sigma_{mn} u_{\alpha/2}, \quad d_{2mn} = \mu_{mn} + \sigma_{mn} u_{\alpha/2}.$$

以 T_{mn}, d_{1mn} 和 d_{2mn} 代替(4.106)式及(4.107)式中的 T, d_1 和 d_2 , 决定 $\hat{\theta}_{imn}$ ($i = 1, 2$), 则 $[\hat{\theta}_{1mn}, \hat{\theta}_{2mn}]$ 为 θ 的一渐近置信系数 $1 - \alpha$ 的置信区间.

适合以上诸条件的 T 的最重要的情况是线性秩统计量

$$T = \sum_{i=1}^n a(R_i),$$

此处 R_i 是 Y_i 在合样本 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 的秩, 且

$$a(1) \leq \dots \leq a(m+n).$$

这样的 T 显然具有性质 1° (这是定理 3.1 的简单推论). 性质 2° 可证明如下:

设 $\theta > 0$, 比较

$$T = \sum_{i=1}^n a(R_i) \quad \text{与} \quad T' = \sum_{i=1}^n a(R'_i).$$

此处 R_i 的意义同上, 而 R'_i 为 $Y_i - \theta$ 在 $(X_1, \dots, X_m, Y_1 - \theta, \dots, Y_n - \theta)$ 中的秩. 将 $Y_1, \dots, Y_n$ 排列为 $Y_{(1)} < \dots < Y_{(n)}$. 以 $\tilde{R}_i$ 记 $Y_{(i)}$ 在 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 中的秩; $\tilde{R}'_i$ 记 $Y_{(i)} - \theta$ 在

$$(X_1, \dots, X_m, Y_1 - \theta, \dots, Y_n - \theta)$$

中的秩. 有

$$T = \sum_{i=1}^n a(\tilde{R}_i), \quad T' = \sum_{i=1}^n a(\tilde{R}'_i). \quad (4.109)$$

但因 $\theta > 0$, 易见

$$\begin{aligned} \tilde{R}'_i &= i + X_1, \dots, X_m \text{ 中小于 } Y_{(i)} - \theta \text{ 的个数} \\ &\leq i + X_1, \dots, X_m \text{ 中小于 } Y_{(i)} \text{ 的个数} = \tilde{R}_i. \end{aligned}$$

因为 $a(\cdot)$ 非降, 有 $a(\tilde{R}'_i) \leq a(\tilde{R}_i)$, 故由 (4.109) 式知 $T' \leq T$. 这就证明了要证的结果. 再根据定理 3.6 知在很一般的条件下, 当 $\theta = 0$ 时, 这样定义的 T 有渐近正态性.

注 4.2 若 $m = n$ 或 $a(i) + a(m+n-i)$ 与 i 无关, 则由定理 3.4 知, 当 $\theta = 0$ 时,

$$T = \sum_{i=1}^n a(R_i)$$

的分布关于 $n\bar{a}$ 对称. 这样在找满足 (4.97) 式的 d_1 和 d_2 时, 只须找出其中一个即可. 因为 $d_1 + d_2 = 2n\bar{a}$.

例 4.8 取 T 为 Wilcoxon 两样本秩和统计量

$$W = \sum_{i=1}^n R_i,$$

有

$$W = \frac{n(n+1)}{2} + U,$$

$$U = \{Y_j - X_i (i = 1, \dots, m; j = 1, \dots, n) \text{ 中大于 } 0 \text{ 的个数}\}$$

((3.6) 式). 可以用 U 代替 W . 当 $\theta = 0$ 时, U 的分布关于点

$$n\bar{a} - \frac{n(n+1)}{2} = n \frac{n+m+1}{2} - \frac{n(n+1)}{2} = \frac{mn}{2}$$

对称, 找 d_1 , 使

$$\sum_{i=d_2+1}^{mn} P_0(U=i) = \frac{\alpha}{2}. \quad (4.110)$$

并取 $d_1 = mn - d_2$ (注 4.1). 由 (4.98) 式和 (4.99) 式决定的 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 不难看出可如下求得:

把 mn 个数 $Y_j - X_i (i=1, \dots, m; j=1, \dots, n)$ 按大小排列为 $U_{(1)} < \dots < U_{(mn)}$, 则

$$\hat{\theta}_1 = U_{(mn-d_2)}, \quad \hat{\theta}_2 = U_{(d_2+1)}. \quad (4.111)$$

θ 的置信区间取为 $[\hat{\theta}_1, \hat{\theta}_2]$. 由于对任何 $i, U_{(i)}$ 有连续分布, 当将 $[\hat{\theta}_1, \hat{\theta}_2]$ 改为 $[\hat{\theta}_1, \hat{\theta}_2]$ 时, 置信系数不变. 自然, 若 (4.110) 式只是近似地成立, 则将 $[\hat{\theta}_1, \hat{\theta}_2]$ 的置信系数作相应的调整.

下面留给读者验证:

$$\text{当 } i \leq \frac{m+n+1}{2} \text{ 时, 取 } a(i) = 0;$$

$$\text{当 } i > \frac{m+n+1}{2} \text{ 时, 取 } a(i) = 1.$$

则得到 θ 的一基于合样本次序统计量的区间估计. 选择不同的 $a(\cdot)$, 可作出 θ 的许多区间估计. 其优劣比较取决于总体分布 F . 换句话说: 若我们对可能的总体分布具有一定的知识, 则有助于选择一个较优的区间估计. 例如, 当 F 为正态时, 通常的 t 区间估计在一定意义下为 θ 的最优区间估计. 但当 F 为 Cauchy 分布时, t 区间估计没有任何优越性, 下一段将从大样本的角度讨论这问题.

注 4.3 关于置信上下限的讨论与置信区间完全是平行的. 以对称中心 θ 的估计来说, 找统计量 $T = T(Z_1, \dots, Z_N)$, 满足 (4.97) 式前面列举的两条性质, 然后在 (4.97) 式中将 $\alpha/2$ 改为 α , 以决定 d_1, d_2 . 最后由 (4.98)、(4.99) 式决定 $\hat{\theta}_1$ 及 $\hat{\theta}_2$, 则 $\hat{\theta}_1$ 为 θ 的置信系数 $1-\alpha$ 的置信下限; $\hat{\theta}_2$ 为 θ 的置信系数 $1-\alpha$ 的置信上限, 即

$$P_\theta(\hat{\theta}_1 \leq \theta) = 1 - \alpha, \quad P_\theta(\hat{\theta}_2 \geq \theta) = 1 - \alpha.$$

证明与区间的情况略无差异. 位置参数的情况也完全类似.

4.3.3 置信区间和置信限的渐近相对效率

设在同一组样本 $Z_1, \dots, Z_N$ 的基础上建立了同一参数 θ 的两个有同一(或渐近相等)置信系数 $1 - \alpha$ 的置信区间 I_N 和 J_N . 如果 I_N 比 J_N 短, 则 I_N 优于 J_N . 这个思想可以用另一种(不完全等价的)方式表述. 设 $\alpha \approx 0$, 则 $1 - \alpha \approx 1$. 当参数真值为 θ 时, $P_\theta(\theta \in I_N) \approx 1$. 即 I_N 以很大的可能性包含 θ . 取定 $\theta' \neq \theta$. 因为 I_N 要包含 θ 而 I_N 又很短, 故它不大可能同时也包含 θ' . 换言之, 若 I_N 优于 J_N , 则当 $\theta' \neq \theta$ 时, $P_\theta(\theta \in I_N)$ 应小于 $P_\theta(\theta' \in J_N)$. 为了把后者降低到和 $P_\theta(\theta' \in I_N)$ 一样, 就需要提高样本大小. 设

$$P_\theta(\theta' \in I_N) = P_\theta(\theta' \in J_{N'}),$$

则可以把 N'/N 称为 I_N 对 J_N 的相对效率. 这个值与所选择的置信系数 $1 - \alpha$ 、点 θ' 及样本大小 N 有关, 为了摆脱这个依赖性, 采取一种与在假设检验情况下相似的极限步骤, 即在样本大小 $N \rightarrow \infty$ 的同时使 $\theta' \rightarrow \theta$, 而 $P_\theta(\theta' \in I_N)$ 则趋于一个非 0 但小于 $1 - \alpha$ 的数 $1 - \beta$.

另一点要注意的是: 下文在谈到区间估计 I_N 与 J_N 时, 都是指一类的区间估计, 而非一特定的区间估计. 例如, 在谈到“ t 区间估计”时, 是指形如 $\bar{x} \pm t_{N-1, \alpha/2} s$ 的任何区间估计. 适当选择其中的参数 α , 可使之具有任何给定的置信系数.

在作了这些解释后, 现可引进下述定义:

定义 4.3 设对任何指定的 $\alpha, \beta (0 < \alpha < \beta < 1)$ 及固定的 θ^* 和一串 $\theta_k \rightarrow \theta^*$, 总可以适当调整 I_N 和 J_N 中的有关常数, 使

1° I_N, J_N 的渐近置信系数都是 $1 - \alpha$;

2° 存在两个自然数子列 $\{N_k\}$ 若 $\{N_k'\}$, 使

$$\lim_{k \rightarrow \infty} P_{\theta^*}(\theta_k \in I_{N_k}) = \lim_{k \rightarrow \infty} P_{\theta^*}(\theta_k \in J_{N_k'}) = 1 - \beta. \quad (4.112)$$

若对任何满足条件(4.112)的 $\{N_k\}$ 和 $\{N_k'\}$, 极限

$$\lim_{k \rightarrow \infty} \frac{N_k'}{N_k}$$

存在(可为 ∞), 且与 α, β, θ^* 及 $\theta_k \uparrow \theta^*$ 的选择无关, 则称这极限是区间估计 I 对区间估计 J 的渐近相对效率, 记为 $\text{ARE}(I, J, F)$.

本定义中出现的分布 F , 其意义与在假设检验的 ARE 的定义中一样, 是总体分布. 例如以对称中心的估计来说, 总体分布 F 关于 0 对称, 样本 $Z_1, \dots, Z_N \sim F(x - \theta)$. 要估计的是 θ . 一区间估计的优劣与 F 有关, 因而区间估计的

(渐近)相对效率也与 F 有关.

对置信限的情况有完全类似的定义,以下限为例.

定义 4.4 设 I_N 和 J_N 是同一参数 θ 的基于同一样本 $Z_1, \dots, Z_N$ 的两个置信下限. 设对任何给定的 $\alpha, \beta (0 < \alpha < \beta < 1)$ 及固定的 θ^* 和一串 $\theta_k \uparrow \theta^*$ (确切地说, 是 $\theta_1 \leq \theta_2 \leq \dots < \theta^*, \theta_k \rightarrow \theta^*$), 总可适当调整 I_N 和 J_N 中的有关常数, 使

$$\begin{aligned} 1^\circ & I_N, J_N \text{ 的渐近置信系数都是 } 1 - \alpha; \\ 2^\circ & \text{ 存在两个自然数子列 } \{N_k\} \text{ 和 } \{N_k'\}, \text{ 使} \\ & \lim_{k \rightarrow \infty} P_{\theta^*}(\theta_k \geq I_{N_k}) = \lim_{k \rightarrow \infty} P_{\theta^*}(\theta_k \geq J_{N_k'}) = 1 - \beta. \end{aligned} \quad (4.113)$$

若对任何满足条件(4.113)的 $\{N_k\}$ 和 $\{N_k'\}$, 极限

$$\lim_{k \rightarrow \infty} \frac{N_k'}{N_k}$$

存在(可为 ∞), 且与 α, β, θ^* 用 $\theta_k \uparrow \theta^*$ 的选择无关, 则称这极限是置信下限 I 对置信下限 J 的(渐近)相对效率, 记为 $\text{ARE}(I, J, F)$. F 的意义与定义 6.3 相同.

假设检验的 ARE 的区间估计的 ARE 之间, 有密切的联系. 为确定计, 现就本节所讨论的两个问题——对称中心与位置参数的估计来进行论述.

设 $Z_1, \dots, Z_N \sim F(x - \theta)$, F 连续且关于 0 点对称. 设

$$S_N = S_N(Z_1, \dots, Z_N), \quad T_N = T_N(Z_1, \dots, Z_N)$$

为检验问题

$$\theta = 0 \leftrightarrow \theta > 0$$

的两个检验统计量, 满足定理 4.1 中的全部要求(这意味着 $\text{ARE}(S, T, F)$ 存在). 又设 S_N 和 T_N 满足(4.97)式前面对 $T(Z_1, \dots, Z_N)$ 所提出的两条要求. 由此, 可用注 4.2 中说明的方法, 由 S_N 和 T_N 分别决定 θ 的置信下限 I_N 和 J_N . 有如下的定理:

定理 4.7 在上述条件下有

$$\text{ARE}(I, J, F) = \text{ARE}(S, T, F). \quad (4.114)$$

证 由于 S_N 和 T_N 都满足定理 4.1 的要求, 特别是当参数 θ 的值为 0 时有渐近正态性. 故根据 4.3.1 小节中关于大样本置信区间的论述(见(4.104)式前后一段)知, 对任何 $\alpha \in (0, 1)$, 可使 I_N 和 J_N 的渐近置信系数都为 $1 - \alpha$. 现任取 $\theta^*, \theta_k \uparrow \theta^* (\theta_k < \theta^*)$ 及 $\{N_k\}$ 和 $\{N_k'\}$, 满足(4.113)式. 则由(4.113)式和(4.99)式, 有

$$P_{\theta^*}(I_{N_k}(Z_1, \dots, Z_{N_k}) > \theta_k) = 1 - P_{\theta^*}(I_{N_k}(Z_1, \dots, Z_{N_k}) \leq \theta_k) \rightarrow \beta \quad (4.115)$$

$$P_{\theta^*}(I_{N_k}(Z_1, \dots, Z_{N_k}) > \theta_k) = P_{\theta^*}(S_{N_k}(Z_1 - \theta_k, \dots, Z_{N_k} - \theta_k) > c_{N_k}). \quad (4.116)$$

此处 c_{N_k} 是在定理 4.1 的叙述中提到的, 满足 (4.2) 式的那个 c_N , 注意到当 $Z_i \sim F(x - \theta^*)$ 时, 有 $Z_i - \theta_k \sim F(x - (\theta^* - \theta_k))$, 由 (4.115) 式与 (4.116) 式得

$$P_{\theta^* - \theta_k}(S_{N_k}(Z_1, \dots, Z_{N_k}) > c_{N_k}) \rightarrow \beta. \quad (4.117)$$

类似地对 T_N 进行讨论, 得

$$P_{\theta^* - \theta_k}(T_{N_k}(Z_1, \dots, Z_{N_k}') > d_{N_k}') \rightarrow \beta. \quad (4.118)$$

此处 d_{N_k}' 的意义也见定理 4.1.

由于 $0 < \alpha < \beta < 1$, 又 θ_k 是任一串从小于 θ^* 的方向趋于 θ^* 的数, 故 $\theta^* - \theta_k$ 是任一串从大于 0 的方向趋于 0 的数, 由 (4.117)、(4.118) 式, 按定理 4.1, 即得

$$\lim_{k \rightarrow \infty} \frac{N_k'}{N_k} = \text{ARE}(S, T, F). \quad (4.119)$$

因为 (4.119) 式对任何满足 (4.113) 式的 $\{N_k\}$ 和 $\{N_k'\}$ 都成立, 依定义 4.4 知 $\text{ARE}(I, J, F)$ 存在, 且 (4.114) 式成立. 定理证毕.

对置信上限也有完全对应的结果. 对置信区间而言, 考虑到定理 4.1 及注 4.1, 用定理 4.7 的证法, 可完全类似地得到下面的定理:

定理 4.8 设 $S_N(Z_1, \dots, Z_N)$ 和 $T_N(Z_1, \dots, Z_N)$ 满足定理 4.7 的全部要求, 按 4.3.1 小节的方式分别由 S_N 和 T_N 决定 θ 的置信区间 I_N 和 J_N , 则 (4.114) 式成立.

对位置参数的估计问题, 用完全同样的方法, 得到完全类似的结果:

设 $(Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n)$, $X_1, \dots, X_m \sim F(x)$, $Y_1, \dots, Y_n \sim F(x - \theta)$, 并设 $S_N(Z_1, \dots, Z_N)$ 和 $T_N(Z_1, \dots, Z_N)$ 为检验问题 $\theta = 0 \leftrightarrow \theta > 0$ 的两个检验统计量, 满足定理 4.1 的全部条件 (这一般要求 $\lim_{N \rightarrow \infty} (m/N)$ 存在, 且大于 0 小于 1, 见例 4.2), 又 S_N 和 T_N 满足 4.3.2 小节中对 T 施加的条件 1° 与 2° (见 4.106 式前面). 有:

定理 4.9 在上面所述条件下, 若以 I_N 和 J_N 分别记通过 S_N 和 T_N 用 4.3.2 小节中提出的方法所决定的置信区间及置信上、下限, 则

$$\text{ARE}(I, J, E) = \text{ARE}(S, T, F). \quad (4.120)$$

根据这两个定理,在4.1节和4.2节中对于对称中心和位置参数的秩检验所述的一切,都可以移用于由这些秩统计量所决定的置信区间及置信上下限.例如当 F 为 logistic 分布地,由例 4.8 所决定的置信区间有最大的“效率因子”.若 F 为正态的,则效率因子最大的置信区间是由 Van der Waerden 或 Fisher-Yates 统计量所决定的,等等.

注 4.4 Lehmann 在文献[111]中提出了一种直接基于长度的相对效率的定义如下:

设 I_N 和 J_N 为同一参数 θ 的基于同一样本的两区估计.若对任何 $\alpha \in (0, 1)$, 可适当调整 I_N 和 J_N 中的常数,使其渐近置信系数都是 $1 - \alpha$. 而其长度平方之比 $|I_N^2/J_N^2|$ 当 $N \rightarrow \infty$ 时,依概率收敛于一个与 α 无关的常数 c , 则称 c 为 I 对 J 的依长度 (Length) 计渐近相对效率,记为 $\text{LARE}(I, J, F)$.

Lehmann 证明:在很一般的条件下有

$$\text{LARE}(I, J, F) = \text{ARE}(I, J, F).$$

例如,当 I 为 t 区间估计而 J 是由 Wilcoxon 秩统计量决定的、对称中心或位置参数的区间估计时,上述等号成立.

4.3.4 Hodges-Lehmann 估计

以上各段讨论的都是区间估计问题.本段讨论对称中心和位置参数的点估计.介绍 Hodges 和 Lehmann 于 1963 年在文献[87]中提出的一种估计方法.

先考虑对称中心的估计问题:设

$$Z_1, \dots, Z_N \sim F(x - \theta),$$

F 连续且关于 0 对称,要估计 θ . 为此找一个适当的统计量

$$V = V(Z_1, \dots, Z_N),$$

满足以下两个条件:

- 1° 当 $Z_1, \dots, Z_N$ 固定时, $V(Z_1 + h, \dots, Z_n + h)$ 作为 h 的函数,是非降的;
- 2° 当 $\theta = 0$ 时, $V(Z_1, \dots, Z_N)$ 的分布关于某点 c 对称, c 已知且与 F 无关 (当然, F 应连续且关于 0 对称)

统计量 V 一般是作为假设检验问题 $\theta = 0 \leftrightarrow \theta > 0$ 的检验统计量而提出的, 见例 4.9.

定义 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 如下:

$$\hat{\theta}_1 = \hat{\theta}_1(Z_1, \dots, Z_N) = \sup\{b: V(Z_1 - b, \dots, Z_N - b) > c\}; \quad (4.121)$$

$$\hat{\theta}_2 = \hat{\theta}_2(Z_1, \dots, Z_N) = \inf\{b: V(Z_1 - b, \dots, Z_N - b) < c\}. \quad (4.122)$$

V 的条件 1° 保证了 $\hat{\theta}_1 \leq \hat{\theta}_2$.

令

$$\hat{\theta} = \hat{\theta}(Z_1, \dots, Z_N) = \frac{1}{2}\{\hat{\theta}_1(Z_1, \dots, Z_N) + \hat{\theta}_2(Z_1, \dots, Z_N)\}, \quad (4.123)$$

即以 $\hat{\theta}$ 作为 θ 的估计. 这就是 Hodges 和 Lehmann 提出的估计. 以下简称为 HL 估计.

例 4.9 使用一样本 t 检验, 统计量为

$$V(Z_1, \dots, Z_N) = \frac{\sqrt{N}\bar{Z}}{S},$$

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i,$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2.$$

则易见 $c = 0, \hat{\theta} = \bar{Z}$.

从这个例子可看出两点事实: 一是 V 不必在原假设 $\theta = 0$ 之下有“与分布无关”的性质(即: 在 $\theta = 0$ 时, $V(Z_1, \dots, Z_N)$ 的分布仍可与 F 有关). 这一点与 4.3.1 小节中所述的区间估计不同. 在那里, 要求统计量 T 的分布在 $\theta = 0$ 时与 F 无关(见 (4.97) 式前面的 1°); 二是由 V 决定的估计, 其优劣取决于未知的总体分布 F . 以本例的估计 $\bar{Z}$ 来说: 众所周知, 若 F 为正态, 则 $\bar{Z}$ 在种种意义下的最优性, 而当 F 为 Cauchy 分布时, $\bar{Z}$ 根本无用(在一定意义下). 在 F 为均匀分布 $R(-1/2, 1/2)$ 时, $\bar{Z}$ 不是最优的, 等等. 在本例中, 所选择的 V 是在 F 为正态时的最优检验统计量, 而 $\hat{\theta}$ 作为 θ 的估计, 也正是在这时为最优. 这不是一个偶然的巧合.

例 4.10 若取 V 为符号统计量

$$V(Z_1, \dots, Z_N) = Z_1, \dots, Z_N \text{ 中大于 } 0 \text{ 的个数}.$$

则易见 $c = N/2$, 而

$$\hat{\theta} = \text{med}\{Z_1, \dots, Z_N\},$$

即用样本中位数作为 θ 的估计. 同样, 若取 V 为 Wilcoxon 一样本符号秩统计量 W^+ ((3.16) 式), 不难验证它适合上面对 V 提出的条件 1° 与 2°. 条件 1° 是显然的; 条件 2° 可验证如下: 由定理 3.10 的证明中看出(见 3.106 式): 在 $\theta = 0$ 时,

$$W^+ \stackrel{d}{=} \sum_{i=1}^N i\Psi_i,$$

这里 $\Psi_1, \dots, \Psi_N$ 为 iid. 且

$$P(\Psi_1 = 1) = P(\Psi_1 = 0) = \frac{1}{2}.$$

因此, $i\Psi_i$ 的分布关于 $i/2$ 对称. 因为若干个独立的对称分布变量之和仍为对称变量(这一点直接由“分布对称 $\Leftrightarrow$ 特征函数为实值函数”推出)知, W^+ 的分布对称, 对称中心为

$$\frac{1}{2} \sum_{i=1}^N i = \frac{1}{4} N(N+1) \triangleq c.$$

为求 $\hat{\theta}$, 将

$$M = \frac{1}{2} N(N+1) \text{ 个值 } \left\{ \frac{Z_i + Z_j}{2}; 1 \leq i \leq j \leq N \right\}$$

按大小排列为

$$W_{(1)}^+ \leq W_{(2)}^+ \leq \dots \leq W_{(M)}^+.$$

考虑两个情况:

i) M 为奇数

$$M = 2k + 1, \quad c = k + \frac{1}{2}.$$

此时易求出 $\hat{\theta}_1 = \hat{\theta}_2 = W_{(k+1)}^+$, 故

$$\hat{\theta} = W_{(k+1)}^+.$$

ii) M 为偶数

$$M = 2k, \quad c = k.$$

此时易求出 $\hat{\theta}_1 = W_{(k)}^+, \hat{\theta}_2 = W_{(k+1)}^+$, 而

$$\hat{\theta} = \frac{1}{2} (W_{(k)}^+ + W_{(k+1)}^+).$$

于是, 结合 i)、ii) 两种情况, 得

$$\hat{\theta} = \text{med} \left\{ \frac{Z_i + Z_j}{2}; 1 \leq i \leq j \leq N \right\}. \quad (4.124)$$

本例使用的统计量是非参数性的, 故相应地可将 $\hat{\theta}$ 称为 θ 的“非参数性的估计”. 但对这种称谓的含义应正确理解. 它不过表示: $\hat{\theta}$ 所来自的统计量 V 在 $\theta = 0$ 时的分布与 F 无关, 因而基于 V 的、关于 $\theta = 0$ 的检验是非参数性的(不依赖 F 须属于一定的参数族的要求). 与之相应, 也可以把 θ 的估计 $\hat{\theta}$ 称为非参数的. 但是, 即使在 $\theta = 0$ 时, $\hat{\theta}$ 的分布也依赖于总体分布 F . 一般地说, 这里所谓“非参数估计”, 只是一种带有更大的稳定性(robustness)的估计而已(参看第6章).

现在考虑位置参数的估计问题: 设 $(Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n)$, $X_1, \dots, X_m \sim F(x)$, $Y_1, \dots, Y_n \sim F(x - \theta)$. F 为未知的连续分布函数. 要估计 θ , 为此, 找适当的统计量

$$V = V(Z_1, \dots, Z_N) = V(X_1, \dots, X_m, Y_1, \dots, Y_n). \quad (4.125)$$

满足以下两个条件:

1° 当 $Z_1, \dots, Z_N$ 固定时,

$$V(X_1, \dots, X_m, Y_1 + h, \dots, Y_n + h)$$

是 h 的非降函数;

2° 当 $\theta = 0$ 时, $V(Z_1, \dots, Z_N)$ 的分布关于某点 c 对称, c 已知且与 F 无关 (当然, 应假设 F 连续).

定义 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 如下:

$$\hat{\theta}_1 = \hat{\theta}_1(Z_1, \dots, Z_N) = \sup\{b: V(X_1, \dots, X_m, Y_1 - b, \dots, Y_n - b) > c\}; \quad (4.126)$$

$$\hat{\theta}_2 = \hat{\theta}_2(Z_1, \dots, Z_N) = \inf\{b: V(X_1, \dots, X_m, Y_1 - b, \dots, Y_n - b) < c\}. \quad (4.127)$$

V 的条件 1° 保证了 $\hat{\theta}_1 \leq \hat{\theta}_2$.

令

$$\hat{\theta}(Z_1, \dots, Z_N) = \frac{1}{2} \{ \hat{\theta}_1(Z_1, \dots, Z_N) + \hat{\theta}_2(Z_1, \dots, Z_N) \},$$

即以 $\hat{\theta}$ 作为 θ 的估计.

例 4.11 取

$$V = \sqrt{\frac{mn}{m+n}} \cdot \frac{\bar{Y} - \bar{X}}{S},$$

其中

$$\bar{X} = \frac{1}{M} \sum_{i=1}^M x_i, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i,$$

$$S^2 = \frac{1}{m+n-2} \left\{ \sum_{i=1}^m (X_i - \bar{X})^2 + \sum_{i=1}^n (Y_i - \bar{Y})^2 \right\}.$$

得 $c = 0$ 而 $\hat{\theta} = \bar{Y} - \bar{X}$. 若取 V 为 Wilcoxon 两样本秩和统计量 W . 则易见它适合条件 1°; 条件 2° 由定理 3.4 推出,

$$c = \frac{n(m+n+1)}{2}.$$

不难证明:

$$\hat{\theta} = \text{med}\{Y_j - X_i; i = 1, \dots, m, j = 1, \dots, n\}. \quad (4.129)$$

这个简易的验证留给读者.

又:在例 4.9 和 4.10 中所作的评论,对本例也同样适用.

现在来考虑 Hodges-Lehmann 估计的若干性质.

定理 4.10 不论 θ 是对称中心还是位置参数,上面所定义的 Hodges-Lehmann 估计 $\hat{\theta}$ 有“同变性”,即

$$\hat{\theta}(Z_1 + k, \dots, Z_N + k) = \hat{\theta}(Z_1, \dots, Z_N) + k(\text{对称中心}); \quad (4.130)$$

$$\begin{aligned} & \hat{\theta}(X_1, \dots, X_m, Y_1 + k, \dots, Y_n + k) \\ &= \hat{\theta}(X_1, \dots, X_m, Y_1, \dots, Y_n) + k(\text{位置参数}). \end{aligned} \quad (4.131)$$

此处 k 为任一常数.

证 以(4.130)式为例,依(4.121)式有

$$\begin{aligned} \hat{\theta}(Z_1 + k, \dots, Z_N + k) &= \sup\{b: V(Z_1 + k - b, \dots, Z_N + k - b) > c\} \\ &= \sup\{b' + k: V(Z_1 - b', \dots, Z_N - b') > c\} \\ &= k + \sup\{b': V(Z_1 - b', \dots, Z_N - b') > c\} \\ &= k + \hat{\theta}_1(Z_1, \dots, Z_N). \end{aligned} \quad (4.132)$$

类似地由(4.122)式得

$$\hat{\theta}_2(Z_1 + k, \dots, Z_N + k) = k + \hat{\theta}_2(Z_1, \dots, Z_N). \quad (4.133)$$

由(4.123)式、(4.132)式和(4.133)式即得(4.130). (4.131)式的证明类似.

定理 4.11 设对称中心 θ 的 Hodges-Lehmann 估计 $\hat{\theta}$ 由 V 决定,而 V 除满足在定义 $\hat{\theta}$ 时所加的条件 1° 与条件 2° 之外,还满足条件^①:对于一切 $(Z_1, \dots, Z_N)$, 有

$$V(-Z_1, \dots, -Z_N) = 2c - V(Z_1, \dots, Z_N) \quad (4.134)$$

成立. 则 $\hat{\theta}$ 的分布关于 θ 对称, 并且

$$\hat{\theta}(-Z_1, \dots, -Z_N) = -\hat{\theta}(Z_1, \dots, Z_N) \quad (4.135)$$

对于一切 $(Z_1, \dots, Z_N)$ 成立.

证 由 $\hat{\theta}_1$ 的定义并利用(4.134)式,得

$$\hat{\theta}_1(-Z_1, \dots, -Z_N) = \sup\{b: V(-Z_1 - b, \dots, -Z_N - b) > c\}$$

^①易见:由当 $\theta = 0$ 时, Z_i 的分布关于 0 对称及(4.134)式推出,当 $\theta = 0$ 时, V 的分布关于 c 对称,由此可见,在定义 $\hat{\theta}$ 时 V 加的条件 2° 并不是虚设的.

$$\begin{aligned}
&= \sup\{b: 2c - V(Z_1 + b, \dots, Z_N + b) > c\} \\
&= \sup\{-b: V(Z_1 - b, \dots, Z_N - b) < c\} \\
&= -\inf\{b: V(Z_1 - b, \dots, Z_N - b) < 0\} \\
&= -\hat{\theta}_2(Z_1, \dots, Z_N).
\end{aligned} \tag{4.136}$$

故又有

$$\begin{aligned}
\hat{\theta}_1(Z_1, \dots, Z_N) &= \hat{\theta}_1(-(-Z_1), \dots, -(-Z_N)) \\
&= -\hat{\theta}_2(-Z_1, \dots, -Z_N).
\end{aligned} \tag{4.137}$$

由(4.136)式与(4.137)式得(4.135)式. 利用(4.135)式及(4.130)式, 并注意到 Z_i 的分布关于 θ 对称, 因而

$$Z_i \stackrel{d}{=} 2\theta - Z_i,$$

有

$$\begin{aligned}
\hat{\theta}(Z_1, \dots, Z_N) &\stackrel{d}{=} \hat{\theta}(2\theta - Z_1, \dots, 2\theta - Z_N) \\
&= 2\theta + \hat{\theta}(-Z_1, \dots, -Z_N) \\
&= 2\theta - \hat{\theta}(Z_1, \dots, Z_N).
\end{aligned}$$

这即证明了 $\hat{\theta}$ 的分布关于 θ 点对称. 定理证毕.

对位置参数的 Hodges-Lehmann 估计有类似结果:

定理 4.12 设位置参数 θ 的 Hodges-Lehmann 估计 $\hat{\theta}$ 由 V 决定, 而 V 除满足在定义 $\hat{\theta}$ 时所加的条件 1° 与条件 2° 外, 还满足条件(4.134), 且对一切 k 及 $(Z_1, \dots, Z_N)$ 有

$$V(Z_1 + k, \dots, Z_N + k) = V(Z_1, \dots, Z_N). \tag{4.138}$$

又 F 的分布关于某点 η 对称, 则 $\hat{\theta}$ 的分布关于 θ 对称, 且(4.135)式成立.

证 由 $\hat{\theta}_1$ 的定义及(4.134)式, 有

$$\begin{aligned}
&\hat{\theta}_1(-X_1, \dots, -X_m, -Y_1, \dots, -Y_n) \\
&= \sup\{b: V(-X_1, \dots, -X_m, -Y_1 - b, \dots, -Y_n - b) > c\} \\
&= \sup\{b: 2c - V(X_1, \dots, X_m, Y_1 + b, \dots, Y_n + b) > c\} \\
&= \sup\{b: V(X_1, \dots, X_m, Y_1 + b, \dots, Y_n + b) < c\} \\
&= \sup\{-b: V(X_1, \dots, X_m, Y_1 - b, \dots, Y_n - b) < c\} \\
&= -\inf\{b: V(X_1, \dots, X_m, Y_1 - b, \dots, Y_n - b) < c\} \\
&= -\hat{\theta}_2(X_1, \dots, X_m, Y_1, \dots, Y_n).
\end{aligned} \tag{4.139}$$

再由此式得

$$\hat{\theta}_2(-X_1, \dots, -X_m, -Y_1, \dots, -Y_n) = -\hat{\theta}_1(X_1, \dots, X_m, Y_1, \dots, Y_n).$$

由此式及(4.139)式得(4.135)式. 又由(4.131)式和(4.138)式及 F 关于 η 点对称, 有

$$\begin{aligned} & \hat{\theta}(X_1, \dots, X_m, Y_1, \dots, Y_n) \\ &= \theta + \hat{\theta}(X_1, \dots, X_m, Y_1 - \theta, \dots, Y_n - \theta) \\ &\stackrel{d}{=} \theta + \hat{\theta}(2\eta - X_1, \dots, 2\eta - X_m, 2\eta - (Y_1 - \theta), \dots, 2\eta - (Y_n - \theta)) \\ &= \theta + \hat{\theta}(-X_1, \dots, -X_m, -(Y_1 - \theta), \dots, -(Y_n - \theta)) \\ &= 2\theta + \hat{\theta}(-X_1, \dots, -X_m, -Y_1, \dots, Y_n) \\ &= 2\theta - \hat{\theta}(X_1, \dots, X_m, Y_1, \dots, Y_n). \end{aligned}$$

这就证明了 $\hat{\theta}$ 的分布关于 θ 对称. 定理证毕.

注意:由以上证明中可看出: F 的对称中心 η 不必与 F 无关.

当定理4.11与定理4.12的条件满足时, θ 的Hodges-Lehmann估计 $\hat{\theta}$ 关于 θ 对称, 故必为“中位无偏”的. 若 $\hat{\theta}$ 的均值存在, 则 $\hat{\theta}$ 也是(均值)无偏的.

下面考虑 $\hat{\theta}$ 的大样本性质: 在此需要在记号上作一点改变, 在定义对称中心的估计时, 把 $V, c, \hat{\theta}_1, \hat{\theta}_2$ 和 $\hat{\theta}$ 分别改为 $V_N, c_N, \hat{\theta}_{1N}, \hat{\theta}_{2N}$ 和 $\hat{\theta}_N$, 而在定义位置参数的估计时, 则分别改为 $V_{mn}, c_{mn}, \hat{\theta}_{1mn}, \hat{\theta}_{2mn}$ 和 $\hat{\theta}_{mn}$. 仍记 $N = m + n$.

定理4.13 设对称中心 θ 的Hodges-Lehmann估计 $\hat{\theta}_N$ 由 $V_N(Z_1, \dots, Z_N)$ 确定. 设 $G(x)$ 为一连续分布函数, 且存在常数 $A > 0$ 及 B , 使对一切的 $a \in (-\infty, \infty)$, 有

$$\begin{aligned} & \lim_{N \rightarrow \infty} P_{-a/\sqrt{N}}(V_N(Z_1, \dots, Z_N) \leq c_N) \\ &= G(aB/A) = \lim_{N \rightarrow \infty} P_{-a/\sqrt{N}}(V_N(Z_1, \dots, Z_N) < c_N), \end{aligned} \quad (4.140)$$

则对一切的 $a \in (-\infty, \infty)$, 有

$$\lim_{N \rightarrow \infty} P_{\theta}(\sqrt{N}(\hat{\theta}_N(Z_1, \dots, Z_N) - \theta) \leq a) = G\left(\frac{aB}{A}\right). \quad (4.141)$$

证 由(4.130)式有

$$\hat{\theta}_N(Z_1, \dots, Z_N) - \theta = \hat{\theta}_N(Z_1 - \theta, \dots, Z_N - \theta),$$

且

$$Z_i \sim F(x - \theta) \Rightarrow Z_i - \theta \sim F(x).$$

故不失普通性, 可设 $\theta = 0$. 由(4.121)式、(4.122)式, 有

$$V_N\left(\frac{Z_1 - a}{\sqrt{N}}, \dots, \frac{Z_N - a}{\sqrt{N}}\right) > c_N \Rightarrow \hat{\theta}_{1N}(Z_1, \dots, Z_N) \geq \frac{a}{\sqrt{N}}. \quad (4.142)$$

$$V_N\left(\frac{Z_1 - a}{\sqrt{N}}, \dots, \frac{Z_N - a}{\sqrt{N}}\right) < c_N \Rightarrow \hat{\theta}_{2N}(Z_1, \dots, Z_N) \leq \frac{a}{\sqrt{N}}. \quad (4.143)$$

注意到 $\hat{\theta}_{1N} \leq \hat{\theta}_N \leq \hat{\theta}_{2N}$, 由(4.142) 式和(4.143) 式分别得

$$\begin{aligned} P_0(\sqrt{N}\hat{\theta}_N \leq a) &\geq P(\sqrt{N}\hat{\theta}_{2N} \leq a) \\ &\geq P_0\left(V_N\left(Z_1 - \frac{a}{\sqrt{N}}, \dots, Z_N - \frac{a}{\sqrt{N}}\right) < c_N\right) \\ &= P_{-a/\sqrt{N}}(V_N(Z_1, \dots, Z_N) < c_N); \end{aligned} \quad (4.144)$$

$$\begin{aligned} P_0(\sqrt{N}\hat{\theta}_N < a) &\leq P(\sqrt{N}\hat{\theta}_{1N} < a) \\ &\leq P_0\left(V_N\left(Z_1 - \frac{a}{\sqrt{N}}, \dots, Z_N - \frac{a}{\sqrt{N}}\right) \leq c_N\right) \\ &= P_{-a/\sqrt{N}}(V_N(Z_1, \dots, Z_N) \leq c_N). \end{aligned} \quad (4.145)$$

在(4.144) 式与(4.145) 式中令 $N \rightarrow \infty$ 并利用(4.140) 式, 得到

$$\liminf_{N \rightarrow \infty} P_0(\sqrt{N}\hat{\theta}_N \leq a) \geq G\left(\frac{aB}{A}\right) \geq \limsup_{N \rightarrow \infty} P_0(\sqrt{N}\hat{\theta}_N < a). \quad (4.146)$$

考虑到 G 的连续性, 由(4.146) 式即得

$$\lim_{N \rightarrow \infty} P_0(\sqrt{N}\hat{\theta}_N \leq a) = G\left(\frac{aB}{A}\right)$$

对任何实数 a 成立. 如上所述, 这就证明了(4.141) 式. 定理证毕.

这个定理把 V_N 的极限分布的存在性与 $\hat{\theta}_N$ 的极限分布的存在性联系了起来. 由 V_N 在很大的程度上可由人选择, 故这结果是 Hodges-Lehmann 估计 $\hat{\theta}_N$ 的一很良好的性质.

下一个定理是定理 4.13 的特例. 但与 $\hat{\theta}_N$ 的渐近效率有更直接的联系.

定理 4.14 设对称中心 θ 的估计 $\hat{\theta}_N$ 由 $V_N(Z_1, \dots, Z_N)$ 确定, 而 V_N 作为 $\theta = 0 \leftrightarrow \theta > 0$ 的一检验统计量, 适合定理 4.1 的全部条件(并沿用该定理中的记号), 且还要取消该定理假定中 $\theta_k \downarrow 0$ 的限制, 即 θ_k 可以用任何方式趋于 0. 又假定

$$\lim_{N \rightarrow \infty} \frac{\mu(V, N, O, F) - c_N}{\sigma(V, N, O, F)} = 0, \quad (4.147)$$

则当 $N \rightarrow \infty$ 时, 有

$$\sqrt{N}(\hat{\theta}_N - \theta) \xrightarrow{\mathcal{L}} N\left(0, \frac{1}{K_V^2(F)}\right). \quad (4.148)$$

注 4.5 要求定理 4.1 的条件不仅在 $\theta_k \downarrow 0$ 时成立, 且在 $\theta_k \rightarrow 0$ 时也成立,

看起来条件加严了. 实际上, 定理 4.1 的条件 1° 一般是由引理 4.1 去验证, 而该引理在将 $\theta_0 \leq \theta \leq \theta_0 + \varepsilon$ 改为 $|\theta - \theta_0| \leq \varepsilon$ 后, 往往在证明上完全一样. 定理 4.1 的其他各条件也类似. 总之, 一般地可以认为: 本定理对 V_N 加上的条件就是定理 4.1 的条件 (自然, V_N 还需适合为确定 Hodges-Lehmann 估计 $\hat{\theta}_N$ 所需的条件).

回到定理的证明, 根据定理 4.13, 只需证明 (4.140) 式. 现有

$$P_{-a/\sqrt{N}}(V_N(Z_1, \dots, Z_N) \leq c_N) \\ = P_{-a/\sqrt{N}} \left[\frac{V_N - \mu\left(V, N, -\frac{a}{\sqrt{N}}, F\right)}{\sigma\left(V, N, -\frac{a}{\sqrt{N}}, F\right)} \leq \frac{c_N - \mu\left(V, N, -\frac{a}{\sqrt{N}}, F\right)}{\sigma\left(V, N, -\frac{a}{\sqrt{N}}, F\right)} \right] \quad (4.149)$$

根据本定理假定, 当 $\theta = -a/\sqrt{N}$ 而 $N \rightarrow \infty$ 时, 变量

$$\left\{ V_N - \mu\left(V, N, -\frac{a}{\sqrt{N}}, F\right) \right\} / \sigma\left(V, N, -\frac{a}{\sqrt{N}}, F\right)$$

依分布收敛于 $N(0, 1)$. 另一方面, 根据定理 4.1 的条件 2° ~ 4° 及本定理的假定 (4.147) 式, 当 $N \rightarrow \infty$ 时, 有

$$\begin{aligned} \frac{c_N - \mu\left(V, N, -\frac{a}{\sqrt{N}}, F\right)}{\sigma\left(V, N, -\frac{a}{\sqrt{N}}, F\right)} &= \frac{\sigma(V, N, O, F)}{\sigma\left(V, N, -\frac{a}{\sqrt{N}}, F\right)} \left\{ \frac{c_N - \mu(V, N, O, F)}{\sigma(V, N, O, F)} \right. \\ &\quad \left. + \frac{\mu(V, N, O, F) - \mu\left(V, N, -\frac{a}{\sqrt{N}}, F\right)}{O(V, N, O, F)} \right\} \\ &\rightarrow 1 \times \{0 + aK_V(F)\} = aK_V(F). \end{aligned}$$

故由此式及 (4.149) 式得

$$\lim_{N \rightarrow \infty} P_{-a/\sqrt{N}}(V_N(Z_1, \dots, Z_N) \leq c_N) = \Phi(aK_V(F)) \quad (< c_N \text{ 的情况一样}).$$

这相当于 (4.140) 式 $G = \Phi$, $A = 1$ 而 $B = K_V(F)$ 的情况. 再注意 $\Phi(x \cdot K_V(F))$ 就是 $N(0, 1/K_V^2(F))$ 的分布函数, 根据 (4.141) 式就证明了本定理.

由本定理可推出两条重要结论:

1. 根据第 3 章的理论, 对称中心的秩检验统计量在很一般的情况下符合定理 4.1 的条件. 因此依本定理, 由这种统计量 (其中有许多也适合为定义 $\hat{\theta}_N$ 所必

须的条件) 所构造的 Hodges-Lehmann 估计 $\hat{\theta}_N$ 有渐近正态性.

2. 根据(4.148)式, 按点估计的大样本理论, 极限分布的方差的倒数, 即 $K_V^{-2}(F)$, 可以作为衡量 $\hat{\theta}_N$ 的渐近效率的指标: $K_V^{-2}(F)$ 愈大, 则 $\hat{\theta}_N$ 的渐近方差愈小而估计愈精. 因此, 若除 V 以外还使用另一统计量 V_N^* 去构造 θ 的另一 Hodges-Lehmann 估计 $\hat{\theta}_N^*$, 且假定 V_N^* 也适合定理 4.1 的条件, 则可以把 $\hat{\theta}_N$ 对 $\hat{\theta}_N^*$ 的渐近相对效率 $\text{ARE}(\hat{\theta}, \hat{\theta}^*, F)$ 定义为 $K_V^{-2}(F)$ 与 $K_{V^*}^{-2}(F)$ 之比, 即有

$$\begin{aligned}\text{ARE}(\hat{\theta}, \hat{\theta}^*, F) &= \frac{K_V^{-2}(F)}{K_{V^*}^{-2}(F)} \\ &= \text{ARE}(V, V^*, F).\end{aligned}\quad (4.150)$$

就是说, 由 V_N 和 V_N^* 所决定的点估计 $\hat{\theta}_N$ 和 $\hat{\theta}_N^*$ 之间的渐近相对效率正是 V_N 和 V_N^* 作为 $\theta = 0$ 的检验的 Pitman 渐近相对效率. 在定理 4.9 中我们证明了: 在假设检验和区间估计之间也有类似的关系. 这样, 犹如百川汇海, 最后把检验、区间估计和点估计这几种主要的统计推断形式的渐近效率的比较都归之于 Pitman 所引进的 ARE. 自然, 所得结果有助于在对总体分布 F 有些知识的情况下去选择适当的 V_N , 以求造出更优的估计 $\hat{\theta}_N$.

例 4.12 若把在例 4.9 和 4.10 中所作出的估计依次记为 $\hat{\theta}_N^{(1)}$ 、 $\hat{\theta}_N^{(2)}$ 和 $\hat{\theta}_N^{(3)}$, 又假定总体分布 F 满足例 4.1 中的条件(4.16), 则

$$\text{ARE}(\hat{\theta}^{(3)}, \hat{\theta}^{(1)}, F) = 12\sigma^2 \left(\int_{-\infty}^{\infty} f^2(x) dx \right)^2; \quad (4.151)$$

$$\text{ARE}(\hat{\theta}^{(2)}, \hat{\theta}^{(1)}, F) = 4\sigma^2 f^2(0). \quad (4.152)$$

此处

$$\sigma^2 = \int_{-\infty}^{\infty} x^2 f(x) dx.$$

由(4.151)式, 按例 4.1 中所证, 有

$$\text{ARE}(\hat{\theta}^{(3)}, \hat{\theta}^{(1)}, F) \geq 0.864.$$

这样, 作为“非参数性”的估计 $\hat{\theta}^{(3)}$, 其渐近效率与典型的“参数性”估计 $\bar{Z}$ 相比, 处于优越的地位.

对位置参数的 Hodges-Lehmann 估计, 有与定理 4.13 和 4.14 完全类似的结果:

定理 4.15 设位置参数 θ 的 Hodges-Lehmann 估计 $\hat{\theta}_{mn}$ 由 $V_{mn}(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 确定 ($N = m + n$). 设 $G(x)$ 为一连续分布函数, 且存在常数 $A > 0$ 及 B , 使对一切 $a \in (-\infty, \infty)$, 有

$$\lim_{N \rightarrow \infty} P_{-a/\sqrt{N}}(V_{mn} \leq c_{mn}) = G\left(\frac{aB}{A}\right) = \lim_{N \rightarrow \infty} P_{-a/\sqrt{N}}(V_{mn} < c_{mn}),$$

则对一切 $a \in (-\infty, \infty)$, 有

$$\lim_{N \rightarrow \infty} P_{\theta}(\sqrt{N}(\hat{\theta}_{mn} - \theta) \leq a) = G\left(\frac{aB}{A}\right).$$

定理 4.16 设位置参数 θ 的估计由

$$V_{mn}(X_1, \dots, X_m, Y_1, \dots, Y_n) \text{ 确定 } (N = m + n).$$

而 V_{mn} 作为 $\theta = 0 \leftrightarrow \theta > 0$ 的一检验统计量, 适合定理 4.1 的全部条件(并沿用该定理的记号), 且还要取消该定理假定中 $\theta_k \downarrow 0$ 的限制, 即 θ_k 可以用任何方式趋于 0. 又假定

$$\lim_{N \rightarrow \infty} \frac{\mu(V, N, O, F) - c_{mn}}{\sigma(V, N, 0, F)} = 0,$$

则当 $N \rightarrow \infty$ (即 $m \rightarrow \infty, n \rightarrow \infty$. 因为在定理 4.1 条件成立时将有 $\frac{m}{N} \rightarrow \lambda \in (0, 1)$) 时, 有

$$\sqrt{N}(\hat{\theta}_{mn} - \theta) \xrightarrow{\mathcal{L}} N\left(0, \frac{1}{K_V^2(F)}\right).$$

由这个定理可以得到对称中心估计问题中同样的结论, 即: 由两个不同的统计量 V_{mn} 和 V_{mn}^* 所决定的位置参数 θ 的两个 Hodges-Lehmann 估计 $\hat{\theta}_{mn}$ 及 $\hat{\theta}_{mn}^*$, 其渐近相对效率 $\text{ARE}(\hat{\theta}, \hat{\theta}^*, F)$ 就等于 V_{mn} 和 V_{mn}^* 作为 $\theta = 0$ 的检验的 Pitman 渐近相对效率.

4.4 多样本问题与随机区组

这一节讨论秩方法在几个简单的方差分析问题中的应用.

4.4.1 多样本问题

1. 检验统计量

设有 m 个总体, 其分布 $F_1, \dots, F_m$ 都是未知的. 从第 i 个总体中抽出 iid. 样本 $X_{i1}, \dots, X_{in_i}$, 即

$$X_{i1}, \dots, X_{in_i} \sim F_i, \quad i = 1, \dots, m \quad (4.153)$$

且当然假定 $X_{11}, \dots, X_{1n_1}, \dots, X_{m1}, \dots, X_{mn_m}$ 全体独立. 要检验假设

$$H: F_1(x) = F_m(x), \quad \text{对一切 } x, \quad (4.154)$$

当 $m = 2$ 时, 这就是在前面仔细讨论过的两样本问题; 当 $m > 2$ 时, 此问题称为多样本问题 (multi-sample problem).

此问题的上述提法过于一般化. 从理论和实用两方面的观点看, 下面的特殊情况最使人产生兴趣:

$$F_i(x) = F(x - \theta_i), \quad i = 1, \dots, m. \quad (4.155)$$

这里 F 是未知的分布函数, 而 $\theta_1, \dots, \theta_m$ 是未知参数. 检验问题 (4.154) 可写为

$$H: \theta_1 = \dots = \theta_m. \quad (4.156)$$

就是说, m 个总体的分布函数虽属未知, 但可知道它们彼此只相差一个位置参数. 比方说, 用几种生产方法生产一种产品, 其质量指标的分布类型一样, 但用较优的方法所生产出的产品的质量指标的分布曲线更靠右边一些. 在许多情况下, 这是一个合用的近似模型. 它在理论上的处理也比较简单.

这种位置参数多样本问题可写为熟悉的方差分析模型的形式:

$$X_{ij} = \theta_i + e_{ij}, \quad j = 1, \dots, n_i; i = 1, \dots, m, \quad (4.157)$$

其中 e_{ij} 为 iid. 变量, 其分布 F 未知. 当假定 F 为正态时, 就回到初等教程中惯见的形式.

现在转到假设 (4.156) 式的检验问题. 以 R_{ij} 记 X_{ij} 在合样本 (即 $\{X_{ij}, j = 1, \dots, n_i, i = 1, \dots, m\}$) 中的秩, 先假定 F 处处连续, 故“结”的问题不存在. 引进记分函数

$$a_N(i) = \phi_N\left(\frac{i}{N+1}\right), \quad i = 1, \dots, N.$$

此处

$$N = n_1 + \dots + n_m, \quad (4.158)$$

且

$$a_N(1) \leq \dots \leq a_N(N), \quad a_N(1) < a_N(N).$$

第 i 组样本 $X_{i1}, \dots, X_{in_i}$ 的“总计分”为

$$S_{Ni} = \sum_{j=1}^{n_i} \phi_N\left(\frac{R_{ij}}{N+1}\right), \quad i = 1, \dots, m. \quad (4.159)$$

若 (4.156) 式正确, 则 $S_{N1}, \dots, S_{Nm}$ 倾向于接近计分的总平均值

$$\bar{\phi}_N = \frac{1}{N} \sum_{i=1}^N \phi_N \left(\frac{i}{N+1} \right).$$

反之,若(4.156)式不真,则某些 θ_i 大于另一些 θ_i . 当 θ_i 甚大时, $X_{i1}, \dots, X_{in_i}$ 倾向于取较大的值, S_{Ni} 也会偏大. 因而 $S_{N1}, \dots, S_{Nm}$ 之间的差距就会大. 这样, 统计量(参看(3.97)式)

$$S_N = \frac{N-1}{D_{N\neq N}} \sum_{i=1}^m n_i \left(\frac{S_{Ni}}{n_i} - \bar{\phi}_N \right)^2 \quad (4.160)$$

可以作为衡量与假设(4.156)式偏离程度的一项指标. 因而导出检验

$$S: \text{当 } S_N > c_N \text{ 时否定假设(4.156)式.} \quad (4.161)$$

常数 c_N 要由给定的检验水平来确定. 在例 3.8 中证明了: 若

$$\phi_N = \phi \text{ (或 } a_N(i) = E\phi(U_{(i)}) \text{ 也可以),}$$

其中 ϕ 为平方可积分函数, 而 $U_{(1)} \leq \dots \leq U_{(N)}$ 为 $R(0,1)$ 的次序样本, 且

$$\lim_{N \rightarrow \infty} \frac{n_i}{N} = \lambda_i > 0, \quad i = 1, \dots, m, \quad (4.162)$$

则在原假设(4.156)式成立时, 有

$$S_N \xrightarrow{\mathcal{L}} \chi_{m-1}^2.$$

利用这一事实, 当 $n_1, \dots, n_m$ 都较大时, 可以取 $\chi_{m-1}^2(\alpha)$ 作为 c_N 的近似值.

一个重要的情况是取 $a_N(i) = i$ (相当于 $\phi(u) = u$). 这时(4.160)式中的统计量成为

$$K_N = \frac{12}{N(N+1)} \sum_{i=1}^m n_i \left(R_i - \frac{N+1}{2} \right)^2,$$

其中

$$R_i = \sum_{j=1}^{n_i} \frac{R_{ij}}{n_i}$$

是第 i 组样本的平均秩. 这就是 Kruskal 和 Wallis 在文献[106]、[107]提出的检验. 在文献[107]中对 $m=3, n_i \leq 5 (i=1,2,3)$ 及检验水平 α 接近 0.01、0.05 和 0.10 的情况, 给出了(4.161)式中的临界值 c_N 的值, Kraft 和 Van Eeden^[103] 对 $m=3$ 和 $n_1 \leq 5$ 给出了 K_N 的精确分布. Lehmann^[112] (第 207 页) 对 $m=3$ 和 $n_1 = n_2 = n_3 = 5$ 的情况给出了 K_N 的 χ^2 近似与精确分布的若干个比较值. 对 n_i 中有些过小而另一些过大的情况, χ^2 近似较差, 而精确分布又不易算. 这时 Kruskal 和 Wallis 的工作^[107]、Rijkoort 和 Wise^[137] 以及 Wallace^[171] 提出了其他的近似法, 可供参考.

2. 相对于 F 检验的 ARE

关于由(4.161)式给定的检验 S 的 Pitman 效率因子的计算问题,解决它有以下几个步骤:首先,需要把 3.3 节中的理论推广到多个线性秩统计量的情况,证明在一定条件下(只要每一个线性秩统计量都满足 3.3 节中的条件以及保证极限分布非退化的条件),多个线性秩统计量的联合分布渐近于多维正态分布.其次,由上述事实证明,(4.160)式定义的 S_N 的一定条件下渐近于非中心的 χ^2 分布,其非中心参数 δ^2 可算出来.最后利用定理 4.1,不难把 Pitman 效率因子通过 δ^2 表达出来(前面曾提到:在定理 4.1 中可以用任一连续严增分布代替正态分布).严格的理论与详细的推导过程,请参看文献[3]中第六章.在此只讲一个重要特例.

用 T 记假设(4.156)的传统的 F 检验,它有否定域

$$\frac{1}{m-1} \sum_{i=1}^m n_i (\bar{X}_i - \bar{X})^2 / \frac{1}{N-m} \sum_{i=1}^m \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 > F_{m-1, N-m}(\alpha)$$

这里

$$\bar{X}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij}, \quad \bar{X} = \frac{1}{N} \sum_{i=1}^m \sum_{j=1}^{n_i} X_{ij},$$

$F_{a,b}(\alpha)$ 是自由度为 a 与 b 的中心 F 分布上的“上 α 点”.可以证明

$$\text{ARE}(S, T, F) = \sigma^2 \left(\int_{-\infty}^{\infty} \phi'(F(x)) f^2(x) dx \right)^2 / \int_0^1 (\phi(u) - \bar{\phi})^2 du.$$

(4.163)

这里 $F(x)$ 是总体分布(见 4.155)式), $f = F'$ 为其密度, ϕ 是计分函数 ϕ_N 与 $N \rightarrow \infty$ 时的极限,而 σ^2 是分布 F 的方差.表达式(4.163)与两样本情况下以 ϕ 为计分函数的秩检验对 t 检验的 ARE 完全一样.因此在 4.1.3 小节中提到过的一些事实也适用于此处,例如取 $\phi(u) = u$,得 Kruskal-Wallis 检验对 F 检验的 ARE 为

$$12\sigma^2 \left(\int_{-\infty}^{\infty} f^2(x) dx \right)^2,$$

其值总小于 0.864,而若取 $\phi(u) = \Phi^{-1}(u)$,得到多样本的情况下的 Van der Waerden 检验,其对 F 检验的 ARE 总不小于 1,且只在 F 是正态时才为 1,等等.

3*. 结存在的情况

以上是在总体分布 F 连续因而结不存在的情况下讨论的.若 F 可以不连续,可按 3.4 节的方法处理.若采用随机化法,则在秩通过随机化确定后,一切均无

变化.若采用平均法,以 $(\tau_1, \dots, \tau_q)$ 记结统计量(定义见(3.125)式前面一段的说明). $(\tau_1, \dots, \tau_q)$ 是由合样本 $\{X_{ij}: j=1, \dots, n_i, i=1, \dots, m\}$ 所决定的.即得 $(\tau_1, \dots, \tau_q)$,将原计分函数 $a_N(\cdot)$ 按(3.125)式改造为 $\bar{a}_N(\cdot)$.在(4.160)式中心 $\bar{a}_N(\cdot)$ 代替 $a_N(\cdot)$,算出的结果记为 S_N' ,最后,令

$$S_N^* = \left\{ 1 - \frac{\sum_{i=1}^N (\bar{a}_N(i) - \bar{a}_N)^2}{\sum_{i=1}^N (a_N(i) - \bar{a}_N)^2} \right\}^{-1} S_N'. \quad (4.164)$$

则根据(3.127)式及定理3.19,用例3.8的证法,即知当定理3.19的条件满足(其中条件2°改为 $0 < \liminf_{N \rightarrow \infty} \frac{n_i}{N} \leq \limsup_{N \rightarrow \infty} \frac{n_i}{N} < \infty, i=1, \dots, m$)且原假设(4.156)式成立时,当 $N \rightarrow \infty$ 时,有

$$S_N^* \xrightarrow{\mathcal{L}} \chi_{m-1}^2. \quad (4.165)$$

由此可作出当结存在时渐近水平为 α 的大样本检验,它有否定域 $\{S_N^* > \chi_{m-1}^2(\alpha)\}$.以Kruskal-Wallis检验为例,先按平均法定出各 X_{ij} 的秩 R_{ij}^* (同处一结内的各样本,其秩都等于该结各位置的平均).记

$$R_i^* = \frac{1}{n_i} \sum_{j=1}^{n_i} R_{ij}^*.$$

再利用(3.136)式,得到当结存在时的Kruskal-Wallis统计量

$$K_N^* = \left\{ 1 - \sum_{i=1}^q \frac{\tau_i^2 - \tau_i}{N^3 - N} \right\}^{-1} \times \frac{12}{N(N+1)} \sum_{i=1}^m n_i \left(R_i^* - \frac{N+1}{2} \right)^2. \quad (4.166)$$

它在(4.156)式成立且 $\min\{n_1, \dots, n_m\} \rightarrow \infty$ 时,依分布收敛于 χ_{m-1}^2 .

4. 有次序的对立假设

前面在考虑原假设(4.156)式的检验问题时,我们心目中的对立假设是无方向的,即任何不全相等的 $(\theta_1, \dots, \theta_m)$ 都有可能.在有些问题中,有一定的根据可认为可能的对立假设有一定的方向性.如

$$H: \theta_1 = \dots = \theta_m \leftrightarrow K: \theta_1 \leq \dots \leq \theta_m (\theta_1 < \theta_m). \quad (4.167)$$

为了检验 $H \leftrightarrow K$,以 U_{ij} 记由第 i, j 两样本构成的Mann-Whitney统计量,即

$$U_{ijN} = \sum_{u=1}^{n_i} \sum_{v=1}^{n_j} I_{(X_{ju} > X_{iv})}, \quad 1 \leq i \leq j \leq m.$$

若 $\theta_i < \theta_j$,则 U_{ij} 倾向于取比较大的值,故若令

$$U_N = \sum_{1 \leq i \leq j \leq m} U_{ijN}. \quad (4.168)$$

则当 K 成立时, U_N 倾向于取较大的值.因此,一个合理的检验是

$$U; \text{当 } U_N > c_N \text{ 时否定 } H. \quad (4.169)$$

其中, c_N 为常数, 依赖于所选定的检验水平 α . 以下证明: 若总体分布 F 连续, 且当 $N \rightarrow \infty$ 时, 有 $\min\{n_1, n_2, \dots, n_m\} \rightarrow \infty$, 则 U_N 渐近于正态分布.

为证明这一事实, 令

$$V_{jN} = \sum_{i=1}^{j-1} U_{ijN}, \quad j = 2, \dots, m, \quad (4.170)$$

有 $U_N = V_{2N} + \dots + V_{mN}$, 易见 $V_{2N}, \dots, V_{mN}$ 相互独立. 这可如下证明: 考虑 V_{mN} 和 $(V_{2N}, \dots, V_{m-1,N})$, 前者是以

$$\{X_{ij}: j = 1, \dots, n_i, i = 1, \dots, m-1\}$$

为一方, 第 m 组样本 $\{X_{mj}: j = 1, \dots, n_m\}$ 为另一方作成的 Mann-Whitney 统计量, 其值只依赖于第 m 组样本的秩. 而

$$V_{2N}, \dots, V_{m-1,N}$$

的值取决于前 $m-1$ 组样本之间的相互比较, 故其值与第 m 组样本的秩了无关系. 由此知 V_{mN} 与 $(V_{2N}, \dots, V_{m-1,N})$ 独立. 循此以往, 又可证明 $V_{m-1,N}$ 与 $(V_{2N}, \dots, V_{m-2,N})$ 独立, $V_{m-2,N}$ 与 $(V_{2N}, \dots, V_{m-3,N})$ 独立等. 不言而喻, 这就证明了 $V_{2N}, \dots, V_{mN}$ 相互独立. 又在上述证明中, 已指出每个 V_{jN} 都是 Mann-Whitney 统计量. 由于各 $n_i \rightarrow \infty$, 由定理 2.4 及 (2.61) 式, 有

$$\left(V_{jN} - \frac{1}{2}n_j \sum_{i=1}^{j-1} n_i\right) / \sqrt{n_j \sum_{i=1}^{j-1} n_i \sum_{i=1}^j \frac{n_i}{12}} \xrightarrow{\mathcal{L}} (0, 1). \quad (4.171)$$

由 (4.171) 式及 $U_N = V_{2N} + \dots + V_{mN}$, 立得

$$\frac{U_N - A_N}{B_N} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.172)$$

其中

$$A_N = \sum_{j=2}^m n_j \sum_{i=1}^{j-1} \frac{n_i}{2} = \frac{1}{4} \left(N^2 - \sum_{i=1}^m n_i^2 \right); \quad (4.173)$$

$$\begin{aligned} B_N^2 &= \frac{1}{12} \sum_{j=2}^m n_j \sum_{i=1}^{j-1} n_i \sum_{i=1}^j n_i \\ &= \frac{1}{72} \left\{ N^2 (2N + 3) - \sum_{i=1}^m n_i^2 (2n_i + 3) \right\}. \end{aligned} \quad (4.174)$$

注意: A_N 和 B_N^2 分别是当 H 成立时 U_N 的均值和方差. 利用 (4.172) 式可确定 (4.167) 式的大样本检验的临界值.

以上的讨论是假定总体分布 F 连续. 若 F 不处处连续, 则有“ ” 结的问题存

在. 如用平均法处理, 相当于把 U_{ijN} 的定义修正为

$$U_{ijN}^k = U_{ijN} + \frac{1}{2} \sum_{u=1}^{n_i} \sum_{v=1}^{n_i} I_{(X_{ju} = x_{iv})}.$$

而 $U_N^* = \sum_{1 \leq i \leq j \leq m} U_{ijN}^*$. 关于 U_N^* 在 H 成立下的渐近正态性, 原则上容易用表达式

$$U_N^* = V_{2N}^* + \cdots + V_{mN}^*; \quad V_{jN}^* = \sum_{i=1}^{j-1} U_{ijN}^*$$

及对每个 V_{jN}^* 使用定理 3.19 而得到. 但计算过程略为繁复. 今将结果引述如下: 以 $(\tau_1, \dots, \tau_q)$ 记统计量, 则易证

$$E(U_N^* \mid \tau_1, \dots, \tau_q) = E(U_N^*) = A_N.$$

而

$$\begin{aligned} \text{Var}(U_N^* \mid \tau_1, \dots, \tau_q) &= \frac{1}{72} \left\{ N(N-1)(2N+5) - \sum_{i=1}^m n_i(n_i-1)(2n_i+5) - \sum_{j=1}^q \tau_j(\tau_j-1)(2\tau_j+5) \right. \\ &\quad + \frac{1}{36N(N-1)(N-2)} \sum_{i=1}^m n_i(n_i-1)(n_i-2) \times \sum_{j=1}^q \tau_j(\tau_j-1)(\tau_j-2) \\ &\quad \left. + \frac{1}{8N(N-1)} \sum_{i=1}^m n_i(n_i-1) \sum_{j=1}^q \tau_j(\tau_j-1) \right\} \triangleq B_N^{*2}. \end{aligned} \quad (4.175)$$

不难看出, 在结不存在时, (4.175) 式转化为 (4.174) 式. 有

$$\frac{U_N^* - A_N}{B_N^*} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.176)$$

由此不难写出 (4.167) 式的大样本检验的临界值.

4.4.2 位置参数差的估计

仍如 4.4.1 小节, 设有样本

$$X_{i1}, \dots, X_{in_i} \sim F(x - \theta_i), \quad i = 1, \dots, m, \quad (4.177)$$

如果经过检验, 否定了假设 (4.156) 式 (或事先有根据认为它不成立), 则在应用上常需进一步考虑有关诸 θ_i 的估计问题. 很明显, 由于在 (4.177) 式中并未明确给定分布 F , 单个的 θ_i 是无法估计的. 比如, 把 $F(x)$ 改为 $F_1(x) = F(x-1)$, 则 (4.177) 式可以写为

$$X_{i1}, \dots, X_{in_i} \sim F_1(X - \theta_i'), \quad \theta_i' = \theta_i - 1.$$

不难知道,在 θ_i 的线性函数 $\sum_{i=1}^m c_i \theta_i$ 中,当且仅当 $\sum_{i=1}^m c_i = 0$, $\sum_{i=1}^m c_i \theta_i$ 才完全由模型(4.177)式确定而不依赖 F 的选择. 因此,只能考虑这种线性函数的估计问题. 在方差分析中,习惯上把这种线性函数称为“对照”(contrast).

最简单的对照是 $\theta_j - \theta_i \triangleq \theta$. 若记 $F_1(x) = F(x - \theta_i)$, 则有:

$$X_{i1}, \dots, X_{in_i} \sim F_1(x), \quad X_{j1}, \dots, X_{jn} \sim F_1(x - \theta).$$

这与 4.3.4 小节中的提法完全一样,因而可按那里的方法对 $\theta_j - \theta_i$ 作出估计,暂记为 $\hat{\theta}_{ji}$, 若

$$\theta \triangleq \sum_{i=1}^m c_i \theta_i$$

为一对照,则 θ 可表为

$$\theta = \sum_{i=1}^m c_i \theta_i - \sum_{i=1}^m c_i \theta_i = \sum_{i=2}^m c_i (\theta_i - \theta_1).$$

因而可以用 $\sum_{i=1}^m c_i \hat{\theta}_{i1}$ 去估计. 这个做法的一个缺点,在于将 θ 表为 $(\theta_j - \theta_i)$ 的线

性函数的方法不是唯一的. 例如,上文的 θ 也可表为 $\sum_{i=1}^{m-1} c_i (\theta_i - \theta_m)$, 因而也可用

$\sum_{i=1}^{m-1} c_i \hat{\theta}_{im}$ 去估计,但后者并不等于 $\sum_{i=2}^m c_i \hat{\theta}_{i1}$.

为克服这一困难,Lehmann 在文献[111]中提出了如下的方法:令

$$\hat{\theta}_i = \sum_{k=1}^m \frac{\hat{\theta}_{ik}}{m}, \quad i = 1, \dots, m. \quad (4.178)$$

$\hat{\theta}_{ik}$ 的意义同前(注意 $\hat{\theta}_{ii} = 0$), 用 $\hat{\theta}_i - \hat{\theta}_j$ 去估计 $\theta_i - \theta_j$. 而对 $\{\theta_i\}$ 的对照 $\theta =$

$\sum_{i=1}^m c_i \theta_i$, 则用任一种可能的方法将其表为

$$\theta = \sum_{i,j} d_{ij} (\theta_i - \theta_j)$$

的形式,然后以

$$\hat{\theta} = \sum_{i,j} d_{ij} (\hat{\theta}_i - \hat{\theta}_j)$$

去估计,不难看出,估计量 $\hat{\theta}$ 与将 θ 表为

$$\sum_{i,j} d_{ij} (\theta_i - \theta_j)$$

的方法无关.

在 4.3.4 小节中曾考虑了位置参数差 $\theta_i - \theta_j$ 的 Hodges-Lehmann 估计 $\hat{\theta}_{ij}$ 的极限分布,并在此基础上定义了这种估计的 ARE(见(4.150)式).Lehmann 在文献[111]中将关于 $\hat{\theta}_{ij}$ 的结果推广到 $\theta_1, \dots, \theta_m$ 的对照 θ 的估计 $\hat{\theta}$.例如,不难证明: $\hat{\theta}$ 对常见的估计 $\theta^* = \sum_{i=1}^m c_i \bar{X}_i$ (此处 $\bar{X}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} X_{ik}$) 的 ARE 与在估计 $\theta_i - \theta_j$ 时 $\hat{\theta}_{ij}$ 对 $\bar{X}_i - \bar{X}_j$ 的 ARE 完全一致.

用(4.178)式定义 $\hat{\theta}_i$,有把各组样本同等看待的意思.但若各组样本大小 $n_1, \dots, n_m$ 不一致,则对样本大小较大的组,应给予更多的重视.根据这个想法,Spjotvoll 在文献[154]中提出,用加权平均

$$\bar{\theta}_i = \sum_{k=1}^m \frac{n_k \hat{\theta}_{ik}}{N}, \quad N = n_1 + \dots + n_m \quad (4.179)$$

去代替由(4.178)式定义的 $\hat{\theta}_i$.

关于 $\{\theta_i\}$ 的一切对照的同时区间估计问题,可参看文献[105]中第 22 章及该处所引文献.

4.4.3 随机区组

1. Friedman 检验

设有 m 个处理要在 N 个区组中进行比较,每个区组中这 m 个处理各重复一次.假设处理效应和区组效应都有可加性,则本问题的统计模型,如同在初等教程中所常见的那样,可写为

$$X_{ij} = \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, m; j = 1, \dots, N. \quad (4.180)$$

这里 X_{ij} 是第 i 处理在第 j 区组中的试验结果, α_i 与 β_i 分别是第 i 处理和第 j 区组的效应,而 e_{ij} 是随机误差.假定

$$e_{ij}; i = 1, \dots, m; j = 1, \dots, N \text{ 相互独立,} \quad (4.181)$$

对固定的 $j, e_{ij}, \dots, e_{mj}$ 为 iid.

在初等教程中进一步假定全部 e_{ij} 有共同的正态分布.在此,不仅不规定任何分布类型,且在不同的区组内,随机误差分布的类型可以不同.我们感兴趣的假设是“处理效应不存在”,即

$$H: \alpha_1 = \dots = \alpha_m. \quad (4.182)$$

先设所有 e_{ij} 的分布都连续.由(4.180)式、(4.181)式可知,对固定的 j , $X_{1j}, \dots, X_{mj}$ 为 iid. 且分布连续.故若以 R_{ij} 记 X_{ij} 在 $\{X_{1j}, \dots, X_{mj}\}$ 中的秩,则在 H 正确时, $(R_{1j}, \dots, R_{mj})$ 具有定理 3.1 所指出的分布(改该处的 n 为 m),且

$$(R_{1j}, \dots, R_{mj}), \quad j = 1, \dots, N$$

为 iid. 记

$$R_i(N) = \sum_{j=1}^N \frac{R_{ij}}{N}, \quad i = 1, \dots, m. \quad (4.183)$$

它是处理 i 在各区组内的秩的平均. 若 H 成立, 则

$$R_1(N), \dots, R_m(N)$$

应倾向于接近; 反之, 若 H 不成立, 则它们之间会倾向于有较大差别. 由此, 可引进如下的检验法: 考虑到在 H 成立时各 $R_i(N)$ 的均值是 $(m+1)/2$, 取

$$Q_N = A_N \sum_{i=1}^m \left(R_i(N) - \frac{1}{2}(m+1) \right)^2. \quad (4.184)$$

A_N 是一适当选择的常数, 然后作如下的检验:

$$Q: \text{当 } Q_N > c_N \text{ 时否定 } H. \quad (4.185)$$

c_N 为常数, 其值依赖于所选择的检验水平 α . 这样检验是 Friedman 在 1937 年于文献[69]中首先引进的. Friedman 取

$$A_N = \frac{12N}{m(m+1)}.$$

Friedman 自己及以后的一些学者都在 m 和 N 很小时, 给出过 Q_N 的分布 (在 H 成立时, 又 A_N 选择如上). 不过这范围总是有限的. 在 N 较大时可使用下述极限定理:

定理 4.17 设诸 e_{ij} 的分布连续且 H 真确, 则当 $N \rightarrow \infty$ (m 固定) 时, $Q_N \xrightarrow{\mathcal{L}} \chi_{m-1}^2$.

证 由多维中心极限定理知: 当 $N \rightarrow \infty$ 时, 有

$$\begin{aligned} Z_N &\triangleq (Z_{N1}, \dots, Z_{Nm})' \\ &= \sqrt{N} \left(R_1(N) - \frac{m+1}{2}, \dots, R_m(N) - \frac{m+1}{2} \right)' \\ &\xrightarrow{\mathcal{L}} N(0, \mathbf{A}). \end{aligned}$$

此处 m 阶方阵 $\mathbf{A} = (\lambda_{ij})_{i,j=1}^m$ 是 $(R_{11}, \dots, R_{m1})'$ 的协方差阵, 即当 $i \neq j$ 时, $\lambda_{ii} = (m^2 - 1)/12$, $\lambda_{ij} = -(m+1)/12$. 易见, 由 $\mathbf{A}$ 的前 $m-1$ 行和列所构成的方阵 $\mathbf{A}_1$ 满秩, 故有

$$(Z_{N1}, \dots, Z_{N,m-1}) \mathbf{A}_1^{-1} (Z_{N1}, \dots, Z_{N,m-1})' \xrightarrow{\mathcal{L}} \chi_{m-1}^2. \quad (4.186)$$

用与例 3.8 相似的方法计算 (4.186) 式的左边, 不难得出它就是 Q_N , 从而证明了本定理.

注意,本定理的证明完全是基于古典的中心极限定理,与线性秩统计量的渐近正态性无关.

在通常方差分析中,假设(4.182)式的 F 检验有否定域

$$N(N-1) \sum_{i=1}^m (\bar{X}_i - \bar{X})^2 / \sum_{i=1}^m \sum_{j=1}^N (X_{ij} - \bar{X}_i)^2 > F_{m-1, (m-1)(N-1)}(\alpha).$$

其中

$$\bar{X}_i = \frac{1}{N} \sum_{j=1}^N X_{ij},$$

$$\bar{X} = \frac{1}{mN} \sum_{i=1}^m \sum_{j=1}^N X_{ij}.$$

Friedman 检验对这个检验的 Pitman ARE, 由 Van Elteren 和 Noether 在文献 [166] 中给出为

$$\text{ARE}(\text{Friedman 检验}, F \text{ 检验}, F) = \frac{m}{m+1} \text{ARE}(W, t, F). \quad (4.187)$$

右边是在两样本位置参数问题中 Wilcoxon 检验对 t 检验的 ARE. 此式表明: m 愈小, Friedman 检验与 F 检验相比, 愈处于不利地位.

2. 结存在的情况

若在模型(4.180)中 e_{ij} 的分布不处处连续, 则 Friedman 统计量要作适当调整.

以 $\tau_j = (\tau_{1j}, \dots, \tau_{qj})$ 记 j 区组内的试验结果 $(X_{1j}, \dots, X_{mj})$ 的结统计量; 以 R_{ij}^* 记 X_{ij} 在“平均法”之下的秩,

$$R_i^*(N) = \sum_{j=1}^N R_{ij}^* / N.$$

令

$$Q_N^* = \left\{ 1 - \sum_{k=1}^{q_j} \frac{\tau_{kj}^3 - \tau_{kj}}{Nm(m^2 - 1)} \right\}^{-1} \\ \times \frac{12N}{m(m+1)} \sum_{i=1}^m \left\{ R_i^*(N) - \frac{m+1}{2} \right\}^2. \quad (4.188)$$

可以证明: 在 $e_{ij}: j = 1, \dots, N, i = 1, \dots, m$ 为 iid. 而 e_{ij} 的分布非退化时, 当 $N \rightarrow \infty$ 时,

$$Q_N^* \xrightarrow{\mathcal{L}} \chi_{m-1}^2.$$

这个结果提供了当分布不连续时, 假设(4.182)式的一个大样本检验法.

在此不详细叙述这个结果的证明, 而只指出: 如同定理 4.17 一样, 其证明是

建筑在古典的中心极限定理上,而非基于线性秩统计量的渐近正态性.具体思路是考虑在给定结统计量 $\tau_1, \dots, \tau_N$ 的条件下, Q_N^* 的条件分布.这一点以及证明中的若干其他细节与(比方说)定理 3.19 相似.

有一个重要的特例值得一提,顺便也可以澄清一个问题:

若 X_{ij} 都只能取 0、1 这两个值,并以 B_i 记 $X_{i1}, \dots, X_{iN}$ 中 1 的个数;以 L_j 记 $X_{1j}, \dots, X_{mj}$ 中 1 的个数,则 Q_N^* 简化为

$$Q_N^* = m(m-1) \left\{ \sum_{i=1}^m B_i^2 - \left(\sum_{i=1}^m B_i \right)^2 / m \right\} / \left\{ m \sum_{j=1}^N L_j - \sum_{j=1}^N L_j^2 \right\}. \quad (4.189)$$

为证此式,只需注意结统计量 τ_j 等于 $(m - L_j, L_j)$,而在区组 j 内,若 $X_{ij} = 0$, 则

$$R_{ij}^* = \frac{1}{2}(m+1-L_j);$$

若 $X_{ij} = 1$, 则

$$R_{ij}^* = m - \frac{1}{2}(L_j - 1).$$

以此代入(4.188)式,再进行一些代数简化即得.(4.189)式与 Cochran 在文献 [48] 中引进的检验统计量一致.然而从模型上说,它不属于所讨论的(4.180)式这种类型.因而,关于当 $N \rightarrow \infty$ 时统计量(4.189)渐近于 χ_{m-1}^2 这个结论,并不能从前述(4.188)式的极限定理得出来.确切地说,此处的统计模型如下:

有 m 个处理,例如治疗某种病的 m 种药物,施加每个处理的结果是成功(1)或失败(0).有 N 个区组,例如, N 个各由 m 个患者组成的小组.同一组内各患者的情况(病情、年龄、体质等)很接近.假定 m 个处理在这 N 个区组内作 mN 次试验是独立的.以 p_{ij} 记“处理 i 在区组 j 内成功”这一事件的概率,并假定若 $p_{ij} > p_{i'j}$ 对某个 j 成立,则对一切 j ($1 \leq j \leq N$) 都成立.在这种条件下,要检验假设

$$p_{1j} = p_{2j} = \dots = p_{mj}, \quad j = 1, 2, \dots. \quad (4.190)$$

可以证明:在(4.190)式成立且

$$\sum_{j=1}^{\infty} p_{1j}(1-p_{1j}) = \infty$$

时,统计量(4.189)当 $N \rightarrow \infty$ 时有极限分布 χ_{m-1}^2 ,因而,以

$$Q_N^* > \chi_{m-1}^2(\alpha)$$

为否定域的检验有渐近水平 α .

3. 假设(4.182)的另一种检验法

为确定计,在此先讨论 e_{ij} 的分布处处连续的情况.经简单的计算表明:当 $m = 2$ 时,Friedman 检验统计量(4.184)

$$\left(\text{其中 } A_N = \frac{12N}{m(m+1)} \right) \Big|_{m=2} = 2N$$

转化为 $4N\left(\frac{A}{N} - \frac{1}{2}\right)^2$,其中 A 是处理1的试验值在 N 个区组中取秩1的次数.

这样一来,在 $m = 2$ 时,Friedman 检验转化为双边的符号检验.一般说来,符号检验的效率不如某些较精细的经验(如 Wilcoxon 符号秩检验)来得高.因此可以设想:作为符号检验的推广的 Friedman 检验,也会有类似的缺点.这一点源出于如下事实:在 Friedman 检验中,只利用了区组内的相互比较—— X_{ij} 的秩 R_{ij} 是相对于 $(X_{1j}, \dots, X_{mj})$ 而言.在各区组之间存在较大差异的情况下,把全部 X_{ij} 放在一起排序不行.但是,若事先进行一定的处置,就可以这样做.据此,Hodges 和 Lehmann 在文献[86]中建立了其效率一般更高的检验.

算出 X_{ij} 对区组平均的调整后的值:

$$X_{ij}' = X_{ij} - X_{\cdot j}, \quad X_{\cdot j} = \frac{1}{m} \sum_{i=1}^m X_{ij}. \quad (4.191)$$

这样在 X_{ij}' 中,由区组的(加性)差异带来的“不平等性”被消去了.事实上可以证明下面的引理.

引理 4.6 在模型(4.180)之下,设 e_{ij} 为 iid.且分布连续.由(4.191)式定义 X_{ij}' .以 R_{ij}' 记 X_{ij}' 在 $\{X_{ij}': j = 1, \dots, N, i = 1, \dots, m\}$ 中的秩.则当假设(4.182)式成立时, mN 维随机向量 $(R_{11}', \dots, R_{mN}')$ 服从定理 3.1 中给出的分布(改该处的 n 为 mN).

证 取 $1, 2, \dots, mN$ 的任一置换

$$(k_{11}, \dots, k_{m1}, \dots, k_{1N}, \dots, k_{mN}),$$

以 S_j 记集合 $\{k_{1j}, \dots, k_{mj}\}$ (不计次序),由(4.191)式和(4.180)式得

$$X_{ij}' = \alpha_i - \bar{\alpha} + e_{ij} - e_{\cdot j}.$$

这里

$$\bar{\alpha} = \frac{1}{m} \sum_{i=1}^m \alpha_i, \quad e_{\cdot j} = \frac{1}{m} \sum_{i=1}^m e_{ij}.$$

由这个表达式看出以下两点:1°. N 个 m 维向量

$$(X_{1j}', \dots, X_{mj}'), \quad j = 1, \dots, N$$

为 iid; 2°. 若 (4.182) 式成立, 则 $(X_{1j}', \dots, X_{mj}')$ 的分布具有“可交换性”(interchangeable), 即将 $X_{1j}', \dots, X_{mj}'$ 作任意置换, 其分布不变. 由 1° 得

$$\begin{aligned} P\{\text{集合}\{R_{1j}', \dots, R_{mj}'\} = \text{集合 } S_j, j = 1, \dots, N\} \\ = \text{将 } mN \text{ 个相异物件分成个数相同的 } N \text{ 堆的分法的倒数} \\ = \frac{(m!)^N}{(mN)!}. \end{aligned} \quad (4.192)$$

由 2° 得

$$P\{R_{1j}' = k_{1j}, \dots, R_{mj}' = k_{mj} \mid \text{集合}\{R_{1j}', \dots, R_{mj}'\} = S_j\} = \frac{1}{m!}. \quad (4.193)$$

又因为在给定“集合 $\{R_{1j}', \dots, R_{mj}'\} = S_j (j = 1, \dots, N)$ ”的条件下, N 个事件 $\{R_{1j}' = k_{1j}, \dots, R_{mj}' = k_{mj}\} (j = 1, \dots, N)$ 为条件独立, 由 (4.192)、(4.193) 式即得

$$P\{R_{ij}' = k_{ij} : j = 1, \dots, N, i = 1, \dots, m\} = \frac{1}{(mN)!}.$$

从而证明了本引理.

因此, 若引进记分函数 $a_N(t), t = 1, \dots, mN$, 而令

$$\begin{aligned} S_{N_i} &= \sum_{j=1}^N a_N(R_{ij}'), \quad i = 1, \dots, m; \\ \bar{a}_N &= \frac{1}{mN} \sum_{t=1}^{mN} a_N(t); \\ S_N &= N(mN - 1) \sum_{i=1}^m \left(\frac{S_{N_i}}{N} - \bar{a}_N \right)^2 \bigg/ \sum_{i=1}^{mN} (a_N(t) - \bar{a}_N)^2. \end{aligned} \quad (4.194)$$

则在

$$a_N(t) = \phi\left(\frac{t}{mN+1}\right)$$

或

$$a_N(t) = E\phi(U_{(t)}),$$

$t = 1, \dots, mN$ ($U_{(1)} \leq \dots \leq U_{(mN)}$ 为 $R(0,1)$ 的次序样本) 且假设 (4.182) 式成立时, 根据例 3.8 有

$$S_N \xrightarrow{\mathcal{L}} \chi_{m-1}^2, \quad N \rightarrow \infty. \quad (4.195)$$

利用这个事实可作出假设 (4.182) 式的大样本检验, 即当 $S_N > \chi_{m-1}^2(\alpha)$ 时否

定. 这检验有渐近水平 α .

在 $a_N(t) = t$ 的特例, 有

$$S_N = \frac{12}{m(mN+1)} \sum_{i=1}^m \left(R_{i.}' - \frac{1}{2}(mN+1) \right)^2, \quad (4.196)$$

其中

$$R_{i.}' = \frac{1}{N} \sum_{j=1}^N R_{ij}'.$$

这个检验与 Friedman 检验的比较大体上相当于 Wilcoxon 符号秩检验与符号检验的比较.

在文献[112]中(见文献[112]第270~273页)考虑了统计量(4.196)的一种变形:

$$S_N^* = \frac{N^2(m-1)}{\sum_{i=1}^m \sum_{j=1}^N (R_{ij}' - R_{.j}')^2} \sum_{i=1}^m \left(R_{i.}' - \frac{1}{2}(mN+1) \right)^2. \quad (4.197)$$

此处

$$R_{.j}' = \frac{1}{m} \sum_{i=1}^m R_{ij}'.$$

经简单计算表明: 当假设(4.182)式成立时, 有

$$\lim_{N \rightarrow \infty} \left\{ E \sum_{i=1}^m \sum_{j=1}^N (R_{ij}' - R_{.j}')^2 / N^3 \right\} = \frac{1}{12} m^2 (m-1). \quad (4.198)$$

进一步也可以证明: 在假设(4.182)式成立时, 有

$$\sum_{i=1}^m \sum_{j=1}^N (R_{ij}' - R_{.j}')^2 / N^3 \xrightarrow{P} \frac{1}{12} m^2 (m-1). \quad (4.199)$$

根据(4.198)式, 为证(4.199)式, 只需证在假设(4.182)式成立时有

$$\text{Var} \left(\sum_{i=1}^m \sum_{j=1}^N (R_{ij}' - R_{.j}')^2 \right) = o(N^6).$$

这一点没有困难, 但计算较繁复.

比较 S_N 和 S_N^* 由(4.199)式知在假设(4.182)式成立时, 当 $N \rightarrow \infty$ 时, 有

$$S_N^* \xrightarrow{\mathcal{L}} \chi_{m-1}^2.$$

关于 S_N 和 S_N^* 的分布哪个与 χ_{m-1}^2 更接近的问题, 尚无所了解 Gilbert^[72] 对 S_N^* 的分布与 χ_{m-1}^2 的接近程度给也若干数据.

基于 S_N^* 的检验当作条件检验看, 更自然. 这一点待到 5.1 节中再作解释.

当结存在时,对统计量(4.194)作适当的修正.修正的方式与多样本问题的情况相同(参看(4.164)式).

4. 有次序的对立假设

仍设有模型(4.180).考虑检验问题

$$H: \alpha_1 = \cdots = \alpha_m \leftrightarrow K: \alpha_1 \leq \cdots \leq \alpha_m, \alpha_1 < \alpha_m. \quad (4.200)$$

设 e_{ij} 的分布处处连续; R_{ij} 的意义同前. 记

$$R_i = \sum_{j=1}^N R_{ij}, \quad i = 1, \cdots, m.$$

R_i 是处理 i 的各区组的秩的和.

令

$$T_N = \sum_{i=1}^m iR_i. \quad (4.201)$$

若 K 成立, 则 T_N 倾向一取较大的值. 于是可提出(4.200)式的一检验 T 如下:

$$T: \text{当 } T_N > c_N \text{ 时, 否定 } H. \quad (4.202)$$

c_N 依赖于选定的水平 α . 当 N 较大时, 可依据下面的极限定理来近似地决定 c_N :

定理 4.18 设(4.181)式成立, 且 e_{ij} 的分布处处连续, 则在

$$\alpha_1 = \cdots = \alpha_m$$

成立时, 有

$$\frac{12\left(T_N - \frac{Nm(m+1)^2}{4}\right)}{\sqrt{Nm(m+1)}\sqrt{m-1}} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.203)$$

证 记

$$\xi_j = \sum_{i=1}^m iR_{ij}, \quad j = 1, \cdots, N.$$

由假定(4.181)式, 易知当 $\alpha_1 = \cdots = \alpha_m$ 时, $\xi_1, \cdots, \xi_N$ 为 iid. 且

$$E(\xi_1) = \frac{m(m+1)^2}{4}, \quad \text{Var}(\xi_1) = \frac{m^2(m+1)^2(m-1)}{144}.$$

又 ξ_1 是有界的. 由古典中心极限定理立得(4.203)式.

根据(4.203)式, 当 N 较大时, (4.202)式中的 c_N 近似地可取为

$$c_N \approx \frac{Nm(m+1)^2}{4} + u_\alpha \frac{\sqrt{Nm(m+1)}\sqrt{m-1}}{12}.$$

结存在的情况也可作相应的修正. 建议读者自己写出细节.

又: 前面论述的基于 X_{ij}' (见(4.191)式) 的秩的检验, 也可以改造使之针对

此处有方向的对立假设一如多样本问题的情形.

5. 处理效应对照的估计

要估计

$$\alpha = \sum_{i=1}^m c_i \alpha_i, c_i \text{ 已知}, \sum_{i=1}^m c_i = 0.$$

先估计 $\alpha_i - \alpha_j$. 仍假定模型(4.180)式, 并设所有的 e_{ij} 为 iid. 且 e_{ij} 的分布关于 0 对称. 则按例 4.10, 可作出 $\alpha_i - \alpha_j$ 的一估计为

$$\hat{\alpha}_{ij} = \text{med} \left\{ \frac{1}{2} (X_{iu} - X_{ju} + X_{iv} - X_{jv}) : 1 \leq u \leq v \leq N \right\}. \quad (4.204)$$

如果通过将 α 表为 $\sum_{i,j} d_{ij} (\alpha_i - \alpha_j)$ 而直接用(4.204)以作出 α 的估计 $\sum_{i,j} d_{ij} \hat{\alpha}_{ij}$, 则存在如在 4.4.2 小节中提到过的那种缺点, 即这一估计将与 $\sum_{i,j} d_{ij} (\alpha_i - \alpha_j)$ 的选择有关. 为避免这一缺点, 沿用 4.4.2 小节中的方法, 令

$$\hat{\alpha}_i = \sum_{j=1}^m \frac{\hat{\alpha}_{ij}}{m},$$

然后以

$$\hat{\alpha} = \sum_{i,j} d_{ij} (\hat{\alpha}_i - \hat{\alpha}_j) \quad (4.205)$$

估计 α . 显然, $\hat{\alpha}$ 与 $\sum_{i,j} d_{ij} (\alpha_i - \alpha_j)$ 的选择无关. 估计(4.205)式是 Lehmann 在文献[111]中提出的.

4.5 随机性与独立性的检验

4.5.1 随机性检验 (Tests of Randomness)

1. 问题提法与基于线性秩统计量的检验法

设对某个量进行了 N 次独立观察, 将其结果记 $X_1, \dots, X_N$. 如果这 N 次观察是在同样条件下进行的, 则 $X_1, \dots, X_N$ 应有相同的分布 (事实上, 这后一句话正是“同样条件”一词在数学上的确切解释). 反之, 若在观察中存在着某种系统

性因素的影响,则 $X_1, \dots, X_N$ 将不具有相同分布. 以 F_i 记 X_i 的分布, 我们称

$$H: F_1(x) = \dots = F_N(x), \quad -\infty < x < \infty \quad (4.206)$$

为“随机性假设”. 就是说, 观察值 $X_1, \dots, X_N$ 未受到系统性因素的影响.

因此, 从表面上看, 随机性假设与多样本问题(4.154) 完全一样. 但有两点不同之处.

1° 在每个分布 F_i 中只抽样一次, 这相当于多样本问题 $n_i = 1$ 的情况;

2° 由 1° 就带来另一个因素, 即随机性假设(4.206) 式必须针对一定的对立假设才能有效地被检验.

事实上, 如果对分布 F_i 无任何假定, 则无法判明任一组数据是否“随机”的. 这里的“假定”一般并不要求指定分布的具体形式, 而是要求指出其倾向性, 即可能存在的系统因素的影响的性质.

举一个简单例子: 设 $N = 4$, 而

$$X_1 = -1, \quad X_2 = 0, \quad X_3 = 1, \quad X_4 = 10\,000. \quad (4.207)$$

从表面上看, 似乎这组数据不符合随机性假设, 因为其中的一个即 X_4 跑得太远了. 但是, 若有一个分布 F 在 $-1, 0, 1, 10\,000$ 四点附近各集中了 $1/4$ 的概率, 则这组观察值可以看成是从这分布中抽取的, 因而有随机性. 如果假设“ F_i 有 $N(a_i, 1) (i = 1, \dots, 4)$ ”的形式, 则随机性假设相当于 $a_1 = \dots = a_4$, 而根据数据(4.207) 式, 有足够的理由否定这个假设. 或者, 若我们在事先有充分根据认为若系统性因素存在, 它的作用倾向于使 X_i 随 i 增加, 则数据(4.207) 式也使我们充分理由否定随机性假设. 这是因为: 数据的倾向性与我们所了解的系统性因素起作用的方式符合, 而纯粹由于随机性以产生这种情况的概率只有 $1/24 < 0.05$.

在实用上, 最重要的违反随机性的“倾向性”是 X_i 随着 i 的增加有上升或下降的趋势, 或按一定的周期而升降的趋势, 为了表述这一点, 我们利用下述概念: 若 $F_i(x) \leq F_j(x)$ 对一切 x 成立, 则称“ X_i 随机地大于 X_j ”. 这一定义的理由是显然的: 当 $F_i(x) \leq F_j(x)$ 时, X_i 取“小值”的可能性不超过 X_j 取“小值”的可能性, 即 X_i 倾向于比 X_j 大. 这样, 可以提出如下的检验问题:

$$H: F_1(x) = \dots = F_N(x) \text{ 对一切 } x \leftrightarrow K: F_1(x) \geq \dots \geq F_N(x) \\ (F_1, \dots, F_N \text{ 不完全恒等}). \quad (4.208)$$

其他倾向(如下降或周期性) 只要其确切性质已知, 则都可以通过改换顺序而提为(4.208) 式的形状.

检验问题(4.208) 式的一个具体例子如下: 设在某工厂中, 一个工人一般连

续工作八小时. 我们想了解: 是否会因为工作时间过长产生过度疲劳而导致产品质量下降. 为此, 我们每隔一小时抽样一次, 测量该时产品的质量指标, 得到 $X_1, \dots, X_8$, 由此检验随机性假设 $F_1 = \dots = F_8$. 在此, 形如(4.208)式的对立假设是自然的. 当然, 要假定没有其他系统性因素存在, 例如所供的原材料的质量在一天之内大体上是均匀的.

转到假设 H 的检验问题: 先设 F_i 都处处连续. 以 R_{Ni} 记 X_i 在 $X_1, \dots, X_N$ 中的秩. 若(4.208)式中的对立假设 K 成立, 则 $R_{N1}, \dots, R_{NN}$ 倾向于按自然次序 $1, \dots, N$ 排列或与此差别不多, 因而表达式^①

$$D_N = \sum_{i=1}^N (R_{Ni} - i)^2 \quad (4.209)$$

的值倾向于小. 这样就可以引进检验法

$$D: \text{当 } D_N < c_N \text{ 时否定 } H. \quad (4.210)$$

c_N 要按指定的水平 α 决定. 当 $N \leq 6$ 时, c_N 很容易通过简单的组合计算而得出. 对较大的 N 可用如下的正态逼近: 当 H 成立且 $N \rightarrow \infty$ 时, 有

$$\frac{6\left(D_N - \frac{N^3 - N}{6}\right)}{N(N+1)\sqrt{N-1}} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.211)$$

由此可写出当 N 较大时, (4.210) 式中 c_N 的渐近值为:

$$c_N \approx \frac{1}{6}[(N^3 - N) - u_\alpha N(N+1)\sqrt{N-1}]. \quad (4.212)$$

(4.211) 式的证明很容易, 只需注意

$$\sum_{i=1}^N R_{Ni}^2 = \sum_{i=1}^N i^2,$$

因而

$$\begin{aligned} D_N &= 2 \sum_{i=1}^N i^2 - 2 \sum_{i=1}^N i R_{Ni} \\ &= \frac{1}{3} N(N+1)(2N+1) - 2 \sum_{i=1}^N i R_{Ni}. \end{aligned} \quad (4.213)$$

再利用定理 3.6 即可. 注意, 由(4.213)式, 利用(3.2.1)式, 得到当 H 成立时, 有

$$E(D_N) = \frac{N^3 - N}{6}, \quad \text{Var}(D_N) = \frac{N^2(N+1)^2(N-1)}{36}. \quad (4.214)$$

① 由下文(4.213)式可知, 此统计量 D_N 等价于线性秩统计量 $\sum i R_{Ni}$.

关于这个检验的 ARE, Stuart 在文献[159] 和[160] 中考虑了线性回归型的对立假设

$$X_i = \alpha + \beta i + e_i, \quad i = 1, \dots, N. \quad (4.215)$$

这里 α, β 为未知常数, X_i 中的 i 起着回归自变量的作用, 而 $e_1, \dots, e_N$ 为 iid. 随机性假设在此模型中转化为 $\beta = 0$. Stuart 假定 e_i 为正态. 在这种情况下, $\beta = 0$ 的常用检验为一个 t 检验. Stuart 算出 D 检验(4.210) 式对这个 t 检验的 ARE 为 $(3/\pi)^{1/3} \approx 0.98$, 很接近于 1, 后来 Aiyar 以及 Guillier 文献[75] 考虑了模型(4.215), 但 e_i 的分布 F 不必为正态, 证明了

$$\text{ARE}(D, t, F) = \{\text{ARE}(W, t, F)\}^{1/3}.$$

此处 $\text{ARE}(W, t, F)$ 是在两样本位置参数检验问题中 Wilcoxon 秩和检验对 t 检验的 ARE. 由此看出, 对鉴别回归型对立假设(4.215) 式而言, D 检验与传统的 t 检验比较处在很有利的地位.

如果 X_i 的分布不处处连续, 则“结”的问题出现. 用“平均法”决定各 X_i 的秩 $R_{N_i}^*$, 而令

$$D_N^* = \sum_{i=1}^N (R_{N_i}^* - i)^2.$$

例如, $N = 5, X_1 = X_3 = 2, X_2 = X_5 = 6, X_4 = 3$, 则

$$R_{51}^* = R_{53}^* = 1.5, \quad R_{52}^* = R_{55}^* = 4.5, \quad R_{54}^* = 3,$$

而 $D_N^* = 10$. 可以证明: 只要 X_i 的公共分布是非退化的, 则在随机性假设 H 成立时, 当 $N \rightarrow \infty$ 时, 有

$$\frac{N_N^* - A_{N\tau}}{B_{N\tau}} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.216)$$

此处 $\tau = (\tau_1, \dots, \tau_q)$ 为结统计量(在上面的例中, τ 是 $(2, 1, 2)$), 而

$$A_{N\tau} = \frac{1}{6}(N^3 - N) - \frac{1}{12} \sum_{i=1}^q (\tau_i^3 - \tau_i); \quad (4.217)$$

$$B_{N\tau} = \frac{1}{36} N^2 (N+1)^2 (N-1) \left\{ 1 - \sum_{i=1}^q \frac{\tau_i^3 - \tau_i}{N^3 - N} \right\}. \quad (4.218)$$

此结果可用于在结存在的情况下确定大样本检验的临界值.

2. 游程检验(Run Test)

这个检验仍是基于样本的秩, 但所用统计量并非线性秩统计量.

先设 X_i 都只取 0 与 1 两个值(例如, 试验结果只是“成功”或“失败”. 成功为 1, 失败为 0). 则样本 $X_1, \dots, X_N$ 就是一串由 0, 1 构成的记号, 如 01110010. 在这

种序列中,尽可能长的同一符号的一连串称为一个“游程”.例如在上述序列中,共有三个0游程0、00和0,两个1游程111和1.显然,在任何情况下两种游程的数目最多只相差1.

从直观上不难想像:若随机性假设成立,则在序列 $X_1, \dots, X_N$ 中,0、1 错开的时候会较多,因而游程总数 S_N 会倾向于多一些.反之,若存在着某种系统性因素起作用,则0、1要倾向于聚在一起而游程数要少一些.例如,随着时间的增加,可能试验成功的机会愈来愈大,这时1将大部集中在序列的后段.根据这一想法,可引进“游程检验法”如下:

$$S: \text{当 } S_N < c_N \text{ 时,否定随机性假设 } H. \quad (4.219)$$

为了确定临界值,须在 H 成立下考虑 S_N 的分布.

设有 m 个0和 n 个1.将其随意排列(每种排法有同等概率).以 ξ_0 和 ξ_1 分别记0游程和1游程的个数,则

$$\begin{aligned} P(\xi_0 = \xi_1 = k) &= 2 \binom{m-1}{k-1} \binom{n-1}{k-1} / \binom{m+n}{m}; \\ P(\xi_0 = \xi_1 + 1 = k+1) &= \binom{m-1}{k} \binom{n-1}{k-1} / \binom{m+n}{n}; \\ P(\xi_0 = \xi_1 - 1 = k) &= \binom{m-1}{k-1} \binom{n-1}{k} / \binom{m+n}{m}. \end{aligned}$$

关于这个公式的证明,可以参看地文献[63]中第二章5a.由以上诸式并注意到当 $\xi_1 = k$ 时, ξ_0 只能为 k 和 $k \pm 1$, 易得

$$P(\xi_1 = k) = \binom{m+1}{k} \binom{n-1}{k} / \binom{m+n}{m}. \quad (4.220)$$

先证下面的引理:

引理 4.7 设 $\min(m, n) \rightarrow \infty$ 且存在 $\varepsilon > 0$ 和 A , 使当 $m+n > A$ 时,

$$m \geq \varepsilon n, \quad n \geq \varepsilon m. \quad (4.221)$$

则

$$\frac{(m+n)^{3/2}}{mn} \left(\xi_1 - \frac{mn}{m+n} \right) \xrightarrow{\mathcal{L}} N(0, 1) \quad (4.222)$$

对满足(4.221)式的 (m, n) 序列一致地成立.更确切地说,若以 G_{mn} 记(4.222)式左边变量的分布函数,则对任给的 $\delta > 0$, 存在 M , 使

$$\sup\{\|G_{mn} - \Phi\| : m+n > M, m \geq \varepsilon n, n \geq \varepsilon m\} < \delta. \quad (4.223)$$

证 稍加分析论证即不难推出:为证(4.223)式.只需证明:对任给的 $H > 0$, 当 $\min(m, n) \rightarrow \infty$ 时, $G_{mn}(\beta) - G_{mn}(\alpha)$ 在 $-H \leq \alpha < \beta \leq H$ 及(4.221)式的范围内一致地收敛于 $\Phi(\beta) - \Phi(\alpha)$. 为此利用概率论中下述熟知的结果:当 $N \rightarrow \infty$ 时,

$$\binom{N}{k} p^k q^{N-k} \sim \frac{1}{\sqrt{2\pi Npq}} \exp\left\{-\frac{(k - Np)^2}{2Npq}\right\} \quad (4.224)$$

对 $0 < \eta \leq p \leq 1 - \eta < 1$ 及 $(k - Np)^3 N^2 \rightarrow 0 (N \rightarrow \infty)$ 一致地成立^①. 此处 $a \sim b$ 表示 $a/b \rightarrow 1$. 记

$$p_N = \frac{n}{N}, \quad q_N = \frac{m}{N}, \quad N = m + n.$$

由(4.221)式知:当 N 充分大时,

$$0 < \frac{\epsilon'}{1 + \epsilon'} \leq p_N \leq \frac{1}{1 + \epsilon'} < 1.$$

由(4.220)式,有

$$P(\xi_1 = k) = \binom{n-1}{k-1} p_N^{n-k} q_N^{k-1} \binom{m+1}{k} p_N^k q_N^{m+1-k} / \binom{m+n}{n} p_N^n q_N^m. \quad (4.225)$$

对于

$$\frac{mn}{m+n} - H \frac{mn}{(m+n)^{3/2}} < k < \frac{mn}{m+n} + H \frac{mn}{(m+n)^{3/2}}$$

内的 k , 不难看出(4.225)式中三个二项概率都可用(4.224)式, 且一致性条件满足(一致性指对满足(4.221)式的 (m, n)). 从而得到(经过少量化简)

$$\begin{aligned} P(\xi_1 = k) &\approx \frac{1}{\sqrt{2\pi}} = \frac{(m+n)^{3/2}}{mn} \exp\left\{-\frac{(m+n)^3(k - mn/(m+n))^2}{2m^2n^2}\right\} \\ &= A\varphi\left(A\left(k - \frac{mn}{m+n}\right)\right), \end{aligned}$$

$$A = \frac{(m+n)^{3/2}}{mn}, \quad \varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

在此式两边对

$$k \in \left(\frac{mn}{m+n} + \alpha \frac{mn}{(m+n)^{3/2}}, \frac{mn}{m+n} + \beta \frac{mn}{(m+n)^{3/2}}\right)$$

^① 证明可参看文献[63]中第七章第2节. 在该处是对固定的 p 讨论的. 然而, 仔细检查该处的证明, 不难看出所述的一致性成立.

求和,注意到上述一致性及当 $\min(m, n) \rightarrow \infty$ 时, $A \rightarrow 0$, 且(4.221)式成立, 即得要证的结果.

为了证明主要定理, 还需要下面的简单引理.

引理 4.8 设有随机变量 ξ_N 与 $(\eta_{1N}, \dots, \eta_{kN})$ ($N = 1, 2, \dots$). η_{iN} 是取非负整数值的随机变量. 设以下条件满足: 对任给的 $\epsilon > 0$, 存在空间 R^k 中一串集合 $\{A_{i_s}, i = 1, 2, \dots\}$ 及自然数 N_0 , 使

$$1^\circ P\{(\eta_{1N}, \dots, \eta_{kN}) \in A_{N_s}, N > N_0\} \geq 1 - \epsilon;$$

2° 以 $G_{a_{1N}, \dots, a_{kN}}^{(N)}$ 记 ξ_N 在给定 $\{\eta_{iN} = a_{iN}, i = 1, \dots, k\}$ 的条件下, ξ_N 的条件分布函数, 则当 $N \rightarrow \infty$ 时, 有

$$\sup\{\|G_{a_{1N}, \dots, a_{kN}}^{(N)} - \Phi\| : (a_{1N}, \dots, a_{kN}) \in A_{N_s}\} \rightarrow 0,$$

则当 $N \rightarrow \infty$ 时, ξ_N 依分布收敛于 $N(0, 1)$.

证 以 F_N 记 ξ_N 的分布函数; 以 H_N 记 $(\eta_{1N}, \dots, \eta_{kN})$ 的分布函数, 则有

$$\begin{aligned} F_N(x) &= \int_{A_{N_s}} G_{a_{1N}, \dots, a_{kN}}^{(N)}(x) dH_N(a_{1N}, \dots, a_{kN}) \\ &\quad + \int_{R^k - A_{N_s}} G_{a_{1N}, \dots, a_{kN}}^{(N)}(x) dH_N(a_{1N}, \dots, a_{kN}). \end{aligned}$$

由假定 1°, 2° 易知右边第一项任意接近 $\Phi(x)$; 而第二项不超过 ϵ . 从而证明了所要的结果.

有了这些准备, 不难证明下面的定理:

定理 4.19 设 $X_1, \dots, X_N, \dots$ 为 iid.,

$$P(X_1 = 1) = 1 - p, \quad P(X_1 = 0) = p, \quad 0 < p < 1.$$

以 $\xi^{(N)}$ 记 $X_1, \dots, X_N$ 的游程总数, 以 m 记 $X_1, \dots, X_N$ 中 0 的个数 ($n = N - m$), 则当 $N \rightarrow \infty$ 时, 有

$$\left(\xi^{(N)} - \frac{2mn}{m+n}\right) / \{2mn(m+n)^{-3/2}\} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.226)$$

证 取定 $\eta, 0 < \eta < \min(p, 1-p)$. 由强大数律知, 对任给的 $\epsilon > 0$, 存在 N_0 , 使

$$P\left\{\left|\frac{n}{N} - p\right| \leq \eta, \mid N > N_0\right\} \geq 1 - \epsilon.$$

取引理 4.8 中的 $k = 2, \eta_{1N} = m, \eta_{2N} = n$. 又

$$A_{N_s} = \left\{(u, v) : u, v \text{ 为非负整数}, u + v = N, \left|\frac{v}{N} - p\right| \leq \eta\right\}, \quad N > N_0;$$

$$A_{N_0} = \{(u, v): u, v \text{ 为非负整数}, u + v = N\}, \quad 1 \leq N \leq N_0.$$

在给定 $\eta_{1N} = u, \eta_{2N} = v (u + v = N, u, v \text{ 为非负整数})$ 时, $\xi^{(N)}$ 的条件分布等于由 u 个 0 和 v 个 1 构成的序列中经过随机排列所得到的总游程数年的分布. 由 A_{N_0} 的做法知它满足引理 4.8 的条件 1°. 又若记

$$\epsilon' = \min\left(\frac{p - \eta}{1 - p + \eta}, \frac{1 - p - \eta}{p + \eta}\right),$$

当 $\epsilon' > 0$, 且当 $u + v = N > N_0$ 时,

$$(u, v) \in A_{N_0} \Rightarrow u \geq \epsilon' v, \quad v \geq \epsilon' u.$$

于是引理 4.7 的条件 (4.221) 满足, 由引理 4.7 的结论知, 若将引理 4.8 中的 ξ_N 取为 $X_1, \dots, X_N$ 中的 1 游程的个数 $\xi_1^{(N)}$, 则该引理的条件 2° 也满足. 因此由引理 4.7 和 4.8 得

$$\left(\xi_1^{(N)} - \frac{mn}{m+n}\right) / \{mn(m+n)^{-3/2}\} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.227)$$

但 $|\xi^{(N)} - 2\xi_1^{(N)}| \leq 1$ 而 $mn(m+n)^{-3/2} \xrightarrow{p} \infty$, 故由 (4.227) 式即得 (4.226) 式定理证毕.

据此定理, 当 N 较大时, 检验法 (4.219) 式中的 c_N 近似地可取为

$$c_N \approx \frac{2mn}{m+n} - u_\alpha \frac{2mn}{(m+n)^{3/2}}. \quad (4.228)$$

值得注意的是: (4.228) 式右边并不是一常数, 而随机变量.

现在考虑 X_i 取值不必限于 0 与 1 的一般情况. 为确定计, 仍针对 (4.208) 式的对立假设来讨论. 有一些方法可将问题转化为 0 与 1 情况:

1° 中位数法: 记 $\tilde{X}_N = \text{med}\{X_1, \dots, X_N\}$, 令

$$\text{当 } X_i \leq \tilde{X}_N \text{ 时, } Y_{Ni} = 0; \quad \text{当 } X_i > \tilde{X}_N \text{ 时, } Y_{Ni} = 1.$$

则 $(Y_{N1}, \dots, Y_{NN})$ 构成一 0-1 序列, 当随机性假设成立时, 显然这个序列仍具有下列性质: 若给定这序列有 n 个 1, 则这 n 个 1 占据 N 个位置中的任意几个的条件概率都等于 $1/\binom{N}{n}$. 另外, 若假定在随机性假设成立下, X_1 的分布满足条件

$$P(X_i \leq \mu) < 1 \text{ (对 } X_1 \text{ 的任何中位数 } \mu). \quad (4.229)$$

以 $\tilde{\mu}$ 记 X_1 的中位数区间 (即由 X_1 的全体中位数构成的闭区间) 的中点. 由 (4.229) 式知

$$0 < p \triangleq P(X_1 > \bar{\mu}) < 1.$$

以 n 记 $Y_{N1}, \dots, Y_{NN}$ 中 1 的个数, 由强大数律有 $n/N \rightarrow p, a.s.$. 因此, 若记

$$\xi^{(N)} = \text{序列 } Y_{N1}, \dots, Y_{NN} \text{ 所含游程总数}, \quad (4.230)$$

则对 $\xi^{(N)}$ 而言, 为证明定理 4.19 的结论(4.226)式所需的条件, 全都成立. 因此, 当 N 较大时, 检验法

$$\text{“当 } \xi^{(N)} < c_N \text{ 时否定随机性假设”} \quad (4.231)$$

中的 c_N 仍可用近似公式(4.228).

检验法(4.231)式是出自如下的直观想法: 若 X_i 有上升的趋势, 则当 i 较小时, Y_{Ni} 多为 0; 而当 i 较大时, 则多为 1, 这样, $\xi^{(N)}$ 将倾向于缩小.

2° 差分法: 为方便计, 将样本写为 $X_0, X_1, \dots, X_N$. 令

$$Y_{Ni} = 0 \text{ 或 } 1, \text{ 视 } X_i \leq X_{i-1} \text{ 或 } X_i > X_{i-1} \text{ 而定 } (i = 1, \dots, N).$$

仍定义 $\xi^{(N)}$ 如(4.230)式. 若 X_i 有随 i 上升的趋势, 则 Y_{Ni} 中等于 1 的居多, 而 $\xi^{(N)}$ 将倾向于缩小. 反之, 若 $X_0, \dots, X_N$ 为 iid., 则 0 与 1 错杂的机会大, 而 $\xi^{(N)}$ 将倾向于增大, 因此, 检验法(4.231)式仍适用. 但是 $\xi^{(N)}$ 的分布与前面讨论过的情况不同. 例如, 这样一个命题不成立: “在给定 $Y_{N1}, \dots, Y_{NN}$ 中的 1 个数为 n 的条件下, 这 n 个 1 以同样概率占据 N 个位置中的任意 n 个”. 事实上, 令 $N = 3$. 设 $X_0, \dots, X_3$ 为 iid., 而且 X_0 的分布连续, 则经简单计算得出:

$$P(Y_{31} = Y_{32} = 1, Y_{33} = 0) = P(Y_{31} = 0, Y_{32} = Y_{33} = 1) = \frac{1}{8};$$

$$P(Y_{31} = Y_{33} = 1, Y_{32} = 0) = \frac{5}{24}.$$

于是在 $n = 2$ 的条件下, 三种可能配置 $(1, 1, 0)$ 、 $(1, 0, 1)$ 和 $(0, 1, 1)$ 的条件概率分布是 $3/11$ 、 $5/11$ 与 $3/11$, 它们不相同. 因此, 对此处的 $\xi^{(N)}$ 而言, 引理 4.7 和定理 4.19 的结论都不成立. 如果在直角坐标上标出 $N+1$ 个点 (i, X_i) ($i = 0, \dots, N$), 用直线段将它们连接起来, 则 $Y_{N1}, \dots, Y_{NN}$ 所含游程数将等于此折线的“转折点”(即由升到降或由降到升的点)即“极值点”的个数加 1. Edgington 文献 [60] 在随机性假设成立下给出了这种点数的分布表.

4.5.2 独立性检验

1. Spearman 秩相关检验

设二维随机向量 (X, Y) 的分布 $F(x, y)$ 未知. 现有了 (X, Y) 的 iid. 样本

$(X_i, Y_i) (i = 1, \dots, N)$, 要检验假设

$$H: X \text{ 与 } Y \text{ 独立.} \quad (4.232)$$

与随机性检验的问题相似, 若不对 (X, Y) 的分布 $F(x, y)$ 或可能的对立假设加以一定的限制, 则这个假设 H 事实上是无法检验的. 一种有实用意义的对立假设是

$$K: X, Y \text{ 呈正相关.} \quad (4.233)$$

“正相关”一词表示当 X, Y 中一个增加时, 另一个也倾向于增加. 可以用种种方式把这个描述性的说明弄得更确切. 例如可以把“正相关”定义为“相关系数大于 0”. 这一解释的缺点在于: 相关系数的存在要求 X, Y 都有二阶矩, 而且相关系数只刻画了线性相关的程度, 与此处解释的意义并不切合. 还有, 相关系数本质上是一个参数统计的概念, 大体上可以说: 它只在 (X, Y) 服从二维正态分布时才较有用. 另一个较切合的解释是: 以 $F_{x \cdot}$ 和 $F_{\cdot y}$ 分别记在给定 $X = x$ 时 Y 的条件分布及给定 $Y = y$ 时 X 的条件分布. 我们称 X, Y 正相关: 若 $1^\circ. x_1 < x_2 \Rightarrow F_{x_2 \cdot}$ 随机地大于 $F_{x_1 \cdot}$; $2^\circ. y_1 < y_2 \Rightarrow F_{y_2 \cdot}$ 随机地大于 $F_{y_1 \cdot}$. 这个解释切合“正相关”概念的原意, 不足之处在于: 以上 $1^\circ, 2^\circ$ 两项不能彼此推出, 即 1° 成立时不必有 2° . 反之亦然 (举个实例如下: (X, Y) 只取 $(0, 0), (1, 1), (1, 3), (2, 2)$ 与 $(2, 3)$ 五组值, 每组值的要概率为 $1/5$. 容易验证, 这时 1° 成立, 但 2° 不然).

先满足于这种一般性的解释, 来讨论假设 (4.232) 式的检验, 对立假设为 (4.233) 式. 先设 (X, Y) 的分布连续. 以 R_{Ni} 和 Q_{Ni} 分别记 X_i 在 $(X_1, \dots, X_N)$ 中的秩、 Y_i 在 $(Y_1, \dots, Y_N)$ 中的秩. 若 X, Y 呈正相关, 则 X_i 与 Y_i 有“同步”性, 因此当 Q_{Ni} 大(小)时, R_{Ni} 也倾向于大(小), 故

$$S_N = \sum_{i=1}^N (Q_{Ni} - R_{Ni})^2 \quad (4.234)$$

将倾向于小. 反之, 若 X, Y 独立, 则 T_N 将倾向于大一些. 这导致如下的检验:

$$S: \text{当 } S_N < c_N \text{ 时否定 } H. \quad (4.235)$$

不难看出: 若 H 成立, 则 $(Q_{N1}, \dots, Q_{NN})$ 与 $(R_{N1}, \dots, R_{NN})$ 独立. 因此给定 $(Q_{N1}, \dots, Q_{NN})$ 后, S_N 的条件分布等于其无条件分布. 现给定 $Q_{Ni} = i (i = 1, \dots, N)$, 就得出: 在原假设 H 下, 由 (4.234) 式定义的 S_N 的分布与 (4.209) 式定义的统计量 D_N 的分布 (在该处的原假设下) 相同. 这样一来, 在前面所谈到过的关于 D_N 分布的事实, 包括当 $N \rightarrow \infty$ 时的渐近正态性及临界值 c_N 的近似确定等, 都可以原封不动地移用于此处.

使用秩来作独立性检验,始于 Spearman,他在 1904 年文献[152]中引进了 N 组秩 $(Q_{Ni}, R_{Ni}) (i = 1, \dots, N)$ 的相关系数,即

$$r_N = \frac{\sum_{i=1}^N (Q_{Ni} - \bar{Q}_N)(R_{Ni} - \bar{R}_N)}{\left\{ \sum_{i=1}^N (Q_{Ni} - \bar{Q}_N)^2 \sum_{i=1}^N (R_{Ni} - \bar{R}_N)^2 \right\}^{1/2}}, \quad (4.236)$$

称为 Spearman 秩相关系数. 此处

$$\bar{Q}_N = \frac{1}{N} \sum_{i=1}^N Q_{Ni} = \frac{N+1}{2},$$

$$\bar{R}_N = \frac{1}{N} \sum_{i=1}^N R_{Ni} = \frac{N+1}{2}.$$

当 r_N 取大值时否定 H . 不难看出, (4.234) 式定义的 S_N 与 r_N 只相差一线性变换. 事实上, 易见

$$S_N = \frac{1}{3} N(N+1)(2N+1) - 2 \sum_{i=1}^N Q_{Ni} R_{Ni};$$

$$r_N = \frac{12}{N^3 - N} \left\{ \sum_{i=1}^N Q_{Ni} R_{Ni} - \frac{1}{4} N(N+1)^2 \right\} = 1 - \frac{6S_N}{N^3 - N}.$$

由此即得上述结论. 由此可知, 基于 S_N 的检验与基于 r_N 的检验完全一样. 关于在原假设 H 之下当 $N \rightarrow \infty$ 时 r_N 的渐近正态性, 首先是由 Hotelling 等于 1936 年在文献[92]中证明的. 当时线性秩统计量的一般理论尚未建立起来.

关于这个检验的效率, 设对立假设为二维正态分布 $N(a, b, \sigma_1^2, \sigma_2^2, \rho)$ ($\rho > 0$, 独立性相当于 $\rho = 0$). 在这个场合, 一个常用的检验是基于样本相关系数

$$\frac{\sum_{i=1}^N (X_i - \bar{X}_N)(Y_i - \bar{Y}_N)}{\left\{ \sum_{i=1}^N (X_i - \bar{X}_N)^2 \sum_{i=1}^N (Y_i - \bar{Y}_N)^2 \right\}^{1/2}}$$

(大值否定). Spearman 的秩检验对此检验的 ARE 是 $9/\pi^2 \approx 0.912$ (参看文献[104]).

也可以用 $a_N(Q_{Ni})$ 和 $a_N(R_{Ni})$ 分别代替 (4.234) 式中的 Q_{Ni} 及 R_{Ni} , 此处 a_N 是非降记分函数. 这样构成的统计量

$$S_N^* = \sum_{i=1}^N \{a_N(Q_{Ni}) - a_N(R_{Ni})\}^2$$

与统计量

$$\tilde{S}_N = \sum_{i=1}^N a_N(Q_{Ni}) a_N(R_{Ni})$$

只相差一个线性变换, 故若一者为渐近正态, 则他者亦然. 但在原假设 H 成立时, 如在前面讨论(4.234) 式的 S_N 时所指出的:

$$\tilde{S}_N \stackrel{d}{=} \sum_{i=1}^N a_N(i) a_N(R_{Ni}).$$

故由定理 3.6 和 3.8 知, 当 $a_N(i)$ 中有 $\phi\left(\frac{i}{N+1}\right)$ 或 $E\phi(U_{(i)})$ 的形式, 其中 ϕ 为平方可积积分函数, 而 $U_{(1)} \leq \dots \leq U_{(N)}$ 为 $R(0,1)$ 的次序样本, 则

$$\sqrt{N-1}(\tilde{S}_N - N\bar{a}_N^2) / \sum_{i=1}^N (a_N(i) - \bar{a}_N)^2 \xrightarrow{\mathcal{L}} N(0,1). \quad (4.237)$$

此处

$$\bar{a}_N = \frac{1}{N} \sum_{i=1}^N a_N(i).$$

过渡到 S_N^* , 成为

$$\sqrt{N-1} \left\{ S_N^* / \left(2 \sum_{i=1}^N (a_N(i) - \bar{a}_N)^2 \right) - 1 \right\} \xrightarrow{\mathcal{L}} N(0,1). \quad (4.238)$$

这提供了确定基于 S_N^* 的大样本临界值的方法. 特别, 取

$$a_N(i) = \Phi^{-1}\left(\frac{i}{N+1}\right),$$

所得检验称为**正态记分检验**. 证明了(参见文献[39]): 针对正态对立假设 $N(a, b, \sigma_1^2, \sigma_2^2, \rho)$ 而言, 正态记分检验对基于样本相关系数的检验的 ARE 等于 1.

在 X 或 Y 的分布非处处连续时, 可以用平均法处理“结”的问题, 以 Spearman 秩相关检验为例. 分别以 $\tau = (\tau_1, \dots, \tau_p)$ 和 $\eta = (\eta_1, \dots, \eta_q)$ 记 X 样本的结统计量与 Y 样本的结统计量. 用平均法所得到的 X_i 在 $(X_1, \dots, X_N)$ 和 Y_i 在 $(Y_1, \dots, Y_N)$ 中的秩, 分别记为 Q_{Ni}^* 和 R_{Ni}^* , 仍记

$$S_N = \sum_{i=1}^N (Q_{Ni}^* - R_{Ni}^*)^2. \quad (4.239)$$

可以证明: 若原假设 H 成立, 且 X, Y 的(边缘)分布都非退化, 则当 $N \rightarrow \infty$ 时,

$$\frac{S_N - A_N}{B_N} \xrightarrow{\mathcal{L}} N(0,1). \quad (4.240)$$

其中

$$A_N = \frac{1}{6}(N^3 - N) - \frac{1}{12} \sum_{i=1}^p (\tau_i^3 - \tau_i) - \frac{1}{12} \sum_{i=1}^q (\eta_i^3 - \eta_i); \quad (4.241)$$

$$B_N^2 = \frac{1}{36}(N-1)N^2(N+1)^2 \left\{ 1 - \sum_{i=1}^q \frac{\tau_i^3 - \tau_i}{N^3 - N} \right\} \\ \times \left\{ 1 - \sum_{i=1}^q \frac{\eta_i^3 - \eta_i}{N^3 - N} \right\}. \quad (4.242)$$

由此可确定基于 S_N 的大样本检验临界值:

$$S_N < A_N - u_\alpha B_N.$$

2. Kendall 检验

仍设 $(X_i, Y_i) (i = 1, \dots, N)$ 为 (X, Y) 的 iid. 样本. 以 F_1 和 F_2 分别记 X 和 Y 的(边缘)分布. 为简单计, 设 F_1 和 F_2 都连续. 考虑

$$p = P\{(X_2 - X_1)(Y_2 - Y_1) > 0\},$$

若原假设 H 成立, 则 $p = 1/2$. 若 X, Y 为正相关, 则 p 倾向于 $> 1/2$ (可以把 $p > 1/2$ 作为正相关的定义). Kendall 引进度量 $\tau = 2p - 1$. 当 X, Y 独立时, $\tau = 0$, 而当 X, Y 正(负)相关时, τ 大于(小于)0. 故通过检验 p 或 τ , 可以提供独立性的一种检验.

我们用 U 统计量的方法对 τ 作一估计. 引进核函数

$$\varphi((x_1, y_1), (x_2, y_2)) = \begin{cases} 1, & (x_2 - x_1)(y_2 - y_1) > 0; \\ -1, & (x_2 - x_1)(y_2 - y_1) \leq 0. \end{cases} \quad (4.243)$$

以 K_N 记以 φ 为核的 U 统计量:

$$K_N = \left[\frac{N}{2} \right]^{-1} \sum_{1 \leq i < j \leq N} \varphi((X_i, Y_i), (X_j, Y_j)). \quad (4.244)$$

不论 H 是否成立, K_N 总是 τ 的无偏估计. 当 H 成立时, 由 X, Y 的分布 F_1 和 F_2 的连续性, 得

$$\varphi_1(x, y) \triangleq E\varphi((x, y), (X_2, Y_2)) \\ = 1 - 2F_1(x) - 2F_2(y) + 4F_1(x)F_2(y).$$

在 H 成立且 F_1, F_2 连续时, $F_1(X_1)$ 和 $F_2(Y_1)$ 独立的 $(0, 1)$ 均匀分布. 由此不难算出

$$E\varphi(X_1, Y_1) = 0, \quad \text{Var}\varphi(X_1, Y_1) = \frac{1}{9}.$$

于是由定理 2.1 知, 在 H 成立时, 有

$$\frac{3\sqrt{N}K_N}{2} \xrightarrow{\mathcal{L}} N(0,1). \quad (4.245)$$

由此得出一基于 K_N 的大样本检验:当

$$K_N > \frac{2u_\alpha}{3\sqrt{N}}, \quad (4.246)$$

时,否定原假设 H .也可以考虑双边性的对立假设,即对立假设可为正相关,也可为负相关,这时相应的否定域为

$$|K_N| > \frac{2u_{\alpha/2}}{3\sqrt{N}}. \quad (4.247)$$

值得注意的是:由 φ 的形状(4.243)式易知,由(4.244)式定义的统计量 K_N 只与前文的 Q_{Ni} 和 R_{Ni} 有关,因而是一个秩统计量.

度量 τ 是 Kendall 于 1938 年在文献[97]中引进的. Kendall 在其著作[99]中对 τ 及上述检验作了研究.在 H 成立时,统计量 K_N 的小样本分布表可参看文献[38]和[96].结存在的情况可参看文献[42]和[147].

3. 列联表检验

列联表检验是独立性检验的一个重要方面,也可以从多样本问题的角度去研究.列联表是在统计文献中很受注意的一个题目.在现今积累的成果中,与秩方法有关的只占一小部分.例如在初等教本中常用的 χ^2 检验法就与秩无关.这里举出列联表中一两个问题以说明秩方法的作用.

设有列联表(表 4.2)如下:

表 4.2

列 行	1	2	...	t	和
1	n_{11}	n_{12}	...	n_{1t}	$n_{1\cdot}$
2	n_{21}	n_{22}	...	n_{2t}	$n_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
s	n_{s1}	n_{s2}	...	n_{st}	$n_{s\cdot}$
和	d_1	d_2	...	d_t	N

表中 s 行可视为 s 个处理,如治一种病 s 种药物. t 列可视为 t 种不同的反应.如“很有效”、“有效”、“效果小”等.反应可以是数量的或非数量的.这种看法相当于把每行(每个处理)看作一个总体,因而表 4.2 更切合地解释为一个多总体

(或说多样本)问题.特殊之处在于:样本取值不必是数量性的,即使是,这种数量也只有分等的意义,而且包含了不少的结.

另一种看法是把行列看成是一个体的某两种属性.这时表 4.2 解释为两变量的关系问题(是否独立等).严格地说,这两种看法所导致的问题在模型上很不一样,但一般都不大拘泥于这种差别(参看文献[3]中第 315 页).

以下为确定计,采用第一种看法,按这种看法,所要检验的原假设是

$$H: \text{处理效应不存在.} \quad (4.248)$$

更确切一些,就是说处理 i 得到反应 j 的概率与 i 无关.至于对立假设,最一般的自然是“处理效应存在”,即上述概率不仅与 j 也与 i 有关.这是一个没有方向性的假设.在初等教程中常见的 χ^2 检验就是针对这种对立假设而作.这对于初步性研究未尝不可,但在许多应用问题中,往往有些先验性知识,使我们可以认为不同的处理在一定意义上有好坏的比较.例如,为方便计可设当 $j < k$ 时,反应 k 优于反应 j .处理 u 优于 v 可解释为:使用处理 u 较之于 v 倾向于更能得到标号较大的反应.这可以根据问题的需要用数学形式确切地表现出来.在此可分为两个情况:其一是在对立假设下,只知道处理之间有优劣之分,但不知优劣的次序;其二是知道这种次序,例如,编号愈大的处理愈优等等.以下分别讨论这两种情况.

先讨论第一种情况:如上所述,我们把反应的标号作为其优劣的表征——若 $j < k$,则反应 k 优于反应 j .这样,即使反应并不具有数量的形式,但还是可以对表 4.2 中的数据排秩.例如,有 d_1 个样本属于反应 1,按平均法,每个秩为

$$\frac{1}{2}(d_1 + 1);$$

有 d_2 个样本属于反应 2,每个秩为

$$d_1 + \frac{1}{2}(d_1 + 1), \dots$$

由于假定了当两个处理的效应不同时可以分出优劣,且优越性表现在取标号大的反应的机会增多.因而,较优的处理其样本倾向于有较大的秩.尽管在这里对立假设并不具有(4.155)式那种位置参数的类型,但该处所作的最后导致检验统计量(4.164)的论点(这里 $a_N(i)$ 取为 i ,而转化为(4.166)式)在此全部有效.注意到对表 4.2 而言,结统计量为 $(d_1, \dots, d_s)$,而相当于(4.166)式中的 R_i^* ,则第 i 处理所有观察值的秩的平均为

$$R_i^* = \frac{1}{n_i} \sum_{j=1}^i \left(\sum_{r=1}^j d_r - \frac{1}{2}(d_j - 1) \right), \quad i = 1, \dots, s. \quad (4.249)$$

得到统计量(4.166)的值为

$$K_N^* = \left[1 - \frac{\sum_{j=1}^t (d_j^3 - d_j)}{N^3 - N} \right]^{-1} \frac{12}{N(N+1)} \sum_{i=1}^R \left(R_i^* - \frac{N+1}{2} \right)^2. \quad (4.250)$$

其中 R_i^* 由(4.249)式确定, 而 $N = n_1 + \cdots + n_s$. 如曾指出的(见 4.166)式下面一行), 当 $\min(n_1, \cdots, n_s) \rightarrow \infty$ 而原假设 H 成立时,

$$K_N^* \xrightarrow{\mathcal{L}} \chi_{s-1}^2.$$

因此, 以

$$K_N^* > \chi_{s-1}^2(\alpha) \quad (4.251)$$

为否定域的检验有渐近水平 α .

例 4.13 设有治疗某种疾病的三种药物 A 、 B 、 C (可以设想其中的一种, 例如 A 是原有的, 而 B 、 C 是新产品), 在 167 名患者身上做试验, 这 167 人开始时病情都相当且较重, 而其他条件, 如年龄、体质等也较均匀. 这样做自然是为了减少其他因素对试验结果的干扰. 事先决定对 70 名患者施用药物 A , 对 30 名施用 B , 对其余的施用 C . 但将何人分在何组, 则用随机化方法决定. 经过一段时期治疗而评价效果, 所以数据如下表 4.3 所示 (此例的数据取自文献[112] 中第 306 页):

表 4.3

反应 药物	严重	中度	轻度	痊愈	和
A	8	8	19	35	70
B	2	3	5	20	30
C	3	4	15	45	67
和	13	15	39	100	167

表中“反应”在此指的是一个患者经过一段治疗后其病情的发展程度.

在此例中, $d_1 = 13, d_2 = 15, \cdots, n_1 = 70, n_2 = 30, n_3 = 67; N = 167$; 而

$$R_1^* = \frac{1}{70} (8 \times 7 + 8 \times 21 + 19 \times 48 + 35 \times 117.5) = 74.9786,$$

$$R_2^* = 889, \quad R_3^* = 91.2313.$$

代入(4.250)式, 算出 $K_N^* = 5.5009$, 而

$$P(\chi_2^2 > 5.5009) = 0.064.$$

因此, 如将水平 α 定为 0.05, 由所得的试验数据尚不能作出“药物疗效有差别”

的结论.

现讨论第二种情况:回到表 4.2, 表中的 s 个处理的效应若有差别, 则优劣是按编号的次序, 即处理 s 最优, 其次为 $s-1, \dots$, 处理 1 最差. 这就是所考虑的对立假设. 更确切地, 不如说针对这样的对立假设去构造一个检验法. 自然, 这种检验法是否成功, 取决于真正的对立假设是否的确如此. 若是, 则这种检验比那种面向四方的检验要有效. 若不然, 效果就可能很差.

所考虑的检验基于这样一个简单的想法: 每个样品按两种方式定秩, 一是在试验前, 一是在试验后. 例如, 表 4.2 中 (i, j) 一格共有 n_{ij} 个样品. 其中任一个在试验时施加处理 i . 在未曾看到试验结果之前, 它的秩按平均法应为

$$R_i = n_1 + n_i - \frac{1}{2}(n_i - 1).$$

其理由与导出 (4.249) 式的一样. 在看到处理结果 (反应 j) 后, 再从反应优劣等级次序去计算基秩, 应为

$$Q_j = d_1 + \dots + d_j - \frac{1}{2}(d_j - 1).$$

如果对立假设正确, 即编号大的处理倾向于产生编号大的反应, 则 R_i 和 Q_j 应比较接近. 反之, 若对立假设不正确, 则二者偏差会倾向于大一些. 因此算出 $(R_i - Q_j)^2$, 并对全部 N 个样品求和, 得统计量

$$D_N = \sum_{i=1}^s \sum_{j=1}^t n_{ij} (R_i - Q_j)^2. \quad (4.252)$$

并提出以 D_N 的大值为否定域的检验.

细心的读者一定会注意到, 统计量 (4.252) 可以看成是检验随机性的统计量 (4.209) 的推广, 这只要容许从一个总体中可以抽出不止一个样本来, 事实上, 这里导出统计量 (4.252) 所持的论据与当时导出 (4.209) 者如出一辙. 不同的是, 此处数据排成一个二维表, 看来似乎复杂些.

可以证明, 当 $\min(n_1, \dots, n_s) \rightarrow \infty$ 时, 有

$$\frac{D_N - A_N}{B_N} \xrightarrow{\mathcal{L}} N(0, 1). \quad (4.253)$$

此处 A_N, B_N 就由公式 (4.241) 和 (4.242) 决定, 但把其中的 p, q 分别改为 s, t , τ_i 和 η_i 分别改为 n_i 和 d_j .

例 4.14 再考虑例 4.12, 所考虑的对立假设规定: C 优于 B , B 优于 A . 以 $(1, 1)$ 格来说, 在试验前后的秩分别是

$$\frac{1}{2}(1+70) = 35.5 \quad \text{及} \quad \frac{1}{2}(1+13) = 7.$$

故此格($n_{11} = 8$)对 D_N 的贡献为 $8(35.5 - 7)^2 = 6498$. 依次算出各格的贡献, 求得 $D_N = 521459.5$. 依据表 4.3 给出的 n_i, d_j, N 的值, 按公式(4.241) 和 (4.242), 算出 $A_N = 631.606, B_N = 48955.79$. 于是得到

$$\frac{D_N - A_N}{B_N} = -2.2499.$$

而 $\Phi(-2.2499) = 0.0123$. 因此表 4.3 中的数据即使在显著性水平只略大于 0.01 时, 也倾向于否定原假设. 这样, 同一批数据按例 4.13 和例 4.14 不同的方式处理, 得到的结论很不同. 解释无非是: 例 4.12 的做法是: 在先验知识甚少的情况下, 采取了较保守的检验法(它不轻易否定原假设. 但应注意, 常用的 χ^2 检验比此更保守: 算出的 χ^2 值为 6.358, 超过它的概率达到 0.384), 而例 4.14 则在有较多先验知识的条件下, 采取了有针对性的检验法. 重要的是, 选定何种检验方法, 应独立于数据进行. 就是说, 只能用试验前已有的知识.

4.6 Смирнов 检验与 Колмогоров 检验

在 20 世纪 30 年代, 前苏联学者 Колмогоров 和 Смирнов 先后引进了一种基于经验分布函数的非参数检验. 前者是一个拟合优度检验; 后者是一个两样本检验. 几十年以来, 许多研究者在这方面作了大量的工作. 我国的张里千等同志在 20 世纪 50 年代曾作出过重要结果.

由于在这个方向上几乎所有的重要结果都没有简单的证法, 而大量的繁琐证明又不适合于写进本书, 因此, 我们打算把这方面的材料写成一章. 而只用少量篇幅介绍一些在统计应用上最有兴趣的内容, 并指出若干重要文献以供读者作进一步研究. 因为 Смирнов 检验的统计量只与样本的秩有关, 将它放在本章内叙述是自然的; 至于 Колмогоров 检验, 并不是一个秩检验. 考虑到它与 Смирнов 检验的密切关系, 按照通常的习惯, 我们把它也写在本节之节.

4.6.1 Смирнов 检验

设样本 $X_1, \dots, X_m \sim F; Y_1, \dots, Y_n \sim G$. F, G 都是未知的一维连续分布

函数. 要检验假设

$$H: F(x) \equiv G(x), \quad (4.254)$$

其对立假设可以是单边的或双边的. 双边的有形式

$$K_1: F(x) \neq G(x); \quad (4.255)$$

而单边的有形式

$$K_2: F(x) \leq G(x) \text{ 对一切 } x \text{ 成立, 但 } F(x) \neq G(x) \quad (4.256)$$

(或 $K_3: F(x) \geq G(x)$ 对一切 x 成立, $F(x) \neq G(x)$).

分别以 $F_m(x)$ 和 $G_n(x)$ 记 $X_1, \dots, X_m$ 及 $Y_1, \dots, Y_n$ 的经验分布函数. Смирнов 在 1939 年(见文献[149])引进了以下的统计量:

$$S_{mn} = \sup_x |F_m(x) - G_n(x)|; \quad (4.257)$$

$$S_{mn}^+ = \sup_x (G_n(x) - F_m(x)). \quad (4.258)$$

以分别用于对立假设为双边及单边的情况, 即:

$$\text{对 } H \longleftrightarrow K: \text{当 } S_{mn} > c_{mn} \text{ 时否定 } H; \quad (4.259)$$

$$\text{对 } H \longleftrightarrow K_1: \text{当 } S_{mn}^+ > c_{mn}^+ \text{ 时否定 } H. \quad (4.260)$$

这里 c_{mn} 和 c_{mn}^+ 是适当选择的常数, 取决于 m, n 及检验的水平 α . 不难看出: 不论是 S_{mn} 或 S_{mn}^+ 的值, 都只与 $X_1, \dots, X_m$ 在合样本 $(X_1, \dots, X_m; Y_1, \dots, Y_n)$ 中的秩 $R_1, \dots, R_m$ 有关. 以 $m = 2, n = 3$ 为例, 有表 4.4

表 4.4

(R_1, R_2)	(1,2)	(1,3)	(1,4)	(1,5)	(2,3)	(2,4)	(2,5)	(3,4)	(3,5)	(4,5)
S_{23}	1	$\frac{2}{3}$	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{2}{3}$	$\frac{1}{3}$	$\frac{1}{2}$	$\frac{2}{3}$	$\frac{2}{3}$	1

因此, 在分布函数 F, G 处处连续的条件下, 当 H 成立时, S_{mn} 与 S_{mn}^+ 的分布都与 F, G 无关, 而(4.259)式与(4.260)式都是相似检验^①. 要决定 c_{mn} 和 c_{mn}^+ , 须计算 S_{mn} 和 S_{mn}^+ 在 H 成立之下的分布. 在 $m = n$ 时, Гнеденко 等在 1951 年定出了这个分布(见文献[73]). 在实际应用时可查专门为此检验制作的表, 例如在 Harter 和 Owen 的统计表^[84]中, 包括了 m 和 n 都不超过 100 的情况. 当 m, n 取更大的

① 易见当 $F \equiv G$, 但 F 非处处连续, 则 S_{mn}, S_{mn}^+ 当 H 成立时的分布仍与 F 有关, 故(4.259)、(4.260)式不再为相似. 这时, 仍可使用在连续情况下定出的 c_{mn} 和 c_{mn}^+ , 所指定的水平 α 保持有效.

值时,可使用 Смирнов 在文献[149]中证明下述极限定理:记 $N = m + n$. 设 $N \rightarrow \infty$ 时,

$$0 < \liminf \frac{m}{N} \leq \limsup \frac{m}{N} < 1,$$

则在 H 成立的条件下,有

$$\lim_{N \rightarrow \infty} P\left(\sqrt{\frac{mn}{N}} S_{mn} \leq x\right) = K(x). \quad (4.261)$$

其中 $K(x)$ 由(1.41)式给出. 又

$$\lim_{N \rightarrow \infty} P\left(\sqrt{\frac{mn}{N}} S_{mn}^+ \leq x\right) = (1 - e^{-2x^2}) I_{(x>0)}. \quad (4.262)$$

利用这些极限定理,可以在 m, n 都比较大时决定 c_{mn} 和 c_{mn}^+ 的近似值. 例如分布 $K(x)$ 的 0.99 和 0.95 分位点分别为 1.628 和 1.358. 依此,当 m 和 n 都较大时,若检验的水平取为 $\alpha = 0.05$ 或 0.01, 则 c_{mn} 可近似地取为 $1.358 \sqrt{(m+n)/mn}$ 或 $1.628 \sqrt{(m+n)/mn}$.

关于 Смирнов 检验的一个一般性的讨论,可参看 Steck 的工作^[155].

4.6.2 Колмогоров 检验

设 $X_1, \dots, X_n$ 为从一个总体中抽出的 iid. 样本,而 $F(x)$ 为一个已知的连续分布函数. 要检验假设.

$$H: \text{总体分布是 } F(x). \quad (4.263)$$

对立假设一般取为 K : 总体分布不是 $F(x)$. 也可以考虑某种形式的单边假设.

仍以 $F_n(x)$ 表示 $X_1, \dots, X_n$ 的经验分布函数, Колмогоров 在 1933 年(见文献[102])引进了统计量

$$D_n = \sup_x |F_n(x) - F(x)|, \quad (4.264)$$

并且在 F 连续且 H 成立的条件下证明了关于 D_n 的极限定理,即本书第 1 章引理 1.2. 利用这个定理,在 n 充分大时,可以近似地确定下述检验

$$\text{当 } D_n > d_n \text{ 时,否定 } H \quad (4.265)$$

中的临界值 d_n . 例如,当检验水平取为 $\alpha = 0.05$ 或 0.01 时, d_n 可分别取为 $1.358/\sqrt{n}$ 或 $1.628/\sqrt{n}$. 研究表明:由极限分布所决定的 d_n 值要比根据 D_n 的精确分布所决定的 d_n 值略大些. 当 n 较大时,应根据专为此检验制作的表去查出 d_n 的值,例如 Miller^[123] 中的表,对 $n = 1(1)100$ 给出了 $\sqrt{n}D_n$ 的精确分布的

0.90、0.95、0.98 和 0.99 分位点.

关于 Колмогоров 检验与其他检验的比较问题,有一些学者作了研究.下面介绍一点 Massey 在 1950 ~ 1952 年期间的工作^[119] 及 Lee 在 1966 年的工作^[108].

Massey 在上述 1950 年的工作中证明了 Колмогоров 检验没有无偏性.他在 1951 年的工作中,对这个检验的功效给出了一个较粗糙的下界.他的推理如下:

以 G 记一分布函数,令

$$\Delta = \sup_x |G(x) - F(x)|.$$

以 $\beta_n(G)$ 表示当总体分布为 G 时 Колмогоров 检验的功效值,即

$$\beta_n(G) = P_G(D_n > d_n).$$

求出 x_0 , 使 $|G(x_0) - F(x_0)| = \Delta$. 则有

$$\beta_n(G) = 1 - P_G(D_n \leq d_n) \geq 1 - P_G(|F_n(x_0) - F(x_0)| \leq d_n).$$

当 $X_1, \dots, X_n \sim G$ 时, $nF_n(x_0)$ 服从二项分布 $B(n, G(x_0))$. 于是 $P_G(|F_n(x_0) - F(x_0)| \leq d_n)$ 可用正态分布逼近,因而当 n 较大时,近似地有

$$\begin{aligned} \beta_n(G) &\geq 1 - \left\{ \Phi \left[\frac{\sqrt{n}(F(x_0) - G(x_0) + d_n)}{\sqrt{G(x_0)(1 - G(x_0))}} \right] \right. \\ &\quad \left. - \Phi \left[\frac{\sqrt{n}(F(x_0) - G(x_0) - d_n)}{\sqrt{G(x_0)(1 - G(x_0))}} \right] \right\} \\ &= 1 - \left\{ \Phi \left[\frac{\sqrt{n}(\Delta + d_n)}{\sqrt{G(x_0)(1 - G(x_0))}} \right] - \Phi \left[\frac{\sqrt{n}(\Delta - d_n)}{\sqrt{G(x_0)(1 - G(x_0))}} \right] \right\} \\ &\geq 1 - \{ \Phi - (2\sqrt{n}(\Delta + d_n)) - \Phi(2\sqrt{n}(\Delta - d_n)) \}. \end{aligned} \quad (4.266)$$

因为 $\lim_{n \rightarrow \infty} d_n = 0$, 故只要 $\Delta > 0$ (即 $G \neq F$), 则必有 $\lim_{n \rightarrow \infty} \beta_n(G) = 1$. 这证明了 Колмогоров 检验的相合性. 根据 (4.266) 式, 并利用 Williams 关于按拟合优度的 χ^2 检验的一项工作^[176], Massey 把 Колмогоров 检验的功效与 χ^2 检验的功效作了比较, 对水平 $\alpha = 0.05$, 结论大体上是: 以 0.5 的功效, χ^2 检验所能察觉的 Δ 值大致只有 Колмогоров 检验的一半. 当样本大小为 $n = 200$ 时, 对比约为 0.6, 当 n 增加时, 对比单调下降, 而有利于 Колмогоров 检验. 尽管到目前为止, 理论上提供的证据还不够充分、广泛, 一般的的感觉是: 对于 (4.263) 式中分布 F 完全已知而不带任何参数的情况, Колмогоров 检验优于 χ^2 检验.

另一方面, Lee 在文献 [108] 中, 在 (4.263) 式中的 $F(x)$ 是正态分布 $\Phi(x/\sigma)$ (σ 已知) 且可能的对立假设为 $\Phi((x - \theta)/\sigma)$ ($\theta > 0$) 的情况下, 对 Колмогоров 检验和通常的 u 检验的功效作了比较. 由于此处的对立假设有单

的形式,所用的柯尔莫戈罗夫检验也是单边的(即以统计量 $\sup_x (F(x) - F_n(x))$ 代替 $\sup_x |F(x) - F_n(x)|$). 取样本大小 $n = 5$, 结果如下表(表 4.5) 所示:

表 4.5

$\frac{\theta}{\sigma}$	水 平 与 检 验			
	$\alpha = 0.05$		$\alpha = 0.01$	
	K	u	K	u
0.5	0.251	0.299	0.087	0.114
1.0	0.616	0.723	0.332	0.464
1.5	0.895	0.956	0.682	0.848
2.0	0.979	0.998	0.905	0.984

例如当检验水平为 0.05 时, 在对立假设 $\Phi\left(\frac{x-\theta}{\sigma}\right)$ 处, 其中 $\theta/\sigma = 1.5$, 柯尔莫戈罗夫检验 u 检验的功效分别为 0.895 和 0.956. 从上面表 4.5 看出: 在这个最有利于 u 检验的情况下, 柯尔莫戈罗夫检验与 u 检验有相当的差距, 但 u 检验的优势还是压倒性的.

其他关于柯尔莫戈罗夫检验的功效对比的工作, 还有 Van der Waerden^[165]、Suzuki^[161]、Shapiro^[144] 以及 Knott^[101] 等. 又 Barr 等人在文献[36] 中讨论了修改柯尔莫戈罗夫检验, 以用于截尾数据的情况.

在有些情况下, 假设(4.263) 中的分布 $F(x)$ 没有完全给定, 而只给定它属于一个参数分布族 $\{F_\theta(x): \theta \in \Theta\}$. 例如一个常见的问题是要检验样本 $X_1, \dots, X_n$ 所抽自的分布是正态分布, 但并未指定分布的均值 a 及方差 σ^2 . 这时 $\theta = (a, \sigma)$, 而

$$F_\theta(x) = \Phi\left(\frac{x-a}{\sigma}\right).$$

对这个问题, 一个自然的想法是: 通过样本对 θ 作出适当的估计 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, 然后引进统计量

$$D_n^* = \sup_x |F_n(x) - F_{\hat{\theta}}(x)|. \quad (4.267)$$

此处 $F_n(x)$ 仍为 $X_1, \dots, X_n$ 的经验分布函数. 麻烦的是, 柯尔莫戈罗夫定理已不再适用. 就是说, 在原假设 H 成立下(即: $X_1, \dots, X_n$ 所来自的总体, 其分布属于族 $\{F_\theta(x): \theta \in \Theta\}$), $\sqrt{n}D_n^*$ 并不具有如引理 1.2 中所指出的极限分布. 事实是:

这一极限分布与分布族 $\{F_\theta(x); \theta \in \Theta\}$ 的形式与 θ 的估计 $\hat{\theta}$ 有关. 必须在每一特定场合下分别处理之. 到目前为止, 这方面的结果还不多.

1967年, Lilliefors 在文献[113]中考虑了正态情况, 即检验样本是否抽自正态分布族. 记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

分别以 $\bar{X}$ 和 S 去估计均值 a 及标准差 σ , 而令

$$D_n^* = \sup_x \left| F_n(x) - \Phi\left(\frac{x - \bar{X}}{S}\right) \right|. \quad (4.268)$$

显然, 只要原假设 H 成立, 则 D_n^* 的分布不依赖于参数 a 和 σ 的值, 因而以

$$D_n^* > d_n^* \quad (4.269)$$

为否定域的检验在原假设上是相似的. 适当选择 d_n^* , 可使这检验具有给定的水平 α , 但是现在还不知道 D_n^* 的精确分布与 $\sqrt{n}D_n^*$ 的极限分布. 因此, Lilliefors 用随机模拟的方法提供了 (4.269) 式中 d_n^* 的近似值 (%) 如表 4.6 所示:

表 4.6

n	5	6	7	8	9	10	11	12	13
0.05	33.7	31.9	30.0	28.5	27.1	25.8	24.9	24.2	23.4
0.01	40.5	36.4	34.8	33.1	31.1	29.4	28.4	27.5	26.8
n	14	15	16	17	18	19	20	25	30
0.05	22.7	22.0	21.3	20.6	20.0	19.5	19.0	17.3	16.1
0.01	26.1	25.7	25.0	24.5	23.9	23.5	23.1	20.0	18.7

当 $n > 30$ 时, 相应于 $\alpha = 0.05$ 和 0.01 的 d_n^* 值定为 $0.866/\sqrt{n}$ 和 $1.031/\sqrt{n}$.

Lilliefors 在文献[113]中并将此检验与 χ^2 检验作了比较. 他考虑若干种对立假设 (即假定样本抽自某些非正态总体.) 结果表明: 在他考察的那些情况下, 检验 (4.269) 优于 χ^2 检验.

1969年, Lilliefors 在文献[114]中对指数分布

$$F_\theta(x) = (1 - e^{-x/\theta}) I_{(x>0)}, \quad \theta > 0$$

的情况也如法炮制. 他用 $\bar{X}$ 去估计 θ , 而定义

$$D_n^* = \sup_x |F_n(x) - (1 - e^{x/\bar{X}})|,$$

然后通过随机模拟以确定 D_n^* 的临界值. 但是, Durbin 及 Margolin 等先后在 1975 年^[58] 和 1976 年^[118] 中求得了 D_n^* 的精确分布, 因而可用之求 D_n^* 的临界值, 这可参看 Durbin 在文献[58] 中提供的表. 当 n 充分大时, 对 $\alpha = 0.05$ 和 0.01 这临界值可分别近似地取为 $1.075/\sqrt{n}$ 及 $1.274/\sqrt{n}$.

另外, Schneider 等在文献[141] 中也讨论了 Gamma 分布族的情况, 其中的参数必须由样本估计.

第 5 章

条件检验与置换检验

关于本章的内容,我们在 5.1 节的结尾处作一简要的说明.因为在目前这阶段是不容易说清楚的.

5.1 定义和例子

设随机向量 X 的分布 F 属于某个给定的分布族 $\mathcal{F}$. H 为 $\mathcal{F}$ 的非空真子集. 对 X 进行了观察, 得到 $X^{(0)}$. 要根据 $X^{(0)}$ 去检验假设

$$H: F \in H. \quad (5.1)$$

在此就用集 H 来记原假设, 这为了在行文上方便.

为检验这个假设, 一般途径是从直观想法或某种理论出发构作一个检验统计量 T , 算出 $T(X^{(0)})$, 然后当 $T(X^{(0)})$ 落在一定的范围内 (一般是 $T(X^{(0)})$ 大于或小于某一常数) 时, 否定 H . 为要定出这个范围, 需要定出 $T(X)$ 在原假设 H 下的分布.

条件检验与此不同的地方是: 除了检验统计量 T 之外, 还要选定另一统计量 $M(X)$. 每当有了样本 $X^{(0)}$ 后, 就算出

$$m_0 = M(X^{(0)}),$$

定出 T 在 H 成立且给定 $M = m_0$ 下的条件分布 $P(\cdot | m_0)$. 然后根据这个条件分布而决定一个范围 B_{m_0} , 使当 $T(X^{(0)}) \in B_{m_0}$ 时, 否定原假设 H . 例如, 决定常数 $C(m_0)$, 使

$$P(T > C(m_0) | m_0) = \alpha, \quad (5.2)$$

然后当 $T(X^{(0)}) > C(m_0)$ 时, 否定 H . 这里否定域 $\{x: T(x) > C(m_0)\}$ 不是根据水平 α 就立即定下来, 还要在有了样本 $X^{(0)}$ 以后, 根据 $M(X^{(0)})$ 的值才能定出来. 可以说, 检验是在 $M = m_0$ 的条件下进行的. 这就是条件检验这个名称的来由.

在以上叙述中, 我们默认了这样的假定: 在 H 成立时, T 在给定 M 下的条件分布与样本 X 的分布无关. 一般, H 是复合假设, 其中包含许多分布, 故这一条很紧要. 这一点正是引进条件检验的理由所在. 因为在不少情况下, 统计量 T 的无条件分布, 即使在 H 成立时, 仍与样本 X 的分布有关. 这常常使得决定 T 的临界值成为不可能 (见例 5.1). 另一方面, 由于上文的统计量 $M(X)$ 可根据问题情

况去适当选择,前面提出的要求(即在 H 成立时, T 在给定 M 之下的条件分布与 X 的分布无关)往往能满足.这就提供了一个能达到既定水平 α 的检验法.因为由(5.2)式显然得出:以

$$\{x: T(x) > C(M(x))\}$$

为否定域的检验犯第一种错误的概率总是 α .

例 5.1 考虑在 4.5.1 节中讨论过的游程检验.样本为 $(X_1, \dots, X_N)$, X_i 都只取值 0,1. 在原假设 H 成立时, $X_1, \dots, X_N$ 为 iid. 其分布决定于 $p = P(X_1 = 1)$, p 可在 $(0, 1)$ 区间内取值.

以 ξ_N 记序列 $X_1, \dots, X_N$ 所含游程数. 如前所指出, 以 $\xi_N < c_N$ 为否定域的检验. 从直观上看是可取的(针对一定的对立假设). 然而, 为要定出 c_N , 须定出 ξ_N 在 H 成立时的分布. 这个分布信赖于 p , 有如下的形式

$$P_p(\xi_N = k) = \sum_{n=0}^N \binom{N}{n} p^n (1-p)^{N-n} P(k | n), \quad (5.3)$$

其中(记 $m = N - n$),

$$\begin{aligned} & P(k | n) \\ &= \begin{cases} 2 \left[\frac{m-1}{2} k - 1 \right] \left[\frac{n-1}{2} k - 1 \right] / \binom{N}{n}, & k \text{ 为偶数;} \\ \left\{ \left[\frac{m-1}{2} (k+1) \right] \left[\frac{n-1}{2} (k+1) \right] + \left[\frac{m-1}{2} (k+1) \right] \left[\frac{n-1}{2} (k-1) \right] \right\} / \binom{N}{n}, & k \text{ 为奇数.} \end{cases} \quad (5.4) \end{aligned}$$

指定水平 $\alpha \in (0, 1)$. 不难看出, 不存在只依赖于 N 的常数 c_N , 使

$$P_p(\xi_N < c_N) = \alpha. \quad (5.5)$$

事实上, 若 $c_N \leq 1$, 则 $P_p(\xi_N < c_N)$ 总为 0. 若 $c_N > 1$, 则当 $p \approx 0$ 或 $p \approx 1$ 时, $P_p(\xi_N < c_N) \approx 1$.

另一方面, 在给定 n 的条件下, 只要 H 成立, 则 ξ_N 的条件分布总是(5.4)式而与 p 无关. 这样, 我们可以把检验建立在这个条件分布的基础上. 这只要取 $c_N(n)$, 使

$$\sum_{k=0}^{c_N(n)-1} P(k | n) = \alpha,$$

然后当 $\xi_N < c_N(n)$ 时否定 H 即可. 这是一个水平为 α 的相似检验^①. 在本例中, ξ_N 和 n 分别相当于前文的 T 和 M . 按这样的观点, 定理 4.19 并无必要: 为作大样本检验, 只需有引理 4.7, 它是关于条件分布 $P(k | n)$ 的极限定理.

现把所作的论述写成形式的定义如下:

定义 5.1 沿用前面的记号 $X, F, \mathcal{F}, H$. 如果可找到两个统计量 T 和 M 及 (T, M) 的值域空间的子集 B , 使检验 ϕ 的否定域为 $G = \{x: T(x), M(x) \in B\}$, 且满足条件

$$P_F(X \in G | M = m) \text{ 与 } m \text{ 及 } F \in H \text{ 都无关,} \quad (5.6)$$

则称 ϕ 为一条条件检验.

一般情况下, ϕ 为一检验函数, 这时条件检验的定义修改为: ϕ 是 (T, M) 的函数, 且 $E_F\{\phi(T(X), M(X)) | M = m\}$ 与 m 与 $F \in H$ 都无关.

应当注意到一个重要点: 条件和非条件检验的差别不在于形式. 就定义 5.1 看, 完全可以把检验统计量看 (T, M) , 这时检验 ϕ 的内容不过是说: 当 (T, M) 属于某集合 B 时否定 H . 这样讲就没有什么“条件”的意味了. 二者的差别在于引出该检验的思想: 它是在考虑 T 对 M 的条件分布的基础上引进的. 唯其有了这种思想, 才会构造这样的检验统计量 (T, M) .

下面再考虑几个例子.

例 5.2 在前两章中处理了一些关于“结”存在时的秩检验问题. 这种检验全都可以从“在给定结统计量 $\tau(\tau_1, \dots, \tau_q)$ 的条件下”的条件检验角度去看. 以 (4.164) 式多样本问题秩检验统计量 S_N^* 为例. 如果考虑 S_N^* 的无条件分布, 则即使原假设

$$F_1 = \dots = F_m$$

(见 (4.154) 式) 成立, S_N^* 的分布仍将与公共分布 $F = F_1$ 有关. 如同例 5.1 那样, 要定出 c_N (只与 $N, n_1, \dots, n_m$ 有关的常数), 使 $P_F(S_N^* > c_N)$ 总等于 α (对一切公共分布 F) 是不可能的. 但是, 若考虑 S_N^* 在给定 τ 之下的条件分布 $P(\cdot | \tau)$, 则此条件分布只依赖 τ 而与公共分布 F 无关, 因而可定出依赖于 τ (及 N, n_i) 的 $c_N(\tau)$, 使对任何 τ 及公共分布 F , 有

① 有可能不存在整数 $c_N(n)$ 使 $\sum_{k=0}^{c_N(n)-1} P(k | n)$ 恰好等于 α . 这时可调整 α 或采用随机

化. 以后我们都这样理解.

$$P\left\{S_N^* > \frac{c_N(\tau)}{\tau}\right\} = \alpha.$$

这样就可以建立一个健全的秩检验,它是一个条件检验,其中 S_N^* 和 τ 分别起着 T 和 M 的作用. 极限定理((4.165)式)也可以在条件化的意义上理解(这提供了大样本条件检验临界值 $c_N(\tau) \approx \chi_{m-1}^2(\alpha)$),即:当 H 成立时, S_N^* 在给定 τ 之下的条件分布 $\xrightarrow{\mathcal{L}} \chi_{m-1}^2$. 不过,在此需要对当 $N \rightarrow \infty$ 时, τ 的性状作一些限制.

例 5.3 考虑一个 2×2 的列联表(表 5.1):

表 5.1

B	A		
	A_1	A_2	和
B_1	X_1	X_2	M_1
B_2	X_3	X_4	M_2
和	M_3	M_4	N

A 、 B 是一个体上的两个属性,各有两个水平. 从总体中随机抽取了 N 个个体,结果如表 5.1. 要检验的原假设 H 是: A 、 B 两属性独立. 若以 p_i 、 q_j 和 r_{ij} 分别记“个体的 A 属性处在水平 i ”、“个体的 B 属性处在水平 j ”及二者同时发生的概率,则 H 可表为:

$$H: r_{ij} = p_i q_j, \quad i, j = 1, 2, \quad (5.7)$$

即使当 H 成立时, p_i 、 q_j 仍可在 $(0, 1)$ 区间内任意取值(自然, $p_1 + p_2 = q_1 + q_2 = 1$).

此问题(在一般的 $s \times t$ 的情况)曾在 4.5.2 小节中从多样本问题角度考察过,而此处是从独立性的角度看. 这使得表中的边缘和 $M_1, \dots, M_4$ 都是随机变量.

为找一适当的检验统计量,我们把对立假设定为:“ A 、 B 两属性正相关”理解为:高(低)标号 A 的个体倾向于(相对于独立时而言)有高(低)标号的 B . 从表 5.1 看,条件概率 $P(A_1 | B_1)$ 可估计为 X_1/M_1 , 而 $P(A_1 | B_2)$ 可估计为 X_3/M_2 . 故当 $X_1/M_1 - X_3/M_2$ 取大值时,有理由否定 H . 遗憾的是:即使 H 成立, $X_1/M_1 - X_3/M_2$ 的分布仍将依赖于 p_i 与 q_j , 因而临界值无法定出. χ^2 检验法“乞灵”于大样本理论. 现在从条件检验的角度来处理此问题. 取定义 5.1 中的 M 为 (M_1, M_3) . 因为

$$\frac{X_1}{M_1} - \frac{X_3}{M_2} = \frac{NX_1 - M_1 M_3}{M_1 M_2}.$$

它在给定 (M_1, M_3) 时只依赖于 X_1 , 且得 X_1 的增函数, 故可取检验统计量为 $T = X_1$. 为确定临界值, 要算出在 H 成立时的条件概率 $P(X_1 = x_1 | M_1 = m_1, M_3 = m_3)$. 有

$$\begin{aligned} P(M_i = m_i, i = 1, 3) &= \sum_i \frac{(p_1 q_1)^i (p_1 q_2)^{m_2-i} (p_2 q_1)^{m_1-i} (p_2 q_2)^{N-m_1-m_3+i}}{i! (m_1-i)! (m_3-i)! (N-m_1-m_3+i)!} \\ &= p_1^{m_2} p_2^{N-m_3} q_1^{m_1} q_2^{N-m_1} \binom{N}{m_1} \sum_i \binom{m_1}{i} \binom{N-m_1}{m_3-i} \\ &= p_1^{m_3} p_2^{N-m_3} q_1^{m_1} q_2^{N-m_1} \binom{N}{m_1} \binom{N}{m_3}. \end{aligned}$$

而在给定 $M_i = m_i (i = 1, 3)$ 之下, 当 $X_1 = x_1$ 时, 有

$$X_2 = m_1 - x_1, \quad X_3 = m_3 - x_1, \quad X_4 = N - m_1 - m_3 + x_1.$$

故

$$\begin{aligned} P(X_1 = x_1 | M_i = m_i, i = 1, 3) &= [P(X_1 = x_1, X_2 = m_1 - x_1, X_3 = m_3 - x_1, \\ &\quad X_4 = N - m_1 - m_3 + x_1)] / [P(M_1 = m_1, M_3 = m_3)] \\ &= \frac{N!}{x_1(m_3 - x_1)! (m_1 - x_1)! (N - m_1 - m_3 + x_1)!} \\ &\quad \times (p_1 q_1)^{x_1} (p_1 q_2)^{m_3-x_1} (p_2 q_1)^{m_1-x_1} (p_2 q_2)^{N-m_1-m_3+x_1} \\ &\quad \div p_1^{m_3} p_2^{N-m_3} q_1^{m_1} q_2^{N-m_1} \binom{N}{m_1} \binom{N}{m_3} \\ &= \frac{\binom{m_1}{x_1} \binom{N-m_1}{m_3-x_1}}{\binom{N}{m_3}}. \end{aligned} \quad (5.8)$$

这与 p_i, q_j 无关, 因而符合定义 5.1 的要求. 在条件分布 (5.8) 式的基础上, 不难建立原假设 H 的水平 α 相似检验.

对一般的 $s \times t$ 列联表此法也可用. 因为容易证明: 在独立性假设 H 成立时, 在给定了表 4.2 的边缘和 $n_1, \dots, n_s$ 和 $d_1, \dots, d_t$ 的条件下, 表 4.2 中的变量 $(n_{11}, \dots, n_{st})$ 的条件分布只依赖于 n_i 和 d_j . 但是, 除非 s, t 和 n_i, d_j 都很小, 这个条件分布在应用上是不现实的. 还有选择检验统计量的问题.

例 5.4 再考虑两样本问题

$$X_1, \dots, X_m \sim F(x), \quad Y_1, \dots, Y_n \sim F(x - \theta),$$

$$H: \theta = 0 \leftrightarrow K: \theta > 0, \quad (5.9)$$

记合样本为 $Z = (Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n)$, $N = m + n$. 考虑统计量

$$T(Z) = \frac{1}{n} \sum_{i=m+1}^N Z_i - \frac{1}{m} \sum_{i=1}^m Z_i = \bar{Y} - \bar{X}.$$

若 $\theta > 0$, 则 $\bar{Y} - \bar{X}$ 倾向于取较大的值. 因此, 从直观上看, 以 $T(Z) > c_N$ 为否定域的检验是可考虑的. 但是, 即使原假设 H 成立, $T(Z)$ 的分布仍将与公共分布 F 有关. 读者不难验证: 若对 F 不作特殊的限制, 要找到这样的 c_N , 对一切 F , 使

$$P_F(T(Z) > c_N) = \alpha, \quad 0 < \alpha < 1 \quad (5.10)$$

是不可能的. 现求助于条件化, 取

$$M(Z) = (Z_{(1)}, \dots, Z_{(N)}) = Z \text{ 的次序统计量.}$$

则易见只要原假设 H 成立, 不论分布 F 如何, 在给定 $M(Z)$ 时 $T(Z)$ 的条件分布总有如下形式: 将原样本点 $Z = (Z_1, \dots, Z_N)$ 经过一切可能的置换, 得到 $N!$ 个形如 $(Z_{i_1}, \dots, Z_{i_N})$ 的点, 记为 $Z^{(1)}, \dots, Z^{(N!)}$. 对每个 $Z^{(i)}$, 算出 $T(Z^{(i)})$ 的值 $t_i (i = 1, \dots, N!)$, 有

$$P(T(Z) = t_i | M(Z)) = \frac{1}{N!}, \quad i = 1, \dots, N! \quad (5.11)$$

(t_i 中有重合者, 将其概率合并之). 利用 (5.11) 式可作出 H 的条件检验如下:

找 $c_{N,M}$, 使 $P(T > c_{N,M} | M) = \alpha$. 计算 $T(Z)$ (Z 为合样本).

若 $T(Z) > c_{N,M}$, 则否定 H . 这是一个水平 α 的相似检验.

也可用另外的统计量来代替 $T(Z)$. 例如

$$\tilde{T}(Z) = \text{med}(Z_{m+1}, \dots, Z_N) - \text{med}(Z_1, \dots, Z_m).$$

推理完全一样. 在第 4 章中, 用 Z 的秩统计量以摆脱对 F 的依赖性. 这里的方法在不求助于秩的同时, 达到了这个目的.

例 5.5 现在再来考察第 4.4.3 小节中随机区组秩检验问题中提到过的两个检验统计量 ((4.191) 式与 (4.197) 式). 这里一共有 N 个区组, 每个区组恰好把 m 个处理各做一次. 处理 i 在区组 j 的试验结果为 X_{ij} . 令 $X'_{ij} = X_{ij} - X_{.j}$ ((4.191) 式). R'_{ij} 为 X'_{ij} 在 $\{X'_{ij}: j = 1, \dots, N, i = 1, \dots, m\}$ 中的秩.

第 4.4.3 小节中证明了 (见引理 4.6): 在原假设 H (即处理效应不存在) 成立时, $(R'_{11}, \dots, R'_{mN})$ 以概率 $1/(mN)!$ 取 $(1, \dots, mN)$ 的任一置换. 于是 (4.196)

式的 S_N 和(4.197)式的 S_N^* 都具有如下的性质:

当 H 成立时,它们的分布与原样本的分布无关.

因此,给定 $\alpha \in (0,1)$ 后,可作出基于 S_N 的及基于 S_N^* 的水平 α 相似检验.我们又曾证明,在原假设 H 成立时, S_N 和 S_N^* 当 $N \rightarrow \infty$ 时都 $\xrightarrow{\mathcal{L}} \chi_{m-1}^2$. 在此基础上可建立大样本检验.

于是就产生了一个问题:为什么有了 S_N ,还要考虑更复杂的 S_N^* ? 这是因为 S_N^* 容许另一种解释——条件化的解释:若以 $R_{(1)j}' < \cdots < R_{(m)j}'$ 记 $(R_{1j}', \cdots, R_{mj}')$ 的次序统计量,并令

$$M = \{(R_{(1)1}', \cdots, R_{(m)1}'), \cdots, (R_{(1)N}', \cdots, R_{(m)N}')\} \quad (5.12)$$

而考虑 S_N^* 在给定 M 时的条件分布,则不仅可证明:以概率 1 此条件分布 $\xrightarrow{\mathcal{L}} \chi_{m-1}^2$, 而且不难验证: $E(S_N^* | M) = m - 1$, 正是 χ_{m-1}^2 的均值. 找 $c_N(M)$, 使 $P(S_N^* > c_N(M) | M) = \alpha$. 然后当 $S_N^* > c_N(M)$ 时否定 H , 则得到一个条件检验. 但 S_N 却不能这样解释,因此在给定 M 时,则 S_N 的条件分布与 χ_{m-1}^2 相去甚远.

可以进一步问:既然从 S_N 可产生一个健全的无条件检验,那么引进这种条件化的 S_N^* 有何益处? 要回答这个问题,就必须涉及基本模型与试验设计上的考虑. 大体上说, S_N 在原假设 H 下的分布理论依赖于引理 4.6 的结论. 而这一点只有在每一区组内的试验单元为绝对均匀时才有效,但在实际问题中,这一点不可能总会实现. 有时甚至相去甚远. 由于这个原因,促使我们要在每个区组内实行随机化. 这种随机化使得在给定 M 后, $(R_{(1)j}', \cdots, R_{(m)j}')$ 以同等的可能性取 $(R_{(1)j}', \cdots, R_{(m)j}')$ 的任一置换. 这正好产生 S_N^* 在给定 M 时的条件分布. 这一条件分布完全来自设计——区组内随机化,而非来自区组内试验单元的绝对均匀. 因此,它使我们在更现实的条件下,得到接近于 χ_{m-1}^2 的条件分布,若用 S_N 就达不到这个目的.

由此可知,基于条件化考虑的 S_N^* 是与随机区组这个设计“配套”的. 区组内愈不均匀,随机化就愈有必要,而 S_N^* 对 S_N 的优越性就愈大. 当区组内的试验单元很均匀时,随机化的重要性降低,而基于 S_N 的无条件检验就优于基 S_N^* 的条件检验.

下面论述置换检验(Permutation Test). 因为不容易给出一个简明而包罗一切的定义,我们只能从各个角度来作些说明:

1. 从形式上看,置换检验可看作是条件检验的一个特例:若在定义 5.1 中,

统计量 $M(X)$ 取为 X 的次序统计量^①, 则所得的条件检验称为**置换检验**. 这样说的道理如下: 设

$$X = (X_1, \dots, X_N),$$

则给定 $M(X)$ 时, 统计量 T 还可以取 $N!$ 个值

$$t_i = T(X^{(i)}), \quad i = 1, \dots, N!,$$

这里 $X^{(1)}, \dots, X^{(N!)}$ 是由 X 经过一切可能的置换得到的 $N!$ 个点, 正是在这里与“置换”发生了联系. 如果在原假设下 $X_1, \dots, X_N$ 为 iid., 则 T 取上述 $N!$ 个值 $t_1, \dots, t_{N!}$ 的概率都是 $1/N!$. 这条件分布不依赖于 X_i 的分布, 因此符合定义 5.1 的要求. 因此, 在构造条件检验时, 常使用这个统计量 M . 例 5.4 是一个典型的例子. 在这种情况下, 习惯上把 T 称为“**置换统计量**”. 若 T 为样本的线性函数, 如在例 5.4 那样, 则称为“**线性置换统计量**”. 应当注意: “置换统计量”一词实在不能反映所指的统计量 T 在外表上有何特点, 它只是关联于统计量 M 而产生的一种称呼.

更广义一些, 如果定义 5.1 中的统计量 M 是这样产生的: 先将样本 X 变换到某变量 $Y = (Y_1, \dots, Y_{N'})$. 将 $(Y_1, \dots, Y_{N'})$ 分割为若干部分, 取每一部分的次序统计量合起来即得 M . 例 4.5 是一典型的例子: 由原始样本 $X = (X_{ij})$ 产生变量 $R' = (R'_{ij})$, 将 R' 分割为 $\{R_{1j}, \dots, R_{mj}\} (j = 1, \dots, N)$, 取每一部分的次序统计量, 即得 M 如 (5.13) 式. 由这种 M 依定义 5.1 产生的条件检验也称为**置换检验**. 相应地, T 也称作“**置换统计量**”.

2. 另一种看法来自 R. A. Fisher 的一项重要思想——随机化原则. 与条件化无关. 考虑下面的例子:

例 5.6 设要比较两个处理 A, B , 有 $N = m + n$ 个试验单元可供使用, 其中预定以 m 个施加处理 A , 其余施加处理 B .

在挑选这 N 个试验单元时虽力求使其均匀, 但实际上总会有差异. 在较多情况下, 这 N 个试验单元是我们所能得到的全部材料而无挑选的余地. 这时单元之间的差异可能更不容忽视了. 我们暂假定: 第 i 单元有一个常数值“单元效应” $a_i (i = 1, \dots, N)$, 而随机误差可忽略不计. 又设处理 A, B 的处理效应分别为 0 和 θ , 且单元效应与处理效应是可加的. 要检验的原假设 H 是“处理效应不存在”, 对立假设是“处理 B 优于处理 A ”, 即

① 若 X_i 是非数量性的, 可以取由 $X_1, \dots, X_N$ 构成的集合作为 M .

$$H: \theta = 0 \leftrightarrow K: \theta > 0. \quad (5.13)$$

在 N 个试验单元中随机地选择 m 个(即:任意 m 个被选出的机会都是

$$\binom{N}{m}^{-1})$$

施加处理 A , 其余施加处理 B . 以 $X_1, \dots, X_m$ 和 $Y_1, \dots, Y_n$ 分别记处理 A 的 m 个试验值与处理 B 的 n 个试验值, 则可以形式地将 X_i 和 Y_i 表为

$$X_i = a_{k_i}, i = 1, \dots, m; \quad Y_j = a_{k_{m+j}} + \theta, \quad j = 1, \dots, n. \quad (5.14)$$

这里 $(k_1, \dots, k_N)$ 是 $(1, \dots, N)$ 的一置换, 且每个这样的置换有概率 $1/(N!)$. 记

$$\bar{a} = \frac{1}{N} \sum_{i=1}^N a_i; \quad \bar{X} = \frac{1}{m} \sum_{i=1}^m X_i; \quad \bar{Y} = \frac{1}{n} \sum_{j=1}^n Y_j.$$

则易见

$$E(\bar{X}) = \bar{a}, \quad E(\bar{Y}) = \bar{a} + \theta.$$

于是当 $\theta > 0$ 时, $\bar{Y} - \bar{X}$ 倾向于大于 0, θ 愈大, 这种倾向性愈强, 于是得到一个在直观上看合理的检验法:

$$\text{当 } T = \bar{Y} - \bar{X} > c \text{ 时, 否定 } H. \quad (5.15)$$

T 在原假设 H 下的分布如下: 记

$$Z = (a_1, \dots, a_N),$$

对 Z 作置换, 得到形如 $(a_{k_1}, \dots, a_{k_N})$ 的 $N!$ 个点

$$Z^{(i)} = (Z_1^{(i)}, \dots, Z_N^{(i)}), \quad i = 1, \dots, N!.$$

算出

$$T(Z^{(i)}) = \frac{1}{n} \sum_{k=1}^n Z_{m+k}^{(i)} - \frac{1}{m} \sum_{k=1}^m Z_k^{(i)}, \quad i = 1, \dots, N!.$$

则 T 取这个 $N!$ 个值的概率都是 $1/(N!)$ (有重复的, 要合并起来).

在这里需要注意以下两点: 一是之所以能得到这样一个在统计上健全的检验, 完全在于进行了适当的设计——随机地挑选处理 A 的 m 个单元. 否则, 单元效应将与处理效应混杂而得不出任何确定的结论. 随机化的作用有使单元效应彼此抵消的倾向. 这一点在任何试验中(只要试验单元不充分均匀)都成立, 而成为由 Fisher 提出的一项基本原则.

第二点是这检验所用统计量 T 的分布与例 5.4 所用统计量的条件分布在要构造上完全一致——它们都是由置换而产生的. 因此, 本例的检验也叫做置换检验. 不过与例 5.4 不同, 此例的检验没有“条件化”的因素, 它本身就是一个无

条件检验. 在本例检验中, 置换之所以在检验统计量的分布中起作用, 完全是从设计方面来的. 至于例 5.4, 它实际上是一个这样的模型: $m+n$ 个试验单元绝对均匀, 但有随机误差存在. 在此设计不起任何作用, 置换系由条件化所引进, 而后者不过是为构造相似检验而使用的一种技巧而已.

在此可以进一步作一点引申. 例 5.4 和 5.6 可以看作是两个极端: 前者无单元效应而只有试验(随机)误差; 后者则只有单元效应而无试验误差. 在实际问题中, 情况多是介于二者之间——试验单元不充分均匀, 且由于试验者和外界环境等等的影 响, 存在着随机性的试验误差. 这时, 本例的模型应由 (5.14) 式修改为

$$X_i = a_{k_i} + e_i, \quad i = 1, \dots, m; \quad Y_j = \theta + a_{k_{m+j}} + e_{m+j}, \quad j = 1, \dots, n \quad (5.16)$$

这里 $e_1, \dots, e_N$ 可设为 iid. 在此 (5.15) 式确定的检验在直观上看仍是合理的. 但是, 在原假设 H 之下, X_i, Y_j 的分布与 e_i 的分布 F 有关. 因而无法根据水平 α 去定出 (5.15) 式中的 c . 实际上, 若记

$$Z = (Z_1, \dots, Z_N) = (X_1, \dots, X_m, Y_1, \dots, Y_n),$$

是当 H 成立时, Z 的分布函数是

$$G(Z_1, \dots, Z_N) = \sum^* \frac{1}{N!} \prod_{i=1}^N F(Z_i - a_{k_i}).$$

此处 $\sum^*$ 求和范围是 $(1, \dots, N)$ 的一切可能的置换 $(k_1, \dots, k_N)$. 这分布 G 不仅与 F 有关. 而且以 G 为分布的 N 维随机向量 $(Z_1, \dots, Z_N)$ 的各分量 $Z_1, \dots, Z_N$ 也并非 iid. 的. 但是, G 关于 $Z_1, \dots, Z_N$ 对称, 即

$$G(Z_{k_1}, \dots, Z_{k_N}) = G(Z_1, \dots, Z_N)$$

对 $(1, \dots, N)$ 的任一置换 $(k_1, \dots, k_N)$ 成立. 因此, 在给定 $Z_1, \dots, Z_N$ 的次序统计量 $Z_{(1)} \leq \dots \leq Z_{(N)}$ 的条件下, 每个置换 $(Z_{k_1}, \dots, Z_{k_N})$ 的条件概率仍是 $1/(N!)$. 因此, 例 5.4 所引进的条件检验所依据的道理在此仍完全适用.

以上主要通过一些例子对条件检验(包括置换检验)的思想作了比较仔细的讨论. 在下节 5.2 节要讨论当样本大小 $N \rightarrow \infty$ 时, 条件检验(主要是置换检验)的渐近性状. 主要的事实是: 在一类基于线性置换统计量(包括其检验统计量能表为若干线性置换统计量的函数者)的置换检验中, 当 $N \rightarrow \infty$ 时, 置换分布收敛于某一特定的分布. 由此就可以用一种非条件化的检验来逼近置换检验. 在 5.3 节中, 将讨论置换检验以及与之相联系的非条件检验在功效上的关系.

5.2 置换检验的渐近性状

设有原假设 H 及建立在 T 和 M 的基础上的条件检验 $\phi(T, M)$ 的意义如定义 5.1). 设检验 ϕ 的否定域为

$$T(X^N) > C(M(X^N)).$$

若存在只依赖于 $M(X^N)$ 的统计量 $h(M(X^N))$, 使当原假设 H 成立时, 在给定 $M(X)$ 的条件下, $T(X^N)/h(M(X^N))$ 的条件分布当 $N \rightarrow \infty$ 时, 收敛于一已知的分布 G (例如标准正态分布、 χ^2 分布等), 这样, 在 N 充分大时, 检验 ϕ 可近似地之以具有否定域

$$T(X^N) > v_\alpha h(M(X^N)) \quad (G(v_\alpha) = 1 - \alpha) \quad (5.17)$$

的无条件检验 ϕ_1 . ϕ 与 ϕ_1 的关系是: 若以 β_ϕ^N 和 $\beta_{\phi_1}^N$ 分别记其功效函数, 则只要分布 F 属于原假设 H , 就有

$$\lim_{N \rightarrow \infty} \beta_\phi^N(F) = \lim_{N \rightarrow \infty} \beta_{\phi_1}^N(F). \quad (5.18)$$

在此需要重复一下在上节中提到的一个论点: 把 ϕ 改为 ϕ_1 , 只不过将依赖于 $M(X^N)$ 的临界值 $C(M(X^N))$ 改为依赖于同一个 $M(X^N)$ 的另一临界值而已. 问题的实质在于: 决定 $C(M(X^N))$ 时往往要涉及由 X^N 的大量置换而产生的大量的点, 计算很难; 反之, 在多数情况下, $h(M(X^N))$ 是一个容易计算的函数, 用不着涉及置换. 因此, 把 (5.18) 式为否定域的检验称为非条件化的. 本节有许多例子将说明上述现象. 以下将称 ϕ 与 ϕ_1 渐近等价.

这种代替 (指导用 ϕ_1 代 ϕ) 大大减轻了计算, 且由 (5.18) 式知, 渐近地说, 检验水平仍保持. 但是应当了解: 一般说来, (5.18) 式并不是对 H 中的 F 一致地成立. 因此, 不论 N 多大, 只要一固定下来, 则 $\beta_{\phi_1}^N(F)$ 在 $F \in H$ 上的值就可以与 α 相差甚多. 但对 ϕ 而言, 不论 N 是多少, 总有 $\beta_\phi^N(F) = \alpha$ 对一切 $F \in H$ 成立.

因此, 这种代替违背我们引进置换检验的初衷. 本节理论只能当作置换检验的一个侧面来看. 置换检验的生命力仍在于其严格实施.

最简单类型的置换检验有如下的形状: 有了样本

$$Z = (Z_1, \dots, Z_N),$$

它可以是随机变量的观察值,有如例 5.4 的 $X_1, \dots, X_m, Y_1, \dots, Y_n$;也可以本身就是一些非随机的常数,有如例 5.6 的 $a_1, \dots, a_N$. 检验统计量是 $Z_1, \dots, Z_N$ 的线性函数

$$\xi_N = \sum_{i=1}^N b_{Ni} Z_i,$$

其中 b_{Ni} 为已知常数,在原假设 H 下,当给定 $Z_1, \dots, Z_N$ 的次序统计量 $Z_{(1)} \leq \dots \leq Z_{(N)}$ 时,每个置换 $(Z_{k_1}, \dots, Z_{k_N})$ 有同一条件概率 $1/(N!)$. 要确定 ξ_N 的临界值,必须算出 $N!$ 个值 $\sum_{i=1}^N c_{Ni} Z_{k_i}$. 显然,当 N 较大时,这一计算工作很繁重. 因此,转而考虑当 $N \rightarrow \infty$ 时, ξ_N 的条件分布的极限.

这样,对每个自然数 ν , 给定自然数 N_ν (N_ν 的作用相当于上文的 N). 由于当 $N \rightarrow \infty$ 的过程中不一定遍取 $N = 1, 2, \dots$ 各值(如在例 5.4 中 $N = m + n$, 当 m, n 都趋于 ∞ 时, N 可能是沿着自然数的某一子序列而趋于 ∞) 及两组常数:

$$A_\nu = \{a_{\nu 1}, \dots, a_{\nu N_\nu}\}, \quad B_\nu = \{b_{\nu 1}, \dots, b_{\nu N_\nu}\}.$$

A_ν 起着上文的 $\{Z_1, \dots, Z_N\}$ 的作用. 上文的统计量 ξ_N 的条件分布与下述变量的分布相同:

$$Q_\nu = b_{\nu 1} \eta_1 + b_{\nu 2} \eta_2 + \dots + b_{\nu N_\nu} \eta_{N_\nu}. \quad (5.19)$$

此处 $(\eta_1, \dots, \eta_{N_\nu})$ 以同一概率 $1/(N_\nu!)$ 取 $(a_{\nu 1}, \dots, a_{\nu N_\nu})$ 的任一置换.

5.2.1 Hajek 定理及其推论

关于由 (5.19) 式定义的 Q_ν 的极限分布的最基本的结果是 Hajek 定理. 此定理在定理 3.6 中已经用适合于秩理论需要的形式表述过. 由于其重要性, 这里再重提一下:

令

$$\bar{a}_\nu = \frac{1}{N_\nu} \sum_{i=1}^{N_\nu} a_{\nu i}, \quad \mu_{2\nu}(A) = \frac{1}{N_\nu} \sum_{i=1}^{N_\nu} (a_{\nu i} - \bar{a}_\nu)^2 \quad (5.20)$$

$\bar{b}_\nu$ 与 $\mu_{2\nu}(B)$ 类似于定义. 在定义 3.4 中, 已给出 A_ν 满足条件 N 的意义, 是(记号上有所变化)

$$\max_{1 \leq i \leq N_\nu} \frac{(a_{\nu i} - \bar{a}_\nu)^2}{\mu_{2\nu}(A)} = o(N_\nu). \quad (5.21)$$

又在定义 3.5 中, 已给出 (A_ν, B_ν) 满足条件 M 的意义为: 对任给的 $\epsilon > 0$, 有

$$\sum_{(i,j): |d_{vij}| \geq \epsilon d_v} \frac{d_{vij}^2}{d_v^2} = o(N_v). \quad (5.22)$$

此处

$$d_{vij} = (a_{vi} - \bar{a}_v)(b_{vj} - \bar{b}_v),$$

而

$$d_v^2 = \sum_{i,j} \frac{d_{vij}^2}{N_v}.$$

定理 5.1 (Hajek) 若 A_v, B_v 都满足条件 N , 则当 $v \rightarrow \infty$ 时,

$$\frac{Q_v - E(Q_v)}{\sqrt{\text{Var}(Q_v)}} \xrightarrow{\mathcal{L}} N(0, 1)$$

的充要条件为: (A_v, B_v) 满足条件 M .

此处 $E(Q_v), \text{Var}(Q_v)$ 分别由

$$E(Q_v) = N_v \bar{a}_v \bar{b}_v, \quad \text{Var}(Q_v) = \frac{N_v^2}{N_v - 1} \mu_{2v}(A) \mu_{2v}(B) \quad (5.23)$$

给出.

注 5.1 由于仅从 A_v, B_v 分别满足条件 N 推不出 (A_v, B_v) 满足条件 M , 故只假定 A_v, B_v 都满足条件 N 推不出定理 5.1 的结论. 事实上, 如陈希孺在文献 [5] 中证明的, 当只假定 A_v, B_v 都满足条件 N 时, $(Q_v - E(Q_v)) / \sqrt{\text{Var}(Q_v)}$ 的极限分布可能不存在. 如果存在, 可以是任一个其方差有限的无穷可分分布.

在历史上, Hajek 定理不是关于 Q_v 的极限定理中最早的. 最早的一个普遍性结果属于 Wald 和 Wolfowitz^[170], 后经 Noether^[129] 加以推广. 这些定理都是 Hajek 定理的特例. 但其条件容易验证.

为叙述这些定理, 要引进一个新的条件: 记

$$\mu_{rv}(A) = \frac{1}{N_v} \sum_{i=1}^{N_v} (a_{vi} - \bar{a}_v)^r, \quad r = 2, 3, \dots.$$

称 A_v 满足条件 W , 若对固定的 r , 序列

$$\left\{ \frac{\mu_{rv}(A)}{(\mu_{2v}(A))^{r/2}} : v = 1, 2, \dots \right\}$$

有界.

定理 5.2 (Wald, Wolfowitz) 若 A_v 和 B_v 都满足条件 W , 则当 $v \rightarrow \infty$ 时,

$$\frac{Q_v - E(Q_v)}{\sqrt{\text{Var}(Q_v)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

定理 5.3 (Noether) 若 A_ν, B_ν 中有一个满足条件 W , 而另一个满足条件 N , 则当 $\nu \rightarrow \infty$ 时,

$$\frac{Q_\nu - E(Q_\nu)}{\sqrt{\text{Var}(Q_\nu)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

为证这两个定理, 只须证明: 在定理 5.3 的假定下, 有 (A_ν, B_ν) 满足条件 M . 设 A_ν 满足条件 N 而 B_ν 满足条件 W . 不失普遍性, 设

$$\bar{a}_\nu = \bar{b}_\nu = 0, \quad \mu_{2\nu}(A) = \mu_{2\nu}(B) = \frac{1}{N_\nu}. \quad (5.24)$$

记

$$R_\nu = \max_{1 \leq i \leq N_\nu} |a_{\nu i}|, \quad c_{\nu i} = \frac{a_{\nu i}}{R_\nu},$$

则 $|c_{\nu i}| \leq 1$. 有

$$\sum_{i=1}^{N_\nu} |a_{\nu i}|^r = R_\nu^r \sum_{i=1}^{N_\nu} |c_{\nu i}|^r. \quad (5.25)$$

由于 A_ν 满足条件 N 及 (5.24) 式, 知

$$\lim_{\nu \rightarrow \infty} R_\nu = 0,$$

故当 $r > 2$ 时, 利用 $|c_{\nu i}| \leq 1$, 有

$$R_\nu^r \sum_{i=1}^{N_\nu} |c_{\nu i}|^r \leq R_\nu^{-2} \sum_{i=1}^{N_\nu} (R_\nu c_{\nu i})^2 = R_\nu^{r-2} \rightarrow 0, \quad \nu \rightarrow \infty.$$

故由 (5.25) 式得

$$\lim_{\nu \rightarrow \infty} \sum_{i=1}^{N_\nu} |a_{\nu i}|^r = 0. \quad (5.26)$$

又由 B_ν 满足条件 W 及 (5.24) 式, 知当 $r = 3, 4, \dots$ 时, 对某常数 K , 有

$$\left| N_\nu^{r/2-1} \sum_{i=1}^{N_\nu} b_{\nu i}^r \right| \leq K, \quad \nu = 1, 2, \dots. \quad (5.27)$$

由 (5.24) 式有 $d_\nu^2 = 1/N_\nu$. 故 (5.22) 式转化为

$$\sum_{(i,j): |d_{\nu ij}| \geq \epsilon / \sqrt{N_\nu} d_{\nu ij}^2} = o(1). \quad (5.28)$$

若此式不成立, 则存在 $\epsilon > 0, \epsilon' > 0$ 及一子列 $\{\nu_k\}$, 使

$$\sum_{(i,j): |d_{\nu_k ij}| \geq \epsilon_k / \sqrt{N_{\nu_k}} d_{\nu_k ij}^2} \geq \epsilon', \quad k = 1, 2, \dots. \quad (5.29)$$

这时有

$$\sum_{i,j=1}^N d_{(\nu_k)ij}^4 \geq \frac{\epsilon^2}{N_{\nu_k}} \sum_{(i,j): |d_{(\nu_k)ij}| \geq \epsilon / \sqrt{N_{\nu_k}} d_{(\nu_k)ij}^2} \geq \frac{\epsilon^2 \epsilon'}{N_{\nu_k}}, \quad k = 1, 2, \dots.$$

(5.30)

另一方面,由(5.26)式及(5.27)式,有

$$\sum_{i,j=1}^{N_{\nu k}} d_{(\nu k)ij}^4 = \sum_{i=1}^N (a_{(\nu k)ij})^4 \sum_{i=1}^{N_{\nu k}} (b_{(\nu k)ij})^4 = o(1) \frac{K}{N_{\nu k}}, \quad k = 1, 2, \dots$$

这与(5.30)式矛盾,因而证明了(5.28)式是正确的,即 (A_{ν}, B_{ν}) 满足条件 M .定理证毕.

由本定理的证明过程及引理3.1知,条件 $W \Rightarrow$ 条件 N (这一点容易直接证明).又:满足条件 W 的一个重要例子如下:

$$\begin{aligned} A_{\nu} &= (1, \dots, 1, 0, \dots, 0), m_{\nu} \text{ 个 } 0, n_{\nu} \text{ 个 } 1, \\ m_{\nu} + n_{\nu} &= N_{\nu}. \text{ 当 } \nu \rightarrow \infty \text{ 时, } N_{\nu} \rightarrow \infty, \end{aligned} \quad (5.31)$$

且

$$\inf_{\nu} \frac{m_{\nu}}{N_{\nu}} > 0, \quad \inf_{\nu} \frac{n_{\nu}}{N_{\nu}} > 0.$$

5.2.2 随机序列的情况

在(5.19)式定义的 Q_{ν} 中的 $(\eta_1, \dots, \eta_{N_{\nu}})$ 是以概率 $1/(N_{\nu}!)$ 取 $(a_{\nu 1}, \dots, a_{\nu N_{\nu}})$ 的任一置换.在许多问题中, $a_{\nu 1}, \dots, a_{\nu N_{\nu}}$ 本身就是随机变量的观察值.因此必须处理关于这种序列的满足条件 N, M 的问题.对此,下面几个定理是有用的.

定理 5.4 设 $X_1, X_2, \dots \sim F, Y_1, Y_2, \dots \sim G$.此处 F, G 为一维分布,其方差是非0有限的.令

$$A_{\nu} = (X_1, \dots, X_{\nu}), \quad B_{\nu} = (Y_1, \dots, Y_{\nu}), \quad \nu = 1, 2, \dots,$$

则 (A_{ν}, B_{ν}) 以概率1满足条件 M .注意:此处并未要求 X_1, Y_1 独立.

证 不失普遍性,可设 F, G 有均值0方差1.先证对任给 $\epsilon > 0$ 存在 c ,使

$$\lim_{\nu \rightarrow \infty} \frac{1}{\nu} \sum_{r, 1 \leq i \leq \nu, |X_i - \bar{X}_{\nu}| \geq c} (X_i - \bar{X}_{\nu})^2 \leq \epsilon, \text{ a.s.} \quad (5.32)$$

式中

$$\bar{X}_{\nu} = \frac{1}{\nu} \sum_{i=1}^{\nu} X_i.$$

由三角不等式,有

$$\begin{aligned} J_{\nu} &\triangleq \left\{ \frac{1}{\nu} \sum_{i, 1 \leq i \leq \nu, |X_i - \bar{X}_{\nu}| \geq c} (X_i - \bar{X}_{\nu})^2 \right\}^{1/2} \\ &\leq \left\{ \frac{1}{\nu} \sum_{i, 1 \leq i \leq \nu, |X_i - \bar{X}_{\nu}| \geq c} X_i^2 \right\}^{1/2} + |\bar{X}_{\nu}|. \end{aligned} \quad (5.33)$$

记

$$D = \{(x_1, x_2, \dots) : |\bar{x}_\nu| \leq \frac{c}{2}, \text{当 } \nu \text{ 充分大}\}.$$

由强大数律知, $P(D) = 1$. 故以概率 1 当 ν 充分大时, 有

$$\begin{aligned} J_\nu &\leq \left\{ \frac{1}{\nu} \sum_{i: 1 \leq i \leq \nu, |X_i| \geq c/2} X_i^2 \right\}^{1/2} + |\bar{X}_\nu| \\ &\rightarrow \left\{ \int_{|x| \geq c/2} x^2 dF(x) \right\}^{1/2}. \end{aligned} \quad (5.34)$$

选 c 充分大, 使

$$\int_{|x| \geq c/2} x^2 dF(x) < \epsilon,$$

由 (5.33)、(5.34) 式即证明了 (5.32) 式. 现有

$$\begin{aligned} d_\nu^2 &= \frac{1}{\nu} \sum_{i,j=1}^{\nu} (X_i - \bar{X}_\nu)^2 (Y_j - \bar{Y}_\nu)^2 \\ &= \nu \left(\frac{1}{\nu} \sum_{i=1}^{\nu} (X_i - \bar{X}_\nu)^2 \right) \left(\frac{1}{\nu} \sum_{i=1}^{\nu} (Y_i - \bar{Y}_\nu)^2 \right). \end{aligned}$$

由于

$$\lim_{\nu \rightarrow \infty} \frac{1}{\nu} \sum_{i=1}^{\nu} (X_i - \bar{X}_\nu)^2 = 1, \text{ a.s.},$$

$$\lim_{\nu \rightarrow \infty} \frac{1}{\nu} \sum_{i=1}^{\nu} (Y_i - \bar{Y}_\nu)^2 = 1, \text{ a.s.},$$

知

$$P(d_\nu^2 \leq 4\nu, \nu \text{ 充分大}) = 1.$$

求 c 充分大, 使 (5.32) 式以及

$$\lim_{\nu \rightarrow \infty} \frac{1}{\nu} \sum_{i: 1 \leq i \leq \nu, |Y_i - \bar{Y}_\nu| \geq c} (Y_i - \bar{Y}_\nu)^2 \leq \epsilon, \text{ a.s.} \quad (5.35)$$

给定 $\delta > 0$, 找 ν_0 , 使

$$\sqrt{4\nu_0 \delta^2} \geq c^2,$$

则为了使

$$|X_i - \bar{X}_\nu| \cdot |Y_j - \bar{Y}_\nu| \geq 2\sqrt{\nu}\delta,$$

当 $\nu < \nu_0$ 时, $|X_i - \bar{X}_\nu|$ 和 $|Y_j - \bar{Y}_\nu|$ 中至少有一个要大于 c . 由此知按概率 1 当 ν 充分大时, 有

$$\begin{aligned}
& \frac{1}{2} \sum_{i,j: 1 \leq i \leq \nu, 1 \leq j \leq \nu, |X_i - X_\nu| |Y_j - Y_\nu| \geq 2\sqrt{\nu\delta}} (X_i - \bar{X}_\nu)^2 (Y_j - \bar{Y}_\nu)^2 \\
& \leq \frac{1}{\nu} \sum_{i: 1 \leq i \leq \nu, |X_i - X_\nu| \geq c} (X_i - \bar{X}_\nu)^2 \frac{1}{\nu} \sum_{j=1}^{\nu} (Y_j - \bar{Y}_\nu)^2 \\
& \quad + \frac{1}{\nu} \sum_{j: 1 \leq j \leq \nu, |Y_j - Y_\nu| \geq c} (Y_j - \bar{Y}_\nu)^2 \frac{1}{\nu} \sum_{i=1}^{\nu} (X_i - \bar{X}_\nu)^2 < 4\epsilon.
\end{aligned}$$

由于 $\epsilon > 0$ 及 $\delta > 0$ 的任意性, 即证明了本定理.

由本定理及引理 3.1, 即得

定理 5.5 设 $X_1, X_2, \dots \sim F$, F 有非 0 而有限的方差, 则

$$A_\nu = (X_1, \dots, X_\nu)$$

以概率 1 服从条件 N .

这个定理是不难直接证明的. 它也是下一定理的特例.

定理 5.6 设 $X_{i1}, X_{i2}, \dots \sim F_i (i = 1, \dots, c)$. 这里 $F_1, \dots, F_c$ 都是一维分布, 其方差非 0 有限.

令

$$A_\nu = (X_{11}, \dots, X_{1n_{\nu 1}}, X_{21}, \dots, X_{2n_{\nu 2}}, \dots, X_{c1}, \dots, X_{cn_{\nu c}})$$

若

$$\lim_{\nu \rightarrow \infty} \min\{n_{\nu 1}, \dots, n_{\nu c}\} = \infty,$$

则 A_ν 以概率 1 满足条件 N .

证 记 $N_\nu = n_{\nu 1} + \dots + n_{\nu c}$, 且

$$\bar{X}_{\nu i} = \frac{1}{n_{\nu i}} \sum_{j=1}^{n_{\nu i}} X_{ij}, \quad \bar{X}_\nu = \frac{1}{N_\nu} \sum_{i=1}^c \sum_{j=1}^{n_{\nu i}} X_{ij}.$$

则

$$\begin{aligned}
\mu_{2\nu}(A) &= \frac{1}{N_\nu} \sum_{i=1}^c \sum_{j=1}^{n_{\nu i}} (X_{ij} - \bar{X}_\nu)^2 \\
&= \frac{1}{N_\nu} \sum_{i=1}^c \sum_{j=1}^{n_{\nu i}} (X_{ij} - \bar{X}_{\nu i})^2 + \frac{1}{N_\nu} \sum_{i=1}^c n_{\nu i} (\bar{X}_{\nu i} - \bar{X}_\nu)^2. \quad (5.36)
\end{aligned}$$

又

$$\begin{aligned}
R_\nu(A) &\triangleq \max\{|X_{ij} - \bar{X}_{\nu i}| : 1 \leq j \leq n_{\nu i}, 1 \leq i \leq c\} \\
&\leq \max\{|X_{ij} - \bar{X}_{\nu i}| : 1 \leq j \leq n_{\nu i}, 1 \leq i \leq c\} \\
&\quad + \max\{|\bar{X}_{\nu i} - \bar{X}_\nu| : 1 \leq i \leq c\}.
\end{aligned}$$

由此式及 (5.36) 式, 知

$$\frac{R_\nu(A)}{(N_\nu \mu_{2\nu}(A))^{1/2}} \leq \max_{1 \leq i \leq c} \left\{ \max_{1 \leq j \leq n_{\nu i}} |X_{ij} - \bar{X}_{\nu i}| / \left(\sum_{j=1}^{n_{\nu i}} (X_{ij} - \bar{X}_{\nu i})^2 \right)^{1/2} \right\} + \max_{1 \leq i \leq c} n_{\nu i}^{-1/2}. \quad (5.37)$$

由定理 5.5 知, $(X_{i1}, \dots, X_{in_{\nu i}})$ 以概率 1 满足条件 $N(i = 1, \dots, c)$. 故 (5.37) 式右边第一项当 $\nu \rightarrow \infty$ 时趋于 0. 又由

$$\min_{1 \leq i \leq c} n_{\nu i} \rightarrow \infty$$

知第二项也趋于 0. 于是证明了要证的结果.

定理 5.7 1° 设 $X_1, X_2, \dots \sim F$, F 为一维分布, 其方差非 0 有限. 又设 $A_\nu = (a_{\nu 1}, \dots, a_{\nu N_\nu})$ 满足条件 N . 则按概率 1, $B_\nu = (X_1 + a_{\nu 1}, \dots, X_{N_\nu} + a_{\nu N_\nu})$ 满足条件 N ;

2° 设 $G_\nu \triangleq (X_{11}, \dots, X_{1n_{\nu 1}}, \dots, X_{c1}, \dots, X_{cn_{\nu c}})$ 满足定理 5.6 的条件, 且 $n_{\nu 1} + \dots + n_{\nu c} = N_\nu$, 则按概率 1, $c_\nu + A_\nu$ 满足条件 N .

当 $c = 2$ 时, 2° 的证明见文献 [2] 中引理 4. 一般 c 的证明无区别; 1° 的证明更简单.

5.2.3 若干简单应用

例 5.7 回到例 5.4. 设 (5.8) 式中的 F 有非 0 的有限方差. 记合样本 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 为 $Z^N (N = m + n)$. 在给定 Z^N 的次序统计量 $Z^{(N)}$ 之下, 对任一统计量 $T = T(Z^N)$ 的条件分布 (即其置换分布) 记为 $\mathcal{L}(T | Z^{(N)})$.

设 $N \rightarrow \infty$ 时, 有

$$0 < \liminf \frac{m}{N} \leq \limsup \frac{m}{N} < 1.$$

则

$$B_N = \left(-\frac{1}{m}, \dots, -\frac{1}{m}, \frac{1}{n}, \dots, \frac{1}{n} \right),$$

其中 $-1/m$ 和 $1/n$ 各有 m 和 n 个, 满足条件 W . 根据定理 5.6, 按概率 1, $A_N = (X_1, \dots, X_m, Y_1, \dots, Y_n)$ 满足条件 N . 于是根据定理 5.3, 并注意到当原假设 H 成立时, 有 (见 (5.23) 式)

$$E(\bar{Y} - \bar{X} | Z^{(N)}) = 0,$$

$$\text{Var}(\bar{Y} - \bar{X} \mid Z^{(N)}) = \frac{N}{mn(N-1)} \cdot \left\{ \sum_{i=1}^m (X_i - \xi_N)^2 + \sum_{j=1}^n (Y_j - \xi_N)^2 \right\},$$

其中

$$\xi_N = \frac{1}{N} \left(\sum_{i=1}^m X_i + \sum_{j=1}^n Y_j \right) = \frac{m}{N} \bar{X}_m + \frac{n}{N} \bar{Y}_n,$$

即得(按概率 1)

$$\begin{aligned} & \mathcal{L} \left[\sqrt{\frac{mn(N-1)}{N}} (\bar{Y} - \bar{X}) / \left(\sum_{i=1}^m (X_i - \xi_N)^2 + \sum_{j=1}^n (Y_j - \xi_N)^2 \right)^{1/2} \middle| Z^{(N)} \right] \\ & \xrightarrow{\mathcal{L}} N(0, 1). \end{aligned} \quad (5.38)$$

当原假设 H 成立时,

$$\frac{1}{N} \left\{ \sum_{i=1}^m (X_i - \xi_N)^2 + \sum_{j=1}^n (Y_j - \xi_N)^2 \right\}$$

以及

$$\frac{1}{N} \left\{ \sum_{i=1}^m (X_i - \bar{X}_m)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2 \right\}$$

都按概率 1 趋于 F 的方差 σ^2 , 而 σ^2 是非 0 有限的. 又

$$\frac{N-2}{N-1} \rightarrow 1,$$

故(5.38)式可改写为

$$\begin{aligned} & \mathcal{L} \left[\sqrt{\frac{mn(N-2)}{N}} (\bar{Y} - \bar{X}) / \left(\sum_{i=1}^m (X_i - \bar{X}_m)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2 \right)^{1/2} \middle| Z^{(N)} \right] \\ & \xrightarrow{\mathcal{L}} N(0, 1). \end{aligned} \quad (5.39)$$

以 T_N 记(5.39)式左边的统计量. 由(5.39)式知, 当 N 很大时, 置换检验与以(5.40)式否定域的无条件检验渐近等价:

$$T_N > u_\alpha. \quad (5.40)$$

但当 N 很大时,

$$u_\alpha \approx t_{N-2}(\alpha).$$

故(5.40)式又近似表为

$$T_N > t_{N-2}(\alpha). \quad (5.41)$$

但(5.41)式不是别的, 正是通常的单边两样本 t 检验. 这样, 从置换检验出发, 通过极限手续, 又回到了在正态假设下惯用的方法.

这可以说是置换检验方法的一个根本弱点: 如果坚持按置换检验的定义实

施,则除非 N 很小,计算量将很大;若用渐近方法,则又回到了传统的检验而得不到新意.正是这个缺点使置换检验不能在应用中起多大作用.因而在非参数统计中的地位也就不如秩检验.在以下一些例子中也可看到这个现象.

但不应由此而根本否定置换检验的意义.首先,导出置换检验的基本出发点比较一般,这使我们对一些传统检验(如 t 检验)获得了新的了解,使这种检验的根基更扎实些.其次,在有些情况下(如例 5.6),只有置换检验才提供了理论上能站住脚的方法,最后,由于现代计算工具的进展,在样本大小不很大时,严格按置换检验做是可行的,而正好是在这种情况,传统检验可能导致重大的错误.

还有一点需要提醒一下:在给定 $Z^{(N)}$ 的条件下, T_N 是 $\bar{Y} - \bar{X}$ 的严格上升函数,故基于 $\bar{Y} - \bar{X}$ 的置换检验与基于 T_N 置换检验是一样的.

例 5.8 独立性的置换检验:设 $(X_1, Y_1), \dots, (X_N, Y_N) \sim F$, F 为一个二维分布,其边缘分布 $F_1(x)$ 与 $F_2(y)$ 都有非 0 的有限方差.要检验假设 $H: X_1, Y_1$ 独立,即

$$F(x, y) = F_1(x)F_2(y).$$

对立假设取为:“ X_1 和 Y_1 正相关”.

取通常的样本相关系数

$$r_N = \sum_{i=1}^N (X_i - \bar{X}_N)(Y_i - \bar{Y}_N) / \left[\sum_{i=1}^N (X_i - \bar{X}_N)^2 \sum_{i=1}^N (Y_i - \bar{Y}_N)^2 \right]^{1/2}$$

为检验统计量,而考虑基于它的置换检验.以 $X^{(N)}$ 和 $Y^{(N)}$ 分别记 $X_1, \dots, X_N$ 和 $Y_1, \dots, Y_N$ 的次序统计量,则在给定 $X^{(N)}$ 和 $Y^{(N)}$ 时, r_N 的分母不依赖于 X_i 和 Y_i (各自) 的置换,而

$$\text{分子} = \sum_{i=1}^N X_i Y_i - N \bar{X}_N \bar{Y}_N$$

是 $\sum_{i=1}^N X_i Y_i$ 的严增函数.故在考虑基于 r_N 的置换检验时,可以用

$$T_N = \sum_{i=1}^N X_i Y_i$$

代替 r_N . 为作 $\mathcal{L}(T_N | X^{(N)}, Y^{(N)})$, 要计算 $(N!)^2$ 个值 $\sum_{i=1}^N X_{j_i} Y_{k_i}$, 其中 $(j_1, \dots, j_N)$ 和 $(k_1, \dots, k_N)$ 都是 $1, \dots, N$ 的置换. 由对称性, 只要计算 $N!$ 个值 $\sum_{i=1}^N X_i Y_{k_i}$ 就行了. 将这 $N!$ 个值排序:

$$t_1 \leq \cdots \leq t_{N!}.$$

若 $T_N > t_{N!(1-\alpha)}$, 则否定原假设^①.

若 N 很大, 则可用正态分布逼近 T_N 的置换分布, 此处相当于

$$A_N = (X_1, \cdots, X_N), \quad B_N = (Y_1, \cdots, Y_N).$$

根据定理 5.4, 按概率 1 有 (A_N, B_N) 满足条件 M , 故定理 5.1 可用. 易见

$$E(T_N | X^{(N)}, Y^{(N)}) = N\bar{X}_N\bar{Y}_N;$$

$$\text{Var}(T_N | X^{(N)}, Y^{(N)}) = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}_N)^2 \sum_{i=1}^N (Y_i - \bar{Y}_N)^2.$$

故由定理 5.1 得(以概率 1)

$$\begin{aligned} & \mathcal{L} \left[(T_N - N\bar{X}_N\bar{Y}_N) / \left(\frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}_N)^2 \sum_{i=1}^N (Y_i - \bar{Y}_N)^2 \right)^{1/2} \middle| X^{(N)}, Y^{(N)} \right] \\ & \xrightarrow{\mathcal{L}} N(0, 1), \end{aligned} \quad (5.42)$$

即

$$\mathcal{L}(\sqrt{N-1}r_N | X^{(N)}, Y^{(N)}) \xrightarrow{\mathcal{L}} N(0, 1). \quad (5.43)$$

由此知, 基于 r_N 的置换检验, 渐近等价于以 (5.44) 式为否定域的无条件检验:

$$r_N > \frac{1}{\sqrt{N-1}} u_\alpha. \quad (5.44)$$

不难看出, 此检验渐近地等价于通常在二维正态分布中检验相关系数为 0 的 t 检验. 事实上, 后者是基于: 当原假设成立时

$$\frac{\sqrt{N-2}r}{\sqrt{1-r^2}}$$

为自由度 $N-2$ 的 t 分布, 由此得出水平 α 检验的否定域为

$$r_N > \frac{t_{N-2}(\alpha)}{\sqrt{N-2+t_{N-2}^2(\alpha)}}. \quad (5.45)$$

因为当 $N \rightarrow \infty$ 时, 有

$$t_{N-2}(\alpha) \rightarrow u_\alpha, \quad \frac{\sqrt{N-1}}{\sqrt{N-2+t_{N-2}^2(\alpha)}} \rightarrow 1$$

知 (5.44)、(5.45) 式确是渐近等价的. 这里又可看到在上例中曾见到过的现象. 当考虑基于某统计量的大样本置换检验时, 就回到了基于该统计量的传统

① 若 $t_1, \cdots, t_{N!}$ 不全相异, 则为达到确切的水平 α , 有可能须施行随机化检验.

检验.

例 5.9 对称性检验: 设 $X_1, \dots, X_N \sim F(x - \theta)$, F 为一维分布, 方差非 0 有限, 关于 0 对称. 要检验假设 $H: \theta = 0$, 对立假设是 $\theta > 0$.

以 $\bar{X}_N$ 为检验统计量, 并过渡到条件检验. 以 $|X|^N$ 记 $|X_1|, \dots, |X_N|$ 的次序统计量, 则易见, 在给定 $|X|^N$ 后, $(X_1, \dots, X_N)$ 有 2^N 个可能值 ($\pm X_1, \dots, \pm X_N$). 我们就这 2^N 个可能值的每一个算出其算术平均值, 得到 2^N 个值

$$\frac{1}{N} \sum_{i=1}^N \pm X_i,$$

记为

$$t_1 \leq \dots \leq t_{2^N}.$$

若 $\bar{X}_N > t_{2^N(1-\alpha)}$, 否定原假设 H .

为了考察当 $N \rightarrow \infty$ 时, $\mathcal{L}(\bar{X}_N \mid |X|^N)$ 的极限分布, 注意: 这分布与变量

$$\xi_N = \frac{1}{N} \sum_{i=1}^N \eta_i$$

的分布一样, 此处 $\eta_1, \dots, \eta_N$ 相互独立, 且

$$P(\eta_i = X_i) = P(\eta_i = -X_i) = \frac{1}{2}$$

(注意: 在此 $X_1, \dots, X_N$ 已视为常数). 以 G_i 记 η_i 的分布. 注意: $\eta_1 + \dots + \eta_N$ 的方差是

$$\sum_{i=1}^N X_i^2.$$

记

$$a = \int_{-\infty}^{\infty} x^2 dF(x),$$

则由假定知 $0 < a < \infty$. 按强大数律有

$$\frac{1}{N} \sum_{i=1}^N X_i^2 \rightarrow a, \text{ a.s.}$$

故知按概率 1, 当 $N \rightarrow \infty$ 时, $\eta_1 + \dots + \eta_N$ 的方差 B_N^2 有数量级 $(aN)/2$. 又由定理 5.5, 按概率 1, $(X_1, \dots, X_N)$ 满足条件 N , 故当 $N \rightarrow \infty$ 时,

$$\max_{1 \leq i \leq N} |X_i - \bar{X}_N| / \sqrt{\sum_{i=1}^N (X_i - \bar{X}_N)^2} \rightarrow 0, \text{ a.s.} \quad (5.46)$$

注意到

$$\sum_{i=1}^N X_i^2 \geq \sum_{i=1}^N (x_i - \bar{X}_N)^2,$$

又

$$|\bar{X}_N| \rightarrow \left| \int_{-\infty}^{\infty} x dF(x) \right| < \infty,$$

由(5.46)式得知:当 $N \rightarrow \infty$ 时,

$$\max_{1 \leq i \leq N} |X_i| / \sqrt{\sum_{i=1}^N X_i^2} \rightarrow 0, \text{ a.s.} \quad (5.47)$$

由(5.47)式即知,按概率 1, Lindeberg-Feller 条件

$$\lim_{N \rightarrow \infty} \frac{1}{B_N^2} \sum_{i=1}^N \int_{|t| \geq \varepsilon B_N} t^2 dG_i(t) = 0$$

满足. 因而由 Lindeberg-Feller 定理知, 当 $N \rightarrow \infty$ 时按概率 1, 有

$$\frac{\sum_{i=1}^N \eta_i}{\left(\sum_{i=1}^N X_i^2\right)^{1/2}} \xrightarrow{\mathcal{L}} N(0, 1)$$

成立. 因此

$$\mathcal{L}\left(N\bar{X}_N / \left(\sum_{i=1}^N X_i^2\right)^{1/2} \mid |X|^N\right) \xrightarrow{\mathcal{L}} N(0, 1). \quad (5.48)$$

由(5.48)式得到: 本例的置换检验渐近等价于以(5.49)式与否定域的无条件检验:

$$\frac{N\bar{X}_N}{\left(\sum_{i=1}^N X_i^2\right)^{1/2}} > u_\alpha. \quad (5.49)$$

对此问题来说, 相应于正态假设之下的传统的一样本单边 t 检验有否定域

$$\sqrt{N(N-1)}\bar{X}_N / \left(\sum_{i=1}^N (X_i - \bar{X}_N)^2\right)^{1/2} > t_{N-1}(\alpha). \quad (5.51)$$

因为在原假设 H 成立时,

$$\frac{1}{N} \sum_{i=1}^N X_i^2 \quad \text{和} \quad \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}_N)^2$$

都是 F 的方差的强相合估计, 有

$$\lim_{N \rightarrow \infty} \left\{ \frac{1}{N} \sum_{i=1}^N X_i^2 / \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}_N)^2 \right\} = 1, \text{ a.s.},$$

且

$$\lim_{N \rightarrow \infty} t_{N-1}(\alpha) = u_{\alpha},$$

由此知两检验(5.49)与(5.50)是渐近等价的——这又碰到前两例中曾看到的情况.

注意:在本例中置换没有起作用.而极限定理的推导不是基于定理5.1,而是基于古典的中心极限定理.

5.2.4 广义对比试验

本节的问题和结果是根据陈希孺的工作^[2].这里不写出仔细的证明过程.有兴趣的读者可参看文献[2].

设要比较 A, B 两个处理.一共有 N 个试验单元可用.根据这些试验单元的性质将其分布 c 个区组,分别包含 $N_1, \dots, N_c$ 个试验单元.同一区组内的试验单元的均匀程度与不在一个组内的单元相比较,要好得多.但一般仍不一定可认为已充分均匀了.故随机化的手续仍有必要.在区组 i 内随机地选取 m_i 个单元施以处理甲,其余 $n_i = N_i - m_i (i = 1, \dots, c)$ 个单元施以处理乙.从第 i 个区组内观察到的试验结果为:

$$\text{处理 } A: X_{i1}, \dots, X_{im_i}; \quad \text{处理 } B: Y_{i1}, \dots, Y_{in_i}. \quad (5.51)$$

由于施行了随机化,这些数据的构造可表述为:

$$\begin{cases} X_{ij} = a_{ic_{ij}} + e_{ij}, & j = 1, \dots, m_i; i = 1, \dots, c; \\ Y_{ij} = \theta + a_{id_{ij}} + e_{i, m_i + j}, & j = 1, \dots, n_i; i = 1, \dots, c. \end{cases} \quad (5.52)$$

式中 θ 是 B 的处理效应 (A 的处理效应定为 0); a_{ij} 是区组 i 内的第 j 个试验单元的“单元效应”; $(c_{i1}, \dots, c_{im_i}, d_{i1}, \dots, d_{in_i})$ 是 $(1, 2, \dots, N_i)$ 的任一置换,它取每个这样的置换的概率,都是 $1/(N_i!)$; 而 $e_{ij} (j = 1, \dots, N_i)$ 是区组 i 中所作 N_i 次试验的随机试验误差.假定全体 $e_{ij} (j = 1, \dots, N_i; i = 1, \dots, c)$ 为 iid. 变量.不难看出,这个模型是例 5.6 结尾处所述的模型由一个区组到 c 个区组的推广.当 $N_1 = N_2 = \dots = N_c = 2$ 时,每个区组包含 A, B 处理各一次.这就是常见的“对比试验”.因此,我们把此处的模型叫做“广义对比试验”.

选择检验统计量为

$$\begin{aligned} T_N &= \sum_{i=1}^c \frac{m_i n_i}{N_i} (\bar{Y}_i - \bar{X}_i), \\ \bar{X}_i &= \frac{1}{m_i} \sum_{j=1}^{m_i} X_{ij}, \quad \bar{Y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}. \end{aligned} \quad (5.53)$$

选择 T_N 一方面是出于线性模型理论的启发;另一方面可由下述直观想法得出:在区组 i 内,以 $\bar{Y}_i - \bar{X}_i$ 估计 θ . 一共得到 c 个估计. 为得到一总的估计,应取其加权. 在 X_{ij} 、 Y_{ij} 都有等方差 σ^2 时, $\bar{Y}_i - \bar{X}_i$ 的方差为

$$\left(\frac{1}{m_i} + \frac{1}{n_i}\right)\sigma^2 = \frac{N_i}{m_i n_i} \sigma^2.$$

其权应与倒数即

$$\frac{m_i n_i}{N_i}$$

成比例.

现在考虑基于 T_N 的置换检验. 以 $Z^{(i)}$ 记 $(X_{i1}, \dots, X_{im_i}, Y_{i1}, \dots, Y_{in_i})$ ($i = 1, \dots, c$) 的次序统计量. 给定 $Z^{(1)}, \dots, Z^{(c)}$ 后, 通过置换可产生 T_N 的 $\prod_{i=1}^c N_i!$ 个值(其中至多只有 $\prod_{i=1}^c \binom{N_i}{m_i}$ 个不同的). 利用这些值, 按定义 5.1 的做法即可作出本问题的置换检验. 在本问题中, 如在例 5.5 一样, 置换不是在全体数据中无限制地进行, 而是分成 c 个部分, 在每部分内进行. 易见, 基于 T_N 的置换检验与基于

$$T_N^* = \sum_{i=1}^c \sum_{j=1}^{n_i} Y_{ij} \quad (5.54)$$

的置换检验是一致的. 事实上, 在上述置换下,

$$\sum_{j=1}^{m_i} X_{ij} + \sum_{j=1}^{n_i} Y_{ij}$$

为一常数. 故在 T_N 上加以

$$\sum_{i=1}^c \frac{n_i}{N_i} \left(\sum_{j=1}^{m_i} X_{ij} + \sum_{j=1}^{n_i} Y_{ij} \right) = \sum_{i=1}^c \left(\frac{m_i n_i}{N_i} \bar{X}_i + \frac{n_i^2}{N_i} \bar{Y}_i \right) \quad (5.55)$$

不至于影响基于 T_N 的置换检验. 易见, T_N 加上 (5.55) 式以后, 即得到 (5.54) 式定义的 T_N^* .

在考虑大样本检验时, 有两个情况是令人感兴趣的:

1. c 固定, $N_i \rightarrow \infty$,

$$0 < \liminf \frac{m_i}{N_i} \leq \limsup \frac{m_i}{N_i} < 1, \quad i = 1, \dots, c.$$

假定对每个 i , $(u_{i1}, \dots, u_{iN_i})$ 满足条件 N . 记

$$B_{N_i} = \left(-\frac{1}{m_i}, \dots, -\frac{1}{m_i}, \frac{1}{n_i}, \dots, \frac{1}{n_i} \right),$$

则由对 m_i, N_i 所作的假定知 B_{N_i} 满足条件 W . 设 e_{ij} 的分布 F 有非 0 而有限的方差, 则考虑 (5.52) 式及定理 5.7 知在原假设 $\theta = 0$ 成立时, $\bar{Y}_i - \bar{X}_i$ 的置换分布为渐近正态: 按概率 1

$$\begin{aligned} & \mathcal{L}(\sqrt{m_i n_i (N_i - 1) / N_i} (\bar{Y}_i - \bar{X}_i) / D_i \mid Z^{(1)}, \dots, Z^{(c)}) \\ & \xrightarrow{\mathcal{L}} N(0, 1), \quad i = 1, \dots, c. \end{aligned} \quad (5.56)$$

此处

$$\begin{aligned} D_i^2 = & \sum_{j=1}^{m_i} \left(X_{ij} - \frac{m_i \bar{X}_i + n_i \bar{Y}_i}{N_i} \right)^2 \\ & + \sum_{j=1}^{n_i} \left(Y_{ij} - \frac{m_i \bar{X}_i + n_i \bar{Y}_i}{N_i} \right)^2, \quad i = 1, \dots, c. \end{aligned} \quad (5.57)$$

因为在给定 $Z^{(1)}, \dots, Z^{(c)}$ 的条件下,

$$\bar{Y}_i - \bar{X}_i, \quad i = 1, \dots, c.$$

的置换分布条件独立, 由 (5.56) 式得 (T_N 见 (5.53) 式) 按概率 1

$$\begin{aligned} & \mathcal{L} \left(T_N / \sum_{i=1}^c \frac{m_i n_i}{N_i (N_i - 1)} D_i^2 \right)^{1/2} \mid Z^{(1)}, \dots, Z^{(c)} \\ & \xrightarrow{\mathcal{L}} N(0, 1). \end{aligned} \quad (5.58)$$

由 (5.58) 式知: 基于 T_N 的置换检验渐近等价于以 (5.59) 式为否定域的无条件检验:

$$T_N > u_\alpha \left(\sum_{i=1}^c \frac{m_i n_i}{N_i (N_i - 1)} D_i^2 \right)^{1/2}. \quad (5.59)$$

在正态线性模型下, 假定试验误差 $e_{ij} \sim N(0, \sigma^2)$, 且区组内各试验单元绝对均匀. 这时模型为

$$\begin{cases} X_{ij} = a_i + e_{ij}, & j = 1, \dots, m_i; \\ Y_{ij} = \theta + a_i + e_{ij}, & j = 1, \dots, n_i; i = 1, \dots, c; a_1, \dots, a_c \text{ 和 } \theta \text{ 为常数;} \\ e_{ij} \text{ 为 iid.}, & j = 1, \dots, N_i; i = 1, \dots, c; e_{ij} \sim N(0, \sigma^2). \end{cases} \quad (5.60)$$

用线性模型的理论 (参看例如文献 [3] 中 5.3 节), 得出

$$H: \theta = 0 \leftrightarrow K: \theta > 0$$

的检验有否定域

$$T_N > t_{N'}(\alpha) R_N \left(\sum_{i=1}^c \frac{m_i n_i}{N_i} \right)^{1/2} / \sqrt{N'} \quad (N' = \sum_{i=1}^c N_i - c - 1), \quad (5.61)$$

$$R_N^2 = \sum_{i=1}^c D_i^2.$$

因为

$$\frac{1}{N} R_N^2 \rightarrow \sigma^2 \text{ a.s.}, \quad \frac{1}{N_i} D_i^2 \rightarrow \sigma^2, \text{ a.s.},$$

且

$$t_{N'}(\alpha) \rightarrow u_\alpha,$$

易见按概率1, (5.59)式右边与(5.61)式右边的比趋于1. 因此, 大样本置换检验(5.59)等价于传统的检验(5.61), 一如前几例的情形. 顺便指出, 在文献[110](见第7章)中证明了在正态线性模型(5.60)式之下, 检验(5.61)是水平 α 的一致最优无偏检验.

2. 另一种情况是 $N_1, N_2, \dots$ 固定, $c \rightarrow \infty$. 这时, 在一定的条件下仍可证明(5.58)式, 因而仍可作出大样本置换检验. 不过, 这时不是使用定理5.1(因 N_i 固定, 定理5.1无法使用), 而是用古典中心极限定理. 所需条件如下: e_{ij} 有非0有限方差, 且

$$\lim_{c \rightarrow \infty} \frac{\max(q_1^2, \dots, q_c^2)}{c + q_1^2 + \dots + q_c^2} = 0,$$

$$q_i^2 = \frac{1}{N_i} \sum_{j=1}^{N_i} \left(u_{ij} - \frac{1}{N_i} \sum_{k=1}^{N_i} u_{ik} \right)^2. \quad (5.62)$$

此结果的证明比较复杂. 其详可参看文献[2]^①.

5.2.5 多样本问题或完全随机化试验

先从多样本问题的角度看: 设有样本

$$X_{i1}, \dots, X_{in_i} \sim F(x - \theta_i), \quad i = 1, \dots, c, \quad (5.63)$$

要检验的原假设是 $H: \theta_1 = \dots = \theta_c$.

记

^① 见文献[2]的第12页. 条件(5.62)是正确的, 但文献[2]的证明中有一处错误, 即为证明正态性, 不应验证文献[2]的(5.44)式, 而应验证Lindeberg条件. 对该处的证明稍加修改即可完成这一证明.

$$N = n_1 + \cdots + n_c,$$

$$\bar{X}_{(N)} = \frac{1}{N} \sum_{i=1}^c \sum_{j=1}^{n_i} X_{ij}, \quad \bar{X}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} X_{ij}.$$

若 H 成立, 则 $\bar{X}_i$ 与 $\bar{X}_{(N)}$ 应比较接近. 因此, $(\bar{X}_i - \bar{X}_{(N)})^2$ 可以作为与 H 的偏离的一种度量. 对 $i = 1, \cdots, c$ 作它们的加权和, 权数自然与 n_i 成比例. 从而得

$$T_N = \sum_{i=1}^c n_i (\bar{X}_i - \bar{X}_{(N)})^2. \quad (5.64)$$

就以 T_N 作为检验统计量, 然后过渡到置换检验.

以 $X^{(N)}$ 记全体 X_{ij} ($j = 1, \cdots, n_i, i = 1, \cdots, c$) 的次序统计量. 则在给定 $X^{(N)}$ 时, $\bar{X}_i - \bar{X}_{(N)}$ 的条件分布与由 (5.19) 式定义的 Q_ν 的分布相同, 这只需改 ν 为 N , 而

$$(b_{N1}, \cdots, b_{NN}) = \left(-\frac{1}{N}, \cdots, -\frac{1}{N}, \cdots, \frac{1}{n_1} - \frac{1}{N}, \cdots, \frac{1}{n_i} - \frac{1}{N}, \cdots, -\frac{1}{N}, \cdots, -\frac{1}{N} \right), \quad (5.65)$$

而 $(\eta_1, \cdots, \eta_N)$ 按概率

$$\frac{1}{N!}$$

取 $(X_{11}, \cdots, X_{1n_1}, \cdots, X_{c1}, \cdots, X_{cn_c})$.

记 (5.65) 式右边为 $B_N^{(i)}$, $(X_{11}, \cdots, X_{1n_1}, \cdots, X_{c1}, \cdots, X_{cn_c})$ 为 A_N . 则依定理 5.5 知 A_N 服从条件 N . 又设当 $N \rightarrow \infty$ 时,

$$\lim \frac{n_i}{N} = \rho_i > 0, \quad i = 1, \cdots, c. \quad (5.66)$$

则 $B_N^{(i)}$ 满足条件 W , 因此由定理 5.2 的证明过程知 $(A_N, B_N^{(i)})$ 满足条件 M . 通过简单计算表明 (与例 3.8 相似): 在给定 $X^{(N)}$ 之下,

$$(\sqrt{n_1}(\bar{X}_1 - \bar{X}_{(N)}), \cdots, \sqrt{n_c}(\bar{X}_c - \bar{X}_{(N)}))$$

的条件协方差阵为

$$\begin{aligned} \mathbf{A}_N &= S_N^2 \tilde{\mathbf{A}}_N, \quad \tilde{\mathbf{A}}_N = (\lambda_{Nij})_1^c, \\ S_N^2 &= \sum_{i=1}^c \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{(N)})^2, \\ \lambda_{Nii} &= \frac{N - n_i}{N(N-1)}, \\ \lambda_{Nij} &= -\frac{\sqrt{n_i n_j}}{N(N-1)}, \quad i \neq j. \end{aligned} \quad (5.67)$$

记 F 的方差为 σ^2 , 当 H 成立时, $S_N^2/N \rightarrow \sigma^2, \text{a.s.}$. 于是有

$$\begin{aligned}\mathbf{A}_N &\rightarrow \sigma^2 \mathbf{A}, \quad \mathbf{A} = (\lambda_{ij})_1^c, \\ \lambda_{ii} &= 1 - \rho_i, \quad \lambda_{ij} = -\sqrt{\rho_i \rho_j}, \quad i \neq j.\end{aligned}\quad (5.68)$$

若用 $\mathbf{A}_1$ 记 $\mathbf{A}$ 的前 $c-1$ 行与 $c-1$ 列所成的方阵, 则由 (5.56) 式, 按例 3.8 的论证知 $\mathbf{A}_1^{-1}$ 存在. 因此, 按例 3.8 中的推理, 若用 $\tilde{\mathbf{A}}_{N_1}$ 记 $\tilde{\mathbf{A}}_N$ 的前 $c-1$ 行与 $c-1$ 列所成的方阵, 则

$$\begin{aligned}\mathcal{L}[S_N^{-2}(\sqrt{n_1}(\bar{X}_1 - X_{(N)}), \dots, \sqrt{n_c}(\bar{X}_c - X_{(N)})) \\ \tilde{\mathbf{A}}_{N_1}^{-1}(\sqrt{n_1}(\bar{X}_1 - \bar{X}_{(N)}), \dots, \sqrt{n_c}(\bar{X}_c - \bar{X}_{(N)}))' | X^{(N)}] \rightarrow \chi_{c-1}^2.\end{aligned}\quad (5.69)$$

按例 3.8 的方法不难算出 (5.69) 式左边为

$$S_N^{-2}(N-1) \sum_{i=1}^c n_i (\bar{X}_i - \bar{X}_{(N)})^2.$$

于是得到以概率为 1, 有

$$\mathcal{L}\left[(N-1) \sum_{i=1}^c n_i (\bar{X}_i - \bar{X}_{(N)})^2 / S_N^2 \mid X^{(N)}\right] \xrightarrow{\mathcal{L}} \chi_{c-1}^2. \quad (5.70)$$

由 (5.70) 式可得到: 基于

$$T_N = \sum_{i=1}^c n_i (\bar{X}_i - \bar{X}_{(N)})^2$$

的置换检验渐近等价于 (5.71) 式否定域的无条件检验.

$$T_N > \frac{\chi_{c-1}^2(\alpha) S_N^2}{N-1}. \quad (5.71)$$

另一方面, 若假定 F 为正态, 则传统的 F 检验有否定域

$$\frac{1}{c-1} T_N / \frac{1}{N-c} \sum_{i=1}^c \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 > F_{c-1, N-c}(\alpha). \quad (5.72)$$

但在原假设下有

$$\begin{aligned}\frac{S_N^2}{N-1} &\rightarrow \sigma^2, \text{ a.s.}, \\ \frac{1}{N-c} \sum_{i=1}^c \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 &\rightarrow \sigma^2, \text{ a.s.}\end{aligned}$$

又

$$(c-1)F_{c-1, N-1}(\alpha) \rightarrow \chi_{c-1}^2(\alpha).$$

由此得知: 两检验 (5.71) 式与 (5.72) 式是渐近等价的.

另一种提法是从试验设计的角度着眼:设有 c 个处理 $A_1, \dots, A_c$ 要比较. 一共有 $N = n_1 + \dots + n_c$ 个试验单元可用. 从这 N 个单元中随机地分配 $n_1, \dots, n_c$ 个给处理 $A_1, \dots, A_c$. 设单元效应为 $a_1, \dots, a_N$. 以 $\bar{a}_i$ 记处理 i 的 n_i 个观察值的算术平均, 实际上就是分配给处理 i 的那 n_i 个单元的单元效应平均——在此假定试验误差不存在. 又以 $\bar{a}_{(N)}$ 记 $a_1, \dots, a_N$ 的算术平均. 则仍用

$$T_N = \sum_{i=1}^c n_i (\bar{a}_i - \bar{a}_{(N)})^2$$

为检验统计量. 按例 5.6 的方式得到一个(非条件化的)置换检验. 其形式从多样本问题所得出的完全一致. 若 $(a_1, \dots, a_N)$ 满足条件 N , 则与上面同样的推理证明: 所得置换检验仍渐近等价于以 (5.71) 式为否定域的检验.

这种试验称为“完全随机化试验”. 因为它在全部单元中不受限制地施行随机化.

也可以除单元效应外, 尚有试验随机误差起作用. 这时, 同样作置换检验, 但是为条件化的. 如果 $(a_1, \dots, a_N)$ 满足条件 N 且随机误差有非 0 有限的方差, 则根据定理 5.7 不难证明: 大样本否定域 (5.71) 式仍成立.

5.2.6 随机区组

c 个处理在 N 个区组中比较, 每个区组恰可容纳 c 次试验. 要检验的假设 H 是: “处理效应不存在”(即在下文中 $t_1 = \dots = t_0 = 0$).

我们一开始就考虑最一般的情况: 以 $t_1, \dots, t_0$ 记处理效应. 第 j 区组中的 c 个单元的效应分别记为 $a_{1j}, \dots, a_{cj}$. 试验随机误差记为 $e_{1j}, \dots, e_{cj}$. 设 e_{ij} ($j = 1, \dots, N; i = 1, \dots, c$) 全体为 iid. 在每个区组内实行完全随机化, 试验结果可表为

$$X_{ij} = t_i + a_{d_{ij}j} + e_{ij}, \quad j = 1, \dots, N; i = 1, \dots, c. \quad (5.73)$$

这里 $(d_{1j}, \dots, d_{cj})$ 是 $(1, \dots, c)$ 的一置换. $(d_{1j}, \dots, d_{cj})$ 取任一这样的置换的概率都是

$$\frac{1}{c!},$$

且 $(d_{11}, \dots, d_{c1}), \dots, (d_{1N}, \dots, d_{cN})$ 相互独立 (e_{ij} 全体为 iid. 在上面已提及). 记

$$\bar{X}_i = \frac{1}{N} \sum_{j=1}^N X_{ij}, \quad \bar{X}_{(N)} = \frac{1}{Nc} \sum_{i=1}^c \sum_{j=1}^N X_{ij}.$$

取

$$T_N = \sum_{i=1}^c (\bar{X}_i - \bar{X}_{(N)})^2 \quad (5.74)$$

作为检验统计量. 以 $X^{(j)}$ 记 $(X_{1j}, \dots, X_{cj})$ 的次序统计量, 在给定 $X^{(1)}, \dots, X^{(N)}$ 的条件下过渡到基于 T_N 的置换检验.

往下要考虑当 $N \rightarrow \infty$ 时, T_N 的置换分布的极限. 现在证明下面的结果:

定理 5.8 记

$$q_j^2 = \sum_{i=1}^c \left(a_{ij} - \frac{1}{c} \sum_{i=1}^c a_{ij} \right)^2, \quad j = 1, \dots, N, \dots$$

假定以下条件成立:

1° $e_{ij} (j = 1, 2, \dots, i = 1, \dots, c)$ 为 iid., e_{ij} 的方差 σ^2 非 0 有限.

2°

$$\lim_{N \rightarrow \infty} \frac{\max(q_1^2, \dots, q_N^2)}{N + q_1^2 + \dots + q_N^2} = 0. \quad (5.75)$$

则在原假设 $H: t_1 = \dots = t_c$ (不失普遍性, 可设公共值为 0, 因为该公共值可加入单元效应中, 而不影响 q_j^2 的值) 成立, 且 $N \rightarrow \infty$ 时, 以概率为 1, 有

$$\mathcal{L} \left[(c-1)N^2 T_N / \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_{.j})^2 \mid x^{(j)}, j = 1, \dots, N \right] \xrightarrow{\mathcal{L}} \chi_{c-1}^2. \quad (5.76)$$

注 5.2 条件 (5.75) 的意义是: 区组内不均匀度不能相差悬殊. 如果每区组内各单元绝对均匀, 这条件自然成立. 另外, 由下面的证明过程不难看出: 若试验随机误差不存在 ($e_{ij} = 0$), 则条件 (5.75) 应代之以

$$\lim_{N \rightarrow \infty} \frac{\max(q_1^2, \dots, q_N^2)}{q_1^2 + \dots + q_N^2} = 0. \quad (5.77)$$

又由以下的证明可看出: 这两个特例的证明不需使用下文引证的 Chow 的结果.

为证明本定理, 须使用 Y. S. Chow 的一个结果: 设 $\xi_1, \xi_2, \dots$ 为 iid., 均值为 0 而方差有限. 又对任何 n 给了常数 $a_{n1}, \dots, a_{nn}$, 使

$$\sum_{i=1}^n a_{ni}^2 = 1,$$

则

$$\lim_{n \rightarrow \infty} \frac{1}{\sqrt{n}} \sum_{i=1}^n a_{ni} \xi_i = 0, \text{ a.s. } \quad (5.78)$$

证明参见文献[47].

引进一串独立的 c 维随机向量

$$\eta^{(j)} = (\eta_{1j}, \dots, \eta_{cj})', \quad j = 1, 2, \dots,$$

其中 η_j 以概率

$$\frac{1}{c!}$$

取 $(X_{1j}, \dots, X_{cj})$ 的任一置换为值. 记

$$X_{\cdot j} = \frac{1}{c} \sum_{i=1}^c X_{ij},$$

并且

$$\bar{\eta}_i = \frac{1}{N} \sum_{j=1}^N \eta_{ij}, \quad \bar{\eta}_{(N)} = \frac{1}{Nc} \sum_{i=1}^c \sum_{j=1}^N \eta_{ij},$$

$$S_j^2 = \sum_{i=1}^c (X_{ij} - X_{\cdot j})^2.$$

则 T_N (见 (5.74) 式) 在给定 $X^{(1)}, \dots, X^{(N)}$ 下的条件分布就是

$$Q_N = \sum_{i=1}^c (\bar{\eta}_i - \bar{\eta}_{(N)})^2 \quad (5.79)$$

的(无条件)分布. 通过简单计算表明

$$E(\eta^{(j)}) = (X_{\cdot j}, \dots, X_{\cdot j})',$$

$$\text{Cov}(\eta^{(j)}) = \frac{1}{c} S_j^2 \mathbf{A}, \quad \mathbf{A} = (\lambda_{uv})_1^c,$$

当 $u = v$ 时,

$$\lambda_{uv} = 1;$$

当 $u \neq v$ 时,

$$\lambda_{uv} = -\frac{1}{c-1}.$$

以 $e_{\cdot j}$ 和 $a_{\cdot j}$ 分别记 $e_{1j}, \dots, e_{cj}$ 和 $a_{1j}, \dots, a_{cj}$ 的算术平均, 有

$$S_j^2 = \sum_{i=1}^c (e_{ij} - e_{\cdot j})^2 + q_j^2 + 2 \sum_{i=1}^c (a_{a_{ij}} - a_{\cdot j})(e_{ij} - e_{\cdot j}). \quad (5.80)$$

由强大数律, 有

$$\sum_{j=1}^N \sum_{i=1}^c \frac{(e_{ij} - e_{\cdot j})^2}{N} \rightarrow E\left(\sum_{i=1}^c (e_{ij} - e_{\cdot j})^2\right) = (c-1)\sigma^2 > 0, \text{ a.s.}$$

(5.81)

此处 σ^2 为 e_{ij} 的方差. 另外, 考虑到

$$\sum_{i=1}^c (a_{d_{ij}} - a_{ij}) = 0,$$

由此知 (5.80) 式右边第三项等于

$$2 \sum_{i=1}^c (a_{d_{ij}} - a_{.j}) \bar{e}_{ij} (\bar{e}_{ij} = e_{ij} - E(e_{ij})),$$

这与

$$2 \sum_{i=1}^c (a_{ij} - a_{.j}) \bar{e}_{ij}$$

同分布. 按上面引述的 Chow 的结果, 有

$$\lim_{N \rightarrow \infty} (N \sqrt{q_1^2 + \cdots + q_N^2})^{-1} \sum_{j=1}^N \sum_{i=1}^c (a_{ij} - a_{.j}) \bar{e}_{ij} = 0, \text{ a.s. },$$

即

$$\lim_{N \rightarrow \infty} (\sqrt{N} \sqrt{q_1^2 + \cdots + q_N^2})^{-1} \sum_{j=1}^N \sum_{i=1}^c (a_{d_{ij}} - a_{.j}) e_{ij} - e_{.j} = 0, \text{ a.s. }, \quad (5.82)$$

因为

$$(N(q_1^2 + \cdots + q_N^2))^{1/2} \leq N + (q_1^2 + q_N^2).$$

由 (5.80) ~ (5.82) 式知: 若记

$$S_{(N)}^2 = S_1^2 + \cdots + S_N^2,$$

则

$$\liminf_{N \rightarrow \infty} \frac{S_{(N)}^2}{N + q_1^2 + \cdots + q_N^2} > 0, \text{ a.s. } \quad (5.83)$$

记

$$\tilde{\eta}^{(j)} = (\eta_{2j} - X_{.j}, \cdots, \eta_{cj} - X_{.j})'.$$

则 $\tilde{\mathbf{A}}$ 记 $\mathbf{A}$ 的后 $c-1$ 行和 $c-1$ 列所构成的方阵. 易见 $\tilde{\mathbf{A}}$ 为正定的. 下证以概率为 1 所成立的下述事实:

当 $N \rightarrow \infty$ 时, 有

$$\frac{\sqrt{c\tilde{\mathbf{A}}}^{-1/2} \sum_{j=1}^N \tilde{\eta}^{(j)}}{S_{(N)}} \xrightarrow{\mathcal{L}} N(0, I). \quad (5.84)$$

I 为 $c-1$ 阶单位阵. 为此利用引理 3.7, 任取一个非零向量

$$\boldsymbol{\rho} = (\rho_2, \cdots, \rho_c)',$$

记

$$\xi_{Nj} = \frac{\sqrt{c\rho'\tilde{\Lambda}}^{-1/2}\tilde{\eta}^{(j)}}{S_{(N)}}.$$

有

$$E(\xi_{Nj}) = 0, \quad \text{Var}(\xi_{Nj}) = \frac{\rho'\rho S_j^2}{S_{(N)}^2},$$

且 $\xi_{N1}, \dots, \xi_{NN}$ 相互独立考察

$$\xi_N = \frac{\sqrt{c\rho'\tilde{\Lambda}}^{-1/2} \sum_{j=1}^N \tilde{\eta}^{(j)}}{S_{(N)}} = \sum_{j=1}^N \xi_{Nj}.$$

据引理 3.7, 为证(5.84) 式, 只需证明以概率为 1 有以下事实:

当 $N \rightarrow \infty$ 时, 有

$$\xi_N \xrightarrow{\mathcal{L}} N(0, \rho'\rho). \quad (5.85)$$

且例外集可选与 ρ 无关. 为此只须证明: 以概率为 1, $(\xi_{N1}, \dots, \xi_{NN})$ 满足 Lindeberg 条件(例外集与 ρ 无关). (参看文献[115] 中第 295 页) 为证此事实, 只需证明:

$$\lim_{N \rightarrow \infty} (\max_{1 \leq j \leq N} \xi_{Nj}^2) = 0, \quad \text{a.s. (例外集与 } \rho \text{ 无关)}. \quad (5.86)$$

由 ξ_{Nj} 的定义, 易见存在只依赖于 c 的常数 K , 使

$$\xi_{Nj}^2 \leq K (\max_{1 \leq i \leq c} |e_{ij} - e_{.j}|^2 + \max_{1 \leq i \leq c} |a_{ij} - a_{.j}|^2) / S_{(N)}^2. \quad (5.87)$$

但

$$\max_{1 \leq i \leq c} |a_{ij} - a_{.j}|^2 \leq q_j^2,$$

故依(5.75) 式和(5.83) 式, 有

$$\lim_{N \rightarrow \infty} (\max_{1 \leq j \leq N} \max_{1 \leq i \leq c} |a_{ij} - a_{.j}|^2 / S_{(N)}^2) = 0, \quad \text{a.s.} \\ (\text{例外集与 } \rho \text{ 无关}). \quad (5.88)$$

又因全体 e_{ij} 为 iid. 知当 i 固定时, $e_{i1} - e_{.1}, e_{i2} - e_{.2}, \dots$ 为 iid., 有均值 0 方差 $\frac{c-1}{c}\sigma^2$ 是非 0 有限. 故由定理 5.5 知

$$\{(e_{i1} - e_{.1}, \dots, e_{iN} - e_{.N}); N = 1, 2, \dots\}$$

以概率为 1 满足条件 N (例外集当然与 ρ 无关), 即

$$\lim_{N \rightarrow \infty} (\max_{1 \leq j \leq N} |e_{ij} - e_{.j}|^2 / \sum_{j=1}^N (e_{ij} - e_{.j})^2) = 0, \quad \text{a.s.}, \quad i = 1, \dots, c. \quad (5.89)$$

因为

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{j=1}^N (e_{ij} - e_{\cdot j})^2 = \frac{c-1}{c} \sigma^2, \text{ a.s.}$$

上式的分母可改为 N , 再注意到 (5.84) 式, 即得

$$\lim_{N \rightarrow \infty} (\max_{1 \leq j \leq N} \max_{1 \leq i \leq c} |e_{ij} - e_{\cdot j}|^2 / S_{(N)}^2) = 0, \text{ a.s.}$$

(例外集与 $\boldsymbol{p}$ 无关) (5.90)

结合 (5.87)、(5.88) 和 (5.89) 诸式, 即得 (5.86) 式. 因而证明了 (5.85) 式, 其例外集与 $\boldsymbol{p}$ 无关. 从而证明了 (5.84) 式. 于是以概率为 1 有以下事实成立:

当 $N \rightarrow \infty$ 时,

$$\frac{c \left(\sum_{j=1}^N \tilde{\eta}^{(j)} \right) \tilde{\mathbf{A}}^{-1} \left(\sum_{j=1}^N \tilde{\eta}^{(j)} \right)}{S_{(N)}^2} \xrightarrow{\mathcal{L}} \chi_{c-1}^2. \quad (5.91)$$

易见

$$\sum_{j=1}^N \tilde{\eta}^{(j)} = N(\eta_{2\cdot} - \bar{X}_{(N)}, \dots, \eta_{c\cdot} - \bar{X}_{(N)})',$$

其中

$$\eta_{i\cdot} = \frac{\sum_{j=1}^N \eta_{ij}}{N},$$

且

$$\sum_{i=2}^c (\eta_{i\cdot} - \bar{X}_{(N)}) = -(\eta_{1\cdot} - \bar{X}_{(N)}).$$

又通过简单计算表明: 当 $u \neq v$ 时, 有

$$\tilde{\mathbf{A}}^{-1} = (d_{uv}) : d_{uu} = \frac{2(c-1)}{c}, \quad d_{uv} = \frac{c-1}{c}.$$

利用这些事实, 不难算同 (5.91) 式左边为

$$(c-1)N^2 \sum_{i=1}^c (\eta_{i\cdot} - \bar{X}_{(N)})^2 / S_{(N)}^2.$$

于是由 (5.91) 式知以概率为 1 成立: 当 $N \rightarrow \infty$ 时,

$$(c-1)N^2 \sum_{i=1}^c (\eta_{i\cdot} - \bar{X}_{(N)})^2 / S_{(N)}^2 \xrightarrow{\mathcal{L}} \chi_{c-1}^2. \quad (5.92)$$

注意到 T_N 和 η_{ij} 的定义, 可看出 (5.92) 式就是 (5.76) 式. 定理证毕.

由(5.76)式知:基于 T_N 置换检验渐近等价于以(5.93)式为否定域的无条件检验:

$$T_N > \chi_{c-1}^2(\alpha) \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - X_{.j})^2 / \{(c-1)N^2\}. \quad (5.93)$$

注意到

$$\begin{aligned} \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - X_{.j})^2 &= \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_i - X_{.j} + \bar{X}_{(N)})^2 \\ &\quad + N \sum_{i=1}^c (\bar{X}_i - \bar{X}_{(N)})^2. \end{aligned} \quad (5.94)$$

可将(5.93)改写为等价的形式:

$$T_N > \left(1 + \frac{\chi_{c-1}^2(\alpha)}{(c-1)N}\right)^{-1} \chi_{c-1}^2(\alpha) \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_i - X_{.j} + \bar{X}_{(N)})^2 / \{(c-1)N^2\}. \quad (5.95)$$

另一方面,在传统的方差分析中,随机区组试验的模型是:

$$\begin{aligned} X_{ij} &= t_i + b_j + e_{ij}, \quad j = 1, \dots, N; i = 1, \dots, c, \\ e_{ij} (j = 1, \dots, N; i = 1, \dots, c) &\text{为 iid., 且 } e_{ij} \sim N(0, \sigma^2). \end{aligned} \quad (5.96)$$

在此模型下,为检验假设 $H: t_1 = \dots = t_c$ 常用 F 检验,它有否定域

$$T_N > F_{(c-1), (c-1)(N-1)}(\alpha) \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_i - X_{.j} + \bar{X}_{(N)})^2 / (N^2 - N). \quad (5.97)$$

因为

$$\begin{aligned} \lim_{N \rightarrow \infty} \frac{1 + \chi_{c-1}^2(\alpha)}{(c-1)N} &= 1, \\ \lim_{N \rightarrow \infty} \frac{N^2 - N}{N^2} &= 1, \end{aligned}$$

而

$$\lim_{N \rightarrow \infty} F_{(c-1), (c-1)(N-1)}(\alpha) = \frac{1}{c-1} \chi_{c-1}^2(\alpha)$$

知两检验(5.93)与(5.97)是渐近等价的.

注 5.3 Robinson 在文献[138]中讨论了本模型当随机误差 e_{ij} 为 0 的情况.

5.3 检验的渐近功效

上节中证明了在许多情况下,当样本大小很大时,置换检验渐近地等价于一通常的非条件化检验.因此自然猜测下面的结论成立:当样本大小趋于 ∞ 时,置换检验的功效会趋于与之渐近等价的那个非条件检验功效的极限.

本节的主要目的是给出这个结论的确切陈述和证明.

首先要指出:这个结论并非不证自明.因为按上节所给的定义,置换检验 ϕ 之渐近等价于通常检验 ϕ_1 ,只是说在原假设下, ϕ 的临界值(它是一个随机变量)收敛于 ϕ_1 的临界值(或更确切地说,二者之比趋于1.因为二者都与样本大小 N 有关),而功效的问题涉及有关统计量的对立假设下的分布.

其次,在考察这个问题时,对立假设不能固定不动,而必须依赖于样本大小 N ,且当 $N \rightarrow \infty$ 时,愈来愈接近于原假设.这是因为:由于一般检验多具有相合性,一旦对立假设固定了下来,这些检验的功效随着 $N \rightarrow \infty$ 将收敛于1,这就比较不出什么结果来了.

至于当样本大小固定时,置换检验的功效与和它相联系的那个无条件检验的功效之间不存在什么一般性的关系.就以(5.96)式的那个传统的随机区组模型来说:这时既可以用无条件检验(5.97),也可以考虑基于由(5.74)式定义的 T_N 的置换检验(这个置换检验与基于

$$T_N / \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_i - X_{.j} + \bar{X}_{(N)})^2$$

的置换检验是一致的.因为由(5.94)式并注意到表达式

$$\sum_{i=1}^c \sum_{j=1}^N (X_{ij} - X_{.j})^2$$

与置换无关,可知

$$T_N / \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_i - X_{.j} + \bar{X}_{(N)})^2$$

在给定 $X^{(1)}, \dots, X^{(N)}$ 之下是 T_N 的严格增加函数).这两个检验的功效有何关系,现在不知道.在其他更简单的问题中情况也是如此.实际上,设条件检验基于

统计量 T 和 M (见定义 5.1) 并有否定域 $T(X) > C(M(X))$, 而无条件检验 ϕ_1 有否定域 $T(X) > C_0$. 则在对立假设 K 之下, 二者的功效分别为

$$\beta_{\phi}(K) = P_k(T(X) > C(M(X))),$$

$$\beta_{\phi_1}(K) = P_k(T(X) > C_0).$$

前者涉及 T 和 M 在 K 之下的联合分布; 而后者只涉及 T 的分布. 二者之间不能建立什么一般性关系是明显的. 当然, 这并不排斥在某种特殊的情况下 (特殊的总体分布、特殊的 T 和 M 、特殊的 H 和 K) 二者有一定关系. 这一点目前几乎毫无了解, 因而值得探讨.

回到大样本问题. 用 θ 来记一堆参数的总集, 它对任何 N 唯一地确定了样本 $Z^N = (Z_1, \dots, Z_N)$ 的分布. θ 的形状可以是很复杂. 以 $\theta \in H$ 和 $\theta \in K$ 分别记原假设成立和对立假设成立的情况. 以模型 (5.73) 为例. 任一个 $\theta \in H$ 有形状:

$$\theta = \{F, t, (a_{1j}, \dots, a_{cj}), j = 1, 2, \dots\}.$$

此处 F 记 e_{ij} 的 (公共) 分布, t 记 $t_1, \dots, t_c$ 的公共值, 而

$$(a_{1j}, \dots, a_{cj}), \quad j = 1, 2, \dots$$

是任意的. 任一个 $\theta \in K$ 有形状

$$\theta = \{F, (t_1, \dots, t_c), (a_{1j}, \dots, a_{cj})\}, j = 1, 2, \dots; t_1, \dots, t_c \text{ 不全相同}\},$$

(5.98)

其中 F 与 $(a_{1j}, \dots, a_{cj})$ 的意义同上, $t_1, \dots, t_c$ 是任意不全相同的常数. 当对立假设中所考虑的参数随样本大小 N 而变化时, 则记为 θ_N . 例如

$$\theta_N = \{F, (t_{1N}, \dots, t_{cN}), (a_{1j}^{(N)}, \dots, a_{cj}^{(N)}),$$

$$j = 1, 2, \dots, t_{1N}, \dots, t_{cN} \text{ 不全相同}\}, \quad N = 1, 2, \dots. \quad (5.99)$$

又

$$T(Z^N) \xrightarrow{\theta_N} a, \quad N \rightarrow \infty$$

是指对任给的 $\epsilon > 0$, 当 $N \rightarrow \infty$ 时, 有

$$P_{\theta_N}(|T(Z^N) - a| \geq \epsilon) \rightarrow 0.$$

“一串对立假设 $\{\theta_N\}$ 当 $N \rightarrow \infty$ 时, 愈来愈接近于原假设”这句话, 按需要作适当的解释. 如在上例中, 这可以解释为

$$\lim_{N \rightarrow \infty} \sum_{i=1}^d \left(t_{iN} - \frac{1}{c} \sum_{i=1}^c t_{iN} \right)^2 = 0; \quad (5.100)$$

也可解释为

$$\text{存在常数 } t, \text{ 使 } \lim_{N \rightarrow \infty} t_{iN} = t, \quad i = 1, \dots, c. \quad (5.101)$$

注意,在这两个解释中,分布 F 都不动,而对 $a_{ij}^{(N)}$ 无任何要求.也可以将 θ_N 中的 F 改为 F_N ,而要求当 $N \rightarrow \infty$ 时, F_N 在某种意义上接近 F ,等等.

现设有了按定义 5.1 建立的、基于统计量

$$T_N = T(Z^N) \quad \text{和} \quad M_N = M(Z^N)$$

的条件检验 ϕ . 根据该定义的要求,在给定 $M_N = m$ 的条件下, $T(Z^N)$ 的条件分布只要原假设 H 成立,就与参数 θ 无关.而只依赖于 m . 现用 $F_N(t | m)$ 来记分布函数

$$P(T(Z^N) < t | M(Z^N) = m).$$

特别强调的是:这条件分布总是在原假设 H 成立之下算出的.

检验 ϕ 的否定域设为(当样本大小为 N 时)

$$T(Z^N) > C(M(Z^N)). \quad (5.102)$$

这检验的水平为 $\alpha \in (0, 1)$. 现在定义基于 $T(Z^N)$ 的无条件检验 ϕ_1 , 它与否定域

$$T(Z^N) > C_N. \quad (5.103)$$

在作了这些准备工作以后,可以证明下述的基本定理.它是由 Hoeffding 首先在文献[89]中提出的.我们在表述上作了一些修改,使其在形式上更一般些.定理的证明是很容易的.

定理 5.9 沿用以上的记号.

1° 设存在定义于 $(-\infty, \infty)$ 的非降函数 F , 使方程

$$F(t) = 1 - \alpha$$

有唯一解 t_α , 且 F 在 t_α 点连续. 又对 F 的任一连续点 t_0 有

$$F_N(t_0 | M(Z^N)) \xrightarrow{\theta_N} F(t_0), \quad N \rightarrow \infty, \quad (5.104)$$

则必有

$$C(M(Z^N)) \xrightarrow{\theta_N} t_\alpha, \quad N \rightarrow \infty. \quad (5.105)$$

此处对 $\{\theta_N\}$ 无任何限制(可在 H 中,也可在 K 中).

2° 设 H 为定义于 $(-\infty, \infty)$ 的非降函数,在 t_α 点连续,且对 H 的任何连续点 t_0 有

$$P_{\theta_N}(T(Z^N) \leq t_0) \rightarrow H(t_0). \quad (5.106)$$

又对这同一串 $\{\theta_N\}$, (5.104) 式成立,

$$\beta_{\theta_N} \rightarrow 1 - H(t_\alpha). \quad (5.107)$$

此处 β_{θ_N} 为样本大小是 N 时,检验 ϕ 的功效函数(下文中 $\beta_{\theta_1 N}$ 的意义与之相同).

3° 设对任何 $\theta \in H$, 记

$$F_{\theta_N}(t) = P_{\theta}(T(Z^N) \leq t),$$

即 $T(Z^N)$ 在参数为 θ 时的无条件分布函数. 设

$$\lim_{N \rightarrow \infty} F_{\theta_N}(t_0) = F(t_0) \quad (5.108)$$

对 F 的任何连续点 t_0 成立, 且 F 就是 1° 中提到的那个 F , 又假定 ϕ_1 为水平 α 渐近相似, 即对一切 $\theta \in H$, 有

$$\lim_{N \rightarrow \infty} \beta_{\phi_1 N}(\theta) = \alpha. \quad (5.109)$$

且 (5.106) 式成立. 则有

$$\lim_{N \rightarrow \infty} \beta_{\phi_1 N}(\theta_N) = 1 - H(t_{\alpha}). \quad (5.110)$$

注 5.4 本定理叙述较长, 为帮助理解, 特作几点解释:

1° 一般, 1° 中的 F 是一个分布函数, 如标准正态分布、 χ^2 分布等. 假定 (5.104) 式可大体上理解为: 条件分布 $F_N(\cdot | M(Z^N))$ 依分布收敛于 $F(\cdot)$. 在 5.2 节中提到, 在许多问题中, 当 $\theta_N = \theta \in H$ 时, (5.104) 式成立. 其中 F 为正态或 χ^2 分布. 这时, 由 (5.105) 式得

$$C(M(Z^N)) \xrightarrow{\theta} t_{\alpha},$$

即在原假设成立时, 条件检验 (5.102) 的临界值 $C(M(Z^N))$ 收敛于常数 t_{α} . 用上节的语言, 就是说条件检验 (5.102) “渐近等价” 于以 $T(Z^N) > t_{\alpha}$ 为否定域的无条件检验.

由此可见, 定理 5.9 的 1° 对 5.2 节中的一些例子作了理论上的表述.

2° 定理的 2° 涉及条件检验 (5.102) 在一串对立假设 $\{\theta_N\}$ 之下的渐近功效. 这一条的实质是: 这一渐近功效可由 $T(Z^N)$ 在 θ_N 之下的 (无条件) 渐近分布来决定, 而不用涉及 $T(Z^N)$ 的条件分布.

3° 第 3° 条涉及与条件检验 (5.102) 相关联的那个无条件检验 ϕ_1 (以 (5.103) 式为否定域). 这一条证明了: 在一定条件下 ϕ_1 在 θ_N 之下的渐近功效与 ϕ 在 θ_N 之下的渐近功效相同.

这样就回答了在本节开始时提到过的那个论点: “当样本大小趋于 ∞ 时, 置换检验的功效趋于与之渐近等价的那个无条件检验功效的极限”. 当然需要加一些条件. 从 Pitman 的 ARE 概念看, 也可以说这两个检验 (ϕ 和 ϕ_1) 的 ARE 为 1.

定理 5.9 的证明 1° 给定 $\varepsilon > 0$, 找 a_1, a_2 , 使

$$a_1 < t_{\alpha} < a_2, \quad a_2 - a_1 < \varepsilon, \quad F(t) \text{ 在 } a_1, a_2 \text{ 处连续.}$$

找 $\delta > 0$ 充分小, 使

$$F(a_1) + \delta < F(t_a) < F(a_2) - \delta.$$

这种 $\delta > 0$ 的存在, 由 $F(t) = 1 - \alpha$ 的解唯一及 F 的非降性推出. 根据 (5.104) 式, 存在 $N(\delta)$, 使当 $N \geq N(\delta)$ 时,

$$P_{\theta_N}(|F_N(a_i | M(Z^N)) - F(a_i)| \leq \delta, i = 1, 2) \geq 1 - \delta.$$

故

$$\begin{aligned} P_{\theta_N}(F_N(a_1 | M(Z^N)) &\leq F(a_1) + \delta, \\ F_N(a_2 | M(Z^N)) &\geq F(a_2 - \delta) \geq 1 - \delta. \end{aligned} \quad (5.111)$$

但

$$\begin{aligned} F_N(a_1 | M(Z^N)) &\leq F(a_1) + \delta \Rightarrow F_N(a_1 | M(Z^N)) < F(t_a) \\ &\Rightarrow F_N(a_1 | M(Z^N)) < 1 - \alpha \Rightarrow C(M(Z^N)) > a_1; \\ F_N(a_2 | M(Z^N)) &\geq F(a_2) - \delta \Rightarrow F_N(a_2 | M(Z^N)) > F(t_a) \\ &\Rightarrow F_N(a_2 | M(Z^N)) > 1 - \alpha \Rightarrow C(M(Z^N)) > a_2. \end{aligned}$$

将此两式与 (5.111) 式结合得知当 $N \geq N(\delta)$ 时,

$$P_{\theta_N}(a_1 < C(M(Z^N)) < a_2) \geq 1 - \delta. \quad (5.112)$$

显然, 这就证明了 1° .

2° 因为 (5.104) 式成立, 由已证的 1° 知, 对这一串 $\{\theta_N\}$ 而言, (5.105) 式成立. 取 $\eta > 0$ 充分小, 使 $t_a \pm \eta$ 为 H 的连续点. 由 (5.105) 式有

$$\lim_{N \rightarrow \infty} P_{\theta_N}(|C(M(Z^N)) - t_a| \leq \eta) = 1. \quad (5.113)$$

由假定 (5.106) 式及 $t_a \pm \eta$ 都是 H 的连续点, 有

$$\begin{aligned} \liminf_{N \rightarrow \infty} \beta_{\theta_N}(\theta_N) &\geq \lim_{N \rightarrow \infty} P_{\theta_N}(T(Z^N) > t_a + \eta) = 1 - H(t_a + \eta); \\ \limsup_{N \rightarrow \infty} \beta_{\theta_N}(\theta_N) &\leq \lim_{N \rightarrow \infty} P_{\theta_N}(T(Z^N) > t_a - \eta) = 1 - H(t_a - \eta). \end{aligned}$$

令 $\eta \downarrow 0$ (但总使 $t_a \pm \eta$ 为 H 的连续点), 注意到 H 在 t_a 处连续, 即得 (5.107) 式.

3° 由假定 (5.108) 式及 (5.109) 式, 并注意到 t_a 是方程 $F(t) = 1 - \alpha$ 的唯一解. 即得

$$\lim_{N \rightarrow \infty} C_N = t_a \quad (C_N \text{ 见 (5.103) 式}).$$

再由 (5.106) 式及 H 在 t_a 点连续, 即得 (5.110) 式. 定理证毕.

在应用本定理时关键的假设有两条: 一是 (5.104) 式. 在 5.2 节中我们所做的工作, 实际上主要就是在 $\theta_N = \theta$ 这个特例之下去验证这个条件. 为了使用本定理, 需要在某些对立假设序列 $\{\theta_N\}$ 之下来验证这一条. 这通常与在 5.2 节各例中所作的论证类似, 但因对立假设的性质比原假设复杂, 故相应地, 这一条在对

立假设下的验证在细节上也略为复杂.

另一条是(5.106)式,它涉及检验统计量在一串对立假设下的极限分布问题.至于条件(5.108),一般是易于验证的.

下面是一个简单例子.

例 5.10 再考虑例 5.4 的两样本问题(5.8).原假设 θ 就表为 F , 对立假设则有 (F, Δ) 的形状, $\Delta > 0$ 是(5.8)式中 θ 的值.取一串对立假设

$$\theta_N = \left(F, \frac{\Delta}{\sqrt{N}}\right), \quad N = 1, 2, \dots$$

此处 F, Δ 固定, F 为方差非 0 有限的一维分布, 而 $\Delta > 0$ 为常数, $N = m + n$. 又假设当 $N \rightarrow \infty$ 时, m/N 趋于极限 $\lambda \in (0, 1)$.

取 $M(Z^N)$ 为

$$Z^N = (X_1, \dots, X_m, Y_1, \dots, Y_n)$$

的次序统计量, 在例 5.4 中取检验统计量为

$$\bar{Y}_n - \bar{X}_m = \frac{1}{n} \sum_{j=1}^n Y_j - \frac{1}{m} \sum_{i=1}^m X_i.$$

不难看出: 基于 $\bar{Y}_n - \bar{X}_m$ 的置换检验与基于统计量

$$T(Z^N) = \sqrt{\frac{mn}{N}} (\bar{Y}_n - \bar{X}_m) / \left[\left(\sum_{i=1}^m (X_i - \bar{X}_m)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2 \right) / (N-2) \right] \quad (5.114)$$

的置换检验一致. 因此若记

$$\bar{Z}_N = \left(\sum_{i=1}^m X_i + \sum_{j=1}^n Y_j \right) / N,$$

则

$$\begin{aligned} & \sum_{i=1}^m (X_i - \bar{X}_m)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2 \\ &= \sum_{i=1}^m (X_i - \bar{Z}_N)^2 + \sum_{j=1}^n (Y_j - \bar{Z}_N)^2 + \frac{mn}{N} (\bar{Y}_n - \bar{X}_m)^2, \end{aligned} \quad (5.115)$$

而表达式

$$\sum_{i=1}^m (X_i - \bar{Z}_N)^2 + \sum_{j=1}^n (Y_j - \bar{Z}_N)^2$$

在 Z^N 的置换下保持不变, 由(5.114)式与(5.115)式可知, 在给定 $M(Z^N)$ 时 $T(Z^N)$ 为 $\bar{Y}_n - \bar{X}_m$ 的严格增函数, 故基于 $T(Z^N)$ 的置换检验 ϕ , 确与基于

$\bar{Y}_n - \bar{X}_n$ 的置换检验一致.

现在证明:对任一串

$$\theta_N = (F, \Delta_N), \quad N = 1, 2, \dots,$$

只要

$$\lim_{N \rightarrow \infty} \Delta_N = 0,$$

则条件(5.104)成立,且 F 为标准正态分布.

注意, X_i 与 Y_j 有下述形式:

$$X_i = e_i, Y_j = \epsilon_j + \Delta_N, \quad 1 \leq i \leq m; 1 \leq j \leq n$$

全体 e_j, ϵ_j 为 iid. 故 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 等于 $(e_1, \dots, e_m, \epsilon_1, \dots, \epsilon_n)$ 与 $(0, \dots, 0, \Delta_N, \dots, \Delta_N)$ 之和. 由于

$$\frac{m}{N} \rightarrow \lambda \in (0, 1),$$

知后者满足条件 N . 再由定理 5.7 的 2° 知以概率为 1, $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 满足条件 N . 于是以概率为 1 为 (5.38) 式. 现在证明: (5.38) 式中的统计量可改为由 (5.114) 式定义的 T_N . 根据 (5.115) 式以及

$$\frac{1}{m} \sum_{i=1}^m (X_i - \bar{Z}_N) \geq \frac{1}{m} \sum_{i=1}^m (X_i - \bar{X}_m) \rightarrow \sigma^2 > 0, \text{ a.s.}$$

及

$$\frac{m}{N} \rightarrow \lambda > 0,$$

可知以概率为 1, 有下式成立:

$$\liminf_{N \rightarrow \infty} \left\{ \sum_{i=1}^m (X_i - \bar{Z}_N)^2 + \sum_{j=1}^n (Y_j - \bar{Z}_N)^2 \right\} / N > 0. \quad (5.116)$$

另一方面,

$$\bar{Y}_n - \bar{X}_m = \frac{1}{n} \sum_{j=1}^n \epsilon_j - \frac{1}{m} \sum_{i=1}^m e_i + \Delta_N.$$

按强大数律,

$$\frac{1}{n} \sum_{j=1}^n \epsilon_j \quad \text{和} \quad \frac{1}{m} \sum_{i=1}^m e_i$$

都以概率为 1 收敛于 F 的均值. 再加上 $\Delta_N \rightarrow 0$, 即知

$$\lim_{N \rightarrow \infty} (\bar{Y}_n - \bar{X}_m)^2 = 0, \text{ a.s.}$$

这与 (5.115)、(5.116) 式结合并注意

$$\frac{mn}{N} < N,$$

即证明了:

$$\lim_{N \rightarrow \infty} \left\{ \left[\sum_{i=1}^m (X_i - \bar{X}_m)^2 + \sum_{j=1}^n (Y_j - \bar{Y}_n)^2 \right] / \left[\sum_{i=1}^m (X_i - \bar{Z}_N)^2 + \sum_{j=1}^n (Y_j - \bar{Z}_N)^2 \right] \right\} = 1, \text{ a.s.}$$

因而(5.38)式中的统计量确可改为 T_N . 这证明了条件(5.104)式成立(对前面描述的 $\{\theta_N\}$, 注意它包括 $\Delta_1 = \Delta_2 = \cdots = 0$ 这一特例).

下面证明: 若取

$$\begin{aligned} \theta_N &= (F, \Delta_N), \quad \Delta_N = \Delta_N' / \sqrt{N}, \\ \lim_{N \rightarrow \infty} \Delta_N' &= \Delta \text{ 存在有限,} \end{aligned} \quad (5.117)$$

则条件(5.106)成立, 其中 H 为 $N(\sqrt{\lambda(1-\lambda)}\Delta/\sigma, 1)$ 的分布函数, 而 σ^2 为 F 的方差. 设 $0 < \sigma^2 < \infty$ (回忆 $\lambda = \lim \frac{m}{N}$).

证明很简单: 由(5.114)式定义的 T_N , 其分子的分布收敛于 $N(\sqrt{\lambda(1-\lambda)}\Delta, \sigma^2)$ (按中心极限定理), 而分母则以概率为 1 收敛于 σ^2 . 特别, 在(5.117)式中取 $\Delta_1' = \Delta_2' = \cdots = 0$, 知条件(5.108)成立. 取基于 T_N 的无条件检验 ϕ_1 为通常的两样本 t 检验, 它有无否定域(5.41)式, 则条件(5.109)也成立. 由(5.110)式得到: 沿着一串对立假设(5.117)式, 两样本置换 t 检验 ϕ 及通常的两样本 t 检验 ϕ_1 , 其渐近功效都是

$$\int_{u_\alpha}^{\infty} \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(x - \frac{\sqrt{\lambda(1-\lambda)}\Delta}{\sigma} \right)^2 \right] dx = 1 - \Phi \left(u_\alpha - \frac{\sqrt{\lambda(1-\lambda)}\Delta}{\sigma} \right).$$

就是在本例这样简单的情况也能使人领会到: Hoeffding 的结果——即上文定理 5.9 只是提供了解决问题的一个步骤, 在具体实例中严格实现每一步骤, 并非轻而易举的事. 目前在文献中已知的结果有 Robinson^[138], 其中考虑了随机区组模型(5.73)当试验随机误差项 e_{ij} 为 0 的情况. 陈希孺在文献[2]及[15]中, 分别考虑了 5.2.4 小节中曾称之为“广义对比试验”模型(5.52)以及一般随机区组模型(5.73)的情况. 后一结果包含 Robinson^[138] 作为一个特例. 以下不加证明地引述文献[15]中的结果作为一个例子(仔细论证请参看文献[15]).

例 5.11 考虑一般随机区组模型(5.73). 取一串形如(5.99)式的对立假设 $\{\theta_N\}$. 沿用定理 5.8 的证明中的记号, 令

$$T_N^* = T(Z^N) = \frac{1}{c-1} N \sum_{i=1}^c (\bar{X}_i - \bar{X}_{(N)})^2 / \frac{1}{(c-1)(N-1)} \cdot \sum_{i=1}^c \sum_{j=1}^N (X_{ij} - \bar{X}_i - X_{\cdot j} + \bar{X}_{(N)})^2 \quad (5.118)$$

以 ϕ 记基于 F 统计量 T_N^* 的水平 α 的置换检验, 而 ϕ_1 记通常的 F 检验, 其否定域为

$$T_N^* > F_{c-1, (c-1)(N-1)}(\alpha).$$

记

$$u_N^2 = \sum_{i=1}^c (t_{iN} - t_{\cdot N})^2, \quad t_{\cdot N} = \frac{\sum_{i=1}^c t_{iN}}{c};$$

$$q_{Nj}^2 = \sum_{i=1}^c (a_{ij}^{(N)} - a_{\cdot j}^{(N)})^2, \quad a_{\cdot j}^{(N)} = \frac{\sum_{i=1}^c a_{ij}^{(N)}}{c};$$

$$q_N^2 = \frac{\sum_{j=1}^N q_{Nj}^2}{N}, \quad j = 1, \dots, N, N = 1, 2, \dots.$$

试验随机误差仍假定为 iid., 其方差 σ^2 非零有限. 有文献[2] 中证明了:

1° 假定

$$\lim_{N \rightarrow \infty} u_N^2 = 0;$$

$$\lim_{N \rightarrow \infty} \frac{\max(q_{N1}^2, \dots, q_{NN}^2)}{N + q_{N1}^2 + \dots + q_{NN}^2} = 0. \quad (5.120)$$

则对 T_N^* 而言, 条件(5.104) 对 $\{\theta_N\}$ 成立(这里不排斥 $u_1^2 = u_2^2 = \dots = 0$, 即 θ_N 属于原假设的情况).

2° 以 H 记 $\chi_{c-1, \delta}^2 / (c-1)$ 的分布函数(即 $H(x) = P(Y < (c-1)x)$, 其中 Y 服从自由度 $c-1$, 非中心参数 δ 的非中心 χ^2 分布). 若除了条件(5.119) 和 (5.120) 外, 再假定

$$\lim_{N \rightarrow \infty} \left\{ Nu_N^2 / \left(\sigma^2 + \frac{1}{c-1} q_N^2 \right) \right\} = \delta^2. \quad (5.121)$$

则条件(5.106) 对 $\{\theta_N\}$ 成立(这里也不排斥 $\delta^2 \geq 0$ 的情况).

由这些结果推出: 沿着服从上述条件的一串对立假设 $\{\theta_N\}$, 置换 F 检验 ϕ 与通常 F 检验 ϕ_1 有相同的渐近功效, 即

$$1 - P(Y < \chi_{c-1}^2(\alpha)),$$

其中 $Y \sim \chi_{c-1, \delta^2}$.

当 $\sigma^2 = 0$ 时, 回到 Robinson^[138] 讨论的情况. 仔细检查文献[15] 中的论证, 不难看出, 以上两条结论 1° 与 2° 仍成立, 只需将 (5.121) 式分母中的 N 和 (5.121) 式分母中的 σ^2 舍去. 这样就回到 Robinson 的条件. 又: 在文献[15] 中论证中假定了 $a_{ij}^{(N)}$ 有 a_{ij} 的形式 (即与 N 无关). 不难看出, 文献[15] 中的论证对本例所表述的较一般的提法仍完全适用.

渐近功效 $1 - P(Y < \chi_{c-1}^2(\alpha)) (Y \sim \chi_{c-1, \delta^2})$ 是 δ 严格上升函数. 从 (5.121) 式看出, δ 的值取决于:

a) u_N^2 愈大, δ 也愈大. 因为 u_N^2 大体上表达了 θ_N 与原假设的距离. 这距离愈大, 功效自应愈大.

b) σ^2 和 q_N^2 愈小, δ 愈大. 即如随机试验误差和区组内不均匀程度都小时, 检验的功效提高; 若 q_N^2 甚大, 则降低 σ^2 对提高功效不能有多少作用, 反之亦然. 总之, 使用大量不均匀材料作的试验, 其精度可能不如材料较少但较均匀的试验. 表达式 (5.121) 有助于在安排试验时适当平衡这些因素.

第 6 章

稳健性概念

本章的目的是对数理统计学中的稳健性概念、理论和方法作一初步的介绍. 固然不能把关于稳健性的统计理论视为非参数统计的一部分(参看 6.1.3 小节), 但是, 稳健性概念与非参数统计有一定的、甚至可以说是较密切的关系. 对它的了解, 在学习和研究非参数统计时是很有益和必要的.

本章内容的着重点在于: 对稳健性的基本概念, 从直观和数学的角度作较仔细的分析, 以帮助读者理解这个不易明确定义的概念. 这部分内容占据了本章前两节. 然后在 6.3 节中, 讨论稳健性概念在位置参数估计中的应用. 目的仍然在于加深对基本概念的理解, 也因为这是稳健性概念得到成功应用的一个主要情况. 在这节末尾附带提一下刻度参数和回归系数的估计问题.

6.1 稳健性概念的一般描述

6.1.1 稳健性的含义

稳健性是从英语“robustness”翻译过来的一个名词, 含有强壮、健康、坚韧等意思. 它是统计方法可能具有的一种特性. 一般说来, 是人们在构造统计方法时所努力追求的一种特性. 对这种性质的确切含义, 诸家在文献中提出了种种不尽相同的说法, 难于用三言两语说清楚. 因此, 在下面我们先根据自己的理解对这个概念作些一般性的描述, 再提出一个例子. 然后在这个基础上作几点进一步的解释.

在理论上解决一个统计问题时, 要假定问题适合一定的统计模型. 就是说, 样本的概率分布属于一定的分布族. 在这个基础上, 根据按问题的要求(估计某一参数, 检验某一假设等) 而选定的优良性准则或者直观上的考虑, 提出一定的统计方法(一个点估计量, 一个检验等).

但在实际上情况比较复杂: 往往没有足够的根据去确定问题的统计模型, 即使有相当的根据去确定其模型, 但往往也只能说是近似地成立而不是一丝不差地成立. 例如, 在一些情况下有理由认为模型近似地为正态, 但很少可能是确切的正态. 由于这一点, 我们希望所使用的统计方法有如下的性质: 当模型有微小的变化时, 统计方法的性能也只受到微小的影响. 如若不然, 则针对模型为正态

所构造的统计方法虽说在理论上有良好的性能,但在实用中可能完全不是那回事.统计方法的性能对模型的微小变化反应不敏感这样一种性质,一般就理解为统计方法的稳健性(另参看 6.1.3 小节中的进一步说明).

稳健性还有另一方面的含义:在实施任一统计方法时,必然要计算某个或某些统计量 T 的值. T 的值由样本 $X_1, \dots, X_n$ 决定.在通过观察或试验以得到 $X_1, \dots, X_n$ 的过程中,可能由于仪表故障或观察者的疏忽及记录时的笔误等,使 $X_1, \dots, X_n$ 中的一个或几个包含了较重大的误差,称为过失误差(gross error).受到这种误差的影响的数据,一般是以离开数据群体的孤立值的情况出现,常称为样本中的异常值(outlier).我们希望:当样本中混入少量异常值时,统计量 T 的值受到的影响不大.如若不然,则一、两个数据的错误可以使统计分析的结论完全改观,这就会使人们对分析的可靠性产生疑问.具有这种性质的统计量 T ,或者说,基于这种统计量 T 的统计方法称为有稳健性.从一定意义上说,上述对稳健性的两种解释是相通的.因为当数据受到过失误差的污染时,该数据可被视为来自另一个总体,其分布与模型原来所规定者不同.

我们注意到:在这种“稳健性”相当的概念在其他数学分支中也有,并且很重要.最显著的例子是微分方程解的稳定性:当初始条件或边界条件有少许变化时,解受到的影响也不大.

6.1.2 一个例子:样本均值与样本中位数的比较

设 $F(x)$ 是一个关于原点对称的分布, θ 为待估计的实参数, $X_1, \dots, X_n$ 为取自分布 $F(x - \theta)$ 的 iid. 样本,要由它估计 θ .

若有一定的理由假定 F 的正态——为简单计就设其为标准正态 $\Phi(x)$, 则样本均值 $\bar{X}_n$ 是一个在种种意义上有优良性的估计量.另一个可供选择的估计量是样本中位数 $\tilde{X}_n$.如前所讲(参见 4.3 节),虽然当 F 严格地为正态时 $\bar{X}_n$ 优于 $\tilde{X}_n$,但后者有它的优点.例如即使 F 的期望值不存在,它仍可以用.现从稳健性的观点对二者作一些比较:

设 F 与正态有些差距.具体说,有形式

$$F(x - \theta) = (1 - \epsilon)\Phi(x - \theta) + \epsilon\Phi\left(\frac{x - \theta}{\tau}\right). \quad (6.1)$$

此处 $\tau > 0, 0 < \epsilon \approx 0$.就是说:分布 F 是由 $1 - \epsilon : \epsilon$ 的比例混合两个正态分布 $N(\theta, 1)$ 与 $N(\theta, \tau^2)$ 而成.由于 $\epsilon \approx 0$,主要成分是前者,因而也被称为受污染(contaminated)的正态模型.从样本的角度看:可以把这理解为:在全部数据中

有 $100\epsilon\%$ 受到过失误差的影响而使误差增大了 τ 倍(按方差为 1 的标准), 分布 (6.1) 仍关于 θ 对称, 有方差

$$\sigma_{\tau\epsilon}^2 = 1 - \epsilon + \epsilon\tau^2 = 1 + (\tau^2 - 1)\epsilon \quad (6.2)$$

及概率密度函数

$$f_{\tau\epsilon}(x - \theta) = (1 - \epsilon)\varphi(x - \theta) + \epsilon\tau^{-1}\varphi\left(\frac{x - \theta}{\tau}\right), \quad (6.3)$$

其中 $\varphi(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$. $\bar{X}_n$ 和 $\tilde{X}_n$ 都是 θ 的无偏估计, 且按中心极限定理及定理

1.4((1.37) 式), 当样本大小 $n \rightarrow \infty$ 时, 有

$$\sqrt{n}(\bar{X}_n - \theta) \xrightarrow{\mathcal{L}} N(0, \sigma_{\tau\epsilon}^2); \quad (6.4)$$

$$\sqrt{n}(\tilde{X}_n - \theta) \xrightarrow{\mathcal{L}} N(0, c_{\tau\epsilon}^2), \quad c_{\tau\epsilon}^2 = \frac{\pi}{2} \left[1 + \left(\frac{1}{\tau} - 1 \right) \epsilon \right]^{-2}. \quad (6.5)$$

二者的渐近相对效率为

$$\text{ARE}(\tilde{X}, \bar{X}, \tau, \epsilon) \sigma_{\tau\epsilon}^2 / c_{\tau\epsilon}^2 \quad (6.6)$$

取 $\tau = 4$, 根据 (6.2)、(6.5) 和 (6.6) 式, 算出对若干 ϵ 值的 $\text{ARE}(\tilde{X}, \bar{X}, 4, \epsilon)$ 见表 6.1.

表 6.1

ϵ	0.000	0.025	0.050	0.100	0.150	0.200
$\text{ARE}(\tilde{X}, \bar{X}, 4, \epsilon)$	0.637	0.843	1.033	1.362	1.637	1.840

由此表看出, 当 $\epsilon = 0$ 即模型确为正态时, $\tilde{X}$ 对 $\bar{X}$ 的渐近相对效率不到 $2/3$. 而有 $\epsilon = 0.05$, 即样本中混入 5% 的异常值时, $\tilde{X}$ 即已优于 $\bar{X}$. 随着 ϵ 的增加, 优势愈来愈显著. 若 $\tau = 10$, 即过失误差更大时, 只要 $\epsilon = 0.006$, 即样本中混入 0.6% 的异常值, $\tilde{X}$ 即已优于 $\bar{X}$. 这就说明: 如果在该项实际应用中, 较大的过失误差有可能存在, 则样本均值在理论上对样本中位数的优越性已没有多少现实意义. 用稳健性的概念说, 就是 $\tilde{X}_n$ 的稳健性优于 $\bar{X}_n$.

现在从另一个意义来考察一下 $\bar{X}_n$ 与 $\tilde{X}_n$ 的稳健性——即统计量 $\bar{X}_n$ 和 $\tilde{X}_n$ 对样本中个别数据的激烈变化的敏感性. 也可以这样看: 原来在样本 $X_1, \dots, X_{n-1}$ 的基础上已算得 $\bar{X}$ 和 $\tilde{X}$ 的值分别为 $\bar{X}_{n-1}$ 及 $\tilde{X}_{n-1}$. 现在增加了一个观察值 $X_n = x$. 则 $\bar{X}$ 的新值为 $\bar{X}_n = \frac{n-1}{n}\bar{X}_{n-1} + \frac{1}{n}x$. 而定义

$$\text{SC}_X(X_1, \dots, X_{n-1}; x) = n[\bar{X}_n - \bar{X}_{n-1}] = x - \bar{X}_{n-1} \quad (6.7)$$

对 $\tilde{X}$ 作类似的计算. 为确定计, 设 n 为偶数 $2m$ (n 的奇数的情况相似), 并以 $X_{(1)} \leq \cdots \leq X_{(n-1)}$ 记样本 $(X_1, \cdots, X_{n-1})$ 的次序统计量, 有

$$SC_{\tilde{X}}(X_1, \cdots, X_{n-1}; x) = n[\tilde{X}_n - \tilde{X}_{n-1}]$$

$$= \begin{cases} -\frac{n}{2}[X_{(m)} - X_{(m-1)}], & x < X_{(m-1)}; \\ \frac{n}{2}[x - X_{(m)}], & X_{(m-1)} \leq x \leq X_{(m+1)}; \\ \frac{n}{2}[X_{(m+1)} - X_{(m)}], & x > X_{(m+1)}. \end{cases} \quad (6.8)$$

(6.7) 式与 (6.8) 式作为 x 的函数, 分别称为 $\bar{X}$ 和 $\tilde{X}$ 的“敏感曲线”, 它反映了单个观察值对统计量值影响的大小. 由 (6.7) 式看出, $\bar{X}$ 的敏感曲线是无界的, 就是说, 个别受到严重过失误差影响的观察值可以对 $\bar{X}$ 的取值造成破坏性的影响. 而由 (6.8) 式知, $\tilde{X}$ 的敏感曲线为有界的, 因而单个观察值的异常对 $\tilde{X}$ 的影响是有限的. 因此 $\tilde{X}$ 的稳健性比 $\bar{X}$ 好.

注 6.1 采取上面的叙述方式, 是为了引进敏感曲线这个概念, 实际上, 单个观察值的变动对 $\tilde{X}$ 及 $\bar{X}$ 的影响几乎是一目了然的.

6.1.3 若干进一步的说明

1. 在 6.1.1 小节中, 曾把统计方法的稳健性理解为其性能对模型的微小变化不敏感. 但是一个统计方法如果只具备这种特点, 并不一定有用. 例如不管样本如何, 总是用一个固定的常数去估计某参数. 稳健则有之, 无用也显然. 因此, 稳健统计所追求的并非只具有稳健性的统计方法, 而还要有其他良好的性能. Huber 在其专著^[94]中提出一种见解: 认为稳健统计的目标是寻求有如下性质的统计方法:

(i) 在实际模型与所假定的模型符合时, 该方法具有良好的性能, 但不必在某种标准下为最优的;

(ii) 在实际模型与所假定的模型有少许差异时, 其性能所受到的影响也较小;

(iii) 在实际模型与假定模型有严重偏离时, 其性能仍“过得去”, 或者说, 不致使该方法变得无用甚至引入歧途. (i)、(ii) 两条的背景是: 有一定的理由假定模型有某种形状(如正态), 且即使实际情况与之有偏差, 程度也不会大. 要求所用的统计方法在这种情况下保持较良好的性能, 则一方面既有了稳健性, 另一方

面也有用.第(iii)条则是要求该方法有较强的“抗灾力”.做到这些要求所可能付出的代价是:当实际模型与假定模型符合时,方法不必具有最优性.

从实用的观点看,这三条要求看来是合理和适度的.不过也要注意,它们仍只是些含义不甚明确的说法.在个别情况下(例如参看文献[95]中第四章)可以把问题提成严密的数学形式并作出相应的解.但因所使用的最优性准则的局限性,这类解的意义仍是有限的.

一个理论模型通常包含多方面的假定,如总体分布的形式、样本的独立性、以至参数的先验分布的形式等等,在目前,稳健统计主要还只限于针对总体分布的形式.

2. 稳健性在很大程度上只有相对的意义,以前面的例子来说:相对于 $\bar{X}$ 而言, $\tilde{X}$ 有较好的稳健性,但不可能找到“最稳健的估计”之类的东西.而且所谓稳健性的比较,也往往是在某种范围和准则下进行的.如在前例中,对正态模型的偏离只考虑(6.1)式的形式.在实用问题中,其他情况也有可能.所采取的准则是极限分布的方差比.当样本大小不大时,这种准则的合理性是可以讨论的.

3. 和非参数统计的关系问题.

(i) 前已提到,Huber 认为稳健统计不能算是非参数统计的一部分.这个论点对于把“稳健性”和“非参数”这两个概念区分开来是有益的,而且在一定程度上无疑是正确的.以前例来说,如果局限在分布族(6.1)内考虑问题,则因该分布族是一个典型的参数族,问题无疑属于参数统计的范围.

(ii) 但是在很多情况下,稳健统计中考虑模型采取下面的形式:有一个参数性的分布族 $\mathcal{F}_0$,但可能的分布不必一定在 $\mathcal{F}_0$ 内,而可以是邻近的某一分布.所以在一定意义下与 $\mathcal{F}_0$ 中的分布为“邻近”的分布构成一个分布族 $\mathcal{F}$.后者是问题中的分布族.由于 $\mathcal{F}$ 一般是非参数性的分布族,把与它有关的统计问题看成非参数的,也是合理的.

(iii) 在文献中,学者们对“稳健”一词有种种的说法.有一种提法把统计方法的稳健性解释为在几种选定的分布族内都具有较高的绝对或相对效率.这种分布族本身就可能是非参数性的,在更多的情况下,适合这种要求的统计方法往往只可能是非参数性的.以估计对称分布的对称中心的问题来说:用基于 Wilcoxon 符号秩和统计量的估计法(见 4.3 节)就是一个在广泛的分布族中都有良好的效率的方法,因而可以认为是一个稳健估计,这是一个典型的非参数方法.从这一点看,非参数统计与稳健性有密切联系,并在稳健性的研究中起很大的作用.

在有些情况下,人们使用“稳健性”一词时,不一定是把它理解为要具有某种

如 Huber 所提出的意义上的方法,而只是指某一特定性质有稳定性.例如一个检验的水平,不因总体分布与假定的分布有些差距而受到重大影响,等等.如果检验统计量在原假设下,在很一般的分布族内为“分布无关”的(参看导言),则必具有这一性质.尽管不能把“稳健性”与“分布无关”混为一谈,但忽视其间的联系也是不妥的.这是稳健性与非参数统计发生联系的一个方面.

(iv) 在提及了和稳健性与非参数的若干联系后,我们肯定,本章开始提到的 Huber 那个观点——即稳健统计不能算是非参数统计的一部分是正确的.首先,二者问题的提法和着重点不同.非参数统计问题对总体分布有很宽的假定.在稳健统计中,虽则对总全体一分布族的限制不像在典型的参数统计问题中那样明确,但是常将其限制在某个参数族的“邻域”内,限制性比非参数统计为大.其次,许多非参数方法确有不同程度的稳健性,但并非所有的非参数方法都有稳健性.例如设 $X_1, \dots, X_n \sim F \in \mathcal{F}$, $\mathcal{F}$ 为一切满足条件 $\int_{-\infty}^{\infty} |x| dF(x)$ 的分布族,要估计 $\theta(F) = \int_{-\infty}^{\infty} x dF(x)$, 样本均值 $\bar{X}$ 是一个可用的估计.由于 $\mathcal{F}$ 是一个非参数族,在这个场合下,有理由把 $\bar{X}$ 看成是一种非参数方法.但一般认为 $\bar{X}$ 这个估计的稳健性并不好.

4. 稳健性要概念的由来虽可追溯到 19 世纪初,有些稳健性较好的方法,如切尾均值等,其应用也较早,不过,可以说到 20 世纪 20 年代,这个概念才开始受到较大的重视.由于这个概念在数理统计中多少是属于“上层建筑”的东西,在 20 世纪前半期(世界大战结束前)它未能得到充分的发展,是可以理解的.1960 年,稳健统计的奠基者之一 Tukey 在其工作^[163]中把 Fisher 和 Eddington 在 20 世纪年代曾经争论过的一个著名问题^{[59], [64]}——即在估计正态分布的标准差时用样本标准差与用平均绝对偏差何者为优的问题,重新提出来,从稳健性的角度加以研究.结果表明:只要正态分布受到少许“污染”,则后一估计就优于前者,尽管前者(当总体分布确为正态时)在种种意义下有优良性.这个结果使学者们感到莫大的兴趣,因而促进了这方面的探讨.1964 年,Huber 发表了其著名工作^[93],在估计对称中心的重要情况下,对“正态污染模型”(比(6.1)更广的意义)首次作出了 Minimax 型稳健解的严格定量的理论.这项开创性的工作使稳健理论进入了一个活跃发展的时期,到 1980 年为止的工作已基本上总在 Huber 专著^[95]中.这个时期另一项值得一提的是 Andrews 等工作^[32],其中对于对称中心的多种重要的稳健估计作了详尽的模拟研究.

6.2 稳健性概念的数学描述

本节的目的是在前节的基础上对与稳健性有关的若干基本概念作较严格的数学描述.大体上说,就是把前节讲述的思想加以严格化和定量化.不过,应指出的是:稳健性这个概念一般性地说起来容易,但不少内容难于用有效而严格的方式加以具体化.这与其发展历史尚短是有关的.

6.2.1 分布函数的距离

如前所述,稳健性考虑的是:当实际模型的分布与理论模型的分布有少许差异时,统计方法的性能受到的影响是怎样的.分布之间的差异可以用适当的距离去刻画:当分布的距离大(小)时,其差异就大(小).在文献中引进了若干种分布距离的概念.例如 Колмогоров 距离 $\rho(F, G) = \sup_x |F(x) - G(x)|$;此外还有 Levy 距离、Прохонов 距离等.在本章中只用到 Levy 距离.关于分布距离的详细讨论可参看文献[95]中第二章.

定义 6.1 设 F 和 G 都是一维分布函数,则

$$d(F, G) = \inf\{\epsilon; \epsilon > 0; \text{对一切 } x \text{ 有 } F(x - \epsilon) - \epsilon \leq G(x) \leq F(x + \epsilon) + \epsilon\}. \quad (6.9)$$

Levy 距离有下述定理中所表述的基本性质:

定理 6.1 以 $\mathfrak{M}$ 记一切一维概率分布所构成的类,则定义在 $\mathfrak{M} \times \mathfrak{M}$ 上的函数 $d(F, G)$ 满足距离空间的三条公理,且

$$d(F_n, F) \rightarrow 0 \Leftrightarrow F_n \xrightarrow{\mathcal{L}} F. \quad (6.10)$$

(我们回忆: $F_n \xrightarrow{\mathcal{L}} F$ 的意思是:对 F 的任一连续点 x , 有 $\lim_{n \rightarrow \infty} F_n(x) = F(x)$. 在文献中常称这为“ F_n 弱收敛于 F ”. (6.10) 式把这个收敛性距离化了.)

定理的证明 首先,若 $F = G$,则由 (6.9) 式显然有 $d(F, G) = 0$;反过来,若 $d(F, G) = 0$,则对任给的 $\epsilon > 0$,有

$$F(x - \epsilon) - \epsilon \leq G(x) \leq F(x + \epsilon) + \epsilon.$$

若 x 是 F 的连续点,则令 $\epsilon \downarrow 0$,得 $F(x) = G(x)$.由此即得 $F = G$.又若

$$F(x - \varepsilon) - \varepsilon \leq G(x) \leq F(x + \varepsilon) + \varepsilon,$$

则在左边一式中以 $x + \varepsilon$ 代 x ; 在右边一式中以 $x - \varepsilon$ 代 x , 得到

$$G(x - \varepsilon) - \varepsilon \leq F(x) \leq G(x + \varepsilon) + \varepsilon.$$

于是得 $d(G, F) = d(F, G)$. 最后, 若 F, G, H 为三个分布函数, 而 $\varepsilon_1 > 0, \varepsilon_2 > 0$, 使

$$F(x - \varepsilon_1) - \varepsilon_1 \leq G(x) \leq F(x + \varepsilon_1) + \varepsilon_1; \quad (6.11)$$

$$G(x - \varepsilon_2) - \varepsilon_2 \leq H(x) \leq G(x + \varepsilon_2) + \varepsilon_2. \quad (6.12)$$

在 (6.11) 式的右边一式中以 $x + \varepsilon_2$ 代 x , 并将所得的结果与 (6.12) 式的右边一式结合, 得

$$H(x) \leq F(x + \varepsilon_1 + \varepsilon_2) + \varepsilon_1 + \varepsilon_2.$$

类似地, 由 (6.11)、(6.12) 式左边的不等式得到

$$H(x) \geq F(x - \varepsilon_1 - \varepsilon_2) - \varepsilon_1 - \varepsilon_2.$$

由此不难推出

$$d(F, H) \leq d(F, G) + d(G, H).$$

这证明了 $d(F, G)$ 满足距离三公里.

往下证明 (6.10) 式: 设 $d(F_n, F) \rightarrow 0$. 给定 $\varepsilon > 0$ 及 F 的连续点 x_0 , 找 $\eta (0 < \eta < \varepsilon/2)$, 使 $|F(x_0 \pm \eta) - F(x_0)| < \varepsilon/2$. 求 $n_0 = n_0(\eta)$ 充分大, 使当 $n \geq n_0$ 时, 有 $d(F_n, F) < \eta$. 于是根据 (6.9) 式, 当 $n \geq n_0$ 时, 有

$$F(x_0 - \eta) - \eta \leq F_n(x_0) \leq F(x_0 + \eta) + \eta.$$

因此, 当 $n \geq n_0$ 时, 有

$$F_n(x_0) \geq F(x_0) - \frac{\varepsilon}{2} - \eta \geq F(x_0) - \varepsilon;$$

$$F_n(x_0) \leq F(x_0) + \frac{\varepsilon}{2} + \eta \leq F(x_0) + \varepsilon.$$

这证明了 $\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0)$. 因而证明了 $F_n \xrightarrow{\mathcal{L}} F$. 反过来, 设 $F_n \xrightarrow{\mathcal{L}} F$. 任给 $\varepsilon > 0$ 取 F 的连续点 $x_0 < x_1 < \cdots < x_m$, 使

$$F(x_0) < \varepsilon, F(x_m) > 1 - \varepsilon, x_i - x_{i-1} < \varepsilon, \quad i = 1, \cdots, m.$$

取 $N = N(\varepsilon)$ 充分大, 使当 $n \geq N$ 时, 有

$$|F_n(x_i) - F(x_i)| < \varepsilon, \quad i = 0, 1, \cdots, m.$$

现任取 x , 若对某个 i 有 $x_{i-1} < x \leq x_i$, 则

$$F_n(x) \leq F_n(x_i) \leq F(x_i) + \varepsilon \leq F(x + \varepsilon) + \varepsilon;$$

$$F_n(x) \geq F_n(x_{i-1}) \geq F(x_{i-1}) - \varepsilon \geq F(x - \varepsilon) - \varepsilon.$$

不难看出,当 $x \leq x_0$ 及 $x \geq x_m$ 时,此两式也成立.因而证明了

$$\text{当 } n \geq N(\varepsilon) \text{ 时, } d(F_n, F) \leq \varepsilon.$$

即 $d(F_n, F) \rightarrow 0$, 于是完成了定理的证明.

6.2.2 稳健性的定性描述

一个统计方法的性能取决于总体分布及该方法所使用的统计量. 总体分布所起的作用在于它决定统计量的分布.

考虑从总体分布 F 中抽出的 iid. 样本 $X_1, X_2, \dots, X_n, F$ 属于一定的分布族 $\mathcal{F}$. 为解决某一统计问题使用了统计量 $T_n = T_n(X_1, \dots, X_n)$, 记 $T = \{T_n\}$. 在许多情况下, 有一种自然的形式把对不同样本大小的 T_n 联系起来, 因而可以抽象地说“统计量 T ”. 例如人们提到样本均值 $\bar{X}$, 指的是当样本大小为 n 时的 $(X_1 + \dots + X_n)/n$. 或者说 $\bar{X} = \{\bar{X}_n\}$.

统计量 T 的性质取决于它的分布. 把总体的分布为 F_0 时, T 的分布记为 $\mathcal{L}_{F_0}(T) = \{\mathcal{L}_{F_0}(T_n)\}$. 如果事实上的总体分布为 F , 它与原来假定的总体分布 F_0 有些差异, 则稳健性要求: 当 F 与 F_0 的距离不大时, $\mathcal{L}_F(T)$ 与 $\mathcal{L}_{F_0}(T)$ 的距离也不大. 根据这一想法, Hampel 于 1971 年在文献[81]中提出了关于 T 的稳健性的一个正式定义如下:

定义 6.2 设 d_* 是 $\mathcal{M}$ 上的一个距离, 满足条件

$$G_n \xrightarrow{\mathcal{L}} G \Leftrightarrow d_*(G_n, G) \rightarrow 0. \quad (6.13)$$

设 $F_0 \in \mathcal{M}$. 若对任何的 $\varepsilon > 0$, 存在 $\delta > 0$ 和自然数 N , 使

$$\{n \geq N, d_*(F_0, F) \leq \delta\} \Rightarrow d_*(\mathcal{L}_{F_0}(T_n), \mathcal{L}_F(T_n)) \leq \varepsilon. \quad (6.14)$$

则称统计量 $T = \{T_n\}$ 在总体分布 F_0 处为稳健的.

本定义中值得注意之处是: (6.14) 式右边要在 F_0 的邻域 $\{F: d_*(F_0, F) \leq \delta\}$ 内一致成立. 如果一个统计量 T 有本定义之下的稳健性, 则当总体分布有微小扰动而样本大小 n 足够大时, 统计量 T_n 的分布也只受到微小扰动. 因此, 本定义属于大样本类型. 在样本大小 n 固定时, 可以把 (6.14) 式左边的条件中的 “ $n \geq N$ ” 去掉, 就可以定义 T_n 的稳健性. 另外, 由于本定义规定的稳健性是通过一个(等度)连续性的关系刻画的, 而没有引进什么衡量稳健性的数量指标, 因而这定义只是定性的. 要注意: 本定义中并未指定任何特定的距离. 但由定理 6.1 知, Levy 距离满足本定义中对于距离 d^* 的要求.

因为 $X_1, \dots, X_n$ 是 iid. 样本, 其次序统计量 $(X_{(1)}, \dots, X_{(n)})$ 是充分的. 故一

般说来,所考虑的统计量 $T_n(X_1, \dots, X_n)$ 只依赖于 $(X_{(1)}, \dots, X_{(n)})$. 换句话说,只依赖于样本 $X_1, \dots, X_n$ 所决定的经验分布函数 F_n . 这样,可以把统计量 T_n 表为 F_n 的某个泛函:

$$T_n = T(F_n). \quad (6.15)$$

当我们把 T_n 写为泛函形式(6.15)时,一般地总是这样选定 T 的形式(在有的情况下, T 有唯一性而不容许自由选择;在有的情况下,则有一定的挑选余地),使 T 的定义域不限于经验分布类,而是在一更广的分布类(包含经验分布,但不必是一切分布的类 $\mathfrak{M}$) 上有意义. 例如 T_n 为样本均值 $\frac{1}{n} \sum_{i=1}^n X_i$. 则 T_n 可写为

$$T_n = T(F_n) = \int_{-\infty}^{+\infty} x dF_n(x). \quad (6.16)$$

这可以扩展到分布类 $\mathfrak{M}_1 \left\{ F: \int_{-\infty}^{+\infty} |x| dF(x) < \infty \right\}$. 对这种泛函 T , 可以定义其弱连续性如下: 称 T 在其定义域内的一点 F_0 处弱连续, 若对任一分布序列 $\{G_n\}$, 当 $G_n \xrightarrow{\mathcal{L}} F_0$ 时, 有 $T(G_n) \rightarrow T(F_0)$ (当 T 的定义域不为 $\mathfrak{M}$ 时, 自然要限制 G_n 属于 T 的定义域). 这显然与下述定义等价: 设 d_* 为一满足条件(6.13)的距离. 若对任给的 $\epsilon > 0$ 存在 $\delta > 0$, 使当 $d_*(F, F_0) \leq \delta$ 时, 有 $|T(F) - T(F_0)| \leq \epsilon$, 则称 T 在 F_0 处弱连续.

在估计问题中, 被估计的量表为总体分布的一个泛函 $T(F)$. 早在 Fisher 文献[65]中就提出了一般性的估计方法, 即用 $T(F_n)$ 估计 $T(F)$, 其中 F_n 为样本 $X_1, \dots, X_n$ 的经验分布. $T(F_n)$ 依赖于样本 $X_1, \dots, X_n$, 是一个随机变量. 若当 $n \rightarrow \infty$ 时,

$$T(F_n) \xrightarrow{F} T(F), \quad \text{或} \quad T(F_n) \rightarrow T(F) \text{ a.s. } F,$$

则分别称估计量 $T(F_n)$ 在总体分布 F 处为弱相合或强相合. 若 T 和 F 处弱连续, 则由 Гливленко 定理可知 $T(F_n)$ 在 F 处为 $T(F)$ 的强相合估计. 但此命题的逆不真. 例如对定义在 $\mathfrak{M}_1$ (见(6.16)式下面) 上的泛函 $T(F) = \int_{-\infty}^{+\infty} x dF(x)$ 而言, (6.16) 式在 $\mathfrak{M}_1$ 中的每个 F 处为强相合, 但不难证明: T 在 $\mathfrak{M}_1$ 上任一点 F 处都不是弱连续的 (建议读者自己作出这一简单事实的证明).

在作了这些准备后, 现在可以提出 Hampel 的下述结果, 它把稳健性与弱连续性联系了起来:

定理 6.2 设 d_* 是满足条件(6.13)的距离, 而统计量 $T_n = T_n(X_1, \dots,$

$X_n) = T(F_n)$ (F_n 如前, 是 $X_1, \dots, X_n$ 的经验分布) 在 F_0 某个按距离 d_* 决定的邻域中为弱相合, 即存在 $\delta > 0$, 使

$$d_*(F, F_0) \leq \delta \Rightarrow T(F_n) \xrightarrow{F} T(F). \quad (6.17)$$

则统计量 $T = \{T_n\}$ 按定义 6.2 在 F_0 处稳健的充要条件是: $T(F)$ 在 F_0 处为弱连续性.

由于条件 (6.17) 通常都满足, 故本定理实质上把稳健性归结为弱连续性.

证 先设 T 在 F_0 处弱连续, 有

$$d_*(\mathcal{L}_{F_0}(T_n), \mathcal{L}_F(T_n)) \leq d_*(\delta_0, \mathcal{L}_{F_0}(T_n)) + d_*(\delta_0, \mathcal{L}_F(T_n)).$$

此处 δ_0 记退化于一点 $T(F_0)$ 的概率分布. 由组合性假定知: 上式右边第一项当 $n \rightarrow \infty$ 时趋于 0. 故为证 $\{T_n\}$ 在 F_0 处的稳健性, 只需证明: 对任给的 $\epsilon > 0$, 存在 $\eta > 0$ 及 n_0 , 使当 $n \geq n_0$ 及 $d_*(F_0, F) \leq \eta$ 时, 有

$$d_*(\delta_0, \mathcal{L}_F(T_n)) \leq \epsilon. \quad (6.18)$$

为此只需证: 对任给 $\epsilon' > 0$, 存在 $\eta > 0$ 及 n_0 , 使当 $n \geq n_0$ 及 $d_*(F_0, F) \leq \eta$ 时, 有

$$P_F(|T(F_0) - T_n| \leq \epsilon') \geq 1 - \epsilon'. \quad (6.19)$$

事实上, 若 (6.19) 式已证, 以 G_n 记概率分布 $\mathcal{L}_F(T_n)$, 以 G 记概率分布 δ_0 , 则因

$$\{T(F_0) \leq x\} \subset \{T_n \leq x + \epsilon'\} \cup \{|T(F_0) - T_n| > \epsilon'\},$$

此式两边在总体分布 F 之下取概率, 得 $G(x) \leq G_n(x + \epsilon') + \epsilon'$ (据 (6.19) 式). 类似地证明 $G(x) \geq G_n(x - \epsilon') - \epsilon'$. 于是得 $d(G, G_n) \leq \epsilon'$, d 为 Levy 距离. 根据定理 6.1 及本定理的假定知: 距离 d 与 d_* 都满足条件 (6.13), 故可将 $\epsilon' > 0$ 取得充分小, 使 $d(G, G_n) \leq \epsilon' \Rightarrow d_*(G, G_n) \leq \epsilon$. 这就证明了 (6.18) 式.

现在证 (6.19) 式: 由于 T 在 F_0 处弱连续, 可找到 $\delta' > 0$, 使

$$d(F_0, F) \leq 2\delta' \Rightarrow |T(F_0) - T(F)| \leq \epsilon'.$$

注意到 $T_n = T(F_n)$, 由此可知: 为证 (6.19) 式只需证

$$P_F(d(F_0, F_n) \leq 2\delta') \geq 1 - \epsilon'. \quad (6.20)$$

(此处仍以 F_n 记 $X_1, \dots, X_n$ 的经验分布) 用弱大数律, 经过初等但较繁琐的论证, 能够证明: 可找到 n_0 , 使当 $n \geq n_0$ 时, 对一切 F , 一致地有

$$P_F(d(F, F_n) \leq \delta') \geq 1 - \epsilon'. \quad (6.21)$$

(这一细节的证明留给读者). 现取 $\eta > 0$ 充分小, 使 $d_*(F_0, F) \leq \eta \Rightarrow d(F_0, F) \leq \delta'$. 则由 (6.21) 式以及 $d(F_0, F_n) \leq d(F_0, F) + d(F, F_n)$ 可知, 当 $n \geq n_0$

及 $d_*(F_0, F) \leq \eta$ 时, 有(6.20) 式. 这即证明了定理的充分性部分.

下面证必要性: 设 $\{T_n\}$ 在 F_0 处稳健, 则对任给的 ϵ' , 存在 δ 及 n_0 , 使

$$\{n \geq n_0, d_*(F, F_0) \leq \delta\} \Rightarrow d_*(\mathcal{L}_F(T_n), \mathcal{L}_{F_0}(T_n)) \leq \epsilon'.$$

在此式中令 $n \rightarrow \infty$, 并注意定理中的相合性假设, 得

$$d_*(F, F_0) \leq \delta \Rightarrow d_*(\delta_{T(F)}, \delta_{T(F_0)}) \leq \epsilon' \quad (6.22)$$

此处 δ_a 为退化于 a 的概率分布. 既然 d_* 满足条件(6.13), 必有

$$d_*(\delta_{a_n}, \delta_a) \rightarrow 0 \iff |a_n - a| \rightarrow 0.$$

于是可找到 $\epsilon' > 0$ 充分小, 使

$$d_*(\delta_a, \delta_{T(F_0)}) \leq \epsilon' \Rightarrow |a - T(F_0)| \leq \epsilon. \quad (6.23)$$

此式与(6.22) 式结合, 即得 $d_*(F, F_0) \leq \delta \Rightarrow |T(F) - T(F_0)| \leq \epsilon$, 即 T 在 F_0 处弱连续. 从而证明了必要性. 定理证毕.

注 6.2 通常在一统计问题中, 所允许考虑的分佈类受到一定的限制, 这时, 须将定义 6.2 和本定理作明显的修改.

例 6.1 总体均值. 即在 $\mathfrak{M}_1$ 上定义的泛函 $T(F) = \int_{-\infty}^{\infty} x dF(x)$. 样本均值 $\bar{X}_n = T(F_n) = \int_{-\infty}^{\infty} x dF_n(x)$ 适合条件(6.17). 但在定理 6.2 的前面已提到: $T(F)$ 在 $\mathfrak{M}_1$ 的任一点处皆非弱连续, 故依定理 6.2, 样本均值 X_n 作为总体均值的估计, 在任一总体分佈处都没有稳健性.

例 6.2 在 $\mathfrak{M}_2 = \left\{F: \int_{(a,b]} dF(x) = F(b) - F(a) > 0\right\}$ 上定义泛函

$$T(F) = \int_{(a,b]} x dF(x) / \int_{(a,b]} dF(x).$$

此处 a, b 为两个已知数, $-\infty < a < b < \infty$. $T(F)$ 可用切尾均值

$$T(F_n) = \sum_{(i, a < X_i \leq b)} X_i / (X_1, \dots, X_n \text{ 落在 } (a, b] \text{ 内的个数})$$

去估计. 条件(6.17) 仍成立. 但 $T(F)$ 是否在 F 处为弱连续, 则取决于 a, b 是否都为 F 的连续点. 因此, 作为 $T(F)$ 的估计的 $T(F_n)$, 在某总体分佈 F_0 处是否有稳健性, 取决于 F_0 是否在 a, b 处连续. 若 F_0 是处处连续的分佈, 则这一点当然成立.

类似地, 定义在整个 $\mathfrak{M}$ 上的泛函

$$T(F) = aF(a) + b[1 - F(b)] + \int_{(a,b]} x dF(x)$$

(a, b 的意义同前) 可以用 Winsor 化均值

$$T(F_n) = \frac{1}{n}(n_1 a + n_2 b + \sum_{(i: a < x_i \leq b)} X_i)$$

去估计, 此处 n_1 和 n_2 分别是 $X_1, \dots, X_n$ 中 $\leq a$ 和 $> b$ 的个数. 与前例相似, 读者可以验证: 统计量 $T(F_n)$ 在 F_0 处为稳健的充要条件仍是 F 在 a, b 两点连续.

例 6.3 记

$$\mathfrak{M}_3 = \{F: F \text{ 为连续对称分布(对称中心 } \theta_F \text{ 与 } F \text{ 有关)}\}, \quad (6.24)$$

取定 $\alpha \in (0, 1/2)$, 以 $-\xi_{\alpha F}$ 记分布函数 $F(x + \theta_F)$ 的 α 分位点. 作两个分布函数 $\bar{F}$ 和 F^* 如下:

$$\bar{F}(x) = \begin{cases} 0, & x < \theta_F - \xi_{\alpha F}; \\ \frac{F(x) - \alpha}{1 - 2\alpha}, & |x - \theta_F| \leq \xi_{\alpha F}; \\ 1, & x > \theta_F + \xi_{\alpha F}. \end{cases} \quad (6.25)$$

$$F^*(x) = \begin{cases} 0, & x < \theta_F - \xi_{\alpha F}; \\ F(x), & \theta_F - \xi_{\alpha F} \leq x < \theta_F + \xi_{\alpha F}; \\ 1, & x \geq \theta_F + \xi_{\alpha F}. \end{cases} \quad (6.26)$$

则 θ_F 可以用两种方式表为 F 的泛函:

$$\theta_F = T^{(1)}(F) = \int_{-\infty}^{\infty} x d\bar{F}(x); \quad (6.27)$$

$$\theta_F = T^{(2)}(F) = \int_{-\infty}^{\infty} x dF^*(x). \quad (6.28)$$

相对于这两种表达形式, 可以作出 θ_F 的两个估计 $T^{(1)}(F_n)$ 和 $T^{(2)}(F_n)$, 它们分别是例 1.2 的切尾均值((1.66) 式) 及例 1.3 的 Winsor 化均值((1.75) 式). 由于泛函 $T^{(1)}$ 和 $T^{(2)}$ 在 $\mathfrak{M}_3$ 内每一点处弱连续知 $T^{(1)}(F_n)$ 在 $\mathfrak{M}_3$ 内每一点处都是稳健的.

例 6.4 记

$$\mathfrak{M}_4 = \{F: F \text{ 的中位数 } T^{(3)}(F) \text{ 唯一}\}, \quad (6.29)$$

泛函 $T^{(3)}(F)$ 定义在 $\mathfrak{M}_4$ 上. 另外, 若 F_n 为样本 $X_1, \dots, X_n$ 的经验分布, 则定义 $T^{(3)}(F_n) = X_1, \dots, X_n$ 的样本中位数((1.18) 式). 根据 1.4.1 小节, 对 $\mathfrak{M}_4$ 中的任一个 F , $T^{(3)}(F_n)$ 为 $T^{(3)}(F)$ 的相合估计. 容易证明作为定义在 $\mathfrak{M}_4$ 上的泛函, $T^{(3)}$ 在任一点 $F \in \mathfrak{M}_4$ 处为弱连续. 事实上, 设 $G_n \in \mathfrak{M}_4 (n = 1, 2, \dots)$, $G_n \xrightarrow{\mathcal{L}} F$, 并记 $\mu = T^{(3)}(F)$. 任给 $\epsilon > 0$, 找 F 的两个连续点 a, b , 使 $\mu - \epsilon < a < \mu < b < \mu + \epsilon$. 由 μ 的唯一性知 $F(a) < 1/2 < F(b)$. 记 $\eta = \min(1/2 - F(a), F(b) - 1/2)$. 找 n_0 充分大, 使当 $n \geq n_0$ 时, 有

$$|G_n(a) - F(a)| > \eta, \quad |G_n(b) - F(b)| < \eta.$$

则当 $n \geq n_0$ 时, 有 $G_n(a) < 1/2 < G_n(b)$. 由此知当 $n \geq n_0$ 时, 有 $T^{(3)}(G_n) \in [a, b]$, 因而 $|T^{(3)}(G_n) - \mu| < \varepsilon$. 于是证明了 $\lim_{n \rightarrow \infty} T^{(3)}(G_n) = \mu = T^{(3)}(F)$, 即 $T^{(3)}$ 在 F 处为弱连续. 据定理 6.2 知, 样本中位数 $T^{(3)}(F_n)$ 作为总体中位数 $T^{(3)}(F)$ 的估计在 $\mathfrak{M}_4$ 的任一点处都是稳健的.

结合以上诸例可以引出一个重要思想, 为此, 引进分布类 $\mathfrak{M}_5$ 如下:

$$\mathfrak{M}_5 = \mathfrak{M}_1 \cap \mathfrak{M}_3 \cap \mathfrak{M}_4. \quad (6.30)$$

则当 $F \in \mathfrak{M}_5$ 时, 其对称中心 θ_F 可以用好几种方式表为 F 的泛函即期望值 $T(F) = \int_{-\infty}^{\infty} x dF(x)$; 由 (6.27) 式和 (6.28) 式定义的 $T^{(1)}(F)$ 和 $T^{(2)}(F)$; 例 6.4 中的 $T^{(3)}(F)$. 按这四种表达法, 可作出 θ_F 的四个不同的估计: $T(F_n)$ 即样本均值; $T^{(1)}(F_n)$ 即切尾均值; $T^{(2)}(F_n)$ 即 Winsor 化均值; $T^{(3)}(F_n)$ 即样本中位数. 根据以上各例知: 除第一个外, 其余都为稳健的. 由此看出: 同一个量 (在此即分布的对称中心) 的若干个从直观上看来同为合理和可行的估计, 确实可能有的为稳健, 有的不为稳健. 而且要找其稳健估计, 往往归结为要找到该量的某种“稳健表达方式”, 在此 $T^{(i)}(F) (i = 1, 2, 3)$. 从定义 6.2 的角度对这三者已不能再加优劣之分了 (即不能说何者“更稳健”一些). 要作这种讨论, 还须引进关于稳健性的某种定量的指标.

6.2.3 崩溃点 (breakdown point)

稳健性并不是一个在任何场合下都可以按人们的意志而获得的性质. 换句话说, 统计问题本身对所能获致的稳健性的程度施加了不可逾越的限制. 这一点从下面的简单分析即可看出来.

仍设 $X_1, \dots, X_n \sim F \in \mathcal{F}$. $T(F)$ 为定义在 $\mathcal{F}$ 上的泛函. 统计问题是由样本 $X_1, \dots, X_n$ 估计 $T(F)$. 设 $F_0 \in \mathcal{F}$, 而 T 在 F_0 的领域内变化很剧烈. 就是说, 尽管 F 与 F_0 的距离很小, 但 $T(F)$ 与 $T(F_0)$ 的差距却很大. 设 T_n 为 $T(F)$ 的一估计量. 若要求它在 F_0 处有稳健性, 则当真实的总体分布为 F_0 , 而由于部分异常值的出现使样本 $X_1, \dots, X_n$ 所来自的总体的分布实际上为 F 时, T_n 仍应较好地估计 $T(F_0)$. 可是, 由于 $T(F_0)$ 与 $T(F)$ 差别很大, 这样一来, 当总体分布为 F 而样本无异常值时, T_n 将与 $T(F_0)$ 有很大差距, 而不能作为 $T(F_0)$ 的估计. 可见, 如果坚持下述合理要求“在样本正常的条件下, 对一切 $F \in \mathcal{F}$, T_n 较好地估计了 $T(F_0)$ ”, 则不能期望 T_n 有多大程度的稳定性. 也许有可能把上述要求放松一

些,而使 T_n 在某个指定的 F_0 的邻近有较好的稳健性.崩溃点的概念从一个角度上对上述想法作了定量的刻画.

设 F_0 为一分布.设对任给的 $\varepsilon \in (0, 1]$, 给定了某个包含 F_0 的分布集 $\mathcal{P}_\varepsilon$, 称为 F_0 的“ ε 邻域”. $\mathcal{P}_\varepsilon$ 的具体形式可根据需要和方便选定,但要满足条件

$$\varepsilon_1 < \varepsilon_2 \Rightarrow \mathcal{P}_{\varepsilon_1} \subset \mathcal{P}_{\varepsilon_2} \quad (6.31)$$

且 $\mathcal{P}_1$ 一般就是问题中所考虑的所有分布的类,例如全体分布构成的类 $\mathcal{M}$. 适合条件(6.31)的两个重要特例是

$$\mathcal{P}_\varepsilon' = \{F; d(F, F_0) \leq \varepsilon\}, d \text{ 为 Levy 距离}; \quad (6.32)$$

$$\mathcal{P}_\varepsilon'' = \{F; F = (1 - \varepsilon')F_0 + \varepsilon'H, H \in \mathcal{M}^*, 0 \leq \varepsilon' \leq \varepsilon\}. \quad (6.33)$$

其中 $\mathcal{M}^*$ 是某一选定的分类^①, 例如 $\mathcal{M}, \mathcal{M}_1$ 等. $\mathcal{P}_\varepsilon''$ 称为 F_0 的“ ε 污染邻域”, 它反映这样的情况: 总体的真实分布为 F_0 , 但在抽样时有 $100\varepsilon\%$ 的样本受到“污染”, 它们实际上是来自具分布 H 的总体, 因此, 综观整个样本, 可以看成是抽自具分布 $F = (1 - \varepsilon)F_0 + \varepsilon H$ 的总体. 由于这个解释, $\mathcal{P}_\varepsilon''$ 这种邻域的处理联系于样本异常值的稳健性问题中有重要的意义. 易见, 不论 $\mathcal{M}^*$ 如何取, 总有 $\mathcal{P}_\varepsilon'' \subset \mathcal{P}_\varepsilon'$.

泛函 $T(F)$ 在 $\mathcal{P}_\varepsilon$ 上的变化幅度可以用

$$b(\varepsilon) = b(\varepsilon, F_0, T) = \sup\{|T(F) - T(F_0)|; F \in \mathcal{P}_\varepsilon\}$$

来刻画. 显然, 若 $0 < \varepsilon_1 < \varepsilon_2 < 1$, 则 $0 \leq b(\varepsilon_1) \leq b(\varepsilon_2) \leq b(1)$. 在不少情况下 $b(1) = \infty$, 但不必如此, 有时对某个 $\varepsilon \in (0, 1)$ 即已有 $b(\varepsilon) = b(1)$. 这可以说成是 $T(F)$ 在 F_0 的 ε 邻域内已“失去控制”, 或者说产生“崩溃”. 发生这种情况的 ε 愈小, 表明 $T(F)$ 在 F_0 的变化愈剧烈, 因而对 $T(F)$ 的估计而言, 在 F_0 处的稳健性愈难于获得. 根据这一分析, 引进崩溃点的定义如下:

定义 6.3 称

$$\varepsilon^* = \varepsilon^*(F_0, T) = \inf\{\varepsilon; 0 < \varepsilon \leq 1, b(\varepsilon) = b(1)\} \quad (6.34)$$

为泛函 T 相对于邻域 $\mathcal{P}_\varepsilon$ 在 F_0 处的崩溃点^②.

有的著作中把崩溃点定义为 $\sup\{\varepsilon; 0 < \varepsilon < 1, b(\varepsilon) < b(1)\}$. 这一定义的缺点在于: 可能根本不存在 $\varepsilon \in (0, 1)$ 使 $b(\varepsilon) < b(1)$. 易见: 若存在这种 ε , 则此定义为与(6.34)式一致.

在有些情况下, $\varepsilon^*(F_0, T)$ 不依赖于 F_0 . 这时 ε^* 就可简称为 T 的崩溃点.

① 通常, $F_0 \in \mathcal{M}^*$, 且 $\mathcal{M}$ 为凸集(即当 $F \in \mathcal{M}^*, G \in \mathcal{M}^*$ 而 $0 < \alpha < 1$ 时, 有 $\alpha F + (1 - \alpha)G \in \mathcal{M}^*$). 易见, 这时(6.33)式可写为 $\mathcal{P}_\varepsilon'' = \{F; F = (1 - \varepsilon)F_0 + \varepsilon H, H \in \mathcal{M}^*\}$.

② 注意: 按本定义决定的 ε^* 丝毫不涉及样本与统计量(另参看后文).

例 6.5 设 $T(F) = \int_{-\infty}^{\infty} x dF(x)$ 定义于 $\mathfrak{M}_1$, $F_0 \in \mathfrak{M}_1$, 选 $\mathcal{P}_\epsilon = \mathcal{P}_\epsilon''$, 其中 $\mathfrak{M}^* = \mathfrak{M}_1$. 则易见 $\epsilon^* = 0$. 若将 $\mathfrak{M}^*$ 取为

$$\left\{ F: a \leq \int_{-\infty}^{\infty} x dF(x) \leq b \right\}, \quad a, b \text{ 为有限实数, } a < b,$$

则 $\epsilon^* = 1$.

例 6.6 以 $\mathfrak{M}_0$ 记一切一维连续分布的类. 在 $\mathfrak{M}_0$ 上定义泛函 $T(F)$ 如下: 以 ξ_α 记 F 的 α 分位点. 取定 $\alpha \in (0, 1/2)$. 令

$$T(F) = \frac{1}{1-2\alpha} \int_{\xi_\alpha}^{\xi_{1-\alpha}} x dF(x), \quad (6.35)$$

选 $\mathcal{P}_\epsilon = \mathcal{P}_\epsilon''$, 其中 $\mathfrak{M}^* = \mathfrak{M}_0$. 不难证明 $\epsilon^*(F_0, T) = \alpha$ 对任何 $F_0 \in \mathfrak{M}_0$ 成立. 事实上, 若 $\epsilon \in (0, \alpha)$, 则 $b(\epsilon) < \infty$. 因为 $(1-\epsilon)F_0 + \epsilon H$ 的 α 分位点不小于 $l_1 = \inf \left\{ x: F_0(x) = \frac{1-\alpha}{1-\epsilon} \right\}$, 而其 $(1-\alpha)$ 分位点不大于 $l_2 = \sup \left\{ x: F_0(x) = \frac{1-\alpha}{1-\epsilon} \right\}$. 故

$$b(\epsilon) \leq |T(F_0)| + (|l_1| + |l_2|) < \infty.$$

另一方面, 若 $\epsilon \in (\alpha, 1/2)$, 取 H 为 $(n, n+1)$ 内的均匀分布. 记 $l = \inf \{x: F_0(x) = \alpha/(1-\epsilon)\}$, 则当 $n > l$ 时, $F = (1-\epsilon)F_0 + \epsilon H$ 的 α 分位点不小于 l , 而其 $(1-\epsilon)$ 分位点则不小于 n . 若 $l \geq 0$, 则 $T(F) \geq n(\epsilon - \alpha)$. 若 $l < 0$, 则 $T(F) \geq n(\epsilon - \alpha) - |l|$. 总之, 当 $n \rightarrow \infty$ 时, 有 $T(F) \rightarrow \infty$. 这证明了当 $\epsilon > \alpha$ 时, $b(\epsilon) = \infty$. 从而证明了 $\epsilon^*(F_0, T) = \alpha$.

例 6.7 设 $T(F)$ 定义于一切一维分布的类 $\mathfrak{M}$, $T(F) = F$ 的中位数区间的中点, 定交 $\mathcal{P}_\epsilon = \mathcal{P}_\epsilon''$, 其中 $\mathfrak{M}^* = \mathfrak{M}$. 则 $\epsilon^*(F_0, T) = 1/2$. 这事实的证明依据下述简单的断言: 若 $F(b) - F(a) > 1/2$, 则 F 的任一中位数必在 $[a, b]$ 内. 按此, 若 $\epsilon \in (0, 1/2)$, 则对任何一维分布 H 可以找到不依赖于 H 的 a, b , 使 $F(b) - F(a) > 1/2$, 其中 $F = (1-\epsilon)F_0 + \epsilon H$. 为此, 只需找 $a < b$, 使 $F_0(b) - F_0(a) > 1/2(1-\epsilon)$. 这证明了当 $\epsilon \in (0, 1/2)$ 时, $b(\epsilon) < \infty$. 反过来, 设 $\epsilon \in (1/2, 1)$, 以 H 记退化于 n 的分布, 则 $F = (1-\epsilon)F_0 + \epsilon H$ 的中位数为 n . 由此知当 $\epsilon \in (1/2, 1)$ 时, $b(\epsilon) = \infty$. 这即证明了上述断言.

例 6.6 的 $T(F)$ 可视为例 6.6 的 $T(F)$ 当 $\alpha \uparrow 1/2$ 的极限, 因此所得结论是在意料之中的.

以上崩溃点的概念是针对总体参数 $T(F)$ 来说的. 一般, 在有了样本 $X_1, \dots, X_n$ 以后用 $T(F_n)$ 去估计. 因此也常把上面定义的 $\epsilon^*(F_0, T)$ 称为

$T(F_n)$ 的(渐近)崩溃点. 更一般些, 统计量也不必一定通过 $T(F_n)$ 的形式与 $T(F)$ 联系. 设 $T_n = T_n(X_1, \dots, X_n)$ 为统计量. 若当 $n \rightarrow \infty$ 时, $T_n \xrightarrow{F} T(F)$, 即 T_n 为 $T(F)$ 的弱相合估计, 则据 $T(F)$ 按定义 6.3 算出的 $\epsilon^*(F_0, T)$ 可定义为统计量 T_n 在 F_0 处的(渐近)崩溃点. 因此, 从这个角度看, 崩溃点仍是一个大样本性质的概念.

6.2.4 影响函数 (Influence function)

Hampel 于 1974 年在文献[82] 中引进了下面的定义:

定义 6.4 设 $T(F)$ 为一泛函, 又对任何实数 x , 以 δ_x 记退化于点 x 的概率分布, 并记 $F_\epsilon = (1 - \epsilon)F + \epsilon\delta_x$ ($0 \leq \epsilon \leq 1$). 则当下述极限

$$IC(x, F, T) = \lim_{\epsilon \downarrow 0} \frac{1}{\epsilon} \{T(F_\epsilon) - T(F)\} = \left. \frac{d}{d\epsilon} T(F_\epsilon) \right|_{\epsilon=0} \quad (6.36)$$

存在时, 它称为泛函 T 当总体分布为 F 时的影响函数. 当 x 变化时, $IC(x, F, T)$ 的图像则称为影响曲线^①.

这个与样本毫无关系的概念可以通过在崩溃点的讨论中曾经用过的方式与统计量联系起来. 仍设 $X_1, \dots, X_n \sim F$, 而 F_n 为其经验分布. 用统计量 $T_n = T(F_n)$ 估计 $T(F)$. 通常 T_n 是 $T(F)$ 的相合估计, 就把由 (6.36) 式算出的 $IC(x, F, T)$ 定义为统计量 $\{T_n\}$ 的影响曲线. 更一般地, T_n 也不必有 $T(F_n)$ 的形式, 只要它是 $T(F)$ 的相合估计即可.

人们在文献中对影响曲线的意义作了如下的解释, 以表明这概念与统计量对样本中的异常值的敏感程度有关. 设样本中有 $100\epsilon\%$ 的异常值. 且为简单起见, 设这些异常值全是 x , 这时若真实的总体分布为 F , 则经过异常值“污染”的样本可认为是来自具分布 F_ϵ 的总体. 因此, $T_n = T(F_n)$ 将与 $T(F_\epsilon)$ 接近. 若 $T(F_\epsilon)$ 与 $T(F)$ 相差过多, 则 T_n 作为 $T(F)$ 的估计的性能将大受影响. 因此, $T(F_\epsilon)$ 在 $\epsilon = 0$ 处的变化速度与 T_n 的稳健性有了关系. 大体上, $IC(x, F, T)$ 反映了当样本大小很大时, 每一单位的取值为 x 的异常值对统计量 $T_n = T(F_n)$ 的影响程度. $|IC(x, F, T)|$ 愈小, 统计量对异常值愈不敏感. 如果一个统计量的影响函数是无界的, 则异常值就可能对它产生严重的后果.

影响函数绝对值的上界

① 参看定义 6.3 的注.

$$\gamma = \sup_x |IC(x, F, T)| \quad (6.37)$$

称为 T 的“过失误差敏感性”(gross error sensitivity).

例 6.8 $T_n = T(F_n) =$ 样本均值 $\bar{X}_n$, $T(F) = \int_{-\infty}^{\infty} t dF(t)$. 容易算出

$$IC(x, F, T) = x - \int_{-\infty}^{\infty} t dF(t), \quad \gamma = \infty. \quad (6.38)$$

影响曲线是无界的,反映了样本均值对异常值的存在很敏感这一事实.

例 6.9 $T_n = X_1, \dots, X_n$ 的样本中位数, 设总体分布 F 的中位数唯一, 则与 T_n 相应的泛函为 $T(F) = F$ 的中位数 $= F^{-1}(1/2)$ (定义见定理 1.7, 3°). 为求其影响曲线, 设 F 有密度 f , 并且 f 在点 $F^{-1}(1/2)$ 处连续, $f(F^{-1}(1/2)) > 0$. 这时易见: 若 $x \neq F^{-1}(1/2)$, 且 $\epsilon > 0$ 充分小, 则 $F_\epsilon = (1 - \epsilon)F + \epsilon\delta_x$ 在点 $F_\epsilon^{-1}(1/2)$ 处连续 (用 $\delta_x(\cdot)$ 记概率分布 δ_x 的分布函数), 因而有

$$\frac{1}{2} = F_\epsilon \left(F_\epsilon^{-1} \left(\frac{1}{2} \right) \right) = (1 - \epsilon) F \left(F_\epsilon^{-1} \left(\frac{1}{2} \right) \right) + \epsilon \delta_x \left(F_\epsilon^{-1} \left(\frac{1}{2} \right) \right).$$

记 $\frac{d}{d\epsilon} T(F_\epsilon) |_{\epsilon=0}$ 为 $\dot{T}$, 将上式两端对 ϵ 求导数, 然后令 $\epsilon = 0$, 知当 $x \neq F^{-1}(1/2)$ 时, 有

$$0 = -F \left(F^{-1} \left(\frac{1}{2} \right) \right) + f \left(F^{-1} \left(\frac{1}{2} \right) \right) \dot{T} + \delta_x \left(F^{-1} \left(\frac{1}{2} \right) \right). \quad (6.39)$$

当 $x = F^{-1}(1/2)$ 而 $\epsilon > 0$ 时, 有

$$T(F_\epsilon) = F_\epsilon^{-1} \left(\frac{1}{2} \right) = F^{-1} \left(\frac{1}{2} \right) = T(F).$$

于是 $\dot{T} = 0$. 由此及 (6.39) 式得 $\{T_n\}$ 的影响曲线为

$$IC(x, F, T) = \begin{cases} - \left(2f \left(F^{-1} \left(\frac{1}{2} \right) \right) \right)^{-1}, & x < F^{-1} \left(\frac{1}{2} \right); \\ 0, & x = F^{-1} \left(\frac{1}{2} \right); \\ \left(2f \left(F^{-1} \left(\frac{1}{2} \right) \right) \right)^{-1}, & x > F^{-1} \left(\frac{1}{2} \right). \end{cases} \quad (6.40)$$

$\gamma = \left(2f \left(F^{-1} \left(\frac{1}{2} \right) \right) \right)^{-1}$ 为有界的, 意味着样本中位数对异常值的存在比较不敏感.

例 6.10 $T_n =$ 样本 $X_1, \dots, X_n$ 的 α 切尾均值 (定义见 (1.66) 式). 设总体分布 F 的 c 分位数为 ξ_c , 则与 T_n 相应的泛函 $T(F)$ 由 (6.35) 式给出. 用类似例 6.9

的方法可以得到:若 ξ_α 与 $\xi_{1-\alpha}$ 都唯一且 F 在这两个点连续,则 $\{T_n\}$ 的影响函数为

$$IC(x, F, T) = \begin{cases} \frac{1}{1-2\alpha}(\xi_\alpha - W(F)), & x < \xi_\alpha; \\ \frac{1}{1-2\alpha}(x - W(F)), & \xi_\alpha \leq x \leq \xi_{1-\alpha}; \\ \frac{1}{1-2\alpha}(\xi_{1-\alpha} - W(F)), & x > \xi_{1-\alpha}. \end{cases} \quad (6.41)$$

此处

$$W(F) = (1-2\alpha)T(F) + \alpha\xi_\alpha + \alpha\xi_{1-\alpha}. \quad (6.42)$$

例 6.11 T_n 样本 $X_1, \dots, X_n$ 的 α -Winsor 化均值(定义见(1.75)式). 设总体分布 F 有密度函数 f , f 在 ξ_α 和 $\xi_{1-\alpha}$ 处连续, 且 $f(\xi_\alpha) > 0, f(\xi_{1-\alpha}) > 0$. 与 T_n 相应的泛函为

$$T(F) = \alpha\xi_\alpha + \alpha\xi_{1-\alpha} + \int_{\xi_\alpha}^{\xi_{1-\alpha}} x dF(x) = W(F). \quad (6.43)$$

用类似于例 6.9 的方法可得 $\{T_n\}$ 的影响函数为

$$IC(x, F, T) = \begin{cases} \xi_\alpha - \frac{\alpha}{f(\xi_\alpha)} - C(F), & x < \xi_\alpha; \\ x - C(F), & \xi_\alpha \leq x \leq \xi_{1-\alpha}; \\ \xi_{1-\alpha} + \frac{\alpha}{f(\xi_{1-\alpha})} - C(F), & x > \xi_{1-\alpha}. \end{cases} \quad (6.44)$$

此处

$$C(F) = W(F) - \frac{\alpha^2}{f(\xi_\alpha)} - \frac{\alpha^2}{f(\xi_{1-\alpha})}.$$

以上两例的影响函数皆有界. 这显示了:就异常值的影响而言,切尾均值和 Winsor 化均值比样本均值都更不敏感. 此两例的推导可参看文献[95]的第三章.

6.3 位置参数的稳健估计

6.3.1 位置参数

定义 6.5 设 $\tilde{\mathfrak{M}}$ 是一个由某些一维分布构成的类, 满足条件

$$F(x) \in \widetilde{\mathfrak{M}} \Rightarrow F(x-a) \in \widetilde{\mathfrak{M}}, \quad \text{对任何实数 } a. \quad (6.45)$$

设 T 是定义在 $\widetilde{\mathfrak{M}}$ 上的一个泛函. 若 T 满足条件

$$T(F(x-a)) = T(F(x)) + a, \quad -\infty < a < \infty, \quad (6.46)$$

则称 $T(F)$ 为 F 的一个位置参数.

例如以 $\widetilde{\mathfrak{M}}$ 记一切其均值有限的一维分布类, 则 (6.45) 式成立. 而 $T(F(x)) = \int_{-\infty}^{\infty} x dF(x)$ 是 F 的一个位置参数. 又如以 $\widetilde{\mathfrak{M}}$ 记一切其中位数唯一的一维分布类, 则 (6.45) 式成立. 而

$$T(F(x)) = F^{-1}\left(\frac{1}{2}\right),$$

即 F 的中位数为 F 的一个位置参数.

位置参数有下面的解释: 不妨设想 $F(x)$ 已知, 但总体分布为 $F(x-\theta)$, 实参数 θ 的值未知, 若 T 为一位置参数, 则 $T(F(x-\theta))$ 与参数 θ 之间有一一对应的关系. 事实上, 根据 (6.46) 式, $T(F(x-\theta))$ 与 θ 之间只相差一个与 θ 无关的数 $T(F(x))$. 估计了 $T(F(x-\theta))$, 就等于估计了 θ . 从稳健性的观点可选择适当的 T , 使 $T(F)$ 有较高的崩溃点, 较平缓的影响曲线等. 从而提高位置参数估计的稳健性.

定义位置参数的一个一般方法如下: 设 $\psi(x)$ 是定义在 $(-\infty, \infty)$ 上的 (Borel 可测) 函数, 以 $\widetilde{\mathfrak{M}}$ 记一切具有下述性质的一维分布 $F(x)$ 的集:

1) 对任意的实数 t , 积分

$$\lambda(t, F) = \int_{-\infty}^{\infty} \psi(x-t) dF(x) \quad (6.47)$$

存在有限;

2) 方程

$$\lambda(t, F) = 0 \quad (6.48)$$

有唯一解, 记为 $T(F)$. 则易见 $\widetilde{\mathfrak{M}}$ 满足条件 (6.45), 而 $T(F)$ 满足条件 (6.46), 即为一位置参数. 例如若 $\psi(x) = x$, $\widetilde{\mathfrak{M}}$ 为一切其均值有限的分布的类, 而 $T(F) = \int_{-\infty}^{\infty} x dF(x)$; 又如, 设

$$\psi(x) = \begin{cases} -1, & x \leq 0; \\ 1, & x > 0. \end{cases} \quad (6.49)$$

则任一分布 F 满足条件 1). 若 F 的中位数唯一, 且 F 在该点处连续, 则条件 2) 也满足, 且 $T(F)$ 就是 F 的中位数.

这样定义的位置参数 $T(F)$ 有一良好的性质, 即它在一定条件下有强连续性. 如以下定理所示:

定理 6.3 设 $\psi(x)$ 在 $-\infty < x < \infty$ 非降有界, $G_0, G_1, G_2, \dots$ 为一串分布, 每一个满足上述条件 1) 和 2), 且当 $n \rightarrow \infty$ 时, $G_n \xrightarrow{\mathcal{L}} G_0$, 则 $\lim_{n \rightarrow \infty} T(G_n) = T(G_0)$.

证明此定理要用到下述引理:

引理 6.1 设 $\lambda_0(t), \lambda_2(t), \lambda_2(t), \dots$ 都是非增函数, t_0 是 $\lambda_0(t)$ 的唯一零点. t_n 为 $\lambda_n(t)$ 的零点 ($n = 1, 2, \dots$). 若 λ 的任意连续点 t 处有 $\lim_{n \rightarrow \infty} \lambda_n(t) = \lambda_0(t)$, 则 $\lim_{n \rightarrow \infty} t_n = t_0$.

证 由假定知存在 t' 和 t'' , 都是 λ 的连续点, 满足条件

$$t_0 - \varepsilon < t' < t < t'' < t_0 + \varepsilon,$$

且 $\lambda(t') > 0 > \lambda(t'')$, 由于当 $t = t'$ 和 t'' 时, $\lim_{n \rightarrow \infty} \lambda_n(t) = \lambda_0(t)$, 可知当 n 充分大时, 有 $\lambda_n(t') > 0 > \lambda_n(t'')$. 因 $\lambda_n(t)$ 非增, 故 $\lambda_n(t)$ 的零点 t_n 必在 (t', t'') 内, 即当 n 充分大时, 有 $|t_n - t_0| \leq \varepsilon$. 引理证毕.

转到定理 6.3 的证明. 记

$$\lambda_0(t) = \int_{-\infty}^{\infty} \psi(x-t) dG_0(x), \quad \lambda_n(t) = \int_{-\infty}^{\infty} \psi(x-t) dG_n(x).$$

则 λ_0, λ_n 都是非增函数, $\lambda_0(t)$ 有唯一零点. 现设 t_0 与 $\lambda_0(t)$ 的连续点.

下证 $\lambda_n(t_0) \rightarrow \lambda_0(t_0)$.

记 $\tilde{\lambda}_n(t) = \lambda_n(t) - \psi(-\infty)$ ($n = 0, 1, 2, \dots$), 则只需证

$$\tilde{\lambda}_n(t_0) \rightarrow \tilde{\lambda}_0(t_0).$$

不失普遍性, 可设 $\psi(\infty) - \psi(-\infty) = 1$ (否则, 以 $\psi(x)/[\psi(\infty) - \psi(-\infty)]$ 代替 ψ). 先补充假定 ψ 为右连续. 这时 ψ 为一概率分布, 而 $\tilde{\lambda}_0 = \psi * G_0, \tilde{\lambda}_n = \psi * G_n$ (* 表示卷积运算). 由特征函数的极限定理及 $G_n \xrightarrow{\mathcal{L}} G_0$, 即得 $\tilde{\lambda}_n \xrightarrow{\mathcal{L}} \tilde{\lambda}_0$. 再由 $\tilde{\lambda}_0$ 在 t_0 处连续知 $\tilde{\lambda}_n(t_0) \rightarrow \tilde{\lambda}_0(t_0)$.

对一般的 ψ , 记 $\psi_1(x) = \inf\{\psi(y): y > x\}$, 则 ψ 可表为 $\psi = \psi_1 + \psi_2$, 其中 ψ_1 右连续, 而 ψ_2 有如下的形式:

$$\psi_2(a_i) = b_i < 0 (i = 1, 2, \dots); \text{ 当 } x \in \{a_1, a_2, \dots\} \text{ 时, } \psi_2(x) = 0. \quad (6.50)$$

$$\lambda_i(t) = \lambda_i^{(1)}(t) + \lambda_i^{(2)}(t) = \sum_{j=1}^2 \int_{-\infty}^{\infty} \psi_j(x-t) dG_i(x), \quad i = 0, 1, 2, \dots.$$

易见 $\lambda_0^{(2)}(t)$ 的零点在 $(-\infty, \infty)$ 处处稠密, 而 $\lambda_0^{(1)}(t)$ 非增. 由此易知: 若 t_0 为

$\lambda_0(t)$ 的连续点, 则必有 $\lambda_0^{(2)}(t_0) = 0$, 且 t_0 为 $\lambda_0^{(1)}(t)$ 的连续点. 由已证部分, 得 $\lambda_n^{(1)}(t_0) \rightarrow \lambda_0^{(1)}(t_0)$. 又由 $\lambda_0^{(2)}(t_0) = 0$ 及 ψ_2 的形式 (6.50), 易见 $G_0(A) = 0$, $A = \{t_0 + a_i; i = 1, 2, \dots\}$. 由 $\sum_{i=1}^{\infty} |b_i| \leq 1$ 及 $G_n \xrightarrow{\mathcal{L}} G_0$ 经简单的论证表明 $\lambda_n^{(2)}(t_0) \rightarrow 0$. 于是

$$\lambda_n(t_0) = \lambda_n^{(1)}(t_0) + \lambda_n^{(2)}(t_0) \rightarrow \lambda_0^{(1)}(t_0) = \lambda_0(t_0).$$

从而引理 6.1 的条件全部满足. 由该引理得出定理 6.3 的结论. 定理证毕.

6.3.2 位置参数的三类估计

设 $X_1, \dots, X_n \sim F \in \mathcal{F}$, $T(F)$ 为位置参数. 为估计 $T(F)$ 文献中引进了三种类型的估计:

1. L 估计: 就是次序统计量的线性组合: 设 $X_{(1)} \leq \dots \leq X_{(n)}$ 为 $X_1, \dots, X_n$ 的次序统计量, $a_1, \dots, a_n$ 为常数, 则形如 $\sum_{i=1}^n a_i X_{(i)}$ 的估计量称为 L 估计. 在这种估计中, 最重要的代表是样本中位数、样本切尾均值及样本 Winsor 化均值. 前面曾多次提到过这几个估计, 并指明它们有较好的稳健性. 在第 1 章中曾证明过这种估计的渐近正态性.

2. R 估计: 就是基于样本的秩的估计, 在 4.3 节中, 曾就分布的对称中心 (它是一种特殊的位置参数) 的特例讨论过几个 R 型的估计. 当时曾指出这种估计能适用于广大范围的总体分布. 例如例 4.12 指出, 在例 4.10 中引进的基于 Wilcoxon 符号秩和统计量的估计与样本均值相比较, 其 ARE 不小于 0.864. 表明这一估计有良好的稳健性.

3. M 估计 (又称最大似然型估计):

定义 6.6 设 $\rho(x)$ 为一个定义在 $(-\infty, \infty)$ 的函数, 且存在 b , 使 ρ 在 $(-\infty, b]$ 非增, 在 $[b, \infty)$ 非降. 若统计量 $T_n = T_n(X_1, \dots, X_n)$ 满足条件

$$\sum_{i=1}^n \rho(X_i - T_n) = \min! \quad (6.51)$$

则称 T_n 为位置参数的一个 M 估计 (下文将解释这位位置参数怎样定义, 以及为何 T_n 可作为它的一个估计). 满足 (6.51) 的 T_n 不必唯一. 但若假定 ρ 在 $(-\infty, \infty)$ 处处连续, 则 T_n 必存在. 又若 ρ 为严格凸函数, 则 T_n 必为唯一的.

当 $\rho' = \psi$ 存在时, 可以把 (6.51) 式写为

$$\sum_{i=1}^n \psi(X_i - T_n) = 0. \quad (6.52)$$

只有在 ρ 为凸函数且 ρ' 在 $(-\infty, \infty)$ 处处存在时, 才可以断言 (6.51) 式与 (6.52) 式等价. 由于 (6.52) 式一般比 (6.51) 式容易处理, 所以在一些著作中径直取 (6.52) 式作为 M 估计的定义, 而不必依赖它与定义 6.6 的关系:

定义 6.6' 设 ψ 为 $(-\infty, \infty)$ 上的非降函数, $\psi(-\infty) < 0 < \psi(\infty)$. 若 T_n 满足 (6.52) 式, 则称 T_n 为位置参数的 M 估计.

导致 M 估计的想法及其名称的由来如下: 为估计总体均值 θ , 一个常用的估计是样本均值 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, 它是极值问题

$$\sum_{i=1}^n (X_i - a)^2 = \min! \quad (6.53)$$

的解. 这就是最小二乘法的最简形式, 相当于 (6.51) 式中的 $\rho(x) = x^2$. 因为当 $|X_i|$ 增加时, $(X_i - a)^2$ 变动很大. 因而极值问题 (6.53) 的解 $\bar{X}_n$ 受异常值的影响很大, 缺乏稳健性. 一个自然想到的改进办法, 是把 x^2 改为一个变化较缓的函数, 例如, 若取 $\rho(x) = |x|$, 则 (6.53) 式改为

$$\sum_{i=1}^n |X_i - a| = \min. \quad (6.54)$$

其解是样本中位数. 从以往的讨论知, 它的稳健性确比样本均值好. 把这种想法一般化, 即允许 ρ 在一定范围内可自由选择, 就得到一般的定义 6.6. 可以看出, M 估计的出发点原在于对付样本的异常值.

特别, 若总体有概率密度 $f(x - \theta)$ ($f(x)$ 为已知函数), 则取 $\psi(x) = \log f(x)$ (此系形式而言, 不管这样的 ψ 是否符合定义 6.6' 中的要求) 时, (6.52) 式的解就是 θ 的 MLE (最大似然估计). 因此, 由 (6.52) 式定义的估计可视为 MLE 的推广, 所以可称为最大似然型的.

在以上的叙述中要注意这样一个问题: 把 $\rho(x)$ 由 x^2 改为 $|x|$, 相当于从样本均值 $\bar{X}_n$ 转向于样本中位数 $\tilde{X}_n$. 它们分别估计总体的均值和中位数. 这二者虽都是位置参数, 但一般并不一致. 因此, 一般地说, 不同的 ρ , 或换句话说, 不同的 ψ 所决定的 M 估计是估计总体不同的位置参数, 而非同一位置参数的不同估计^①. 因此需要明确: 由 (6.52) 式决定的 M 估计可以合理地视为估计总体的什么样的位置参数? 答案是: 它是由方程 (自然, 要假定对任何 t , $\int_{-\infty}^{\infty} |\psi(x - t)| dF(x)$

① 在特殊情况下, 不同的 ρ 所决定的 M 估计可视为是估计同一位置参数. 如当总体分布为对称时, $\rho(x) = x^2$ 和 $|x|$ 所相应的 M 估计是估计同一位置参数——对称中心.

$< \infty$)

$$\lambda(t) = E_F \psi(X - t) = \int_{-\infty}^{\infty} \psi(x - t) dF(x) = 0 \quad (6.55)$$

的解所决定的位置参数. 这一点的根据在于下面的定理, 它断言在一定的条件下, 由(6.52)式所决定的 M 估计 T_n 是由(6.55)式的解所决定的位置参数 $T(F)$ 的相合估计.

定理 6.4 设方程(6.55)的解 $T(F) = t_0$ 唯一, 且对任何样本 $X_1, \dots, X_n$ 方程(6.52)式的解 T_n 存在(不必唯一), 以 $T_n = T_n(X_1, \dots, X_n)$ 记(6.52)式的任一解, 则当 $n \rightarrow \infty$ 时, 有

$$\lim_{n \rightarrow \infty} T_n = t_0, \text{ a.s. F.} \quad (6.56)$$

证 记

$$T_n^* = \sup \left\{ t : \sum_{i=1}^n \psi(X_i - t) > 0 \right\}, \quad T_n^{**} = \inf \left\{ t : \sum_{i=1}^n \psi(X_i - t) < 0 \right\}. \quad (6.57)$$

由 ψ 的非降性知 $T_n^* \leq T_n^{**}$, 且(6.52)式的任一解 T_n 都落在 T_n^* 与 T_n^{**} 之间, 有

$$\{T_n^* < t\} \subset \left\{ \sum_{i=1}^n \psi(X_i - t) \leq 0 \right\} \subset \{T_n^* \leq t\}; \quad (6.58)$$

$$\{T_n^{**} < t\} \subset \left\{ \sum_{i=1}^n \psi(X_i - t) < 0 \right\} \subset \{T_n^{**} \leq t\}. \quad (6.59)$$

由 ψ 的非降性及 t_0 为 $\lambda(t)$ 的唯一零点知: 对任何 $\varepsilon > 0$, 有 $\lambda(t_0 + \varepsilon) < 0 < \lambda(t_0 - \varepsilon)$. 依强大数律, 有

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \psi(X_i, t_0 \pm \varepsilon) = \lambda(t_0 \pm \varepsilon), \text{ a.s. F.}$$

取一串 $\varepsilon_k \downarrow 0$, 有

$$P_F \left\{ \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \psi(X_i, t_0 \pm \varepsilon_k) = \lambda(t_0 \pm \varepsilon_k), k = 1, 2, \dots \right\} = 1. \quad (6.60)$$

任意固定 k , 有 $\lambda(t_0 + \varepsilon_k) < 0 < \lambda(t_0 - \varepsilon_k)$. 故如点 $(X_1, X_2, \dots)$ 落在(6.60)式左边的事件内时, 当 n 充分大时, 有

$$\sum_{i=1}^n \psi(X_i, t_0 + \varepsilon_k) < 0 < \sum_{i=1}^n \psi(X_i, t_0 - \varepsilon_k). \quad (6.61)$$

但当(6.61)式发生时, 有

$$t_0 - \varepsilon_k \leq T_n^* \leq T_n^{**} \leq t_0 + \varepsilon_k.$$

因为这个情况对一切 k 成立,且前已指出(6.52)式的解 T_n 在 $[T_n^*, T_n^{**}]$ 内.因此以概率为1有下述事实成立:对任何 k ,当 n 充分大时,有 $|T_n - t_0| \leq \varepsilon_k$.再注意 $\varepsilon_k \rightarrow 0$,即完成了定理的证明.

根据这个定理,由方程(6.55)的解所确定的位置参数 $T(F)$ 所定出的崩溃点和影响函数等,也可解释为由方程(6.52)所确定的统计量 T_n 的崩溃点和影响函数.因此,为了得到位置参数的具有良好稳健性的估计,就要适当的选定 ψ ,以(6.55)式的解作为位置参数,并且(6.52)式的根去估计.

在本节以下几段中将集中讨论 M 估计的稳健性问题.由于篇幅的关系,关于 L 和 R 估计不再深入讨论了,有兴趣的读者可参看文献[95]的第三章.

6.3.3 M 估计的影响函数

以 $T(F)$ 记由(6.55)式的根所确定的位置参数,有

$$\int_{-\infty}^{\infty} \psi(x - F(F))dF(x) = 0. \quad (6.62)$$

以 δ_x 记退化于点 x 的分布, $F_\varepsilon = (1 - \varepsilon)F + \varepsilon\delta_x$. 以 F_ε 代替(6.62)式中的 F ,对 ε 求导后令 $\varepsilon = 0$,并记 $\dot{T} = \frac{d}{d\varepsilon}T(F_\varepsilon)|_{\varepsilon=0}$ 得

$$-\dot{T} \int_{-\infty}^{\infty} \psi'(x - T(F))dF + \int_{-\infty}^{\infty} \psi(x - T(F))dF + \psi(x - T(F)) = 0. \quad (6.63)$$

由 $T(F)$ 的定义知(6.63)式左边第二项为0.故得 $T(F)$ 的影响函数为

$$IC(x, F, T) = \frac{\psi(x - T(F))}{\int_{-\infty}^{\infty} \psi'(x - T(F))dF(x)}. \quad (6.64)$$

当然,公式(6.64)的导出需要一定条件,例如 $\psi'(x) = d\psi(x)/dx$ 存在、可以在积分 $\int_{-\infty}^{\infty} \psi(x - T)(F_\varepsilon)dF(x)$ 号下对 ε 求导等.

6.3.4 M 估计的崩溃点

在计算 M 估计的崩溃点之前需要一个预备事实:

引理 6.2 设 F 为一个分布函数, F_1, F_2 都是非降右连续函数,满足条件

$$\text{对一切 } x \in (-\infty, \infty), F_1(x) \geq F(x); F_1(\infty) = 1; \quad (6.65)$$

$$\text{对一切 } x \in (-\infty, \infty), F_2(x) \leq F(x); F_2(-\infty) = 0. \quad (6.66)$$

又设 $\psi(x)$ 为定义在 $(-\infty, \infty)$ 的非降有界函数, 则

$$\int_{-\infty}^{\infty} \psi(x) dF(x) \geq \int_{-\infty}^{\infty} \psi(x) dF_1(x) + \psi(-\infty) F_1(-\infty); \quad (6.67)$$

$$\int_{-\infty}^{\infty} \psi(x) dF(x) \leq \int_{-\infty}^{\infty} \psi(x) dF_2(x) + \psi(\infty) [1 - F_2(\infty)]. \quad (6.68)$$

证 只证(6.67)式; 因为(6.68)式的证明类似. 先设 $F_1(-\infty) = 0$ (即 F_1 也是分布函数), 则因 $F_1 \geq F$, 对任何 $t \in (0, 1)$, 有 $F_1^{-1}(t) \leq F^{-1}(t)$. 于是由 ψ 的非降性, 得

$$\begin{aligned} \int_{-\infty}^{\infty} \psi(x) dF(x) &= \int_0^1 \psi(F^{-1}(t)) dt \geq \int_0^1 \psi(F_1^{-1}(t)) dt \\ &= \int_{-\infty}^{\infty} \psi(x) dF_1(x). \end{aligned} \quad (6.69)$$

对一般情况, 取实数 a , 定义两个分布函数:

$$F^{(a)}(x) = \begin{cases} F(x), & x \geq a; \\ 0, & x < a. \end{cases} \quad F_1^{(a)}(x) = \begin{cases} F_1(x), & x \geq a; \\ 0, & x < a. \end{cases}$$

则对下切 x , 有 $F^{(a)}(x) \leq F_1^{(a)}(x)$. 由已证的(6.69)式, 有

$$\int_{-\infty}^{\infty} \psi(x) dF^{(a)}(x) \geq \int_{-\infty}^{\infty} \psi(x) dF_1^{(a)}(x),$$

即

$$\int_{[a, \infty)} \psi(x) dF(x) + \psi(a) F(a-) \geq \int_{[a, \infty)} \psi(x) dF_1(x) + \psi(a) F_1(a-). \quad (6.70)$$

令 $a \rightarrow -\infty$, 注意到 ψ 的有界性, $F(a-) \rightarrow 0$ 以及 $F_1(a-) \rightarrow F_1(-\infty)$, 由(6.70)式即得(6.67)式.

现设 ψ 为有界非降, $T(F)$ 为方程(6.55)的根. 现在来计算 $T(F)$ 的崩溃点. 将邻域选为(6.32)式, 即 Levy 距离 d 所确定的 $\mathcal{P}_\varepsilon'$. 取定分布 $F_0, \varepsilon \in (0, 1)$, 令

$$b_+(\varepsilon) = \sup\{T(F); d(F_0, F) \leq \varepsilon\}; \quad (6.71)$$

$$b_-(\varepsilon) = \inf\{T(F); d(F_0, F) \leq \varepsilon\}. \quad (6.72)$$

则易见

$$\begin{aligned} &\sup\{|T(F) - T(F_0)|; d(F_0, F) \leq \varepsilon\} \\ &= \max\{b_+(\varepsilon) - T(F_0), -b_-(\varepsilon) + T(F_0)\}. \end{aligned} \quad (6.73)$$

记 $\lambda(t, F) = \int \psi(x - t) dF(x)$, 以及

$$F_2(x) = \max\{0, F_0(x - \varepsilon) - \varepsilon\}.$$

则 $F_2(x)$ 为非降右连续, $F_2(-\infty) = 0, F_2(\infty) = 1 - \varepsilon$. 由 Levy 距离的定义知: 若 F 为一分布, 且 $d(F_0, F) \leq \varepsilon$, 则对一切 $x, F(x) \geq F_2(x)$, 于是由引理 6.2 的 (6.68) 式, 并以 x_0 记 F_0 的 ε 分位点, 得

$$\lambda(t, F) \leq \int_{x_0}^{\infty} \psi(x - t + \varepsilon) dF_0(x) + \varepsilon \psi(\infty) (= K(t)). \quad (6.74)$$

由 ψ 的单调知 $K(t)$ 非增. 又因 $\psi(-\infty) < 0 < \psi(\infty)$, 知 $K(-\infty) > 0$. 为简便计, 设 F_0 在 x_0 处连续, 则有 $K(\infty) = (1 - \varepsilon)\psi(-\infty) + \varepsilon\psi(\infty)$. 当 $\varepsilon < -\psi(\infty)/[\psi(\infty) - \psi(-\infty)]$ 时, $K(\infty) < 0$ 而 $K(t)$ 有零点. 以 t_0 记其最大零点. 则由 (6.74) 式知, 当 $d(F_0, F) \leq \varepsilon, T(F) \leq t_0$. 因而 $b_+(\varepsilon) < \infty$. 反之, 若 $\varepsilon > -\psi(-\infty)/[\psi(\infty) - \psi(-\infty)]$, 则存在 $\eta > 0$, 使 $K(t) \geq \eta$ 对一切 t 成立, 取分布

$$G_a(x) = \begin{cases} F_2(x), & x < a; \\ F_0(x), & x \geq a. \end{cases}$$

则易见 $d(F_0, G_a) \leq \varepsilon$, 且当 $a \rightarrow \infty$ 时, $\lambda(t, G_a)$ 在 $(-\infty, \infty)$ 一致收敛于 $K(t)$. 因此, 当 a 充分大时, $\lambda(t, G_a)$ 的零点 $T(G_a)$ 可任意大, 以至没有零点. 由此可知, 当 $\varepsilon > -\psi(-\infty)/[\psi(\infty) - \psi(-\infty)]$ 时, $b_+(\varepsilon) = \infty$. 另一方面, 取

$$F_1(x) = \min\{F_0(x + \varepsilon) + \varepsilon, 1\}$$

利用引理 6.2 的 (6.67) 式, 与上述讨论平行的推理证明: $b_-(\varepsilon) < \infty$ 或 $= \infty$, 视 $\varepsilon < \psi(\infty)/[\psi(\infty) - \psi(-\infty)]$ 或 $\varepsilon > \psi(\infty)/[\psi(\infty) - \psi(-\infty)]$ 而定. 由此得到 $T(F)$ 的崩溃点:

$$\varepsilon^* = \min\{\psi(\infty), |\psi(-\infty)|\} / [\psi(\infty) + |\psi(-\infty)|]. \quad (6.75)$$

注意 ε^* 与 F_0 无关. 显然, $0 < \varepsilon^* \leq 1/2$. 当且仅当 $\psi(\infty) = |\psi(-\infty)|$ 时, 达到最大值 $1/2$.

另外, 不难证明, 当 $\psi(\infty) + |\psi(-\infty)| = \infty$ 时, 必有 $\varepsilon^* = 0$. 因此, 为选定可给予稳健估计的位置参数, 应取非降有界的 ψ , 且 $\psi(-\infty) < 0 < \psi(\infty)$. 总计中位数相当于挑选当 $x \leq 0$ 时, $\psi(x) = -1$; 当 $x > 0$ 时, $\psi(x) = 1$, 这时崩溃点为 $1/2$, 与前面计算的结果相符合.

常用的 ψ 除了刚才提到的那个 (相应于总体中位数) 以及 $\psi(x) = x$ (相当于总体期望值) 外, 还有

1) (Huber)

$$\rho(t) = \begin{cases} \frac{1}{2}t^2, & |t| \leq k; \\ k|t| - \frac{1}{2}k^2, & |t| > k. \end{cases} \quad \psi(t) = \begin{cases} 1, & |t| \leq k; \\ k \cdot \text{sign}(t), & |t| > k. \end{cases}$$

2) (Tukey)

$$\rho(t) = \begin{cases} \frac{B^2}{6} \left\{ 1 - \left[1 - \left(\frac{t}{B} \right)^2 \right]^3 \right\}, & |t| \leq B; \\ \frac{B^2}{6}, & |t| > B. \end{cases}$$

$$\psi(t) = \begin{cases} t \left[1 - \left(\frac{t}{B} \right)^2 \right]^2, & |t| \leq B; \\ 0, & |t| > B. \end{cases}$$

3) (Andrews)

$$\rho(t) = \begin{cases} A^2 \left[1 - \cos \frac{t}{A} \right], & |t| \leq \pi A; \\ 2A^2, & |t| > \pi A. \end{cases} \quad \psi(t) = \begin{cases} A \sin \frac{t}{A}, & t \leq \pi A; \\ 0, & |t| > \pi A. \end{cases}$$

注意在后两例中, $\psi(t)$ 的非降条件不满足. 这种情况(如这两例所示)多发生在当 $|t|$ 充分大时, $\psi(t) = 0$. 从统计意义上说, 这相当于将离群过远的数据定为异常值, 并从样本中抛弃这些异常值.

6.3.5 M 估计的渐近正态性

设 $X_1, \dots, X_n \sim F$, M 估计 T_n 由(6.52)式定义, $\lambda(t)$ 由(6.55)式定义. 设 $\psi(x)$ 在 $-\infty < x < \infty$ 单调非降, 且 $\lambda(t)$ 至少有一个零点 t_0 , $\lambda(t)$ 的一切零点的集记为 B . 由 ψ 的非降性知 B 为凸集, 假定此集有界, 其左、右端点分别记为 b_1 和 b_2 .

本段的目的是证明下面的定理:

定理 6.5 在上述条件下, 并进一步假定存在 $\epsilon > 0$, 使 1) $\lambda(t)$ 在 $(b_1 - \epsilon, b_2 + \epsilon)$ 上连续; 2) 表达式

$$\sigma^2(t) = \int_{-\infty}^{\infty} \psi^2(x-t) dF(x) - \lambda^2(t) = \text{Var}_F \psi(X-t) \quad (6.76)$$

在 $(b_1 - \epsilon, b_2 - \epsilon)$ 内有限、大于 0 且连续. 记 $\sigma_0^2 = \sigma^2(t_0)$, 则当 $n \rightarrow \infty$ 时, 有

$$\frac{-\sqrt{n} \lambda(T_n)}{\sigma_0} \xrightarrow{\mathcal{L}} N(0, 1). \quad (6.77)$$

又若 $\lambda'(t_0)$ 存在且不为 0, 则

$$\frac{\lambda'(t_0)(T_n - t_0)}{\sigma_0} \xrightarrow{\mathcal{L}} N(0, 1). \quad (6.78)$$

证 若(6.77)式已证, 则由 $\lambda(t_0) = 0$ 知

$$-\frac{\sqrt{n}[\lambda(T_n) - \lambda(t_0)]}{\sigma_0} \xrightarrow{\mathcal{L}} N(0, 1).$$

由此式及 $\lambda'(t_0)$ 存在且不为 0, 据极限理论中周知的事实(例如参看文献[135]中第 385 页), 即得(6.78)式. 因此, 只需证明(6.77)式.

仍根据(6.57)式定义 T_n^* 及 T_n^{**} , 前已指出: 方程(6.52)式的任一解 T_n 都满足 $T_n^* \leq T_n \leq T_n^{**}$.

下面证明: 当以 T_n^* 或 T_n^{**} 代替(6.77)式中的 T_n 时, (6.77)式成立. 再由 $\lambda(T_n^*) \geq \lambda(T_n) \geq \lambda(T_n^{**})$, 即知(6.77)式成立. 我们只讨论 T_n^* , 因为 T_n^{**} 的情况完全相似.

任取实数 y , 由关于 $\lambda(t)$ 在 $(b_1 - \epsilon, b_2 + \epsilon)$ 连续, 在 (b_1, b_2) 为 0 及 $\lambda(t)$ 非增的事实知: 存在一串 $\{t_n\}$, 使当 n 充分大时, 有 $y = -\sqrt{n}\lambda(t_n)$. 令

$$Y_{ni} = \frac{\psi(X_i - t_n) - \lambda(t_n)}{\sigma(t_n)}, \quad i = 1, \dots, n; n = 1, 2, \dots, \quad (6.79)$$

则 $Y_{n1}, \dots, Y_{nn}$ 为 iid., 有均值 0 方差 1, 有

$$\begin{aligned} \{-\sqrt{n}\lambda(T_n^*) < y\} &= \{-\lambda(T_n^*) < -\lambda(t_n)\} \subset \{T_n^* < t_n\} \\ &\subset \{T_n^* \leq t_n\} \subset \{-\lambda(T_n^*) \leq -\lambda(t_n)\} \\ &\subset \{-\sqrt{n}\lambda(T_n^*) \leq y\}. \end{aligned}$$

因此, 若 y 为 $-\sqrt{n}\lambda(T_n^*)$ 的分布的连续点, 则

$$P(-\sqrt{n}\lambda(T_n^*) < y) = P(T_n^* < t_n) = P(T_n^* \leq t_n).$$

由此式和(6.58)式以及 Y_{ni} 的定义(6.79)式, 得

$$P(-\sqrt{n}\lambda(T_n^*) < y) = P\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n Y_{ni} < \frac{y}{\sigma(t_n)}\right). \quad (6.80)$$

易见在 (b_1, b_2) 内, $\sigma^2(t)$ 的值保持不变. 事实上, 设 $a_1 < a_2$ 为此区间的两点, 则

$$0 = \int_{-\infty}^{\infty} \psi(x - a_1) dF(x) = \int_{-\infty}^{\infty} \psi(x - a_2) dF(x). \quad (6.81)$$

但由 ψ 的非降性及 $a_1 < a_2$ 知对一切 x , 有 $\psi(x - a_1) \geq \psi(x - a_2)$, 故集 $\{x: \psi(x$

$-a_1) \neq \psi(x - a_2)\}$ 的 F 测度为 0, 因而有

$$\int_{-\infty}^{\infty} \psi^2(x - a_1) dF(x) = \int_{-\infty}^{\infty} \psi^2(x - a_2) dF(x),$$

即 $\sigma^2(a_1) = \sigma^2(a_2)$. 因为 $t_0 \in [b_1, b_2]$, 有 $\sigma(t_0) = \sigma(b_1) = \sigma(b_2)$. 又由 $[b_1, b_2]$ 的定义知 $t_n \rightarrow b_1$ 或 $t_n \rightarrow b_2$ 二者必居其一. 再由 $\sigma(t)$ 的连续性假定知

$$\sigma(t_n) \rightarrow \sigma(t_0) = \sigma_0 > 0.$$

故由 (6.80) 式知, 若能证得

$$\text{当 } n \rightarrow \infty \text{ 时, } \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_{ni} \xrightarrow{\mathcal{L}} N(0, 1). \quad (6.82)$$

则由 (6.80) 式知, 对除去一个至多可列集 (由 $-\sqrt{n}\lambda(T_n^*)/\sigma_0 (n=1, 2, \dots)$ 的一切不连续点构成) 外的其他 y 有

$$\lim_{n \rightarrow \infty} P\left(-\frac{\sqrt{n}\lambda(T_n^*)}{\sigma_0} < y\right) = \Phi(y).$$

因而此式对一切 y 成立. 这证明了 (6.77) 式当 T_n 改为 T_n^* 时成立. 如上所述, 这就证明了本定理.

由于 Y_{ni} 为 iid., 有均值 0 方差 1, 故为证 (6.82) 式, 只需验证下述 Lindeberg 条件 (见文献 [115] 中第 295 页):

$$\text{对任给的 } \epsilon' > 0, \text{ 有 } \lim_{n \rightarrow \infty} E\{Y_{n1}^2 I_{(|Y_{n1}| > \sqrt{n}\epsilon')}\} = 0. \quad (6.83)$$

由于 $\sigma(t_n) \rightarrow \sigma_0 > 0$ 而 $\lambda(t_n) \rightarrow 0$, (6.83) 式等价于

$$\lim_{n \rightarrow \infty} E\{\psi^2(x - t_n) I_{(|\psi(x - t_n)| \geq \sqrt{n}\epsilon')}\} = 0. \quad (6.84)$$

任取 $\eta \in (0, \epsilon)$, 记 $a_1 = b_1 - \eta, a_2 = b_2 + \eta$. 由 ψ 的单调性有

$$\psi^2(x - t_n) \leq \psi^2(x - a_1) + \psi^2(x - a_2), \quad \text{当 } n \text{ 充分大.}$$

因为 a_1, a_2 都在 $(b_1 - \epsilon, b_2 + \epsilon)$ 内, 有

$$\int_{-\infty}^{\infty} \psi^2(x - a_j) dF(x) < \infty, \quad j = 1, 2.$$

于是 $\{\psi^2(x - t_n); n = 1, 2, \dots\}$ 为一可积函数 (对 dF 可积) 所控制, 又

$$\lim_{n \rightarrow \infty} \psi^2(X - t_n) I_{(|\psi(X - t_n)| \geq \sqrt{n}\epsilon')} = 0, \text{ a.s. .}$$

于是由控制收敛定理得出 (6.83) 式, 因而证得 (6.82) 式. 定理证毕.

表达式

$$A(F, \psi) = \frac{\sigma_0^2}{(\lambda'(t_0))^2} = \int_{-\infty}^{\infty} \frac{\psi^2(x - T(F))^2 dx}{[\lambda'(T(F))]^2}, \quad (6.85)$$

其中 $T(F)$ 是由方程 (6.55) 的根所确定的位置参数, 也是由 (6.52) 式所决定的 M 估计 T_n 的渐近方差, 显然, 当总体分布由 $F(x)$ 改为 $F(x - \theta)$ (θ 为常数) 时, (6.85) 式的右边的值不变.

6.3.6 Huber 的渐近 Minimax 理论

从大样本的观点看, $A(F, \psi)$ 愈小, M 估计 T_n 就愈好. 按照这个准则, Huber 发展了一种渐近 Minimax 理论. 它可以作为一种稳健性的解释. Huber 的这一理论发端于其 1964 年的工作^[93], 并详细叙述了他的专著^[95] 的第四章. 严格而系统地叙述这个理论需要较多的篇幅, 在此只介绍一下其梗概以及在个别重要情况下的具体结果.

仍设样本 $X_1, \dots, X_n \sim F \in \mathcal{F}, \mathcal{F}_0$ 为 $\mathcal{F}$ 的子集, 满足条件:

$$F(x) \in \mathcal{F}_0 \Rightarrow F(x - a) \in \mathcal{F}_0, \quad \text{对任何常数 } a \text{ 成立.}$$

当选定一个函数 ψ 以按 (6.52) 式确定 M 估计 T_n 时, 其渐近方差 $A(F, \psi)$ 由 (6.85) 式确定. 一般不能确知真正的总体分布 F , 而有一定的把握认为 F 在 $\mathcal{F}_0$ 内, 故采用函数 ψ 时, 所确定的 T_n 的渐近方差在 $\mathcal{F}_0$ 内有上确界 $\sup\{A(F, \psi): F \in \mathcal{F}_0\}$. 我们自然希望这个值愈小愈好. 就是说, 要选择 ψ_0 , 使

$$\sup_{F \in \mathcal{F}_0} A(F, \psi_0) = \inf_{\psi} \sup_{F \in \mathcal{F}_0} A(F, \psi). \quad (6.86)$$

若这种 ψ_0 存在, 则由它所确定的 M 估计 T_n^0 的渐近方差的最大值达到最小. 这自然可以看作一个与稳健性不相涉的问题的解, 但也可以在一定的意下赋予它以稳健性的解释. 因为在通常情况下, $\mathcal{F}_0$ 是我们设想的总体分布 G 的某个邻域 (例如, G 是正态分布, $\mathcal{F}_0$ 为 G 的“ ϵ 污染邻域”). 真正的总体分布不必是 G , 而可以是 $\mathcal{F}_0$ 中的任一分布. 因此, 若固定于 G , 而选择 ψ 为使 $A(G, \psi)$ 达到最小的 ψ_G , 则当总体分布确为 G 时, 由这个 ψ_G 所定出的 M 估计固然很好, 但有一个危险——即有可能当总体分布并非 G 而是 $\mathcal{F}_0$ 中的某个 F 时, $A(F, \psi_G)$ 变得很大. 为防止这种情况发生, 我们不用这个 ψ_G , 而使用由 (6.86) 式决定的 ψ_0 . 由它所决定的 T_n^0 防止了可能最坏的情况的出现. 但当总体分布确为 G 时, 则可能不如由 ψ_G 所决定的估计, 因为 $A(G, \psi_G) \leq A(G, \psi_0)$. 这就是由 ψ_G 改用 ψ_0 所付出的代价. 在上述渐近方差的意义上, 可以说由 ψ_0 决定的 T_n^0 是一个稳健性好

的估计. 因为即使当真正的总体分布 F 与设想的总体分布 G 有所偏差时, 这估计的性能(以其渐近方差衡量) 依然保持较好的水平.

下面转到 Huber 理论的具体内容. 中心问题是满足(6.86)式的 ψ_0 的存在性及如何求. 有以下几点:

1) 前已指出, $A(F, \psi)$ 与位置参数的值 $T(F)$ 无关. 故不失普遍性可设 $T(F) = 0$. 又因 $\lambda(t) = \int_{-\infty}^{\infty} \psi(x-t) dF(x)$, 若能在积分号下求导, 则有

$$\lambda'(0) = - \int_{-\infty}^{\infty} \psi'(x) dF(x). \quad (6.87)$$

例如当 F 有密度 f , 满足条件:

① 存在 $c > 0$ 及函数 g , 使当 $0 < |h| < c$ 时, 对一切 x , 有

$$\left| \frac{1}{h}(f(x+h) - f(x)) \right| \leq g(x);$$

②
$$\int_{-\infty}^{\infty} |\psi(x)| g(x) dx < \infty.$$

则易见(6.87)式成立. 这时, 若记

$$I(F, \psi) = \left(\int_{-\infty}^{\infty} \psi'(x) dF(x) \right)^2 / \int_{-\infty}^{\infty} \psi^2(x) dF(x), \quad (6.88)$$

则有

$$A(F, \psi) = \frac{1}{I(F, \psi)}. \quad (6.89)$$

于是, 若记

$$I(F) = \sup_{\psi} I(F, \psi). \quad (6.90)$$

则有

$$\inf_{\psi} A(F, \psi) = \frac{1}{I(F)}. \quad (6.91)$$

Huber 把(6.90)式的 $I(F)$ 定义为 Fisher 信息量. 他证明了 $I(F) < \infty$ 的充要条件是: F 有绝对连续的密度 f , 且

$$\int_{-\infty}^{\infty} (f'(x)/f(x))^2 f(x) dx < \infty.$$

当这些条件成立后, 后一积分就是 $I(F)$. 因此在这一场合下, Huber 定义的 Fisher 信息量与通常初等教本中的定义是一致的.

Huber 的结果(6.91)式与点估计的大样本理论中周知的结果是一致的, 即

在一定条件下,参数的任一相合估计的渐近方差的下确界为 Fisher 信息量的倒数,且这下确界在最大似然估计的情况下能达到.这后一事实下面还要用到.

2) Huber 证明:当 $\mathcal{F}_0$ 满足一定的条件时,存在唯一的 $F_0 \in \mathcal{F}_0$,使

$$\text{对一切 } F \in \mathcal{F}_0, \text{ 有 } I(F_0) \leq I(F). \quad (6.92)$$

3) 以 f_0 记 F_0 的密度.取 $\psi_0(x) = -f'_0(x)/f_0(x)$ 作为 (6.52) 式中的 ψ ,以定义 M 估计 T_n^0 ,则当总体分布为 F 时, T_n^0 的渐近方差为 $A(F, \psi_0)$. 在一定的条件(加在 $\mathcal{F}_0$ 上)之下,Huber 证明了

$$\text{对任何 } F \in \mathcal{F}_0, \text{ 有 } A(F, \psi_0) \leq A(F_0, \psi_0). \quad (6.93)$$

4) 由此就可以推出: ψ_0 就是 Minimax 问题 (6.86) 的解.事实上,因为 T_n^0 是在总体分布为 $\{F_0(x - \theta)\}$ 之下的最大似然估计,故 $A(F_0, \psi_0) = 1/I(F_0)$. 由 (6.93) 式,有

$$\sup_{F \in \mathcal{F}_0} A(F, \psi_0) = \frac{1}{I(F_0)}. \quad (6.94)$$

另一方面,以 T_n 记另一个 ψ 所决定的 M 估计,则因最大似然估计使渐近方差达到最小,知当总体分布为 F_0 时,有 $A(F_0, \psi) \geq 1/I(F_0)$,从而

$$\sup_{F \in \mathcal{F}_0} A(F, \psi) \geq \frac{1}{I(F_0)}. \quad (6.95)$$

由 (6.94)、(6.95) 式,即得所要的结果.

Huber 并提出了寻找满足 (6.92) 式的 F_0 的方法,且在若干特例下算出了具体结果.现就一重要场合引述其结果如下:

设以 $\mathcal{N}$ 记正态分布类, $\mathcal{A}$ 记分布类 $\{H: H \text{ 的密度 } h \text{ 存在且绝对连续}, I(H) < \infty\}$, 又 $\epsilon \in (0, 1)$, 而

$$\mathcal{F}_0 = \{(1 - \epsilon)G + \epsilon H; G \in \mathcal{N}, H \in \mathcal{A}\}. \quad (6.96)$$

这时可得满足条件 (6.92) 的 F_0 如下: F_0 的密度函数 f_0 为

$$f_0(x) = \begin{cases} \frac{1-\epsilon}{\sqrt{2\pi}} e^{-x^2/2}, & |x| < k; \\ \frac{1-\epsilon}{\sqrt{2\pi}} e^{k^2/2 - k|x|}, & |x| \geq k. \end{cases} \quad (6.97)$$

其中 k 由方程

$$\frac{2}{\sqrt{2\pi}k} e^{-k^2/2} - 2\Phi(-k) = \frac{\epsilon}{1-\epsilon} \quad (6.98)$$

所决定. 相应于此 f_0 的 ψ_0 为

$$\psi_0(x) = \max\{-k, \min(k, x)\}, \quad -\infty < x < \infty. \quad (6.99)$$

即在 6.3.4 小节的末尾处所提到过的 Huber 的 ψ . 由 (6.99) 式决定的 ψ_0 , 可根据控制异常值的作用这一点给以一种直观的解释. Huber 的渐近 Minimax 理论给予它以一种理论的根据.

以上考虑的 $\mathcal{F}_0$ (见 6.96) 式是 ϵ 污染型的. Huber 也讨论了 Колмогоров 型的邻域: 给定 $\epsilon \in (0, 1)$,

$$\mathcal{F}_0 = \{F: F \in \mathcal{A}; \text{存在 } G \in \mathcal{N}, \text{使 } \sup_x |F(x) - G(x)| \leq \epsilon\}.$$

在这个情况下, Huber 也决定了 F_0 , 其概率密度 f_0 和相应的 ψ_0 形式比较复杂: 存在 $\epsilon_0 \approx 0.0303$, 使

① $0 < \epsilon < \epsilon_0$: 这时, 记

$$\varphi(x) = \Phi'(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2},$$

由方程

$$\epsilon = \frac{\varphi(x_1)}{x_1} - \Phi(-x_1) \quad (6.100)$$

决定 x_1 , 由方程组

$$x_0 = \left(u \tan \frac{u}{2}\right)^{1/2}, \quad \epsilon = \Phi(x_0) - \frac{1}{2} - x_0 \varphi(x_0) \frac{1 + \sin u / u}{1 + \cos u} \quad (6.101)$$

决定 x_0 和 u ($0 < x_0 < x_1$). 则 $f_0(-x) = f_0(x)$, 而

$$f_0(x) = \begin{cases} \frac{\varphi(x_0)}{\cos^2(u/2)} \cos^2\left(\frac{ux}{2x_0}\right), & 0 \leq x < x_0; \\ \varphi(x), & x_0 \leq x \leq x_1; \\ \varphi(x_1) e^{-x_1(x-x_1)}, & x > x_1. \end{cases} \quad (6.102)$$

相应的 ψ_0 为

$$\begin{aligned} \psi_0(-x) &= -\psi_0(x); \\ \psi_0(x) &= \begin{cases} \frac{u}{x_0} \tan \frac{ux}{2x_0}, & 0 \leq x < x_0; \\ x, & x_0 \leq x \leq x_1; \\ x_1, & x > x_1. \end{cases} \end{aligned} \quad (6.103)$$

② $\epsilon_0 \leq \epsilon \leq 1$: 这时有 $f_0(-x) = f_0(x)$, 而

$$f_0(x) = \begin{cases} \frac{\varphi(x_0)}{\cos^2(u/2)} \cos^2\left(\frac{ux}{2x_0}\right), & 0 \leq x < x_0; \\ \varphi(x_0)e^{-\lambda(x-x_0)}, & x \geq x_0. \end{cases} \quad (6.104)$$

其中 x_0, u, λ 由方程组

$$\begin{cases} \lambda x_0 = u \tan \frac{u}{2} \\ x_0 \varphi(x_0) = \cos^2\left(\frac{u}{2}\right) \cdot \frac{u \tan(u/2)}{u \tan(u/2) + 2} \\ \epsilon = \frac{1}{\lambda} \varphi(x_0) - \Phi(-x_0) \end{cases} \quad (6.105)$$

决定,而

$$\psi_0(x) = \begin{cases} \frac{u}{x_0} \tan\left(\frac{ux}{2x_0}\right), & 0 \leq x < x_0; \\ \lambda, & x \geq x_0. \end{cases} \quad (6.106)$$

6.3.7 位置参数的刻度同变 M 估计

总体均值和中位数等常见的位置参数都具有如下的性质:

若 $a > 0$, 而总体分布由 $F(x)$ 改为 $F(x/a)$, 则它们的值改为原值的 a 倍. 换言之, 有

$$T\left(F\left(\frac{x}{a}\right)\right) = aT(F(x)), \quad a > 0. \quad (6.107)$$

这些参数的估计量——即样本均值和样本中位数也具有类似的性质, 即若 $a > 0$, 而样本由 $(X_1, \dots, X_n)$ 改为 $(aX_1, \dots, aX_n)$, 则估计值改为原值的 a 倍. 换言之, 有

$$T_n(aX_1, \dots, aX_n) = aT_n(X_1, \dots, X_n), \quad a > 0. \quad (6.108)$$

但是, 如果位置参数 $T(F)$ 定为方程 (6.55) 的根, 则一般它并不具备性质 (6.107). 为了克服这一缺点, 可将方程 (6.55) 修改为

$$\int_{-\infty}^{\infty} \psi\left(\frac{x-t}{S(F)}\right) dF(x) = 0. \quad (6.109)$$

这里的 $S(F)$ 是一个满足如下三个条件的泛函: 1°. $S(F) > 0$; 2°. 对任何 c , 有 $S(F(x-c)) = S(F(x))$; 3°. $S(F(x/a)) = aS(F(x))$ 对任何 $a > 0$ 成立. 满足这种条件 $S(F)$ 称为 F 的刻度参数. 不难看出, 若 $T(F)$ 为方程 (6.109) 的解,

则它满足(6.107)式.事实上,设 $a > 0$, 则 $T(F(x/a))$ 为方程

$$\int_{-\infty}^{\infty} \psi \left(\frac{x-t}{S(F(\frac{x}{a}))} \right) dF\left(\frac{x}{a}\right) = 0 \quad (6.110)$$

的解,即 $\int_{-\infty}^{\infty} \psi \left(\frac{x-t}{aS(F)} \right) dF(x/a) = 0$ 的解.作变数代换 $x = ay$ (仍将 y 换为 x),

得 $\int_{-\infty}^{\infty} \psi \left(\frac{x-t/a}{S(F)} \right) dF(x) = 0$, 故 $t/a = T(F)$, 而得(6.110)式的解为 $aT(F)$.

又易见,由(6.109)式定义的 $T(F)$ 满足位置参数的条件(6.46).

由(6.52)式的解 T_n 所定义的位置参数估计一般不满足(6.108)式,需要作相应的修改.其修改要与位置参数的新定义(6.109)式相配合.为此,需要找到 $S(F)$ 的一个适当估计 $S_n = S_n(X_1, \dots, X_n)$ (至少应为相合的), 满足条件
 1°. $S_n > 0$ ^①; 2°. $S_n(X_1 + c, \dots, X_n + c) = S_n(X_1, \dots, X_n)$ 对任何常数 c 成立.
 3°. $S_n(aX_1, \dots, aX_n) = aS_n(X_1, \dots, X_n)$ 对任何 $a > 0$ 成立. 然后将方程(6.52)修改为

$$\sum_{i=1}^n \psi \left(\frac{X_i - T_n}{S_n} \right) = 0. \quad (6.111)$$

不难验证:由方程(6.111)式确定的估计 T_n 满足刻度同变性条件(6.108)式,且与(6.52)式的解一样,具有平移同变性:对任何 c , 有

$$T_n(X_1 + c, \dots, X_n + c) = T_n(X_1, \dots, X_n) + c. \quad (6.112)$$

最常用的刻度参数为总体分布的标准差——即方差的平方根.它可用样本标准差 $\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right)^{1/2}$ 估计.这个估计的稳健性较差,为获得较好的稳健性,可改用

$$S(F) = \text{med} |X - \text{med } X|. \quad (6.113)$$

此处变量 X 有分布 $F(x)$, 而 $\text{med } \xi$ 表示变量 ξ 的中位数.相应的估计量是

$$S_n(X_1, \dots, X_n) = \text{med}(|X_i - \text{med}(X_1, \dots, X_n)|, i = 1, \dots, n). \quad (6.114)$$

这里 $\text{med}(X_1, \dots, X_n)$ 表示 $X_1, \dots, X_n$ 的样本中位数,易见 S 和 S_n 分别满足对刻度参数及其估计的三个条件.

① 一般,当且仅当 $X_1, \dots, X_n$ 都相同时, $S_n(X_1, \dots, X_n) = 0$.

方程(6.52)或(6.111)的解一般只能用数值方法(如常用的牛顿法)求得. 此外, Tukey 和 Huber 等都提出过数值解法, 详见文献[95].

6.3.8 回归系数的 M 估计

从一定意义上, 可以把线性回归系数看作是位置参数的推广. 故在此附带讨论一下线性回归系数的 M 估计.

在现今应用最多的回归分析方法中, 通常假定回归函数为自变量的线性函数(或通过适当的变数代换可化成这种形式), 并以最小二乘法估计未知的回归系数, 即令

$$Y_i = x_i' \beta + e_i, \quad i = 1, \dots, n. \quad (6.115)$$

其中 Y_i 为第 i 次试验时因变量所取的值. $x_i = (x_{i1}, \dots, x_{ip})'$ 为已知的 p 维向量, 是自变量(p 维)在第 i 次试验中所取的值, β 为未知的 p 维回归系数向量, 而 e_i 为第 i 次试验的随机误差. 一般假定 $e_1, \dots, e_n$ 为 iid. 的. (6.115) 式也可写为矩阵的形式.

$$Y = X\beta + e. \quad (6.116)$$

其中

$$Y = (Y_1, \dots, Y_n)', \quad X = (x_1 : x_2 : \dots : x_n)', \quad e = (e_1, \dots, e_n)'. \quad (6.117)$$

最小二乘法就是由条件

$$\|Y - X\beta\|^2 = \sum_{i=1}^n (Y_i - x_i' \beta)^2 = \min! \quad (6.117)$$

决定 β 的估计 $\hat{\beta}$. 有

$$\hat{\beta} = S^{-1} X'Y, \quad S = X'X. \quad (6.118)$$

这一套方法在应用上取得了很大的成功, 但经验和理论都指明: 它并非总是给出好的结果. 问题无非是在两个方面: 其一是在一些问题中, 回归函数与线性函数的偏离较大, 或更一般地说, 没有根据去假定回归函数有任何特定的数学形式. 为克服这一困难引进了非参数回归方法, 这已在 6.2 节中讨论过了. 另一个问题是出在最小二乘法上面. 前已指出, 这个方法的“抗异常值能力”差. 由于在回归问题中异常值一般不易识别, 盲目使用最小二乘法就可能导致不好的结果. 稳健回归方法就是为克服这一困难而引进的: 它仍认定模型有线性的形式(6.115), 但不用最小二乘法去估计 β . 前面在讨论位置参数估

计时提到的 M 、 L 和 R 三种方法都可以用于估计 β . 但到目前为止, M 估计所给出的结果比较好, 且在计算上较容易实现. 故在此处只简略地讨论一个这种估计.

与在位置参数情况下的考虑一样, 回归系数 β 的 M 估计就是在 (6.117) 式中用比 x^2 增长较慢的函数 $\rho(x)$ 取代 x^2 , 而将极值问题改为

$$\sum_{i=1}^n \rho(Y_i - x_i' \beta) = \min!. \quad (6.119)$$

函数 ρ 要满足定义 6.6 中所列举的条件. 若 $\rho' = \psi$ 存在, 则在一定条件下 (6.119) 式等价于解方程组

$$\sum_{i=1}^n \psi(Y_i - x_i' \beta) x_{ij} = 0, \quad j = 1, \dots, p. \quad (6.120)$$

往往选择适当的 ψ , 而把 (6.120) 式的解定义为 (由 ψ 决定的) M 估计, 不必考虑它与 (6.119) 式的联系. 这时要假定随机误差 e_i (已假定为 iid. 的) 满足^①

$$E\psi(e_i) = 0. \quad (6.121)$$

一个讨论得较多的 M 估计是在 (6.119) 式中取 $\rho(x) = |x|$, 称为 L_1 模估计. 详见文献[17] 及其所引的文献. 另外, 在 6.3.4 小节结尾处提到的 Huber、Tukey、Andrews 等引进的 ψ 也常用. 又, 为了考虑刻度同变性, 可将方程 (6.120) 修改为

$$\sum_{i=1}^n \psi\left(\frac{Y_i - x_i' \beta}{S_n}\right) x_{ij} = 0, \quad j = 1, \dots, p. \quad (6.122)$$

其中 S_n 为 e_i 的分布的某种刻度参数估计. 例如先用某种方法 (如最小二乘法) 对 β 作一估计得 $\hat{\beta}$. 算出残差 $r_i = Y_i - x_i' \hat{\beta}$ ($i = 1, \dots, n$), 然后令 $S_n = \text{med}(|r_1|, \dots, |r_n|)$. 不论是方程组 (6.120) 还是 (6.122), 其解都需要通过数值方法计算.

前已指出, 用 M 估计法而不用最小二乘法去估计回归系数, 主要是为了对付异常值. 从直观的角度看, 有理由相信 M 估计在这方面能起到一定的作用. 现实的例子还不多, 一个在文献中常被引用的例子如下: Brownlee 在文献[41] 中有一个三自变量、21 组数据的线性回归问题. 在文献[52] 中的 Daniel 等花了相

① 在前述位置参数的 M 估计中, 没有加上类似于 (6.121) 式的条件, 问题在于: 在那里被估计的位置参数也决定于 ψ , 而此处则固定为 β .

当的篇幅细致地讨论了这个问题. 他们的基本想法是力求发现并剔除异常值, 然后用最小二乘法. 这种作法要求使用者有较丰富的经验. 不然的话, 就容易误入歧途, 把本应剔除的异常值保留了下来, 而剔除了并非异常值的样本. 即使要在简单的一元线性回归中, 这种情况也可能出现(参看文献[95]中7.1节中的例子). 因此, 这不是一个容易使用的方法. 就此处提到的 Brownlee 例子而言, Daniel 等经过不少讨论, 最后剔除了四组异常数据, 用剩下的 17 组数据按最小二乘法配出了线性回归方程. 另一方面, Andrews 在文献[33]中用 M 估计法(所用的 ψ 是在 6.3.4 小节)结尾处提到的 $A \sin \frac{t}{A} \cdot I_{(|t| \leq \pi A})$) 没有作任何附加的分析, 就一下子就得到了 Daniel 等最后结果很接近的方程. 四组异常值未剔除这一点, 对 Andrews 的估计没有起多大影响. 反之, 用 Andrews 的估计法可以判断它们是异常值. 关于 Brownlee 这个例子的数据及其细节, 读者可参阅文献[16]的第四章.

关于回归系数的 M 估计的大样本理论, 也作出了一些结果, 首要的是其渐近正态性, 可参看文献[94]或[95]的第七章, 该处的结果对 ψ 加上了过强的要求. 更进一步的结果可参看文献[178].

参 考 文 献

- [1] 陈希孺. 关于 U 统计量和 Von-Mises 统计量的极限性质[J]. 中国科学, 1980, 6: 522~532.
- [2] 陈希孺. 区组内不均匀时的两样本置换检验[J]. 武汉大学学报, 1980, 4: 1~13.
- [3] 陈希孺. 数理统计引论[M]. 北京: 科学出版社, 1981.
- [4] 陈希孺. 最近邻密度估计的渐近均方误差(英文)[J]. 数学年刊, 1981, 2(4): 425~430.
- [5] 陈希孺. 线性置换统计量的两个问题[J]. 应用数学学报, 1981, 4(4): 342~355.
- [6] 陈希孺. 最近邻密度估计的收敛速度[J]. 中国科学, 1981, 12: 1419~1428.
- [7] 陈希孺. 众数的一个估计[J]. 科学探索, 1981, 1(3): 23~28.
- [8] 陈希孺. 密度核估计的一致收敛速度(英文)[J]. 系统科学与数学.
- [9] 陈希孺. 关于概率密度估计的一个问题[J]. 科学探索, 1982, 2(3): 73~78.
- [10] 陈希孺. 概率密度的最佳收敛速度问题(英文)[J]. 数学年刊.
- [11] 陈希孺. 结存在时两样本线性秩统计量的渐近正态性[J]. 武汉大学学报, 1982, 4: 1~11.
- [12] 陈希孺. 最近邻密度估计的一致收敛速度(英文)[J]. 数学研究与评论, 1983, 3(1): 61~68.
- [13] 陈希孺. k 近邻判别法后验错误概率的指数限(英文)[J]. 中国科学.
- [14] 陈希孺. 非参数回归估计的几乎处处收敛性(英文)[J]. 数学年刊; B 辑.
- [15] 陈希孺. 一般情况下随机区组设计的置换检验的大样本理论[J]. 武汉大学学报: 自然科学版, 1983, 4: 1~12.
- [16] 陈希孺, 王松桂. 近代实用回归分析[M]. 桂林: 广西人民出版社, 1983.
- [17] 王松桂. 线性模型参数估计的新进展[J]. 全国概率统计年会报告, 昆明, 1982.
- [18] 韦来生, 苏淳. 非参数回归函数最近邻估计 L_p 收敛的速度(英文)[J]. 数学研究与评论.
- [19] 白志东. NN 判别中错判概率估计的强相合性(英文)[J]. 数学年刊.
- [20] 白志东. 渐近 Bayes 判别[J]. 数学学报.
- [21] 陈桂景. 非参数回归核估计的收敛速度[J]. 数学学报.
- [22] 陈桂景. 概率密度函数及其导函数, 众数核估计的强收敛速度[J]. 中国科学: A, 1983, 7:

577~585.

- [23] 苏淳. 关于正态逼近的最佳非一致界限[J]. 科学通报, 1983, 12: 705~708.
- [24] 赵林城. 关于概率密度估计的无偏性[J]. 中国科学技术大学学报.
- [25] 赵林城, 白志东. 非参数回归函数最近邻估计的强相合性[J]. 中国科学.
- [26] 赵林城, 方兆本. 非参数回归核估计的强收敛(英文)[J]. 数学年刊.
- [27] 赵林城, 陈希孺. U 统计量的分布的非一致收敛速度[J]. 中国科学: A, 1982, 12: 1066~1078.
- [28] 班成. 变叙的项的极限分布[J]. 数学学报, 1964, 14(5): 694~714.
- [29] 班成. 非正则中项变叙的极限分布[J]. 数学学报, 1980, 23(3): 323~330.
- [30] 柴根象. 密度函数的相合随机窗宽核估计[J]. 中国科学.
- [31] 柴根象. 一类密度函数 NN 估计的一致收敛速度[J]. 数学学报.
- [32] Andrews D F, et al. Robust Estimation of Location; Survey and Advances[M]. New Jersey: Princeton University Press, 1972.
- [33] Andrews D F. A robust method for multiple linear regression[J]. Technometrics, 1974, 16: 523~531.
- [34] Ansari A R, Bradley R A. Rand-sum tests for dispersions[J]. Ann. Math. Statist., 1960, 31: 1174~1189.
- [35] Balkema A A, de Haan L. Limit distribution for order statistics[J]. I and II. Teor, Veroyat. Primen. 1978; 80~96, 358.
- [36] Barr D R, Davidson T. A Kolmogorov-Smirnov test for censored samples [J]. Technometrics, 1973, 15: 739~757.
- [37] Berk R H. Limiting behavior of posterior distributions when the model is incorrect Ann[J]. Math. Statist., 1966, 37: 51~58.
- [38] Best D J. Extended Tables for Kendall's tau[J]. Biometrika. 1973, 60: 429, 340.
- [39] Bhuchongkul S. A class of nonparametric tests for independence in bivariate populations[J]. Ann. Math. Statist., 1964, 35: 138~149.
- [40] Boss D D. A differential for L-statistics[J]. Ann. Statist., 1979, 7: 955~959.
- [41] Brownlee K A. Statistical Theory and Methodology in Science and Engineering[M]. 2nd Ed. New York: John Wiley. 1965.
- [42] Burr E J. The distribution of Kendall's Score S for a pair of tied rankings [J]. Biometrika, 1960, 47: 151~171.
- [43] Callaert H, Janssen P. The Berry-Esséen theorem for U-statistics[J]. Ann. Statist., 1978, 6: 417~421.
- [44] Capon J. Asymptotic efficiency of certain locally most powerful rank test[J]. Ann. Math. Statist., 1961, 32: 88~100.

- [45] Chernoff H, Gastwirth J L, Johns M V. Jr. Asymptotic distribution of linear combinations of functions of order statistics with applications to estimation[J]. Ann. Math. Statist., 1967, 38: 52~72.
- [46] Chernoff H., Savage I R. Asymptotic normality and efficiency of certain non-parametric test statistics[J]. Ann. Math. Statist., 1958, 2: 972~994.
- [47] Chow Y S. Some convergence theorems for independent random variables[J]. Ann. Math. Statist., 1966, 37: 1 482~1 493.
- [48] Cochran W G. Some Methods for Strengthening the Common χ^2 Test[J]. Biometrics, 1954, 10: 417~451.
- [49] Conover W J. Practical Nonparametric Statistics [M]. 2nd Ed. New York: John Wiley. 1980.
- [50] Cover T M, Hart P E. Nearest neighbor pattern classification[J]. IEEE Trans Inform Theory. IT., 1967, 13: 21~27.
- [51] Cramér H. Mathematical Methods of Statistics[M]. New Jersey: Princeton University Press. 1946.
- [52] Daniel C, Wood F S. Fitting equations to Data[M]. New York: John Wiley, 1971.
- [53] David H A. Order Statistics[M]. 2nd Ed. New York: John Wiley, 1981.
- [54] Devroye L P, Wagner T J. The strong uniform consistency of nearest neighbor density estimates[J]. Ann. Statist., 1977, 5: 536~540.
- [55] Devroye L P, Wagner T J. The strong uniform consistency of kernel density estimates [J]. Multivariate Analysis-V (P. R. Krishnaiah ed.) North-Holland Publishing Company, 1980: 59~77.
- [56] Devroye L P, Wagner T J. Distribution free consistency results in nonparametric discrimination and regression function estimation[J]. Ann. Statist., 1980, 8: 231~239.
- [57] Devroye L P. On the almost everywhere convergence of nonparametric regression function estimates[J]. Ann. Statist., 1981, 9: 1 310~1 319.
- [58] Durbin J. Kolmogorov-Smirnov tests when parameters are estimated with applications to tests of exponentiality and tests on spacings[J]. Biometrika, 1975, 62: 5~22.
- [59] Eddington A S. Stellar Movement and the Structure of Universe [M]. London Macmillan Press, 1914.
- [60] Eddington E S. Probability table for numbers of runs of signs of first differences in order series[J]. J. Amer. Statist. Ass., 1961, 56: 156~159.
- [61] Farrell R H. On the lack of a uniformly consistent sequence of estimators of a density function in certain cases[J]. Ann. Math. Statist., 1967, 38: 471~474.
- [62] Farrell R H. On the best obtainable asymptotic rates of convergence in estimation of a

- density function at a point[J]. *Ann. Math. Statist.*, 1972; 43: 170~180.
- [63] Feller W. *An Introduction to Probability Theory and Its Applications*[M]. New York: John Wiley, 1957.
- [64] Fisher R A. A mathematical examination of the methods of determining the accuracy of an observation by the mean error and the mean square error[J]. *Monthly Not, Roy, Astron. Soc.*, 1920, 80: 758~770.
- [65] Fisher R A. On the mathematical foundations of theoretical statistics[J]. *Phil. Trans. A*, 1922, 222: 309~368.
- [66] Fisher R A. *The Design of Experiments*[M]. Edinburgh, Oliver and Boyd, 1935.
- [67] Fisher R A, Yates F. *Statistical Tables for Biological, Agricultural and Medical Research*[M]. Oliver and Boyd. Edinburgh, 1938.
- [68] Fraser D A S. *Nonparametric Methods of Statistics*[M]. New York: John Wiley, 1957.
- [69] Friedman M. The use of ranks to avoid the assumption of normality implicit in the analysis of variance[J]. *J. Amer. Statist. Ass.*, 1937, 33: 675~701.
- [70] Fritz J. Distribution-free exponential error bound for nearest neighbor pattern classification[J]. *IEEE Trans, Inform. Theory. IT*, 1975, 21: 552~557.
- [71] Galamgbos J. *The Asymptotic Theory of Extreme Order Statistics*[M]. New York: John Wiley, 1978.
- [72] Gilbert R O. A Monte Carlo study of analysis of variance and competing rank tests for Scheffe's Mixed model[J]. *J. Amer. Statist. Ass.*, 1972, 67: 71~75.
- [73] Gnedenko B V, Korolyuk V S. On the maximum discrepancy between two empirical distributions (Russian) *Doklady Akademii Nauk SSSR*[J]. 1951, 80: 525~528.
- [74] Govindarajulu Z, LeGam L, Raghavachari M. Generalizations of theorems of Chernoff and Savage on the asymptotic normality of test statistics[J] // Neyman J, LeCam L. *Proc. Fifth Berkeley Symp. on Math. stat. and Prob.* San Diego: University of California Press, 1966: 609~638.
- [75] Guillier G L. Asymptotic relative efficiencies of rank tests for trend alternatives[D]. Ph. D. Thesis. Univ of Calif. Berkeley, 1972.
- [76] Gumbel E J. *Statistics of Extremes* [M]. New York: Columbia University Press, 1958.
- [77] Hájek J. Some extensions of the Wald-Wolfowitz-Noether theorem[J]. *Ann. Math. Statist.*, 1961, 32: 506~523.
- [78] Hájek J, Šidák Z. *Theory of Rank Tests*[M]. New York: Academic Press, 1967.
- [79] Hájek J. Asymptotic normality of simple linear rank statistics under alternatives[J]. *Ann. Math. Statist.*, 1968, 39: 325~346.

- [80] Hájek J. A Course in Nonparametric Statistics[M]. Holden-Day, San Francisco, 1969.
- [81] Hampel F R. A general qualitative definition of robustness[J]. Ann Math. Statist., 1971, 42: 1 887~1 996.
- [82] Hampel F R. The influence curve and its role in robust estimation[J]. J. Amer. Statist. Assoc., 1974, 62: 1 179~1 186.
- [83] Harter H L. Order Statistics and Their Use in Testing and Estimation[J]. U. S Government Printing Office, Washington. DC, 1970: 1, 2.
- [84] Harter H L, Owen D B. Selected Tables in Mathematical Statistics[J]. Amer. Math. Soc. Providence, 1975: 3.
- [85] Helmers R. The order of the normal approximation for linear combinations of order statistics with smooth weight functions[J]. Ann. Probab., 1977, 5: 940~953.
- [86] Hodges J L Jr, Lehmann E L. Rank methods for combination of independent experiments in analysis of variance[J]. Ann. Math. Statist., 1962, 33: 482~497.
- [87] Hodges J L Jr, Lehmann E L. Estimates of location based on rank tests[J]. Ann. Math. Statist., 1963, 34: 598~611.
- [88] Hoeffding W. A class of statistics with asymptotic normal distribution[J]. Ann. Math. Statist., 1948, 19: 293~325.
- [89] Hoeffding W. Optimum nonparametric tests[J]//Proc. of the Second Berk. Symp. on Math. Statist. and Prob. Berkeley California; University California Press, 1951: 83~92.
- [90] Hoeffding W. Probability inequalities for sums of bounded random variables[J]. J. Amer. Statist. Ass., 1963, 58: 13~30.
- [91] Hollander M, Proschan F. Testing whether new is better than used[J]. Ann. Math. Statist., 1972, 43: 1 136~1 146.
- [92] Hotelling H, Pabst Margaret R. Rank Correlation and Tests of Significance involving no assumption of normality[J]. Ann. Math. Statist., 1936, 7: 29~43.
- [93] Huber P J. Robust estimation of a location parameter[J]. Ann. Math. Statist., 1964, 35: 73~101.
- [94] Huber P J. Robust regression: asymptotics, conjectures and Monte Carlo[J]. Ann. Statist., 1973, 1: 799~821.
- [95] Huber P J. Robust Statistics[M]. New York: John Wiley, 1981.
- [96] Kaarsemaker L, Van Wijngaarden. Tables for use in rank correlation Statistical Neerlandika[J]. 1953, 7: 41~54.
- [97] Kendall M G. A new measure of rank correlation[J]. Biometrika, 1938, 30: 81~93.
- [98] Kendall M G, Sundrum R M. Distribution-free methods and order properties Review

- of the International Statistical Institute[J]. 1953, 21(3): 124~134.
- [99] Kendal M G. Rank Correlation Methods [M]. London: Charles Griffin Company, 1975.
- [100] Klotz J. Nonparametric tests for scale[J]. Ann. Math. Statist., 1962, 33: 498~512.
- [101] Knott M. The small sample power of one-sided Kolmogorov tests for a shift in location of the normal distribution[J]. J. Amer. Statist. Ass., 1970, 65: 1 384 ~ 1 391.
- [102] Kolmogorov A N. Sulla determinazione empirica di una legge di distribuzione[J]. Giorn. dell'Istituto Ital. degli Attuari, 1933, 4: 83~91.
- [103] Kraft C H, Van Eeden C. A Nonparametric Introduction to Statistics[M]. London: Macmillan Press, 1968.
- [104] Kraemer H C. The non-null distribution of the Spearman rank correlation coefficient [J]. J. Amer. Statist. Ass., 1974, 69: 114~117.
- [105] Krishnaiah P R ed. Handbook of Statistics Vol 1 Analysis of Variance North-Holland [M]. 1980.
- [106] Kruskal W H. A nonparametric test for the several sample problem[J]. Ann. Math. Statist., 1952, 23: 525~540.
- [107] Kruskal W H, Wallis W A. Use of ranks in one-criterion variance analysis[J]. J. Amer. Statist. Ass., 1952, 47: 583~621; 1953, 48: 907~911.
- [108] Lee S W. The power of the one-sided and one-sample Kolmogorov-Smirnov test[M]. master's report, Kansas state Univ, 1966.
- [109] Lehmann E L. Consistency and unbiasedness of certain nonparametric tests[J]. Ann. Math. Statist., 1951, 22: 165~179.
- [110] Lehmann E L. Testing statistical hypotheses[M]. New York: John Wiley, 1959.
- [111] Lehmann E L. Robust estimation in analysis of variance[J]. Ann. Math. Statist., 1963, 34: 957~66.
- [112] Lehmann E L. Nonparametrics; Statistical Methods Based on Ranks[M]. Holden-Day, San Francisco, 1975.
- [113] Lilliefors H W. On the Kolmogorov-Smirnov test for normality with mean and variance unknown[J]. J. Amer. Statist. Ass., 1967, 62: 399~402.
- [114] Lilliefors H W. On the Kolmogorov-Smirnov test for exponential distribution with mean unknown[J]. J. Amer. Statist. Ass., 1969, 64: 387~389.
- [115] Loève M. Probability theory[M]. 2nd Ed. Van Nostrand. Princeton, 1960.
- [116] Loftsgaarden D G, Quesenberry C P. A nonparametric estimate of a multivariate density function[J]. Ann. Math. Statist., 1965, 36: 1 049~1 051.

- [117] Mann H B, Whitney D R. On a test of whether one of two random variables is stochastically larger than the other[J]. Ann. Math. Statist., 1947, 18, 50~60.
- [118] Margolin B H, Maurer W. Tests of Kolmogorow-Smirnov type for exponential data with unknown scale and related problems Biometrika[J]. 1976, 63, 149~160.
- [119] Massey F J. A note on the estimation of a distribution function by confidence limits [J]. Ann. Math. Statist., 1950, 21, 116~119.
- [120] Massey F J. A note on the power of a nonparametric test[J]. Ann. Math. Statist., 1950, 21, 440~443.
- [121] Massey F J. Distribution table for the deviation between two sample cumulatives[J]. Ann. Math. Statist., 1952, 23, 435~441.
- [122] Meizler D. Limit distribution for the extreme-order statistics[J]. Canad. Math. Bull, 1978, 21, 447~459.
- [123] Miller L H. Table of percentage points of Kolmogorov Statistics[J]. J. Amer Statist. Ass., 1956, 51, 111~121.
- [124] Mood A M. Introduction to the theory of Statistics[M]. New York: McGraw-Hill, 1950.
- [125] Mood A M. On the asymptotic efficiency of certain nonparametric two-sample tests[J]. Ann. Math. Statist., 1954, 25, 514~522.
- [126] Moore D S. An elementary proof of asymptotic normality of linear function of order Statistics[J]. Ann. Math. Statist., 1968, 39, 263~265.
- [127] Moore D S, Jackel J W. Consistency properties of nearest neighbor density function estimates[J]. Ann. Statist., 1977, 5, 143~154.
- [128] Nadaraya E A. On estimating regression [J]. Theor. Probab. Appl, 1964, 9, 141~142.
- [129] Noether G E. On a theorem by Wald and Wolfowitz[J]. Ann. Math. Statist., 1949, 20, 455~458.
- [130] Noether G E. On a theorem by Pitman[J]. Ann. Math Statist., 1955, 26, 64~68.
- [131] Parzen E. On estimation of a probability density function and mode[J]. Ann. Math. Statist., 1962, 33, 1 065~1 076.
- [132] Pearson E S, Hartley H O. Biometrika Table for Statisticians [M]. London: Cambridge University Press. Vol I 3rd Ed. 1970; Vol II, 1972.
- [133] Petrov V V. Sums of Independent random variables[M]. New York: Springer-Verlag, 1975.
- [134] Pitman E J G. Notes on nonparametric statistical inference[M]. Columbia University Press, 1948.

- [135] Rao C R. Linear Statistical Inference and Its Applications[M]. 2nd Ed. New York: John Wiley, 1973.
- [136] Rejto L, Revesz P. Density estimation and pattern classification[J]. Problems of Control and Information Theory, 1973, 2: 67~80.
- [137] Rijkooort P J, Wise M E. Simple approximations and nomograms for two ranking tests [J]. Indagationes math, 1953, 15: 294~302.
- [138] Robinson J. The large-sample power of permutation tests for randomization models [J]. Ann. Statist., 1973, 1: 291~296.
- [139] Rosenblatt M. Remarks on some nonparametric estimates of a density function[J]. Ann. Math. Statist., 1956, 27: 832~837.
- [140] Sarhan A E, Greenberg B G. (Eds) contribution to Order Statistics[M]. New York: John Wiley, 1962.
- [141] Schneider B E, Clickner R P. On the distribution of the Kolmogorov-Smirnov test statistic for the Gamma distribution with unknown parameters[J]. Dept of Statistics. Temple Univ. Mimeo Series, 1976: 36.
- [142] Schuster E F. Estimation of a probability density function and its derivatives[J]. Ann. Math. Statist., 1969, 40: 1 187~1 195.
- [143] Sen P K. On the distribution of the one-sample rank order statistics. Nonparametric Tech[J]//Puri M L. Statist. Inf. New York: Cambridge Univ. Press, 1970: 53~72.
- [144] Shapiro S S, Wilk M B, Chen H J. A comparative study of various test for normality [J]. J. Amer. Statist. Ass., 1968, 63: 1 343~1 372.
- [145] Shorack G R. Asymptotic normality of linear combinations of functions of order statistics[J]. Ann. Math. Statist., 1969, 40: 2 041~2 050.
- [146] Siegel S, Tukey J W. A nonparametric sum of ranks procedure for relative spread in unpaired samples[J]. J. Amer. Statist Ass., 1960, 55: 429~445; Correction, 1961, 56: 1 005.
- [147] Sillitto G B. The distribution of Kendall's coefficient of rank correlation in rankings containnig ties[J]. Biometrika, 1947, 34: 36~40.
- [148] Singh R S. Improvement on some knowm nonparametric uniformly consistent estimators of derivatives of a density[J]. Ann. Statist., 1977, 5: 394~399.
- [149] Smirnov N V. Estimate of deviation between empirical distribution functions in two independent samples(Russian) Bulletin Moscow Univ[J]. 1939, 2(2): 3~16.
- [150] Smirnov N V. Convergence of distributions of order statistics to the normal distribution[J]. Izv. Akad. Nauk Uz SSR Ser. Fiz-Mat. Nauk., 1966, 10 (3): 24~32.

- [151] Smirnov N V. Some remarks on limit laws for order statistics[J]. Theory Prob and its Application, 1967,12:337~339.
- [152] Spearman C. The proof and measurement of association between two things[J]. Amer. J. Psychol., 1904,15:72~101.
- [153] Spiegelman C, Sacks J. Consistency window estimation in nonparametric regression [J]. Ann. Statist., 1980,8:240~246.
- [154] Spjøtvoll E. A note on robust estimation in analysis of variance[J]. Ann. Math. Statist., 1968,39:1 486~1 492.
- [155] Steck G P. The Smirnov two Sample tests as a rank tests[J]. Ann. Math. Statist., 1969,40:1 449~1 466.
- [156] Stigler S M. Linear functions of order statistics[J]. Ann. Math. Statist., 1969,40: 770~788.
- [157] Stone C J. Consistent nonparametric regression (with discussion)[J]. Ann. Statist., 1977,5:549~645.
- [158] Stout W F. Almost Sure Convergence[M]. New York: Academic Press,1974.
- [159] Stuart A. Asymptotic relative efficiencies of distribution-free tests of randomness against normal alternatives[J]. J. Amer. Statist. Ass., 1954,49:147~157.
- [160] Stuart A. The efficiencies of tests of randomness against normal regression[J]. J. Amer. Statist. Ass., 1956,51:285~287.
- [161] Suzuki G. Kolmogorov-Smirnov tests of fit based on some general bounds[J]. J. Amer. Statist. Ass., 1968,63:919~924.
- [162] Terry M E. Some rank order tests which are most powerful against specific parametric alternatives[J]. Ann. Math. Statist., 1952,23:346~366.
- [163] Tukey J W. A survey of sampling from contaminated distributions [C]. in: Contributions to Probability and Statistics. I. Olkin, Ed., Stanford University press, 1960.
- [164] Van der Waerden B L. Order tests for the two-sample problem and their power[J]. I, II, III, Indagationes math. 1952, 14; 453 ~ 458; 1953, 15; 303 ~ 310, 311 ~ 316; Correction: Indag. 15:80.
- [165] Van der Waerden B L. Testing a distribution function Proc. Konin[J]. Neder, Akad. Van Wetens;A, 1953,56:201~207.
- [166] Van Elteren P, Noether G E. The asymptotic efficiency of the χ^2 -test for a balanced incomplete block design[J]. Biometrika, 1959,46:475~477.
- [167] Van Ryzin J. On strong consistency of density estimates[J]. Ann. Math. Statist., 1969,40:1 765~1 772.
- [168] Von Mises R. On the asymptotic distribution of differentiable statistical functions[J].

- Ann. Math. Statist., 1947, 18: 309~348.
- [169] Wagner T J. Convergence of the Nearest Neighbor rule[J]. IEEE Trans. Inform Theory. IT., 1971, 17: 566~571.
- [170] Wald A, Wolfowitz J. Statistical tests based on permutations of the observations[J]. Ann. Math. Statist., 1944, 15: 358~372.
- [171] Wallace D L. Simplified beta-approximations to the Kurskal-Wallis H-test[J]. J. Amer. Statist. Ass., 1959, 54: 225~230.
- [172] Walsh J E. Handbook of Nonparametric Statistics [M]. New Jersey: Van-Nostrand, 1962.
- [173] Wastson G S. Smooth regression analysis. Sankhya[J]. Ser. A., 1964, 26: 359~372.
- [174] Westenberg J. Significance test for median and interquartile range in Samples from continuous populations of any from[J]. 1948, 51: 252~261.
- [175] Wilcoxon F. Individual comparisons by ranking methods[J]. Biometrics, 1945, 1: 80~83.
- [176] Williams C A. Jr. On the choice of the number and width of classes for the chi-square test of goodness of fit[J]. J. Amer. Statist. Ass., 1950, 45: 77.
- [177] Wolverson C T, Wagner T J. Asymptotically Optimal discrimination functions for pattern classification[J]. IEEE Trans. Inform. Theory. IT., 1969, 15: 258~265.
- [178] Yohai V J, Maronna, R A. Asymptotic Behavior of M-estimators for the linear model[J]. Ann. Statist., 1979, 7: 258~268.

陈希孺文集

《陈希孺统计文选》
《高等数理统计学》
《概率论与数理统计》
《数理统计学教程》
《非参数统计》
《广义线性模型的拟似然法》

定价：38.00元

ISBN 978-7-312-02283-8



9 787312 022838 >